

**BỘ THÔNG TIN VÀ TRUYỀN THÔNG
HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG**



Bài giảng

XỬ LÝ ẢNH

Biên soạn: TS. Đào Thị Thuý Quỳnh
TS. Nguyễn Tất Thắng

2023

LỜI NÓI ĐẦU

Ngày nay, ảnh số đã trở nên hết sức thông dụng. Việc thu nhận ảnh số bằng các thiết bị cá nhân hay chuyên dụng đã trở nên đơn giản hơn. Các hệ thống máy tính cá nhân với tài nguyên tính toán đáp ứng được các tác vụ xử lý ảnh phức tạp cũng rất sẵn có. Các ứng dụng của xử lý ảnh số ngày càng mở rộng và được trang bị ở nhiều nơi từ các ứng dụng gọn nhẹ trên các thiết bị di động cho đến các hệ thống thị giác máy – computer vision v.v. Trong hoàn cảnh đó, xử lý ảnh là một lĩnh vực đã và đang được quan tâm và trở thành môn học chuyên ngành của sinh viên ngành Công nghệ Thông tin trong nhiều trường đại học trên cả nước. Với mong muốn cập nhật nội dung môn học Xử lý ảnh cho sinh viên Khoa Công nghệ Thông tin Học viện Công nghệ Bưu chính Viễn thông, chúng tôi đã thực hiện hiệu chỉnh cập nhật nội dung Bài giảng Xử lý ảnh dựa trên đề cương môn học đã được duyệt.

Nội dung cuốn bài giảng hiệu chỉnh, cập nhật gồm 8 chương:

Chương 1: Nhập môn xử lý ảnh.

Chương 2: Xử lý, nâng cao chất lượng ảnh.

Chương 3: Xử lý ảnh màu.

Chương 4: Xử lý hình thái ảnh.

Chương 5: Phân vùng ảnh.

Chương 6: Trích rút đặc trưng.

Chương 7: Phân loại mẫu ảnh.

Chương 8: Nén dữ liệu ảnh.

Nội dung cuốn Bài giảng chỉnh sửa cập nhật được kế thừa một số phần kiến thức cơ bản từ cuốn Bài giảng Xử lý ảnh 2010 của tác giả Đỗ Năng Toàn, Học viện Công nghệ Bưu chính Viễn thông (các chương 1, 2 và 8) và được cập nhật mới phần lớn theo cuốn sách Xử lý ảnh số - Digital Image Processing, 2017 (tái bản lần thứ 4, là lần tái bản mới nhất) và một sách/giáo trình về xử lý ảnh, thị giác máy tính – computer vision, trí tuệ nhân tạo – artificial intelligence có liên quan (cho các chương 3, 4, 5, 6, 7). Đặc biệt, cuốn giáo trình về xử lý ảnh của tác giả Gonzalez được tái bản nhiều lần và được sử dụng rộng rãi trên thế giới của hai tác giả Rafael C. Gonzalez và Richard E. Woods tại Khoa Điện và Khoa học máy tính, trường đại học Tennessee, Knoxville (UTK), Mỹ.

Các tác giả xin được chân thành cảm ơn Bộ môn Khoa học Máy tính, Khoa Công nghệ Thông tin Học viện Công nghệ Bưu chính Viễn thông và các đồng nghiệp đã động viên, góp ý và giúp đỡ để hoàn chỉnh nội dung cuốn sách.

Chúng tôi xin cảm ơn Lãnh đạo Khoa Công nghệ Thông tin, Học viện Công nghệ Bưu chính Viễn thông đã hỗ trợ và tạo điều kiện cho việc chỉnh sửa, cập nhật bài giảng này.

Mặc dù rất cố gắng nhưng cuốn bài giảng này chắc chắn không tránh khỏi còn những sai sót. Chúng tôi xin trân trọng tiếp thu tất cả những ý kiến đóng góp để có chỉnh lý kịp thời.

Thư góp ý xin gửi về:

Bộ môn Khoa học Máy tính, Khoa Công nghệ Thông tin, Học viện Công nghệ Bưu chính Viễn thông.

Nhóm tác giả.

MỤC LỤC

Chương 1	10
NHẬP MÔN XỬ LÝ ẢNH	10
1.1. Tổng quan về hệ thống xử lý ảnh.....	10
1.2. Những vấn đề cơ bản trong xử lý ảnh.....	11
1.2.1. Một số khái niệm cơ bản.....	11
1.2.2. Nắn chỉnh biến dạng	11
1.2.3. Khử nhiễu	12
1.2.4. Chỉnh số mức xám	12
1.2.5. Phân tích ảnh.....	12
1.2.6. Nhận dạng và phân loại ảnh.....	13
1.2.7. Nén ảnh	13
1.3. Các thiết bị thu nhận ảnh	14
1.4. Lấy mẫu và lượng tử hóa	14
1.4.1. Giai đoạn lấy mẫu	14
1.4.2. Lượng tử hóa.....	15
1.5. Một số phương pháp biểu diễn ảnh.....	15
1.5.1. Mô hình Raster.....	15
1.5.2. Mô hình Vector.....	16
1.6. Một số định dạng ảnh cơ bản.....	16
1.6.1. Định dạng ảnh IMG	16
1.6.2. Định dạng ảnh PCX	17
1.6.3. Định dạng ảnh TIFF.....	18
1.6.4. Định dạng file ảnh BITMAP	19
1.7. Kỹ thuật tái nhận ảnh.....	21
1.7.1. Kỹ thuật chụp ảnh.....	21
1.7.2. Kỹ thuật in ảnh.....	21
1.8. Khái niệm ảnh đen trắng, ảnh màu	23
1.8.1. Phân loại ảnh số	24
1.8.2. Màu sắc	24
Câu hỏi ôn tập và bài tập	25
Chương 2	26
XỬ LÝ NÂNG CAO CHẤT LƯỢNG ẢNH	26
2.1. Cải thiện ảnh sử dụng toán tử điểm	26
2.1.1. Giới thiệu	26

2.1.2. Tăng giảm độ sáng.....	26
2.1.3. Tách ngưỡng	27
2.1.4. Bỏ cụm.....	27
2.1.5. Cân bằng histogram	28
2.1.6. Kỹ thuật tìm tách ngưỡng tự động	28
2.1.7. Biến đổi cấp xám tổng thể	29
2.2. Cải thiện ảnh sử dụng toán tử không gian	31
2.2.1. Phép nhân chập và mẫu	31
2.2.2. Một số mẫu thông dụng	33
2.2.3. Lọc trung vị.....	34
2.2.4. Lọc trung bình.....	36
2.2.5. Lọc trung bình theo k giá trị gần nhất.....	37
2.3. Khôi phục ảnh.....	38
2.3.1. Nhiễu và mô hình nhiễu.....	38
2.3.2. Các loại nhiễu	39
2.3.3. Các kỹ thuật lọc nhiễu	39
Câu hỏi ôn tập và bài tập	42
Chương 3	43
XỬ LÝ ẢNH MÀU	43
3.1. Cơ bản về màu sắc	43
3.2. Các mô hình màu	49
3.2.1. Mô hình RGB.....	49
3.2.2. Mô hình CMY và CMYK.....	50
3.2.3. Mô hình HSI	51
3.2.4. Chuyển đổi từ RGB sang HSI.....	53
3.2.5. Chuyển đổi HSI sang RGB.....	53
3.3. Xử lý ảnh giả màu.....	54
3.3.1. Cắt cường độ sáng và mã hoá màu	54
3.3.2. Các phép biến đổi cường độ sáng thành màu	55
3.4. Cơ bản về xử lý ảnh màu đầy đủ	56
3.5. Các phép biến đổi màu sắc	57
3.5.1. Công thức.....	57
3.5.2. Màu tương phản.....	58
3.5.3. Cắt màu sắc.....	58
3.5.4. Các hiệu chỉnh màu và tông màu.....	59
3.5.5. Xử lý lược đồ xám của ảnh màu	59
3.6. Làm trơn và làm sắc nét ảnh màu	59

3.6.1. Làm trơn ảnh màu.....	59
3.6.2. Làm sắc nét ảnh màu	60
3.7. Sử dụng màu trong phân vùng ảnh màu	60
3.7.1. Phân vùng ảnh trong không gian màu HSI.....	60
3.7.2. Phân vùng ảnh trong không gian màu RGB	61
3.7.3. Phát hiện biên trong ảnh màu	62
3.8. Nhiễu trong ảnh màu.....	63
3.9. Nén ảnh màu	63
Câu hỏi ôn tập và bài tập	64
Chương 4	65
XỬ LÝ HÌNH THÁI ẢNH.....	65
4.1. Giới thiệu	65
4.2. Phép co và phép giãn	67
4.2.1. Phép co.....	67
4.2.2. Phép giãn.....	69
4.3. Phép mở và phép đóng ảnh.....	70
4.4. Phép biến đổi Hit-or-Miss.....	73
4.5 Một số thuật toán hình thái cơ bản.....	76
4.5.1. Trích xuất biên.....	76
4.5.2. Điền đầy vùng trống	77
4.5.3. Trích xuất các thành phần liên thông.....	78
4.5.4. Bao lồi.....	79
4.5.5. Làm mảnh hình	80
4.5.6. Làm dày hình	82
4.5.7. Tìm xương	82
4.5.8. Cắt tia các hình	84
Câu hỏi ôn tập và bài tập	86
Chương 5	87
PHÂN VÙNG ẢNH	87
5.1. Cơ bản về phân vùng ảnh.....	87
5.2. Phát hiện biên, đường, điểm trong ảnh	88
5.2.1. Cơ sở về phát hiện biên, đường, điểm	88
5.2.2. Phát hiện điểm	92
5.2.3. Phát hiện đường	94
5.2.4. Mô hình biên.....	96
5.2.5. Phát hiện biên cơ bản.....	99
5.2.6. Các kỹ thuật nâng cao để phát hiện biên	106

5.3. Phân ngưỡng trong phân vùng ảnh	111
5.3.1. Phân ngưỡng toàn cục đơn giản.....	111
5.3.2. Phương pháp phân ngưỡng tối ưu Otsu	115
5.4. Phân đoạn bằng phát triển vùng, tách vùng và nhất vùng	119
5.4.1. Thuật toán phát triển vùng.....	119
5.4.2. Thuật toán tách vùng và ghép vùng	121
5.5. Phân đoạn vùng bằng cách sử dụng phân cụm và siêu điểm ảnh	123
5.5.1. Phân đoạn vùng sử dụng thuật toán phân cụm K-Means	124
5.5.2. Phân đoạn vùng bằng siêu điểm ảnh - superpixels	125
5.6. Phân đoạn vùng bằng cách cắt đồ thị.....	131
5.6.1. Biểu diễn hình ảnh dưới dạng đồ thị.....	131
5.6.2. Cắt đồ thị tối thiểu	133
5.7. Phân đoạn sử dụng lưu vực hình thái - morphological watersheds.....	138
5.7.1. Kiến trúc nền tảng.....	139
5.7.2. Xây dựng đập – dam construction	142
5.7.3. Thuật toán phân đoạn lưu vực	144
5.7.4. Sử dụng điểm đánh dấu – marker	146
5.8. Sử dụng chuyển động trong phân đoạn ảnh.....	147
5.8.1 Kỹ thuật không gian.....	147
5.8.2 Cách tiếp cận cơ bản	147
5.8.3. Chênh lệch tích lũy	148
5.8.4. Thiết lập một hình ảnh tham chiếu	149
5.8.5. Kỹ thuật miền tần số	150
Câu hỏi ôn tập và bài tập	154
Chương 6	155
TRÍCH RÚT ĐẶC TRƯNG	155
6.1. Cơ sở của trích chọn đặc trưng	155
6.2. Tiền xử lý biên.....	157
6.2.1. Theo dõi biên	158
6.2.2. Mã chuỗi - chain codes	159
6.2.3. Xấp xỉ biên sử dụng đa giác chu vi tối thiểu	163
6.2.4. Biên dạng - signature	167
6.2.5. Xương, trục tâm và các phép biến đổi khoảng cách (Skeletons, Medial Axes, and Distance Transforms).....	169
6.3. Các bộ mô tả đặc trưng biên	171
6.3.1. Một số mô tả biên cơ bản.....	171
6.3.2. Số hình dạng - shape numbers	173
6.3.3. Bộ mô tả Fourier - Fourier descriptors	175

6.3.4. Mô men thống kê - statistical moments	177
6.4. Bộ mô tả đặc điểm vùng	178
6.4.1. Một số mô tả cơ bản.....	178
6.4.2. Kết cấu - texture.....	184
6.4.3. Các cách tiếp cận thống kê - statistical approaches	185
6.4.4. Các tiếp cận phổ - spectral approaches	192
6.4.5. Các bất biến mô men - moment invariants	194
6.5. Các bộ mô tả đặc trưng ảnh sử dụng các thành phần chính – principal components	196
6.6. Các đặc trưng toàn ảnh	201
6.6.1. Bộ phát hiện góc Harris-Stephens	202
6.6.2. Các vùng cực trị ổn định tối đa - maximally stable extremal regions (MSERs)	207
6.7 Phép biến đổi đặc trưng bất biến tỷ lệ - Scale-Invariant Feature Transform (SIFT).....	212
6.7.1. Không gian tỷ lệ - Scale Space	213
6.7.2. Phát hiện cực trị cục bộ.....	216
6.8. Biểu đồ tần xuất gradient định hướng - histogram of oriented gradients (HOG, một dạng SIFT)	226
6.9. Đặc trưng mẫu nhị phân địa phương - local binary patterns (LBP)	227
6.10. Đặc trưng kiểu Haar - Haar-like feature	228
Câu hỏi ôn tập và bài tập	230
Chương 7	231
PHÂN LOẠI MẪU ẢNH.....	231
7.1. Mở đầu.....	231
7.2. Các mẫu và các lớp mẫu	233
7.2.1. Các vector mẫu	233
7.2.2. Các mẫu cấu trúc.....	236
7.3. Phân loại mẫu bằng cách khớp nguyên mẫu.....	237
7.3.1. Bộ phân loại khoảng cách nhỏ nhất hay bộ phân loại láng giềng gần nhất.....	238
7.3.2. Bộ phân loại sử dụng phép tính tương quan cho bài toán khớp nguyên mẫu 2-D	238
7.3.3. Khớp các đặc trưng của phép biến đổi đặc trưng bất biến theo kích thước (phép biến đổi SIFT – Scale-Invariant Feature Transform).....	240
7.3.4. Khớp các nguyên mẫu cấu trúc.....	240
7.4. Support-vector machine (SVM).....	241
7.4.1. Phân loại tuyến tính với lề cực đại.....	241
7.4.2. Kỹ thuật hàm nhân và SVM tổng quát	245
7.4.3. Sử dụng SVM trên thực tế	247
7.5. AdaBoost – Adaptive Boosting	247

7.5.1. Tiếp cận Boosting	248
7.5.2. Thuật toán AdaBoost	249
7.5.3. Sử dụng Adaboost trong thực tế	251
7.6. Bộ phân loại thống kê tối ưu Bayes	252
7.6.1. Xây dựng bộ phân loại Bayes	253
7.6.2. Bộ phân loại Bayes cho các lớp mẫu Gauss	254
7.6.3. Áp dụng mô hình phân loại Bayes trong thực tế	257
7.7. Các mạng nơ-ron - neural networks và học sâu - deep learning	257
7.7.1. Giới thiệu	258
7.7.2. Mạng Perceptron.....	260
7.7.3. Mạng nơ-ron đa tầng lan truyền thẳng.....	266
7.7.4. Lan truyền thẳng qua mạng nơ-ron lan truyền thẳng.....	269
7.7.5. Sử dụng lan truyền ngược - backpropagation để huấn luyện mạng nơ-ron sâu	272
7.8. Các mạng nơ-ron tích chập sâu	277
7.8.1. Kiến trúc cơ bản của mạng CNN	277
7.8.2. Các phương trình lan truyền thẳng trong một mạng CNN	282
7.8.3. Các phương trình lan truyền ngược trong huấn luyện mạng CNN.....	283
7.9. Một số chi tiết bổ sung về cài đặt các phương pháp	286
Câu hỏi ôn tập và bài tập	288
Chương 8	291
NÉN DỮ LIỆU ẢNH	291
8.1. Giới thiệu	291
8.1.1. Một số khái niệm	291
8.1.2. Các loại dữ liệu thừa dữ liệu.....	291
8.1.3. Phân loại phương pháp nén.....	292
8.2. Các phương pháp nén thể hệ thứ nhất.....	293
8.2.1. Phương pháp mã hóa loạt dài.....	293
8.2.2. Phương pháp mã hóa Huffman	293
8.2.3. Phương pháp LZW.....	294
8.2.4. Phương pháp mã hóa khối	296
8.2.5. Phương pháp thích nghi	298
8.2.6. Biến đổi Cosin và chuẩn nén JPEG	298
8.3. Các phương pháp nén thể hệ thứ hai.....	303
8.3.1. Phương pháp Kim tự tháp Laplace - Laplacian Pyramids	303
8.3.2. Phương pháp mã hóa dựa vào biểu diễn ảnh	303
8.4. Kết luận.....	304
Câu hỏi ôn tập và bài tập	306

THƯ VIỆN PTIT

Chương 1

NHẬP MÔN XỬ LÝ ẢNH


Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu khái niệm về ảnh kỹ thuật số.
- ✓ Tìm hiểu tổng quan về cơ sở lịch sử của lĩnh vực xử lý ảnh kỹ thuật số.
- ✓ Hiểu định nghĩa và phạm vi của xử lý ảnh kỹ thuật số.
- ✓ Hiểu biết về cơ bản của quang phổ điện từ và mối quan hệ của nó với quá trình tạo hình ảnh.
- ✓ Nắm được về các lĩnh vực khác nhau mà phương pháp xử lý hình ảnh kỹ thuật số được áp dụng.
- ✓ Quen với các quy trình cơ bản liên quan đến xử lý hình ảnh.
- ✓ Quen với các thành phần tạo nên một hệ thống xử lý hình ảnh kỹ thuật số đa dụng.
- ✓ Quen với phạm vi của tài liệu nơi công việc xử lý hình ảnh được báo cáo.

1.1. Tổng quan về hệ thống xử lý ảnh

Con người thu nhận thông tin qua các giác quan, trong đó thị giác đóng vai trò quan trọng nhất. Những năm trở lại đây với sự phát triển của phần cứng máy tính, xử lý ảnh và đồ họa đã phát triển một cách mạnh mẽ và có nhiều ứng dụng trong cuộc sống. Xử lý ảnh và đồ họa đóng một vai trò quan trọng trong tương tác người máy.


Quá trình xử lý ảnh được xem như là quá trình thao tác ảnh đầu vào nhằm cho ra kết quả mong muốn. Kết quả đầu ra của một quá trình xử lý ảnh có thể là một ảnh “tốt hơn” hoặc một kết luận.



Hình 1.1 Quá trình xử lý ảnh.

Ảnh có thể xem là tập hợp các điểm ảnh và mỗi điểm ảnh được xem như là đặc trưng cường độ sáng hay một dấu hiệu nào đó tại một vị trí nào đó của đối tượng trong không gian và nó có thể xem như một hàm n biến $P(c_1, c_2, \dots, c_n)$. Do đó, ảnh trong xử lý ảnh có thể xem như ảnh n chiều.

Sơ đồ tổng quát của một hệ thống xử lý ảnh:



Hình 1.2 Các bước cơ bản trong một hệ thống xử lý ảnh.

Khối thu nhận ảnh: có nhiệm vụ tiếp nhận ảnh đầu vào.

Khối tiền xử lý: có nhiệm vụ xử lý nâng cao chất lượng ảnh như giảm nhiễu, phân vùng, tìm biên v.v..

Khối trích chọn đặc điểm: có nhiệm vụ trích chọn các đặc trưng quan trọng của các bức ảnh đã được tiền xử lý để sử dụng trong hệ quyết định.

Khối hậu xử lý: có nhiệm vụ xử lý các đặc điểm đã trích chọn, có thể lược bỏ hoặc biến đổi các đặc điểm này để phù hợp với các kỹ thuật cụ thể sử dụng trong hệ quyết định.

Khối hệ quyết định và lưu trữ: có nhiệm vụ đưa ra quyết định (phân loại) dựa trên dữ liệu đã học lưu trong khối lưu trữ.

Khối kết luận: đưa ra kết luận dựa vào quyết định của khối quyết định.

1.2. Những vấn đề cơ bản trong xử lý ảnh

1.2.1. Một số khái niệm cơ bản

* Ảnh và điểm ảnh:


Điểm ảnh được xem như là dấu hiệu hay cường độ sáng tại 1 tọa độ trong không gian của đối tượng và ảnh được xem như là 1 tập hợp các điểm ảnh.

* Mức xám, màu

Là số các giá trị có thể có của các điểm ảnh của ảnh

1.2.2. Nắn chỉnh biến dạng

Ảnh thu nhận thường bị biến dạng do các thiết bị quang học và điện tử.



Hình 1.3 Ảnh thu nhận và ảnh mong muốn.

Để khắc phục người ta sử dụng các phép chiếu, các phép chiếu thường được xây dựng trên tập các điểm điều khiển.

Giả sử (P_i, P_i') $i = \overline{1, n}$ có n các tập điều khiển

Tìm hàm $f: P_i \mapsto f(P_i)$ sao cho

$$\sum_{i=1}^n \|f(P_i) - P_i'\|^2 \rightarrow \min$$

Giả sử ảnh bị biến đổi chỉ bao gồm: Tịnh tiến, quay, tỷ lệ, biến dạng bậc nhất tuyến tính. Khi đó hàm f có dạng:

$$f(x, y) = (a_1x + b_1y + c_1, a_2x + b_2y + c_2)$$

Ta có:

$$\phi = \sum_{i=1}^n (f(P_i) - P_i')^2 = \sum_{i=1}^n [(a_1x_i + b_1y_i + c_1 - x_i')^2 + (a_2x_i + b_2y_i + c_2 - y_i')^2]$$

Để cho $\phi \rightarrow \min$

$$\begin{cases} \frac{\partial \phi}{\partial a_1} = 0 \\ \frac{\partial \phi}{\partial b_1} = 0 \\ \frac{\partial \phi}{\partial c_1} = 0 \end{cases} \Leftrightarrow \begin{cases} \sum_{i=1}^n a_1 x_i^2 + \sum_{i=1}^n b_1 x_i y_i + \sum_{i=1}^n c_1 x_i = \sum_{i=1}^n x_i x'_i \\ \sum_{i=1}^n a_1 x_i y_i + \sum_{i=1}^n b_1 y_i^2 + \sum_{i=1}^n c_1 y_i = \sum_{i=1}^n y_i x'_i \\ \sum_{i=1}^n a_1 x_i + \sum_{i=1}^n b_1 y_i + n c_1 = \sum_{i=1}^n x'_i \end{cases}$$

Giải hệ phương trình tuyến tính tìm được a_1, b_1, c_1

Tương tự tìm được a_2, b_2, c_2

$\Rightarrow$ Xác định được hàm f

1.2.3. Khử nhiễu

Có 2 loại nhiễu cơ bản trong quá trình thu nhận ảnh

- Nhiễu hệ thống: là nhiễu có quy luật có thể khử bằng các phép biến đổi
- Nhiễu ngẫu nhiên: vết bản không rõ nguyên nhân $\rightarrow$ khắc phục bằng các phép lọc

1.2.4. Chỉnh số mức xám

Nhằm khắc phục tính không đồng đều của hệ thống gây ra. Thông thường có 2 hướng tiếp cận:

- Giảm số mức xám: Thực hiện bằng cách nhóm các mức xám gần nhau thành một bó. Trường hợp chỉ có 2 mức xám thì chính là chuyển về ảnh đen trắng. Ứng dụng: In ảnh màu ra máy in đen trắng.
- Tăng số mức xám: Thực hiện nội suy ra các mức xám trung gian bằng kỹ thuật nội suy. Kỹ thuật này nhằm tăng cường độ mịn cho ảnh

1.2.5. Phân tích ảnh

Là khâu quan trọng trong quá trình xử lý ảnh để tiến tới hiểu ảnh. Trong phân tích ảnh việc trích chọn đặc điểm là một bước quan trọng. Các đặc điểm của đối tượng được trích chọn tùy theo mục đích nhận dạng trong quá trình xử lý ảnh. Có thể nêu ra một số đặc điểm của ảnh sau đây:

- **Đặc điểm không gian:** Phân bố mức xám, phân bố xác suất, biên độ, điểm uốn v.v..
- **Đặc điểm biến đổi:** Các đặc điểm loại này được trích chọn bằng việc thực hiện lọc vùng (zonal filtering). Các bộ vùng được gọi là “mặt nạ đặc điểm” (feature mask) thường là các khe hẹp với hình dạng khác nhau (chữ nhật, tam giác, cung tròn v.v..)
- **Đặc điểm biên và đường biên:** Đặc trưng cho đường biên của đối tượng và do vậy rất hữu ích trong việc trích chọn các thuộc tính bất biến được dùng khi nhận dạng đối tượng. Các đặc điểm này có thể được trích chọn nhờ toán tử gradient,

toán tử la bàn, toán tử Laplace, toán tử “chéo không” (zero crossing) v.v..

Việc trích chọn hiệu quả các đặc điểm giúp cho việc nhận dạng các đối tượng ảnh chính xác, với tốc độ tính toán cao và dung lượng nhớ lưu trữ giảm xuống.

1.2.6. Nhận dạng và phân loại ảnh

Nhận dạng tự động (automatic recognition), mô tả đối tượng, phân loại và phân nhóm các mẫu là những vấn đề quan trọng trong thị giác máy, được ứng dụng trong nhiều ngành khoa học khác nhau. Tuy nhiên, một câu hỏi đặt ra là: mẫu (pattern) là gì? Watanabe, một trong những người đi đầu trong lĩnh vực này đã định nghĩa: “Ngược lại với hỗn loạn (chaos), mẫu là một thực thể (entity), được xác định một cách ang áng (vaguely defined) và có thể gán cho nó một tên gọi nào đó”. Ví dụ mẫu có thể là ảnh của vân tay, ảnh của một vật nào đó được chụp, một chữ viết, khuôn mặt người hoặc một ký đồ tín hiệu tiếng nói. Khi biết một mẫu nào đó, để nhận dạng hoặc phân loại mẫu đó có thể:

Hoặc **phân loại có mẫu** (supervised classification), chẳng hạn phân tích phân biệt (discriminant analysis), trong đó mẫu đầu vào được định danh như một thành phần của một lớp đã xác định.

Hoặc **phân loại không có mẫu** (unsupervised classification hay clustering) trong đó các mẫu được gán vào các lớp khác nhau dựa trên một tiêu chuẩn đồng dạng nào đó. Các lớp này cho đến thời điểm phân loại vẫn chưa biết hay chưa được định danh.

Hệ thống nhận dạng tự động bao gồm ba khâu tương ứng với ba giai đoạn chủ yếu sau đây:

- 1°. Thu nhận dữ liệu và tiền xử lý.
- 2°. Biểu diễn dữ liệu.
- 3°. Nhận dạng, ra quyết định.

Bốn cách tiếp cận khác nhau trong lý thuyết nhận dạng là:

- 1°. Đối sánh mẫu dựa trên các đặc trưng được trích chọn.
- 2°. Phân loại thống kê.
- 3°. Đối sánh cấu trúc.
- 4°. Phân loại dựa trên mạng nơ-ron nhân tạo.

Trong các ứng dụng rõ ràng là không thể chỉ dùng có một cách tiếp cận đơn lẻ để phân loại “tối ưu” do vậy cần sử dụng cùng một lúc nhiều phương pháp và cách tiếp cận khác nhau. Do vậy, các phương thức phân loại tổ hợp hay được sử dụng khi nhận dạng và nay đã có những kết quả có triển vọng dựa trên thiết kế các hệ thống lai (hybrid system) bao gồm nhiều mô hình kết hợp.

Việc giải quyết bài toán nhận dạng trong những ứng dụng mới, nảy sinh trong cuộc sống không chỉ tạo ra những thách thức về thuật giải, mà còn đặt ra những yêu cầu về tốc độ tính toán. Đặc điểm chung của tất cả những ứng dụng đó là những đặc điểm đặc trưng cần thiết thường là nhiều, không thể do chuyên gia đề xuất, mà phải được trích chọn dựa trên các thủ tục phân tích dữ liệu.

1.2.7. Nén ảnh

Nhằm giảm thiểu không gian lưu trữ. Thường được tiến hành theo cả hai cách khuynh hướng là nén có bảo toàn và không bảo toàn thông tin. Nén không bảo toàn thì thường có khả năng nén cao hơn nhưng khả năng phục hồi thì kém hơn. Trên cơ sở hai khuynh hướng, có 4 cách tiếp cận cơ bản trong nén ảnh:

- Nén ảnh thống kê: Kỹ thuật nén này dựa vào việc thống kê tần suất xuất hiện của giá trị các điểm ảnh, trên cơ sở đó mà có chiến lược mã hóa thích hợp. Một ví dụ điển hình cho kỹ thuật mã hóa này là *.TIF
- Nén ảnh không gian: Kỹ thuật này dựa vào vị trí không gian của các điểm ảnh để tiến hành mã hóa. Kỹ thuật lợi dụng sự giống nhau của các điểm ảnh trong các vùng gần nhau. Ví dụ cho kỹ thuật này là mã nén *.PCX
- Nén ảnh sử dụng phép biến đổi: Đây là kỹ thuật tiếp cận theo hướng nén không bảo toàn và do vậy, kỹ thuật thường nén hiệu quả hơn. *.JPG chính là tiếp cận theo kỹ thuật nén này.
- Nén ảnh Fractal: Sử dụng tính chất Fractal của các đối tượng ảnh, thể hiện sự lặp lại của các chi tiết. Kỹ thuật nén sẽ tính toán để chỉ cần lưu trữ phần gốc ảnh và quy luật sinh ra ảnh theo nguyên lý Fractal.

1.3. Các thiết bị thu nhận ảnh

Các thiết bị thu nhận ảnh bao gồm camera, scanner các thiết bị thu nhận này có thể cho ảnh đen trắng hoặc ảnh màu.

Các thiết bị thu nhận ảnh có 2 loại chính ứng với 2 loại ảnh thông dụng Raster, Vector.

Các thiết bị thu nhận ảnh thông thường Raster là camera các thiết bị thu nhận ảnh thông thường Vector là sensor hoặc bàn số hoá Digitalizer hoặc được chuyển đổi từ ảnh Raster.


Nhìn chung các hệ thống thu nhận ảnh thực hiện 1 quá trình

- Cảm biến: biến đổi năng lượng quang học thành năng lượng điện (giai đoạn lấy mẫu)
- Tổng hợp năng lượng điện thành ảnh (giai đoạn lượng tử hóa)

1.4. Lấy mẫu và lượng tử hóa

1.4.1. Giai đoạn lấy mẫu

Người ta sử dụng bộ cảm biến hoặc máy quét để biến tín hiệu quang của ảnh thành tín hiệu điện liên tục. Phương pháp sử dụng máy quét phổ biến hơn. Máy quét sẽ quét theo chiều ngang để tạo ra tín hiệu điện của ảnh, kết quả cho ra một tín hiệu điện hai chiều $f(x,y)$ liên tục.



Xét ảnh liên tục được biểu diễn bởi hàm $f(x, y)$, gọi Δx là khoảng cách giữa hai điểm

được giữ lại theo trục x, gọi Δy là khoảng cách giữa hai điểm được giữ lại theo trục y. Δy , Δx được gọi là chu kỳ lấy mẫu theo trục x và y.

Giai đoạn lấy mẫu sẽ biến hàm liên tục $f(x, y) \rightarrow f(n\Delta x, m\Delta y)$. Với m, n là nguyên.

Theo SHANON để đảm bảo không xảy ra hiện tượng chồng phổ, cho phép tái tạo lại ảnh gốc từ ảnh đã số hóa:

- Gọi $f_x = \frac{1}{\Delta x}$ là tần số lấy mẫu theo trục x.

- Gọi $f_y = \frac{1}{\Delta y}$ là tần số lấy mẫu theo trục y.

Để không xảy ra hiện tượng chồng phổ thì tần số lấy mẫu phải ít nhất phải lớn hơn hoặc bằng 2 tần số cao nhất của tín hiệu ảnh. Tức là:

$$f_x \geq 2f_{x_{max}}$$

$$f_y \geq 2f_{y_{max}}$$

Trong đó $f_{x_{max}}, f_{y_{max}}$ là tần số cao nhất của tín hiệu theo trục x, y.

1.4.2. Lượng tử hóa

Ảnh sau khi lấy mẫu sẽ có dạng $f(m, n)$ với m, n là nguyên nhưng giá trị $f(m, n)$ vẫn là giá trị vật lý liên tục. Quá trình biến đổi giá trị $f(m, n)$ thành một số nguyên thích hợp để lưu trữ gọi là lượng tử hoá. Đây là quá trình ánh xạ một biến liên tục u vào biến rời rạc u^* thuộc tập hữu hạn $[u_1, u_2, \dots, u_L]$ xác định trước, L là mức lượng tử hoá được tạo ra.

Ví dụ:

+ Tạo ảnh đa cấp xám thì $L=256$, $f(m, n) = g \in [0, 255]$

+ Tạo ảnh 2^{24} thì $L=2^{24}$, $f(m, n) = g \in [0, 2^{24} - 1]$

1.5. Một số phương pháp biểu diễn ảnh

Ảnh trên máy tính là kết quả thu nhận theo các phương pháp số hoá được nhúng trong các thiết bị kỹ thuật khác nhau. Quá trình lưu trữ ảnh nhằm 2 mục đích:

- Tiết kiệm bộ nhớ
- Giảm thời gian xử lý

Việc lưu trữ thông tin trong bộ nhớ có ảnh hưởng rất lớn đến việc hiển thị, in ấn và xử lý ảnh được xem như là 1 tập hợp các điểm với cùng kích thước nếu sử dụng càng nhiều điểm ảnh thì bức ảnh càng đẹp, càng mịn và càng thể hiện rõ hơn chi tiết của ảnh người ta gọi đặc điểm này là độ phân giải.

Việc lựa chọn độ phân giải thích hợp tùy thuộc vào nhu cầu sử dụng và đặc trưng của mỗi ảnh cụ thể, trên cơ sở đó các ảnh thường được biểu diễn theo 2 mô hình cơ bản.

1.5.1. Mô hình Raster


Đây là cách biểu diễn ảnh thông dụng nhất hiện nay, ảnh được biểu diễn dưới dạng ma trận các điểm (điểm ảnh). Thường thu nhận qua các thiết bị như camera, scanner. Tùy theo yêu cầu thực tế mà mỗi điểm ảnh được biểu diễn qua 1 hay nhiều bit.

Mô hình Raster thuận lợi cho hiển thị và in ấn. Ngày nay công nghệ phần cứng cung

cấp những thiết bị thu nhận ảnh Raster phù hợp với tốc độ nhanh và chất lượng cao cho cả đầu vào và đầu ra. Một thuận lợi cho việc hiển thị trong môi trường Windows là Microsoft đưa ra khuôn dạng ảnh DIB (Device Independent Bitmap) làm trung gian. Hình 1.4 thể hiện quy trình chung để hiển thị ảnh Raster thông qua DIB.

Một trong những hướng nghiên cứu cơ bản trên mô hình biểu diễn này là kỹ thuật nén ảnh các kỹ thuật nén ảnh lại chia ra theo 2 khuynh hướng là nén bảo toàn và không bảo toàn thông tin nén bảo toàn có khả năng phục hồi hoàn toàn dữ liệu ban đầu còn nếu không bảo toàn chỉ có khả năng phục hồi độ sai số cho phép nào đó. Theo cách tiếp cận này người ta đã đề ra nhiều quy cách khác nhau như BMP, TIF, GIF, PCX...

Hiện nay trên thế giới có trên 50 khuôn dạng ảnh thông dụng bao gồm cả trong đó các kỹ thuật nén có khả năng phục hồi dữ liệu 100% và nén có khả năng phục hồi với độ sai số nhận được.



Hình 1.4 Quá trình hiển thị và chỉnh sửa, lưu trữ ảnh thông qua DIB.

1.5.2. Mô hình Vector

Biểu diễn ảnh ngoài mục đích tiết kiệm không gian lưu trữ dễ dàng cho hiển thị và in ấn còn đảm bảo dễ dàng trong lựa chọn sao chép di chuyển tìm kiếm... Theo những yêu cầu này kỹ thuật biểu diễn vector tỏ ra ưu việt hơn.

Trong mô hình vector người ta sử dụng hướng giữa các vector của điểm ảnh lân cận để mã hoá và tái tạo hình ảnh ban đầu ảnh vector được thu nhận trực tiếp từ các thiết bị số hoá như Digital hoặc được chuyển đổi từ ảnh Raster thông qua các chương trình số hoá

Công nghệ phần cứng cung cấp những thiết bị xử lý với tốc độ nhanh và chất lượng cho cả đầu vào và ra nhưng lại chỉ hỗ trợ cho ảnh Raster.

Do vậy, những nghiên cứu về biểu diễn vector đều tập trung từ chuyển đổi từ ảnh Raster.



Hình 1.5 Sự chuyển đổi giữa các mô hình biểu diễn ảnh.

1.6. Một số định dạng ảnh cơ bản

Hiện nay trên thế giới có trên 50 khuôn dạng ảnh thông dụng. Sau đây là một số định dạng ảnh hay dùng trong quá trình xử lý ảnh hiện nay.

1.6.1. Định dạng ảnh IMG

Ảnh IMG là ảnh đen trắng, phần đầu của ảnh IMG có 16 byte chứa các thông tin:

- 6 byte đầu: dùng để đánh dấu định dạng ảnh. Giá trị của 6 byte này viết dưới dạng Hexa: 0x0001 0x0008 0x0001

- 2 byte tiếp theo: chứa độ dài mẫu tin. Đó là độ dài của dãy các byte kề liền nhau mà dãy này sẽ được lặp lại một số lần nào đó. Số lần lặp này sẽ được lưu trong byte đếm. Nhiều dãy giống nhau được lưu trong một byte.
- 4 byte tiếp: mô tả kích cỡ pixel.
- 2 byte tiếp: số pixel trên một dòng ảnh.
- 2 byte cuối: số dòng ảnh trong ảnh.

Ảnh IMG được nén theo từng dòng, mỗi dòng bao gồm các gói (pack). Các dòng giống nhau cũng được nén thành một gói. Có 4 loại gói sau:

- Loại 1: Gói các dòng giống nhau.

Quy cách gói tin này như sau: 0x00 0x00 0xFF Count. Ba byte đầu tiên cho biết số các dãy giống nhau, byte cuối cho biết số các dòng giống nhau.

- Loại 2: Gói các dãy giống nhau.

Quy cách gói tin này như sau: 0x00 Count. Byte thứ hai cho biết số các dãy giống nhau được nén trong gói. Độ dài của dãy ghi ở đầu tệp.

- Loại 3: Dãy các Pixel không giống nhau, không lặp lại và không nén được.

Quy cách gói tin này như sau: 0x80 Count. Byte thứ hai cho biết độ dài dãy các pixel không giống nhau không nén được.

- Loại 4: Dãy các Pixel giống nhau.

Tuỳ theo các bit cao của byte đầu tiên được bật hay tắt. Nếu bit cao được bật (giá trị 1) thì đây là gói nén các byte chỉ gồm bit 0, số các byte được nén được tính bởi 7 bit thấp còn lại. Nếu bit cao tắt (giá trị 0) thì đây là gói nén các byte gồm toàn bit 1. Số các byte được nén được tính bởi 7 bit còn lại.

Các gói tin của file IMG rất đa dạng do ảnh IMG là ảnh đen trắng, do vậy chỉ cần 1 bit cho 1 pixel thay vì 4 hoặc 8 như đã nói ở trên. Toàn bộ ảnh chỉ có những điểm sáng và tối tương ứng với giá trị 1 hoặc 0. Tỷ lệ nén của kiểu định dạng này là khá cao.

1.6.2. Định dạng ảnh PCX

Định dạng ảnh PCX là một trong những định dạng ảnh cổ điển. Nó sử dụng phương pháp mã hoá loạt dài RLE (Run – Length – Encoded) để nén dữ liệu ảnh. Quá trình nén và giải nén được thực hiện trên từng dạng ảnh. Thực tế, phương pháp giải nén PCX kém hiệu quả hơn so với kiểu IMG. Tệp PCX gồm 3 phần: đầu tệp (header), dữ liệu ảnh (Image data) và bảng màu mở rộng.

Header của tệp PCX có kích thước cố định gồm 128 byte và được phân bố như sau:

- 1 byte: chỉ ra kiểu định dạng. Nếu là PCX/PCC thì nó luôn có giá trị là 0Ah.
- 1 byte: chỉ ra version sử dụng để nén ảnh, có thể có các giá trị sau:
 - + 0: version 2.5.
 - + 2: version 2.8 với bảng màu.
 - + 3: version 2.8 hay 3.0 không có bảng màu.
 - + 5: version 3.0 có bảng màu.

- 1 byte: chỉ ra phương pháp mã hoá. Nếu là 0 thì mã hoá theo phương pháp BYTE PACKED, ngược lại là phương pháp RLE.
- 1 byte: Số bit cho một điểm ảnh plane.
- 1 word: toạ độ góc trái của ảnh. Với kiểu PCX nó có giá trị là (0,0), còn PCC thì khác (0,0).
- 1 word: toạ độ góc phải dưới.
- 1 word: kích thước bề rộng và bề cao của ảnh.
- 1 word: số điểm ảnh.
- 1 word: độ phân giải màn hình.
- 1 word.
- 48 byte: chia nó thành 16 nhóm, mỗi nhóm 3 byte. Mỗi nhóm này chứa thông tin về một thanh ghi màu. Như vậy ta có 16 thanh ghi màu.
- 1 byte: không dùng đến và luôn đặt là 0.
- 1 byte: số bit plane mà ảnh sử dụng. Với ảnh 16 màu, giá trị này là 4, với ảnh 256 màu (1pixel/8bits) thì số bit plane lại là 1.
- 1 byte: số bytes cho một dòng quét ảnh.
- 1 word: kiểu bảng màu.
- 58 byte: không dùng.

Định dạng ảnh PCX thường được dùng để lưu trữ ảnh và thao tác đơn giản, cho phép nén và giải nén nhanh. Tuy nhiên, vì cấu trúc của nó cố định, nên trong một số trường hợp làm tăng kích thước lưu trữ. Cũng vì nhược điểm này mà một số ứng dụng sử dụng một kiểu định dạng khác mềm dẻo hơn: định dạng TIFF (Targed Image File Format) sẽ mô tả dưới đây.

1.6.3. Định dạng ảnh TIFF

Kiểu định dạng TIFF được thiết kế để làm nhẹ bớt các vấn đề liên quan đến việc mở rộng tệp ảnh cố định. Về cấu trúc, nó cũng gồm 3 phần chính:

- Phần Header (IFH): có trong tất cả các tệp TIFF và gồm 8 byte:
 - + 1 word: chỉ ra kiểu tạo tệp trên máy tính PC hay máy Macintosh. Hai loại này khác nhau rất lớn ở thứ tự các byte lưu trữ trong các số dài 2 hay 4 byte. Nếu trường này có giá trị là 4D4Dh thì đó là ảnh cho máy Macintosh, nếu là 4949h là của máy PC.
 - + 1 word: version. từ này luôn có giá trị là 42. đây là đặc trưng của file TIFF và không thay đổi.
 - + 2 word: giá trị Offset theo byte tính từ đầu tới cấu trúc IFD là cấu trúc thứ hai của file. Thứ tự các byte này phụ thuộc vào dấu hiệu trường đầu tiên.
- Phần thứ 2 (IFD): Không ở ngay sau cấu trúc IFH mà vị trí được xác định bởi trường Offset trong đầu tệp. Có thể có một hay nhiều IFD cùng tồn tại trong một file. Một IFD bao gồm:

- + 2 byte: chứa các DE (Directory Entry).
- + 12 byte là các DE xếp liên tiếp, mỗi DE chiếm 12 byte.
- + 4 byte: chứa Offset trở tới IFD tiếp theo. Nếu đây là IFD cuối cùng thì trường này có giá trị 0.
- Phần thứ 3: các DE: các DE có độ dài cố định gồm 12 byte và chia làm 4 phần:
 - + 2 byte: chỉ ra dấu hiệu mà tệp ảnh đó được xây dựng.
 - + 2 byte: kiểu dữ liệu của tham số ảnh. Có 5 kiểu tham số cơ bản:
 - 1: BYTE (1 byte)
 - 2: ASCII (1 byte)
 - 3: SHORT (2 byte).
 - 4: LONG (4 byte)
 - 5: RATIONAL (8 byte)
 - + 4 byte: trường độ dài chưa số lượng chỉ mục của kiểu dữ liệu đó chỉ ra. Nó không phải là tổng số byte cần thiết để lưu trữ. Để có số liệu này ta cần nhân số chỉ mục với kiểu dữ liệu đã dùng.
 - + 4 byte: đó là Offset tới điểm bắt đầu dữ liệu liên quan tới dấu hiệu, tức là liên quan với DE không phải lưu trữ vật lý cùng với nó nằm ở một vị trí nào đó trong file.

Dữ liệu chứa trong tệp thường được tổ chức thành các nhóm dòng (cột) quét của dữ liệu ảnh. Cách tổ chức này làm giảm bộ nhớ cần thiết cho việc đọc tệp. Việc giải nén được thực hiện theo 4 kiểu khác nhau được lưu trữ trong byte dấu hiệu nén.

1.6.4. Định dạng file ảnh BITMAP

Mỗi file BITMAP gồm đầu file chứa các thông tin chung về file, đầu thông tin chứa các thông tin về ảnh, một bảng màu và một mảng dữ liệu ảnh. Khuôn dạng được cho như sau:

BITMAPFILEHEADER	bmfh;
BITMAPINFOHEADER	bmih;
RGBQUAD	aColors[];
BYTE	aBitmapBits[];

Trong đó, các cấu trúc được định nghĩa như sau:

```
typedef struct tagBITMAPFILEHEADER { /* bmfh */
    UINT        bfType;
    DWORD       bfSize;
    UINT        bfReserved1;
    UINT        bfReserved2;
    DWORD       bfOffBits;
} BITMAPFILEHEADER;
```



```
typedef struct tagBITMAPINFOHEADER { /* bmih */
    DWORD    biSize;
    LONG     biWidth;
    LONG     biHeight;
    WORD     biPlanes;
    WORD     biBitCount;
    DWORD    biCompression;
    DWORD    biSizeImage;
    LONG     biXPelsPerMeter;
    LONG     biYPelsPerMeter;
    DWORD    biClrUsed;
    DWORD    biClrImportant;
} BITMAPINFOHEADER, *LPBITMAPINFOHEADER;
```

với

biSize	kích thước của BITMAPINFOHEADER
biWidth	Chiều rộng của ảnh, tính bằng số điểm ảnh
biHeight	Chiều cao của ảnh, tính bằng số điểm ảnh
biPlanes	Số plane của thiết bị, phải bằng 1
biBitCount	Số bit cho một điểm ảnh
biCompression	Kiểu nén
biSizeImage	Kích thước của ảnh tính bằng byte
biXPelsPerMeter	độ phân giải ngang của thiết bị, tính bằng điểm ảnh trên met
biYPelsPerMeter	độ phân giải dọc của thiết bị, tính bằng điểm ảnh trên met
biClrUsed	Số lượng các màu thực sự được sử dụng
biClrImportant	Số lượng các màu cần thiết cho việc hiển thị, bằng 0 nếu tất cả các màu đều cần để hiển thị

Nếu `bmih.biBitCount > 8` thì mảng màu `rgbq[]` trống, ngược lại thì mảng màu có $2^{bmih.biBitCount}$ phần tử.

```
typedef struct tagRGBQUAD { /* rgbq */
    BYTE    rgbBlue;
    BYTE    rgbGreen;
    BYTE    rgbRed;
    BYTE    rgbReserved;
} RGBQUAD;
```


Ta cũng có:

```
typedef struct tagBITMAPINFO {  
    BITMAPINFOHEADER    bmiHeader;  
    RGBQUAD             bmiColors[1];  
} BITMAPINFO, *PBITMAPINFO;
```

1.7. Kỹ thuật tái nhận ảnh

1.7.1. Kỹ thuật chụp ảnh

Phương pháp sao chụp ảnh là phương pháp đơn giản, giá thành thấp, chất lượng cao. Sau bước chụp là kỹ thuật phòng tối nhằm tăng cường ảnh như mong muốn. Ví dụ kỹ thuật phòng tối như: phóng đại ảnh, thu nhỏ ảnh..., tùy theo ứng dụng. Kỹ thuật chụp ảnh màn hình màu khá đơn giản. Nó bao gồm các bước sau:

- Đặt camera trong phòng tối, cách màn hình khoảng 10 feet (1foot=0,3048m)
- Mở ống kính để phẳng mặt cong màn hình, do vậy ảnh sẽ dần đều hơn
- Tắt phím sáng tối (Brightness) và phím tương phản (Contrast) của màn hình để tạo độ rõ cho ảnh. Các màu chói, cường độ cao trên ảnh sẽ giảm đi.
- Đặt tốc độ ống kính từ 1/8 đến 1/2 giây.

1.7.2. Kỹ thuật in ảnh

Người ta dùng kỹ thuật nửa cường độ để thể hiện ảnh trên sách báo, tạp chí. Theo kỹ thuật này, một ảnh tạo nên bởi một chuỗi các điểm in trên giấy. Thực chất, mỗi điểm ảnh thường gồm một hình vuông trắng bao quanh một chấm đen. Do vậy, nếu chấm đen càng lớn ảnh sẽ càng xảm màu. Màu xám có thể coi như chấm đen chiếm nửa vùng trắng. Vùng trắng là vùng gồm một chùm các điểm ảnh có rất ít hoặc không có chấm đen.

Từ đặc điểm cảm nhận của mắt người, sự thay đổi cường độ chấm đen trong các phần tử ảnh trắng tạo nên mô phỏng của một ảnh liên tục. Như vậy, mắt người cảm nhận từ một ảnh mà màu biến đổi từ đen qua xám rồi đến trắng. Tổng số cường độ duy nhất hiện diện sẽ xác định các kích thước khác nhau của chấm đen. Thông thường, báo ảnh tạo ảnh nửa cường độ với độ phân giải từ 60 đến 80 DPI (dot per inchs: số điểm ảnh trên một inch), sách có thể in đến 150 DPI.

Tuy nhiên, các máy in ghép nối với máy tính không có khả năng sắp xếp các chấm đen có kích thước khác nhau của ảnh. Do đó, người ta dùng một số kỹ thuật biến đổi như: phân ngưỡng, chọn mẫu, dithering (dithering sẽ định nghĩa dưới đây).

a) Phân ngưỡng

Kỹ thuật này đặt ngưỡng để hiển thị các tông màu liên tục. Các điểm trong ảnh được so sánh với ngưỡng định trước. Giá trị của ngưỡng sẽ quyết định điểm có được hiển thị hay không.

Do vậy ảnh kết quả sẽ mất đi một số chi tiết. Có nhiều kỹ thuật chọn ngưỡng áp dụng cho các đối tượng khác nhau:

- Hiển thị 2 màu: chỉ dùng ảnh đen trắng có 256 mức xám. Bản chất của phương pháp này là chọn ngưỡng dựa trên lược đồ mức xám của ảnh. Để đơn giản có thể lấy ngưỡng với giá trị là 127. Như vậy:

$$u(m,n) = \begin{cases} 1 & \text{nếu } h(m,n) \leq 127 \\ 0 & \text{nếu khác} \end{cases}$$

trong đó $u(m, n)$ là mức xám tại tọa độ (m, n) .

Nhìn chung kỹ thuật này khó chấp nhận vì ảnh mất khá nhiều chi tiết.

- Hiện thị 4 màu: hiện 4 màu để khắc phục nhược điểm của kỹ thuật hiện thị 2 màu. Một ví dụ của Bảng mã 4 màu được cho ở Bảng 1.1.

Mã màu	Màn hình monochrome (đơn sắc)	Màn hình màu
0	Đen	Đen
1	Xám đậm	Đỏ
2	Xám nhạt	Xanh
3	Trắng	Vàng

Bảng 1.1 Bảng mã 4 màu.

b) Kỹ thuật chọn theo mẫu

Kỹ thuật này sử dụng một nhóm các phần tử trên thiết bị ra (máy in chẳng hạn) để biểu diễn một pixel trên ảnh nguồn. Các phần tử của nhóm quyết định độ sáng tối của cả nhóm. Các phần tử này mô phỏng các chấm đen trong kỹ thuật nửa cường độ. Nhóm thường được chọn có dạng ma trận vuông. Nhóm $n \times n$ phần tử sẽ tạo nên $n^2 + 1$ mức sáng. Ma trận mẫu thường được chọn là ma trận Rylander. Ma trận Rylander cấp 4 có dạng như Bảng 1.2.

0	8	2	10
4	12	6	14
3	11	1	9
7	15	5	13

Bảng 1.2 Ma trận Rylander cấp 4.

Việc chọn kích thước của nhóm như vậy sẽ làm giảm độ mịn của ảnh. Vì vậy kỹ thuật này chỉ áp dụng trong trường hợp mà độ phân giải của thiết bị ra lớn hơn độ phân giải của ảnh nguồn.

Ví dụ: thiết bị ra có độ phân giải 640x480 khi sử dụng nhóm có kích thước 4x4 sẽ chỉ còn 160x120.

c) Kỹ thuật Dithering

Dithering là việc biến đổi một ảnh đa cấp xám (nhiều mức sáng tối) sang ảnh nhị phân (hai mức sáng tối). Kỹ thuật Dithering được áp dụng để tạo ra ảnh đa cấp sáng khi độ phân giải nguồn và đích là như nhau. Kỹ thuật này sử dụng một ma trận mẫu gọi là ma trận Dither.

Ma trận này gần giống như ma trận Rylander.

Để tạo ảnh, mỗi phần tử của ảnh gốc sẽ được so sánh với phần tử tương ứng của ma trận Dither. Nếu lớn hơn, phần tử ở đầu ra sẽ sáng và ngược lại.

d) Kỹ thuật khuếch tán lỗi (Error diffusion)

Khuếch tán lỗi cho phép giảm thiểu mức độ mất chi tiết của ảnh khi tách ngưỡng bằng cách phân tán lỗi do lượng tử hóa ra các điểm ảnh xung quanh. Bằng cách này tổng giá trị điểm ảnh của một vùng nhỏ được giữ tương đối gần với giá trị trên ảnh gốc.

Khuếch tán lỗi có hai dạng, khuếch tán lỗi một chiều và khuếch tán lỗi hai chiều. Khuếch tán lỗi một chiều chỉ phân tán lỗi sang điểm ảnh lân cận trên cùng một dòng trong khi đó khuếch tán lỗi hai chiều phân tán lỗi sang các điểm ảnh lân cận theo một tỷ lệ xác định bởi một ma trận khuếch tán lỗi.

Kỹ thuật khuếch tán lỗi một chiều:

- o Ảnh được duyệt từ trái qua phải, từ trên xuống dưới.
 - o Tại mỗi điểm ảnh, giá trị điểm ảnh được tách theo ngưỡng có sẵn.
 - o Phần dư do lượng tử hóa được chuyển sang điểm ảnh tiếp theo trên cùng dòng.
- Các bước được lặp lại cho đến hết dòng, phần dư của điểm ảnh cuối cùng sẽ được loại bỏ.

Kỹ thuật khuếch tán lỗi hai chiều:

- o Các bước được thực hiện như khuếch tán lỗi một chiều, tuy nhiên lỗi do lượng tử hóa sẽ được phân tán ra các điểm xung quanh theo tỷ lệ xác định bởi ma trận khuếch tán.
- o Có hai ma trận phổ biến (Hình 1.5):

Ma trận của Floyd và Steinberg.

Ma trận của J F Jarvis, C N Judice, và W H Ninke tại phòng thí nghiệm Bell.

$$\frac{1}{16} \begin{bmatrix} - & \# & 7 \\ 3 & 5 & 1 \end{bmatrix}$$

Floyd và Steinberg

$$\frac{1}{48} \begin{bmatrix} - & - & \# & 7 & 5 \\ 3 & 5 & 7 & 5 & 3 \\ 1 & 3 & 5 & 3 & 1 \end{bmatrix}$$

Phòng thí nghiệm Bell

Hình 1.5 Ma trận khuếch tán lỗi,

Trong đó "#" chỉ điểm đang xét và "□" chỉ các điểm đã xét, các con số chỉ tỷ lệ lỗi được phân tán từ điểm hiện tại.

1.8. Khái niệm ảnh đen trắng, ảnh màu

Ảnh trong thực tế là một ảnh liên tục về không gian và giá trị cường độ sáng. Để có thể xử lý ảnh bằng máy tính người ta cần thiết phải số hóa ảnh. Trong quá trình số hóa, ta biến đổi tín hiệu liên tục sang tín hiệu rời rạc thông qua quá trình lấy mẫu (rời rạc hóa về không gian) và lượng tử hóa thành phần giá trị mà về nguyên tắc bằng mắt thường không phân biệt được hai điểm kề nhau. Một ảnh sẽ là một tập hợp các phần tử ảnh (Picture element) hay còn được gọi là Pixel.

Như vậy, ảnh số là một tập hợp các điểm ảnh. Khi được số hóa, nó thường được biểu diễn bởi một mảng hai chiều $I(n,p)$ với n là số dòng và p là số cột. Ta nói ảnh gồm $n \times p$ pixels.

Người ta thường ký hiệu $I(x,y)$ để chỉ một pixel I chính là giá trị cường độ sáng của ảnh tại pixel đó. ảnh có thể được biểu diễn với các độ phân giải khác nhau. Một pixel có thể được lưu trữ trên 1, 4, 8 hay 24 bit tùy thuộc vào các mức cường độ sáng cần phân biệt của ảnh và số lượng thành phần màu cơ bản chứa trong ảnh đó.

1.8.1. Phân loại ảnh số

Người ta thường chia ảnh số ra làm ba loại chính là:

- Ảnh đen trắng: Mỗi phần tử ảnh nhận một trong hai giá trị tương ứng với hai mức sáng đen và trắng (còn gọi là ảnh nhị phân)
- Ảnh xám (ảnh đa mức xám): Các phần tử ảnh chứa thông số về cường độ sáng đã được mã hoá thành N mức (8, 256 hoặc nhiều hơn) tương ứng với 3 bit, 8 bit hoặc hơn nữa. ảnh xám có một đặc trưng là lược đồ xám (histogram). Ảnh xám được gọi là ảnh grayscale.
- Ảnh màu: Mỗi phần tử ảnh được lưu trữ trong ảnh dưới dạng một cấu trúc có 3 trường chứa thông tin về 3 màu cơ bản là đỏ, xanh, lơ (red, blue, green). Màu của ảnh sẽ là tổng hợp của 3 giá trị trên. Mỗi trường biểu diễn giá trị màu có thể dùng 8 bit, 16 bit hoặc 24 bit để mã hoá.

Như vậy ảnh màu là ảnh mang thông tin về đối tượng đầy đủ nhất so với ảnh đen trắng và ảnh xám. Tuy nhiên tất cả cách biểu diễn này đều chỉ là sự mô phỏng hệ màu trong tự nhiên. Thực tế thì một màu được phân biệt qua 3 thuộc tính là độ chói (Brightness), sắc thái màu (Hue) và độ bão hoà (Saturation). Tuy nhiên với khả năng cảm nhận của mắt người thì cách biểu diễn ảnh dưới dạng cấu trúc 3 màu RGB chất lượng ảnh thu được là có thể chấp nhận được.

1.8.2. Màu sắc

Mắt người có thể phân biệt được vài chục màu nhưng chỉ có thể cảm nhận được hàng ngàn màu. Ba thuộc tính của một màu đó là: Sắc (Hue), Độ thuần khiết (Saturation), và độ sáng hay độ chói (Intensity).

Trong xử lý ảnh và đồ họa, mô hình màu là một chỉ số kỹ thuật của một hệ tọa độ màu 3 chiều với tập các màu nhỏ thành phần có thể trông thấy được trong hệ thống tọa độ màu thuộc một gam màu đặc trưng. Ví dụ như mô hình màu RGB (Red, Green, Blue): là một đơn vị tập các màu thành phần sắp xếp theo hình lập phương của hệ trục tọa độ Đề các.

Mục đích của mô hình màu là cho phép các chỉ số kỹ thuật quy ước của một số loại màu sắc thích hợp với các màu sắc của một số gam màu khác. Chúng ta có thể nhìn thấy trong mô hình màu này, không gian màu là một tập hợp nhỏ hơn của không gian các màu có thể nhìn thấy được, vì vậy một mô hình màu không thể được sử dụng để định rõ tất cả có thể nhìn thấy. Trong chương 3, ta xem xét một số mô hình hay được sử dụng nhất.

Câu hỏi ôn tập và bài tập

Bài tập 1

Thế nào là mô hình Raster và Vector? Trình bày sự giống và khác nhau của hai mô hình này.

Bài tập 2

Nêu các định dạng ảnh phổ biến. Trình bày cách nén ảnh của định dạng ảnh BITMAP.

Bài tập 3

Kỹ thuật khuếch tán lỗi (Error diffusion) là gì? Thực hiện khuếch tán lỗi một chiều với ảnh sau, được biết ngưỡng là 127.

$$I = \begin{bmatrix} 1 & 23 & 156 & 22 & 45 \\ 133 & 13 & 12 & 12 & 212 \\ 12 & 232 & 127 & 32 & 21 \end{bmatrix}$$

Bài tập 4

Kỹ thuật khuếch tán lỗi hai chiều khác gì với một chiều. Thực hiện khuếch tán lỗi hai chiều với ảnh ở Bài tập 3 sử dụng ma trận khuếch tán lỗi Floyd và Steinberg, được biết ngưỡng là 127.

Bài tập 5

Bạn được yêu cầu thiết kế một hệ thống chụp ảnh để nghiên cứu các hình dạng biên của tế bào, vi khuẩn, virus và protein. Ở đây hệ thống bao gồm nguồn sáng và máy ảnh. Đường kính của các hình tròn cần để bao quanh từng mẫu trong mỗi nhóm này tương ứng là 50, 1, 0.1 và 0.01 micromet.

(a) Bạn có thể giải quyết bài toán chụp ảnh như thế này bằng một cảm biến và máy ảnh duy nhất không? Nếu câu trả lời là có, cho biết dải bước sóng ánh sáng và loại máy ảnh cần thiết. Xác định máy ảnh cụ thể là một máy ảnh màu, máy ảnh dải trên hồng ngoại (far infrared), hoặc bất kỳ tên nào tương ứng theo nguồn sáng.

(b) Nếu câu trả lời ở (a) là không, bạn hãy đề xuất loại nguồn sáng và cảm biến hình ảnh tương ứng? Xác định nguồn sáng và máy ảnh theo yêu cầu ở phần (a). Sử dụng số nguồn sáng và máy ảnh ít nhất để giải quyết bài toán.

Bài tập 6

Một cảm biến camera CCD có kích thước 7x7 mm, với 1024x1024 điểm ảnh, được dùng để chụp ảnh một vùng vuông, phẳng, cách xa 0.5 m. Máy ảnh với cảm biến này có thể chụp được ảnh có bao nhiêu cặp đường mỗi mm (mà vẫn phân biệt được các đường thẳng)? Máy ảnh này được trang bị một ống kính 35 mm (tiêu cự của thấu kính là 35 mm).

Bài tập 7

Một nhà sản xuất ô tô đang tự động hóa việc đặt các cấu kiện nhất định lên trên cản của dòng xe thể thao phiên bản giới hạn – limited edition. Các thành phần được phối màu, vì vậy robot cần biết màu của mỗi chiếc xe để chọn cấu kiện phù hợp cho cản. Mẫu xe chỉ có bốn màu: xanh da trời, xanh lá cây, đỏ và trắng. Bạn được đề nghị đề xuất một giải pháp sử dụng kỹ thuật chụp ảnh. Làm thế nào bạn có thể giải quyết vấn đề xác định tự động màu sắc của mỗi chiếc xe (với chi phí tối thiểu)?

Chương 2

XỬ LÝ NÂNG CAO CHẤT LƯỢNG ẢNH

Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu ý nghĩa của xử lý theo miền không gian – spatial domain và sự khác biệt so với xử lý trên miền biến đổi – transform domain.
- ✓ Quen thuộc với các kỹ thuật cơ bản được sử dụng cho các phép biến đổi cường độ sáng.
- ✓ Hiểu ý nghĩa vật lý của lược đồ xám của ảnh và cách chúng có thể được biến đổi để tăng cường ảnh.
- ✓ Hiểu cơ chế của bộ lọc không gian và cách tạo ra các bộ lọc không gian.
- ✓ Hiểu nguyên lý của phép tính tích chập và phép tính tương quan không gian.
- ✓ Quen thuộc với các loại bộ lọc không gian cơ bản và cách áp dụng các bộ lọc đó.
- ✓ Hiểu được về các mối quan hệ giữa các bộ lọc không gian và nắm được vai trò cơ bản của bộ lọc thông thấp.
- ✓ Hiểu cách sử dụng kết hợp các phép tăng cường ảnh trong những trường hợp mà một phép đơn lẻ là không đủ.

2.1. Cải thiện ảnh sử dụng toán tử điểm

2.1.1. Giới thiệu

Các phép toán không phụ thuộc không gian là các phép toán không phụ thuộc vị trí của điểm ảnh. Ví dụ: Phép tăng giảm độ sáng, phép thống kê tần suất, biến đổi tần suất v.v..

Một trong những khái niệm quan trọng trong xử lý ảnh là biểu đồ tần suất (Histogram):

Biểu đồ tần suất của mức xám g của ảnh I là số điểm ảnh có giá trị g của ảnh I . Ký hiệu là $h(g)$

Ví dụ:

$$I = \begin{pmatrix} 1 & 2 & 0 & 4 \\ 1 & 0 & 0 & 7 \\ 2 & 2 & 1 & 0 \\ 4 & 1 & 2 & 1 \\ 2 & 0 & 1 & 1 \end{pmatrix}$$

g	0	1	2	4	7
$h(g)$	5	7	5	2	1

2.1.2. Tăng giảm độ sáng

Giả sử ta có I kích thước $m \times n$ và số nguyên c

Khi đó, kỹ thuật tăng, giảm độ sáng được thể hiện

for ($i = 0$; $i < m$; $i++$)

for ($j = 0$; $j < n$; $j++$)

$I[i, j] = I[i, j] + c$;

- Nếu $c > 0$: ảnh sáng lên
- Nếu $c < 0$: ảnh tối đi

2.1.3. Tách ngưỡng

Giả sử ta có ảnh I ~ kích thước $m \times n$, hai số Min, Max và ngưỡng θ khi đó: Kỹ thuật tách ngưỡng được thể hiện

```
for (i = 0; i < m; i++)
    for (j = 0; j < n; j++)
        I[i, j] = I[i, j] >=  $\theta$ ? Max: Min;
```

***Ứng dụng:**


Nếu Min = 0, Max = 1 kỹ thuật chuyển ảnh thành ảnh đen trắng được ứng dụng khi quét và nhận dạng văn bản có thể xảy ra sai sót nên thành ảnh hoặc ảnh thành nền dẫn đến ảnh bị đứt nét hoặc dính.

2.1.4. Bó cụm

Kỹ thuật nhằm giảm bớt số mức xám của ảnh bằng cách nhóm lại số mức xám gần nhau thành 1 nhóm

Nếu chỉ có 2 nhóm thì chính là kỹ thuật tách ngưỡng. Thông thường có nhiều nhóm với kích thước khác nhau.

Để tổng quát khi biến đổi người ta sẽ lấy cùng 1 kích thước bunch_size



$$I[i, j] = I[i, j] / \text{bunch_size} * \text{bunch_size} \quad \forall (i, j)$$

Ví dụ: Bó cụm ảnh sau với bunch_size=3

$$I = \begin{pmatrix} 1 & 2 & 4 & 6 & 7 \\ 2 & 1 & 3 & 4 & 5 \\ 7 & 2 & 6 & 9 & 1 \\ 4 & 1 & 2 & 1 & 2 \end{pmatrix}$$

$$I_{kq} = \begin{pmatrix} 0 & 0 & 3 & 6 & 6 \\ 0 & 0 & 3 & 3 & 3 \\ 6 & 0 & 6 & 9 & 0 \\ 3 & 0 & 0 & 0 & 0 \end{pmatrix}$$

2.1.5. Cân bằng histogram

Ảnh I được gọi là cân bằng "lý tưởng" nếu với mọi mức xám g, g' ta có $h(g) = h(g')$

Giả sử, ta có ảnh $I \sim$ kích thước $m \times n$

$new_level \sim$ số mức xám của ảnh cân bằng

$TB = \frac{m \times n}{new_level} \sim$ số điểm ảnh trung bình của mỗi mức xám của ảnh cân bằng

$$t(g) = \sum_{i=0}^g h(i) \sim \text{số điểm ảnh có mức xám} \leq g$$

Xác định hàm $f: g \mapsto f(g)$

$$\text{Sao cho: } f(g) = \max \left\{ 0, \text{round} \left(\frac{t(g)}{TB} \right) - 1 \right\}$$

Ví dụ: Cân bằng ảnh sau với $new_level = 4$

$$I = \begin{pmatrix} 1 & 2 & 4 & 6 & 7 \\ 2 & 1 & 3 & 4 & 5 \\ 7 & 2 & 6 & 9 & 1 \\ 4 & 1 & 2 & 1 & 2 \end{pmatrix}$$

g	h(g)	t(g)	f(g)
1	5	5	0
2	5	10	1
3	1	11	1
4	3	14	2
5	1	15	2
6	2	17	2
7	2	19	3
9	1	20	3

$$I_{kq} = \begin{pmatrix} 0 & 1 & 2 & 2 & 3 \\ 1 & 0 & 1 & 2 & 2 \\ 3 & 1 & 2 & 3 & 0 \\ 2 & 0 & 1 & 0 & 1 \end{pmatrix}$$

Chú ý: Ảnh sau khi thực hiện cân bằng chưa chắc đã là cân bằng "lý tưởng".

2.1.6. Kỹ thuật tìm tách ngưỡng tự động

Ngưỡng θ trong kỹ thuật tách ngưỡng thường được cho bởi người sử dụng. Kỹ thuật

tìm tách ngưỡng tự động nhằm tìm ra ngưỡng θ một cách tự động dựa vào histogram theo nguyên lý trong vật lý là vật thể tách làm 2 phần nếu tổng độ lệnh trong từng phần là tối thiểu.

Giả sử, ta có ảnh

$I \sim$ kích thước $m \times n$

$G \sim$ là số mức xám của ảnh kể cả khuyết thiếu

$t(g) \sim$ số điểm ảnh có mức xám $\leq g$

$$m(g) = \frac{1}{t(g)} \sum_{i=0}^g i \cdot h(i) \sim \text{mômen quán tính TB có mức xám } \leq g$$

Hàm $f: g \mapsto f(g)$

$$f(g) = \frac{t(g)}{m \times n - t(g)} [m(g) - m(G-1)]^2$$

Tìm θ sao cho:

$$f(\theta) = \max_{0 \leq g < G-1} \{f(g)\}$$

Ví dụ: Tìm ngưỡng tự động của ảnh sau

$$I = \begin{pmatrix} 0 & 1 & 2 & 3 & 4 & 5 \\ 0 & 0 & 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

Lập bảng:

g	$h(g)$	$t(g)$	$g \cdot h(g)$	$\sum_{i=0}^g i \cdot h(i)$	$m(g)$	$f(g)$
0	15	15	0	0	0	1.35
1	5	20	5	5	0,25	1.66
2	4	24	8	13	0,54	1.54
3	3	27	9	22	0,81	1.10
4	2	29	8	30	1,03	0.49
5	1	30	5	35	1,16	∞

Ngưỡng cần tách $\theta = 1$ ứng với $f(\theta) = 1.66$

2.1.7. Biến đổi cặp xám tổng thể

Nếu biết ảnh và hàm biến đổi thì ta có thể tính được ảnh kết quả và do đó ta sẽ có được histogram của ảnh biến đổi. Nhưng thực tế nhiều khi ta chỉ biết histogram của ảnh gốc và hàm biến đổi, câu hỏi đặt ra là liệu ta có thể có được histogram của ảnh biến đổi. Nếu có như vậy ta có thể hiệu chỉnh hàm biến đổi để thu được ảnh kết quả có phân bố histogram như

mong muốn.


Bài toán đặt ra là biết histogram của ảnh, biết hàm biến đổi hãy vẽ histogram của ảnh mới.

Ví dụ:


g	1	2	3	4
$H(g)$	4	2	1	2

$$f(g) = \begin{cases} g + 1 & \text{nếu } g \leq 2 \\ g & \text{nếu } g = 3 \\ g - 1 & \text{nếu } g > 3 \end{cases}$$

Bước 1: Vẽ Histogram của ảnh cũ



Bước 2: Vẽ đồ thị hàm $f(g)$




Bước 3: Vẽ Histogram của ảnh mới

Đặt $q = f(g)$

$h(q) = \text{card}(\{P/I(P) = q\})$

$$\begin{aligned}
&= \text{card} (\{P/I(P) = f(g)\}) \\
&= \text{card} (\{P/g = f^{-1}(I(P))\}) \\
&= \sum_{i \in f^{-1}(q)} h(i)
\end{aligned}$$

Histogram của ảnh mới thu được bằng cách chồng hình và tính giá trị theo các $q (=f(g))$ theo công thức tính trên. Kết quả cuối thu được sau phép quay góc 90 thuận chiều kim đồng hồ.



2.2. Cải thiện ảnh sử dụng toán tử không gian

2.2.1. Phép nhân chập và mẫu

Giả sử ta có ảnh I kích thước $M \times N$, mẫu T có kích thước $m \times n$ khi đó, ảnh I nhân chập theo mẫu T được xác định bởi công thức.

$$I \otimes T(x, y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} I(x+i, y+j) * T(i, j) \quad (2.1)$$

$$\text{Hoặc} \quad I \otimes T(x, y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} I(x-i, y-j) * T(i, j) \quad (2.2)$$

VD:

$$I = \begin{pmatrix} 1 & 2 & 4 & 5 & 8 & 7 \\ 2 & 1 & 1 & 4 & 2 & 2 \\ 4 & 5 & 5 & 8 & 8 & 2 \\ 1 & 2 & 1 & 1 & 4 & 4 \\ 7 & 2 & 2 & 1 & 5 & 2 \end{pmatrix}$$

$$T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$I \otimes T(x, y) = \sum_{i=0}^1 \sum_{j=0}^1 I(x+i, y+j) * T(i, j) = I(x, y) * T(0,0) + I(x+1, y+1) * T(1,1)$$

$$= I(x, y) + I(x+1, y+1)$$

THƯ VIỆN PTIT

Tính theo (2.1)

$$I \otimes T = \begin{pmatrix} 2 & 3 & 8 & 7 & 10 & * \\ 7 & 6 & 9 & 12 & 4 & * \\ 6 & 6 & 6 & 12 & 12 & * \\ 3 & 4 & 2 & 6 & 6 & * \\ * & * & * & * & * & * \end{pmatrix}$$

Tính theo công thức 2.2

$$I \otimes T = \begin{pmatrix} * & * & * & * & * & * \\ * & 2 & 3 & 8 & 7 & 10 \\ * & 7 & 6 & 9 & 12 & 4 \\ * & 6 & 6 & 6 & 12 & 12 \\ * & 3 & 4 & 2 & 6 & 6 \end{pmatrix}$$

*** Nhận xét:**

- Trong quá trình thực hiện phép nhân chập có một số thao tác ra ngoài ảnh, ảnh không được xác định tại những vị trí đó dẫn đến ảnh thu được có kích thước nhỏ hơn.

- Ảnh thực hiện theo công thức 2.1 và 2.2 chỉ sai khác nhau 1 phép dịch chuyển để đơn giản ta sẽ hiểu phép nhân chập là theo công thức 2.1

2.2.2. Một số mẫu thông dụng

- Mẫu:

$$T_1 = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

~ Dùng để khử nhiễu $\Rightarrow$ Các điểm có tần số cao

VD1:

$$I = \begin{pmatrix} 1 & 2 & 4 & 5 & 8 & 7 \\ 2 & 31 & 1 & 4 & 2 & 2 \\ 4 & 5 & 5 & 8 & 8 & 2 \\ 1 & 2 & 1 & 1 & 4 & 4 \\ 7 & 2 & 2 & 1 & 5 & 2 \end{pmatrix}$$

$$I \otimes T_1 = \begin{pmatrix} 55 & 65 & 45 & 46 & * & * \\ 52 & 58 & 34 & 35 & * & * \\ 29 & 27 & 35 & 35 & * & * \\ * & * & * & * & * & * \\ * & * & * & * & * & * \end{pmatrix}$$

Áp dụng kỹ thuật cộng hằng số với $c = -27$, ta có:

$$I_{kq} = \begin{pmatrix} 28 & 38 & 18 & 19 & * & * \\ 25 & 31 & 7 & 8 & * & * \\ 2 & 0 & 8 & 8 & * & * \\ * & * & * & * & * & * \\ * & * & * & * & * & * \end{pmatrix}$$

- Mẫu:

$$T_2 = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{pmatrix}$$

~ Dùng để phát hiện các điểm có tần số cao

VD2:

$$I \otimes T_2 = \begin{pmatrix} 114 & -40 & 0 & -14 & * & * \\ -22 & 5 & 14 & 16 & * & * \\ -1 & -6 & -10 & -2 & * & * \\ * & * & * & * & * & * \\ * & * & * & * & * & * \end{pmatrix}$$

2.2.3. Loại trung vị

* Định nghĩa 2.1 (Trung vị)

Cho dãy $x_1; x_2; \dots; x_n$ đơn điệu tăng (giảm). Khi đó trung vị của dãy ký hiệu là $\text{Med}(\{x_n\})$, được định nghĩa:

$$+ \text{ Nếu } n \text{ lẻ } x_{\left\lceil \frac{n}{2} + 1 \right\rceil}$$

$$+ \text{ Nếu } n \text{ chẵn: } x_{\left\lfloor \frac{n}{2} \right\rfloor} \text{ hoặc } x_{\left\lceil \frac{n}{2} + 1 \right\rceil}$$

* Mệnh đề 2.1

$$\sum_{i=1}^n |x - x_i| \rightarrow \min \text{ tại } Med(\{x_n\})$$

Chứng minh

+ Xét trường hợp n chẵn

$$\text{Đặt } M = \frac{n}{2}$$

Ta có:

$$\begin{aligned} \sum_{i=1}^n |x - x_i| &= \sum_{i=1}^M |x - x_i| + \sum_{i=1}^M |x - x_{M+i}| \\ &= \sum_{i=1}^M (|x - x_i| + |x_{M+i} - x|) \geq \sum_{i=1}^M |x_{M+i} - x_i| \\ &= \sum_{i=1}^M [(x_{M+1} - x_M) + (x_M - x_i)] \\ &= \sum_{i=1}^M |x_{M+i} - Med(\{x_i\})| + \sum_{i=1}^M |x_i - Med(\{x_i\})| \\ &= \sum_{i=1}^n |x_i - Med(\{x_i\})| \end{aligned}$$

+ Nếu n lẻ:

Bổ sung thêm phần tử $Med(\{x_i\})$ vào dãy. Theo trường hợp n chẵn ta có:

$$\begin{aligned} \sum_{i=1}^n |x - x_i| + |Med(\{x_i\}) - Med(\{x_i\})| &\rightarrow \min \text{ tại } Med(\{x_n\}) \\ \sum_{i=1}^n |x - x_i| &\rightarrow \min \text{ tại } Med(\{x_n\}) \end{aligned}$$

*** Kỹ thuật lọc trung vị**

Giả sử ta có ảnh I ngưỡng θ của số $W(P)$ và điểm ảnh P

Khi đó kỹ thuật lọc trung vị phụ thuộc không gian bao gồm các bước cơ bản sau:

+ **Bước 1:** Tìm trung vị

$$\{I(q) | q \in W(P)\} \rightarrow Med(P)$$

+ **Bước 2:** Gán giá trị

$$I(P) = \begin{cases} I(P) & |I(P) - Med(P)| \leq \theta \\ Med(P) & \text{Ngược lại} \end{cases}$$

Ví dụ:

$$I = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & 16 & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

$$W(3 \times 3); \theta = 2$$

$$I_{kq} = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & \textcircled{2} & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

Giá trị 16, sau phép lọc có giá trị 2, các giá trị còn lại không thay đổi giá trị.

2.2.4. Lọc trung bình

* Định nghĩa 2.2 (Trung bình)

Cho dãy $x_1, x_2, \dots, x_n$ khi đó trung bình của dãy ký hiệu $AV(\{x_n\})$ được định nghĩa:

$$AV(\{x_n\}) = \text{round}\left(\frac{1}{n} \sum_{i=1}^n x_i\right)$$

* Mệnh đề 2.2

$$\sum_{i=1}^n (x - x_i)^2 \rightarrow \min \text{ tại } AV(\{x_n\})$$

Chứng minh:

$$\text{Đặt: } \phi(x) = \sum_{i=1}^n (x - x_i)^2$$

Ta có:

$$\phi(x) = 2 \sum_{i=1}^n (x - x_i)$$

$$\phi'(x) = 0$$

$$\Leftrightarrow \sum_{i=1}^n (x - x_i) = 0$$

$$\Leftrightarrow x = \frac{1}{n} \sum_{i=1}^n x_i = AV(\{x_i\})$$

$$\text{Mặt khác, } \phi''(x) = 2n > 0$$

$$\Rightarrow \phi \rightarrow \min \text{ tại } x = AV(\{x_i\})$$

Kỹ thuật lọc trung bình

Giả sử ta có ảnh I, điểm ảnh P, cửa sổ W(P) và ngưỡng θ . Khi đó kỹ thuật lọc trung bình phụ thuộc không gian bao gồm các bước cơ bản sau:

+ **Bước 1:** Tìm trung bình

$$\{I(q) \mid q \in W(P)\} \rightarrow AV(P)$$

+ **Bước 2:** Gán giá trị

$$I(P) = \begin{cases} I(P) & |I(P) - AV(P)| \leq \theta \\ AV(P) & \text{Nguoc lai} \end{cases}$$

Ví dụ:

$$I = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & 16 & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

W(3 × 3); $\theta = 2$

$$I_{kq} = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & \textcircled{3} & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

Giá trị 16 sau phép lọc trung bình có giá trị 3, các giá trị còn lại giữ nguyên sau phép lọc.

2.2.5. Lọc trung bình theo k giá trị gần nhất

Giả sử ta có ảnh I, điểm ảnh P, cửa sổ W(P), ngưỡng θ và số k. Khi đó, lọc trung bình theo k giá trị gần nhất bao gồm các bước sau:

+ **Bước 1:** Tìm K giá trị gần nhất

$$\{I(q) \mid q \in W(p)\} \rightarrow \{k \sim \text{giá trị gần } I(P) \text{ nhất}\}$$

+ **Bước 2:** Tính trung bình

$$\{k \sim \text{giá trị gần } I(P) \text{ nhất}\} \rightarrow AV_k(P)$$

+ **Bước 3:** Gán giá trị

$$I(P) = \begin{cases} I(P) & |I(P) - AV_k(P)| \leq \theta \\ AV_k(P) & \text{Nguoc lai} \end{cases}$$

Ví dụ:

$$I = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & 16 & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

$$W(3 \times 3); \theta = 2; k = 3$$

$$I_{kq} = \begin{pmatrix} 1 & 2 & 3 & 2 \\ 4 & 8 & 2 & 1 \\ 4 & 2 & 1 & 1 \\ 2 & 1 & 2 & 1 \end{pmatrix}$$

*** Nhận xét:**

- Nếu k lớn hơn kích thước cửa sổ thì kỹ thuật chính là kỹ thuật lọc trung bình
- Nếu k = 1 thì ảnh kết quả không thay đổi
- ⇒ Chất lượng của kỹ thuật phụ thuộc vào số phân tử lựa chọn k.


2.3. Khôi phục ảnh

2.3.1. Nhiều và mô hình nhiễu

Ảnh được coi là một miền đồng nhất về mức xám, tức là các điểm ảnh lân cận có sự biến đổi liên tục về mức xám. Như vậy sau quá trình số hoá thì trong mỗi cửa sổ đang xét các điểm ảnh đều có giá trị gần bằng nhau. Thực tế quan sát có những điểm ảnh có giá trị khác hơn nhiều so với các điểm ảnh khác. Đó chính là nhiễu. Như vậy, nhiễu trong ảnh số được xem như là sự dịch chuyển đột ngột của tín hiệu thu nhận trên một khoảng cách nhỏ.

Mô hình liên tục

Hệ thống thu nhận ảnh chuyển các hình ảnh thực của môi trường xung quanh $g(x,y)$ thành dạng tín hiệu ảnh $g'(x,y)$. Tuy nhiên trong quá trình chuyển đổi có nhiều yếu tố tác động tạo thành nhiễu. Do đó tín hiệu $g'(x,y)$ có thể chứa các thành phần nhiễu trong đó. Quá trình thu nhận ảnh có nhiễu có thể mô tả một cách trực quan như sau:



Hình 2.1 Mô hình nhiễu.

Mô hình rời rạc:

Trên cơ sở mô hình nhiễu liên tục, ta có thể xây dựng một mô hình nhiễu rời rạc tương

ứng với ảnh số. Khi đó $g(x,y)$ sẽ chuyển thành ảnh rời rạc $g[m,n]$, ảnh liên tục $g'(x,y)$ sẽ chuyển thành ma trận điểm ảnh $g'[m,n]$ và nhiễu cũng phân bố rời rạc tại các điểm ảnh $\eta[m,n]$. Giả sử H là hàm tuyến tính bất biến trong phạm vi $M \times N$ (kích thước ảnh) thì ta có:

$$g'[m,n] = h[m,n] * g[m,n] + \eta[m,n] = \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} h[m-k, n-l] \cdot g[k,l] + \eta[m,n]$$

Đối với xử lý số ảnh thì ta chỉ sử dụng mô hình nhiễu rời rạc.

2.3.2. Các loại nhiễu

Các tín hiệu nhiễu thường được chia thành các loại chính như sau:

Nhiều do thiết bị thu nhận ảnh là loại nhiễu gây ra do giới hạn nhiễu xạ và quang sai của thấu kính, nhiễu do bộ phận cảm quang, ảnh mờ nhòe do ống kính, nhiễu do rung động thiết bị trong quá trình thu nhận.

Nhiều ngẫu nhiên độc lập là các loại nhiễu gây ra do ảnh hưởng của môi trường xung quanh, do ảnh hưởng của khí quyển.

Nhiều do vật quan sát. Đây là nhiễu gây ra do bề mặt của bản thân vật có độ nhám gồ ghề. Chính nhiễu này gây hiện tượng tán xạ của các tia đơn sắc và sinh ra hiện tượng nhiễu lốm đốm.


Thường người ta xấp xỉ các loại nhiễu bằng các quá trình tuyến tính bất biến vì có nhiều công cụ tuyến tính có thể giải quyết vấn đề khôi phục ảnh hơn là các công cụ phi tuyến. Việc xử lý nhiễu bằng cách xấp xỉ tuyến tính cũng giúp cho công việc dễ dàng hơn trong trường hợp dùng cách biến đổi phi tuyến.

2.3.3. Các kỹ thuật lọc nhiễu

Trong phần này ta sẽ xét hai kỹ thuật lọc tuyến tính hay sử dụng là lọc ngược và lọc giả ngược.

Lọc ngược (inverse filter):

Nguyên lý của lọc ngược là sử dụng hàm ngược của đáp ứng xung $h[m,n]$ để khôi phục lại một ảnh xấp xỉ ảnh nguyên gốc $g[m,n]$ từ ảnh $g'[m,n]$ đã biết nguyên lý này được biểu diễn mô tả theo sơ đồ sau:



Hình 2.2 Lọc ngược khôi phục ảnh nguyên.

Như vậy ảnh khôi phục $g^*[m,n]$ sẽ được tính theo công thức:

$$g^*[m,n] = g'[m,n] * h^{-1}[m,n]$$

Trong đó $h^{-1}[m,n]$ chính là hàm của bộ lọc ngược. Vì $H^{-1}(H(x)) = x$ nên ta có giá trị đầu ra $g^*[m,n]$ cũng bằng giá trị vào $g[m,n]$. Như vậy ta đã khôi phục được ảnh $g[m,n]$ nhờ dùng hàm ngược của đáp ứng xung $h[m,n]$.

Nếu dùng biến đổi Fourier ta có:

$$G[u, v] = G'[u, v].H^T[u, v] = \frac{G'[u, v]}{H[u, v]}$$

Qua đó ta thấy, đáp ứng tần số của bộ lọc ngược là nghịch đảo của đáp ứng tần số của hệ thu nhận ảnh. Nếu đánh giá được mức nhiễu ta có thể xấp xỉ gần hơn với ảnh nguyên gốc:

$$G[u, v] = \frac{G'[u, v]}{H[u, v]} + \frac{N[u, v]}{H[u, v]} \text{ với } N[u, v] \text{ là nhiễu ước lượng.}$$

Nếu $H[u, v] = 0$ hoặc khá nhỏ thì hệ thống khôi phục sẽ không ổn định (hàm $H^T[u, v]$ không xác định). Đây chính là nhược điểm của phương pháp lọc ngược. Tuy bộ lọc ngược có khả năng ngăn nhiễu do hệ thống nhận ảnh gây ra khá tốt nhưng việc thiết kế bộ lọc này lại là khá phức tạp.

Lọc giả ngược (Pseudoinverse filter):

Kỹ thuật lọc này khắc phục được nhược điểm của kỹ thuật lọc ngược là làm cho hàm $H^T[u, v]$ luôn xác định:

$$H^T[u, v] = \begin{cases} \frac{1}{H[u, v]} & \text{khi } |H[u, v]| \geq \varepsilon \\ 0 & \text{khi } |H[u, v]| < \varepsilon \end{cases}$$

Với ε là một giá trị cho trước.

Trong trường hợp ảnh nguyên gốc $g[m, n]$ chuyển động tịnh tiến theo phương x và y sinh ra hiện tượng nhoè ảnh thì $H^T[u, v]$ sẽ được xác định theo các thông số chuyển động, và lọc giả ngược có khả năng khôi phục được ảnh nhoè này.

Lọc nhiễu lốm đốm:

Ta đã biết nhiễu lốm đốm gây ra do tính chất gồ ghề của bề mặt vật thể gây ra hiện tượng tán xạ các tia đơn sắc. Phần này ta sẽ nghiên cứu một kỹ thuật lọc nhiễu lốm đốm là kỹ thuật trung bình thống kê sử dụng bộ lọc đồng cầu.

Kỹ thuật lọc nhiễu trung bình thống kê tiến hành thống kê các cường độ sáng của đối tượng ảnh bị nhiễu lốm đốm bằng N lần thu nhận độc lập và lấy trung bình các cường độ đó.

Ta giả thiết hệ thống chỉ có nhiễu lốm đốm và nhiễu này có thể coi như tổng vô số hạn các pha độc lập và đồng nhất. Ta có thể biểu diễn nhiễu lốm đốm như sau:

$$a[m, n] = a_R[m, n] + ja_I[m, n]$$

Với a_R và a_I là các biến ngẫu nhiên độc lập phân bố theo Gaussian, ứng với mỗi tọa độ $[m, n]$ thì trị trung bình bằng 0 với phương sai σ^2 . Ta có cường độ S:

$$S[m, n] = |a[m, n]|^2 = a_R^2 + a_I^2$$

Như vậy ảnh thu được trong lần nhận thứ i (1, ..., N) sẽ là:

$$g_i'[m, n] = g[m, n].s_i[m, n]$$

Trị trung bình thống kê của N lần thu nhận ảnh sẽ là:

$$g'_N[m, n] = \frac{1}{N} \sum_{i=1}^N g'_i[m, n] = g[m, n] \cdot \left(\frac{1}{N} \sum_{i=1}^N s'_i[m, n] \right) = g[m, n] \cdot s_N[m, n]$$

Trong đó $s_N[m, n]$ là trị trung bình thống kê của trường cường độ nhiễu lốm đốm

Lọc đồng cầu (Homomorphic filter):

Nếu lấy logarit 2 vế của biểu thức trên ta thu được:

$$\log g'_N[m, n] = \log g[m, n] + \log s_N[m, n]$$

$$\text{Đặt } w_N[m, n] = \log g'_N[m, n], \quad z[m, n] = \log g[m, n], \quad \eta_N[m, n] = \log s_N[m, n]$$

Ta có mô hình quan sát có nhiễu lốm đốm như sau:

$$w_N[m, n] = z[m, n] + \eta_N[m, n]$$

Từ đó ta thấy có thể tìm ra $z[m, n]$ từ $w_N[m, n]$ và $\eta_N[m, n]$. Như vậy là có thể tách nhiễu lốm đốm và khôi phục lại ảnh ban đầu.

Trong công thức tính $w_N[m, n]$ thì $\eta_N[m, n]$ là nhiễu trắng dừng. Với $N \geq 2$ thì $\eta_N[m, n]$ có thể mô tả gần với nhiễu ngẫu nhiên Gaussian với mật độ phổ được định nghĩa như sau:

$$S_{\eta_N}(\xi_1, \xi_2) = \sigma^2 = \begin{cases} \pi^2 / 6 & N = 1 \\ 1 / N & N > 1 \end{cases}$$

Câu hỏi ôn tập và bài tập

Bài tập 1

Biểu đồ tần suất là gì? Hãy tìm biểu đồ tần suất $h(g)$ cho ảnh I sau, được biết các điểm ảnh có giá trị từ 0 đến 9:

$$I = \begin{bmatrix} 1 & 2 & 1 & 3 & 2 & 1 \\ 4 & 4 & 3 & 2 & 4 & 0 \\ 6 & 9 & 2 & 3 & 2 & 1 \\ 6 & 2 & 0 & 5 & 3 & 0 \\ 3 & 4 & 0 & 5 & 1 & 5 \\ 5 & 6 & 8 & 9 & 3 & 6 \end{bmatrix}$$

Bài tập 2

Thực hiện các phép biến đổi sau với ảnh I ở câu 1.

- Tăng cường độ sáng với $c = 4$.
- Tách ngưỡng với $\theta = 3$.
- Cân bằng tần suất với ảnh kết quả có cùng số mức xám với ảnh gốc.
- Tìm ngưỡng tự động và tách ngưỡng.

Lưu ý: Các điểm ảnh chỉ nhận giá trị từ 0 đến 9.

Bài tập 3

Từ biểu đồ tần suất $h(I)$ tính được ở câu 1/ hãy tính biểu đồ tần suất $h(I')$ của ảnh I' thu nhận được từ ảnh I sử dụng biểu thức:

$$I' = |2I - 9|$$

Bài tập 4

Thực hiện nhân chập ảnh I ở Bài tập 1 với ma trận nhân chập H:

$$H = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}$$

Bài tập 5

Thực hiện lọc với cửa sổ 3×3 và $\theta = 3$ sử dụng các phương pháp sau với ảnh I ở câu 1:

- Lọc trung vị.
- Lọc trung bình.
- Lọc trung bình k giá trị gần nhất với $k = 4$

Chương 3

XỬ LÝ ẢNH MÀU


Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu rõ về cơ bản của màu sắc và phổ màu.
- ✓ Quen thuộc với một số mô hình màu được sử dụng trong xử lý ảnh kỹ thuật số.
- ✓ Biết cách áp dụng các kỹ thuật cơ bản trong xử lý ảnh giả màu – pseudo color, bao gồm cắt cường độ sáng và chuyển đổi cường độ sáng thành màu.
- ✓ Quen thuộc với cách xác định xem phương pháp xử lý cho ảnh xám có thể mở rộng được cho ảnh màu hay không.
- ✓ Hiểu cơ bản về làm việc với ảnh đầy đủ màu sắc, bao gồm các biến đổi màu, bổ sung màu sắc và sửa lỗi tông/màu sắc.
- ✓ Quen thuộc với vai trò của nhiễu trong xử lý ảnh màu.
- ✓ Biết cách thực hiện lọc không gian trên ảnh màu.
- ✓ Hiểu rõ những lợi ích của việc sử dụng màu sắc trong phân đoạn ảnh.


3.1. Cơ bản về màu sắc

Mặc dù quá trình mà não người sử dụng để nhận thức và diễn giải màu sắc là hiện tượng sinh lý tâm thần chưa được hiểu biết đầy đủ, bản chất vật lý của màu sắc có thể được biểu diễn một cách hệ thống và được hỗ trợ bởi kết quả thực nghiệm và lý thuyết.

Năm 1666, Sir Isaac Newton phát hiện rằng khi một tia nắng mặt trời đi qua một lăng trụ thủy tinh, ánh sáng đầu ra không phải là trắng, mà thay vào đó là một phổ - dải màu liên tục từ màu tím (ở một đầu của dải) đến màu đỏ (ở đầu còn lại của dải màu). Như hình 3.1 thể hiện, phổ màu có thể được chia thành sáu dải rộng: tím, xanh da trời, xanh lá cây, vàng, cam và đỏ. Khi xem ở dạng màu đầy đủ (xem hình 3.2), không có màu nào trong phổ kết thúc đột ngột; thay vào đó, mỗi màu chuyển tiếp liên tục sang màu kế tiếp.



Hình 3.1 Phổ màu thu nhận được bằng cách chiếu ánh sáng trắng qua 1 lăng trụ.




Hình 3.2 Các bước sóng tạo nên vùng nhìn thấy của phổ điện từ.

Về cơ bản, màu sắc mà con người và một số loài động vật cảm nhận được từ một vật thể được xác định bởi tự nhiên của ánh sáng phản xạ từ vật thể. Như minh họa trong Hình 3.2, ánh sáng nhìn thấy được tạo thành từ một dải tần số tương đối hẹp trong phổ điện từ. Một vật thể phản xạ ánh sáng cân bằng ở tất cả các bước sóng nhìn thấy sẽ có màu trắng đối với người quan sát. Tuy nhiên, một vật thể phản xạ ưu tiên trong một khoảng hẹp nào đó của phổ nhìn thấy sẽ mang gam màu đó. Ví dụ, các vật thể màu xanh lá cây phản xạ ánh sáng chủ yếu ở khoảng 500 đến 570 nm, trong khi hấp thụ hầu hết năng lượng ở các bước sóng khác. Vì thế người quan sát sẽ thấy vật có màu xanh lá cây.

Nghiên cứu, phân tích đặc tính ánh sáng là trung tâm của khoa học màu sắc. Nếu ánh sáng là không màu (không có màu sắc), đặc điểm duy nhất của nó là cường độ sáng. Ví dụ ánh sáng không màu là trong các bộ phim trước những năm 1930. Như được định nghĩa trong chương trước và đã được sử dụng nhiều lần, thuật ngữ mức xám (hoặc cường độ sáng) đề cập đến đo lường vô hướng về cường độ biến đổi liên tục từ màu đen, đến các gam màu xám, và cuối cùng là đến trắng.

Ánh sáng màu trải dài trên phổ điện từ trên khoảng 400 đến 700 nm. Ba đại lượng cơ bản được sử dụng để mô tả đặc tính của nguồn sáng màu là: radiance – độ trung, luminance – độ chói và brightness – độ sáng. Radiance là tổng lượng năng lượng phát ra từ nguồn sáng, và thường được đo bằng đơn vị công suất watts (W). Luminance, được đo trong lumen (lm), là một đo lường về lượng năng lượng mà người quan sát nhận từ nguồn sáng. Ví dụ, ánh sáng phát ra từ một nguồn hoạt động trong vùng hồng ngoại xa của phổ có thể có năng lượng lớn (radiance), nhưng một người quan sát gần như không thể cảm nhận được nó; luminance của nó gần như bằng không. Cuối cùng, brightness là một mô tả chủ quan khó đo lường. Nó bao gồm khái niệm không màu – achromatic của cường độ và là một trong những yếu tố chính trong việc mô tả cảm giác màu sắc.

Như đã tìm hiểu ở phần trước, những tế bào hình nón là đơn vị cảm biến trong mắt chịu trách nhiệm cho cảm nhận màu sắc. Thực nghiệm đã xác định có 6 đến 7 triệu tế bào hình nón trong mắt người và chúng có thể được chia thành ba loại tương ứng với các loại tế bào cảm nhận màu đỏ, loại cảm nhận màu xanh lá cây và loại cảm nhận màu xanh da trời. Khoảng 65% tế bào hình nón nhạy với ánh sáng đỏ, 33% nhạy với ánh sáng xanh lá cây, và chỉ khoảng 2% nhạy đến ánh sáng xanh da trời. Tuy nhiên, nhóm xanh da trời lại là nhạy nhất. Hình 4.3 thể hiện các đường cong thực nghiệm trung bình về chi tiết của sự hấp thụ ánh sáng bởi các nhóm tế bào nón ứng với các màu đỏ, xanh lá cây và xanh da trời trong mắt. Do các đặc điểm hấp thụ này, mắt người nhìn thấy màu sắc như là sự kết hợp – tổ hợp của 3 màu chủ yếu là: đỏ (R), xanh lá cây (G) và xanh da trời (B).




Hình 3.3 Đo đặc hấp thụ ánh sáng của các tế bào hình nón ứng với các nhóm cho màu đỏ, xanh lá cây và xanh da trời dưới dạng hàm của bước sóng.

Với mục đích tiêu chuẩn hóa, CIE (Commission Internationale de l'Eclairage - Ủy ban Quốc tế về Ánh sáng) đã thống nhất vào năm 1931 các giá trị bước sóng cụ thể sau đây cho ba màu chủ yếu: xanh da trời = 435.8 nm, xanh lá cây = 546.1 nm, và đỏ = 700 nm. Tiêu chuẩn này được thiết lập trước khi kết quả như trong Hình 3.3 được công bố vào năm 1965. Do đó, tiêu chuẩn của CIE chỉ tương đối tương ứng với dữ liệu thực nghiệm. Quan trọng cần lưu ý rằng việc xác định ba bước sóng cụ thể cho mục đích tiêu chuẩn hóa không có nghĩa là ba thành phần RGB cố định này hoạt động độc lập có thể tạo ra tất cả các màu trong phổ. Việc sử dụng từ "primary - cơ bản" đã bị hiểu sai thành ba màu cơ bản tiêu chuẩn, khi được trộn với các tỷ lệ cường độ khác nhau, có thể tạo ra tất cả các màu của ánh sáng nhìn thấy. Như chúng ta sẽ thấy ngay sau đây, cách hiểu này không đúng trừ khi bước sóng cũng được phép biến đổi, trong trường hợp đó, chúng ta sẽ không còn ba màu cơ bản với bước sóng cố định nữa.

Các màu cơ bản có thể được cộng lại để tạo ra các màu phụ của ánh sáng - đỏ nhạt (đỏ cộng xanh da trời), xanh da trời nhạt (xanh lá cây cộng xanh da trời) và vàng nhạt (đỏ cộng xanh lá cây). Khi trộn ba màu cơ bản hoặc một màu phụ với màu cơ bản bù trừ của nó (xem Hình 3.4), ở cường độ phù hợp sẽ tạo ra ánh sáng trắng. Kết quả này được minh họa trong Hình 3.4(a), cũng thể hiện ba màu cơ bản và sự kết hợp của chúng để tạo ra các màu phụ của ánh sáng.

a
b



Hình 3.4 Các màu cơ bản và màu thứ cấp của ánh sáng và chất tạo màu.

Phân biệt giữa màu cơ bản của ánh sáng và màu cơ bản của chất tạo màu là quan trọng. Trong trường hợp chất tạo màu, màu cơ bản được định nghĩa là màu loại trừ đi hoặc hấp thụ màu cơ bản của ánh sáng và phản xạ hoặc truyền hai màu còn lại. Do đó, màu cơ bản của chất tạo màu là magenta, cyan và yellow, và màu phụ là red, green và blue. Ví dụ: màu cơ bản yellow của chất tạo màu sẽ hấp thụ - loại bỏ hoàn toàn màu xanh da trời (màu cơ bản của ánh sáng), và phản xạ lại 2 màu cơ bản còn lại của ánh sáng là màu đỏ - red và màu xanh lá cây - green. Những màu này được thể hiện trong Hình 3.4(b). Sự kết hợp chính xác của ba màu cơ bản của chất tạo màu, hoặc một màu phụ với màu cơ bản ngược lại của nó, tạo ra màu đen. Tạo màu sắc trong tivi màu là một ví dụ về bản chất cộng của màu sắc ánh sáng. Bên trong màn hình truyền hình màu CRT (cathode ray tube) sử dụng phổ biến đến cuối thập kỷ 1990 (trước khi màn hình LCD trở nên phổ biến) được tạo thành từ một mảng lớn các

mẫu điểm tam giác của photpho nhạy electron. Khi kích thích, mỗi điểm trong một bộ ba tạo ra ánh sáng ở một trong ba màu cơ bản. Cường độ của các điểm photpho phát ra màu đỏ được điều chỉnh (còn gọi là điều biến) bởi một súng electron bên trong ống, tạo ra xung tương ứng với "năng lượng màu đỏ" được nhìn thấy bởi máy ảnh. Các điểm photpho xanh và xanh da trời trong mỗi bộ ba được điều chỉnh theo cùng một cách. Hiệu ứng, khi nhìn từ truyền hình, là ba màu cơ bản từ mỗi bộ ba photpho được nhận và "cộng" lại bởi những tế bào hình nón nhạy màu trong mắt và được nhìn thấy như một hình ảnh đầy đủ màu sắc. Ba màu sắc liên tục thay đổi mỗi giây trong tất cả ba màu sắc hoàn thành ảo ảnh của màn hình.

Màn hình CRT bắt đầu được thay thế vào cuối thập kỷ 1990 bởi các công nghệ số phẳng, chẳng hạn như màn hình hiển thị LCD (liquid crystal displays) và thiết bị plasma. Mặc dù chúng có bản chất khác nhau so với CRTs, những công nghệ này và những công nghệ tương tự sử dụng nguyên tắc giống nhau trong việc đòi hỏi ba subpixel (đỏ, xanh lá cây và xanh da trời) để tạo ra một pixel màu đơn. LCD sử dụng các tính chất của ánh sáng phân cực để chặn hoặc truyền ánh sáng tới màn hình LCD và, trong trường hợp của các công nghệ hiển thị ma trận hoạt động, các transistor màng mỏng (TFTs) được sử dụng để cung cấp các tín hiệu phù hợp để xác định cho mỗi pixel trên màn hình. Bộ lọc ánh sáng được sử dụng để tạo ra ba màu cơ bản của ánh sáng tại mỗi vị trí bộ ba điểm ảnh. Trong thiết bị plasma, các pixel là tế bào khí nhỏ phủ photpho để tạo ra một trong ba màu cơ bản. Các tế bào riêng biệt được xử lý theo cách tương tự như LCDs. Một bộ 3 pixel riêng biệt này phối hợp khả năng tạo màu và là nền tảng của công nghệ màn hình số.

Các đặc điểm thường được sử dụng để phân biệt một màu so với một màu khác là độ sáng - brightness, màu sắc - hue và độ bão hòa - saturation. Như đã chỉ ra trước đây trong phần này, độ sáng bao gồm khái niệm không màu về cường độ. Màu sắc là một thuộc tính liên quan đến bước sóng chiếm ưu thế trong một hỗn hợp sóng ánh sáng. Màu sắc đại diện cho màu chủ đạo như được nhìn thấy bởi người quan sát. Do đó, khi chúng ta gọi một đối tượng là đỏ, cam hoặc vàng, chúng ta đang nói về màu sắc của nó. Độ bão hòa liên quan đến sự tinh khiết tương đối hoặc lượng ánh sáng trắng được pha trộn với một màu chủ đạo. Các màu tinh khiết của phổ ánh sáng trắng là hoàn toàn bão hòa. Các màu như hồng (đỏ và trắng) và lavender (violet và trắng) ít bão hòa hơn, với mức độ bão hòa đảo ngược tỉ lệ với lượng ánh sáng trắng được thêm vào.

Màu sắc và độ bão hòa cùng nhau được gọi là chromaticity và, do đó, một màu có thể được đặc trưng bởi độ sáng và chromaticity của nó. Lượng màu đỏ, xanh lá cây và xanh da trời cần thiết để tạo thành một màu cụ thể nào đó được gọi là giá trị ba màu cơ bản, và được ký hiệu là X, Y và Z tương ứng. Một màu sau đó được xác định bởi các hệ số ba màu cơ bản của nó, được định nghĩa là:

$$x = X / (X + Y + Z) \quad 3-1$$

$$y = Y / (X + Y + Z) \quad 3-2$$

và


$$z = Z / (X + Y + Z) \quad 3-3$$

Và từ đó ta có:

$$x + y + z = 1 \quad 3-4$$

Đối với bất kỳ bước sóng ánh sáng nào trong phổ nhìn thấy được, giá trị ba thành phần cơ bản cần thiết để tạo ra màu tương ứng với bước sóng đó có thể được lấy trực tiếp từ đồ thị hoặc các bảng đã được tổng hợp từ các kết quả thực nghiệm. Một cách tiếp cận khác để chỉ định màu sắc là sử dụng biểu đồ màu của CIE (xem Hình 3.5), biểu đồ này cho thấy thành phần màu sắc dưới dạng hàm số của x (đỏ) và y (xanh lá cây). Đối với bất kỳ giá trị nào của

x và y, giá trị tương ứng của z (xanh da trời) được lấy từ phương trình (3-4) bằng cách chú ý rằng $z = 1 - (x + y)$. Điểm được đánh dấu màu xanh lá cây trong Hình 3.5, ví dụ, có khoảng 62% thành phần màu xanh lá cây và 25% thành phần màu đỏ. Từ phương trình (3-4), ta có thể suy ra rằng thành phần màu xanh da trời là khoảng 13%.



Hình 3.5 Lược đồ độ bão hòa màu CIE.


Các vị trí của các màu sắc trong phổ từ màu tím tại 380 nm đến màu đỏ tại 780 nm được chỉ ra xung quanh ranh giới của biểu đồ màu cơ bản hình lưỡi hái. Đây là những màu sắc thuần khiết được thể hiện trong phổ của Hình 3.2. Bất kỳ điểm nào không nằm trực tiếp trên biên, nhưng ở bên trong miền biểu đồ, đều biểu diễn một sự pha trộn nhất định của các màu sắc thuần khiết trong phổ. Điểm năng lượng bằng nhau được thể hiện trong Hình 3.5 tương ứng với tỷ lệ bằng nhau của ba màu cơ bản; nó đại diện cho tiêu chuẩn CIE cho ánh sáng trắng. Bất kỳ điểm nào nằm trên biên giới của biểu đồ màu cơ bản đều bão hòa hoàn toàn. Khi một điểm rời khỏi biên và tiến gần điểm năng lượng bằng nhau, nhiều ánh sáng trắng được thêm vào màu sắc, và màu sắc trở nên ít bão hòa hơn. Độ bão hòa tại điểm năng lượng bằng nhau là không.

Biểu đồ màu cơ bản hữu ích để pha trộn màu vì một đoạn thẳng nối bất kỳ hai điểm nào trong biểu đồ định rõ tất cả các biến thể màu sắc khác nhau có thể được đạt được bằng cách

kết hợp hai màu sắc này theo cách cộng gộp. Ví dụ, xem đoạn thẳng nối giữa điểm đỏ và điểm xanh lá cây được thể hiện trong Hình 3.5. Nếu có nhiều ánh sáng đỏ hơn ánh sáng xanh lá cây, điểm chính xác đại diện cho màu mới sẽ nằm trên đoạn thẳng, nhưng nó sẽ gần hơn với điểm đỏ hơn là điểm xanh lá cây. Tương tự, một đoạn thẳng nối từ điểm năng lượng bằng nhau đến bất kỳ điểm nào trên biên giới của biểu đồ sẽ định rõ tất cả các tông màu của màu sắc cụ thể đó.

Mở rộng quy trình này lên ba màu sắc là dễ dàng. Để xác định phạm vi màu sắc có thể thu nhận được từ bất kỳ ba màu sắc đã cho nào trong biểu đồ màu cơ bản, chúng ta chỉ cần vẽ các đoạn thẳng nối ba điểm màu sắc. Kết quả là một tam giác, và bất kỳ màu nào ở bên trong tam giác, hoặc trên biên của nó, có thể được tạo ra bằng cách kết hợp các màu của ba điểm ở đỉnh. Một tam giác với đỉnh tại ba màu cố định nào đó không thể bao quát toàn bộ vùng màu sắc trong Hình 3.5. Quan sát này hỗ trợ, về mặt đồ họa, cho nhận xét trước đó rằng không phải tất cả các màu sắc có thể được đạt được với ba màu cơ bản cố định, vì ba màu sắc tạo thành một tam giác.

Tam giác trong Hình 3.6 cho thấy một vùng màu sắc đại diện (gọi là gamut màu) được tạo ra bởi các loại màn hình RGB. Khu vực có màu xám bên trong tam giác minh họa gamut màu của các thiết bị in màu chất lượng cao hiện nay. Biên của vùng gamut của máy in màu là không đều vì in màu là sự kết hợp của quá trình pha trộn màu cộng và màu trừ, một quy trình khó kiểm soát hơn nhiều so với việc hiển thị màu sắc trên màn hình, dựa trên việc thêm vào ba màu cơ bản có khả năng kiểm soát tốt.



Hình 3.6 Minh họa gamut màu của màn hình màu (tam giác) và của các thiết bị in màu

(vùng tô xám).


3.2. Các mô hình màu

Mục đích của một mô hình màu (còn được gọi là không gian màu hoặc hệ thống màu) là để thuận tiện cho việc xác định màu sắc theo một cách thức chuẩn nào đó. Cơ bản, một mô hình màu là một đặc tả của (1) một hệ tọa độ và (2) một không gian con bên trong hệ tọa độ đó, sao cho mỗi màu sắc trong mô hình được biểu diễn bằng một điểm duy nhất nằm trong không gian con đó.

Hầu hết các mô hình màu được sử dụng ngày nay đều được hướng tới phần cứng (như màn hình màu và máy in màu) hoặc các ứng dụng phần mềm với mục tiêu là xử lý màu sắc (việc tạo đồ họa màu sắc cho hoạt hình là một ví dụ cho các phần mềm ứng dụng). Đối với xử lý ảnh số, những mô hình hướng tới phần cứng thường được sử dụng thực tế bao gồm mô hình RGB (đỏ, xanh lá cây, xanh da trời) cho màn hình màu và loạt các loại máy ảnh/máy ghi hình màu; mô hình CMY (cyan, magenta, yellow) và CMYK (cyan, magenta, yellow, black) cho in ấn màu; và mô hình HSI (hue, saturation, intensity), là mô hình có sự tương đồng chặt chẽ với cách con người mô tả và hiểu màu sắc. Mô hình HSI cũng có ưu điểm là nó tách rời thông tin màu và thông tin mức xám trong một hình ảnh, làm cho nó phù hợp với nhiều kỹ thuật xử lý mức xám được phát triển trong xử lý ảnh. Hiện nay có nhiều mô hình màu được sử dụng. Điều này là phản ánh thực tế khoa học màu sắc là một lĩnh vực rộng lớn bao gồm nhiều lĩnh vực ứng dụng. Chúng ta sẽ tập trung vào một số mô hình đại diện cho những mô hình được sử dụng trong xử lý ảnh. Sau khi đã nắm vững nội dung trong chương này, bạn sẽ không gặp khó khăn trong việc hiểu các mô hình màu khác được sử dụng hiện nay.


3.2.1. Mô hình RGB

Trong mô hình RGB, mỗi màu xuất hiện trong các thành phần phổ cơ bản của nó là đỏ, xanh lá cây và xanh da trời. Mô hình này dựa trên hệ tọa độ Descartes. Không gian màu RGB là hình lập phương được hiển thị trong Hình 3.7, trong đó giá trị chính của RGB nằm ở ba góc; các màu thứ cấp là cyan, magenta và yellow nằm ở ba góc khác như trên hình; màu đen ở gốc; và màu trắng ở góc xa nhất từ gốc. Trong mô hình này, mức xám (các điểm có giá trị RGB bằng nhau) nối từ đen đến trắng dọc theo đường nối giữa hai điểm này. Các màu khác nhau trong mô hình này là các điểm trên hoặc bên trong hình lập phương và được định nghĩa bằng các vector xuất phát từ gốc. Để thuận tiện, giả sử rằng tất cả các giá trị màu đã được chuẩn hóa sao cho hình lập phương trong Hình 3.7 là hình lập phương đơn vị. Đó là, tất cả các giá trị của R, G và B trong biểu diễn này nằm trong đoạn $[0, 1]$. Lưu ý rằng các màu cơ bản RGB có thể được giải thích như các vector đơn vị bắt nguồn từ gốc của hình lập phương.



Hình 3.7 Sơ đồ khối lập phương màu RGB. Các điểm dọc theo đường chéo chính thể hiện các giá trị mức xám, từ đen ở góc (0, 0, 0) ở 1 đầu đến trắng ở đầu cuối còn lại tại (1, 1, 1).

Một ảnh được biểu diễn trong mô hình màu RGB bao gồm ba ảnh thành phần, mỗi hình ảnh tương ứng với một màu cơ bản. Khi đưa vào một màn hình RGB, ba ảnh này kết hợp trên màn hình để tạo ra một ảnh màu tổng hợp, như đã giải thích ở Mục 3.1. Số bit được sử dụng để biểu diễn mỗi pixel trong không gian màu RGB được gọi là độ sâu pixel. Xem xét một ảnh RGB trong đó mỗi ảnh đỏ, xanh lá cây và xanh da trời đều là ảnh 8-bit. Dưới những điều kiện này, mỗi pixel màu RGB [tức là, một bộ ba giá trị (R, G, B)] có độ sâu là 24 bit (3 lớp ảnh nhân với số bit trên mỗi lớp). Thuật ngữ full-color thường được sử dụng để chỉ một ảnh màu RGB 24-bit. Tổng số màu có thể có trong một ảnh RGB 24-bit là $(2^8)^3 = 16\,777\,216$ màu. Hình 3.8 cho thấy khối màu RGB 24-bit tương ứng với biểu đồ trong Hình 3.7. Lưu ý rằng đối với ảnh số, phạm vi giá trị trong khối được tự động chuyển đổi thành các số có thể biểu diễn được bởi số bit trong ảnh. Theo như trên, các ảnh cơ bản là ảnh 8-bit, giới hạn của khối theo từng trục là [0, 255]. Khi đó, chẳng hạn, màu trắng sẽ là điểm có tọa độ [255, 255, 255].



Hình 3.8 Khối lập phương màu RGB 24 bit.

3.2.2. Mô hình CMY và CMYK

Như đã chỉ ra ở Mục 3.1, cyan, magenta và yellow là các màu thứ cấp của ánh sáng hoặc, theo cách khác, chúng là các màu cơ bản của chất tạo màu. Ví dụ, khi một bề mặt phủ mực cyan được chiếu sáng bằng ánh sáng trắng, không có ánh sáng đỏ nào được phản xạ từ bề mặt. Do màu cyan trừ hay loại bỏ ánh sáng đỏ từ ánh sáng trắng phản xạ.

Hầu hết các thiết bị in sẽ in mực màu trên giấy, như máy in màu và máy photocopy màu, đều yêu cầu đầu vào dữ liệu CMY hoặc thực hiện chuyển đổi từ RGB sang CMY bên trong thiết bị. Chuyển đổi này được thực hiện bằng cách sử dụng phép toán đơn giản sau:

$$\begin{bmatrix} C \\ M \\ Y \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (3-5)$$

trong đó giả định rằng tất cả các giá trị màu RGB đã được chuẩn hóa trong đoạn [0, 1]. Phương trình (3-5) minh họa bản chất ánh sáng phản xạ từ bề mặt phủ mực cyan thuần không chứa ánh sáng đỏ (tức là, $C = 1 - R$ trong phương trình). Tương tự, magenta thuần không phản xạ xanh lá cây, và yellow thuần không phản xạ xanh da trời. Phương trình (3-5) cũng cho thấy rằng giá trị RGB có thể dễ dàng được thu được từ một bộ giá trị CMY bằng cách lấy 1 trừ giá trị CMY.

Theo Hình 3.4, các lượng bằng nhau của các thành phần cơ bản của chất tạo màu (gồm cyan, magenta và yellow) nên tạo ra màu đen. Trong thực tế, do các thành phần C, M và Y của chất tạo màu hiếm khi là các màu thuần, việc kết hợp những màu này để in màu đen thường tạo ra một màu nâu đậm thay vì đen thuần. Vì vậy, để tạo ra màu đen thuần (là màu cơ bản

trong in ấn), một màu thứ tư, đen, được thêm vào, được ký hiệu là K, tạo nên mô hình màu CMYK. Màu đen được thêm vào với tỉ lệ cần thiết để tạo ra màu đen thuần. Do đó, trong in ấn khi ta nói về "in ấn bốn màu" nghĩa là chúng ta đang nói đến ba màu CMY, cộng với một phần của màu đen.


3.2.3. Mô hình HSI

Như chúng ta đã thấy, việc tạo ra màu trong các mô hình RGB, CMY và CMYK, cũng như chuyển đổi từ một mô hình sang mô hình khác, là tương đối đơn giản. Những hệ màu này thích hợp cho các thiết bị phần cứng cụ thể. Ngoài ra, hệ thống RGB phù hợp tốt với thực tế mắt người nhạy cảm với các màu cơ bản là đỏ, xanh lá cây và xanh da trời. Tuy nhiên, các mô hình màu RGB, CMY và các mô hình màu tương tự không phải lúc nào cũng phù hợp để mô tả màu sắc thực tế theo trực quan của con người. Ví dụ, khi mô tả màu của một chiếc ô tô với mọi người, chúng ta sẽ không nói về tỷ lệ phần trăm của mỗi màu cơ bản tạo nên màu sắc của ô tô. Hơn nữa, chúng ta cũng không nghĩ về ảnh màu như được tạo ra từ ba ảnh màu cơ bản gồm R, G, B để kết hợp để tạo ra ảnh thực tế.

Khi con người quan sát một đối tượng màu sắc, chúng ta mô tả nó một cách tự nhiên bằng các thông tin: màu sắc cơ bản, độ bão hòa và độ sáng. Từ phần thảo luận ở Mục 3-1, màu sắc là một thuộc tính mô tả một màu sắc tinh khiết (ví dụ vàng thuần, cam, hoặc đỏ thuần), trong khi độ bão hòa đo lường mức độ mà một màu sắc thuần bị pha loãng bởi ánh sáng trắng. Độ sáng là một đặc điểm chủ quan khó đo lường. Nó bao gồm ý tưởng (độc lập với màu hay còn gọi là không màu) về độ mạnh yếu - cường độ và là một trong những yếu tố chính trong việc mô tả cảm giác màu sắc. Chúng ta biết rằng cường độ (mức xám) là một đặc điểm rất hữu ích của hình ảnh xám (không màu). Đối với mô hình màu HSI (hue, saturation, intensity), ta sẽ tách rời thành phần cường độ khỏi thông tin về màu sắc (gồm màu cơ bản và độ bão hòa) trong một ảnh màu. Do đó, mô hình HSI là một công cụ hữu ích để phát triển các thuật toán xử lý hình ảnh dựa trên mô tả màu sắc tự nhiên và trực quan đối với con người, chính là những người phát triển và người sử dụng các thuật toán này. Có thể tóm tắt rằng RGB là lựa chọn lý tưởng cho việc tạo ra màu sắc hình ảnh (như trong việc chụp hình bằng camera màu hoặc hiển thị hình ảnh trên màn hình máy tính), nhưng việc sử dụng nó để mô tả màu sắc có giới hạn nhiều hơn. Phần tiếp theo sẽ cung cấp một cách hiệu quả để làm điều này, chính là hệ màu HSI.

Một ảnh màu RGB được tạo thành từ ba ảnh xám (đại diện cho cường độ của các màu đỏ, xanh lá cây và xanh da trời), vì vậy ngược lại chúng ta cũng có thể trích xuất cường độ từ một ảnh RGB. Có thể thấy rõ hơn nếu chúng ta lấy khối màu từ Hình 4-7 và đặt nó ở góc đen, (0, 0, 0), với đỉnh trắng, (1, 1, 1), trực tiếp phía trên nó [xem Hình 4-10(a)]. Như đã trong hình Hình 3.7, thang đo cường độ (mức xám) nằm dọc theo đường nối giữa hai đỉnh này. Trong các Hình 3.10(a) và (b), đường (trục cường độ) nối giữa hai đỉnh đen và trắng là thẳng đứng. Do đó, nếu chúng ta muốn xác định thành phần cường độ của bất kỳ điểm màu nào trong Hình 3.10, chúng ta chỉ cần định nghĩa một mặt phẳng chứa điểm màu đó và, đồng thời, vuông góc với trục cường độ. Giao điểm của mặt phẳng với trục cường độ sẽ cho ta điểm có giá trị cường độ trong khoảng [0, 1]. Từ đó có thể suy ra rằng độ bão hòa của một màu sắc tăng theo hàm số của khoảng cách tới trục cường độ. Độ bão hòa của các điểm trên trục cường độ là bằng không. Tất cả các điểm dọc theo trục này đều là màu xám.

a b




Hình 3.9 Ý tưởng về quan hệ giữa mô hình màu RGB và mô hình màu HSI.

Màu sắc - hue cũng hoàn toàn có thể được xác định từ giá trị RGB. Trong Hình 3.9(b) thể hiện một mặt phẳng được định nghĩa bởi ba điểm đen, trắng và xanh da trời. Do đen và trắng nằm trong mặt phẳng nên trục cường độ cũng nằm trong mặt phẳng đó. Hơn nữa, chúng ta thấy rằng tất cả các điểm nằm trong phần mặt phẳng được xác định bởi trục cường độ và các biên của khối hộp có cùng màu cơ bản (xanh da trời trong trường hợp này). Chúng ta cũng đã biết rằng tất cả các màu được tạo ra bằng ba màu nằm trong tam giác được xác định bởi những màu đó. Nếu hai trong những điểm đó là đen và trắng, và điểm thứ ba là một điểm màu, tất cả các điểm trên tam giác đó sẽ có cùng màu cơ bản - hue (cường độ sáng và độ bão hòa của các điểm trong tam giác này sẽ khác nhau). Bằng cách xoay mặt phẳng đã tô màu quanh trục cường độ thẳng đứng, chúng ta sẽ thu được các màu cơ bản khác nhau. Từ đó chúng ta có thể kết luận rằng giá trị màu cơ bản - hue, độ bão hòa - saturation, và cường độ - intensity của không gian màu HSI có thể được tạo ra từ khối màu RGB. Cụ thể, chúng ta có thể chuyển đổi bất kỳ điểm RGB nào thành một điểm tương ứng trong không gian màu HSI với các công thức chuyển đổi sẽ được trình bày tiếp theo dưới đây.

Điểm chính liên quan đến cấu trúc khối trong Hình 3.9, và không gian màu HSI tương ứng của nó, là không gian HSI được biểu diễn bằng một trục cường độ thẳng đứng và quỹ đạo của các điểm màu nằm trên các mặt phẳng vuông góc với trục đó. Khi các mặt phẳng di chuyển lên và xuống trục cường độ, các biên được xác định bởi giao điểm của mỗi mặt phẳng với các mặt của khối hộp có hình dạng tam giác hoặc lục giác. Điều này có thể được hình dung dễ dàng hơn bằng cách nhìn thẳng theo trục các cấp xám của khối, như thể hiện trong Hình 3.10(a). Chúng ta thấy rằng các màu cơ bản RGB được tách biệt bởi góc 120° . Các màu thứ cấp cách màu cơ bản 60° , điều này có nghĩa là góc giữa chúng cũng là 120° . Hình 3.10(b) cho thấy cùng một hình dạng lục giác và một điểm màu tùy ý (được hiển thị dưới dạng một chấm). Màu cơ bản của điểm được xác định bởi một góc từ một điểm tham chiếu nào đó. Thông thường là một góc 0° từ trục màu đỏ được quy định là màu cơ bản 0, và màu cơ bản tăng ngược chiều kim đồng hồ kể từ màu 0 đó. Độ bão hòa (khoảng cách từ trục đứng) là độ dài của vector từ gốc đến điểm màu đang nghiên cứu. Lưu ý rằng góc được xác định bởi giao điểm của mặt màu với trục đứng – trục cường độ sáng. Các thành phần quan trọng của không gian màu HSI là trục cường độ thẳng đứng, chiều dài của vector đến một điểm màu, và góc mà vector này tạo với trục màu đỏ. Các mặt phẳng HSI được xác định từ khối RGB có thể có dạng hình lục giác, tam giác, hoặc thậm chí là một vòng tròn, như Hình 3.10(c) và (d). Hình dạng được chọn không quan trọng vì bất kỳ hình dạng nào trong số ba hình dạng này đều có thể biến đổi thành một trong hai hình dạng còn lại thông qua một biến đổi hình học.

a
b c d



Hình 3.10 Màu sắc và độ bão hoà trong mô hình màu HIS. Điểm – dot là bất kỳ điểm màu nào trong khối RGB. Góc từ trục đỏ - Red cho giá trị của màu sắc. Độ dài vector là độ bão hoà – saturation. Cường độ của tất cả các màu trong các mặt phẳng đó được cho bởi vị trí của mặt phẳng giao cắt đi qua điểm màu và vuông góc với trục cường độ.

3.2.4. Chuyển đổi từ RGB sang HSI

Cho một ảnh RGB, thành phần màu sắc H – Hue của mỗi pixel RGB được thu nhận sử dụng phương trình:

$$H = \begin{cases} \theta & \text{if } B \leq G \\ 360 - \theta & \text{if } B > G \end{cases} \quad (3-6)$$

Với

$$\theta = \cos^{-1} \left\{ \frac{\frac{1}{2}[(R - G) + (R - B)]}{[(R - G)^2 + (R - B)(G - B)]^{1/2}} \right\} \quad (3-7)$$

Độ bão hoà được tính bởi:

$$S = 1 - \frac{3}{(R + G + B)} [\min(R, G, B)] \quad (3-8)$$

Và cường độ được tính theo phương trình:

$$I = \frac{1}{3}(R + G + B) \quad (3-8)$$

Các phương trình này giả sử rằng giá trị RGB đã được chuẩn hóa trong đoạn $[0, 1]$, và góc θ được đo theo trục màu đỏ của không gian HSI, như trong Hình 3.10. Màu sắc cơ bản – hue có thể được chuẩn hoá vào đoạn $[0, 1]$ bằng cách chia góc thu được cho 360° . Hai tham số còn lại là độ bão hoà và cường độ đã thoả mãn có giá trị nằm trong đoạn $[0, 1]$.

3.2.5. Chuyển đổi HSI sang RGB

Với các giá trị của các tham số HSI nằm trong khoảng $[0, 1]$, chúng ta muốn tìm giá trị RGB tương ứng trong cùng khoảng. Các phương trình áp dụng phụ thuộc vào giá trị của H. Có ba miền quan trọng, tương ứng với các khoảng 120° trong việc phân chia màu cơ bản – hue. Chúng ta bắt đầu bằng cách nhân H với 360° , để đưa lại giá trị màu cơ bản H về khoảng $[0^\circ, 360^\circ]$.

Vùng RG: $0^\circ \leq H \leq 120^\circ$. Khi H thuộc vùng này, các thành phần RGB được xác định bởi các phương trình:

$$B = I(1 - S) \quad (3-9)$$

$$R = I \left[1 + \frac{S \cos H}{\cos(60^\circ - H)} \right] \quad (3-10)$$

Và

$$G = 3I - (R + B) \quad (3-11)$$

Vùng RG: $120^\circ \leq H \leq 240^\circ$. Khi H thuộc vùng này, đầu tiên chúng ta trừ H cho 120° , sau đó các thành phần RGB được xác định bởi các phương trình:

$$H = H - 120^\circ \quad (3-12)$$

$$R = I(1 - S) \quad (3-13)$$

$$G = I \left[1 + \frac{S \cos H}{\cos(60^\circ - H)} \right] \quad (3-14)$$

Và

$$B = 3I - (R + G) \quad (3-15)$$

Vùng RG: $240^\circ \leq H \leq 360^\circ$. Khi H thuộc vùng này, chúng ta trừ H cho 240° và các thành phần RGB được xác định bởi các phương trình:

$$H = H - 240^\circ \quad (3-16)$$

$$G = I(1 - S) \quad (3-17)$$

$$B = I \left[1 + \frac{S \cos H}{\cos(60^\circ - H)} \right] \quad (3-18)$$

Và


$$R = 3I - (G + B) \quad (3-19)$$

3.3. Xử lý ảnh giả màu

Xử lý hình ảnh giả màu (đôi khi được gọi là màu giả) bao gồm việc gán màu cho các giá trị xám dựa trên một tiêu chí cụ thể nào đó. Thuật ngữ giả màu hay màu giả được sử dụng để phân biệt quá trình gán màu cho ảnh không màu – acromatic từ các quá trình liên quan đến ảnh màu thực được trình bày trong phần tiếp theo. Việc chính của giả màu là để con người có thể hình dung và diễn giải các dữ kiện xuất hiện trong ảnh xám hoặc chuỗi hình ảnh xám. Như đã nói ở đầu chương này, một trong những động lực chính để sử dụng màu là vì con người có thể phân biệt hàng nghìn gam màu và độ sáng, so với số mức xám thường là khá nhỏ.

3.3.1. Cắt cường độ sáng và mã hoá màu

Các kỹ thuật cắt cường độ (đôi khi được gọi là mật độ) và mã hoá màu là những ví dụ đơn giản và sớm nhất của xử lý ảnh kỹ thuật số giả màu. Nếu ảnh được hiểu như một hàm 3D, phương pháp có thể được xem như là việc đặt các mặt phẳng song song với mặt phẳng tọa độ của hình ảnh; mỗi mặt phẳng "cắt" hàm trong miền giao cắt. Hình 3.11 thể hiện một ví dụ về việc sử dụng một mặt phẳng $f(x, y) = l_i$ ở để cắt hàm cường độ sáng của hình ảnh thành hai mức.



Hình 3.11 Biểu diễn đồ họa của kỹ thuật cắt cường độ.


Nếu mỗi bên của mặt phẳng trong Hình 3.11 được gán một màu khác nhau, bất kỳ pixel nào có độ sáng lớn hơn mặt phẳng sẽ được mã màu một cách, và bất kỳ pixel nào ở dưới mặt phẳng sẽ được mã màu khác. Các giá trị nằm trên mặt phẳng có thể được gán một trong hai màu một cách tùy ý, hoặc chúng có thể được gán một màu thứ ba để làm nổi bật tất cả các pixel ở cùng một mức. Kết quả như vậy là một ảnh hai màu (hoặc ba màu) mà diện tích tương đối có thể được kiểm soát bằng cách di chuyển mặt phẳng cắt lên và xuống theo trục độ sáng.

Nói chung, kỹ thuật cho nhiều màu có thể được tóm tắt như sau. Đặt $[0, L-1]$ đại diện cho thang các mức xám, đặt l_0 biểu diễn mức đen $[f(x,y)=0]$ và đặt l_{L-1} biểu diễn mức trắng $[f(x,y)=L-1]$. Giả sử rằng P mặt phẳng vuông góc với trục cường độ sáng được định nghĩa tại các mức $l_1, l_2, \dots, l_P$. Sau đó, giả sử rằng $0 < P < L-1$, P mặt phẳng chia thang mức xám thành $P + 1$ khoảng $I_1, I_2, \dots, I_{P+1}$. Phép gán cường độ thành màu tại mỗi vị trí pixel (x, y) được thực hiện theo phương trình:

$$\text{Nếu } f(x,y) \text{ thuộc } I_k, \text{ đặt } f(x,y) = c_k \quad (3-20)$$

trong đó c_k là màu được liên kết với đoạn cường độ sáng thứ I_k được định nghĩa bởi các mặt phẳng tại $l = k - 1$ và $l = k$.

Tương tự Hình 3.11, Hình 3.12 thể hiện một cách tiếp cận tương đương. Theo ánh xạ trong hình, mọi cường độ sáng dưới mức l_i được gán một màu, và bất kỳ mức nào ở trên sẽ được gán một màu khác. Khi sử dụng nhiều mức phân chia hơn, hàm ánh xạ có dạng bậc thang.




Hình 3.12 Một cách biểu diễn khác của kỹ thuật cắt cường độ sáng.

3.3.2. Các phép biến đổi cường độ sáng thành màu

Các phép biến đổi khác có tính chất tổng quát hơn, do đó có khả năng đạt được một dải rộng hơn các kết quả cải thiện giả màu so với kỹ thuật cắt cường độ sáng đơn giản đã được trình bày. Hình 3.13 trình bày một phương pháp như vậy. Về cơ bản, ý tưởng nền móng của


phương pháp này là thực hiện ba biến đổi độc lập trên cường độ sáng của các pixel đầu vào. Ba kết quả đầu ra sau đó được đưa riêng rẽ vào các kênh đỏ, xanh lá cây và xanh da trời tương ứng của hệ màu RGB. Phương pháp này tạo ra một ảnh tổng hợp mà nội dung màu sắc của nó được điều chỉnh bởi bản chất của các hàm biến đổi.



Hình 3.13 Sơ đồ khối của hàm cho xử lý ảnh giả màu. Các ảnh f_R , f_G và f_B được đưa vào các đầu vào đỏ, xanh lá cây và xanh da trời tương ứng của hệ màu RGB.

Phương pháp cắt độ sáng được trình bày trong phần trước là một trường hợp đặc biệt của kỹ thuật tổng quát này. Trong trường hợp đó, các hàm tuyến tính theo từng đoạn của các mức cường độ sáng (xem Hình 3.12) được sử dụng để tạo ra các màu. Ngược lại, phương pháp được trình bày trong phần này có thể dựa trên các hàm tròn, phi tuyến, điều này mang lại khả năng linh hoạt đáng kể cho phương pháp.

Phương pháp trong Hình 3.13 dựa trên một hình ảnh xám đơn. Thông thường, việc kết hợp một số ảnh xám thành một ảnh tổng hợp màu sắc là biến đổi được quan tâm, như minh họa trong Hình 3.14. Một ứng dụng phổ biến của phương pháp này là trong xử lý hình ảnh đa phổ (ví dụ các kênh của ảnh vệ tinh v.v.), nơi các bộ cảm biến khác nhau tạo ra các ảnh xám riêng biệt, mỗi ảnh thuộc một dải phổ khác nhau. Các phương pháp xử lý bổ sung thể hiện trong Hình 3.14 có thể là các kỹ thuật như cân bằng màu sắc và lọc không gian, sẽ được trình bày sau trong chương này. Khi được kết hợp với các thông tin nền về đặc tính vật lý của mỗi dải phổ, mã màu theo cách này là một công cụ hỗ trợ mạnh mẽ cho phân tích thị giác người đối với các ảnh đa phổ phức tạp.



Hình 3.14 Một phương pháp mã giả màu sử dụng nhiều ảnh xám. Các đầu vào là các ảnh xám. Các đầu ra là ba thành phần của một ảnh tổng hợp RGB.

3.4. Cơ bản về xử lý ảnh màu đầy đủ

Trong phần này, chúng ta bắt đầu nghiên cứu các phương pháp xử lý cho ảnh màu đầy đủ. Các kỹ thuật được phát triển trong các phần tiếp theo minh họa cách xử lý hình ảnh màu đầy đủ cho nhiều nhiệm vụ xử lý hình ảnh. Các phương pháp xử lý ảnh màu đầy đủ thuộc hai nhóm chính. Trong nhóm đầu tiên, chúng ta xử lý từng ảnh xám thành phần một cách riêng lẻ, sau đó tạo ra một ảnh màu tổng hợp từ các thành phần đã được xử lý riêng rẽ đó. Trong nhóm thứ hai, chúng ta làm việc trực tiếp với các điểm ảnh màu. Vì ảnh màu đầy đủ có ít nhất ba thành phần, điểm ảnh màu ứng với các vector. Ví dụ, trong hệ RGB, mỗi điểm màu có thể được hiểu là một vector mở rộng từ gốc đến điểm đó trong hệ tọa độ RGB.

Đặt c biểu diễn một vector tùy ý trong không gian màu RGB:


$$c = \begin{bmatrix} c_R \\ c_G \\ c_B \end{bmatrix} = \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (3-21)$$

Phương trình này cho thấy rằng các thành phần của c là các thành phần RGB của một ảnh màu tại một điểm. Chúng ta xem xét thực tế rằng màu của các điểm ảnh trong một ảnh là một hàm của các tọa độ không gian (x, y) bằng cách sử dụng ký hiệu:

$$c(x, y) = \begin{bmatrix} c_R(x, y) \\ c_G(x, y) \\ c_B(x, y) \end{bmatrix} = \begin{bmatrix} R(x, y) \\ G(x, y) \\ B(x, y) \end{bmatrix} \quad (3-22)$$

Đối với một hình ảnh có kích thước là $M \times N$ có MN vector như vậy, $c(x, y)$, cho $x = 0, 1, 2, \dots, M-1$ và $y = 0, 1, 2, \dots, N-1$.

a b



Hình 3.15 Lân cận không gian cho ảnh xám và ảnh màu RGB. (b) cho thấy một cặp tọa độ không gian duy nhất, (x, y) , xác định cùng một vị trí không gian trong cả ba hình ảnh.

3.5. Các phép biến đổi màu sắc

Các kỹ thuật mô tả trong phần này, gọi chung là biến đổi màu sắc, xử lý các thành phần của một ảnh màu trong ngữ cảnh của một mô hình màu duy nhất, khác với các biến đổi màu sắc giữa các mô hình màu, như đã trình bày trong Phần 3.2.

3.5.1. Công thức

Tương tự như các kỹ thuật biến đổi cường độ sáng đã trình bày, chúng ta mô hình hóa các biến đổi màu cho hình ảnh đa phổ bằng cách sử dụng biểu thức tổng quát:

$$s_i = T_i(r_i) \quad i = 1, 2, \dots, n \quad (3-24)$$

Trong đó,


n là số các ảnh thành phần; r_i là giá trị cường độ sáng của ảnh thành phần đầu vào; s_i là giá trị cường độ sáng tương ứng trong không gian ảnh đầu ra, và T là một tập hợp các hàm biến đổi hoặc ánh xạ màu hoạt động trên r_i để tạo ra s_i . Phương trình (3-24) được áp dụng riêng

để cho tất cả các pixel trong hình ảnh đầu vào. Ví dụ, trong trường hợp hình ảnh màu RGB, $n=3$, r_1, r_2, r_3 là giá trị cường độ sáng tại một điểm trong các ảnh thành phần đầu vào, và s_1, s_2, s_3 là các pixel đầu ra tương ứng đã được biến đổi. i cũng là một chỉ số dưới của T có nghĩa là, về nguyên tắc, chúng ta có thể thực hiện một biến đổi khác nhau cho mỗi hình ảnh thành phần đầu vào.

Chúng ta có thể áp dụng Công thức (3-24) cho bất kỳ ảnh thành phần trong không gian màu nào. Về mặt lý thuyết, bất kỳ biến đổi nào cũng có thể được thực hiện trong mô hình màu bất kỳ. Tuy nhiên, trong thực tế, một số phép biến đổi thích hợp hơn cho các mô hình màu cụ thể. Đối với một biến đổi cho trước, các tác động của việc biến đổi giữa các dạng biểu diễn phải được xem xét cụ thể trong không gian màu kết quả.

3.5.2. Màu tương phản

Vòng tròn màu (còn được gọi là bánh xe màu) trong Hình 3.16 do Isaac Newton phát minh vào thế kỷ 17 bằng cách nối các đầu mút của quang phổ màu. Vòng tròn màu là một biểu diễn hình ảnh của các màu được sắp xếp theo mối quan hệ màu sắc giữa chúng. Vòng tròn được tạo ra bằng cách đặt các màu chính cách đều với nhau. Sau đó, các màu phụ được đặt giữa các màu chính, cũng sắp xếp đều. Kết quả tổng là các màu ở phía đối diện trực tiếp trên vòng màu được gọi là màu tương phản. Mối quan tâm của chúng ta đối với các màu tương phản là ở chỗ chúng tương tự như ảnh xám âm bản mà đã. Tương tự như trường hợp ảnh xám, màu tương phản hữu ích để làm nổi bật chi tiết ẩn sau các vùng tối của một ảnh màu, đặc biệt là khi các vùng đó chiếm ưu thế về kích thước.



Hình 3.16 Các màu tương phản trên bánh xe màu.

3.5.3. Cắt màu sắc

Làm nổi bật một vùng màu nhất định nào đó trong một ảnh là hữu ích để phân tách các đối tượng khỏi phần ảnh xung quanh. Ý tưởng cơ bản có thể là:

- (1) hiển thị các màu cần quan tâm sao cho chúng nổi bật so với nền;
- (2) dùng miền được xác định bởi các màu như một mặt nạ cho xử lý tiếp theo.

Cách tiếp cận đơn giản nhất là mở rộng các kỹ thuật cắt cường độ sáng ở phần trước. Tuy nhiên, do mỗi pixel màu là một đại lượng n chiều, các hàm biến đổi màu phức tạp hơn so với các hàm biến đổi mức xám tương ứng. Trên thực tế, các phép biến đổi được yêu cầu thường phức tạp hơn so với các biến đổi màu thành phần đã trình bày. Điều này là do tất cả các phương pháp cắt màu thực tế đều yêu cầu mỗi thành phần màu đã biến đổi của mỗi pixel là một hàm của tất cả n thành phần màu ban đầu của pixel đó.

Một trong những cách đơn giản nhất để "cắt" một ảnh màu là ánh xạ các màu nằm ngoài một dải màu quan tâm vào một màu trung tính không nổi bật. Nếu các màu cần quan tâm được bao quanh bởi một khối (hoặc siêu khối cho n chiều) có chiều rộng W và tâm tại một màu mẫu (ví dụ, trung bình) với các thành phần là $(a_1, a_2, \dots, a_n)$, tập các biến đổi cần thiết là:

$$s_i = \begin{cases} 0.5 & \text{if } |r_j - a_j| > \frac{W}{2} \text{ any } 1 \leq j \leq n \\ r_i & \text{otherwise} \end{cases} \quad i = 1, 2, \dots, n \quad (3-25)$$

Các biến đổi này làm nổi bật các màu xung quanh màu mẫu bằng cách buộc tất cả các màu khác về giữa không gian màu tham chiếu (đây là một điểm trung tính được chọn ngẫu nhiên). Ví dụ đối với không gian màu RGB, một điểm trung tính phù hợp là mức xám trung bình hoặc màu $(0.5, 0.5, 0.5)$.

Nếu một hình cầu được sử dụng để xác định các màu quan tâm, công thức (4-25) trở thành:

$$s_i = \begin{cases} 0.5 & \text{if } \sum_{j=1}^n (r_j - a_j)^2 > R_0^2 \\ r_i & \text{otherwise} \end{cases} \quad i = 1, 2, \dots, n \quad (3-26)$$

Ở đây, R_0 là bán kính của hình cầu bao quanh (hoặc siêu cầu cho n chiều) và $(a_1, a_2, \dots, a_n)$ là các thành phần của tâm hình cầu (tức là màu mẫu). Các biến thể hữu ích khác của công thức (3-25) và (3-26) bao gồm việc triển khai nhiều màu mẫu và giảm cường độ sáng của các màu ở bên ngoài khu vực quan tâm - thay vì đặt tất cả chúng thành một hằng số trung tính.

3.5.4. Các hiệu chỉnh màu và tông màu

Các vấn đề liên quan đến dải tông màu của một ảnh cần được hiệu chỉnh trước khi các bất thường về màu sắc, chẳng hạn như màu quá bão hoà và dưới bão hoà, có thể được xử lý. Dải tông màu của một hình ảnh, còn được gọi là kiểu xác định – key type, là sự phân bố tông thể của cường độ màu. Hầu hết thông tin trong các ảnh high-key được tập trung ở các mức cường độ cao (hoặc các mức sáng); các màu của các ảnh low-key chủ yếu nằm ở các mức cường độ thấp; và các ảnh middle-key nằm ở giữa. Tương tự như trong trường hợp ảnh xám, chúng ta thường mong muốn phân bố cường độ của một ảnh màu là cân bằng giữa các mức sáng và tối.

3.5.5. Xử lý lược đồ xám của ảnh màu

Khác với các phương pháp cải thiện ảnh màu mang tính tương tác ở các phần trước, các biến đổi xử lý lược đồ xám của ảnh đa cấp xám có thể được áp dụng vào ảnh màu một cách tự động. Lưu ý rằng cân bằng lược đồ xám xác định một cách tự động một biến đổi tạo ra một ảnh có lược đồ xám cân bằng. Như chúng ta đã thấy, xử lý lược đồ xám có thể khá hiệu quả trong việc xử lý ảnh có độ tương phản thấp high-key, middle-key hoặc low-key. Tuy nhiên với ảnh màu, việc cân bằng một cách riêng rẽ lược đồ xám của các ảnh thành phần của một ảnh màu thường dẫn đến lỗi màu sắc. Một cách tiếp cận có logic hơn là phân bố đồng đều cường độ của các màu, mà duy trì màu cơ bản (ví dụ như tham số màu sắc H trong hệ HSI) không thay đổi.

3.6. Làm trơn và làm sắc nét ảnh màu

Bước tiếp theo của các phép biến đổi từng điểm ảnh của một ảnh màu (không xem xét đến các điểm ảnh lân cận như đã trình bày trong phần trước) là phép biến đổi giá trị của điểm ảnh dựa trên các đặc trưng của các điểm ảnh xung quanh. Trong phần này, các cơ bản của kiểu biến đổi lân cận sẽ được minh họa trong ngữ cảnh làm trơn và làm sắc nét ảnh màu.

3.6.1. Làm trơn ảnh màu

Theo Hình 3.15(a) và các nội dung đã được trình bày, việc làm trơn hay làm mịn ảnh xám

có thể được xem như là một phép lọc không gian trong đó các hệ số của nhân - kernel lọc có cùng giá trị. Khi kernel trượt qua hình ảnh cần làm mịn, mỗi pixel sẽ được thay thế bằng trung bình của các pixel trong vùng lân cận xác định bởi kernel. Như Hình 3.15(b) cho thấy, khái niệm này dễ dàng mở rộng cho việc xử lý ảnh đầy đủ màu sắc. Sự khác biệt chính là thay vì giá trị cường độ sáng vô hướng (chỉ có 1 giá trị cho mỗi pixel), chúng ta làm việc với các vector thành phần theo dạng được cho trong phương trình (3-22).

Ký hiệu S_{xy} là tập hợp các tọa độ xác định một vùng lân cận có tâm tại (x, y) trong một ảnh màu RGB. Trung bình của các vector thành phần RGB trong vùng lân cận này là:

$$\bar{c}(x, y) = \frac{1}{K} \sum_{(s, t) \in S_{xy}} c(s, t) \quad (3-27)$$

Từ phương trình (3-22) và các tính chất cộng vector ta có:

$$\bar{c}(x, y) = \begin{bmatrix} \frac{1}{K} \sum_{(s, t) \in S_{xy}} R(s, t) \\ \frac{1}{K} \sum_{(s, t) \in S_{xy}} G(s, t) \\ \frac{1}{K} \sum_{(s, t) \in S_{xy}} B(s, t) \end{bmatrix} \quad (3-28)$$

Chúng ta thấy rằng các thành phần của vector này là các ảnh vô hướng thu được bằng cách làm mịn độc lập trên mỗi mặt phẳng của ảnh RGB gốc bằng cách sử dụng phép xử lý lằng giềng thông thường với ảnh xám. Do đó, ta kết luận rằng làm mịn bằng cách sử dụng phép trung bình của vùng lằng giềng có thể được thực hiện trên cơ sở từng mặt màu riêng lẻ. Kết quả là giống như khi phép trung bình được thực hiện sử dụng các vector màu RGB.

3.6.2. Làm sắc nét ảnh màu

Ở đây chúng ta xem xét việc làm sắc nét ảnh sử dụng toán tử Laplace. Theo tính chất của vector ta có Laplace của 1 vector được định nghĩa là một vector mà các thành phần của nó là Laplace của các thành phần vô hướng riêng rẽ. Trong ảnh màu RGB, Laplace của 1 vector c trong phương trình (3-22) là:

$$\nabla^2[c(x, y)] = \begin{bmatrix} \nabla^2 R(x, y) \\ \nabla^2 G(x, y) \\ \nabla^2 B(x, y) \end{bmatrix} \quad (3-29)$$

Mà, như ở phần trước, cho chúng ta kết quả tính toán Laplace của một ảnh màu đầy đủ bằng cách tính toán Laplace riêng rẽ của mỗi ảnh thành phần.

3.7. Sử dụng màu trong phân vùng ảnh màu

Phân vùng ảnh là quá trình phân chia ảnh thành các vùng. Mặc dù phân vùng ảnh là một nội dung quan trọng của xử lý ảnh. Chúng ta sẽ trình bày ngắn gọn phân vùng ảnh màu ở đây để đảm bảo tính liên tục nội dung.

3.7.1. Phân vùng ảnh trong không gian màu HSI

Nếu chúng ta muốn phân vùng một ảnh dựa trên màu sắc và đồng thời muốn làm việc trên từng mặt phẳng riêng lẻ, thì không gian màu HSI nên được xét đầu tiên bởi vì trong hệ HIS màu sắc được biểu diễn thuận tiện trong ảnh màu cơ bản - ảnh H. Thông thường, độ bão hòa - ảnh S được sử dụng như ảnh mặt nạ để cô lập các khu vực quan tâm khác nhau trong ảnh H. Ảnh cường độ sáng - ảnh I ít được sử dụng hơn trong phân vùng ảnh màu vì nó không mang theo thông tin màu sắc.


3.7.2. Phân vùng ảnh trong không gian màu RGB

Mặc dù việc làm việc trong không gian HSI trực quan hơn theo ý nghĩa là các màu được biểu diễn theo một định dạng quen thuộc hơn, phân vùng ảnh là một lĩnh vực mà thường đạt được kết quả tốt hơn bằng cách sử dụng các vector màu RGB. Phương pháp này khá tường minh. Giả sử mục tiêu là phân vùng các đối tượng thuộc một dải màu cụ thể trong một ảnh RGB. Cho trước một tập các điểm màu mẫu đại diện cho các màu quan tâm, chúng ta có được một ước lượng về màu "trung bình" mà chúng ta muốn phân vùng. Ký hiệu màu trung bình này bằng vector RGB a . Mục tiêu của phân vùng là phân loại mỗi pixel RGB trong một ảnh cho trước xem có màu trong khoảng đã xác định hay không. Để thực hiện so sánh này, cần có một độ đo tính tương đồng. Một trong những độ đo đơn giản nhất là khoảng cách Euclid. Ký hiệu z là một điểm tùy ý trong không gian RGB. Chúng ta nói rằng z tương tự với a nếu khoảng cách giữa chúng nhỏ hơn một ngưỡng xác định D_0 . Khoảng cách Euclid giữa z và a được tính bằng công thức:

$$\begin{aligned} D(z, a) &= \|z - a\| \\ &= [(z - a)^T (z - a)]^{\frac{1}{2}} \\ &= [(z_R - a_R)^2 + (z_G - a_G)^2 + (z_B - a_B)^2]^{\frac{1}{2}} \end{aligned} \quad (3-30)$$

Ở đây các chỉ số dưới R, G và B ký hiệu các thành phần RGB của các vector a và z . Vị trí các điểm mà $D(z, a) \leq D_0$ là một hình cầu đặc với bán kính D_0 , như minh họa trong Hình 3.17(a). Các điểm nằm bên trong hình cầu đáp ứng tiêu chí màu chỉ định; các điểm bên ngoài hình cầu không đáp ứng. Mã hóa hai tập hợp điểm này trong ảnh, chẳng hạn, với màu đen và trắng tạo ra một hình ảnh phân đoạn nhị phân.

a b c



Hình 3.17 Ba phương pháp để đóng các vùng dữ liệu để phân vùng vector RGB.

Một dạng tổng quát hóa khá hữu ích của Phương trình (3-30) là một đo đặc khoảng cách theo dạng:

$$D(z, a) = [(z - a)^T C^{-1} (z - a)]^{\frac{1}{2}} \quad (3-30)$$

Trong đó C là ma trận hiệp phương sai của các mẫu được chọn để đại diện cho khoảng màu chúng ta muốn phân đoạn. Vị trí của các điểm sao cho $D(z, a) \leq D_0$ mô tả một vật thể elip 3D đặc [Hình 3.17(b)] với tính chất quan trọng là các trục chính của nó được hướng theo hướng của sự phân tán dữ liệu tối đa. Khi $C = I$, ma trận đơn vị 3×3 , phương trình (3-30) suy biến thành phương trình (3-29). Phương pháp phân vùng ảnh khi đó giống như mô tả trong phần ngay trên.

Bởi vì khoảng cách là dương và đơn điệu, chúng ta có thể làm việc với bình phương khoảng cách, do đó, tránh được các phép tính căn bậc hai. Tuy nhiên, việc triển khai các phương trình (3-29) hoặc (3-30) đòi hỏi chi phí tính toán cao cho các ảnh có kích thước thực tế (cỡ lớn), ngay cả khi không tính toán căn bậc hai. Khi đó giải pháp có thể là sử dụng một hộp giới hạn, như mô tả trong Hình 3.17(c). Trong phương pháp này, hộp được lập với tâm a , và kích thước của nó theo mỗi trục màu được chọn tỷ lệ với độ lệch chuẩn của các mẫu theo

từng trục. Chúng ta sử dụng dữ liệu mẫu để tính các độ lệch chuẩn, là các tham số được sử dụng để phân vùng trong phương pháp này. Cho một điểm màu tùy ý, chúng ta phân vùng nó bằng cách xác định xem nó có nằm trên bề mặt hay bên trong hộp không, giống như trong các công thức khoảng cách. Tuy nhiên, việc xác định xem một điểm màu có nằm trong hay ngoài một hộp là đơn giản về mặt tính toán hơn so với một vùng bao hình cầu hoặc elip. Lưu ý rằng thảo luận ở trước phần này là một tổng quát hóa của phương pháp cắt màu đã được giới thiệu ở trên.

3.7.3. Phát hiện biên trong ảnh màu

Về cơ bản, biên là những vị trí trên ảnh nơi có thay đổi đột ngột về cường độ sáng. Việc phát hiện biên là một công cụ quan trọng cho phân vùng ảnh. Trong phần này, chúng ta quan tâm đến vấn đề tính toán biên trên từng ảnh thành phần, thay vì tính toán biên trực tiếp trong không gian vector màu.

Biên trong ảnh xám có thể được phát hiện sử dụng toán tử gradient. Tuy nhiên, gradient không được định nghĩa cho các đại lượng vector trong ảnh màu. Do đó, nếu chúng ta tính toán gradient trên từng hình ảnh riêng rẽ và sau đó kết hợp lại để tạo thành một ảnh biên sẽ dẫn đến kết quả tính toán sai.

Bài toán cần giải quyết là định nghĩa gradient (gồm cả độ lớn và hướng) của vector c trong phương trình (3-22) tại bất kỳ điểm (x, y) nào. Như đã nói, gradient áp dụng cho một hàm vô hướng $f(x, y)$; không áp dụng cho các hàm vector. Dưới đây là một trong những cách mà chúng ta có thể mở rộng khái niệm gradient cho các hàm vector. Nhắc lại là với một hàm vô hướng $f(x, y)$, gradient là một vector chỉ hướng tốc độ thay đổi lớn nhất của f ở vị trí (x, y) .

Ký hiệu r , g , và b là các vector đơn vị theo các trục R , G , và B của không gian màu RGB, và định nghĩa các vector:

$$\mathbf{u} = \frac{\partial R}{\partial x} \mathbf{r} + \frac{\partial G}{\partial x} \mathbf{g} + \frac{\partial B}{\partial x} \mathbf{b} \quad (3-31)$$

và

$$\mathbf{v} = \frac{\partial R}{\partial y} \mathbf{r} + \frac{\partial G}{\partial y} \mathbf{g} + \frac{\partial B}{\partial y} \mathbf{b} \quad (3-32)$$

Đặt các đại lượng g_{xx} , g_{yy} và g_{xy} được định nghĩa theo tích vô hướng của các vector đó như sau:

$$g_{xx} = \mathbf{u} \cdot \mathbf{u} = \mathbf{u}^T \mathbf{u} = \left| \frac{\partial R}{\partial x} \right|^2 + \left| \frac{\partial G}{\partial x} \right|^2 + \left| \frac{\partial B}{\partial x} \right|^2 \quad (3-33)$$

$$g_{yy} = \mathbf{v} \cdot \mathbf{v} = \mathbf{v}^T \mathbf{v} = \left| \frac{\partial R}{\partial y} \right|^2 + \left| \frac{\partial G}{\partial y} \right|^2 + \left| \frac{\partial B}{\partial y} \right|^2 \quad (3-34)$$

Và

$$g_{xy} = \mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v} = \frac{\partial R}{\partial x} \frac{\partial R}{\partial y} + \frac{\partial G}{\partial x} \frac{\partial G}{\partial y} + \frac{\partial B}{\partial x} \frac{\partial B}{\partial y} \quad (3-35)$$

Nhớ rằng R , G và B và các giá trị g là các hàm của x và y . Sử dụng ký hiệu này, người ta đã chứng minh được rằng hướng tốc độ thay đổi mạnh nhất của $c(x, y)$ được cho bởi:

$$\theta(x, y) = \frac{1}{2} \tan^{-1} \left[\frac{2g_{xy}}{g_{xx} - g_{yy}} \right] \quad (3-36)$$

Và giá trị của tốc độ thay đổi của c tại vị trí (x, y) theo hướng $\theta(x, y)$ được cho bởi:

$$F_{\theta}(x, y) = \left\{ \frac{1}{2} \left[(g_{xx} + g_{yy}) + (g_{xx} - g_{yy}) \cos 2\theta(x, y) + 2g_{xy} \sin 2\theta(x, y) \right] \right\}^{\frac{1}{2}} \quad (3-37)$$

Vì $\tan(\alpha) = \tan(\alpha \pm \pi)$, nếu θ_0 là một nghiệm của phương trình (3-36), thì $\theta_0 \pm \pi/2$ cũng là nghiệm. Hơn thế $F_{\theta} = F_{\theta + \pi}$, vì thế F chỉ phải được tính toán cho các giá trị của θ trong khoảng mở $[0, \pi)$. Thực tế là phương trình (3-36) cho hai giá trị cách nhau $\pi/2$ có nghĩa là phương trình này gắn với mỗi điểm (x, y) một cặp 2 hướng trực giao. Theo một trong 2 hướng đó, F là cực đại và nó là cực tiểu theo hướng còn lại. Việc thu nhận các giá trị đó là khá dài dòng và không nhiều lợi ích cho mục tiêu xử lý ảnh màu của chúng ta nên nó sẽ được bỏ qua ở đây. Toán tử Sobel trình bày trong phần phát hiện biên với ảnh xám có thể được sử dụng để tính toán các đạo hàm riêng cần dùng cho các phương trình (3-33) đến (3-35).

3.8. Nhiều trong ảnh màu

Các mô hình nhiều được trình bày cho ảnh xám cũng áp dụng cho ảnh màu. Thông thường, nhiều của một ảnh màu có các đặc tính giống nhau trong mỗi kênh màu, nhưng vẫn có thể xảy ra trường hợp các kênh màu bị ảnh hưởng khác nhau bởi nhiễu. Một khả năng là do các thành phần điện tử của một kênh nào đó gặp sự cố. Tuy nhiên, việc có các mức độ nhiễu khác nhau cho mỗi kênh phần lớn là do khác biệt về mức độ chiếu sáng cho mỗi kênh màu. Ví dụ, việc sử dụng bộ lọc màu đỏ trong một máy ảnh số sẽ giảm khả năng ánh sáng được phát hiện bởi các cảm biến màu đỏ. Thông thường ảnh số có nhiều nhiễu hơn ở mức độ ánh sáng thấp hơn (ánh sáng phản xạ từ đối tượng là yếu), do đó thành phần màu đỏ của ảnh RGB output sẽ có xu hướng bị nhiễu hơn so với hai ảnh thành phần G, B trong tình huống này.

Việc lọc nhiễu với ảnh đầy đủ màu có thể được thực hiện dựa trên từng hình ảnh riêng rẽ hoặc trực tiếp trong không gian vector màu, tùy thuộc vào quá trình xử lý, điều này cũng đúng với nhiều quá trình xử lý khác chúng ta đã giới thiệu. Ví dụ, giảm nhiễu bằng cách sử dụng bộ lọc trung bình cho kết quả giống như trong không gian vector nếu các hình ảnh thành phần được xử lý độc lập. Tuy nhiên, điều đó không đúng với nhiều bộ lọc khác như bộ lọc thống kê v.v.

3.9. Nén ảnh màu

Do số bit cần thiết để biểu diễn màu sắc thường gấp ba đến bốn lần số bit được sử dụng biểu diễn ảnh xám, nén dữ liệu đóng một vai trò quan trọng trong việc lưu trữ và truyền tải màu. Đối với các ảnh RGB, CMY(K), và HSI, dữ liệu nén là các thành phần của mỗi pixel màu (ví dụ: các thành phần đỏ, xanh lá cây, và xanh da trời của các pixel trong một hình ảnh RGB). Nén là quá trình giảm thiểu hoặc loại bỏ dữ liệu dư thừa và/hoặc không liên quan. Các thuật toán nén loại bỏ dư thừa dữ liệu sẽ được trình bày cụ thể trong chương Nén ảnh.

Câu hỏi ôn tập và bài tập

Bài tập 1

Ghi lại tỷ lệ phần trăm ánh sáng đỏ (X), xanh lá cây (Y), và xanh da trời (Z) cần thiết để tạo ra điểm được đặt tên là "trắng ấm – warm white" trong Hình 3.5.

Bài tập 2

Xem xét hai màu hợp lệ bất kỳ c_1 và c_2 với các tọa độ (x_1, y_1) và (x_2, y_2) trong lược đồ độ bão hòa màu Hình 3.5. Thu nhận biểu thức tổng quát cần thiết để tính phần trăm tương đối của các màu c_1 và c_2 tạo thành một màu cụ thể cho trước nằm trên đoạn thẳng nối hai màu này.

Bài tập 3

Xem xét ba màu hợp lệ bất kỳ c_1 , c_2 , và c_3 , với các tọa độ (x_1, y_1) , (x_2, y_2) , và (x_3, y_3) trong biểu đồ độ bão hòa màu của Hình 3.5. Rút ra biểu thức tổng quát cần thiết để tính phần trăm tương đối của c_1 , c_2 , và c_3 tạo thành một màu cụ thể được biết đến nằm trong tam giác có các đỉnh tại các tọa độ của c_1 , c_2 , và c_3 .

Bài tập 4

Hệ màu HSL và HSV được phát triển vì mục đích gì? Dựa theo lý thuyết đã trình bày ở trên, hãy viết code ngắn gọn chuyển ảnh giữa các hệ màu RGB, CMY, HSV và HSB.

Chương 4

XỬ LÝ HÌNH THÁI ẢNH

Sau khi hoàn thành chương này, sinh viên sẽ có thể:


- ✓ Hiểu các khái niệm cơ bản về xử lý hình thái và cách áp dụng chúng vào xử lý ảnh số.
- ✓ Quen với các công cụ được sử dụng cho xử lý hình thái ảnh nhị phân, bao gồm các phép co, giãn, mở, đóng, và cách kết hợp chúng để tạo ra các phép toán phức tạp hơn.
- ✓ Có khả năng phát triển các thuật toán dựa trên hình thái ảnh nhị phân để thực hiện các xử lý như làm mịn hình thái, phát hiện biên, trích xuất các thành phần liên thông, và tạo xương của đối tượng.
- ✓ Quen với cách mà hình thái ảnh nhị phân có thể được mở rộng sang với ảnh xám.
- ✓ Có khả năng phát triển các thuật toán xử lý hình thái ảnh xám để thực hiện các nhiệm vụ như phân vùng cấu trúc, tính toán kích thước hạt – phần tử, tính toán gradient ảnh xám, và những công việc khác.

4.1. Giới thiệu

Ngôn ngữ của hình thái toán học là lý thuyết tập hợp. Do đó, hình thái cung cấp một phương pháp mạnh và thống nhất cho nhiều vấn đề xử lý ảnh. Khi làm việc với ảnh, tập hợp trong hình thái toán học đại diện cho các đối tượng trong những ảnh đó. Trong ảnh nhị phân, các tập hợp đó là các thành phần của không gian số nguyên 2D là Z^2 , trong đó mỗi phần tử của một tập hợp là một bộ (vector 2D) có tọa độ là tọa độ của một pixel đối tượng (thường là vật cảnh - foreground) trong ảnh. Ảnh xám có thể được biểu diễn dưới dạng các tập hợp mà các thành phần của nó thuộc không gian Z^3 . Trong trường hợp này, hai thành phần của mỗi phần tử của tập hợp là tọa độ của một pixel và phần thứ ba tương ứng với giá trị cường độ sáng rời rạc của pixel. Các tập hợp trong không gian nhiều chiều hơn có thể chứa các thuộc tính khác của ảnh, chẳng hạn như màu sắc và các tham số thay đổi theo thời gian.

Các phép toán hình thái được định nghĩa theo ngôn ngữ của các tập hợp. Trong xử lý ảnh, chúng ta sử dụng hình thái với hai loại tập hợp các pixel: đối tượng và các phần tử kết cấu (SE - structuring elements). Thông thường, đối tượng được định nghĩa là các tập hợp của các pixel vật cảnh - foreground. Các phần tử SE có thể được xác định theo ngôn ngữ của cả các pixel vật cảnh và các pixel nền - background. Ngoài ra, các phần tử SE đôi khi chứa các phần tử được gọi là "không quan tâm - don't care", được ký hiệu bằng ký hiệu $\times$ và nó thỏa mãn rằng giá trị của phần tử cụ thể đó trong SE bằng bao nhiêu không quan trọng. Theo nghĩa này, giá trị đó có thể được bỏ qua hoặc có thể được làm để phù hợp với một giá trị mong muốn trong việc tính toán một biểu thức; ví dụ, nó có thể nhận giá trị của một pixel trong một hình ảnh trong các ứng dụng mà mục tiêu là việc khớp giá trị.

Do chúng ta làm việc với ảnh là mảng hình chữ nhật, và các tập hợp nói chung có hình dạng tùy ý, việc áp dụng hình thái trong xử lý ảnh yêu cầu tập hợp được nhúng trong các mảng hình chữ nhật. Trong quá trình tạo ra các mảng như vậy, chúng ta gán giá trị nền cho tất cả các pixel không thuộc tập hợp đối tượng. Hàng trên cùng trong Hình 4.1 cho thấy một ví dụ như vậy. Ở bên trái là các tập hợp theo định dạng đồ họa bạn quen thấy trong các hình minh họa trong tài liệu này. Ở giữa, các tập hợp đã được nhúng trong một nền hình chữ nhật (màu trắng) để tạo thành một hình ảnh đồ họa. Ở bên phải, chúng ta trình bày một hình ảnh số (lưu ý sự có mặt của lưới trong ảnh) là định dạng chúng ta sử dụng cho xử lý ảnh số.




Hình 4.1 Hàng trên cùng. Bên trái: 2 đối tượng được biểu diễn dưới dạng các tập hợp đồ họa (hay dạng hình vẽ). Giữa: các đối tượng đó được nhúng vào một nền để tạo thành một ảnh đồ họa. Bên phải: các đối tượng đó và nền được số hóa để tạo thành một ảnh số (lưu ý sự có mặt của lưới). Dòng thứ hai: Ví dụ về một phần tử SE được biểu diễn dưới dạng một tập hợp, một hình ảnh đồ họa, và cuối cùng là một SE số hóa.

Các phần tử SE được định nghĩa theo cùng một cách, và hàng thứ hai trong Hình 4.1 cho ta một ví dụ. Có một khác biệt quan trọng giữa cách chúng ta biểu diễn ảnh số và phần tử SE số. Quan sát ở phía trên bên phải ta thấy rằng có một biên các pixel nền bao quanh các đối tượng, trong khi không có biên nào quanh SE. Các phần tử SE được sử dụng theo một hình thức tương tự như các kernel tích chập trong không gian (tương tự trong phần lọc ảnh), và biên ảnh vừa mô tả là tương tự với phân chèn thêm các pixel nền quanh ảnh. Các phép toán hình thái thì khác, nhưng các phép chèn thêm nền và phép trượt cửa là giống nhau như trong các phép tính tích chập.

Ngoài các định nghĩa tập hợp nói chung, khái niệm về phản xạ ảnh và tịnh tiến của tập hợp được sử dụng một cách rộng rãi trong hình thái kết hợp với các phần tử SE. Phản xạ của một tập hợp (phần tử SE) B quanh gốc của nó, được ký hiệu bằng $\hat{B}$, được định nghĩa là:

$$\hat{B} = \{w \mid w = -b, \text{ for } b \in B\} \quad (4-1)$$

Nói cách khác, nếu B là một tập hợp các điểm trong không gian 2D, thì $\hat{B}$ là tập hợp các điểm trong B mà tọa độ (x, y) của chúng đã được thay thế bởi $(-x, -y)$. Hình 4.2 mô tả một số ví dụ về các tập hợp số (phần tử SE) và phản xạ của chúng quanh gốc. Dấu chấm ký hiệu gốc của SE. Lưu ý rằng phản xạ đơn giản chỉ là việc quay một SE quanh gốc của nó, và tất cả các phần tử, bao gồm cả phần tử nền và phần tử không quan tâm, đều bị quay.



Hình 4.2 Các phần tử SE và phản xạ của chúng xung quanh gốc ($\times$ là các phần tử không quan tâm, và dấu chấm là gốc). Phản xạ là sự quay 180° của một SE quanh gốc của nó.


Phép tịnh tiến của một tập hợp B bởi điểm $z = (z_1, z_2)$, và được ký hiệu bởi $(B)_z$, được định nghĩa như sau:

$$(B)_z = \{c \mid c = b + z, \text{ for } b \in B\} \quad (4-2)$$

Nói cách khác, nếu B là một tập hợp các điểm trong không gian 2D, thì $(B)_z$ là tập hợp các

điểm trong B mà tọa độ (x, y) được thay thế bằng $(x+z_1, y+z_2)$. Phương thức này được sử dụng để chuyển vị (trượt) phần tử SE trên ảnh, và mỗi vị trí thực hiện một tập các phép toán giữa SE và vùng ảnh dưới SE tương tự như với các phép tính tương quan và tích chập. Cả phản xạ và tịnh tiến đều được định nghĩa theo gốc của B.

Để giới thiệu cách thực hiện các phép toán hình thái giữa ảnh và phần tử SE, xem Hình 4.3, mô tả một ảnh nhị phân đơn giản I, bao gồm một đối tượng (tập hợp) A được đánh dấu, và một phần tử SE với tất cả các phần tử là 1 (pixel tiền cảnh – foreground). Các pixel nền (0) được hiển thị màu trắng. Chúng ta quan tâm đến việc thực hiện các phép toán hình thái sau đây: (1) tạo ra một hình ảnh mới, có kích thước giống như I, chỉ chứa giá trị nền (0) ban đầu, (2) tịnh tiến (trượt) B qua hình ảnh I, và (3) ở mỗi bước tịnh tiến, nếu B hoàn toàn chứa trong A, đánh dấu vị trí gốc của B như một pixel 1 (tiền cảnh – foreground) trong hình ảnh mới; nếu không, để nó là một điểm nền (0). Hình 4.3(c) là kết quả cuối cùng sau khi gốc của B đã thăm từng phần tử - pixel của I. Chúng ta thấy rằng, khi gốc của B đang ở một phần tử biên của A, một phần của B không còn được chứa trong A nữa, do đó đơn giản là loại bỏ vị trí đó của gốc của B không còn là pixel tiền cảnh (1) trong hình ảnh mới mà sẽ đổi thành nền (0). Kết quả cuối cùng là ranh giới của tập hợp A bị làm mòn, như Hình 4.3(e). Do cách chúng ta định nghĩa phép toán, hành trình tối đa cần thiết để B nằm trong I là khi gốc của B (nằm ở tâm của B) được chứa trong A. Với B có kích thước 3×3 , phần chèn thêm nên hẹp nhất mà chúng ta cần là một pixel, như được hiển thị trong Hình 4.3(a). Bằng cách sử dụng biên nhỏ nhất cần thiết cho một phép toán, chúng ta giữ ảnh nhỏ hơn. Trong thực tế, chúng ta xác định chiều rộng của đệm dựa trên kích thước tối đa của các phần tử SE được sử dụng, bất kể các phép toán được thực hiện là gì.



Hình 4.3 (a) Một ảnh nhị phân chứa một đối tượng (tập hợp), A. (b) Một phần tử SE 3×3 , B. (c) Hình ảnh kết quả từ một phép toán hình thái ở trên.

Khi sử dụng thuật ngữ như "phần tử SE B được chứa trong tập A," chúng ta chỉ cụ thể rằng các phần tử tiền cảnh (pixel 1) của B trùng với các phần tử (pixel 1) của A. Điều này là quan trọng khi B cũng chứa các phần tử nền (0) và, có thể, các phần tử $\times$, nghĩa là khi đó chúng ta chỉ quan tâm đến các phần tử vật cảnh hay các pixel 1. Ngoài ra, chúng ta sử dụng tập A để chỉ tất cả các pixel vật cảnh của I. Những pixel này có thể là một đối tượng duy nhất, như trong Hình 4.3, hoặc chúng có thể biểu diễn các tập con không giao nhau của các phần tử vật cảnh, như trong dòng đầu tiên của Hình 4.1. Chúng ta sẽ thảo luận về hình ảnh nhị phân và phần tử SE trong các phần sau. Chúng ta cũng sẽ xem xét mở rộng các lý thuyết xử lý hình thái ảnh nhị phân sang ảnh xám và các phần tử SE xám.

4.2. Phép co và phép dẫn

Chúng ta bắt đầu thảo luận về xử lý hình thái ảnh bằng cách nghiên cứu hai phép toán: co và dẫn. Những phép toán này là cơ bản trong xử lý hình thái ảnh. Trên thực tế, nhiều thuật toán hình thái học được trình bày trong chương này dựa trên hai phép toán cơ bản này.

4.2.1. Phép co

Các biểu thức hình thái được viết dưới dạng các phần tử SE và một tập hợp, A, của các pixel vật cảnh, hoặc dưới dạng các phần tử kết cấu và một hình ảnh, I, chứa A. Chúng ta xem xét cách tiếp cận thứ nhất trước. Với A và B là các tập hợp trong Z^2 , quá trình co A bởi B, ký hiệu là $A \ominus B$, được định nghĩa là:

$$A \ominus B = \{z | (B)_z \subseteq A\} \quad (4-3)$$

trong đó A là một tập hợp của các pixel vật cảnh, B là một phần tử SE, và các giá trị z (các giá trị 1) là giá trị của các pixel vật cảnh. Nói bằng lời, phương trình này chỉ ra rằng quá trình co của A bởi B là tập hợp tất cả các điểm z sao cho B, dịch chuyển bởi z, nằm trong A. (Lưu ý việc di chuyển hay chuyển vị được định nghĩa theo gốc của B.) Phương trình (4-3) chính là công thức tạo ra các pixel vật cảnh giá trị 1 của ảnh trong Hình 4.3(c). Đồng thời lưu ý, tập A có thể đại diện (hoặc là hợp) của nhiều tập hợp phân biệt của các pixel vật cảnh 1 (tức là các đối tượng).

Như đã ghi chú, chúng ta làm việc với các tập hợp của các pixel 1 được nhúng vào một tập hợp của các pixel nền để tạo thành một hình ảnh hoàn chỉnh, I. Do đó, đầu vào và đầu ra của các phép toán hình thái cũng chính là các ảnh chứa đối tượng, không phải là các tập hợp riêng rẽ. Chúng ta có thể viết lại phương trình (4-3) dưới dạng

$$I \ominus B = \{z | (B)_z \subseteq A \text{ and } A \subseteq I\} \cup \{A^c | A^c \subseteq I\} \quad (4-4)$$

trong đó I là một mảng hình chữ nhật của các pixel vật cảnh 1 và pixel nền 0. Ý nghĩa của cặp ngoặc đầu tiên giống với phương trình (4-3), với giải thích thêm A là một tập hợp con của (tức là, được chứa trong) I. Phép hợp với phép toán bên trong cặp ngoặc thứ hai bổ sung thêm các pixel không thuộc tập hợp con A (tức là, chúng là tập hợp các pixel nền) vào kết quả từ cặp ngoặc đầu tiên, yêu cầu rằng các pixel nền cũng phải là một phần của hình chữ nhật được định nghĩa bởi I. Nói chung, phương trình này chỉ nói rằng co của I bởi B là tập hợp tất cả các điểm, z, sao cho B, dịch chuyển theo z, nằm trong A. Phương trình cũng làm rõ rằng A được chứa trong I, kết quả được nhúng vào một tập hợp của các pixel nền, và toàn bộ quá trình có cùng kích thước với I.


Ở đây, chúng ta không sử dụng ký hiệu công kênh của phương trình (4-4), chỉ để làm nổi bật một điểm quan trọng. Thay vào đó, chúng ta sử dụng ký hiệu $A \ominus B$ khi một phép toán hình thái chỉ sử dụng các phần tử vật cảnh và $I \ominus B$ khi phép toán sử dụng cả các phần tử vật cảnh và phần tử không quan tâm $\times$. Sự phân biệt này có vẻ hiển nhiên, nhưng giả sử chúng ta muốn thực hiện quá trình co với phương trình (4-3), sử dụng các phần tử vật cảnh 1 của phần tử SE ở cột cuối cùng trong Hình 4.2. Phần tử SE này cũng chứa các pixel nền, nhưng phương trình (4-3) giả sử rằng B chỉ chứa các pixel vật cảnh 1. Trên thực tế, quá trình co chỉ được định nghĩa cho các phép toán giữa các phần tử 1 – vật cảnh, vì vậy việc viết $I \ominus B$ sẽ trở nên không ý nghĩa mà không có giải thích được nhúng trong phương trình (4-4). Để tránh nhầm lẫn, chúng ta sử dụng A trong các biểu thức hình thái khi phép toán chỉ liên quan đến các phần tử 1, và I khi phép toán cũng liên quan đến phần tử 0 và/hoặc không quan tâm. Chúng ta cũng tránh sử dụng các ký hiệu hình thái tiêu chuẩn $\ominus$ khi làm việc với các phần tử SE hỗn hợp.

Một cách khác, trong phép co, vì ta yêu cầu tịnh tiến B phải được chứa trong A, điều này tương đương với việc B không chia sẻ bất kỳ phần tử nào chung với phần tử nền (tức là, phần bù của A), chúng ta có thể biểu diễn quá trình co một cách tương đương như sau:

$$A \ominus B = \{z | (B)_z \cap A^c = \emptyset\} \quad (4-5)$$

trong đó, $\emptyset$ là tập rỗng.

Hình 4.4 trình bày một số ví dụ về quá trình co. Các phần tử của tập A (được tô đậm) là các pixel 1 của ảnh I, và, phần nền 0 được hiển thị trong màu trắng. Biên liên bên trong biên nét đứt trong Hình 4.4(c) là giới hạn mà vượt qua giới hạn này, nếu có dịch chuyển của gốc của B sẽ làm cho một số pixel của phần tử SE không còn hoàn toàn nằm trong A nữa.



Hình 4.4 (a) Ảnh I, bao gồm một tập hợp 1 (đối tượng) A và nền 0. (b) Hình vuông SE, B (điểm chấm là gốc). (c) Phép co của A bởi B (được hiển thị làm đậm trong hình ảnh kết quả). (d) Hình dáng kéo dài của SE. (e) Erosion của A bởi B. (Erosion là một đường.) Viên chấm chấm trong (c) và (e) là ranh giới của A, được hiển thị để tham khảo.

Các phương trình (4-3) và (4-5) không phải là định nghĩa duy nhất của erosion. Tuy nhiên, các phương trình này có ưu điểm là dễ hiểu hơn khi phần tử cấu trúc B là một kernel riêng trượt qua một tập hợp, như trong phép tích chập.

4.2.2. Phép dẫn


Với A và B là các tập trong Z^2 , phép dẫn A bởi phần tử SE B, được ký hiệu là:

$$A \oplus B = \{z \mid (\hat{B})_z \cap A \neq \emptyset\} \quad (4-6)$$

Phương trình này dựa trên việc phản xạ B quanh gốc của nó, tiếp theo là tịnh tiến phản xạ đó bởi z (bước này giống như trong quá trình co). Quá trình mở rộng của A bởi B sau đó là tập hợp tất cả các chuyển vị z sao cho các phần tử 1 của B có ít nhất một phần tử chồng lên A. Chú ý rằng, z là chuyển vị của gốc của $\hat{B}$. Theo nguyên lý này, phương trình (5-6) có thể được viết tương đương như sau:

$$A \oplus B = \{z \mid [(\hat{B})_z \cap A] \subseteq A\} \quad (4-7)$$

Phương trình (5-6) và (5-7) không phải là định nghĩa duy nhất của phép dẫn. Như với quá trình co lại, các định nghĩa này có ưu điểm là dễ hiểu hơn khi phần tử cấu trúc B được xem xét như một nhân – kernel tích chập. Như đã lưu ý trước đây, quá trình cơ bản của việc lật (xoay) B quanh gốc của nó và sau đó liên tục di chuyển nó để nó trượt qua tập A tương tự như tích chập không gian. Tuy nhiên, lưu ý rằng quá trình mở rộng dựa trên các phép toán tập hợp và do đó là một phép toán phi tuyến tính, trong khi tích chập là tổng của các tích, là một phép toán tuyến tính. Khác với quá trình co, là một phép toán co hoặc làm mảnh, quá trình dẫn "phát triển" hoặc "làm dày" các đối tượng trong một ảnh nhị phân. Cách thức và mức độ của sự làm dày này được kiểm soát bởi hình dạng và kích thước của phần tử cấu trúc được sử dụng. Hình 4.5(a) cho thấy cùng một đối tượng được sử dụng trong Hình 4.4 (khu vực nền lớn hơn để chứa quá trình mở rộng), và Hình 4.5(b) cho thấy một phần tử cấu trúc (trong trường hợp này $\hat{B}=B$ là vì SE đối xứng qua gốc của nó). Đường kẻ đứt trong Hình 4.5(c) chỉ ra giới hạn của đối tượng ban đầu để tham khảo, và đường kẻ liền chỉ ra giới hạn vượt quá giới hạn mà bất kỳ di chuyển nào của gốc của B bởi z cũng sẽ khiến cho phần giao của $\hat{B}$ và A trở thành rỗng. Do đó, tất cả các điểm trên và bên trong giới hạn này đều tạo thành quá trình mở rộng của A bởi B. Hình 4.5(d) cho thấy một phần tử cấu trúc được thiết kế để đạt được thêm dẫn nhiều theo chiều dọc hơn là theo chiều ngang, và Hình 4.5(e) cho thấy quá trình dẫn được đạt được với phần tử này.



Hình 4.5 (a) Hình ảnh I, bao gồm tập hợp 1 (đối tượng) A và nền 0. (b) Hình vuông SE (chấm là góc SE). (c) Dẫn của A bởi B (được hiển thị bằng cách làm đậm). (d) SE được kéo dài. (e) Dẫn của A bởi phần tử này. Đường nét đứt trong (c) và (e) là biên của A, được hiển thị để tham khảo.

4.3. Phép mở và phép đóng ảnh

Như chúng ta đã thấy trong phần trước, quá trình dẫn mở rộng các thành phần của một tập hợp và quá trình co thu nhỏ tập hợp. Trong phần này, chúng ta tìm hiểu hai phép toán hình thái quan trọng khác: mở và đóng. Mở thường làm mịn đường biên của một đối tượng, phá vỡ những đường hẹp, và loại bỏ những đoạn đứt mảnh. Ngược lại, đóng cũng có xu hướng làm mịn các phần của đường biên, nhưng, so với mở, nó thường gộp các đoạn đứt hẹp và khe nứt dài, loại bỏ những lỗ nhỏ và lấp đầy khoảng trống trong đường viền.

Quá trình mở của tập A bởi phần tử cấu trúc B, được ký hiệu là $A \circ B$ và được định nghĩa như sau:

$$A \circ B = (A \ominus B) \oplus B \quad (4-8)$$

Như vậy phép mở A với phần tử cấu trúc B là co A bởi B tiếp theo là dẫn kết quả cũng chính với B.


Tương tự như vậy, phép đóng A bởi phần tử SE B ký hiệu là $A \bullet B$ và được định nghĩa như sau:

$$A \bullet B = (A \oplus B) \ominus B \quad (4-9)$$

Phương trình này có nghĩa là phép đóng của A bởi B đơn giản là phép dẫn A bởi B và tiếp theo đó là phép co kết quả cũng chính với phần tử B.


Phương trình (4-8) có ý nghĩa hình học đơn giản: Quá trình mở A bởi B là hợp của tất cả các tịnh tiến của B sao cho B vừa vặn hoàn toàn trong A. Hình 4.6(a) cho thấy một hình ảnh

chứa một tập hợp (đối tượng) A và Hình 4.6(b) là một phần tử cấu trúc tròn, B. Hình 4.6(c) cho thấy một số tịnh tiến của B sao cho nó được chứa trong A, và tập hợp được làm đậm trong Hình 4.6(d) là hợp của tất cả các dịch chuyển có thể như vậy. Có thể thấy rằng, trong trường hợp này, kết quả mở ảnh là một tập hợp bao gồm hai tập con không giao nhau, kết quả từ việc B không thể vừa vặn vào đoạn hẹp ở giữa của A. Như vậy, khả năng loại bỏ các khu vực hẹp hơn phần tử cấu trúc là một trong những đặc điểm quan trọng của quá trình mở ảnh hình thái.



Hình 4.6 (a) Ảnh I, được tạo thành từ tập hợp (đối tượng) A với các pixel 1 và nền (pixel 0). (b) Phần tử cấu trúc, B. (c) Các tịnh tiến của B trong A. (A được hiển thị tối màu để dễ nhận biết.) (d) Kết quả phép mở A bằng B.

Khi một phần tử cấu trúc tròn được sử dụng cho quá trình mở ảnh, người ta thường liên hệ sự tương đồng của kết quả mở ảnh như là được xác định khi cho một quả bóng – phần tử SE lăn mà có thể đạt được nhiều nhất trên biên nội của tập hợp (Hình 4.6(c) và (d)). Đối với phép toán hình thái đóng ảnh, thì kết quả sẽ tương tự như quả bóng lăn trên biên ngoài và hình dạng của ảnh được xác định bởi khoảng cách mà theo đó quả bóng vẫn có thể chạm được vào biên (Xem Hình 4.7).



Hình 4.7 (a) Ảnh I tạo nên từ tập (đối tượng) A và nền. (b) Phần tử cấu trúc SE. (c) Các tịnh tiến của B mà không giao với bất kỳ phần nào của A. (A được vẽ màu tối để dễ hình dung). (d) Kết quả phép đóng A bởi B.

Phép mở ảnh A với phần tử cấu trúc B cũng có thể được viết như sau:


$$A \circ B = \cup \{ (B)_x \mid (B)_x \subseteq A \} \quad (4-10)$$

Với $\cup$ ký hiệu phép hợp của các tập trong dấu ngoặc nhọn.


Phép đóng hình thái ảnh cũng tương tự, ngoại trừ việc trong phép đóng chúng ta dịch chuyển B bên ngoài A. Kết quả của phép đóng sau đó là phần bù của hợp tất cả các chuyển vị của B mà không giao với với A. Hình 4.7 minh họa khái niệm này. Lưu ý rằng biên của phép đóng ảnh được xác định bởi những điểm xa nhất mà B có thể đạt được mà không đi vào bất kỳ phần nào của A. Dựa vào ý nghĩa này, chúng ta có thể viết phép đóng của A với phần tử cấu trúc B như sau:

$$A \bullet B = [\cup \{(B)_z | (B)_z \cap A = \emptyset\}]^c \quad (4-11)$$

a
b c
d e
f g
h i



Hình 4.8 Mở và đóng hình thái. (a) Ảnh I , được tạo thành từ một tập hợp (đối tượng, pixel) 1) A và nền; phần tử cấu trúc SE tròn và đặc. (Chấm là gốc của SE.) (b) Phần tử SE ở các vị trí khác nhau. (c)-(i) Các phép toán hình thái để mở và đóng A .



Hình 4.9 (a) Ảnh nhiễu. (b) Phần tử cấu trúc SE. (c) Ảnh đã co. (d) Dẫn của ảnh đã co (phép mở ảnh A). (e) Dẫn của ảnh mở. (f) đóng của ảnh mở (= co của kết quả của (e)).

4.4. Phép biến đổi Hit-or-Miss

Biến đổi hit-or-miss hình thái (HMT) là một công cụ cơ bản để phát hiện hình dạng. Giả sử I là một ảnh nhị phân được tạo thành từ các điểm ảnh 1 (A) và phần nền 0, tương ứng. Khác với các phép hình thái đã trình bày cho đến nay, HMT sử dụng hai phần tử cấu trúc: B₁ để phát hiện hình dạng trong phần A và B₂ để phát hiện hình dạng trong phần nền. HMT của ảnh I được định nghĩa như sau:


Như đã nói ở phương trình (4-4), chúng ta mô tả phép biến đổi hình thái HMT hoạt động trực tiếp trên ảnh I, để chỉ rõ rằng các phần tử cấu trúc hoạt động trên các tập điểm ảnh 1 và 0 đồng thời.

$$I \odot B_{1,2} = \{z | (B_1)_z \subseteq A \text{ and } (B_2)_z \subseteq A^c\} \\ = (A \ominus B_1) \cap (A^c \ominus B_2) \quad (4-12)$$

Trong đó dòng thứ hai xuất phát từ định nghĩa của quá trình co trong công thức (4-3). Nói bằng lời thì phương trình này nói rằng HMT là tập hợp các tịnh tiến z của các phần tử cấu trúc B₁ và B₂ sao cho, một cách đồng thời, B₁ khớp trong đối tượng (tức là B₁ nằm trong A) và B₂ khớp trong nền (tức là B₂ nằm trong A^c). Đồng thời ở đây ý rằng z là cùng một phép tịnh tiến của cả hai phần tử cấu trúc. Từ "miss" trong HMT xuất phát từ việc B₂ khớp trong A^c là giống như B² không khớp trong A.

Hình 4.10 minh họa phép biến đổi Hit-or-Miss. Giả sử chúng ta muốn tìm vị trí của gốc của đối tượng (hay tập) D trong ảnh I. Ở đây, A là hợp của tất cả các tập đối tượng, vì vậy D là một tập con của A. Cách làm tiếp theo sẽ cho thấy việc yêu cầu cả hai phần tử cấu trúc có khả năng phát hiện các đặc tính của cả ảnh và nền trở nên rõ ràng. Cả ba đối tượng đều được tạo thành từ điểm ảnh 1 và một cách để giải thích tại sao chúng xuất hiện dưới dạng các hình dạng khác nhau là vì mỗi đối tượng chiếm một diện tích khác nhau của phần nền. Nói cách khác, bản chất của một hình dạng được xác định bởi sự sắp xếp hình học của cả điểm ảnh phần trước và phần nền.

a	b
c	d
e	f



Hình 4.10 (a) Ảnh bao gồm một đối tượng A (các pixel 1), là hợp của các đối tượng, và nền 0. (b) Ảnh với đối tượng được định nghĩa là A^c . (c) Các phần tử cấu trúc được thiết kế để phát hiện đối tượng D . (d) Co của A bởi B_1 . (e) Co của A^c bởi B_2 . (f) Giao của (d) và (e), hiển thị vị trí gốc của D như yêu cầu đặt ra. Nét đứt chỉ các thành phần tương ứng ban đầu. Mỗi dấu chấm là một pixel duy nhất.

Hình 4.10(a) cho thấy I được tạo thành từ phần đối tượng (A) và các pixel nền. Hình 4.10(b) là I^c , phần bù của I . Phần của I^c được định nghĩa là tập các pixel trong A^c và phần nền là hợp của ba đối tượng. Hình 4.10(c) hiển thị hai phần tử cấu trúc SE để phát hiện D . Phần tử B_1 bằng chính D . Như Hình 4.10(d) cho thấy, kết quả phép co của A bởi B_1 chứa một điểm duy nhất: gốc của D yêu cầu, nhưng nó cũng chứa các phần của đối tượng C .


Phần tử cấu trúc B_2 được thiết kế để phát hiện D trong I^c . Bởi vì D được tạo nên từ các phần tử nền (pixel 0) trong I^c và phép co làm việc với các phần tử 1, B_2 cần phải được thiết kế để phát hiện biên của D mà được tạo thành từ các pixel 1 trong I^c . Phần tử cấu trúc trong Hình 4.10(c) chính xác thực hiện điều này. Nó bao gồm một hình chữ nhật các phần tử 1 với độ dày một pixel. Kích thước của hình chữ nhật là sao cho nó chứa kích thước của D . Hình 4.10(e) hiển thị (được tô màu) kết quả co phần đối tượng của ảnh I^c bởi B_2 . Nó chứa gốc của D , nhưng cũng chứa các phần của các tập A^c và C . Vùng ngoài được tô màu ở Hình 4.10(e) lớn hơn so với được hiển thị; hình ảnh ở đây đã được cắt gọt để có cùng kích thước với ảnh I để cho thống nhất. Các phần tử chung duy nhất trong Hình 4.10(d) và (e) là gốc của D , do đó giao của hai tập hợp phần tử này cho ta vị trí của điểm đó như trong Hình 4.10(f).

Giải thích ở trên là cách truyền thống để trình bày phép biến đổi HMT bằng cách sử dụng phép co, phép toán hình thái này được định nghĩa cho các pixel 1. Một câu hỏi tốt nên đặt ra ở đây là: Tại sao không thử phát hiện D trực tiếp trong ảnh I bằng một phần tử cấu trúc duy nhất, thay vì phải thực hiện một quá trình phức tạp như vậy? Câu trả lời là có thể làm như vậy, nhưng không trong ngữ cảnh "truyền thống" của phép co như chúng ta đã định nghĩa


trong các công thức (4-3) và (4-5). Để thấy cách điều này có thể được thực hiện với ví dụ trong Hình 4.10, chúng ta định nghĩa một phần tử cấu trúc, B , giống như D , nhưng có bổ sung thêm một biên các phần tử 0 với độ rộng một pixel. Chúng ta có thể sử dụng một phần tử cấu trúc như vậy để mô tả lại phép biến đổi HMT như sau:

$$I \odot B = \{z | (B)_z \subseteq I\} \quad (4-13)$$

Dạng công thức này giống như công thức (4-3), nhưng bây giờ chúng ta kiểm tra xem B có phải là một tập con của ảnh I không, gồm cả các pixel 1 và 0. Định nghĩa này là chung theo nghĩa là B có thể được thiết lập để phát hiện bất kỳ dạng bố trí (hình dạng) nào của các pixel trong ảnh I , như các hình Hình 4.11 và 4.12 sẽ minh họa.



Hình 4.11 Cùng lời giải như trong Hình 4.10 nhưng ở đây chỉ sử dụng 1 phần tử cấu trúc theo phương trình (4-13).



Hình 4.12 Ba ví dụ sử dụng phần tử cấu trúc đơn và phương trình (4-13) để phát hiện các đặc trưng nhất định. Hàng đầu: phát hiện lỗ rỗng 1 pixel. Hàng 2: phát hiện góc trên bên phải. Hàng 3: phát hiện nhiều đặc trưng.

Hình 4.11 minh họa cùng một giải pháp như Hình 4.10(f), nhưng sử dụng 1 phần tử cấu trúc duy nhất đã trình bày ở trên. Hình 4.12 cho thấy một số ví dụ dựa trên việc sử dụng phương trình (4-13). Dòng đầu tiên hiển thị kết quả của việc sử dụng một SE nhỏ được tạo thành từ cả các phần tử 1 (được tô màu) và nền 0. SE này được thiết kế để phát hiện lỗ một pixel (tức là một pixel nền được bao quanh bởi một biên kết nối của các pixel 1) có trong ảnh I .

SE ở dòng thứ hai có khả năng phát hiện pixel góc trên bên phải của đối tượng trong I . Việc sử dụng SE này trong công thức (4-13) tạo ra ảnh bên phải. Như ta có thể thấy, pixel đúng đã được xác định.

Dòng cuối cùng của Hình 4.12 cho thấy một phần tử cấu trúc được tạo thành từ các pixel đối tượng 1, nền 0 và phần tử không quan tâm mà như đã được trình bày ở trước, chúng ta ký hiệu bằng $\times$. Chúng ta có thể xem như là, về mặt giá trị, một phần tử không quan tâm luôn khớp với pixel tương ứng của nó trong một hình ảnh. Trong ví dụ này, khi SE được tập trung vào pixel góc trên, bên phải, các phần tử không quan tâm nằm ở phía trên của SE có thể được coi là nền, và các phần tử không quan tâm ở hàng dưới như các pixel 1, cũng cho ta sự trùng khớp. Khi SE tập trung vào pixel góc dưới, bên phải, vai trò của các phần tử không quan tâm đảo ngược lại, và cũng tạo ra sự trùng khớp. Các pixel biên khác giữa hai góc phải trên và dưới cũng được phát hiện tương tự bằng cách xem xét tất cả các phần tử không quan tâm có thể là các pixel 1. Do đó, việc sử dụng các phần tử không quan tâm tăng cường tính linh hoạt của phần tử cấu trúc để thực hiện nhiều khả năng khác nhau.


4.5 Một số thuật toán hình thái cơ bản

4.5.1. Trích xuất biên

Biên của một tập hợp A các pixel đối tượng 1, được ký hiệu bằng $\beta(A)$, có thể được thu được bằng cách trước tiên co A bằng một phần tử cấu trúc B thích hợp, và sau đó lấy hiệu giữa tập A và co của nó. Đó là:

$$\beta(A) = A - (A \ominus B) \quad (4-14)$$

Hình 4.13 minh họa cơ chế của việc trích xuất biên. A là ảnh nhị phân một đối tượng đơn giản, một phần tử cấu trúc B và kết quả của việc sử dụng công thức (4-14). Phần tử cấu trúc trong Hình 4.13(b) là một trong những phần tử cấu trúc được sử dụng thường xuyên nhất trong các phép toán hình thái, nhưng nó không phải là duy nhất. Ví dụ, việc sử dụng một phần tử cấu trúc 5 x 5 của các pixel 1 sẽ tạo ra một biên dày 2 - 3 pixel. Ảnh trong Hình 5.13(a) đã được thêm biên đậm bằng một lớp các phần tử nền 0, và lớp đậm cũng được loại bỏ trong kết quả để hình trở lại kích thước ban đầu sau khi các thao tác hình thái học hoàn thành.



Hình 4.13 (a) Tập A, các pixel 1. (b) Phần tử cấu trúc. (c) A co bởi B. (d) Biên của A.



Hình 4.14 (a) Ảnh nhị phân. (b) Kết quả áp dụng phương trình (4-14) với phần tử cấu trúc

trong Hình 4.13(b).

4.5.2. Điền đầy vùng trống


Vùng trống có thể được định nghĩa là một khu vực nền được bao quanh bởi một biên kết nối của các pixel 1. Trong phần này, chúng ta phát triển một thuật toán dựa trên phép dẫn, lấy phần bù và giao của tập hợp để điền các vùng trống trong một ảnh. Ký hiệu A là một tập hợp mà các phần tử của nó là biên liên kết kiểu liên kết 8 (8-connected) bao quanh vùng rỗng, với mỗi biên bao quanh một vùng rỗng (gọi là 1 một lỗ rỗng - hole). Cho trước một điểm trong mỗi lỗ, mục tiêu là điền đầy tất cả các lỗ với các phần tử 1.

Chúng ta bắt đầu bằng cách tạo một mảng X_0 , gồm các phần tử 0, cùng kích thước với ảnh I chứa ảnh A , ngoại trừ ở các vị trí trong X_0 mà tương ứng với các pixel được biết là các lỗ rỗng, mà chúng sẽ được gán thành 1. Sau đó, thuật toán sau điền tất cả các lỗ bằng 1:

Lưu ý rằng, phép dẫn ảnh X bởi phần tử cấu trúc B là dẫn các phần tử 1 của X bởi B .

$$X_k = (X_{k-1} \oplus B) \cap I^c \quad k = 1, 2, 3, \dots \quad (4-15)$$

Trong đó B là phần tử cấu trúc đối xứng như trong Hình 4.15(c). Thuật toán kết thúc tại bước lặp k nếu $X_k = X_{k-1}$. Khi đó X_k chứa tất cả các lỗ đã được điền đầy. Khi đó hợp của X_k và I chứa tất cả các lỗ đã được điền đầy và biên của các lỗ (hay vùng rỗng).



Hình 4.15 Điền đầy vùng rỗng. (a) Tập A (vùng được tô màu) trong ảnh I . (b) Phần bù của I . (c) Phần tử cấu trúc B . Chỉ các phần tử 1 được sử dụng trong các phép toán hình thái. (d) Điểm khởi đầu bên trong lỗ, được đặt thành 1. (e)–(h) Các bước khác nhau khi thực hiện công thức (4-15). (i) Kết quả cuối cùng hợp của (a) và (h).


Phép dẫn trong công thức (4-15) sẽ điền toàn bộ ảnh nếu không kiểm soát, nhưng phép giao tại mỗi bước với I^c giới hạn kết quả chỉ bên trong vùng quan tâm cần điền đầy. Đây là ví dụ đầu tiên cho thấy cách một quá trình với các phép toán hình thái có thể được điều khiển để đáp ứng một thuộc tính yêu cầu. Trong ứng dụng hiện tại làm đầy vùng, quá trình được gọi là dẫn có điều kiện. Phần còn lại của Hình 4.15 minh họa thêm cơ chế của công thức (4-15). Ví dụ này chỉ có một lỗ, nhưng thuật toán áp dụng cho bất kỳ số lỗ hữu hạn nào, giả sử rằng có một điểm cho trước trong mỗi lỗ.

4.5.3. Trích xuất các thành phần liên thông

Khả năng trích xuất các thành phần liên thông từ một ảnh nhị phân là trọng tâm của nhiều ứng dụng xử lý phân tích ảnh tự động. Ký hiệu A là một tập hợp các pixel đối tượng 1 bao gồm một hoặc nhiều thành phần liên thông, và thiết lập một ảnh X_0 (cùng kích thước với ảnh I chứa A) mà các phần tử của nó là 0 (giá trị nền), ngoại trừ ở mỗi vị trí được biết tương ứng với một điểm trong mỗi thành phần liên thông trong A , mà chúng ta đặt giá trị là 1 (giá trị pixel thuộc đối tượng). Mục tiêu là bắt đầu với X_0 và tìm tất cả các thành phần liên thông trong I . Thuật toán lặp sau đây thực hiện điều đó:

$$X_k = (X_{k-1} \oplus B) \cap I \quad k = 1, 2, 3, \dots \quad (4-16)$$

Trong đó B là phần tử cấu trúc trong Hình 4.16(a). Thuật toán kết thúc khi $X_k = X_{k-1}$ với X_k chứa tất cả các thành phần kết nối của các pixel 1 trong ảnh. Cả hai công thức (4-15) và (4-16) sử dụng phép dẫn có điều kiện để giới hạn sự mở rộng của phép dẫn tập hợp, nhưng công thức (4-16) sử dụng I thay vì I^c . Điều này là vì ở đây chúng ta đang tìm kiếm các điểm 1, trong khi mục tiêu của (4-15) là tìm các điểm 0. Hình 4.16 minh họa cơ chế của công thức (4-16), với sự hội tụ được đạt được khi $k = 6$. Lưu ý rằng hình dạng của phần tử cấu trúc sử dụng dựa trên kết nối 8 (8-connected) giữa các pixel. Như trong thuật toán điền lỗ rỗng, công thức (4-16) áp dụng cho bất kỳ số thành phần liên thông hữu hạn nào chứa trong I , giả sử rằng cho trước một điểm trong mỗi thành phần.



Hình 4.16 (a) Phần tử cấu trúc. (b) Ảnh chứa một tập hợp với một thành phần kết nối. (c) Mạng ban đầu chứa một phần tử 1 trong vùng của thành phần liên thông. (d)–(g) Các bước trong quá trình lặp của công thức (4-16).

a
b
c d



Connected component	No. of pixels in connected comp
01	11
02	9
03	9
04	39
05	133
06	1
07	1
08	743
09	7
10	11
11	11
12	9
13	9
14	674
15	85



Hình 4.17 (a) Ảnh X quang một khoanh thịt gà chế biến sẵn vẫn còn xương. (b) Ảnh đã phân ngưỡng (hiển thị ở chế độ âm bản để tiện theo dõi). (c) Ảnh được co sử dụng một phần tử cấu trúc 5 x 5 gồm các phần tử 1. (d) Số pixel trong mỗi thành phần liên thông của (c).

4.5.4. Bao lồi

Một tập hợp, S, các điểm trong mặt phẳng Euclid được coi là lồi nếu và chỉ nếu đoạn thẳng nối bất kỳ hai điểm nào trong S nằm hoàn toàn trong S. Bao lồi, H, của S là tập hợp lồi nhỏ nhất chứa S. Phần bù lồi (convex deficiency) của S được định nghĩa là hiệu giữa tập hợp H-S. Khác với mặt phẳng Euclid, mặt phẳng ảnh số chỉ cho phép các điểm tại các tọa độ rời rạc. Do đó, các tập hợp mà chúng ta làm việc là các tập số. Các khái niệm về tính lồi vẫn có thể được áp dụng cho các tập số, nhưng định nghĩa của tập số lồi có một chút hiệu chỉnh. Một tập số, A, được coi là lồi nếu và chỉ nếu bao lồi Euclid của nó chỉ chứa các điểm số thuộc A. Một cách đơn giản để hình dung nếu một tập số của các điểm 1 là lồi là nối các điểm biên của nó bằng các đoạn thẳng Euclid thẳng (liên tục). Nếu chỉ có các điểm 1 chứa trong tập hợp được hình thành bởi các đoạn thẳng, thì tập hợp đó là lồi; ngược lại thì tập không phải là lồi. Các định nghĩa của bao lồi và phần bù lồi đưa ra ở trên cho S, có thể được mở rộng trực tiếp áp dụng cho các tập số. Thuật toán hình thái học sau đây có thể được sử dụng để có một xấp xỉ của bao lồi của một tập A các pixel 1, nhúng trong một hình ảnh nhị phân I.

Ký hiệu B^i , $i=1, 2, 3, 4$, là 4 phần tử cấu trúc trong Hình 4.18(a). Thuật toán tìm bao lồi của một tập bao gồm việc thực hiện phép toán hình thái học:

$$X_k^i = (X_{k-1}^i \odot B^i) \cup X_{k-1}^i \quad i = 1, 2, 3, 4 \text{ and } k = 1, 2, 3, \dots \quad (4-17)$$



Hình 4.18 (a) Các phân tử cấu trúc. (b) Tập A. (c) – (f) Kết quả hội tụ với các phân tử cấu trúc được hiển thị trong (a). (g) Bao lồi. (h) Bao lồi với thông tin đóng góp của mỗi phân tử cấu trúc trong kết quả.

với $X_0^i = I$. Khi thuật toán hội tụ bằng cách sử dụng phân tử cấu trúc thứ i (nghĩa là khi $X_k^i = X_{k-1}^i$) chúng ta đặt $D_i = X_k^i$. Khi đó bao lồi của A là hợp của bốn kết quả:

$$C(A) = \bigcup_{i=1}^4 D_i \quad (4-18)$$

Chúng ta thấy thuật toán bao gồm việc áp dụng lặp của phép biến đổi hit-or-miss vào I sử dụng B^1 đến khi hội tụ, sau đó đặt $D^1 = X_k^1$ với k là bước đạt hội tụ. Quy trình được lặp lại với B^2 (áp dụng cho ảnh I) cho đến khi không có thay đổi nào xảy ra nữa, và cứ tiếp tục như vậy. Hợp của bốn kết quả tạo thành bao lồi của A. Thuật toán được khởi tạo với $k = 0$ và $X_0^i = I$ với $i = 1, 2, 3, 4$.

4.5.5. Làm mảnh hình

Làm mảnh một tập hợp A của các điểm ảnh của đối tượng bằng bởi một phân tử cấu trúc B, ký hiệu là $A \otimes B$, có thể được định nghĩa dưới dạng biến đổi hit-or-miss:

$$\begin{aligned} A \otimes B &= A - (A \odot B) \\ &= A \cap (A \odot B)^c \end{aligned} \quad (4-19)$$

Trong đó dòng thứ hai là kết quả từ định nghĩa hiệu tập hợp đã được trình bày. Một biểu thức hữu ích hơn để làm mảnh A một cách đối xứng là dựa trên một chuỗi các phân tử cấu trúc:


$$\{B\} = \{B^1, B^2, B^3, \dots, B^n\} \quad (4-20)$$

Sử dụng khái niệm này, chúng ta định nghĩa phép toán làm mảnh hình bằng một chuỗi các phần tử cấu trúc như sau:

$$A \otimes \{B\} = (((((A \otimes B^1) \otimes B^2) \dots) \otimes B^n) \quad (4-21)$$

Quá trình là làm mảnh A qua một lượt với B^1 , sau đó làm mảnh kết quả qua một lượt với B^2 và tiếp tục như vậy, cho đến khi A được mảnh mỏng qua một lượt với B^n . Toàn bộ quy trình được lặp lại cho đến khi không còn thay đổi nào xảy ra sau một lượt hoàn chỉnh qua tất cả các phần tử cấu trúc. Mỗi lượt làm mảnh riêng rẽ được thực hiện bằng cách sử dụng công thức (4-19).

Như trước, chúng ta giả sử rằng ảnh chứa đối tượng A đã được bổ sung vùng đệm xung quanh để chứa tất cả các di chuyển của B, và cuối cùng kết quả được cắt gọt bớt phần đệm đã bổ sung. Chúng ta chỉ trình bày A để cho đơn giản.



Hình 4.19 (a) Các phần tử cấu trúc. (b) Tập A. (c) Kết quả của việc làm mảnh A với B^1 (các pixel được tô đậm). (d) Kết quả của việc làm mảnh A_1 với B^2 . (e)–(i) Kết quả của việc làm mảnh với sáu phần tử cấu trúc tiếp theo. (Không có thay đổi giữa A_7 and A_8). (j)–(k) Kết quả của việc sử dụng lặp lại bốn phần tử đầu tiên. (l) Kết quả sau khi hội tụ. (m) Kết quả chuyển đổi thành m-kết nối.

Hình 4.19(a) hiển thị một tập hợp các phần tử cấu trúc thường được sử dụng để làm mảnh các ảnh đối tượng (lưu ý rằng B^i bằng B^{i-1} bằng cách xoay theo chiều kim đồng hồ góc 45°), và Hình 4.19(b) hiển thị tập hợp A cần được làm mảnh, sử dụng thuật toán vừa trình bày. Hình 4.19(c) hiển thị kết quả của việc làm mảnh A với một lượt của B^1 để nhận được A_1 . Hình 4.19(c) là kết quả của việc làm mảnh với A_1 với B^2 , và Hình 4.19(e) đến (k) hiển thị các kết quả của các lượt làm mảnh với các phần tử cấu trúc còn lại (kết quả không có sự thay đổi từ A_7 đến A_8 hoặc từ A_9 đến A_{11}). Hội tụ được đạt sau lượt làm mảnh thứ hai của B^6 . Hình 4.19(l) hiển thị kết quả đã được làm mảnh cuối cùng. Cuối cùng, Hình 4.19(m) hiển thị tập hợp đã được làm mảnh và đã được chuyển đổi thành m-kết nối để loại bỏ các đường có đa kết nối (multiple path, ví dụ như trong l).

4.5.6. Làm dày hình


Làm dày là phép toán hình thái đối ngẫu của việc làm mảnh và được định nghĩa bởi biểu thức:

$$A \odot B = A \cup (A \odot B) \quad (4-22)$$

Ở đây, B là một phần tử cấu trúc phù hợp để làm dày. Như trong trường hợp làm mảnh, việc làm dày có thể được định nghĩa là 1 phép toán tuần tự như sau:

$$A \odot \{B\} = (((((A \odot B^1) \odot B^2) \dots) \odot B^n) \quad (4-23)$$

Các phần tử cấu trúc được sử dụng cho việc làm dày có cùng hình dạng như những phần tử được hiển thị trong Hình 4.19(a), nhưng tất cả 1 và 0 được hoán đổi vị trí cho nhau. Tuy nhiên, một thuật toán riêng biệt cho việc làm dày hiếm khi được sử dụng trong thực tế. Thay vào đó, quy trình thông thường làm mảnh nền của tập hợp - ảnh đối tượng đang nghiên cứu, sau đó lấy phần bù của kết quả. Nói cách khác, để làm dày một tập A, chúng ta tạo ra A^c , làm mảnh A^c , và sau đó lấy phần bù của tập đã làm mảnh để có được kết quả làm dày của A. Hình 4.20 minh họa quy trình này. Như trước, chúng ta chỉ hiển thị tập A và ảnh I, không hiển thị hình chèn thêm viền của I.




Hình 4.20 (a) Tập hợp A. (b) Phần bù của A. (c) Kết quả của việc làm mảnh của phần bù đó. (d) Tập làm dày đạt được bằng cách lấy phần bù của (c). (e) Kết quả cuối cùng, không có điểm không liên thông.

Tùy thuộc vào cấu trúc của A, thuật toán này có thể dẫn đến các điểm không liên thông như trong Hình 4.20(d). Do đó, thường thì việc làm dày bằng cách này thường được tiếp ngay theo sau bởi một quá trình xử lý để loại bỏ các điểm không liên thông. Chú ý từ Hình 4.20(c) rằng nền đã làm mảnh tạo ra một biên cho quá trình làm dày. Đây là một đặc trưng hữu ích mà nó không có trong việc triển khai trực tiếp của thuật toán làm dày bằng cách sử dụng phương trình (4-23), và đây là một trong những lý do chính để sử dụng việc làm mảnh nền để thực hiện phép làm dày.

4.5.7. Tìm xương

Hình 4.21 trình bày ký hiệu một xương S(A) của tập A. Chúng ta suy luận từ hình như sau:

a	b
c	d



Hình 4.21 (a) Tập A. (b) Các vị trí khác nhau của các đĩa lớn nhất mà tâm của chúng một phần định nghĩa xương của A. (c) Một đĩa lớn nhất khác, mà tâm của nó định nghĩa một đoạn khác của xương của A. (d) Xương đầy đủ (đường nét đứt).

- Nếu z là một điểm thuộc $S(A)$ và $(D)_z$ là đĩa lớn nhất có tâm tại z và chứa trong A, ta không thể tìm thấy một đĩa lớn hơn (không nhất thiết tâm tại z) chứa $(D)_z$ và đồng thời nằm trong A. Một đĩa $(D)_z$ thỏa mãn những điều kiện đó được gọi là đĩa lớn nhất.
- Nếu $(D)_z$ là một đĩa lớn nhất, nó chạm vào biên của A ở hai hoặc nhiều vị trí khác nhau.

Xương của A có thể được biểu diễn dưới dạng các phép co và phép mở. Đó là, người ta có thể chứng minh được rằng:

$$S(A) = \bigcup_{k=0}^K S_k(A) \quad (4-24)$$

Với

$$S_k(A) = (A \ominus kB) \circ B \quad (4-25)$$

Trong đó B là một phần tử cấu trúc, và $A \ominus kB$ chỉ ra k phép co liên tiếp bắt đầu với ảnh A; đó là A đầu tiên được co với B, kết quả sau đó lại được co bởi B và cứ thế k lần.

$$(A \ominus kB) = (((A \ominus B) \ominus B) \ominus \dots) \ominus B \quad (4-26)$$

K trong phương trình (4-24) là bước lặp cuối cùng trước khi co a đến tập rỗng. Nói cách khác:

$$K = \max\{k | (A \ominus kB) \neq \emptyset\} \quad (4-27)$$

Công thức trong các phương trình (4-24) và (4-25) chỉ ra rằng $S(A)$ có thể được thu nhận như là hợp của các xương con $S_k(A)$, $k = 0, 1, 2, \dots, K$.

Người ta đã chứng minh được rằng A có thể được tái tạo từ các tập con đó:

$$A = \bigcup_{k=0}^K (S_k(A) \oplus kB) \quad (4-28)$$

Trong đó $(S_k(A) \oplus kB)$ ký hiệu k phép giãn liên tiếp, bắt đầu với $S_k(A)$; đó là:

$$(S_k(A) \oplus kB) = (((S_k(A) \oplus B) \oplus B) \oplus \dots) \oplus B) \quad (4-29)$$

4.5.8. Cắt tỉa các hình


Phương pháp tỉa cây là một bổ sung cần thiết cho các thuật toán làm mảnh và tạo xương, bởi vì các thuật toán đó thường tạo ra những gai nhiễu ở biên cần phải được làm sạch hay làm trơn thông qua một phép xử lý bổ sung sau đó. Chúng ta bắt đầu phần này với bài toán cắt tỉa cây, sau đó phát triển một giải pháp dựa trên các nội dung đã được trình bày trong các phần trước. Như vậy, nhân dịp này chúng ta minh họa cách giải quyết một vấn đề bằng cách kết hợp nhiều phép toán hình thái đã được trình bày.

Một phương pháp phổ biến trong việc nhận diện tự động các ký tự được viết tay là phân tích hình dạng của xương của một ký tự. Những xương này thường chứa các gai nhiễu phát sinh trong quá trình co ảnh do nhiễu và do tính không đồng đều trong các nét của ký tự. Trong phần này, chúng ta phát triển một kỹ thuật hình thái để xử lý vấn đề này, bắt đầu với giả định rằng chiều dài của một thành phần gai nhiễu không vượt quá một số lượng pixel đã xác định.

Hình 4.22(a) cho thấy xương của một chữ cái "a" viết tay. Gai nhiễu gần ở phần cực trái của ký tự là ví dụ cho cái chúng ta muốn làm sạch – làm trơn. Giải pháp là dựa trên việc loại dần một nhánh gai nhiễu bằng cách loại bỏ liên tục điểm cuối cùng của nó. Tất nhiên, điều này cũng làm ngắn (hoặc loại bỏ) các nhánh khác trong ký tự nhưng, trong trường hợp thiếu thông tin cấu trúc khác, giả thiết trong ví dụ này là bất kỳ nhánh nào có ba hoặc ít hơn ba pixel sẽ bị loại bỏ. Làm mảnh tập A, với một chuỗi các phần tử cấu trúc được thiết kế để chỉ phát hiện điểm cuối cùng, đạt được kết quả mong muốn. Đó là, đặt:

$$X_1 = A \otimes \{B\}$$

(4-30)



Hình 4.22 (a) Tập hợp A các pixel đối tượng ảnh – pixel 1 (tô đậm). (b) Các phần tử cấu trúc được sử dụng để xóa các điểm cuối. (c) Kết quả của ba chu kỳ làm mảnh. (d) Các điểm cuối của (c). (e) Dẫn các điểm cuối với điều kiện (a). (f) Ảnh đã cắt tỉa.

trong đó $\{B\}$ ký hiệu chuỗi phần tử cấu trúc trong Hình 4.22(b). Chuỗi phần tử cấu trúc bao gồm hai cấu trúc khác nhau, mỗi cái được xoay 90° để tạo ra tám cấu trúc. Ký hiệu "x" trong Hình 4.22(b) biểu thị phần tử không quan tâm như đã định nghĩa ở các phần trước. Chú ý

rằng mỗi phần tử cấu trúc SE là một bộ dò một điểm cuối cụ thể theo một hướng nhất định. Chúng ta có thể định nghĩa một điểm cuối là tâm của một vùng 3×3 thỏa mãn bất kỳ sắp xếp nào trong Hình 4.22(b).

Áp dụng phương trình (4-30) cho A ba lần tạo ra tập X_1 trong Hình 4.22(c). Bước tiếp theo là khôi phục ký tự về hình dạng ban đầu, nhưng với các gai nhiễu đã bị loại bỏ. Để làm được điều đó trước tiên chúng ta phải tạo ra một tập X_2 chứa tất cả các điểm cuối trong X_1 :

$$X_2 = \bigcup_{k=1}^8 (X_1 \odot B^k) \quad (4-31)$$

trong đó B^k là các bộ dò điểm cuối trong Hình 4.22(b). Bước tiếp theo là dẫn các điểm cuối. Thông thường, số lần dẫn ít hơn số lần loại bỏ điểm cuối để giảm khả năng gai nhiễu mọc trở lại. Trong trường hợp này, chúng ta biết thông qua kiểm tra rằng không có gai nhiễu mới nào được tạo ra, vì vậy chúng ta dẫn các điểm cuối ba lần bằng cách sử dụng A như một giới hạn dừng. Đó cũng chính là số lần làm mảnh:

$$X_3 = (X_2 \oplus H) \cap A \quad (4-32)$$

Trong đó H là một phần tử cấu trúc với các giá trị 1, và phép giao với A được thực hiện sau mỗi bước. Cũng giống như trường hợp của thuật toán làm đầy vùng, loại phép dẫn có điều kiện này ngăn chặn việc tạo ra các phần tử có giá trị 1 bên ngoài vùng tính toán, như minh họa trong kết quả ở Hình 4.22(e). Cuối cùng, hợp của X_1 và X_3 tạo ra kết quả mong muốn trong Hình 4.22(f).

$$X_4 = X_1 \cup X_3 \quad (4-33)$$

Trong các tình huống phức tạp hơn, việc sử dụng phương trình (4-32) đôi khi có thể bắt được điểm đầu của một số nhánh. Điều này có thể xảy ra khi các điểm cuối của những nhánh đó gần với xương. Mặc dù phương trình (4-32) có thể loại bỏ chúng, chúng có thể lại được bắt lại trong quá trình dẫn vì chúng là điểm hợp lệ trong A. Tuy nhiên, trừ khi toàn bộ các gai nhiễu lại được bắt lại (trường hợp hiếm khi những phần tử này ngắn so với các nét hợp lệ), việc phát hiện và loại bỏ các phần tử đã được xây dựng lại là dễ dàng vì chúng là các vùng không liên thông.

Câu hỏi ôn tập và bài tập

Bài tập 1

- a) Đề xuất một thuật toán hình thái để chuyển đổi biên nhị phân liên kết 8 (8-connected) thành một biên liên kết m (m -connected). Có thể giả định rằng biên là hoàn toàn liên thông và chỉ dày một pixel.
- (b) Kiểm tra xem thuật toán được đề xuất có yêu cầu nhiều hơn một lần lặp với mỗi phần tử cấu trúc không? Giải thích lập luận đưa ra.
- (c) Hiệu năng của thuật toán có phụ thuộc vào thứ tự theo đó các phần tử cấu trúc được áp dụng không? Nếu câu trả lời là có, chứng minh điều đó; nếu không, đưa ra một ví dụ minh họa sự phụ thuộc của thuật toán vào thứ tự áp dụng các phần tử cấu trúc.

Bài tập 2

Phép co một tập hợp A với phần tử cấu trúc B là một tập con của A miễn là gốc của B nằm trong B . Đưa ra một ví dụ trong đó phép co A bằng B nằm bên ngoài, hoặc nằm một phần bên ngoài A .

Bài tập 3

Bốn phát biểu sau đây là đúng. Đưa ra lập luận để chứng minh lý do cho tính đúng đắn của chúng. Phần (a) đúng nói chung. Phần (b) đến (d) đúng chỉ đối với các tập hợp số. Để chứng minh tính đúng đắn của (b) đến (d), vẽ một lưới vuông rời rạc và đưa ra một ví dụ cho mỗi trường hợp sử dụng các tập được tạo thành từ các điểm trên lưới này. Gợi ý: Giữ số điểm trong mỗi trường hợp ít nhất có thể trong khi vẫn thiết lập được tính đúng đắn của các phát biểu.

- (a) Phép co của một tập lồi bởi một phần tử cấu trúc lồi là một tập hợp lồi.
- (b) Phép dẫn của một tập hợp lồi bởi một phần tử cấu trúc lồi không nhất thiết luôn luôn là tập hợp lồi.
- (c) Các điểm trong một tập số lồi không luôn luôn liên thông.
- (d) Có thể có một tập hợp các điểm trong đó một đoạn thẳng nối mọi cặp điểm trong tập hợp nằm hoàn toàn trong tập hợp nhưng tập hợp không phải là lồi.

Chương 5

PHÂN VÙNG ẢNH

Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu rõ đặc điểm của các loại cạnh/biên khác nhau thường gặp trong thực tế xử lý ảnh.
- ✓ Hiểu cách sử dụng lọc không gian để phát hiện cạnh/biên.
- ✓ Quen thuộc với các phương pháp phát hiện cạnh/biên khác nhau mở rộng hơn so với các phép toán lọc không gian.
- ✓ Hiểu về ngưỡng cường độ sáng của ảnh bằng cách sử dụng một số phương pháp khác nhau.
- ✓ Biết cách kết hợp ngưỡng và lọc không gian để cải thiện phân đoạn ảnh.
- ✓ Quen với phân đoạn ảnh dựa trên vùng/miền, bao gồm phân cụm và siêu điểm ảnh.
- ✓ Hiểu cách sử dụng các phương pháp cắt đồ thị và các phép toán hình thái lưu vực trong quá trình phân đoạn ảnh.
- ✓ Quen thuộc với các kỹ thuật cơ bản dựa trên việc sử dụng chuyển động trong việc phân đoạn hình ảnh.

5.1. Cơ bản về phân vùng ảnh

Chúng ta có thể xem phân đoạn hình ảnh như một quá trình phân chia R thành n vùng con $R_1, R_2, \dots, R_n$, sao cho:

- a) $\bigcup_{i=1}^n R_i = R$
- b) R_i là một tập kết nối – connected set (hay tập liên thông), với $i = 0, 1, 2, \dots, n$
- c) $R_i \cap R_j = \emptyset$ với tất cả i và j , $i \neq j$
- d) $Q(R_i) = TRUE$ với $i = 0, 1, 2, \dots, n$
- e) $Q(R_i \cup R_j) = FALSE$ với bất kì vùng liền kề R_i và R_j


Trong đó: $Q(R_k)$ là một vị từ logic – logical predicate được xác định trên các điểm trong tập hợp R_k và $\emptyset$ là một tập rỗng. Hai ký hiệu $\cup$ và $\cap$ lần lượt biểu diễn phép hợp và phép giao tập hợp. Hai vùng R_i và R_j được coi là *kề nhau* (adjacent) nếu phần hợp của chúng tạo thành một tập liên kết. Nếu tập được hình thành bởi sự kết hợp hai vùng không kết nối, các vùng đó được gọi là *rời rạc* (disjoint).

Điều kiện (a) chỉ ra rằng việc phân đoạn phải hoàn chỉnh, theo nghĩa là mọi điểm ảnh phải nằm trong một vùng. Điều kiện (b) yêu cầu các điểm trong một vùng được kết nối theo một nghĩa nào đó được xác định trước (ví dụ: các điểm phải được kết nối 8 – 8 connected). Điều kiện (c) nói rằng các vùng phải rời nhau. Điều kiện (d) xử lý các thuộc tính mà các điểm ảnh trong một vùng được phân đoạn phải đáp ứng - ví dụ: $Q(R_i) = TRUE$ nếu tất cả các điểm ảnh trong đó có cùng cường độ. Cuối cùng, điều kiện (e) chỉ ra rằng hai vùng liền kề nhau R_i và R_j phải khác nhau về nghĩa của vị từ Q . Vị từ Q có thể là một biểu thức ghép chẳng hạn như $Q(R_i) = TRUE$ “nếu cường độ trung bình của các điểm ảnh trong vùng R_i nhỏ hơn m_i VÀ nếu độ lệch chuẩn của cường độ của chúng lớn hơn σ_i ” trong đó m_i và σ_i là các hằng số xác định.

Vì vậy, chúng ta thấy rằng vấn đề cơ bản trong phân đoạn là phân chia hình ảnh thành các vùng thỏa mãn các điều kiện trước đó. Các thuật toán phân đoạn cho ảnh đơn sắc thường dựa trên một trong hai loại cơ bản liên quan đến các thuộc tính của giá trị cường độ: tính gián đoạn và tính tương tự. Trong loại đầu tiên, chúng tôi giả định rằng ranh giới của các

vùng đủ khác nhau và so với nền, để cho phép phát hiện ranh giới dựa trên sự gián đoạn cục bộ về cường độ. Phân đoạn dựa trên cạnh là phương pháp chính được sử dụng trong loại này. Các phương pháp phân đoạn dựa trên vùng trong loại thứ hai dựa trên việc phân vùng hình ảnh thành các vùng tương tự nhau theo một bộ tiêu chí được xác định trước.

a b c
d e f



Hình 5.1 (a) Hình ảnh của vùng cường độ xám không đổi. (b) Ranh giới dựa trên sự không liên tục về cường độ. (c) Kết quả của phân đoạn. (d) Hình ảnh của vùng kết cấu. (e) Kết quả tính toán cường độ không liên tục (lưu ý số lượng lớn các cạnh nhỏ). (f) Kết quả phân đoạn dựa trên đặc tính vùng.

5.2. Phát hiện biên, đường, điểm trong ảnh

Trọng tâm của phần này là các phương pháp phân đoạn dựa trên việc phát hiện những thay đổi đột ngột về cường độ xám. Ba loại đặc điểm ảnh mà chúng ta quan tâm là các điểm, đường và biên. Điểm ảnh biên là các điểm ảnh tại đó cường độ của hình ảnh thay đổi đột ngột và các cạnh là tập hợp các điểm ảnh cạnh được kết.

Bộ dò cạnh là công cụ xử lý hình ảnh cục bộ được thiết kế để phát hiện các điểm ảnh cạnh. Một đường có thể được xem như một đoạn cạnh mỏng (thông thường) trong đó cường độ của nền ở hai bên của đường thẳng cao hơn hoặc thấp hơn nhiều so với cường độ của các điểm ảnh của đường. Trên thực tế, như chúng ta sẽ thảo luận sau, các đường nét tạo nên cái gọi là “roof edges”. Cuối cùng, một điểm bị cô lập có thể được xem dưới dạng điểm ảnh nền trước (hoặc nền sau) được bao quanh bởi các điểm ảnh nền sau (hoặc nền trước)

5.2.1. Cơ sở về phát hiện biên, đường, điểm

Như chúng ta đã thấy, phép trung bình địa phương làm mịn (làm mờ) hình ảnh. Biết rằng phép tính trung bình tương tự như phép tích phân, thế thì chúng ta có thể thấy một cách trực quan rằng có thể phát hiện được những thay đổi cục bộ, đột ngột về cường độ bằng cách sử dụng đạo hàm. Chúng ta có thể sớm thấy ngay rằng, đạo hàm bậc một và bậc hai đặc biệt phù hợp cho mục đích này.

Đạo hàm của hàm số được định nghĩa theo sai phân hữu hạn. Có nhiều cách khác nhau để tính toán những khác biệt này, nhưng, như đã giải thích từ trước, chúng ta yêu cầu rằng bất kỳ phép tính gần đúng nào được sử dụng cho đạo hàm bậc nhất (1) phải bằng 0 trong các vùng có cường độ không đổi; (2) phải khác 0 khi bắt đầu bước cường độ hoặc đoạn đường nối; và (3) phải khác 0 tại các điểm dọc theo đường dốc cường độ. Tương tự, chúng ta yêu cầu phép tính gần đúng được sử dụng cho đạo hàm bậc hai (1) phải bằng 0 trong vùng có

cường độ không đổi; (2) phải khác 0 khi bắt đầu và kết thúc bước cường độ hoặc đoạn đường nối; và (3) phải bằng 0 dọc theo các đường dốc cường độ. Bởi vì chúng ta đang xử lý các đại lượng rời rạc (digital) có giá trị hữu hạn, nên sự thay đổi cường độ tối đa có thể xảy ra cũng hữu hạn và khoảng cách ngắn nhất mà sự thay đổi có thể xảy ra là giữa các điểm ảnh liên kề.

Chúng ta thu được xấp xỉ với đạo hàm bậc nhất tại một điểm x tùy ý của hàm một chiều $f(x)$ bằng cách mở rộng hàm $f(x + \Delta x)$ thành chuỗi Taylor về x .

Nhớ rằng: kí hiệu $n!$ là n giai thừa: $n! = 1 \times 2 \times \dots \times n$.

$$\begin{aligned} f(x + \Delta x) &= f(x) + \Delta x \frac{\partial f(x)}{\partial x} + \frac{(\Delta x)^2}{2!} \frac{\partial^2 f(x)}{\partial x^2} + \frac{(\Delta x)^3}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{(\Delta x)^n}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned} \quad (5-1)$$

Trong đó Δx là hiệu khoảng cách giữa các mẫu của f . Vì mục đích của chúng tôi, hiệu khoảng cách này được đo bằng đơn vị điểm ảnh. Vì vậy, theo quy ước trong sách, $\Delta x = 1$ đối với mẫu trước x và $\Delta x = -1$ mẫu sau x . Khi $\Delta x = 1$ phương trình (5-1) trở thành:

$$\begin{aligned} f(x + 1) &= f(x) + \frac{\partial f(x)}{\partial x} + \frac{1}{2!} \frac{\partial^2 f(x)}{\partial x^2} + \frac{1}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{1}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned} \quad (5-2)$$

Tương tự, khi $\Delta x = -1$,

$$\begin{aligned} f(x - 1) &= f(x) - \frac{\partial f(x)}{\partial x} + \frac{1}{2!} \frac{\partial^2 f(x)}{\partial x^2} - \frac{1}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{(-1)^n}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned} \quad (5-3)$$

Trong phần tiếp theo, chúng tôi tính toán sự khác biệt về cường độ chỉ bằng cách sử dụng một số số hạng của chuỗi Taylor. Đối với đạo hàm cấp một, chúng ta chỉ sử dụng các số hạng tuyến tính và có thể tạo thành sai phân theo một trong ba cách.

Sự khác biệt phía trước được lấy từ phương trình (5-2):

$$\frac{\partial f(x)}{\partial x} = f'(x) = f(x + 1) - f(x) \quad (5-4)$$

ở đó, như bạn có thể thấy, chúng tôi chỉ giữ lại các số hạng tuyến tính. Sự khác biệt phía sau có được tương tự bằng cách chỉ giữ lại các số hạng tuyến tính trong biểu thức (5-3):

$$\frac{\partial f(x)}{\partial x} = f'(x) = f(x) - f(x - 1) \quad (5-5)$$

và sự khác biệt trung tâm có được bằng cách trừ phương trình (5-3) từ phương trình (5-2):

$$\frac{\partial f(x)}{\partial x} = f'(x) = \frac{f(x+1) - f(x-1)}{2} \quad (5-6)$$

Các số hạng cao hơn của chuỗi mà chúng tôi không sử dụng thể hiện sai số giữa khai triển đạo hàm chính xác và gần đúng. Nói chung, chúng ta càng sử dụng nhiều số hạng trong chuỗi Taylor để biểu diễn đạo hàm thì phép tính gần đúng sẽ càng chính xác. Việc bao gồm nhiều số hạng hơn có nghĩa là nhiều điểm hơn được sử dụng trong phép tính gần đúng, mang lại sai số thấp hơn. Tuy nhiên, hóa ra những khác biệt trung tâm có sai số thấp hơn đối với cùng một số điểm. Vì lý do này, đạo hàm thường được biểu diễn dưới dạng sai phân trung tâm.

Đạo hàm cấp hai dựa trên sai phân trung tâm, $\partial^2 f(x)/\partial x^2$ thu được bằng cách cộng các phương trình (5-2) và (5-3):

$$\frac{\partial^2 f(x)}{\partial x^2} = f''(x) = f(x+1) - 2f(x) + f(x-1) \quad (5-7)$$

Để đạt được bậc ba, đạo hàm trung tâm, chúng ta cần thêm một điểm ở hai bên của x . Nghĩa là, chúng ta cần khai triển Taylor cho $f(x+2)$ và $f(x-2)$ chúng ta thu được từ các phương trình (5-2) và (5-3) tương ứng với $\Delta x = 2$ và $\Delta x = -2$. Chiến lược là kết hợp hai khai triển Taylor để loại bỏ tất cả các đạo hàm thấp hơn khai triển thứ ba. Kết quả sau khi bỏ qua tất cả các số hạng bậc cao hơn [xem Bài toán 10.3(a)] là:

$$\frac{\partial^3 f(x)}{\partial x^3} = f'''(x) = \frac{f(x+2) - 2f(x+1) + 0f(x) + 2f(x-1) - f(x-2)}{2} \quad (5-8)$$

Tương tự, sai phân hữu hạn thứ tư (mức cao nhất mà chúng tôi sử dụng trong cuốn sách) sau khi bỏ qua tất cả các số hạng bậc cao hơn được cho bởi:

$$\frac{\partial^4 f(x)}{\partial x^4} = f''''(x) = f(x+2) - 4f(x+1) + 6f(x) - 4f(x-1) + f(x-2) \quad (5-9)$$

Bảng 5.1 tóm tắt bốn đạo hàm trung tâm đầu tiên vừa được thảo luận. Chú ý tính đối xứng của các hệ số quanh tâm. Sự đối xứng này là nguồn gốc giải thích tại sao hiệu sai số trung tâm có sai số gần đúng thấp hơn đối với cùng số điểm so với hai hiệu số còn lại. Đối với hai biến, chúng tôi áp dụng kết quả trong Bảng 10.1 cho từng biến một cách độc lập. Ví dụ:

$$\frac{\partial^2 f(x, y)}{\partial x^2} = f(x+1, y) - 2f(x, y) + f(x-1, y) \quad (5-10)$$

BẢNG 5.1

Bốn đạo hàm rời rạc (digital) trung tâm đầu tiên (sai phân hữu hạn) cho các mẫu được lấy thống nhất, $\Delta x = 1$ tách biệt các đơn vị

	$f(x+2)$	$f(x+1)$	$f(x)$	$f(x-1)$	$f(x-2)$
$2f'(x)$		1	0	-1	
$f''(x)$		1	-2	1	
$2f'''(x)$	1	-2	0	2	-1

thị từ trái sang phải. Ban đầu, đạo hàm bậc một khác 0 ở điểm bắt đầu và dọc theo toàn bộ đoạn cường độ, trong khi đạo hàm bậc hai chỉ khác 0 ở điểm bắt đầu và kết thúc đoạn đường nối. Bởi vì các cạnh của hình ảnh kỹ thuật số giống với kiểu chuyển đổi này, chúng tôi kết luận rằng đạo hàm cấp một tạo ra các cạnh “dày”, và đạo hàm cấp hai mỏng hơn nhiều. Tiếp theo chúng ta gặp phải điểm nhiễu bị cô lập. Ở đây, độ lớn của đáp ứng tại điểm đối với đạo hàm bậc hai mạnh hơn nhiều so với đạo hàm bậc một. Điều này không có gì bất ngờ, bởi vì đạo hàm bậc hai mạnh mẽ hơn nhiều so với đạo hàm bậc một trong việc tăng cường những thay đổi rõ rệt. Vì vậy, chúng ta có thể kỳ vọng đạo hàm bậc hai sẽ tăng cường chi tiết tốt (bao gồm cả nhiễu) nhiều hơn so với đạo hàm bậc một. Đường thẳng trong ví dụ này khá mỏng nên cũng rất chi tiết và chúng ta lại thấy rằng đạo hàm bậc hai có độ lớn lớn hơn. Cuối cùng, lưu ý ở cả cạnh dốc và cạnh bậc rằng đạo hàm bậc hai có dấu ngược nhau (âm sang dương hoặc dương sang âm) khi nó chuyển vào và ra khỏi một cạnh. Hiệu ứng “cạnh kép” này là một đặc điểm quan trọng có thể được sử dụng để xác định vị trí các cạnh, như chúng tôi sẽ trình bày sau trong phần này. Khi chúng ta di chuyển vào cạnh, dấu của đạo hàm bậc hai cũng được sử dụng để xác định xem một cạnh là sự chuyển đổi từ sáng sang tối (đạo hàm bậc hai âm) hay từ tối sang sáng (đạo hàm bậc hai dương).

Tóm lại, chúng tôi đi đến các kết luận sau: (1) Đạo hàm cấp một thường tạo ra các cạnh dày hơn. (2) Đạo hàm bậc hai có phản ứng mạnh hơn với các chi tiết nhỏ, chẳng hạn như đường mảnh, điểm cô lập và nhiễu. (3) Đạo hàm bậc hai tạo ra phản ứng hai cạnh khi chuyển đổi cường độ và bước chuyển tiếp. (4) Dấu của đạo hàm bậc hai có thể được sử dụng để xác định xem sự chuyển tiếp sang một cạnh là từ sáng sang tối hay từ tối sang sáng.

Cách tiếp cận được lựa chọn để tính đạo hàm bậc nhất và đạo hàm bậc hai ở mọi vị trí điểm ảnh trong ảnh là sử dụng tích chập không gian. Đối với bộ lọc bộ lọc 3x3 trong Hình 5.3, quy trình là tính tổng các tích của các hệ số bộ lọc với các giá trị cường độ trong vùng được bao quanh bởi bộ lọc. Nghĩa là, phản hồi của bộ lọc tại điểm trung tâm của bộ lọc là:

$$Z = w_1 z_1 + w_2 z_2 + \dots + w_9 z_9 = \sum_{k=1}^9 w_k z_k \quad (5-12)$$

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

Hình 5.3 Một bộ lọc lọc không gian chung. W là các hệ số bộ lọc (trọng số).

Trong đó z_k là cường độ của điểm ảnh có vị trí không gian tương ứng với vị trí của hệ số bộ lọc thứ k.

5.2.2. Phát hiện điểm

Dựa trên các kết luận đạt được trong phần trước, chúng ta biết rằng việc phát hiện điểm phải dựa trên đạo hàm bậc hai, có nghĩa là sử dụng toán tử Laplace:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (5-13)$$

trong đó đạo hàm riêng được tính bằng cách sử dụng sai phân hữu hạn bậc hai trong các phương trình (5-10) và (5-11). Khi đó toán tử Laplace là:

$$\nabla^2 f(x, y) = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y) \quad (5-14)$$




Biểu thức này có thể được triển khai bằng cách sử dụng bộ lọc Laplace trong Hình 5.4(a) trong Ví dụ 5.1. Sau đó, chúng tôi nói rằng một điểm đã được phát hiện tại vị trí (x, y) mà bộ lọc được căn giữa nếu giá trị tuyệt đối của phản hồi của bộ lọc tại điểm đó vượt quá ngưỡng được chỉ định. Những điểm như vậy được gán nhãn 1 và tất cả những điểm khác được gán nhãn 0 trong ảnh đầu ra, do đó tạo ra ảnh nhị phân. Nói cách khác, chúng ta sử dụng biểu thức:

$$g(x, y) = \begin{cases} 1 & \text{nếu } |Z(x, y)| > T \\ 0 & \text{nếu khác} \end{cases} \quad (5-15)$$

trong đó $g(x, y)$ là hình ảnh đầu ra, T là ngưỡng không âm và Z được cho bởi biểu thức (5-12). Công thức này chỉ đơn giản đo lường sự khác biệt có trọng số giữa một điểm ảnh và 8 điểm ảnh lân cận của nó. Theo trực giác, ý tưởng là cường độ của một điểm cô lập sẽ hoàn toàn khác với môi trường xung quanh và do đó loại bộ lọc này sẽ dễ dàng phát hiện được. Những chênh lệch về cường độ được quan tâm là những chênh lệch đủ lớn (được xác định bởi T) để được coi là các điểm biệt lập. Lưu ý rằng, như thường lệ đối với bộ lọc phải sinh, các hệ số có tổng bằng 0, biểu thị rằng phản hồi của bộ lọc sẽ bằng 0 trong các vùng có cường độ không đổi.

a
b c d

1	1	1
1	-8	1
1	1	1



Hình 5.4 (a) Bộ lọc Laplacian được sử dụng để phát hiện điểm. (b) Ảnh X-quang của cánh tuabin bị xâm thực được biểu hiện bằng một điểm ảnh màu đen. (c) Kết quả của việc kết hợp bộ lọc với hình ảnh. (d) Kết quả của việc sử dụng phương trình (5-15) là một điểm duy nhất (được phóng to ở đầu mũi tên).

VÍ DỤ 5.1 Phát hiện các điểm biệt lập trong ảnh.

Hình 5.4(b) là hình ảnh tia X của cánh tuabin từ động cơ phản lực. Cánh tuabin bị xâm thực được biểu hiện bằng một điểm ảnh màu đen ở góc phần tư phía trên bên phải của hình ảnh. Hình 5.4(c) là kết quả của việc lọc ảnh bằng bộ lọc Laplace và Hình 5.4(d) hiển thị kết quả của phương trình (5-15) với T bằng 90% giá trị điểm ảnh tuyệt đối cao nhất của ảnh trong Hình 5.4(c). Điểm ảnh đơn lẻ được hiển thị rõ ràng trong hình ảnh này ở đầu mũi tên (điểm ảnh được phóng to để nâng cao khả năng hiển thị của nó). Loại quy trình phát hiện này mang tính chuyên biệt vì nó dựa trên sự thay đổi cường độ đột ngột tại các vị trí một điểm ảnh được bao quanh bởi nền đồng nhất trong khu vực của nhân máy dò. Khi điều kiện này không được thỏa mãn, các phương pháp khác được thảo luận trong chương này sẽ phù hợp hơn để phát hiện sự thay đổi cường độ.


5.2.3. Phát hiện đường

Mức độ phức tạp tiếp theo là phát hiện đường thẳng. Dựa trên cuộc thảo luận trước đó trong phần này, chúng ta biết rằng để phát hiện đường thẳng, chúng ta có thể mong đợi đạo hàm thứ hai mang lại phản ứng lọc mạnh hơn và tạo ra các đường mỏng hơn so với đạo hàm thứ nhất. Vì vậy, chúng ta cũng có thể sử dụng bộ lọc Laplacian trong Hình 5.4(a) để phát hiện đường thẳng, hãy nhớ rằng hiệu ứng đường đôi của đạo hàm bậc hai phải được xử lý đúng cách. Ví dụ sau đây minh họa quy trình.

VÍ DỤ 5.2 Sử dụng Laplacian để phát hiện đường thẳng.

Hình 5.5(a) hiển thị một phần (nhị phân) của mặt nạ liên kết dây cho một mạch điện tử và Hình 5.5(b) hiển thị hình ảnh Laplacian của nó. Vì ảnh Laplace chứa các giá trị âm, nên cần phải chia tỷ lệ để hiển thị. Như phần phóng to cho thấy, màu xám ở giữa biểu thị số 0, màu xám đậm hơn biểu thị giá trị âm và màu sáng hơn biểu thị giá trị dương. Hiệu ứng đường đôi có thể nhìn thấy rõ ở vùng phóng đại.

a b
c d



Hình 5.5 (a) Ảnh gốc. (b) Hình ảnh Laplacian; phần được phóng to cho thấy đặc tính hiệu ứng đường đôi dương/âm của Laplacian. (c) Giá trị tuyệt đối của Laplacian. (d) Giá trị dương của Laplacian.

Lúc đầu, có vẻ như các giá trị âm có thể được xử lý đơn giản bằng cách lấy giá trị tuyệt đối của ảnh Laplace. Tuy nhiên, như hình 5.5(c) cho thấy, cách tiếp cận này làm tăng gấp đôi độ dày của các đường. Một cách tiếp cận phù hợp hơn là chỉ sử dụng các giá trị dương của Laplacian (trong các tình huống nhiễu, chúng tôi sử dụng các giá trị vượt quá ngưỡng dương để loại bỏ các biến đổi ngẫu nhiên về 0 do nhiễu gây ra). Như hình 5.5(d) cho thấy, cách tiếp cận này tạo ra các đường mỏng hơn và thường hữu ích hơn. Lưu ý trong hình 5.5(b) đến (d) rằng khi các đường thẳng rộng so với kích thước của bộ lọc Laplacian, thì các đường này được phân tách bằng một “thung lũng” số 0. Điều này không có gì bất ngờ. Ví dụ: khi bộ lọc 3x3 được căn giữa trên một đường có cường độ không đổi rộng 5 điểm ảnh, phản hồi sẽ bằng 0, do đó tạo ra hiệu ứng vừa đề cập. Khi chúng ta nói về phát hiện đường thẳng, giả định là các đường này mỏng so với kích thước của máy dò. Các đường không thỏa mãn giả định này tốt nhất được coi là vùng và được xử lý bằng các phương pháp phát hiện cạnh được thảo luận trong phần sau.

Bộ lọc máy dò Laplacian trong Hình 5.4(a) là đẳng hướng, do đó phản ứng của nó không phụ thuộc vào hướng (đối với bốn hướng của bộ lọc: dọc, ngang và hai đường chéo). Thông thường, mỗi quan tâm nằm ở việc phát hiện các đường theo hướng xác định. Hãy xem xét các bộ lọc trong Hình 5.6. Giả sử rằng một hình ảnh có nền không đổi và chứa nhiều dòng khác nhau (được định hướng tại $0^\circ, \pm 45^\circ, 90^\circ$) được lọc bằng bộ lọc đầu tiên. Phản hồi tối đa sẽ xảy ra tại các vị trí hình ảnh trong đó một đường ngang đi qua hàng giữa của bộ lọc. Điều này có thể dễ dàng xác minh bằng cách phác thảo một mảng đơn giản gồm các số 1 với một dòng có cường độ khác nhau (chẳng hạn như 5 giây) chạy ngang qua mảng. Một thí nghiệm tương tự sẽ tiết lộ rằng bộ lọc thứ hai trong Hình 5.6 phản ứng tốt nhất với các đường hướng từ bộ lọc thứ ba đến các đường thẳng đứng; và bộ lọc thứ tư thành các dòng theo hướng. Hướng ưu tiên của mỗi bộ lọc được tính trọng số với hệ số lớn hơn (tức là 2) so với các hướng có thể khác. Các hệ số trong mỗi bộ lọc có tổng bằng 0, biểu thị phản hồi bằng 0 trong các vùng có cường độ không đổi.


-1	-1	-1	2	-1	-1	-1	2	-1	-1	-1	2
2	2	2	-1	2	-1	-1	2	-1	-1	2	-1
-1	-1	-1	-1	-1	2	-1	2	-1	2	-1	-1
Horizontal			+45°			Vertical			-45°		
a	b	c	d								

Hình 5.6 Bộ lọc phát hiện đường. Các góc dương được đo ngược chiều kim đồng hồ đối với trục x (dọc).

Đặt Z_1, Z_2, Z_3, Z_4 biểu thị các phản ứng của các bộ lọc trong Hình 5.6, từ trái sang phải, trong đó Z_s được cho bởi phương trình (5-12). Giả sử rằng một hình ảnh được lọc bằng bốn bộ lọc này, mỗi lần một bộ lọc. Nếu, tại một điểm nhất định trong ảnh, $|Z_k| > |Z_j|$ đối với tất cả $j \neq k$ điểm đó được cho là có nhiều khả năng liên kết với một đường theo hướng của bộ lọc k . Ví dụ: nếu tại một điểm trong ảnh, $|Z_1| > |Z_j|$ với $j = 2, 3, 4$ điểm đó được cho là có nhiều khả năng liên kết với một đường ngang. Nếu chúng ta quan tâm đến việc phát hiện tất cả các dòng trong một hình ảnh theo hướng được xác định bởi một bộ lọc nhất định, chúng ta chỉ cần chạy bộ lọc thông qua hình ảnh và đặt ngưỡng giá trị tuyệt đối của kết quả, như

trong biểu thức. (5-15) . Các điểm khác 0 còn lại sau khi đặt ngưỡng là những phản hồi mạnh nhất, đối với các dòng có độ dày một điểm ảnh, tương ứng gần nhất với hướng được xác định bởi bộ lọc.

Hình 5.7(a) hiển thị hình ảnh được sử dụng trong ví dụ trước. Giả sử rằng chúng ta quan tâm đến việc tìm tất cả các dòng có độ dày một điểm ảnh và được định hướng tại. Với mục đích này, chúng ta sử dụng kernel trong Hình 5.6(b) . Hình 5.7(b) là kết quả của việc lọc ảnh bằng kernel đó. Như trước đây, các sắc thái tối hơn nền xám trong Hình 5.7(b) tương ứng với các giá trị âm. Có hai phân đoạn chính trong hình ảnh được định hướng theo hướng $+45^\circ$, một ở phía trên bên trái và một ở phía dưới bên phải. Hình 5.7(c) và (d) hiển thị các phần được phóng to của Hình 5.7(b) tương ứng với hai khu vực này. Đoạn thẳng trong Hình 5.7(d) sáng hơn đoạn trong Hình 5.7(c) vì đoạn thẳng ở dưới cùng bên phải của Hình 5.7(a) dày một điểm ảnh, trong khi đoạn thẳng ở trên cùng bên trái không phải. Bộ lọc được "điều chỉnh" để phát hiện các đường có độ dày một điểm ảnh theo hướng, vì vậy chúng tôi hy vọng phản hồi của nó sẽ mạnh hơn khi phát hiện các đường như vậy. Hình 5.7(e) thể hiện các giá trị dương của Hình 5.7(b) . Vì chúng ta quan tâm đến phản hồi mạnh nhất nên chúng ta đặt T bằng 254 (giá trị lớn nhất trong Hình 5.7(e) trừ một). Hình 5.7(f) hiển thị màu trắng các điểm có giá trị thỏa mãn điều kiện $g > T$ trong đó g là ảnh trong Hình 5.7(e). Các điểm biệt lập trong hình là các điểm cũng có phản ứng mạnh tương tự đối với bộ lọc. Trong ảnh gốc, những điểm này và các điểm lân cận của chúng được định hướng sao cho bộ lọc tạo ra phản hồi tối đa tại các vị trí đó. Những điểm biệt lập này có thể được phát hiện bằng cách sử dụng kernel trong Hình 5.4(a) và sau đó xóa hoặc chúng có thể bị xóa bằng cách sử dụng các toán tử hình thái, như đã thảo luận trong chương trước.




Hình 5.7 (a) Hình ảnh của mẫu liên kết dây. (b) Kết quả xử lý với bộ lọc phát hiện đường thẳng $+45^\circ$ trong Hình 5.6. (c) Chế độ xem phóng to của vùng trên cùng bên trái của (b). (d) Chế độ xem phóng to của vùng dưới cùng bên phải của (b). (e) Hình ảnh trong (b) với tất cả các giá trị âm được đặt thành 0. (f) Tất cả các điểm (màu trắng) có giá trị thỏa mãn điều kiện $g > T$ trong đó g là ảnh trong (e) và (giá trị điểm ảnh tối đa trong ảnh trừ 1). (Các điểm trong (f) đã được phóng to để dễ nhìn hơn.)


5.2.4. Mô hình biên

Phát hiện biên là một phương pháp được sử dụng thường xuyên để phân đoạn hình ảnh dựa

trên những thay đổi cường độ xám đột ngột. Chúng tôi bắt đầu bằng cách giới thiệu một số cách để mô hình hóa một số loại biên và sau đó thảo luận về một số phương pháp tiếp cận để phát hiện cạnh.




Hình 5.8 Từ trái sang phải, các mô hình biên, biên bước nhảy (Step edge), biên thoải thoải (Ramp edge), biên mái nhà (roof edge)




Hình 5.9 Hình ảnh 1508×1970 hiển thị các mặt cắt đoạn đường nối thực tế (phóng to) (dưới, trái), bậc (trên, phải) và mép mái. Các đường nét từ tối đến sáng, trong các khu vực được bao quanh bởi các vòng tròn nhỏ. Cấu hình đoạn đường nối và bậc thang lần lượt có kích thước 9 điểm ảnh và 2 điểm ảnh. Nền của biên mái nhà là 3 điểm ảnh.

Hình 5.10(a) hiển thị hình ảnh từ đó đoạn trong Hình 5.8(b) được trích xuất. Hình 5.10(b) thể hiện đường cong cường độ theo chiều ngang. Hình này cũng cho thấy đạo hàm bậc nhất và bậc hai của biểu đồ cường độ. Di chuyển từ trái sang phải dọc theo biểu đồ cường độ, chúng tôi lưu ý rằng đạo hàm bậc nhất dương tại điểm bắt đầu của đoạn đường nối và tại các điểm trên đoạn đường nối, và nó bằng 0 trong các vùng có cường độ không đổi. Đạo hàm thứ hai dương ở đầu đoạn đường nối, âm ở cuối đoạn đường nối, bằng 0 tại các điểm trên đoạn đường nối và bằng 0 tại các điểm có cường độ không đổi. Dấu của đạo hàm vừa thảo luận sẽ bị đảo ngược đối với một biên chuyển từ sáng sang tối. Giao điểm giữa trục cường độ bằng 0 và một đường kéo dài giữa cực trị của đạo hàm thứ hai đánh dấu một điểm gọi là giao điểm 0 của đạo hàm thứ hai.



Hình 5.10 (a) Hai vùng có cường độ không đổi được ngăn cách bởi một biên dốc lý tưởng. (b) Chi tiết gần rìa, hiển thị cấu hình cường độ ngang và các đạo hàm thứ nhất và thứ hai của nó.



Hình 5.11 Cột đầu tiên: hình ảnh 8 bit có các giá trị trong phạm vi $[0, 255]$ và cấu hình

cường độ của cạnh dốc bị hỏng do nhiễu Gaussian có giá trị trung bình bằng 0 và độ lệch chuẩn lần lượt là 0,0, 0,1, 1,0 và 10,0 mức cường độ. Cột thứ hai: Hình ảnh đạo hàm đầu tiên và hồ sơ cường độ. Cột thứ ba: Hình ảnh đạo hàm thứ hai và cấu hình cường độ.

Hãy xem xét hình ảnh ở đầu cột trung tâm. Như đã thảo luận trong Hình 5.10(b), đạo hàm của đường quét bên trái bằng 0 trong các vùng không đổi. Đây là hai dải màu đen hiển thị trong hình ảnh phải sinh. Đạo hàm tại các điểm trên đoạn đường nối không đổi và bằng độ dốc - gradient của đoạn đường nối. Các giá trị không đổi này trong ảnh phải sinh được hiển thị bằng màu xám. Khi chúng ta di chuyển xuống cột giữa, đạo hàm ngày càng trở nên khác biệt so với trường hợp không có tiếng ồn. Trên thực tế, sẽ khó liên kết mặt cắt cuối cùng ở cột giữa với đạo hàm bậc nhất của cạnh dốc. Điều làm cho những kết quả này trở nên thú vị là nhiều hàu như không thể phát hiện được bằng mắt thường trong các hình ảnh ở cột bên trái. Những ví dụ này là những minh họa tốt về độ nhạy của đạo hàm đối với nhiễu.

Đúng như dự đoán, đạo hàm bậc hai thậm chí còn nhạy hơn với nhiễu. Đạo hàm thứ hai của hình ảnh không nhiễu được hiển thị ở đầu cột bên phải. Các đường thẳng đứng mỏng màu trắng và đen là thành phần dương và âm của đạo hàm bậc hai, như được giải thích trong Hình 5.10. Màu xám trong những hình ảnh này đại diện cho số 0 (như đã thảo luận trước đó, việc chia tỷ lệ khiến số 0 hiển thị dưới dạng màu xám). Hình ảnh đạo hàm thứ hai có nhiều duy nhất gần như không giống với trường hợp không có nhiễu tương ứng với nhiễu có độ lệch chuẩn là 0,1. Các hình ảnh và cấu hình đạo hàm bậc hai còn lại minh họa rõ ràng rằng thực sự sẽ khó phát hiện các thành phần dương và âm của chúng, đây là những tính năng thực sự hữu ích của đạo hàm bậc hai về mặt phát hiện cạnh.

Thực tế là nhiễu hình ảnh nhỏ như vậy có thể có tác động đáng kể đến hai dẫn xuất chính được sử dụng để phát hiện các cạnh là một vấn đề quan trọng cần lưu ý. Đặc biệt, việc làm mịn hình ảnh phải được xem xét nghiêm túc trước khi sử dụng các dẫn xuất trong các ứng dụng có khả năng xuất hiện nhiễu với các mức tương tự như mức chúng ta vừa thảo luận.

Tóm lại, ba bước được thực hiện điển hình để phát hiện biên là:

1. Làm mịn hình ảnh để giảm nhiễu. Sự cần thiết của bước này được minh họa bằng kết quả ở cột thứ hai và thứ ba của Hình 5.11.

2. Phát hiện các điểm biên. Như đã đề cập trước đó, đây là một thao tác cục bộ trích xuất từ một hình ảnh tất cả các điểm có thể là điểm biên tiềm năng.

3. Bản địa hóa biên. Mục tiêu của bước này là chỉ chọn từ các điểm ứng viên những điểm là thành viên của tập hợp các điểm bao gồm một biên.

Phần còn lại của phần này đề cập đến các kỹ thuật để đạt được các mục tiêu này

5.2.5. Phát hiện biên cơ bản

Như đã minh họa trong phần thảo luận trước, việc phát hiện những thay đổi về cường độ nhằm mục đích tìm kiếm các cạnh có thể được thực hiện bằng cách sử dụng đạo hàm bậc một hoặc bậc hai. Chúng ta bắt đầu với đạo hàm cấp một và làm việc với đạo hàm bậc hai trong mục sau.

Độ dốc - gradient hình ảnh và các thuộc tính của nó

Công cụ được lựa chọn để tìm cường độ và hướng cạnh tại một vị trí tùy ý (x, y) của ảnh, f là độ dốc, được ký hiệu là ∇f và định nghĩa là vector.

Để thuận tiện, chúng ta nhắc lại ở đây một số khái niệm và phương trình độ dốc được giới thiệu trong:

$$\nabla f(x, y) \equiv \text{grad}[f(x, y)] \equiv \begin{bmatrix} g_x(x, y) \\ g_y(x, y) \end{bmatrix} = \begin{bmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{bmatrix} \quad (5-16)$$

Vector này có một tính chất quen thuộc là nó chỉ hướng tốc độ thay đổi cực đại của f tại (x, y) . Phương trình (5-16) có giá trị tại một điểm tùy ý (nhưng đơn) (x, y) . Khi được đánh giá cho tất cả các giá trị có thể áp dụng của x và y , $\nabla f(x, y)$ sẽ trở thành một hình ảnh vector, mỗi phần tử của nó là một vector được cho bởi biểu thức. (5-16). Độ lớn $M(x, y)$ của vector độ dốc này tại một điểm (x, y) được cho bởi chuẩn vector Euclide của nó:

$$M(x, y) = \|\nabla f(x, y)\| = \sqrt{g_x^2(x, y) + g_y^2(x, y)} \quad (5-17)$$

Đây là giá trị tốc độ thay đổi theo hướng của vector độ dốc tại điểm (x, y) . Lưu ý rằng $M(x, y)$, $\|\nabla f(x, y)\|$, $g_x(x, y)$ và $g_y(x, y)$ là các mảng có cùng kích thước với f , được tạo khi x và y được phép thay đổi trên tất cả các vị trí điểm ảnh trong f . Thông thường, người ta coi $M(x, y)$ và $\|\nabla f(x, y)\|$ là hình ảnh độ dốc hoặc đơn giản là độ dốc khi ý nghĩa rõ ràng. Các phép tính tổng, bình phương và căn bậc hai là các phép toán theo từng phần tử, như được định nghĩa trước đây.

Hướng của vector độ dốc - gradient tại một điểm (x, y) được cho bởi:


$$\alpha(x, y) = \tan^{-1} \left[\frac{g_y(x, y)}{g_x(x, y)} \right] \quad (5-18)$$

Các góc được đo theo hướng ngược chiều kim đồng hồ so với trục x . Đây cũng là một hình ảnh có cùng kích thước với f , được tạo bằng phép chia theo từng phần tử và trên tất cả các giá trị có thể áp dụng của x và y . Ví dụ sau minh họa, hướng của một cạnh tại một điểm (x, y) vuông góc với hướng của vector độ dốc tại điểm đó.

VÍ DỤ 5.5 Tính độ dốc - gradient

Hình 5.12(a) hiển thị một phần được phóng to của hình ảnh chứa đoạn cạnh thẳng. Mỗi hình vuông tương ứng với một điểm ảnh và chúng tôi quan tâm đến việc đạt được cường độ và hướng của cạnh tại điểm được đánh dấu bằng hộp. Các điểm ảnh được tô bóng trong hình này được giả sử là có giá trị 0 và các điểm ảnh trắng có giá trị 1. Sau ví dụ này, chúng ta thảo luận về một phương pháp tính đạo hàm theo hướng x và y bằng cách sử dụng vùng lân cận 3×3 có tâm tại một điểm. Phương pháp này bao gồm việc trừ các điểm ảnh ở hàng trên cùng của vùng lân cận khỏi các điểm ảnh ở hàng dưới cùng để thu được đạo hàm riêng theo hướng x . Tương tự, chúng ta trừ các điểm ảnh ở cột bên trái khỏi các điểm ảnh ở cột bên phải của vùng lân cận để thu được đạo hàm riêng theo hướng y . Sau đó, sử dụng những khác biệt này làm ước tính về các phần, sao cho $\frac{\partial f}{\partial x} = -2$ và $\frac{\partial f}{\partial y} = 2$ tại điểm được đề cập. Sau đó,

$$\nabla f = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} -2 \\ 2 \end{bmatrix}$$



Hình 5.12 Sử dụng độ dốc để xác định cường độ cạnh và hướng tại một điểm. Lưu ý rằng hướng của cạnh vuông góc với hướng của vectơ độ dốc tại điểm tính độ dốc. Mỗi ô vuông đại diện cho một điểm ảnh.

từ đó chúng ta thu được $\|\nabla f\| = 2\sqrt{2}$ tại điểm đó. Tương tự, hướng của vectơ độ dốc tại cùng một điểm tuân theo biểu thức. (10-18): $\alpha = \tan^{-1}\left(\frac{g_y}{g_x}\right) = -45^\circ$ tương tự như được đo theo hướng dương 135° (ngược chiều kim đồng hồ) đối với trục x trong hệ tọa độ ảnh của chúng ta. Hình 5.12(b) cho thấy vectơ độ dốc và góc hướng của nó.

Như đã đề cập trước đó, hướng của một cạnh tại một điểm là trực giao với vectơ độ dốc tại điểm đó. Vì vậy, góc định hướng của cạnh trong ví dụ này là $\alpha - 90^\circ = 135^\circ - 90^\circ = 45^\circ$ như được minh họa trong Hình 5.12(c). Tất cả các điểm cạnh trong hình 5.12(a) có cùng độ dốc, do đó toàn bộ đoạn cạnh có cùng hướng. Vectơ độ dốc đôi khi được gọi là cạnh chuẩn tắc. Khi vectơ được chuẩn hóa thành đơn vị chiều dài bằng cách chia nó cho độ lớn của nó, vectơ kết quả được gọi là pháp tuyến đơn vị cạnh.

Toán tử độ dốc - gradient

Để có được độ dốc của hình ảnh đòi hỏi phải tính toán đạo hàm riêng $\partial f/\partial x$ và $\partial f/\partial y$ tại mọi vị trí điểm ảnh trong hình ảnh. Đối với độ dốc, chúng ta thường sử dụng sai phân hữu hạn tiến hoặc chính giữa (xem Bảng 5.1). Sử dụng chênh lệch kỳ hạn chúng ta thu được:


$$g_x(x, y) = \frac{\partial f(x, y)}{\partial x} = f(x + 1, y) - f(x, y) \quad (5-19)$$

và

$$g_y(x, y) = \frac{\partial f(x, y)}{\partial y} = f(x, y + 1) - f(x, y) \quad (5-20)$$

Hai phương trình này có thể được thực hiện cho tất cả các giá trị của x và y bằng cách lọc $f(x, y)$ với các bộ lọc 1-D trong Hình 5.13

a b



Hình 5.13 Bộ lọc 1-D được sử dụng để triển khai các phương trình (5-19) và (5-20)

Khi hướng cạnh chéo được quan tâm, chúng ta cần bộ lọc 2-D. Các toán tử độ dốc chéo của Roberts là một trong những nỗ lực sớm nhất để sử dụng bộ lọc 2-D với ưu tiên đường chéo.

Hãy xem xét vùng 3×3 trong Hình 5.14(a). Các toán tử Roberts dựa trên việc thực hiện sự khác biệt đường chéo.

Các bộ lọc được sử dụng để tính toán đạo hàm cần thiết cho độ dốc thường được gọi là toán tử độ dốc, toán tử sai phân, toán tử cạnh hoặc bộ dò cạnh.

$$g_x = \frac{\partial f}{\partial x} = (z_9 - z_5) \quad (5-21)$$

và

$$g_y = \frac{\partial f}{\partial y} = (z_8 - z_6) \quad (5-22)$$

a
b c
d e
f g

z_1	z_2	z_3
z_4	z_5	z_6
z_7	z_8	z_9

-1	0	0	-1
0	1	1	0

Roberts

-1	-1	-1	-1	0	1
0	0	0	-1	0	1
1	1	1	-1	0	1

Prewitt

-1	-2	-1	-1	0	1
0	0	0	-2	0	2
1	2	1	-1	0	1

Sobel

Hình 5.14 Một vùng 3×3 của hình ảnh (z là giá trị cường độ) và các bộ lọc khác nhau được sử dụng để tính toán độ dốc - gradient tại điểm được gắn nhãn z_5 .

Các đạo hàm này có thể được thực hiện bằng cách lọc một hình ảnh với các bộ lọc được hiển thị trong hình 5.14(b) và (c).

Các bộ lọc có kích thước 2×2 đơn giản về mặt khái niệm, nhưng chúng không hữu ích cho việc tính toán hướng cạnh như các bộ lọc đối xứng về tâm của chúng, hạt nhỏ nhất có kích thước 3×3 . Các bộ lọc này tính đến bản chất của dữ liệu ở các phía đối diện của điểm trung tâm, và do đó mang nhiều thông tin hơn về hướng của một cạnh. Các phép tính gần đúng rời rạc xấp xỉ (digital) đơn giản nhất đối với đạo hàm riêng sử dụng các bộ lọc có kích thước 3×3 được đưa ra bởi:

Quan sát rằng hai phương trình này là sai phân trung tâm bậc nhất như được cho trong biểu thức (5-6), nhưng nhân với 2.

$$g_x = \frac{\partial f}{\partial x} = (z_7 + z_8 + z_9) - (z_1 + z_2 + z_3) \quad (5-23)$$

và

$$g_y = \frac{\partial f}{\partial y} = (z_3 + z_6 + z_9) - (z_1 + z_4 + z_7)$$

Trong công thức này, hiệu giữa hàng thứ ba và hàng đầu tiên của vùng 3×3 xấp xỉ đạo hàm theo hướng x và chênh lệch giữa cột thứ ba và cột đầu tiên gần đúng với đạo hàm theo hướng y. Theo trực giác, chúng ta mong đợi những phép tính gần đúng này sẽ chính xác hơn các phép tính gần đúng thu được bằng cách sử dụng các toán tử Roberts. Các phương trình (5-22) và (5-23) có thể được triển khai trên toàn bộ hình ảnh bằng cách lọc nó bằng hai bộ lọc trong Hình 5.14(d) và (e). Những bộ lọc này được gọi là toán tử Prewitt.

Một biến thể nhỏ của hai phương trình trước đó sử dụng trọng số là 2 trong hệ số trung tâm:

$$g_x = \frac{\partial f}{\partial x} = (z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3) \quad (5-24)$$

và

$$g_y = \frac{\partial f}{\partial y} = (z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7) \quad (5-25)$$

Có thể chứng minh rằng việc sử dụng số 2 ở vị trí trung tâm sẽ làm mịn hình ảnh. Hình 5.14(f) và (g) hiển thị các bộ lọc được sử dụng để triển khai các phương trình (5-24) và (5-25). Những bộ lọc này được gọi là toán tử Sobel.

Bộ lọc Prewitt dễ triển khai hơn bộ lọc Sobel, nhưng sự khác biệt nhỏ về mặt tính toán giữa chúng thường không phải là vấn đề. Thực tế là các bộ lọc Sobel có đặc tính khử nhiễu (làm mịn) tốt hơn khiến chúng được ưa chuộng hơn bởi vì, như đã đề cập trước đó trong phần thảo luận ở Hình 5.11, khử nhiễu là một vấn đề quan trọng khi xử lý các dẫn xuất. Lưu ý rằng các hệ số của tất cả các bộ lọc trong Hình 5.14 có tổng bằng 0, do đó đưa ra phản hồi bằng 0 trong các vùng có cường độ không đổi, như mong đợi của các toán tử đạo hàm.

Bất kỳ cặp bộ lọc nào trong Hình 5.14 đều được tích hợp với một hình ảnh để thu được các thành phần độ dốc - gradient g_x và g_y tại mọi vị trí điểm ảnh. Hai mảng đạo hàm riêng này sau đó được sử dụng để ước tính cường độ và hướng của cạnh. Để có được độ lớn của độ dốc yêu cầu tính toán trong biểu thức (5-17). Việc triển khai này không phải lúc nào cũng được mong muốn vì gánh nặng tính toán được yêu cầu bởi bình phương và căn bậc hai, đồng thời một cách tiếp cận được sử dụng thường xuyên là tính gần đúng độ lớn của độ dốc theo các giá trị tuyệt đối:

$$M(x, y) \approx |g_x| + |g_y| \quad (5-26)$$

Phương trình này hấp dẫn hơn về mặt tính toán và nó vẫn bảo toàn những thay đổi tương đối về mức cường độ. Cái giá phải trả cho lợi thế này là các bộ lọc thu được sẽ không đẳng hướng (bất biến đối với phép quay) nói chung. Tuy nhiên, đây không phải là vấn đề khi các bộ lọc như bộ lọc Prewitt và Sobel được sử dụng để tính toán g_x và g_y vì những bộ lọc này chỉ cho kết quả đẳng hướng đối với các cạnh dọc và ngang. Điều này có nghĩa là các kết quả sẽ chỉ đẳng hướng đối với các cạnh theo hai hướng đó, bất kể phương trình nào trong hai

Các bộ lọc 3×3 trong Hình 5.14 thể hiện phản ứng mạnh nhất của chúng chủ yếu đối với các cạnh dọc và ngang. Bộ lọc la bàn Kirsch trong Hình 5.15, được thiết kế để phát hiện độ lớn cạnh và hướng (góc) theo tất cả tám hướng la bàn. Thay vì tính toán độ lớn bằng phương trình (5-17) và góc sử dụng phương trình (5-18), cách tiếp cận của Kirsch là xác định độ lớn cạnh bằng cách kết hợp một hình ảnh với tất cả tám bộ lọc và gán độ lớn cạnh tại một điểm làm phản hồi của bộ lọc mang lại giá trị tích chập mạnh nhất tại điểm đó. Góc cạnh tại điểm đó là hướng liên kết với bộ lọc đó. Ví dụ: nếu giá trị mạnh nhất tại một điểm trong ảnh là kết quả của việc sử dụng bộ lọc phía bắc (N), thì cường độ cạnh tại điểm đó sẽ được gán phản hồi của bộ lọc đó và hướng sẽ là 0° (vì các cặp bộ lọc la bàn khác nhau bởi vòng quay 180° , việc chọn phản hồi tối đa sẽ luôn cho kết quả là số dương). Mặc dù khi làm việc với bộ lọc Sobel chẳng hạn, chúng ta coi cạnh bắc hoặc nam là thẳng đứng, nhưng bộ lọc la bàn N và S phân biệt giữa hai hạt này, sự khác biệt là hướng chuyển đổi cường độ xác định cạnh. Ví dụ: giả sử rằng các giá trị cường độ nằm trong phạm vi $[0, 1]$, cạnh nhị phân trong Hình 5.8(a) được xác định bởi màu đen (0) ở bên trái và màu trắng (1) ở bên phải. Khi tất cả các bộ lọc Kirsch được áp dụng cho cạnh này, bộ lọc N sẽ mang lại giá trị cao nhất, do đó biểu thị một cạnh được định hướng theo hướng bắc (tại thời điểm tính toán).

Hình 5.15 Bộ lọc la bàn Kirsch. Hướng cạnh của phản ứng mạnh nhất của mỗi bộ lọc được dán nhãn bên dưới nó.


Hình 5.16 minh họa đáp ứng giá trị tuyệt đối Sobel của hai thành phần độ dốc, $|g_x|$ và $|g_y|$, cũng như ảnh độ dốc được hình thành từ tổng của hai thành phần này. Tính định hướng của các thành phần ngang và dọc của độ dốc được thể hiện rõ trong Hình 5.16(b) và (c). Ví dụ, hãy lưu ý độ bền của mái ngói, các mối nối gạch ngang và các đoạn ngang của cửa sổ trong Hình 5.16(b) so với các cạnh khác. Ngược lại, Hình 5.16(c) thiên về các đặc điểm như các thành phần thẳng đứng của mặt tiền và cửa sổ. Thuật ngữ phổ biến là sử dụng thuật ngữ bản đồ cạnh khi đề cập đến một hình ảnh có đặc điểm chính là các cạnh, chẳng hạn như hình ảnh cường độ độ dốc. Cường độ của hình ảnh trong Hình 5.16(a) được chia tỷ lệ thành phạm vi $[0, 1]$. Chúng tôi sử dụng các giá trị trong phạm vi này để đơn giản hóa việc lựa chọn tham số trong các phương pháp khác nhau để phát hiện cạnh được thảo luận trong phần này.

a b
c d



Hình 5.16 (a) Hình ảnh có kích thước 834×1114 điểm ảnh, với các giá trị cường độ được chia tỷ lệ theo phạm vi $[0, 1]$. (b) $|g_x|$, thành phần của độ dốc theo hướng x, thu được bằng cách sử dụng bộ lọc Sobel trong Hình 5.14(f) để lọc hình ảnh. (c) $|g_y|$, thu được bằng cách sử dụng bộ lọc trong Hình 5.14(g). (d) Độ dốc hình ảnh, $|g_x| + |g_y|$.

Hình 5.17 cho thấy hình ảnh góc độ dốc được tính toán bằng phương trình (5-18). Nói chung, hình ảnh góc không hữu ích như hình ảnh độ lớn độ dốc để phát hiện cạnh, nhưng chúng bổ sung cho thông tin được trích xuất từ hình ảnh bằng cách sử dụng độ lớn của độ dốc. Ví dụ, các vùng cường độ không đổi trong Hình 5.16(a), chẳng hạn như cạnh trước của mái dốc và các dải ngang trên cùng của bức tường phía trước, không đổi trong Hình 5.17, biểu thị rằng hướng vector độ dốc ở tất cả các điểm ảnh vị trí ở các khu vực đó là như nhau. Như chúng tôi sẽ trình bày sau trong phần này, thông tin góc đóng vai trò hỗ trợ chính trong việc triển khai thuật toán phát hiện cạnh Canny, một cơ chế phát hiện cạnh được sử dụng rộng rãi.



Hình 5.17 Hình ảnh góc độ dốc - gradient được tính toán bằng phương trình (5-18). Các vùng có cường độ không đổi trong hình ảnh này cho biết hướng của vector độ dốc là như nhau ở tất cả các vị trí điểm ảnh trong các vùng đó.

Hình ảnh gốc trong Hình 5.16(a) có độ phân giải khá cao và ở khoảng cách thu được hình ảnh, sự đóng góp của các viên gạch trên tường tạo nên chi tiết hình ảnh là rất đáng kể. Mức độ chi tiết tốt này thường không được mong muốn trong việc phát hiện cạnh vì nó có xu hướng hoạt động như nhiễu, được tăng cường bởi các tính toán đạo hàm và do đó làm phức tạp việc phát hiện các cạnh chính. Một cách để giảm chi tiết nhỏ là làm mịn hình ảnh trước khi tính toán các cạnh. Hình 5.18 hiển thị cùng một chuỗi hình ảnh như trong Hình 5.16, nhưng với ảnh gốc được làm mịn trước bằng cách sử dụng bộ lọc trung bình 5×5 . Phản hồi của mỗi bộ lọc giờ đây hầu như không có sự đóng góp nào do các khối gạch, với kết quả chủ yếu bị chi phối bởi các cạnh chính trong hình ảnh.


Hình 5.16 và 5.18 cho thấy các hạt Sobel ngang và dọc không phân biệt các cạnh theo các hướng $\pm 45^\circ$. Nếu điều quan trọng là phải nhấn mạnh các cạnh được định hướng theo các hướng chéo cụ thể thì nên sử dụng một trong các bộ lọc Kirsch trong Hình 5.15. Hình 5.19(a) và (b) lần lượt thể hiện phản hồi của bộ lọc Kirsch 45° (NW) và -45° (SW). Độ chọn lọc theo đường chéo mạnh hơn của các bộ lọc này được thể hiện rõ trong các hình này. Cả hai bộ lọc đều có phản hồi tương tự với các cạnh ngang và dọc, nhưng phản hồi theo các hướng này yếu hơn.

a b
c d



Hình 5.18 Trình tự tương tự như trong Hình 5.16, nhưng với ảnh gốc được làm mịn bằng cách sử dụng bộ lọc trung bình trước khi phát hiện cạnh.

a b



Hình 5.19 Phát hiện cạnh chéo. (a) Kết quả của việc sử dụng bộ lọc Kirsch trong Hình 5.15(c). (b) Kết quả của việc sử dụng bộ lọc trong Hình 5.15(d). Hình ảnh đầu vào trong cả hai trường hợp là Hình 5.18(a).

5.2.6. Các kỹ thuật nâng cao để phát hiện biên

Trong phần này, chúng ta thảo luận về các kỹ thuật nâng cao hơn nhằm cải thiện các phương

pháp phát hiện cạnh đơn giản bằng cách tính đến các yếu tố như nhiều hình ảnh và bản chất của chính các cạnh.

Phương pháp phát hiện cạnh Marr-Hildreth

Một trong những nỗ lực thành công sớm nhất trong việc kết hợp các phân tích phức tạp hơn vào quá trình tìm kiếm cạnh là của Marr và Hildreth. Các phương pháp phát hiện cạnh được sử dụng vào thời điểm đó dựa trên các toán tử nhỏ, chẳng hạn như bộ lọc Sobel đã thảo luận trước đó. Marr và Hildreth lập luận (1) rằng sự thay đổi cường độ không độc lập với tỷ lệ hình ảnh, ngụ ý rằng việc phát hiện chúng đòi hỏi phải sử dụng các toán tử có kích thước khác nhau; và (2) rằng sự thay đổi cường độ đột ngột sẽ tạo ra một đỉnh hoặc đáy trong đạo hàm thứ nhất hoặc tương đương, tạo ra điểm giao nhau bằng 0 trong đạo hàm thứ hai (như chúng ta đã thấy trong Hình 5.10).

Những ý tưởng này gợi ý rằng toán tử được sử dụng để phát hiện cạnh phải có hai đặc điểm nổi bật. Đầu tiên và quan trọng nhất, nó phải là một toán tử vi phân có khả năng tính toán xấp xỉ rời rạc (digital) của đạo hàm bậc nhất hoặc đạo hàm thứ hai tại mọi điểm trong ảnh. Thứ hai, nó phải có khả năng được “điều chỉnh” để hoạt động ở bất kỳ tỷ lệ mong muốn nào, sao cho có thể sử dụng các toán tử lớn để phát hiện các cạnh mờ và các toán tử nhỏ để phát hiện các chi tiết nhỏ được tập trung sắc nét.

Marr và Hildreth gợi ý rằng toán tử thỏa mãn các điều kiện này nhất là bộ lọc $\nabla^2 G$ trong đó, như được định nghĩa, ∇^2 là hàm Laplacian và G là hàm Gaussian 2-D với độ lệch chuẩn σ (đôi khi được gọi là hằng số không gian trong ngữ cảnh này). Chúng tôi tìm thấy biểu thức $\nabla^2 G$ bằng cách áp dụng Laplacian cho biểu thức (5-27):

Phương trình (5-27) khác với định nghĩa của hàm Gaussian bởi hằng số nhân. Ở đây, chúng ta chỉ quan tâm đến hình dạng tổng quát của hàm Gaussian

$$G(x, y) = e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (5-27)$$

$$\nabla^2 G(x, y) = \frac{\partial^2 G(x, y)}{\partial x^2} + \frac{\partial^2 G(x, y)}{\partial y^2} \quad (5-28)$$

$$\begin{aligned} &= \frac{\partial}{\partial x} \left(\frac{-x}{\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \right) + \frac{\partial}{\partial y} \left(\frac{-y}{\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \right) \\ &= \left(\frac{x^2}{\sigma^4} - \frac{1}{\sigma^2} \right) e^{-\frac{x^2+y^2}{2\sigma^2}} + \left(\frac{y^2}{\sigma^4} - \frac{1}{\sigma^2} \right) e^{-\frac{x^2+y^2}{2\sigma^2}} \end{aligned}$$


Gộp các điều trên, ta được:

$$\nabla^2 G(x, y) = \left(\frac{x^2 + y^2 - 2\sigma^2}{\sigma^4} \right) e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (5-29)$$

Biểu thức này được gọi là **Laplacian của Gaussian (LoG)**.

Các Hình 5.21(a) đến (c) hiển thị biểu đồ, hình ảnh và mặt cắt ngang 3-D của phía âm của hàm LoG (lưu ý rằng điểm giao nhau bằng 0 của LoG xảy ra tại $x^2 + y^2 = 2\sigma^2$ xác định một vòng tròn bán kính $\sqrt{2}\sigma$ có tâm ở đỉnh của hàm Gaussian). Do hình dạng được minh họa trong Hình 5.21(a), hàm LoG đôi khi được gọi là toán tử mũ Mexico. Hình 5.21(d) hiển thị một bộ lọc có hình dạng gần giống như trong Hình 5.21(a) (thông thường, chúng ta sẽ sử dụng giá trị âm của bộ lọc này). Sự gần đúng này không phải là duy nhất. Mục đích của nó

là nắm bắt hình dạng cơ bản của hàm LoG; theo Hình 5.21(a), điều này có nghĩa là số hạng dương, trung tâm được bao quanh bởi một vùng âm liên kết có giá trị giảm theo hàm của khoảng cách từ gốc và vùng bên ngoài bằng 0. Các hệ số phải có tổng bằng 0 sao cho phản ứng của bộ lọc bằng 0 trong những vùng có cường độ không đổi.



Hình 5.21 (a) Biểu đồ 3-D âm của LoG. (b) Phản âm của LoG được hiển thị dưới dạng hình ảnh. (c) Mặt cắt ngang của (a) thể hiện điểm giao cắt bằng 0. (d) bộ lọc 5×5 gần đúng với hình dạng trong (a). Âm bản của bộ lọc này sẽ được sử dụng trong thực tế.

Bộ lọc có kích thước tùy ý (nhưng σ cố định) có thể được tạo bằng cách lấy mẫu phương trình (5-29) và chia tỷ lệ các hệ số sao cho chúng có tổng bằng 0. Một cách tiếp cận hiệu quả hơn để tạo bộ lọc LoG là phương trình lấy mẫu (5-27) đến kích thước mong muốn, sau đó tích hợp mảng kết quả với nhân Laplacian, chẳng hạn như nhân trong Hình 5.4(a). Bởi vì việc tích hợp một hình ảnh với một nhân có hệ số tổng bằng 0 sẽ tạo ra một hình ảnh có các phần tử có tổng bằng 0, cách tiếp cận này tự động thỏa mãn yêu cầu tổng các hệ số nhân LoG bằng 0. Chúng ta sẽ thảo luận về việc lựa chọn kích thước cho bộ lọc LoG ở phần sau.

Có hai ý tưởng cơ bản đằng sau việc lựa chọn toán tử $\nabla^2 G$. Thứ nhất, phần Gaussian của toán tử làm mờ hình ảnh, do đó làm giảm cường độ của cấu trúc (bao gồm cả nhiễu) ở tỷ lệ nhỏ hơn nhiều so với bộ lọc trung bình được sử dụng trong Hình 5.18, Gaussian chức năng mượt mà ở cả miền không gian và tần số, và do đó ít có khả năng tạo ra các hiện vật giả (ví dụ: tiếng chuông) không có trong ảnh gốc. Ý tưởng khác liên quan đến các tính chất đạo hàm bậc hai của toán tử Laplacian ∇^2 . Mặc dù đạo hàm bậc nhất có thể được sử dụng để phát hiện những thay đổi đột ngột về cường độ nhưng chúng là các toán tử có hướng. Mặt khác, Laplacian có ưu điểm quan trọng là tính đẳng hướng (bất biến với phép quay), không chỉ tương ứng với các đặc điểm của hệ thị giác con người mà còn phản ứng như nhau với những thay đổi về cường độ theo bất kỳ hướng bộ lọc nào, do đó tránh phải sử dụng nhiều bộ lọc để tính toán phản hồi mạnh nhất tại bất kỳ điểm nào trong ảnh.

Thuật toán Marr-Hildreth bao gồm việc kết hợp bộ lọc LoG với một hình ảnh đầu vào, sau đó tìm các giao điểm bằng 0 của $g(x, y)$ để xác định vị trí của các cạnh trong $f(x, y)$. Bởi vì Laplacian và tích chập là các quá trình tuyến tính nên chúng ta có thể viết phương trình (5-30) cho thấy rằng trước tiên chúng ta có thể làm mịn hình ảnh bằng bộ lọc Gaussian và sau

đó tính toán Laplacian của kết quả. Hai phương trình này cho kết quả giống hệt nhau.

$$g(x, y) = [\nabla^2 G(x, y)] \star f(x, y) \quad (5-30)$$

$$g(x, y) = \nabla^2 [G(x, y) \star f(x, y)] \quad (5-31)$$

Thuật toán phát hiện cạnh Marr-Hildreth có thể được tóm tắt như sau:

1. Lọc hình ảnh đầu vào bằng bộ lọc thông thấp Gaussian thu được bằng cách lấy mẫu phương trình (5-27).
2. Tính Laplacian của ảnh thu được từ Bước 1 bằng cách sử dụng bộ lọc 3×3 trong Hình 5.4(a) chẳng hạn. [Bước 1 và 2 triển khai phương trình (5-31)]
3. Tìm điểm giao nhau bằng 0 của hình ảnh ở Bước 2.


Để xác định kích thước của bộ lọc Gaussian, hãy nhớ lại thảo luận của chúng ta ở Hình 3.41 rằng các giá trị của hàm Gaussian ở khoảng cách lớn hơn giá trị trung bình là đủ nhỏ để có thể bỏ qua chúng. Như đã thảo luận trong Phần 3.5, điều này ngụ ý sử dụng bộ lọc Gaussian có kích thước $|6\sigma| \times |6\sigma|$ trong đó $|6\sigma|$ biểu thị mức trần của số nguyên đó là số nguyên nhỏ nhất không nhỏ hơn. Vì chúng ta làm việc với bộ lọc có kích thước lẻ nên chúng ta sẽ sử dụng số nguyên lẻ nhỏ nhất thỏa mãn điều kiện này. Việc sử dụng bộ lọc nhỏ hơn mức này sẽ “cắt bớt” hàm LoG, với mức độ cắt bớt tỷ lệ nghịch với kích thước của bộ lọc. Sử dụng kernel lớn hơn sẽ tạo ra một chút khác biệt trong kết quả.

Một cách tiếp cận để tìm các giao điểm bằng 0 tại bất kỳ điểm ảnh p , nào của hình ảnh được lọc, $g(x, y)$, là sử dụng một vùng lân cận có tâm tại p . Điểm giao nhau bằng 0 tại p ngụ ý rằng dấu của ít nhất hai điểm ảnh lân cận đối diện của nó phải khác nhau. Có bốn trường hợp để kiểm tra: trái/phải, lên/xuống và hai đường chéo. Nếu các giá trị của $g(x, y)$ được so sánh với một ngưỡng (một cách tiếp cận phổ biến), thì không chỉ dấu của các láng giềng đối lập phải khác nhau mà giá trị tuyệt đối của hiệu số của chúng cũng phải vượt quá ngưỡng trước khi chúng ta có thể gọi p là điểm ảnh xuyên không. Chúng tôi minh họa cách tiếp cận này trong Ví dụ 5.7.

Tính toán các điểm giao nhau bằng 0 là tính năng chính của phương pháp phát hiện cạnh Marr-Hildreth. Cách tiếp cận được thảo luận ở đoạn trước rất hấp dẫn vì tính đơn giản trong thực hiện và vì nó thường mang lại kết quả tốt. Nếu độ chính xác của các vị trí giao nhau bằng 0 được tìm thấy bằng phương pháp này là không đủ trong một ứng dụng cụ thể thì có thể sử dụng một kỹ thuật tìm các điểm giao nhau bằng 0 với độ chính xác dưới điểm ảnh.

Hình 5.22(a) hiển thị hình ảnh tòa nhà được sử dụng trước đó và Hình 5.22(b) là kết quả của Bước 1 và 2 của thuật toán Marr-Hildreth, sử dụng $\sigma = 4$ (khoảng 0,5% kích thước ngắn của hình ảnh) và để đáp ứng yêu cầu điều kiện kích thước đã nêu ở trên. Như trong Hình 5.5, tông màu xám trong ảnh này là do tỷ lệ. Hình 5.22(c) cho thấy các giao điểm bằng 0 thu được bằng cách sử dụng phương pháp lân cận 3×3 vừa thảo luận, với ngưỡng bằng 0. Lưu ý rằng tất cả các cạnh tạo thành các vòng khép kín. Cái gọi là “hiệu ứng spaghetti” này là một nhược điểm nghiêm trọng của phương pháp này khi sử dụng giá trị ngưỡng bằng 0. Chúng tôi tránh các cạnh vòng kín bằng cách sử dụng ngưỡng dương.

a b
c d



Hình 5.22 (a) Hình ảnh có kích thước 834×1114 điểm ảnh, với các giá trị cường độ được chia tỷ lệ theo phạm vi $[0, 1]$. (b) Kết quả của Bước 1 và 2 của thuật toán Marr-Hildreth sử dụng $\sigma = 4$ và $n = 25$ (c) Giao điểm 0 của (b) sử dụng ngưỡng 0 (lưu ý các cạnh vòng kín). (d) Không tìm thấy giao điểm nào khi sử dụng ngưỡng bằng 4% giá trị tối đa của hình ảnh trong (b). Lưu ý các cạnh mỏng.

Hình 5.22(d) hiển thị kết quả của việc sử dụng ngưỡng xấp xỉ bằng 4% giá trị tối đa của ảnh LoG. Phần lớn các cạnh chính được phát hiện dễ dàng và các đặc điểm “không liên quan”, chẳng hạn như các cạnh do gạch và mái ngói, đã được lọc ra. Loại hiệu suất này hầu như không thể đạt được bằng cách sử dụng các kỹ thuật phát hiện cạnh dựa trên độ dốc đã thảo luận trước đó. Một hệ quả quan trọng khác của việc sử dụng giao điểm bằng 0 để phát hiện cạnh là các cạnh thu được có độ dày 1 điểm ảnh. Thuộc tính này đơn giản hóa các giai đoạn xử lý tiếp theo, chẳng hạn như liên kết cạnh.

Có thể tính gần đúng hàm LoG trong biểu thức (5-29) bởi sự khác biệt của Gaussians (DoG):

$$D_G(x, y) = \frac{1}{2\pi\sigma_1^2} e^{-\frac{x^2+y^2}{2\sigma_1^2}} - \frac{1}{2\pi\sigma_2^2} e^{-\frac{x^2+y^2}{2\sigma_2^2}} \quad (5-32)$$

với $\sigma_1 > \sigma_2$, kết quả thử nghiệm cho thấy rằng một số “kênh” nhất định trong hệ thống thị giác của con người có tính chọn lọc về hướng và tần số, đồng thời có thể được mô hình hóa bằng phương trình (5-32) với tỷ lệ độ lệch chuẩn là 1.75:1. Việc sử dụng tỷ lệ 1.6:1 bảo toàn các đặc điểm cơ bản của những quan sát này và cũng cung cấp một xấp xỉ “kỹ thuật” gần hơn với hàm LoG. Để LoG và DoG có cùng điểm giao nhau bằng 0, giá trị của LoG phải được chọn dựa trên phương trình sau:

$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 - \sigma_2^2} \ln \left[\frac{\sigma_1^2}{\sigma_2^2} \right] \quad (5-33)$$

Mặc dù giao điểm 0 của LoG và DoG sẽ giống nhau khi sử dụng giá trị này, thang biên độ của chúng sẽ khác nhau. Chúng ta có thể làm cho chúng tương thích bằng cách chia tỷ lệ cả hai hàm sao cho chúng có cùng giá trị tại gốc.

Các sơ đồ trong hình 5.23(a) và (b) được tạo ra với tỷ lệ độ lệch chuẩn lần lượt là 1:1.75 và 1:1.6 (theo quy ước, các đường cong được hiển thị là đảo ngược, như trong Hình 5.21). Cấu hình LoG là các đường liền nét và cấu hình DoG là các chấm. Các đường cong được hiển thị là các cấu hình cường độ xuyên qua tâm của mảng LoG và DoG, được tạo bằng cách lấy mẫu các phương trình (5-29) và (5-32) tương ứng. Biên độ của tất cả các đường cong tại điểm gốc được chuẩn hóa thành 1. Như Hình 5.23(b) cho thấy, tỷ lệ 1:1.6 mang lại sự gần đúng hơn một chút giữa các hàm LoG và DoG (ví dụ: so sánh các thùy dưới của hai hình).

a b



Hình 5.23 (a) Phân âm của cấu hình LoG (snake) và DoG (chấm) sử dụng tỷ lệ 1.75:1. (b) Sơ đồ thu được bằng tỷ lệ 1.6:1.

Bộ lọc Gaussian có thể tách rời (xem Phần 3.4). Do đó, cả hoạt động lọc LoG và DoG đều có thể được triển khai bằng phép tích chập 1-D thay vì sử dụng trực tiếp phép tích chập 2-D. Đối với một hình ảnh có kích thước $M \times N$ và bộ lọc có kích thước $n \times n$, làm như vậy sẽ làm giảm số lượng phép nhân và phép cộng cho mỗi phép tích chập từ tỷ lệ thuận $n^2 MN$ với tích chập 2-D thành tỷ lệ thuận với nMN đối với tích chập 1-D. Sự khác biệt thực hiện này là đáng kể. Ví dụ: nếu $n = 25$ việc triển khai 1-D sẽ yêu cầu các phép tính nhân và cộng ít hơn 12 lần so với sử dụng tích chập 2-D.

5.3. Phân ngưỡng trong phân vùng ảnh

Do các đặc tính trực quan, thực hiện đơn giản và tốc độ tính toán, ngưỡng ảnh chiếm vị trí trung tâm trong các ứng dụng phân đoạn ảnh. Ngưỡng đã được giới thiệu trong phần trước và chúng ta cũng đã sử dụng nó trong nhiều. Trong phần này, chúng ta thảo luận về ngưỡng theo cách chính thức hơn và phát triển các kỹ thuật tổng quát hơn đáng kể so với những gì đã được trình bày cho đến nay.

5.3.1. Phân ngưỡng toàn cục đơn giản

Giả sử rằng biểu đồ cường độ trong Hình 5.32(a) tương ứng với một hình ảnh $f(x, y)$, bao gồm các đối tượng sáng trên nền tối, theo cách mà các điểm ảnh đối tượng và nền có các giá trị cường độ được nhóm thành hai chế độ vượt trội. Một cách rõ ràng để trích xuất các đối tượng khỏi nền là chọn một ngưỡng T để phân tách các chế độ này. Khi đó, bất kỳ điểm nào (x, y) trong ảnh thỏa mãn $f(x, y) > T$ thì được gọi là điểm đối tượng. Ngược lại, điểm đó được gọi là điểm nền. Nói cách khác, ảnh được phân đoạn, ký hiệu là $g(x, y)$, được cho bởi:

$$g(x, y) = \begin{cases} 1 & \text{nếu } f(x, y) > T \\ 0 & \text{nếu } f(x, y) \leq T \end{cases} \quad (5-46)$$

Nhớ rằng, $f(x, y)$ biểu thị cường độ của f tại tọa độ (x, y) . Mặc dù chúng tôi tuân theo quy ước trong việc sử dụng cường độ 0 cho nền và 1 cho điểm ảnh đối tượng, bất kỳ hai giá trị riêng biệt nào cũng có thể được sử dụng trong biểu thức (5-46).


Khi T là hằng số áp dụng được trên toàn bộ ảnh, quá trình đưa ra trong phương trình này được gọi là ngưỡng toàn cục. Khi giá trị của T thay đổi trên một ảnh, chúng ta sử dụng thuật ngữ ngưỡng biến. Thuật ngữ ngưỡng cục bộ hoặc ngưỡng khu vực đôi khi được sử dụng để biểu thị ngưỡng biến đổi trong đó giá trị của T tại bất kỳ điểm nào (x, y) trong ảnh phụ thuộc vào các thuộc tính của vùng lân cận (x, y) (ví dụ: cường độ trung bình của các điểm ảnh trong vùng lân cận). Nếu T phụ thuộc vào tọa độ không gian (x, y) , thì ngưỡng biến đổi

thường được gọi là ngưỡng động hoặc ngưỡng thích ứng. Việc sử dụng các thuật ngữ này không phổ biến

Hình 5.32(b) cho thấy một vấn đề ngưỡng khó khăn hơn liên quan đến biểu đồ có ba chế độ vượt trội, ví dụ, tương ứng với hai loại đối tượng sáng trên nền tối. Ở đây, nhiều ngưỡng phân loại một điểm (x, y) thuộc về nền nếu $f(x, y) \leq T_1$ thuộc một lớp đối tượng nếu $T_1 < f(x, y) \leq T_2$ và thuộc lớp đối tượng khác nếu $f(x, y) > T_2$. Nghĩa là, hình ảnh được phân đoạn được đưa ra bởi:

$$g(x, y) = \begin{cases} a & \text{nếu } f(x, y) > T_2 \\ b & \text{nếu } T_1 < f(x, y) \leq T_2 \\ c & \text{nếu } f(x, y) \leq T_1 \end{cases} \quad (5-47)$$

trong đó a , b và c là ba giá trị cường độ riêng biệt bất kỳ. Chúng ta sẽ thảo luận về ngưỡng kép sau trong phần này. Các vấn đề về phân đoạn yêu cầu nhiều hơn hai ngưỡng rất khó giải quyết (hoặc thường là không thể) và thường thu được kết quả tốt hơn bằng cách sử dụng các phương pháp khác, chẳng hạn như ngưỡng biến đổi, như sẽ được thảo luận sau trong phần này, hoặc phát triển vùng, như chúng ta sẽ thảo luận trong phần phát triển vùng.




Hình 5.32 Biểu đồ cường độ có thể được phân chia (a) theo một ngưỡng duy nhất và (b) theo ngưỡng kép.

Dựa trên các lý luận trước đây, chúng ta có thể suy luận một cách trực quan rằng sự thành công của ngưỡng cường độ có liên quan trực tiếp đến chiều rộng và độ sâu của (các) thung lũng ngăn cách các chế độ biểu đồ. Đổi lại, các yếu tố chính ảnh hưởng đến tính chất của (các) thung lũng là: (1) sự tách biệt giữa các đỉnh (các đỉnh càng cách xa nhau thì cơ hội tách các chế độ càng tốt); (2) nội dung nhiều trong ảnh (các chế độ mở rộng khi nhiều tăng); (3) kích thước tương đối của vật thể và nền; (4) tính đồng nhất của nguồn chiếu sáng; và (5) tính đồng nhất của đặc tính phản xạ của hình ảnh.

Vai trò của nhiễu trong phân ngưỡng hình ảnh


Hình ảnh tổng hợp đơn giản trong Hình 5.33(a) không bị nhiễu, do đó biểu đồ của nó bao gồm hai chế độ “tăng đột biến”, như Hình 5.33(d) cho thấy. Việc phân chia hình ảnh này thành hai vùng là một nhiệm vụ đơn giản: chúng ta chỉ cần chọn một ngưỡng ở bất kỳ đâu giữa hai chế độ. Hình 5.33(b) cho thấy ảnh gốc bị hỏng do nhiễu Gaussian có giá trị trung bình bằng 0 và độ lệch chuẩn là 10 mức cường độ. Các chế độ hiện nay rộng hơn, nhưng sự tách biệt của chúng đủ để độ sâu của thung lũng giữa chúng đủ để làm cho các chế độ dễ dàng tách ra. Một ngưỡng được đặt ở giữa hai đỉnh sẽ thực hiện được công việc. Hình 5.33(c) cho thấy kết quả của việc làm hỏng hình ảnh với nhiễu Gaussian có giá trị trung bình bằng 0 và độ lệch chuẩn là 50 mức cường độ. Như biểu đồ trong Hình 5.33(f) cho thấy, tình hình hiện nay nghiêm trọng hơn nhiều vì không có cách nào để phân biệt giữa hai chế độ. Nếu không có quá trình xử lý bổ sung (chẳng hạn như các phương pháp được thảo luận sau trong phần này), chúng ta có rất ít hy vọng tìm được ngưỡng phù hợp để phân đoạn hình ảnh này.



Hình 5.33 (a) Hình ảnh 8 bit không nhiễu. (b) Hình ảnh có nhiễu Gaussian cộng có giá trị trung bình là 0 và độ lệch chuẩn là 10 mức cường độ. (c) Hình ảnh có nhiễu Gaussian phụ gia có giá trị trung bình là 0 và độ lệch chuẩn là 50 mức cường độ. (d) đến (f) Biểu đồ tương ứng.

Vai trò của độ sáng và độ phản xạ trong phân ngưỡng hình ảnh

Hình 5.34 minh họa hiệu ứng chiếu sáng có thể có trên biểu đồ của hình ảnh. Hình 5.34(a) là hình ảnh nhiễu từ Hình 5.33(b) và Hình 5.34(d) hiển thị biểu đồ của nó. Như trước đây, hình ảnh này có thể dễ dàng phân đoạn bằng một ngưỡng duy nhất. Giả sử rằng chúng ta nhân hình ảnh trong Hình 5.34(a) với một hàm cường độ không đồng nhất, chẳng hạn như đường dốc cường độ trong Hình 5.37(b), có biểu đồ được hiển thị trong Hình 5.34(e). Hình 5.34(c) hiển thị tích của hai hình ảnh này và Hình 5.34(f) là biểu đồ kết quả. Thung lũng sâu giữa các đỉnh đã bị hỏng đến mức không thể tách các chế độ mà không cần xử lý bổ sung (sẽ được thảo luận sau trong phần này). Các kết quả tương tự sẽ đạt được nếu độ chiếu sáng hoàn toàn đồng đều, nhưng độ phản xạ của hình ảnh không phải là kết quả của các biến thể phản xạ tự nhiên trên bề mặt của vật thể và/hoặc nền.



Hình 5.34 (a) Hình ảnh nhiễu. (b) Độ dốc cường độ trong khoảng $[0,2, 0,6]$. (c) Tích của (a) và (b). (d) đến (f) Biểu đồ tương ứng.

Điểm quan trọng là độ chiếu sáng và độ phản xạ đóng vai trò trung tâm trong sự thành công của phân đoạn hình ảnh bằng cách sử dụng ngưỡng hoặc các kỹ thuật phân đoạn khác. Do đó, việc kiểm soát các yếu tố này khi có thể nên là bước đầu tiên được xem xét trong giải pháp cho vấn đề phân khúc. Có ba cách tiếp cận cơ bản cho vấn đề khi không thể kiểm soát được các yếu tố này. Đầu tiên là sửa trực tiếp kiểu tô bóng. Ví dụ, độ chiếu sáng không đồng đều (nhưng cố định) có thể được điều chỉnh bằng cách nhân hình ảnh với nghịch đảo của mẫu, có thể thu được bằng cách chụp ảnh một bề mặt phẳng có cường độ không đổi. Thứ hai là cố gắng sửa mô hình tô bóng tổng thể thông qua quá trình xử lý bằng cách sử dụng, ví dụ, phép biến đổi mũ trên cùng. Cách tiếp cận thứ ba là “giải quyết” sự không đồng đều bằng cách sử dụng ngưỡng thay đổi, như được thảo luận sau trong phần này.

Khái niệm cơ bản về ngưỡng toàn cục

Khi sự phân bố cường độ của các đối tượng và điểm ảnh nền đủ khác biệt, có thể sử dụng một ngưỡng (tổng thể) duy nhất áp dụng cho toàn bộ hình ảnh. Trong hầu hết các ứng dụng, thường có đủ sự biến đổi giữa các hình ảnh, ngay cả khi ngưỡng toàn cục là một cách tiếp cận phù hợp, cần phải có một thuật toán có khả năng ước tính giá trị ngưỡng cho mỗi hình ảnh. Thuật toán lặp sau đây có thể được sử dụng cho mục đích này:

1. Chọn ước tính khởi tạo cho ngưỡng toàn cục T .
2. Phân đoạn hình ảnh bằng T trong biểu thức (5-46). Điều này sẽ tạo ra hai nhóm điểm ảnh: G_1 bao gồm các điểm ảnh có giá trị cường độ $> T$ và G_2 bao gồm các điểm ảnh có giá trị $\leq T$.
3. Tính toán các giá trị cường độ trung bình (trung bình) m_1 và m_2 cho các điểm ảnh tương ứng trong G_1 và G_2 .
4. Tính giá trị ngưỡng mới ở giữa m_1 và m_2 :


$$T = \frac{1}{2}(m_1 + m_2)$$

5. Lặp lại các bước từ 2 đến 4 cho đến khi chênh lệch giữa các giá trị của T trong các lần lặp liên tiếp nhỏ hơn giá trị được xác định trước ΔT .

Thuật toán được trình bày ở đây dưới dạng ngưỡng liên tục của hình ảnh đầu vào và tính toán giá trị trung bình ở mỗi bước, bởi vì việc giới thiệu nó theo cách này sẽ trực quan hơn. Tuy nhiên, có thể phát triển một quy trình tương đương (và hiệu quả hơn) bằng cách biểu diễn tất cả các tính toán theo biểu đồ hình ảnh, vốn chỉ được tính một lần.

Thuật toán trước hoạt động tốt trong các tình huống có khoảng trống hợp lý giữa các chế độ của biểu đồ liên quan đến đối tượng và nền. Tham số ΔT được sử dụng để dừng lặp lại khi những thay đổi về giá trị ngưỡng là nhỏ. Ngưỡng ban đầu phải được chọn lớn hơn mức tối thiểu và nhỏ hơn mức cường độ tối đa trong ảnh (cường độ trung bình của ảnh là lựa chọn ban đầu tốt cho T). Nếu điều kiện này được đáp ứng, thuật toán sẽ hội tụ theo một số bước hữu hạn, cho dù các chế độ có thể tách rời hay không.

Hình 5.35 cho thấy một ví dụ về phân đoạn bằng thuật toán lặp trước đó. Hình 5.35(a) là ảnh gốc và Hình 5.35(b) là biểu đồ hình ảnh, hiển thị một thung lũng khác biệt. Việc áp dụng thuật toán toàn cục cơ bản dẫn đến ngưỡng $T = 125.4$ sau ba lần lặp, bắt đầu bằng T bằng cường độ trung bình của hình ảnh và sử dụng $\Delta T = 0$. Hình 5.35(c) cho thấy kết quả thu được khi sử dụng $T = 125$ để phân đoạn hình ảnh gốc. Đúng như mong đợi từ sự phân tách rõ ràng các chế độ trong biểu đồ, sự phân chia giữa đối tượng và nền rất hoàn hảo.



Hình 5.35 (a) Dấu vân tay nhiều (b) Biểu đồ. (c) Kết quả được phân đoạn sử dụng ngưỡng chung (đường viền hình ảnh mỏng được thêm vào để rõ ràng).

5.3.2. Phương pháp phân ngưỡng tối ưu Otsu

Phân ngưỡng có thể được xem như một bài toán lý thuyết quyết định thống kê với mục tiêu là giảm thiểu sai số trung bình phát sinh khi gán điểm ảnh cho hai hoặc nhiều nhóm (còn gọi là lớp). Bài toán này được biết là có một giải pháp dạng đóng tính toán được gọi là hàm quyết định Bayes. Giải pháp chỉ dựa trên hai tham số: hàm mật độ xác suất (PDF) của mức cường độ của từng lớp và xác suất mà mỗi mclass xảy ra trong một ứng dụng nhất định. Thật không may, việc ước mật độ xác suất PDF cũng khá phức tạp, vì vậy vấn đề thường được đơn giản hóa bằng cách đưa ra các giả định khả thi về dạng của hàm PDF, chẳng hạn như giả sử rằng chúng là các hàm Gaussian. Ngay cả khi đơn giản hóa, quy trình triển khai các giải pháp sử dụng các giả định này có thể phức tạp và không phải lúc nào cũng phù hợp cho các ứng dụng thời gian thực.

Cách tiếp cận trong phần thảo luận sau đây, được gọi là phương pháp của Otsu, là một phương pháp thay thế hấp dẫn. Phương pháp này tối ưu theo nghĩa là nó tối đa hóa phương sai giữa các lớp, một thước đo nổi tiếng được sử dụng trong phân tích phân biệt thống kê. Ý tưởng cơ bản sai rằng các lớp được ngưỡng đúng cách phải khác biệt đối với các giá trị cường độ của các điểm ảnh của chúng và ngược lại, ngưỡng tạo ra sự phân tách tốt nhất giữa các lớp về giá trị cường độ của chúng sẽ là ngưỡng (tối ưu) tốt nhất. Ngoài tính tối ưu của

nó, phương pháp của Otsu còn có một đặc tính quan trọng là nó hoàn toàn dựa trên các tính toán được thực hiện trên biểu đồ của một hình ảnh, một mảng 1-D có thể dễ dàng thu được.

Đặt $(0, 1, \dots, L-1)$ biểu thị tập hợp L mức cường độ nguyên riêng biệt trong một ảnh kỹ thuật số có kích thước $M \times N$ điểm ảnh và đặt n_i biểu thị số lượng điểm ảnh có cường độ i . Tổng số điểm ảnh, MN , trong ảnh là $MN = n_0 + n_1 + \dots + n_{L-1}$. Biểu đồ histogram chuẩn hóa có các thành phần $p_i = n_i/MN$ mà từ đó nó tuân theo:

$$\sum_{i=0}^{L-1} p_i = 1 \quad p_i \geq 0 \quad (5-48)$$

Bây giờ, giả sử rằng chúng ta chọn một ngưỡng $T(k) = k, 0 < k < L-1$ và sử dụng nó để phân ngưỡng hình ảnh đầu vào thành hai lớp c_1 và c_2 , trong đó c_1 bao gồm tất cả các điểm ảnh trong ảnh có giá trị cường độ trong phạm vi $[0, k]$ và c_2 bao gồm các điểm ảnh có giá trị trong phạm vi $[k+1, L-1]$. Khi sử dụng ngưỡng này, xác suất $P_1(k)$ để một điểm ảnh được gán cho lớp c_1 (tức là được phân ngưỡng) được tính bằng tổng tích lũy:

$$P_1(k) = \sum_{i=0}^k p_i \quad (5-49)$$

Nhìn theo cách khác, đây là xác suất xảy ra lớp c_1 . Ví dụ: nếu chúng ta đặt $k=0$ xác suất của lớp c_1 có bất kỳ điểm ảnh nào được gán cho nó là bằng 0. Tương tự, xác suất của lớp c_2 xảy ra là:

$$P_2(k) = \sum_{i=k+1}^{L-1} p_i = 1 - P_1(k) \quad (5-50)$$

Từ đó, giá trị cường độ trung bình của các điểm ảnh trong c_1 là:

$$m_1(k) = \sum_{i=0}^k iP\left(\frac{i}{c_1}\right) = \sum_{i=0}^k iP\left(\frac{c_1}{i}\right) \frac{P(i)}{P(c_1)} = \frac{1}{P_1(k)} \sum_{i=0}^k ip_i \quad (5-51)$$

Trong đó $P_1(k)$ được đưa tính bởi phương trình (5-49). Thuật ngữ $P(i/c_1)$ trong phương trình (5-51) là xác suất của giá trị cường độ i , với điều kiện i thuộc lớp c_1 . Số hạng ngoài cùng bên phải ở dòng đầu tiên của phương trình được rút ra từ công thức Bayes:

$$P\left(\frac{A}{B}\right) = P(B/A)P(A)/P(B)$$

Dòng thứ hai xuất phát từ thực tế là $P(c_1/i)$ - xác suất của c_1 khi biết i là 1 vì chúng ta chỉ xử lý các giá trị của i từ lớp c_1 . Ngoài ra, $P(i)$ là xác suất của giá trị thứ i , là thành phần thứ i của biểu đồ p_i . Cuối cùng, $P(c_1)$ là xác suất của lớp c_1 , từ biểu thức (5-49), tương đương với $P_1(k)$.

Tương tự, giá trị cường độ trung bình của các điểm ảnh được gán cho lớp c_2 là:

$$m_2(k) = \sum_{i=k+1}^{L-1} iP\left(\frac{i}{c_2}\right) = \frac{1}{P_2(k)} \sum_{i=k+1}^{L-1} ip_i \quad (5-52)$$

Giá trị trung bình tích lũy (cường độ trung bình) lên đến mức k được tính bằng:

$$m(k) = \sum_{i=0}^k ip_i \quad (5-53)$$

và cường độ trung bình của toàn bộ hình ảnh (tức là giá trị trung bình toàn cầu) được tính bằng:

$$m_G = \sum_{i=0}^{L-1} ip_i \quad (5-54)$$

Tính hợp lệ của hai phương trình sau có thể được xác minh bằng cách thay thế trực tiếp các kết quả trước đó:

$$P_1 m_1 + P_2 m_2 = m_G \quad (5-55)$$

và

$$P_1 + P_2 = 1 \quad (5-56)$$

trong đó chúng tôi đã tạm thời bỏ qua ks để có được sự rõ ràng về mặt ký hiệu.

Để đánh giá hiệu quả của ngưỡng ở mức k, chúng tôi sử dụng thước đo chuẩn hóa, không nguyên:

$$\eta = \frac{\sigma_B^2}{\sigma_G^2} \quad (5-57)$$

trong đó σ_G^2 là phương sai toàn cục (tức là phương sai cường độ của tất cả các điểm ảnh trong ảnh):

$$\sigma_G^2 = \sum_{i=0}^{L-1} (i - m_G)^2 p_i \quad (5-58)$$

và σ_B^2 là phương sai giữa các lớp, được định nghĩa là:

$$\sigma_B^2 = P_1(m_1 - m_G)^2 + P_2(m_2 - m_G)^2 \quad (5-59)$$

Biểu thức này cũng có thể được viết là:

$$\sigma_B^2 = P_1 P_2 (m_1 - m_2)^2 = \frac{(m_G P_1 - m)^2}{P_1 (1 - P_1)}$$

Dòng đầu tiên của phương trình này được tính theo các phương trình (5-55), (5-56) và (5-59). Dòng thứ hai được tính từ phương trình (5-50) đến (5-54). Dạng này hiệu quả hơn một chút về mặt tính toán vì giá trị trung bình toàn cục chỉ được tính một lần, do đó chỉ có hai tham số và cần được tính cho bất kỳ giá trị nào của k.

Dòng đầu tiên trong phương trình (5-60) chỉ ra rằng hai giá trị trung bình m_1 và m_2 càng xa nhau thì σ_B^2 càng lớn, ngụ ý rằng phương sai giữa các lớp là thước đo khả năng phân tách giữa các lớp. Bởi vì σ_G^2 là một hằng số nên nó cũng là thước đo khả năng phân tách và việc tối đa hóa số liệu này tương đương với việc tối đa hóa σ_B^2 . Mục tiêu sau đó là xác định giá trị ngưỡng k để tối đa hóa phương sai giữa các lớp như đã nêu trước đó. Lưu ý rằng phương trình (5-57) ngầm giả định rằng $\sigma_G^2 > 0$. Phương sai này chỉ có thể bằng 0 khi tất cả các mức cường độ trong ảnh là như nhau, điều này ngụ ý sự tồn tại của chỉ một loại điểm ảnh. Điều này có nghĩa là $\eta = 0$ đối với một hình ảnh không đổi vì khả năng phân tách của một lớp với chính nó là bằng 0.

Giới thiệu lại k , ta có kết quả cuối cùng:

$$\eta(k) = \frac{\sigma_B^2(k)}{\sigma_G^2} \quad (5-61)$$

và

$$\sigma_B^2 = \frac{[m_G P_1(k) - m(k)]^2}{P_1(k)[1 - P_1(k)]} \quad (5-62)$$

Khi đó, ngưỡng tối ưu là giá trị k^* sao cho tối đa hóa giá trị $\sigma_B^2(k)$:

$$\sigma_B^2(k^*) = \max_{0 \leq k \leq L-1} \sigma_B^2(k) \quad (5-63)$$

Để tìm k^* , chúng ta chỉ cần đánh giá phương trình này cho tất cả các giá trị nguyên của k (tuân theo điều kiện $0 < P_1(k) < 1$) và chọn giá trị k mang lại giá trị $\sigma_B^2(k)$ lớn nhất. Nếu cực đại tồn tại với nhiều hơn một giá trị của k , thì thông thường ta lấy trung bình các giá trị khác nhau của k ở đó $\sigma_B^2(k)$ lớn nhất. Có thể chỉ ra rằng mức cực đại luôn tồn tại, tuân theo điều kiện $0 < P_1(k) < 1$. Đánh giá các phương trình (5-62) và (5-63) cho tất cả các giá trị của k là một thủ tục có chi phí tính toán thấp, bởi vì số lượng giá trị số nguyên tối đa mà có thể có là L , chỉ có 256 đối với ảnh 8 bit.

Sau khi đã thu được k^* , ảnh đầu vào $f(x, y)$ được phân đoạn như trước:

$$g(x, y) = \begin{cases} 1 & \text{nếu } f(x, y) > k^* \\ 0 & \text{nếu } f(x, y) \leq k^* \end{cases} \quad (5-64)$$

với $x = 0, 1, 2, \dots, M-1$ và $y = 0, 1, 2, \dots, N-1$. Lưu ý rằng tất cả các đại lượng cần thiết để đánh giá phương trình (5-62) thu được chỉ bằng cách sử dụng biểu đồ của $f(x, y)$. Ngoài ngưỡng tối ưu, các thông tin khác liên quan đến ảnh được phân đoạn có thể được trích xuất từ biểu đồ. Ví dụ: $P_1(k^*)$ và $P_2(k^*)$ là xác suất của lớp được đánh giá ở ngưỡng tối ưu, cho biết các phần của khu vực bị chiếm giữ bởi các lớp (nhóm điểm ảnh) trong hình ảnh có ngưỡng. Tương tự, giá trị trung bình $m_1(k^*)$ và $m_2(k^*)$ là ước tính cường độ trung bình của các lớp trong ảnh gốc.

Nói chung, số đo trong phương trình (5-61) có các giá trị trong khoảng:

$$0 \leq \eta(k) \leq 1 \quad (5-65)$$

đối với các giá trị của k trong phạm vi $[0, L-1]$. Khi được đánh giá ở ngưỡng tối ưu k^* , thước đo này là ước tính định lượng về khả năng phân tách của các lớp, từ đó cho chúng ta ý tưởng về độ chính xác của việc đặt ngưỡng cho một hình ảnh nhất định với k^* . Giới hạn dưới trong biểu thức (5-65) chỉ có thể đạt được bằng các hình ảnh có mức cường độ không đổi, duy nhất. Giới hạn trên chỉ có thể đạt được bằng các ảnh có hai giá trị với cường độ bằng 0 và $L-1$.

Thuật toán Otsu:

1. Tính toán biểu đồ chuẩn hóa của hình ảnh đầu vào. Biểu thị các thành phần của biểu đồ bằng $p_i, i = 0, 1, 2, \dots, L-1$.
2. Tính tổng tích lũy $P_1(k)$ với $k = 0, 1, 2, \dots, L-1$ sử dụng phương trình (5-49).
3. Tính giá trị trung bình tích lũy $m(k)$ với $k = 0, 1, 2, \dots, L-1$ sử dụng phương trình (5-

53).

4. Tính giá trị trung bình toàn cục m_G , sử dụng phương trình (5-54).

5. Tính số hạng phương sai giữa các lớp $\sigma_B^2(k)$ với $k = 0, 1, 2, \dots, L - 1$ sử dụng phương trình (5-62).

6. Lấy ngưỡng Otsu, k^* với giá trị k thì $\sigma_B^2(k)$ lớn nhất. Nếu mức tối đa không phải là duy nhất, tính k^* bằng cách lấy trung bình các giá trị của k tương ứng với các cực đại khác nhau được phát hiện.

7. Tính phương sai tổng thể σ_C^2 , sử dụng phương trình (5-58), sau đó thu được thước đo khả năng phân tách η^* , bằng cách đánh giá biểu thức (5-61) với $k = k^*$.

5.4. Phân đoạn bằng phát triển vùng, tách vùng và nhất vùng

5.4.1. Thuật toán phát triển vùng

Đúng như tên gọi của nó, phát triển vùng là một quy trình nhóm các điểm ảnh hoặc tiểu vùng thành các vùng lớn hơn dựa trên các tiêu chí tăng trưởng được xác định trước. Cách tiếp cận cơ bản là bắt đầu với một tập hợp các điểm “hạt giống” và từ các vùng phát triển này bằng cách thêm vào mỗi hạt giống những điểm ảnh lân cận có các thuộc tính được xác định trước tương tự như hạt giống (chẳng hạn như phạm vi cường độ hoặc màu sắc).

Việc chọn một tập hợp gồm một hoặc nhiều điểm bắt đầu thường có thể dựa trên bản chất của vấn đề, như chúng tôi sẽ trình bày sau trong ví dụ 5.20. Khi thông tin tiên nghiệm không có sẵn, quy trình sẽ tính toán ở mỗi điểm ảnh cùng một tập hợp thuộc tính mà cuối cùng sẽ được sử dụng để gán điểm ảnh cho các vùng trong quá trình phát triển. Nếu kết quả của những tính toán này hiển thị các cụm giá trị thì các điểm ảnh có thuộc tính đặt chúng gần tâm của các cụm này có thể được sử dụng làm hạt giống.

Việc lựa chọn tiêu chí tương tự không chỉ phụ thuộc vào vấn đề đang được xem xét mà còn phụ thuộc vào loại dữ liệu hình ảnh có sẵn. Ví dụ: việc phân tích hình ảnh vệ tinh sử dụng đất phụ thuộc rất nhiều vào việc sử dụng màu sắc. Vấn đề này sẽ khó giải quyết hơn nhiều, hoặc thậm chí không thể giải quyết được nếu không có thông tin vốn có trong hình ảnh màu. Khi hình ảnh đơn sắc, việc phân tích vùng phải được thực hiện với một bộ mô tả dựa trên mức cường độ và đặc tính không gian (chẳng hạn như kết cấu).

Chỉ riêng các bộ mô tả có thể mang lại kết quả sai lệch nếu các thuộc tính kết nối không được sử dụng trong quá trình phát triển vùng. Ví dụ: hình dung sự sắp xếp ngẫu nhiên các điểm ảnh có ba giá trị cường độ riêng biệt. Việc nhóm các điểm ảnh có cùng giá trị cường độ để tạo thành một “vùng” mà không chú ý đến khả năng kết nối sẽ mang lại kết quả phân đoạn vô nghĩa trong bối cảnh của cuộc thảo luận này.

Một vấn đề khác trong việc phát triển khu vực là việc xây dựng quy tắc dừng. Sự phát triển của vùng sẽ dừng lại khi không còn điểm ảnh nào thỏa mãn tiêu chí để đưa vào vùng đó. Các tiêu chí như giá trị cường độ, kết cấu và màu sắc mang tính chất cục bộ và không tính đến “lịch sử” phát triển của khu vực. Tiêu chí bổ sung có thể tăng sức mạnh của thuật toán phát triển vùng sử dụng khái niệm về kích thước, độ tương tự giữa điểm ảnh ứng cử viên và điểm ảnh được phát triển cho đến nay (chẳng hạn như so sánh cường độ của ứng cử viên và cường độ trung bình của vùng đã phát triển) và hình dạng của vùng đang được trồng. Việc sử dụng các loại mô tả này dựa trên giả định rằng mô hình kết quả mong đợi ít nhất có sẵn một phần.

Đặt $f(x, y)$ biểu thị một hình ảnh đầu vào; $S(x, y)$ biểu thị một mảng hạt giống chứa 1 tại vị trí của các điểm hạt giống và 0 ở những nơi khác; và Q biểu thị một vị trí từ được áp dụng tại mỗi vị trí (x, y) . Mảng f và S được giả sử có cùng kích thước. Thuật toán phát triển vùng cơ bản dựa trên kết nối 8 có thể được phát biểu như sau:

1. Tìm tất cả các thành phần liên thông trong $S(x, y)$ và gán mỗi thành phần liên thông thành

một điểm ảnh; gắn nhãn tất cả các điểm ảnh tìm thấy là 1. Tất cả các điểm ảnh khác trong S được gắn nhãn 0.

2. Tạo một ảnh f_Q sao cho tại mỗi điểm (x, y) , $f_Q(x, y) = 1$ nếu ảnh đầu vào thỏa mãn một vị từ Q cho trước tại các tọa độ đó; nếu không, $f_Q(x, y) = 0$.


3. Cho g là một ảnh được hình thành bằng cách thêm vào mỗi điểm giống trong S tất cả các điểm có giá trị 1 trong đó được kết nối 8 với điểm giống đó.

4. Dán nhãn cho mỗi thành phần được kết nối trong g bằng nhãn vùng khác nhau (ví dụ: số nguyên hoặc chữ cái). Đây là hình ảnh được phân đoạn thu được theo vùng đang phát triển.

Ví dụ sau minh họa cơ chế của thuật toán này:

VÍ DỤ 5.20: Phân đoạn ảnh bằng phát triển vùng.

Hình 5.46(a) hiển thị ảnh X quang 8 bit của một mối hàn (vùng tối ngang) có chứa một số vết nứt và độ xốp (vùng sáng chạy ngang qua tâm của hình ảnh). Chúng ta minh họa việc sử dụng phát triển vùng bằng cách phân đoạn các vùng hàn bị lỗi. Các vùng này có thể được sử dụng trong các ứng dụng như kiểm tra mối hàn, đưa vào cơ sở dữ liệu nghiên cứu lịch sử hoặc để điều khiển hệ thống hàn tự động.



Hình 5.46 (a) Ảnh X-quang của mối hàn bị lỗi (b) Lược đồ xám. (c) Hình ảnh hạt giống ban đầu. (d) Hình ảnh hạt giống cuối cùng (các điểm được phóng to cho rõ ràng). (e) Giá trị tuyệt đối của chênh lệch giữa giá trị hạt giống (255) và (a). (f) Biểu đồ của (e). (g) Ngưỡng hình ảnh khác biệt sử dụng ngưỡng kép. (h) Hình ảnh khác biệt được ngưỡng với ngưỡng nhỏ nhất trong số các ngưỡng kép. (i) Kết quả phân khúc thu được theo vùng đang

phát triển.

Điều đầu tiên chúng ta làm là xác định điểm hạt giống. Từ tính chất vật lý của vấn đề, chúng tôi biết rằng các vết nứt và độ xốp sẽ làm suy giảm tia X ít hơn đáng kể so với các mối hàn snake, vì vậy chúng tôi hy vọng các vùng chứa các loại khuyết tật này sẽ sáng hơn đáng kể so với các phần khác của hình ảnh tia X. Chúng ta có thể trích xuất các điểm giống bằng cách đặt ngưỡng cho ảnh gốc, sử dụng ngưỡng được đặt ở phân vị cao. Hình 5.46(b) hiển thị biểu đồ của hình ảnh và Hình 5.46(c) hiển thị kết quả ngưỡng thu được với ngưỡng bằng 99,9 phân vị giá trị cường độ trong ảnh, trong trường hợp này là 254. Hình 5.46(d) cho thấy kết quả của sự xói mòn về mặt hình thái từng bộ phận được kết nối trong Hình 5.46(c) thành một điểm duy nhất.

Tiếp theo, chúng ta phải chỉ định một vị ngữ. Trong ví dụ này, chúng tôi quan tâm đến việc thêm vào mỗi hạt giống tất cả các điểm ảnh (a) được kết nối 8 lân cận với hạt giống đó và (b) “tương tự” với nó. Sử dụng chênh lệch cường độ tuyệt đối làm thước đo độ tương tự, vị từ của chúng tôi áp dụng tại mỗi vị trí (x, y) là:

$$Q = \begin{cases} TRUE & \text{nếu chênh lệch tuyệt đối về cường độ giữa hạt giống và pixel tại } (x, y) \leq T \\ FALSE & \text{nếu khác} \end{cases}$$

trong đó T là ngưỡng xác định. Mặc dù vị từ này dựa trên sự khác biệt về cường độ và sử dụng một ngưỡng duy nhất, nhưng chúng ta có thể chỉ định các sơ đồ phức tạp hơn trong đó một ngưỡng khác nhau được áp dụng cho từng điểm ảnh và sử dụng các thuộc tính khác ngoài sự khác biệt. Trong trường hợp này, vị từ trước đó là đủ để giải quyết vấn đề, như phần còn lại của ví dụ này cho thấy.

Từ phần trước, chúng ta biết rằng tất cả các giá trị hạt giống là 255 vì hình ảnh được đặt ngưỡng 254. Hình 5.46(e) cho thấy sự khác biệt giữa giá trị hạt giống (255) và Hình 5.46(a). Hình ảnh trong Hình 5.46(e) chứa tất cả những khác biệt cần thiết để tính toán vị từ tại mỗi vị trí (x, y) . Hình 5.46(f) hiển thị biểu đồ tương ứng. Chúng ta cần một ngưỡng để sử dụng trong vị ngữ để thiết lập sự tương đồng. Biểu đồ có ba chế độ chính, vì vậy chúng ta có thể bắt đầu bằng cách áp dụng cho ảnh khác biệt kỹ thuật ngưỡng kép được thảo luận trong Phần 10.3. Hai ngưỡng thu được trong trường hợp này là $T_1 = 68$ và $T_2 = 126$ chúng tôi thấy tương ứng chặt chẽ với các đáy của biểu đồ. (Như một sự lạc đề ngắn gọn, chúng tôi đã phân đoạn hình ảnh bằng hai ngưỡng này. Kết quả trong Hình 5.46(g) cho thấy rằng việc phân đoạn các khuyết tật không thể được thực hiện bằng cách sử dụng các ngưỡng kép, mặc dù thực tế là các ngưỡng nằm trong các thung lũng sâu của biểu đồ.)


Hình 5.46(h) hiển thị kết quả của việc phân ngưỡng hình ảnh khác biệt chỉ với T_1 . Điểm đen là các điểm ảnh mà vị từ là TRUE; những điểm khác sai trong vị ngữ. Kết quả quan trọng ở đây là các điểm ở các vùng tốt của điểm kết nối không đúng vị ngữ nên sẽ không được đưa vào kết quả cuối cùng. Các điểm ở khu vực bên ngoài sẽ được thuật toán phát triển khu vực coi là ứng cử viên. Tuy nhiên, Bước 3 sẽ loại bỏ các điểm bên ngoài vì chúng không được kết nối 8 lân cận với điểm hạt giống. Trên thực tế, như Hình 5.46(i) cho thấy, bước này dẫn đến việc phân đoạn chính xác, cho thấy rằng việc sử dụng kết nối là yêu cầu cơ bản trong trường hợp này. Cuối cùng, lưu ý rằng ở Bước 4, chúng tôi đã sử dụng cùng một giá trị cho tất cả các vùng được thuật toán tìm thấy. Trong trường hợp này, tốt nhất nên làm như vậy về mặt trực quan vì tất cả các vùng đó đều có cùng ý nghĩa vật lý trong ứng dụng này - tất cả chúng đều thể hiện độ xốp.

5.4.2. Thuật toán tách vùng và ghép vùng

Quy trình vừa thảo luận sẽ phát triển các vùng từ điểm hạt giống. Một cách khác là chia một hình ảnh ban đầu thành một tập hợp các vùng rời rạc, sau đó hợp nhất và/hoặc tách các vùng nhằm thỏa mãn các điều kiện phân đoạn. Những vấn đề cơ bản về tách và hợp nhất vùng sẽ

được thảo luận tiếp theo.

Đặt R đại diện cho toàn bộ vùng hình ảnh và chọn một vị từ Q . Một cách tiếp cận để phân đoạn R là chia nó liên tiếp thành các vùng góc phần tư nhỏ hơn và nhỏ hơn sao cho $R_i, Q(R_i) = TRUE$, đối với bất kỳ vùng nào. Chúng ta bắt đầu với toàn bộ vùng R . Nếu $Q(R) = FALSE$, chúng ta chia hình ảnh thành góc phần tư. Nếu Q là FALSE cho bất kỳ góc phần tư nào, chúng ta chia góc phần tư đó thành các góc phần tư phụ, v.v. Kỹ thuật phân chia này có một cách biểu diễn thuận tiện dưới dạng cái gọi là cây phần tư; nghĩa là, các cây trong đó mỗi nút có chính xác bốn cây con, như Hình 5.47 cho thấy (các hình ảnh tương ứng với các nút của cây tứ giác đôi khi được gọi là tứ giác hoặc tứ giác). Lưu ý rằng gốc của cây tương ứng với toàn bộ hình ảnh và mỗi nút tương ứng với việc phân chia một nút thành bốn nút con cháu. Trong trường hợp này, chỉ R_4 được chia nhỏ hơn nữa.



Hình 5.47 (a) Hình ảnh được phân vùng. (b) Cây tứ phân tương ứng. R đại diện cho toàn bộ vùng hình ảnh.

Nếu chỉ sử dụng tính năng chia tách thì phân vùng cuối cùng thường chứa các vùng liên kết có thuộc tính giống hệt nhau. Hạn chế này có thể được khắc phục bằng cách cho phép hợp nhất cũng như chia tách. Việc thỏa mãn các ràng buộc của phân đoạn được nêu trong Phần 5.1 yêu cầu chỉ hợp nhất các vùng liên kết có các điểm ảnh kết hợp thỏa mãn vị từ Q . Nghĩa là, hai vùng liên kết R_j và R_k chỉ được hợp nhất nếu $Q(R_j \cup R_k) = TRUE$.

Có thể được tóm tắt bằng quy trình sau, trong đó, tại bất kỳ bước nào, chúng ta thực hiện:


1. Chia thành bốn góc phần tư riêng biệt mà bất kỳ vùng R_i thỏa mãn $Q(R_i) = FALSE$.
2. Khi không thể phân tách thêm nữa, hãy hợp nhất bất kỳ vùng liên kết nào R_j và R_k sao cho $Q(R_j \cup R_k) = TRUE$.
3. Dừng khi không thể hợp nhất được nữa.

Có thể có nhiều biến thể của chủ đề cơ bản này. Ví dụ: sẽ có kết quả đơn giản hóa đáng kể nếu ở Bước 2, chúng tôi cho phép hợp nhất hai vùng liên kết bất kỳ R_j và R_k nếu mỗi vùng thỏa mãn vị từ riêng lẻ. Điều này dẫn đến một thuật toán đơn giản hơn nhiều (và nhanh hơn), bởi vì việc kiểm tra vị từ được giới hạn ở các vùng riêng lẻ. Như ví dụ sau đây cho thấy, việc đơn giản hóa này vẫn có khả năng mang lại kết quả phân đoạn tốt.

VÍ DỤ 5.21: Phân đoạn theo việc tách và hợp nhất vùng

Hình 5.48(a) hiển thị hình ảnh tia X của siêu tân tinh Cygnus Loop có kích thước 566×566 . Mục tiêu của ví dụ này là phân đoạn (trích xuất từ hình ảnh) “vòng” vật chất ít đậm đặc hơn bao quanh vùng đậm đặc bên trong. Vùng quan tâm có một số đặc điểm rõ ràng có thể giúp phân khúc nó. Đầu tiên, chúng tôi lưu ý rằng dữ liệu trong vùng này có tính chất ngẫu nhiên, cho thấy độ lệch chuẩn của nó phải lớn hơn độ lệch chuẩn của nền (gần 0) và của vùng trung tâm rộng lớn, trơn tru. Tương tự, giá trị trung bình (cường độ trung bình) của vùng chứa dữ liệu từ vòng ngoài phải lớn hơn giá trị trung bình của nền tối hơn và nhỏ hơn

giá trị trung bình của vùng trung tâm sáng hơn. Vì vậy, chúng ta có thể phân đoạn vùng quan tâm bằng cách sử dụng vị trí từ sau:



Hình 5.48 (a) Hình ảnh siêu tân tinh Cygnus Loop, được chụp trong dải tia X bởi Kính viễn vọng Hubble của NASA. (b) đến (d) Kết quả giới hạn vùng tứ giác nhỏ nhất được phép có kích thước tương ứng là điểm ảnh và điểm ảnh.

$$Q(R) = \begin{cases} TRUE & \text{nếu } \sigma_R > a \text{ và } 0 < m_R < b \\ FALSE & \text{nếu khác} \end{cases}$$

trong đó σ_R và m_R là độ lệch chuẩn và giá trị trung bình của vùng đang được xử lý và là các hằng số không âm.

Phân tích một số vùng ở vùng quan tâm bên ngoài cho thấy cường độ điểm ảnh trung bình ở các vùng đó không vượt quá 125 và độ lệch chuẩn luôn lớn hơn 10. Hình 5.48(b) đến (d) cho thấy kết quả thu được khi sử dụng những vùng này. các giá trị cho a và b, đồng thời thay đổi kích thước tối thiểu được phép cho các vùng từ 32 đến 8. Các điểm ảnh trong một vùng tứ giác thỏa mãn vị trí từ được đặt thành màu trắng; tất cả những thứ khác trong khu vực đó được đặt thành màu đen. Kết quả tốt nhất về việc nắm bắt hình dạng của vùng bên ngoài thu được bằng cách sử dụng các bốn vùng có kích thước 16×16 . Các hình vuông nhỏ màu đen trong Hình 5.48(d) là các vùng có kích thước bốn vùng mà các điểm ảnh không thỏa mãn vị trí. Việc sử dụng các vùng tứ giác nhỏ hơn sẽ làm tăng số lượng các vùng màu đen như vậy. Việc sử dụng các vùng lớn hơn vùng được minh họa ở đây sẽ tạo ra sự phân đoạn “giống khối” hơn. Lưu ý rằng trong mọi trường hợp, vùng được phân đoạn (điểm ảnh trắng) là vùng được kết nối giúp tách biệt hoàn toàn vùng bên trong, mịn hơn khỏi nền. Do đó, quá trình phân đoạn đã phân chia hình ảnh thành ba vùng riêng biệt một cách hiệu quả tương ứng với ba đặc điểm chính trong hình ảnh: nền, vùng dày đặc và vùng thưa thớt. Sử dụng bất kỳ vùng màu trắng nào trong Hình 5.48 làm mặt nạ sẽ làm cho việc trích xuất các vùng này từ ảnh gốc trở thành một nhiệm vụ tương đối đơn giản. Như trong Ví dụ 5.20, những kết quả này không thể đạt được bằng cách sử dụng phân đoạn dựa trên cạnh hoặc ngưỡng.

5.5. Phân đoạn vùng bằng cách sử dụng phân cụm và siêu điểm ảnh

Trong phần này, chúng tôi thảo luận về hai cách tiếp cận liên quan đến phân đoạn vùng. Đầu

tiên là cách tiếp cận cổ điển dựa trên việc tìm kiếm các cụm dữ liệu, liên quan đến các biến số như cường độ và màu sắc. Cách tiếp cận thứ hai hiện đại hơn đáng kể và dựa trên việc sử dụng phân cụm để trích xuất “các siêu điểm ảnh - superpixels” từ một hình ảnh.

5.5.1. Phân đoạn vùng sử dụng thuật toán phân cụm K-Means

Ý tưởng cơ bản đằng sau cách tiếp cận phân cụm được sử dụng trong chương này là phân chia một tập hợp Q các quan sát thành một số cụm cụ thể, k . Trong phân cụm k-mean, mỗi quan sát được gán cho cụm có giá trị trung bình gần nhất (do đó có tên của phương thức) và mỗi giá trị trung bình được gọi là nguyên mẫu của cụm đó. Thuật toán k-mean là một thủ tục lặp liên tục tinh chỉnh các phương tiện cho đến khi đạt được sự hội tụ.

Đặt $\{z_1, z_2, \dots, z_Q\}$ là tập hợp các vector quan sát (mẫu). Các vector này có dạng:

$$z = \begin{bmatrix} z_1 \\ z_2 \\ \dots \\ z_n \end{bmatrix} \quad (5-84)$$

Trong phân đoạn ảnh, mỗi thành phần của vector z đại diện cho một thuộc tính điểm ảnh bằng số. Ví dụ: nếu phân đoạn chỉ dựa trên cường độ thang độ xám thì $z = z$ đó là đại lượng vô hướng biểu thị cường độ của điểm ảnh. Nếu chúng ta đang phân đoạn các ảnh màu RGB, z thường là một vector 3-D, mỗi thành phần của nó là cường độ của một điểm ảnh ở một trong ba ảnh màu cơ bản, như chúng ta đã thảo luận trong Chương 7. Mục tiêu của phân cụm k-means là phân chia tập hợp Q của các quan sát thành tập hợp k ($k \leq Q$) cụm rời rạc $C = \{C_1, C_2, \dots, C_k\}$ sao cho thỏa mãn tiêu chí tối ưu sau:

$$\underset{C}{\operatorname{argmin}} \left(\sum_{i=1}^k \sum_{z \in C_i} \|z - m_i\|^2 \right) \quad (5-85)$$

trong đó m_i là vector trung bình (hoặc centroid) của các mẫu trong tập hợp C_i và $\|arg\|$ là chuẩn vector của đối số. Thông thường, định mức Euclide được sử dụng, vì vậy thuật ngữ $\|z - m_i\|$ này là khoảng cách Euclide quen thuộc từ một mẫu trong C_i tới giá trị trung bình m_i . Nói cách khác, phương trình này nói lên rằng chúng ta quan tâm đến việc tìm các tập hợp $C = \{C_1, C_2, \dots, C_k\}$ sao cho tổng khoảng cách từ mỗi điểm trong một tập hợp đến giá trị trung bình của tập hợp đó là tối thiểu.

Việc tìm ra mức tối thiểu này là một bài toán NP-khó mà không có giải pháp thực tế nào được biết đến. Kết quả là, một số phương pháp heuristic cố gắng tìm các giá trị gần đúng ở mức tối thiểu đã được đề xuất trong nhiều năm qua. Trong phần này, chúng ta thảo luận về những gì thường được coi là thuật toán k-means “tiêu chuẩn”, dựa trên khoảng cách Euclide. Cho một tập hợp vector quan sát $\{z_1, z_2, \dots, z_Q\}$ và giá trị k được chỉ định, thuật toán như sau:

1. Khởi tạo thuật toán: Chỉ định tập phương tiện ban đầu, $m_i(1), i = 1, 2, \dots, k$.

2. Gán mẫu vào cụm: Gán từng mẫu vào tập cụm có giá trị trung bình gần nhất (các mối liên hệ được giải quyết tùy ý, nhưng các mẫu chỉ được gán cho một cụm):

$$z_q \rightarrow C_i \text{ nếu } \|z_q - m_i\|^2 < \|z_q - m_j\|^2 \text{ với } j = 1, 2, \dots, k (j \neq i); q = 1, 2, \dots, Q$$

3. Cập nhật các trung tâm cụm (giá trị trung bình):

$$m_i = \frac{1}{|C_i|} \sum_{z \in C_i} z \text{ với } i = 1, 2, \dots, k$$

trong đó, $|C_i|$ là số lượng mẫu trong cụm C_i .


4. Kiểm tra mức độ hoàn thành: Tính toán định mức Euclide về sự khác biệt giữa các

vector trung bình ở bước hiện tại và bước trước đó. Tính sai số dư, E , là tổng của k chuẩn. Dừng nếu $E \leq T$, trong đó T là ngưỡng được chỉ định, không âm. Ngược lại, quay lại Bước 2.

Khi $T = 0$, thuật toán này được biết là hội tụ trong một số lần lặp hữu hạn đến mức tối thiểu cục bộ. Nó không được đảm bảo mang lại mức tối thiểu toàn cầu cần thiết để giảm thiểu phương trình (5-85). Kết quả tại thời điểm hội tụ phụ thuộc vào các giá trị ban đầu được chọn cho Một cách tiếp cận được sử dụng thường xuyên trong phân tích dữ liệu là chỉ định giá trị trung bình ban đầu là k mẫu được chọn ngẫu nhiên từ tập mẫu đã cho và chạy thuật toán nhiều lần với một tập hợp ngẫu nhiên mới. mẫu ban đầu mỗi lần. Điều này nhằm kiểm tra “sự ổn định” của giải pháp. Trong phân đoạn hình ảnh, vấn đề quan trọng là giá trị được chọn cho k vì giá trị này xác định số vùng được phân đoạn.

VÍ DỤ 5.22 Sử dụng phân cụm k-mean để phân đoạn

Hình 5.49(a) hiển thị một hình ảnh có kích thước 688×688 điểm ảnh và Hình 5.49(b) là phân đoạn thu được bằng thuật toán k-means với $k = 3$. Như bạn có thể thấy, thuật toán có thể trích xuất tất cả các vùng có ý nghĩa của hình ảnh này với độ phân giải cao, sự chính xác. Ví dụ: so sánh chất lượng của các ký tự trong cả hai hình ảnh. Điều quan trọng là phải nhận ra rằng toàn bộ phân đoạn được thực hiện bằng cách phân cụm một biến duy nhất (cường độ). Bởi vì k-mean hoạt động với các quan sát vector nói chung, nên khả năng phân biệt giữa các vùng của nó tăng lên khi số lượng thành phần của vector z trong biểu thức (5-84) tăng lên.




Hình 5.49 (a) Hình ảnh có kích thước 688×688 điểm ảnh. (b) Hình ảnh được phân đoạn bằng thuật toán k-mean với $k = 3$.

5.5.2. Phân đoạn vùng bằng siêu điểm ảnh - superpixels

Ý tưởng đằng sau siêu điểm ảnh là thay thế lưới điểm ảnh tiêu chuẩn bằng cách nhóm các điểm ảnh thành các vùng nguyên thủy có ý nghĩa hơn về mặt cảm nhận so với các điểm ảnh riêng lẻ. Mục tiêu là giảm tải tính toán và cải thiện hiệu suất của các thuật toán phân đoạn bằng cách giảm các chi tiết không liên quan. Một ví dụ đơn giản sẽ giúp giải thích cách tiếp cận cơ bản của biểu diễn siêu điểm ảnh.

Hình 5.50(a) hiển thị một hình ảnh có kích thước 600×800 (480.000) điểm ảnh chứa nhiều mức độ chi tiết khác nhau có thể được mô tả bằng lời nói như sau: “Đây là hình ảnh của hai hình chạm khắc lớn ở tiền cảnh và ít nhất ba hình chạm khắc nhỏ hơn nhiều nghỉ ngơi trên hàng rào phía sau những nhân vật lớn. Các nhân vật này đang ở trên một bãi biển, với hậu cảnh là đại dương và bầu trời.” Hình 5.50(b) hiển thị cùng một hình ảnh được biểu thị bằng 4.000 siêu điểm ảnh và các ranh giới của chúng (các ranh giới được hiển thị để tham khảo—chúng không phải là một phần của dữ liệu) và Hình 5.50(c) hiển thị hình ảnh siêu điểm ảnh. Người ta có thể lập luận rằng mức độ chi tiết trong hình ảnh siêu điểm ảnh sẽ dẫn đến mô tả giống như bản gốc, nhưng bản gốc chỉ chứa 4.000 đơn vị nguyên thủy, trái ngược với

480.000 đơn vị trong bản gốc. Việc biểu diễn siêu điểm ảnh có “đầy đủ” hay không còn tùy thuộc vào ứng dụng. Nếu mục tiêu là mô tả hình ảnh ở mức độ chi tiết nêu trên thì câu trả lời là có. Mặt khác, nếu mục tiêu là phát hiện những điểm không hoàn hảo ở độ phân giải cấp điểm ảnh thì câu trả lời rõ ràng là không. Và có những ứng dụng, chẳng hạn như chẩn đoán y tế trên máy tính, trong đó những biểu diễn gần đúng dưới bất kỳ hình thức nào đều không được chấp nhận. Tuy nhiên, nhiều lĩnh vực ứng dụng, chẳng hạn như truy vấn cơ sở dữ liệu hình ảnh, điều hướng tự động và một số nhánh robot nhất định, trong đó tính kinh tế của việc triển khai và những cải tiến tiềm năng về hiệu suất phân đoạn sẽ vượt xa mọi sự mất chi tiết hình ảnh đáng kể.



Hình 5.50 (a) Hình ảnh có kích thước 600×800 (480.000) điểm ảnh. (b) Hình ảnh bao gồm 4.000 siêu điểm ảnh (ranh giới giữa các siêu điểm ảnh (màu trắng) được đặt chồng lên hình ảnh siêu điểm ảnh để tham khảo—các ranh giới không phải là một phần của dữ liệu). (c) Ảnh siêu điểm ảnh.

Một yêu cầu quan trọng của bất kỳ cách biểu diễn siêu điểm ảnh nào là tuân thủ các ranh giới. Điều này có nghĩa là ranh giới giữa các vùng quan tâm phải được giữ nguyên trong ảnh siêu điểm ảnh. Chúng ta có thể thấy rằng đây thực sự là trường hợp của hình ảnh trong Hình 5.50(c). Ví dụ, hãy lưu ý ranh giới giữa các hình và nền rõ ràng đến mức nào. Điều tương tự cũng đúng với ranh giới giữa bãi biển và đại dương, giữa đại dương và bầu trời. Các đặc điểm quan trọng khác là việc bảo toàn các đặc tính tô pô và tất nhiên là hiệu quả tính toán. Thuật toán siêu điểm ảnh được thảo luận trong phần này đáp ứng các yêu cầu này.


Có thể giảm sự khác biệt giữa hình ảnh siêu điểm ảnh và hình ảnh gốc của nó mà vẫn đạt được mức tiết kiệm đáng kể về thời gian lưu trữ và tính toán. Ví dụ: Hình 5.51(a) hiển thị cùng một hình ảnh như trước và Hình 5.51(b) là hình ảnh siêu điểm ảnh được tạo bằng 40.000 siêu điểm ảnh. Những hình ảnh này thực tế giống hệt nhau về mặt chi tiết hình ảnh, ngoại trừ một chút khác biệt về độ tương phản, gây ra bởi cường độ trung bình trong mỗi vùng siêu điểm ảnh (chúng ta sẽ thảo luận vấn đề này chi tiết hơn ở phần sau). Hình ảnh khác biệt trong Hình 5.51(c) biểu thị sự khác biệt tổng thể về độ tương phản và một số khác biệt nhỏ ở các khu vực xung quanh các cạnh sắc nét. Nhưng hãy nhớ rằng, hình ảnh siêu điểm ảnh có ít phân tử hơn so với ảnh gốc và nếu cần, sự khác biệt về độ tương phản có thể dễ dàng được khắc phục bằng cách xử lý biểu đồ.



Hình 5.51 (a) Ảnh gốc. (b) Hình ảnh bao gồm 40.000 siêu điểm ảnh. (c) Sự khác biệt giữa

(a) và (b).

Như một minh họa cuối cùng, chúng tôi trình bày kết quả của việc giảm nghiêm trọng số lượng siêu điểm ảnh xuống còn 1.000, 500 và 250. Kết quả trong Hình 5.52 cho thấy sự mất chi tiết đáng kể so với Hình 5.50(a), nhưng hai kết quả đầu tiên hình ảnh chứa hầu hết các chi tiết liên quan đến mô tả hình ảnh đã thảo luận trước đó. Một điểm khác biệt đáng chú ý là hai trong số ba hình chạm khắc nhỏ trên hàng rào phía sau đã bị loại bỏ. Hình ảnh siêu điểm ảnh 250 phần tử thậm chí còn mất đi phần thứ ba. Tuy nhiên, ranh giới giữa các vùng chính cũng như cấu trúc liên kết cơ bản của hình ảnh vẫn được giữ nguyên.



Hình 5.52 Hàng trên cùng: Kết quả sử dụng 1.000, 500 và 250 siêu điểm ảnh trong biểu diễn của Hình 5.50(a). Như trước đây, ranh giới giữa các siêu điểm ảnh được đặt chồng lên hình ảnh để tham khảo. Hàng dưới cùng: Hình ảnh siêu điểm ảnh.

Thuật toán siêu điểm ảnh SLIC – Simple Linear Iterative Clustering

Trong phần này chúng ta thảo luận về một thuật toán tạo siêu điểm ảnh, được gọi là phân cụm lặp tuyến tính đơn giản (SLIC). Thuật toán tương đối đơn giản về mặt khái niệm và có các lợi thế về tính toán cũng như hiệu suất khác so với các kỹ thuật siêu điểm ảnh khác. SLIC là một sửa đổi của thuật toán k-means đã thảo luận ở phần trước. Các quan sát SLIC thường sử dụng (nhưng không giới hạn) vector 5 chiều chứa ba thành phần màu và hai tọa độ không gian. Ví dụ: nếu chúng ta đang sử dụng hệ màu RGB, vector 5 chiều được liên kết với điểm ảnh hình ảnh có dạng:

$$z = \begin{bmatrix} r \\ g \\ b \\ x \\ y \end{bmatrix}$$

(5-86)

trong đó, (r, g, b) là ba thành phần màu của một điểm ảnh và (x, y) là hai tọa độ không gian của nó. Đặt n_{sp} biểu thị số siêu điểm ảnh mong muốn và n_{tp} biểu thị tổng số điểm ảnh trong ảnh. Các tâm siêu điểm ảnh ban đầu $m_i = [r_i \ g_i \ b_i \ x_i \ y_i]^T, i = 1, 2, \dots, n_{sp}$ có được bằng cách lấy mẫu hình ảnh trên một lưới thông thường cách nhau s đơn vị. Để tạo ra các siêu điểm ảnh có kích thước gần bằng nhau (tức là diện tích), khoảng cách lưới được chọn là $s = [n_{tp}/n_{sp}]^{1/2}$. Để ngăn việc căn giữa siêu điểm ảnh ở rìa của hình ảnh và để giảm khả năng bắt đầu tại một điểm nhiễu, các trung tâm cụm ban đầu sẽ được di chuyển đến vị trí có độ dốc thấp nhất trong vùng lân cận 3×3 quanh mỗi tâm.

Thuật toán siêu điểm ảnh SLIC bao gồm các bước sau. Hãy nhớ rằng siêu điểm ảnh nói

chung là vectơ. Khi chúng ta đề cập đến một “điểm ảnh” trong thuật toán, chúng ta đang đề cập đến vị trí (x, y) của siêu điểm ảnh so với hình ảnh.

Khởi tạo thuật toán: Tính toán tâm cụm siêu điểm ảnh ban đầu,

$$m_i = [r_i \ g_i \ b_i \ x_i \ y_i]^T, i = 1, 2, \dots, n_{sp}$$

bằng cách lấy mẫu hình ảnh ở các bước lưới thông thường, s. Di chuyển tâm cụm đến vị trí có độ dốc thấp nhất trong vùng lân cận 3×3 . Đối với mỗi vị trí điểm ảnh, p, trong ảnh, đặt nhãn $L(p) = -1$ và khoảng cách $d(p) = \infty$.

2. Gán mẫu cho tâm cụm: Với mỗi tâm cụm $m_i, i = 1, 2, \dots, n_{sp}$, tính khoảng cách $D_i(p)$, giữa m_i và mỗi điểm ảnh p trong một vùng lân cận $2s \times 2s$ về m_i . Sau đó, với mỗi p và $i = 1, 2, \dots, n_{sp}$, nếu $D_i < d(p)$, đặt $d(p) = D_i$ và $L(p) = i$.

3. Cập nhật tâm cụm: Đặt C_i biểu thị tập hợp điểm ảnh trong ảnh với nhãn $L(p) = i$. Cập nhật m_i :

$$m_i = \frac{1}{|C_i|} \sum_{z \in C_i} z \text{ với } i = 1, 2, \dots, n_{sp}$$

trong đó, $|C_i|$ là số lượng điểm ảnh trong tập C_i và z được cho bởi biểu thức (10-86).

5. Kiểm tra độ hội tụ: Tính toán định mức Euclide về sự khác biệt giữa các vectơ trung bình ở bước hiện tại và bước trước đó. Tính sai số dư, E, là tổng của các định mức. Nếu $E < T$ trong đó T là ngưỡng không âm được chỉ định, hãy chuyển sang Bước 5. Nếu không, quay lại Bước 2.

6. Xử lý hậu kỳ các vùng siêu điểm ảnh: Thay thế tất cả các siêu điểm ảnh trong từng vùng C_i bằng giá trị trung bình của chúng m_i .

Lưu ý ở Bước 5 rằng siêu điểm ảnh cuối cùng là các vùng liên kết có giá trị không đổi. Giá trị trung bình không phải là cách duy nhất để tính hằng số này nhưng nó được sử dụng rộng rãi nhất. Đối với hình ảnh mức xám, giá trị trung bình chỉ là cường độ trung bình của tất cả các điểm ảnh trong vùng được bao trùm bởi siêu điểm ảnh. Thuật toán này tương tự như thuật toán k-mean trong phần trước, ngoại trừ khoảng cách không được chỉ định là khoảng cách Euclide (xem bên dưới) và các khoảng cách này được tính cho các vùng có kích thước $2s \times 2s$ thay vì cho tất cả các điểm ảnh trong hình ảnh, do đó làm giảm đáng kể thời gian tính toán. Trong thực tế, sự hội tụ SLIC đối với E có thể đạt được với các giá trị T khá lớn chẳng hạn $T = 10$ trong một số nghiên cứu.

Xác định hàm đo khoảng cách

Các siêu điểm ảnh SLIC tương ứng với các cụm trong không gian có tọa độ là màu sắc và các biến không gian. Sẽ là vô nghĩa nếu sử dụng một khoảng cách Euclide trong trường hợp này, vì tỷ lệ trong các trục của hệ tọa độ này là khác nhau và không liên quan. Nói cách khác, khoảng cách không gian và màu sắc phải được xử lý riêng biệt. Điều này được thực hiện bằng cách chuẩn hóa khoảng cách của các thành phần khác nhau, sau đó kết hợp chúng thành một thước đo duy nhất. Đặt d_c và d_s biểu thị màu sắc và khoảng cách Euclide không gian giữa hai điểm trong một cụm tương ứng:

$$d_c = [(r_j - r_i)^2 + (g_j - g_i)^2 + (b_j - b_i)^2]^{1/2} \quad (5-87)$$

và

$$d_s = [(x_j - x_i)^2 + (y_j - y_i)^2]^{1/2}$$

(5-88)

Sau đó chúng tôi định nghĩa D là khoảng cách tổng hợp:

$$D = \left[\left(\frac{d_c}{d_{cm}} \right)^2 + \left(\frac{d_s}{d_{sm}} \right)^2 \right]^{1/2} \quad (5-89)$$

trong đó d_{cm} và d_{sm} là các giá trị mong đợi tối đa của d_c và d_m . Khoảng cách không gian tối đa phải tương ứng với khoảng thời gian lấy mẫu; nghĩa là, $d_{sm} = s = [n_{tp}/n_{sp}]^{1/2}$. Việc xác định khoảng cách màu tối đa không đơn giản vì những khoảng cách này có thể khác nhau đáng kể giữa các cụm và từ hình ảnh này sang hình ảnh khác. Một giải pháp là đặt d_{cm} thành hằng số c sao cho phương trình (5-89) trở thành:

$$D = \left[\left(\frac{d_c}{c} \right)^2 + \left(\frac{d_s}{s} \right)^2 \right]^{1/2} \quad (5-90)$$

Chúng ta có thể viết phương trình này dưới dạng:

$$D = \left[d_c^2 + \left(\frac{d_s}{s} \right)^2 \right]^{1/2} \quad (5-91)$$

Đây là hàm khoảng cách được sử dụng cho từng cụm trong thuật toán. Hằng số c có thể được sử dụng để cân nhắc tầm quan trọng tương đối giữa độ tương tự màu sắc và khoảng cách không gian. Khi c lớn, khoảng cách về mặt không gian quan trọng hơn và các siêu điểm ảnh thu được sẽ nhỏ gọn hơn. Khi c nhỏ, các siêu điểm ảnh thu được sẽ bám chặt hơn vào ranh giới hình ảnh nhưng có kích thước và hình dạng kém đều đặn hơn.

Đối với ảnh mức xám, như trong Ví dụ 5.23 bên dưới, chúng ta sử dụng:

$$d_c = [(l_j - l_i)^2]^{1/2} \quad (5-92)$$

trong phương trình (5-91), trong đó l là mức cường độ của các điểm mà khoảng cách đang được tính toán.

Trong 3-D, siêu điểm ảnh trở thành *supervoxel*, được xử lý bằng cách xác định:

$$d_s = [(x_j - x_i)^2 + (y_j - y_i)^2 + (z_j - z_i)^2]^{1/2}$$


trong đó z là tọa độ của chiều không gian thứ ba. Chúng ta cũng phải thêm biến không gian thứ ba z , vào vector trong biểu thức (5-86).

Do không có điều khoản nào được đưa ra trong thuật toán để thực thi kết nối nên các điểm ảnh bị cô lập có thể vẫn tồn tại sau khi hội tụ. Chúng được gán nhãn của cụm gần nhất bằng thuật toán các thành phần được kết nối. Mặc dù chúng ta đã giải thích thuật toán trong bối cảnh các thành phần màu RGB, phương pháp này cũng có thể áp dụng được cho các hệ màu khác. Trong thực tế, các thành phần khác của vector z trong biểu thức (5-86) (ngoại trừ các biến không gian) có thể là các giá trị đặc trưng có giá trị thực khác, miễn là có thể xác định được thước đo khoảng cách có ý nghĩa cho chúng.

VÍ DỤ 5.23 Sử dụng siêu điểm ảnh để phân đoạn ảnh


Hình 5.53(a) hiển thị hình ảnh của một tảng băng trôi và Hình 5.53(b) hiển thị kết quả phân đoạn hình ảnh này bằng thuật toán k-means được phát triển ở phần trước, với $k = 3$. Mặc

dù các vùng chính của hình ảnh đã được phân đoạn nhưng vẫn có rất nhiều lỗi phân đoạn ở cả hai khu vực của tầng băng trôi cũng như ở ranh giới ngăn cách nó với nền. Lỗi hiển thị dưới dạng các điểm ảnh riêng biệt (và cũng như các nhóm điểm ảnh nhỏ) có sắc thái sai (ví dụ: các điểm ảnh đen trong vùng trắng). Hình 5.53(c) hiển thị biểu diễn 100 siêu điểm ảnh của hình ảnh với các ranh giới siêu điểm ảnh được xếp chồng lên nhau để tham khảo và Hình 5.53(d) hiển thị cùng một hình ảnh không có ranh giới. Hình 5.53(e) là phân đoạn của (d) sử dụng thuật toán k-mean với $k = 3$ như trước. Lưu ý sự cải thiện đáng kể so với kết quả trong (b), cho thấy rằng hình ảnh gốc có nhiều chi tiết (không liên quan) hơn mức cần thiết để phân đoạn thích hợp. Về mặt lợi thế tính toán, hãy xem xét rằng việc tạo Hình 5.53(b) yêu cầu xử lý riêng lẻ trên 300K điểm ảnh, trong khi (e) yêu cầu xử lý 100 điểm ảnh với ít sắc thái xám hơn đáng kể.



Hình 5.53 (a) Ảnh có kích thước 533×566 (301.678) điểm ảnh. (b) Hình ảnh được phân đoạn bằng thuật toán k-means. (c) Hình ảnh siêu điểm ảnh 100 phần tử hiển thị các ranh giới để tham khảo. (d) Cùng một hình ảnh không có ranh giới. (e) Hình ảnh siêu điểm ảnh (d) được phân đoạn bằng thuật toán k-means.

Hình 5.54(a) giống với Hình 5.49(a) và Hình 5.54(b) là hình ảnh siêu điểm ảnh 95K (khoảng 20% số điểm ảnh trong ảnh gốc). Hình ảnh gốc và hình ảnh siêu điểm ảnh khá gần nhau về mặt trực quan. Mặc dù số lượng siêu điểm ảnh nhỏ hơn đáng kể so với số lượng điểm ảnh trong bản gốc nhưng về cơ bản chúng có cùng nội dung. Ví dụ: Hình 5.54(c) là kết quả của việc phân đoạn Hình 5.54(b) bằng cách sử dụng cùng một phương pháp k-mean mà chúng ta đã sử dụng để tạo Hình 5.49(b), đây là một phân đoạn của ảnh gốc. Bạn có thể thấy bằng cách so sánh các Hình 5.54(c) và 5.42(b) cho thấy kết quả sử dụng siêu điểm ảnh là tốt hơn. Một phần thường bỏ sung là khối lượng tính toán của việc phân đoạn hình ảnh siêu điểm ảnh ít hơn đáng kể.



Hình 5.54 (a) Hình ảnh có kích thước 688×688 (473.344) điểm ảnh. (b) Hình ảnh siêu điểm ảnh 95000 phần tử. (c) Phân đoạn ảnh siêu điểm ảnh bằng thuật toán k-mean với $k = 3$.

5.6. Phân đoạn vùng bằng cách cắt đồ thị

Trong phần này, chúng ta thảo luận về cách tiếp cận phân vùng hình ảnh thành các vùng bằng cách biểu thị các điểm ảnh của hình ảnh dưới dạng các nút của đồ thị và sau đó tìm phân vùng (cắt) tối ưu của đồ thị thành các nhóm nút. Tính tối ưu dựa trên các tiêu chí có giá trị cao đối với các thành viên trong một nhóm (tức là một khu vực) và thấp đối với các thành viên thuộc các nhóm khác nhau. Như bạn sẽ thấy ở phần sau của phần này, trong một số trường hợp, phân đoạn cắt đồ thị có khả năng mang lại kết quả vượt trội so với kết quả có thể đạt được bằng bất kỳ phương pháp phân đoạn nào được nghiên cứu cho đến nay. Cái giá của lợi ích tiềm năng này là sự phức tạp gia tăng trong quá trình cài đặt, điều này thường dẫn đến tốc độ tính toán chậm.

5.6.1. Biểu diễn hình ảnh dưới dạng đồ thị

Đồ thị G , là một cấu trúc toán học bao gồm tập V gồm các nút và tập E gồm các cạnh nối các đỉnh đó:

Các nút và các cạnh cũng được gọi tương ứng là các đỉnh và các liên kết.

$$G = (V, E) \quad (5-94)$$

trong đó V là một tập hợp và

$$E \subseteq V \times V \quad (5-95)$$

là một tập hợp các cặp phần tử có thứ tự từ V . Nếu $(u, v) \in E$ suy ra rằng $(v, u) \in E$ và ngược lại, đồ thị được cho là đồ thị vô hướng; nếu không thì đồ thị có hướng. Ví dụ: chúng ta có thể coi bản đồ đường phố là một đồ thị trong đó các nút là giao lộ và các cạnh là các đường nối các giao lộ đó. Nếu tất cả các đường đều là hai chiều thì đồ thị là vô hướng (có nghĩa là chúng ta có thể đi cả hai chiều từ hai nút giao bất kỳ). Ngược lại, nếu có ít nhất một đường là đường một chiều thì đồ thị có hướng.

Các loại đồ thị mà chúng ta quan tâm là đồ thị vô hướng có các cạnh được đặc trưng hơn nữa bởi một ma trận W , có phần tử $w(i, j)$ là trọng số gắn với cạnh nối các nút i và j . Vì đồ thị vô hướng nên $w(i, j) = w(j, i)$, nghĩa là W là ma trận đối xứng. Các trọng số được chọn tỷ lệ thuận với một hoặc nhiều thước đo độ tương tự giữa tất cả các cặp nút. Đồ thị có các cạnh gắn với trọng số được gọi là đồ thị có trọng số.

Bản chất của tài liệu trong phần này là biểu diễn một hình ảnh được phân đoạn dưới dạng đồ thị có trọng số, vô hướng, trong đó các nút của đồ thị là các điểm ảnh trong ảnh và một cạnh được hình thành giữa mỗi cặp nút. Trọng số $w(i, j)$ của mỗi cạnh là hàm của độ tương tự

giữa các nút i và j . Sau đó, chúng tôi tìm cách phân chia các nút của đồ thị thành các tập con rời rạc $V_1, V_2, \dots, V_K$, trong đó, theo một số thước đo, độ tương tự giữa các nút trong một tập hợp con là cao và độ tương tự giữa các nút của các tập hợp con khác nhau là thấp. Các nút của tập hợp con được phân vùng tương ứng với các vùng trong ảnh được phân đoạn.


Siêu điểm ảnh cũng rất phù hợp để sử dụng làm nút đồ thị. Do đó, khi chúng tôi đề cập đến “điểm ảnh” trong một hình ảnh trong phần này, thì theo ngụ ý, chúng tôi cũng đề cập đến siêu điểm ảnh.

Tập V được chia thành các tập con bằng cách cắt đồ thị. Việc cắt đồ thị là phép chia đồ thị V thành hai tập con A và B sao cho:

$$A \cup B = V \text{ và } A \cap B = \emptyset \quad (5-96)$$

trong đó việc cắt được thực hiện bằng cách loại bỏ các cạnh nối các đồ thị con A và B . Có hai khía cạnh chính của việc sử dụng các đường cắt đồ thị để phân đoạn hình ảnh: (1) cách liên kết đồ thị với một hình ảnh; và (2) cách cắt đồ thị theo cách hợp lý về mặt phân vùng hình ảnh thành các điểm ảnh nền và nền trước (đối tượng). Tiếp theo chúng ta sẽ giải quyết hai câu hỏi này


Hình 5.55 cho thấy một cách tiếp cận đơn giản để tạo đồ thị từ một hình ảnh. Các nút của đồ thị tương ứng với các điểm ảnh trong ảnh và để giải thích đơn giản, chúng tôi chỉ cho phép các cạnh giữa các điểm ảnh liên kề sử dụng kết nối 4 lân cận, nghĩa là không có cạnh chéo nào liên kết các điểm ảnh. Tuy nhiên, hãy nhớ rằng, nói chung, các cạnh được chỉ định giữa mỗi cặp điểm ảnh. Trọng số cho các cạnh thường được hình thành từ các mối quan hệ không gian (ví dụ: khoảng cách từ điểm ảnh đỉnh) và thước đo cường độ (ví dụ: kết cấu và màu sắc), phù hợp với việc thể hiện sự tương đồng giữa các điểm ảnh. Trong ví dụ đơn giản này, chúng tôi xác định mức độ tương tự giữa hai điểm ảnh là nghịch đảo của sự khác biệt về cường độ của chúng. Nghĩa là, đối với hai nút (điểm ảnh) n_i và n_j , trọng số của cạnh giữa chúng là $w(i, j) = 1/(|I(n_i) - I(n_j)| + c)$, trong đó $I(n_i)$ và $I(n_j)$, là cường độ của hai nút (điểm ảnh) và c là hằng số được đưa vào để ngăn việc chia cho 0. Do đó, giá trị cường độ giữa các điểm ảnh liên kề càng gần thì giá trị của w sẽ càng lớn.



Hình 5.55 (a) Một ảnh 3×3 . (c) Một đồ thị tương ứng. (d) Cắt đồ thị. (e) Hình ảnh được phân đoạn.

Với mục đích minh họa, độ dày của mỗi cạnh trong Hình 5.55 được hiển thị tỷ lệ thuận với mức độ tương tự giữa các điểm ảnh mà nó kết nối. Như bạn có thể thấy trong hình, các cạnh giữa các điểm ảnh tối mạnh hơn các cạnh giữa các điểm ảnh tối và sáng và ngược lại. Về mặt khái niệm, việc phân đoạn đạt được bằng cách cắt đồ thị dọc theo các cạnh yếu của nó, như được minh họa bằng đường đứt nét trong Hình 5.55(d). Hình 5.55(c) hiển thị hình ảnh được phân đoạn.

Mặc dù cấu trúc cơ bản trong Hình 5.55 là trọng tâm thảo luận trong phần này, chúng tôi đề cập đến một cách tiếp cận phổ biến khác để xây dựng đồ thị hình ảnh cho đầy đủ. Hình 5.56 hiển thị cùng một đồ thị như đồ thị chúng ta vừa thảo luận, nhưng ở đây bạn thấy hai nút bổ sung được gọi là nút đầu cuối nguồn và đích, mỗi nút được kết nối với tất cả các nút trong đồ thị thông qua các liên kết một chiều được gọi là liên kết t . Các nút đầu cuối không phải là một phần của hình ảnh; chẳng hạn, vai trò của chúng là liên kết với mỗi điểm ảnh một xác suất rằng đó là điểm ảnh nền hoặc điểm ảnh nền trước (đối tượng). Xác suất là trọng số của các liên kết t . Trong Hình 5.56(c) và (d), độ dày của mỗi liên kết t tỷ lệ thuận với giá trị xác suất mà nút đồ thị mà nó được kết nối là điểm ảnh nền trước hoặc điểm ảnh nền (độ dày được hiển thị sao cho kết quả phân đoạn sẽ giống như trong Hình 5.55). Nút nào trong hai nút mà chúng ta gọi là nền hoặc nền trước là tùy ý.



Hình 5.56 (a) Hình ảnh tương tự như trong Hình 10.55(a). (c) Đồ thị tương ứng và các nút đầu cuối. (d) Cắt đồ thị. (b) Hình ảnh được phân đoạn.

5.6.2. Cắt đồ thị tối thiểu


Khi một hình ảnh đã được thể hiện dưới dạng đồ thị, bước tiếp theo là cắt đồ thị thành hai hoặc nhiều đồ thị con. Các nút (điểm ảnh) trong mỗi đồ thị con kết quả tương ứng với một vùng trong hình ảnh được phân đoạn. Các phương pháp tiếp cận dựa trên Hình 5.56 dựa vào việc diễn giải đồ thị dưới dạng mạng dòng chảy (ví dụ như các đường ống) và thu được cái thường được gọi là đường cắt đồ thị tối thiểu. Công thức này dựa trên cái gọi là Định lý Max-Flow, Min-Cut. Định lý này phát biểu rằng, trong mạng luồng, lượng luồng tối đa đi từ

nguồn đến đích bằng với mức cắt tối thiểu. Mức cắt tối thiểu này được định nghĩa là tổng trọng lượng nhỏ nhất của các cạnh mà nếu bị loại bỏ sẽ ngắt kết nối khỏi nguồn:

$$cut(A, B) = \sum_{u \in A, v \in B} w(u, v) \quad (5-97)$$

trong đó A và B thỏa mãn phương trình (5-96). Phân vùng tối ưu của đồ thị là phân vùng giảm thiểu giá trị cắt này. Có một số lượng cấp số nhân của các phân vùng như vậy, điều này sẽ đặt ra cho chúng ta một vấn đề tính toán khó giải quyết. Tuy nhiên, các thuật toán hiệu quả chạy trong thời gian đa thức đã được phát triển để giải các bài toán luồng cực đại. Do đó, dựa trên Định lý Max-Flow, Min-Cut, chúng ta có thể áp dụng các thuật toán này để phân đoạn hình ảnh, với điều kiện là chúng ta coi phân đoạn là một vấn đề về luồng và chọn trọng số cho các cạnh và các liên kết sao cho sẽ dẫn đến việc cắt đồ thị tối thiểu trong các phân đoạn có ý nghĩa.

Mặc dù phương pháp cắt tối thiểu mang lại một giải pháp tính toán nhưng nó có thể dẫn đến việc nhóm thiên về việc cắt các tập hợp nhỏ các nút bị cô lập trong đồ thị, dẫn đến phân đoạn không chính xác. Hình 5.57 cho thấy một ví dụ, trong đó hai vùng quan tâm được đặc trưng bởi độ chặt chẽ của các nhóm điểm ảnh. Các trọng số cạnh có ý nghĩa phản ánh thuộc tính này sẽ tỷ lệ nghịch với khoảng cách giữa các cặp điểm. Nhưng điều này sẽ dẫn đến các trọng số sẽ nhỏ hơn đối với các điểm cô lập, dẫn đến việc cắt giảm tối thiểu như ví dụ trong Hình 5.57. Trong thực tế, bất kỳ vết cắt nào phân chia các điểm riêng lẻ ở bên trái của hình sẽ có giá trị vết cắt nhỏ hơn trong biểu thức (5-4) so với cách cắt phân chia chính xác các điểm thành hai nhóm dựa trên khoảng cách gần nhau của chúng, chẳng hạn như phân vùng được hiển thị trong Hình 5.57.



Hình 5.57 Một ví dụ cho thấy việc cắt tối thiểu có thể dẫn đến việc phân đoạn vô nghĩa như thế nào. Trong ví dụ này, sự giống nhau giữa các điểm ảnh được xác định là khoảng cách không gian của chúng, dẫn đến hai vùng riêng biệt.

Thay vì nhìn vào tổng giá trị trọng lượng của các cạnh kết nối hai phân vùng, ý tưởng là sử dụng thước đo “phân ly” để tính chi phí dưới dạng một phần của tổng số kết nối cạnh tới tất cả các nút trong đồ thị. Biện pháp này, được gọi là cắt không chuẩn hóa (Ncut), được định nghĩa là:

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)} \quad (5-98)$$

trong đó $cut(A, B)$ được cho bởi phương trình (5-97) và:

$$assoc(A, V) = \sum_{u \in A, z \in V} w(u, z)$$

(5-99)

là tổng trọng số của tất cả các cạnh từ các nút của đồ thị con A đến các nút của toàn bộ đồ thị. Tương tự,

$$assoc(B, V) = \sum_{v \in B, z \in V} w(v, z) \quad (5-100)$$

là tổng trọng số của các cạnh từ tất cả các cạnh trong B đến toàn bộ đồ thị. Như bạn có thể thấy, $assoc(A, V)$ chỉ đơn giản là phần cắt của A khỏi phần còn lại của đồ thị và tương tự đối với $assoc(B, V)$.

Bằng cách sử dụng $Ncut(A, B)$ thay vì $cut(A, B)$, phép cắt phân vùng các điểm cô lập sẽ không còn giá trị nhỏ. Ví dụ, bạn có thể thấy điều này bằng cách lưu ý trong Hình 5.57 rằng nếu A là nút đơn được hiển thị, $cut(A, B)$ và $assoc(A, V)$ sẽ có cùng giá trị. Do đó, độc lập với mức độ nhỏ $cut(A, B)$, $Ncut(A, B)$ sẽ luôn lớn hơn hoặc bằng 1, do đó cung cấp sự chuẩn hóa như sau:

Dựa trên các khái niệm tương tự, chúng ta có thể xác định thước đo cho tổng liên kết chuẩn hóa trong các phân vùng đồ thị là:

$$Nassoc(A, B) = \frac{assoc(A, A)}{assoc(A, V)} + \frac{assoc(B, B)}{assoc(B, V)} \quad (5-101)$$

trong đó $assoc(A, A)$ và $assoc(B, B)$ lần lượt là tổng trọng số kết nối các nút trong A và trong B. Không khó để chỉ ra (xem Bài toán 10.48) rằng:

$$Ncut(A, B) = 2 - Nassoc(A, B) \quad (5-102)$$

ngụ ý rằng việc giảm thiểu $Ncut(A, B)$ đồng thời tối đa hóa $Nassoc(A, B)$.

Dựa trên cuộc thảo luận trước đó, việc phân đoạn hình ảnh bằng cách sử dụng các đường cắt đồ thị giờ đây dựa trên việc tìm một phân vùng làm giảm thiểu $Ncut(A, B)$. Thật không may, việc giảm thiểu chính xác số lượng này là một nhiệm vụ tính toán NP-đầy đủ và chúng ta không còn có thể dựa vào các giải pháp có sẵn cho luồng cực đại vì cách tiếp cận đang được thực hiện hiện nay dựa trên các khái niệm được giải thích liên quan đến Hình 5.55. Tuy nhiên, người ta đã có thể tìm ra một giải pháp rời rạc gần đúng để giảm thiểu $Ncut(A, B)$ bằng cách xây dựng công thức tối thiểu hóa như một bài toán giá trị riêng tổng quát, trong đó tồn tại nhiều cách triển khai.

5.6.2.1. Tính toán cắt đồ thị tối thiểu

Như trên, đặt V biểu thị các nút của đồ thị G và đặt A và B là hai tập con của V thỏa mãn phương trình (5-96). Gọi K biểu thị số nút trong V và xác định vector chỉ báo K chiều là x, có phần tử x_i có tính chất $x_i = 1$ nếu nút n_i của V nằm trong A và $x_i = -1$ nếu nó nằm trong B.

Nếu các nút của đồ thị G là các điểm ảnh trong một ảnh thì $K = M \times N$, trong đó M và N là số hàng và số cột trong ảnh.

Đặt:

$$d_i = \sum_j w(i, j) \quad (5-103)$$

là tổng trọng số từ nút đến tất cả các nút khác trong V. Sử dụng các định nghĩa này, chúng ta có thể viết phương trình (10-98) như sau:

$$Ncut(A, B) = \frac{cut(A, B)}{cut(A, V)} + \frac{cut(A, B)}{cut(B, V)} = \frac{\sum_{x_i > 0, x_j < 0} -w(i, j)x_i x_j}{\sum_{x_i > 0} d_i} + \frac{\sum_{x_i < 0, x_j > 0} -w(i, j)x_i x_j}{\sum_{x_i < 0} d_i} \quad (5-104)$$

Mục tiêu là tìm một vector x, làm cực tiểu Ncut(A, B). Một giải pháp dạng đóng giúp giảm thiểu phương trình (5-104) có thể được tìm thấy, nhưng chỉ khi các phần tử của x được phép là số thực, liên tục thay vì bị ràng buộc ở mức ± 1 . Một lời giải đã được đưa ra bằng cách giải biểu thức hệ giá trị riêng tổng quát:

$$(D - W)y = \lambda y \quad (5-105)$$

trong đó D là ma trận đường chéo $K \times K$ với các phần tử đường chéo chính $d_i, i = 1, 2, \dots, K$ và W là ma trận trọng số $K \times K$ với các phần tử $w(i, j)$, như được định nghĩa trước đó. Giải phương trình (5-105) cho K giá trị riêng và K vector riêng, mỗi giá trị tương ứng với một giá trị riêng. Lời giải cho bài toán của chúng ta là vector riêng tương ứng với giá trị riêng nhỏ nhất thứ hai.

Chúng ta có thể chuyển đổi công thức giá trị riêng tổng quát trước đó thành bài toán giá trị riêng tiêu chuẩn bằng cách viết phương trình (10-105) là:

$$Az = \lambda z \quad (5-106)$$

trong đó,

$$A = D^{-\frac{1}{2}}(D - W)D^{-\frac{1}{2}} \quad (5-107)$$

và:

$$z = D^{\frac{1}{2}}y \quad (5-108)$$

từ đó có:

$$y = D^{-\frac{1}{2}}z \quad (5-109)$$

Do đó, chúng ta có thể tìm vector riêng (có giá trị liên tục) tương ứng với giá trị riêng nhỏ nhất thứ hai bằng cách sử dụng bộ giải giá trị riêng tổng quát hoặc tiêu chuẩn. Vector x (rời rạc) mong muốn có thể được tạo từ vector nghiệm có giá trị liên tục thu được bằng cách tìm điểm phân chia giá trị của các phần tử vector riêng liên tục thành hai phần. Chúng ta thực hiện điều này bằng cách tìm điểm phân tách mang lại giá trị nhỏ nhất của Ncut(A, B), vì đây là đại lượng mà chúng ta đang cố gắng cực tiểu hóa. Để đơn giản hóa việc tìm kiếm, chúng tôi chia phạm vi giá trị trong vector liên tục thành Q giá trị cách đều nhau, đánh giá phương trình (5-104) cho mỗi giá trị và chọn điểm phân tách mang lại giá trị nhỏ nhất của Ncut(A, B). Sau đó, tất cả các giá trị của vector riêng có giá trị trên điểm phân tách được gán giá trị 1; tất cả những thứ khác được gán giá trị -1. Kết quả là vector x mong muốn. Khi đó, phân vùng A là tập hợp các nút trong V tương ứng với 1 trong x; các nút còn lại tương ứng với phân vùng B. Việc phân vùng này chỉ được thực hiện nếu đáp ứng tiêu chí về độ ổn định được thảo luận trong đoạn sau.

Việc tìm kiếm điểm phân tách ngụ ý tính toán tổng giá trị Q của Ncut(A, B) và chọn giá trị nhỏ nhất. Một vùng không thể phân chia rõ ràng thành hai tiểu vùng bằng cách sử dụng các

trọng số đã chỉ định thường sẽ dẫn đến nhiều điểm phân tách có giá trị tương tự của $Ncut(A, B)$. Cố gắng phân đoạn một khu vực như vậy có thể dẫn đến việc phân vùng vô nghĩa. Để tránh hành vi này, một vùng (tức là đồ thị con) chỉ được phân chia nếu nó đáp ứng tiêu chí ổn định, thu được bằng cách tính toán đồ thị đầu tiên của các giá trị vector riêng, sau đó hình thành tỷ lệ giữa số lượng thùng tối thiểu và tối đa. Trong một vector riêng “không chắc chắn”, các giá trị trong đồ thị sẽ tương đối giống nhau và tỷ lệ sẽ tương đối cao. Người ta đã phát hiện bằng thực nghiệm rằng việc đặt ngưỡng tỷ lệ ở mức 0,06 là một tiêu chí không hiệu quả để không phân chia khu vực đang được đề cập.

5.6.2.2. Thuật toán phân đoạn cắt đồ thị

Trong phần thảo luận trước, chúng tôi đã minh họa hai cách có thể tạo ra trọng số cạnh từ một hình ảnh. Trong các hình 5.55 và 5.56, chúng tôi đã xem xét các trọng số được tạo bằng cách sử dụng các giá trị cường độ hình ảnh và trong Hình 5.57, chúng tôi đã xem xét các trọng số dựa trên khoảng cách giữa các điểm ảnh. Nhưng đây chỉ là hai ví dụ trong số nhiều cách mà chúng ta có thể tạo đồ thị và các trọng số tương ứng từ một hình ảnh. Ví dụ: chúng ta có thể sử dụng màu sắc, kết cấu, các khoảng khắc thống kê về một vùng và các loại đặc điểm khác sẽ được thảo luận trong chương tiếp theo. Nói chung, khi đó, đồ thị có thể được xây dựng từ các đặc điểm hình ảnh, trong đó cường độ điểm ảnh là trường hợp đặc biệt. Với khái niệm này làm nền tảng, chúng ta có thể tóm tắt cuộc thảo luận cho đến nay trong phần này bằng thuật toán sau:

1. Cho một tập hợp các đặc điểm, chỉ định một đồ thị có trọng số, $G = (V, E)$ trong đó V chứa các điểm trong không gian đặc trưng và E chứa các cạnh của đồ thị. Tính toán cạnh trọng số và sử dụng chúng để xây dựng ma trận W và D . Gọi K là số phân vùng mong muốn của đồ thị.
2. Giải hệ giá trị riêng $(D - W)y = \lambda y$ để tìm vector riêng có giá trị riêng nhỏ nhất thứ hai.
3. Sử dụng vector riêng từ Bước 2 để phân chia đồ thị bằng cách tìm điểm phân tách sao cho $Ncut(A, B)$ là nhỏ nhất.
4. Nếu số lượng vết cắt chưa đạt K , hãy quyết định xem có nên chia nhỏ phân vùng hiện tại hay không bằng cách kiểm tra độ ổn định của vết cắt.
5. Lặp lại phân vùng các phần đã được phân đoạn nếu cần thiết.

Lưu ý rằng thuật toán hoạt động bằng cách tạo đệ quy các đường cắt hai chiều. Số lượng nhóm (ví dụ: vùng) trong hình ảnh được phân đoạn được kiểm soát bởi K . Các tiêu chí khác, chẳng hạn như kích thước tối đa được phép cho mỗi lần cắt, có thể tinh chỉnh thêm phân đoạn cuối cùng. Ví dụ: khi sử dụng điểm ảnh và cường độ của chúng làm cơ sở để xây dựng đồ thị, chúng ta có thể chỉ định kích thước tối đa và/hoặc tối thiểu được phép cho từng vùng.

VÍ DỤ 5.24 Chỉ định trọng số cho phân đoạn cắt đồ thị

Trong Hình 5.55, chúng tôi đã minh họa cách tạo trọng số đồ thị bằng cách sử dụng các giá trị cường độ và trong Hình 5.57, chúng tôi đã thảo luận ngắn gọn về cách tạo trọng số dựa trên khoảng cách giữa các điểm ảnh. Trong ví dụ này, chúng tôi đưa ra một cách tiếp cận thực tế hơn để tạo ra các trọng số bao gồm cả cường độ và khoảng cách từ một điểm ảnh, từ đó đưa ra khái niệm về vùng lân cận trong phân đoạn đồ thị.

Đặt n_i và n_j biểu thị hai nút (điểm ảnh hình ảnh). Như đã đề cập trước đó trong phần này, các trọng số được cho là phản ánh sự giống nhau giữa các nút trong đồ thị. Khi xem xét phân đoạn, một trong những cách chính để xác định khả năng hai điểm ảnh trong ảnh là một phần của cùng một vùng hoặc đối tượng là xác định sự khác biệt về giá trị cường độ của chúng và mức độ gần nhau của các điểm ảnh. Giá trị trọng số của cạnh giữa hai điểm ảnh phải lớn khi các điểm ảnh có cường độ và khoảng cách rất gần nhau (tức là khi các điểm ảnh “tương tự

nhau”) và sẽ giảm khi chênh lệch cường độ và khoảng cách giữa chúng tăng lên. Nghĩa là, giá trị trọng số phải là một hàm về mức độ giống nhau của các điểm ảnh về cường độ và khoảng cách. Hai khái niệm này có thể được nhúng vào một hàm trọng số bằng cách sử dụng biểu thức sau:

$$w(i, j) = \begin{cases} \frac{[I(n_i) - I(n_j)]^2}{\sigma_I^2} e^{-\frac{\text{dist}(n_i, n_j)}{\sigma_d^2}} & \text{nếu } \text{dist}(n_i, n_j) < r \\ 0 & \text{nếu khác} \end{cases}$$

trong đó $I(n_i)$ là cường độ của nút n_i , σ_I^2 và σ_d^2 là các hằng số xác định độ rộng của hai hàm giống Gaussian, $\text{dist}(n_i, n_j)$ là khoảng cách (ví dụ: Khoảng cách Euclide) giữa hai nút và r là hằng số xuyên tâm xác định khoảng cách mà chúng ta sẵn sàng xem xét sự giống nhau. Các số hạng hàm mũ giảm theo hàm của sự khác biệt về cường độ và là hàm của khoảng cách giữa các nút, theo yêu cầu của chúng ta đo độ tương tự trong trường hợp này.

VÍ DỤ 5.25: Phân đoạn bằng cách cắt đồ thị.

Việc cắt đồ thị là lý tưởng để có được sự phân đoạn thô của các vùng chính trong ảnh. Hình 5.58 cho thấy một kết quả điển hình. Hình 5.58(a) là hình ảnh tòa nhà quen thuộc. Phù hợp với ý tưởng trích xuất các vùng chính của một hình ảnh, Hình 5.58(b) cho thấy hình ảnh được làm mịn bằng một bộ lọc 25×25 đơn giản. Hãy quan sát cách làm mịn các chi tiết nhỏ, chỉ để lại những đặc điểm chính của khu vực như mặt tiền và bầu trời. Hình 5.58(c) là kết quả của việc phân đoạn bằng thuật toán cắt đồ thị vừa được phát triển, với các trọng số có dạng đã thảo luận trong ví dụ trước và chỉ cho phép hai phân vùng. Lưu ý rằng vùng tương ứng với tòa nhà được trích xuất tốt như thế nào mà không có đặc điểm chi tiết nào của các phương pháp được thảo luận trước đó trong chương này. Trên thực tế, gần như không thể thu được kết quả có thể so sánh được bằng cách sử dụng bất kỳ phương pháp nào mà chúng ta đã thảo luận cho đến nay nếu không có quá trình xử lý bổ sung đáng kể. Loại kết quả này lý tưởng cho các nhiệm vụ như cung cấp tín hiệu rộng rãi để điều hướng tự động, tìm kiếm cơ sở dữ liệu hình ảnh và phân tích hình ảnh cấp thấp.



Hình 5.58 (a) Ảnh có kích thước 600×600 điểm ảnh. (b) Ảnh được làm mịn bằng hạt nhân hộp 25×25 . (c) Phân đoạn cắt đồ thị thu được bằng cách chỉ định hai vùng.

Hình 5.59 cho thấy một ví dụ khác trong đó ảnh được làm mịn bằng cùng một hạt nhân. Ở đây, trước tiên chúng tôi xác định hai vùng, dẫn đến Hình 5.59(c). Lưu ý độ trung thực của sự tách biệt giữa tầng bằng trời và nền. Hình 5.59(d) là kết quả của việc xác định ba vùng trong phân đoạn. Chúng tôi thấy bằng cách so sánh Hình 5.59(d) và Hình 5.42(c) rằng phương pháp cắt đồ thị mang lại sự phân đoạn chính xác hơn nhiều, theo nghĩa là không có điểm ảnh nào trong các vùng bị gán nhãn sai là thuộc về một vùng khác.

5.7. Phân đoạn sử dụng lưu vực hình thái - morphological watersheds


Cho đến nay, chúng ta đã thảo luận về phân đoạn dựa trên ba khái niệm chính: phát hiện cạnh, ngưỡng và trích xuất vùng. Mỗi cách tiếp cận này đều có ưu điểm (ví dụ: tốc độ trong

trường hợp ngưỡng toàn cầu) và nhược điểm (ví dụ: nhu cầu xử lý hậu kỳ, chẳng hạn như liên kết cạnh, trong phân đoạn dựa trên cạnh). Trong phần này, chúng ta thảo luận về một cách tiếp cận dựa trên khái niệm được gọi là lưu vực hình thái. Phân đoạn theo lưu vực sông thể hiện nhiều khái niệm của ba cách tiếp cận còn lại và do đó, thường tạo ra kết quả phân đoạn ổn định hơn, bao gồm cả các ranh giới phân đoạn được kết nối. Cách tiếp cận này cũng cung cấp một khuôn khổ đơn giản để kết hợp các ràng buộc dựa trên kiến thức (xem Hình 1.23) trong quy trình phân đoạn, như chúng ta sẽ thảo luận ở cuối phần này.


5.7.1. Kiến thức nền tảng

Khái niệm lưu vực dựa trên việc hình dung một hình ảnh theo ba chiều, hai tọa độ không gian so với cường độ, như trong Hình 2.18(a). Trong cách giải thích “địa hình” như vậy, chúng tôi xem xét ba loại điểm: (1) các điểm thuộc vùng tối thiểu; (2) những điểm mà tại đó một giọt nước, nếu được đặt ở vị trí của bất kỳ điểm nào trong số đó, chắc chắn sẽ rơi xuống một mức tối thiểu; và (3) những điểm mà tại đó nước có khả năng giảm xuống nhiều hơn một mức tối thiểu như nhau. Đối với một mức tối thiểu khu vực cụ thể, tập hợp các điểm thỏa mãn điều kiện (2) được gọi là lưu vực lưu vực hoặc lưu vực của mức tối thiểu đó. Các điểm thỏa mãn điều kiện (3) tạo thành các đỉnh trên bề mặt địa hình, gọi là đường phân chia hoặc đường phân nguồn.

Mục tiêu chính của các thuật toán phân đoạn dựa trên các khái niệm này là tìm ra các đường đầu nguồn. Phương pháp thực hiện việc này có thể được giải thích nhờ sự trợ giúp của Hình 5.60. Hình 5.60(a) hiển thị hình ảnh thang độ xám và Hình 5.60(b) là chế độ xem địa hình, trong đó chiều cao của “ngọn núi” tỷ lệ thuận với giá trị cường độ trong hình ảnh đầu vào. Để dễ hiểu, mặt sau của các cấu trúc được tô bóng. Điều này không được nhầm lẫn với các giá trị cường độ; chỉ có địa hình chung của biểu diễn ba chiều là không được quan tâm. Để ngăn nước dâng tràn ra ngoài rìa của hình ảnh, chúng ta tưởng tượng chu vi của toàn bộ địa hình (hình ảnh) được bao bọc bởi những con đập cao hơn ngọn núi cao nhất có thể, giá trị của nó được xác định bởi cường độ cao nhất có thể giá trị trong hình ảnh đầu vào.



Hình 5.60 (a) Ảnh gốc. (b) Chế độ xem địa hình. Chỉ có nền là màu đen. Chậu bên trái nhạt hơn màu đen một chút. (c) và (d) Hai giai đoạn lũ lụt. Tất cả các giá trị tối không đổi của màu xám là cường độ trong ảnh gốc. Chỉ có màu xám nhạt không đổi tượng trưng cho “nước”.



Hình 5.61 (e) Hậu quả của lũ lụt tiếp theo. (f) Bắt đầu hợp nhất nước từ hai lưu vực (một con đập ngăn được xây dựng giữa chúng). (g) Đập dài hơn. (h) Các đường đầu nguồn (phân đoạn) cuối cùng được xếp chồng lên ảnh gốc.

Giả sử rằng một lỗ được đục lỗ ở mỗi vùng tối thiểu [được hiển thị dưới dạng vùng tối trong Hình 5.60(b)] và toàn bộ địa hình bị ngập từ bên dưới bằng cách để nước dâng lên qua các lỗ với tốc độ đồng đều. Hình 5.60(c) cho thấy giai đoạn ngập lụt đầu tiên, trong đó “nước” được hiển thị bằng màu xám nhạt, chỉ bao phủ các khu vực tương ứng với nền đen trong ảnh. Trong Hình 5.60(d) và (e) chúng ta thấy rằng nước hiện đã dâng lên lưu vực lưu vực thứ nhất và lưu vực thứ hai. Khi nước tiếp tục dâng cao, cuối cùng nó sẽ tràn từ lưu vực này sang lưu vực khác. Dấu hiệu đầu tiên của điều này được thể hiện ở Hình 5.60(f). Ở đây, nước từ phần dưới của lưu vực bên trái tràn vào lưu vực bên phải và một “đập” ngăn (gồm các điểm ảnh đơn lẻ) được xây dựng để ngăn nước hòa vào mức lũ đó (chi tiết toán học của việc xây đập). được thảo luận ở phần sau). Hiệu ứng này rõ rệt hơn khi nước tiếp tục dâng cao, như trong Hình 5.60(g). Hình này cho thấy một con đập dài hơn giữa hai lưu vực lưu vực và một con đập khác ở phần trên của lưu vực bên phải. Con đập thứ hai được xây dựng để ngăn chặn sự hòa nhập của nước từ lưu vực đó với nước từ các khu vực tương ứng với nền. Quá trình này được tiếp tục cho đến khi đạt mức ngập tối đa (tương ứng với giá trị cường độ cao nhất trong ảnh). Các con đập cuối cùng tương ứng với các đường phân chia đầu nguồn, là ranh giới phân đoạn mong muốn. Kết quả của ví dụ này được hiển thị trong Hình 5.60(h) dưới dạng các đường dẫn tối, dày một điểm ảnh được xếp chồng lên ảnh gốc. Lưu ý đặc tính quan trọng là các đường phân nguồn tạo thành các đường dẫn được kết nối, do đó tạo ra các ranh

giới liên tục giữa các khu vực.


Do sự tương phản lân cận, vùng ngoài cùng bên trái trong Hình 5.60(c) có vẻ màu đen, nhưng nó nhạt hơn một vài sắc độ so với nền đen. Màu xám giữa ở lưu vực thứ hai là màu xám tự nhiên từ hình ảnh trong (a).

Một trong những ứng dụng chính của phân đoạn lưu vực là trích xuất các đối tượng gần như đồng nhất (giống như đám mây) từ nền. Các vùng được đặc trưng bởi sự thay đổi cường độ nhỏ có giá trị độ dốc nhỏ. Vì vậy, trong thực tế, chúng ta thường thấy phân đoạn lưu vực được áp dụng cho độ dốc của hình ảnh, thay vì cho chính hình ảnh đó. Trong công thức này, giá trị cực tiểu khu vực của lưu vực lưu vực tương quan chặt chẽ với giá trị nhỏ của độ dốc tương ứng với các đối tượng quan tâm...

5.7.2. Xây dựng đập – dam construction

Việc xây dựng đập dựa trên ảnh nhị phân, là thành viên của không gian số nguyên 2 chiều Z^2 . Cách đơn giản nhất để xây dựng các đập ngăn cách các tập điểm nhị phân là sử dụng phép giãn nở hình thái.

Hình 5.61 minh họa những kiến thức cơ bản về xây dựng đập sử dụng phương pháp giãn nở. Phần (a) thể hiện các phần của hai lưu vực lưu vực ở bước ngập $n - 1$, và Hình 5.61(b) thể hiện kết quả ở bước ngập tiếp theo n . Nước đã tràn từ lưu vực này sang lưu vực khác và do đó, một con đập phải được xây dựng để ngăn chặn điều này xảy ra. Để phù hợp với ký hiệu được giới thiệu sau đây, gọi M_1 và M_2 biểu thị tập hợp tọa độ các điểm trong hai cực tiểu miền. Sau đó, đặt tập hợp tọa độ các điểm trong lưu vực lưu vực liên quan đến hai cực tiểu này ở giai đoạn $n - 1$ của lũ lụt được ký hiệu lần lượt là $C_{n-1}(M_1)$ và $C_{n-1}(M_2)$. Đây là hai vùng màu xám trong Hình 5.61(a).



Hình 5.62 (a) Hai lưu vực bị ngập một phần ở giai đoạn lũ $n-1$. (b) Lũ lụt giai đoạn, thể hiện nước đã tràn giữa các lưu vực. (c) Phần tử cấu trúc được sử dụng để giãn nở. (d) Kết quả của việc giãn nở và xây dựng đập.

Mô tả:

Đặt $C[n-1]$ biểu thị sự kết hợp của hai tập hợp này. Có hai thành phần được kết nối trong Hình 5.61(a) và chỉ có một thành phần trong Hình 5.61(b). Thành phần được kết nối này bao gồm hai thành phần trước đó, được hiển thị bằng nét đứt. Hai thành phần được kết nối trở thành một thành phần duy nhất cho thấy nước giữa hai lưu vực lưu vực đã hợp nhất ở bước lũ n . Đặt thành phần kết nối này được ký hiệu là q . Lưu ý rằng hai thành phần từ bước $n-1$ có thể được trích xuất từ q bằng cách thực hiện phép toán logic AND, $q \cap C[n-1]$. Cũng quan sát thấy rằng tất cả các điểm thuộc một lưu vực riêng biệt tạo thành một thành phần được kết nối duy nhất.

Giả sử rằng mỗi thành phần được kết nối trong Hình 5.61(a) được giãn nở bởi phần tử cấu trúc trong Hình 5.61(c), tuân theo hai điều kiện: (1) Độ giãn nở phải bị ràng buộc ở q (điều này có nghĩa là tâm của phần tử cấu trúc chỉ có thể được định vị tại các điểm trong q trong quá trình giãn nở); và (2) việc giãn nở không thể được thực hiện trên các điểm có thể khiến các tập hợp bị giãn nở hợp nhất (tức là trở thành một thành phần được kết nối duy nhất). Hình 5.61(d) cho thấy đường giãn nở đầu tiên (màu xám nhạt) đã mở rộng ranh giới của từng thành phần được kết nối ban đầu. Lưu ý rằng điều kiện (1) được thỏa mãn ở mọi điểm trong

quá trình giãn nở và điều kiện (2) không áp dụng cho bất kỳ điểm nào trong quá trình giãn nở; nhờ đó, ranh giới từng vùng được mở rộng đồng đều

Trong lần giãn thứ hai, được thể hiện bằng màu đen trong Hình 5.61(d), một số điểm không đạt điều kiện (1) trong khi đáp ứng điều kiện (2), dẫn đến chu vi bị hỏng như trong hình. Rõ ràng là các điểm duy nhất trong q thỏa mãn hai điều kiện đang xem xét mô tả đường dẫn kết nối dày một điểm ảnh được gạch chéo trong Hình 5.61(d). Con đường này chính là đập ngăn cách mong muốn ở giai đoạn n lũ. Việc xây dựng đập ở mức lũ này được hoàn thành bằng cách đặt tất cả các điểm trên đường dẫn vừa xác định thành giá trị lớn hơn giá trị cường độ tối đa có thể có của hình ảnh (ví dụ: lớn hơn 255 đối với hình ảnh 8 bit). Điều này sẽ ngăn nước tràn qua phần đập đã hoàn thành khi mực nước lũ tăng lên. Như đã lưu ý trước đó, các đập được xây dựng theo quy trình này, là ranh giới phân đoạn mong muốn, là các thành phần được kết nối. Nói cách khác, phương pháp này loại bỏ các vấn đề về đường phân đoạn bị hỏng.

Mặc dù quy trình vừa được mô tả dựa trên một ví dụ đơn giản, phương pháp được sử dụng cho các tình huống phức tạp hơn hoàn toàn giống nhau, bao gồm cả việc sử dụng phân tử cấu trúc đối xứng 3×3 trong Hình 5.61(c).

5.7.3. Thuật toán phân đoạn lưu vực

Đặt $M_1, M_2, \dots, M_R$ là các tập hợp biểu thị tọa độ của các điểm trong cực tiểu khu vực của một ảnh, $g(x, y)$. Như đã đề cập trước đó, đây thường là một hình ảnh chuyển màu. Cho $C(M_i)$ là tập hợp biểu thị tọa độ của các điểm trong lưu vực lưu vực gắn với cực tiểu khu vực M_i (nhớ lại rằng các điểm trong bất kỳ lưu vực lưu vực nào đều tạo thành một thành phần liên thông). Ký hiệu min và max sẽ được dùng để biểu thị giá trị tối thiểu và tối đa của $g(x, y)$. Cuối cùng, đặt $T[n]$ biểu thị tập hợp tọa độ (s, t) mà $g(s, t) < n$. Đó là:

$$T[n] = \{(s, t) | g(s, t) < n\} \quad (5-110)$$

Về mặt hình học, $T[n]$ là tập hợp tọa độ các điểm trong $g(x, y)$ nằm bên dưới mặt phẳng $g(x, y) = n$.

Địa hình sẽ bị ngập với số gia lũ nguyên, từ $n = \min + 1$ đến $n = \max + 1$. Ở bất kỳ bước n nào của quá trình ngập, thuật toán cần biết số điểm nằm dưới độ sâu lũ. Về mặt khái niệm, giả sử rằng tọa độ trong $T[n]$ nằm bên dưới mặt phẳng $g(s, t) = n$ được “đánh dấu” màu đen và tất cả các tọa độ khác được đánh dấu màu trắng. Sau đó, khi chúng ta nhìn “xuống” trên mặt phẳng xy ở bất kỳ mức tăng n nào của lũ lụt, chúng ta sẽ thấy một ảnh nhị phân trong đó các điểm đen tương ứng với các điểm trong hàm nằm bên dưới mặt phẳng $g(s, t) = n$. Cách giải thích này khá hữu ích và sẽ làm cho cuộc thảo luận sau đây dễ hiểu hơn.

Gọi $C_n(M_i)$ là tập hợp tọa độ các điểm trong lưu vực lưu vực gắn với mức tối thiểu bị ngập ở giai đoạn n . Liên quan đến cuộc thảo luận ở đoạn trước, chúng ta có thể xem $C_n(M_i)$ dưới dạng ảnh nhị phân cho bởi:

$$C_n(M_i) = C(M_i) \cap T[n] \quad (5-111)$$

Nói cách khác, $C_n(M_i) = 1$ tại vị trí (x, y) nếu $(x, y) \in C_n(M_i)$ VÀ $(x, y) \in T[n]$; ngược lại $C_n(M_i) = 0$. Việc giải thích hình học của kết quả này rất đơn giản. Chúng tôi chỉ đơn giản sử dụng toán tử AND để cô lập ở giai đoạn n làm tràn phần ảnh nhị phân trong $T[n]$ được liên kết với vùng tối thiểu.

Tiếp theo, gọi B là số lượng lưu vực bị ngập ở giai đoạn n và gọi $C[n]$ là sự hợp nhất của các lưu vực này ở giai đoạn n :

$$C[n] = \bigcup_{i=1}^B C(M_i) \quad (5-112)$$

Khi đó $C[\max + 1]$ là hợp của tất cả các lưu vực:

$$C[\max + 1] = \bigcup_{i=1}^B C(M_i) \quad (5-113)$$

Có thể chỉ ra rằng các phần tử trong cả $C_n(M_i)$ và $T[n]$ không bao giờ được thay thế trong quá trình thực hiện thuật toán và số phần tử trong hai tập hợp này tăng lên hoặc giữ nguyên như n tăng. Do đó, $C[n - 1]$ là tập con của $C[n]$. Theo phương trình (5-112) và (5-113), $C[n]$ là tập con của $T[n]$, do đó $C[n]$ cũng là tập con của $T[n]$. Từ đó chúng ta có kết quả quan trọng là mỗi thành phần liên thông của $C[n - 1]$ được chứa trong đúng một thành phần liên thông của $T[n]$.

Thuật toán tìm đường phân nguồn được khởi tạo bằng cách đặt $C[\min + 1] = T[\min + 1]$. Sau đó, quy trình sẽ tiến hành đệ quy, tính toán liên tục $C[n]$ từ $C[n-1]$, sử dụng phương pháp sau. Gọi Q là tập hợp các thành phần liên thông trong $T[n]$. Khi đó, với mỗi thành phần liên thông $q \in Q[n]$, có ba khả năng:


1. $q \cap C[n - 1]$ trống.
2. $q \cap C[n - 1]$ chứa một thành phần liên thông của $C[n - 1]$.
3. $q \cap C[n - 1]$ chứa nhiều hơn một thành phần liên thông của $C[n - 1]$.

Việc xây dựng $C[n]$ từ $C[n - 1]$ phụ thuộc vào điều kiện nào trong ba điều kiện này. Điều kiện 1 xảy ra khi gặp một mức tối thiểu mới, trong trường hợp đó thành phần liên thông q được tích hợp vào $C[n - 1]$ để tạo thành $C[n]$. Điều kiện 2 xảy ra khi q nằm trong lưu vực lưu vực của một mức tối thiểu nào đó trong khu vực, trong trường hợp đó q được tích hợp vào $C[n - 1]$ để tạo thành $C[n]$. Tình trạng 3 xảy ra khi gặp phải tất cả (hoặc một phần) sườn núi ngăn cách hai hoặc nhiều lưu vực lưu vực. Lũ lụt tiếp theo sẽ khiến mực nước trong các lưu vực lưu vực này hòa vào nhau. Do đó, một con đập (hoặc các đập nếu có nhiều hơn hai lưu vực lưu vực) phải được xây dựng trong phạm vi q để ngăn chặn dòng chảy tràn giữa các lưu vực lưu vực. Như đã giải thích trước đó, một con đập dày một điểm ảnh có thể được xây dựng khi cần bằng cách giãn nở $q \cap C[n - 1]$ với phần tử cấu trúc 3×3 có kích thước 1 giây và hạn chế độ giãn nở ở mức q .

Hiệu quả của thuật toán được cải thiện bằng cách chỉ sử dụng các giá trị của n tương ứng với các giá trị cường độ hiện có trong $g(x, y)$. Chúng ta có thể xác định các giá trị này cũng như các giá trị min và max từ biểu đồ của $g(x, y)$.

VÍ DỤ 5.26: Minh họa thuật toán phân đoạn lưu vực


Hãy xem xét hình ảnh và độ dốc của nó trong Hình 5.62(a) và (b), tương ứng. Việc áp dụng thuật toán lưu vực vừa mô tả sẽ mang lại các đường phân nguồn (đường dẫn màu trắng) được hiển thị chồng lên trên hình ảnh chuyển màu trong Hình 5.62(c). Các ranh giới phân đoạn này được hiển thị chồng lên ảnh gốc trong Hình 5.62(d). Như đã lưu ý ở phần đầu của phần này, các ranh giới phân đoạn có đặc tính quan trọng là các đường dẫn được kết nối.



Hình 5.63 (a) Hình ảnh các đốm màu. (b) Độ dốc hình ảnh. (c) Các đường đầu nguồn, chồng lên ảnh gradient. (d) Các đường phân nước chồng lên ảnh gốc.

5.7.4. Sử dụng điểm đánh dấu – marker

Việc áp dụng trực tiếp thuật toán phân đoạn lưu vực theo dạng đã thảo luận ở phần trước thường dẫn đến phân đoạn quá mức, gây ra bởi nhiễu và các bất thường cục bộ khác của độ dốc. Như Hình 5.63 minh họa, việc phân đoạn quá mức có thể nghiêm trọng đến mức khiến kết quả của thuật toán hầu như vô dụng. Trong trường hợp này, điều này có nghĩa là một số lượng lớn các vùng được phân đoạn. Một giải pháp thực tế cho vấn đề này là giới hạn số vùng được phép bằng cách kết hợp giai đoạn tiền xử lý được thiết kế để đưa kiến thức bổ sung vào quy trình phân đoạn.




Hình 5.64 (a) Hình ảnh điện di. (b) Kết quả áp dụng thuật toán phân đoạn lưu vực cho ảnh độ dốc. Sự phân chia quá mức là điều hiển nhiên.

Một cách tiếp cận được sử dụng để kiểm soát việc phân đoạn quá mức dựa trên khái niệm về điểm đánh dấu. Điểm đánh dấu là một thành phần được kết nối thuộc về một hình ảnh. Chúng tôi có các điểm đánh dấu bên trong, được liên kết với các đối tượng quan tâm và các điểm đánh dấu bên ngoài, được liên kết với nền. Quy trình lựa chọn điểm đánh dấu thường bao gồm hai bước chính: (1) tiền xử lý; và (2) định nghĩa về một bộ tiêu chí mà các điểm đánh dấu phải đáp ứng. Để minh họa, hãy xem lại hình 5.63(a). Một phần của vấn đề dẫn đến kết quả bị phân đoạn quá mức trong Hình 5.63(b) là số lượng lớn các cực tiểu tiềm năng. Do kích thước của chúng, nhiều điểm cực tiểu trong số này là những chi tiết không liên quan. Như đã được chỉ ra nhiều lần trong các cuộc thảo luận trước đó, một phương pháp hiệu quả để giảm thiểu ảnh hưởng của chi tiết không gian nhỏ là lọc hình ảnh bằng bộ lọc làm mịn. Đây cũng là một sơ đồ tiền xử lý thích hợp trong trường hợp này.

Giả sử chúng ta định nghĩa điểm đánh dấu bên trong là (1) một vùng được bao quanh bởi các điểm có “độ cao” cao hơn; (2) sao cho các điểm trong vùng tạo thành một thành phần được kết nối; và (3) trong đó tất cả các điểm trong thành phần được kết nối có cùng giá trị cường độ. Sau khi hình ảnh được làm mịn, các điểm đánh dấu bên trong thu được từ định nghĩa này được hiển thị dưới dạng các vùng giống như đốm màu, màu xám nhạt trong Hình

5.64(a). Tiếp theo, thuật toán lưu vực được áp dụng cho hình ảnh được làm mịn, với hạn chế là các điểm đánh dấu bên trong này là cực tiểu khu vực duy nhất được phép. Hình 5.64(a) thể hiện các đường phân chia kết quả. Những đường đầu nguồn này được xác định là các điểm đánh dấu bên ngoài. Lưu ý rằng các điểm dọc theo đường phân nguồn đi dọc theo các điểm cao nhất giữa các điểm đánh dấu lân cận.



Hình 5.65 (a) Hình ảnh hiển thị các điểm đánh dấu bên trong (vùng màu xám nhạt) và điểm đánh dấu bên ngoài (đường đầu nguồn). (b) Kết quả phân đoạn. Lưu ý sự cải thiện so với Hình 5.63(b).

5.8. Sử dụng chuyển động trong phân đoạn ảnh

Chuyển động là một tín hiệu mạnh mẽ được con người và nhiều loài động vật sử dụng để trích xuất các đối tượng hoặc vùng quan tâm từ nền chi tiết không liên quan. Trong các ứng dụng hình ảnh, chuyển động phát sinh từ sự dịch chuyển tương đối giữa hệ thống cảm biến và cảnh đang được xem, chẳng hạn như trong các ứng dụng robot, điều hướng tự động và phân tích cảnh động. Trong cuộc thảo luận sau đây, chúng tôi xem xét việc sử dụng chuyển động trong phân đoạn cả về mặt không gian và miền tần số. Trong chương tiếp theo chúng ta sẽ xem chuyển động như một bài toán theo dõi, sử dụng các đường viền chuyển động.

5.8.1 Kỹ thuật không gian

Trong phần tiếp theo, chúng ta sẽ xem xét hai cách tiếp cận để phát hiện chuyển động, hoạt động trực tiếp trong miền không gian. Mục tiêu chính là cung cấp cho bạn ý tưởng về cách đo lường những thay đổi trong hình ảnh kỹ thuật số bằng cách sử dụng một số kỹ thuật đơn giản.

5.8.2 Cách tiếp cận cơ bản

Một trong những cách tiếp cận đơn giản nhất để phát hiện những thay đổi giữa hai khung hình $f(x, y, t_i)$ và $f(x, y, t_j)$ được chụp tại các thời điểm t_i và t_j tương ứng là so sánh hai hình ảnh theo từng điểm ảnh. Một thủ tục để làm điều này là tạo thành một hình ảnh khác biệt. Giả sử chúng ta có một ảnh tham chiếu chỉ chứa các thành phần cố định. So sánh hình ảnh này với hình ảnh tiếp theo của cùng một cảnh, nhưng bao gồm một hoặc nhiều vật thể chuyển động, dẫn đến sự khác biệt của hai hình ảnh loại bỏ các phần tử đứng yên, chỉ để lại các mục không khác 0 tương ứng với các thành phần hình ảnh không cố định.

Một hình ảnh khác nhau của hai hình ảnh (có cùng kích thước) được chụp tại các thời điểm t_i và t_j có thể được định nghĩa là:

$$d_{ij}(x, y) = \begin{cases} 1 & \text{nếu } |f(x, y, t_i) - f(x, y, t_j)| > T \\ 0 & \text{nếu khác} \end{cases} \quad (5-114)$$

trong đó T là ngưỡng không âm. Lưu ý rằng $d_{ij}(x, y)$ chỉ có giá trị 1 tại tọa độ không gian (x, y) nếu chênh lệch cường độ giữa hai ảnh khác nhau đáng kể ở các tọa độ đó, như được xác định bởi T . Cũng lưu ý rằng tọa độ (x, y) trong biểu thức (5-114) trải rộng kích thước của hai hình ảnh, do đó hình ảnh khác biệt có cùng kích thước với các hình ảnh trong chuỗi.

Trong cuộc thảo luận sau đây, tất cả các điểm ảnh trong $d_{ij}(x, y)$ có giá trị 1 được coi là kết quả của chuyển động của vật thể. Cách tiếp cận này chỉ có thể áp dụng nếu hai hình ảnh được đăng ký theo không gian và nếu độ chiếu sáng tương đối ổn định trong giới hạn do T thiết lập. Trong thực tế, các mục có giá trị 1 trong $d_{ij}(x, y)$ cũng có thể phát sinh do nhiễu. Thông thường, các mục này là các điểm biệt lập trong ảnh khác biệt và cách tiếp cận đơn giản để loại bỏ chúng là tạo thành các vùng 1 hoặc 4 được kết nối của 1 trong ảnh $d_{ij}(x, y)$, sau đó bỏ qua bất kỳ vùng nào có ít hơn số phần tử được xác định trước. Mặc dù nó có thể dẫn đến việc bỏ qua các vật thể nhỏ và/hoặc chuyển động chậm, cách tiếp cận này cải thiện khả năng các mục còn lại trong hình ảnh khác biệt thực sự là kết quả của chuyển động chứ không phải nhiễu.

Mặc dù phương pháp vừa mô tả rất đơn giản nhưng nó được sử dụng thường xuyên làm cơ sở cho các hệ thống hình ảnh được thiết kế để phát hiện những thay đổi trong môi trường được kiểm soát, chẳng hạn như giám sát các cơ sở đỗ xe, tòa nhà và các địa điểm cố định tương tự.

5.8.3. Chênh lệch tích lũy

Hãy xem xét một chuỗi các khung hình được biểu thị bằng $f(x, y, t_1), f(x, y, t_2), \dots, f(x, y, t_n)$ và đặt $f(x, y, t_1)$ lấy hình ảnh tham chiếu. Một hình ảnh khác biệt tích lũy (ADI) được hình thành bằng cách so sánh hình ảnh tham chiếu này với mọi hình ảnh tiếp theo trong chuỗi. Bộ đếm cho từng vị trí điểm ảnh trong ảnh tích lũy được tăng lên mỗi khi có sự khác biệt xảy ra ở vị trí điểm ảnh đó giữa tham chiếu và hình ảnh trong chuỗi. Do đó, khi khung thứ k được so sánh với tham chiếu, mục nhập trong một điểm ảnh nhất định của hình ảnh tích lũy sẽ cho biết số lần cường độ ở vị trí đó khác nhau [như được xác định bởi T trong biểu thức (10-114)] từ giá trị điểm ảnh tương ứng trong ảnh tham chiếu.

Giả sử rằng giá trị cường độ của các vật thể chuyển động lớn hơn nền, chúng ta xem xét ba loại ADI. Đặt $R(x, y)$ biểu thị hình ảnh tham chiếu và, để đơn giản hóa ký hiệu, đặt k ký hiệu cho t_k sao cho $f(x, y, k) = f(x, y, t_k)$. Chúng tôi giả định rằng $R(x, y) = f(x, y, k) = f(x, y, 1)$. Sau đó, với bất kỳ và lưu ý rằng các giá trị của ADI là số đếm, chúng tôi xác định các sai phân tích lũy sau đây cho tất cả các giá trị liên quan của (x, y) :

$$A_k(x, y) = \begin{cases} A_{k-1}(x, y) + 1 & \text{nếu } |R(x, y) - f(x, y, k)| > T \\ A_{k-1}(x, y) & \text{nếu khác} \end{cases} \quad (5-115)$$

$$P_k(x, y) = \begin{cases} P_{k-1}(x, y) + 1 & \text{nếu } |R(x, y) - f(x, y, k)| > T \\ P_{k-1}(x, y) & \text{nếu khác} \end{cases} \quad (5-116)$$

và


$$N_k(x, y) = \begin{cases} N_{k-1}(x, y) + 1 & \text{nếu } |R(x, y) - f(x, y, k)| < -T \\ N_{k-1}(x, y) & \text{nếu khác} \end{cases} \quad (5-117)$$

trong đó $A_k(x, y)$, $P_k(x, y)$ và $N_k(x, y)$ lần lượt là các ADI trị tuyệt đối, dương và âm được tính toán bằng hình ảnh thứ k trong chuỗi. Cả ba ADI đều bắt đầu với số lượng bằng 0 và có cùng kích thước với các hình ảnh trong chuỗi. Thứ tự của các bất đẳng thức và dấu của các ngưỡng trong các phương trình (5-116) và (5-117) bị đảo ngược nếu giá trị cường độ của điểm ảnh nền lớn hơn giá trị của đối tượng chuyển động.

VÍ DỤ 5.27: Tính toán các ảnh sai phân tích lũy tuyệt đối, dương và âm

Hình 5.65 cho thấy ba ADI được hiển thị dưới dạng hình ảnh cường độ cho một đối tượng hình chữ nhật có kích thước 75×50 điểm ảnh đang di chuyển theo hướng đông nam với

tốc độ $5\sqrt{2}$ điểm ảnh trên mỗi khung hình. Các hình ảnh có kích thước 256×256 điểm ảnh. Chúng tôi lưu ý những điều sau: (1) Diện tích khác 0 của ADI dương bằng kích thước của vật chuyển động; (2) vị trí của ADI dương tương ứng với vị trí của vật chuyển động trong hệ quy chiếu; (3) số lượng số đếm trong ADI dương ngừng tăng khi đối tượng chuyển động bị dịch chuyển hoàn toàn so với cùng một đối tượng trong hệ quy chiếu; (4) nADI tuyệt đối chứa các vùng của ADI dương và âm; và (5) hướng và tốc độ của vật thể chuyển động có thể được xác định từ các mục trong ADI tuyệt đối và âm.



Hình 5.65 ADI của một vật thể hình chữ nhật chuyển động theo hướng đông nam. (a) ADI tuyệt đối. (b) ADI dương. (c) ADI âm.

5.8.4. Thiết lập một hình ảnh tham chiếu

Chìa khóa thành công của các kỹ thuật vừa thảo luận là có một hình ảnh tham chiếu để có thể thực hiện các so sánh tiếp theo. Sự khác biệt giữa hai ảnh trong bài toán tạo ảnh động có xu hướng loại bỏ tất cả các thành phần đứng yên, chỉ để lại các phần tử ảnh tương ứng với nhiễu và các vật thể chuyển động.

Việc thu được một hình ảnh tham chiếu chỉ có các phần tử đứng yên không phải lúc nào cũng có thể thực hiện được và việc xây dựng một tham chiếu từ một tập hợp các hình ảnh chứa một hoặc nhiều đối tượng chuyển động trở nên cần thiết. Điều này đặc biệt áp dụng cho các tình huống mô tả cảnh bận rộn hoặc trong trường hợp cần cập nhật thường xuyên. Một quy trình để tạo ra một hình ảnh tham chiếu như sau. Hãy coi hình ảnh đầu tiên trong chuỗi là hình ảnh tham chiếu. Khi một thành phần không cố định đã di chuyển hoàn toàn ra khỏi vị trí của nó trong khung tham chiếu, nền tương ứng trong khung hiện tại có thể được sao chép ở vị trí ban đầu mà đối tượng chiếm giữ trong khung tham chiếu. Khi tất cả các vật thể chuyển động đã di chuyển hoàn toàn ra khỏi vị trí ban đầu của chúng, một hình ảnh tham chiếu chỉ chứa các thành phần đứng yên sẽ được tạo ra. Sự dịch chuyển đối tượng có thể được thiết lập bằng cách theo dõi những thay đổi trong ADI dương, như đã chỉ ra trước đó. Ví dụ sau minh họa cách xây dựng hệ quy chiếu bằng cách sử dụng phương pháp vừa mô tả.

VÍ DỤ 5.28 Xây dựng hình ảnh tham chiếu

Hình 5.66(a) và (b) hiển thị hai khung hình của một nút giao thông. Hình ảnh đầu tiên được coi là hình ảnh tham chiếu và hình ảnh thứ hai mô tả cảnh tương tự một thời gian sau đó. Mục tiêu là loại bỏ các đối tượng chuyển động chính trong ảnh tham chiếu để tạo ra ảnh tĩnh. Mặc dù có những vật thể chuyển động nhỏ hơn khác, đặc điểm chuyển động chính là ô tô tại ngã tư di chuyển từ trái sang phải. Với mục đích minh họa, chúng tôi tập trung vào đối tượng này. Bằng cách theo dõi những thay đổi trong ADI dương, có thể xác định vị trí ban đầu của một vật thể chuyển động, như đã giải thích ở trên. Sau khi xác định được vùng chiếm giữ của đối tượng này, đối tượng có thể được xóa khỏi ảnh bằng phép trừ. Bằng cách xem khung hình theo trình tự mà ADI dương ngừng thay đổi, chúng ta có thể sao chép từ hình ảnh này khu vực trước đó bị vật thể chuyển động chiếm giữ trong khung hình ban đầu. Sau đó, vùng

này được dán vào hình ảnh mà đối tượng đã bị cắt ra, do đó khôi phục nền của vùng đó. Nếu điều này được thực hiện cho tất cả các đối tượng chuyển động, kết quả là một hình ảnh tham chiếu chỉ có các thành phần tĩnh mà chúng ta có thể so sánh các khung hình tiếp theo để phát hiện chuyển động. Hình ảnh tham chiếu thu được từ việc loại bỏ phương tiện di chuyển về phía đông và khôi phục nền được hiển thị trong Hình 5.66(c).



Hình 5.66 Xây dựng một hình ảnh tham chiếu tĩnh. (a) và (b) Hai khung hình liên tiếp. (c) Ô tô đi về hướng đông bị trừ khỏi (a) và nền được khôi phục từ khu vực tương ứng trong (b).

5.8.5. Kỹ thuật miền tần số

Trong phần này chúng ta xét bài toán xác định chuyển động thông qua công thức biến đổi Fourier. Hãy xem xét một chuỗi $f(x, y, t), t = 0, 1, 2, \dots, K - 1$ của K khung hình ảnh kỹ thuật số có kích thước $M \times N$ điểm ảnh, được tạo bởi một máy ảnh cố định. Chúng tôi bắt đầu phát triển bằng cách giả định rằng tất cả các khung hình có nền đồng nhất có cường độ bằng 0. Ngoại lệ là một đối tượng đơn, 1 điểm ảnh có cường độ đơn vị đang chuyển động với vận tốc không đổi. Giả sử rằng đối với khung một ($t = 0$), đối tượng ở vị trí (x', y') và mặt phẳng ảnh được chiếu lên trục x ; nghĩa là cường độ điểm ảnh được tính tổng (cho mỗi hàng) trên các cột trong hình ảnh. Hoạt động này mang lại một mảng 1-D với M mục bằng 0, ngoại trừ tại x' đó là tọa độ x của đối tượng một điểm. Nếu bây giờ chúng ta nhân tất cả các thành phần của mảng 1-D với số lượng $\exp[j2\pi a_1 x \Delta t]$ với $x = 0, 1, 2, \dots, M - 1$ và cộng các kết quả lại, chúng ta thu được số hạng duy nhất $\exp[j2\pi a_1 x' \Delta t]$ vì chỉ có một điểm khác 0 trong mảng. Trong ký hiệu này, a_1 là số nguyên dương và Δt là khoảng thời gian giữa các khung.

Giả sử trong khung hình hai ($t = 1$), đối tượng đã di chuyển đến tọa độ $(x' + 1, y')$, tức là nó đã di chuyển song song 1 điểm ảnh với trục x . Sau đó, lặp lại quy trình chiếu đã thảo luận ở đoạn trước sẽ tính tổng $\exp[j2\pi a_1 (x' + 1) \Delta t]$. Nếu đối tượng tiếp tục di chuyển 1 vị trí điểm ảnh trên mỗi khung hình thì tại bất kỳ thời điểm nguyên nào, t , kết quả sẽ là $\exp[j2\pi a_1 (x' + t) \Delta t]$ kết quả mà khi sử dụng công thức Euler, có thể được biểu thị dưới dạng:

$$e^{j2\pi a_1 (x' + t) \Delta t} = \cos[2\pi a_1 (x' + t) \Delta t] + j \sin[2\pi a_1 (x' + t) \Delta t] \quad (10-118)$$

với $t = 0, 1, 2, \dots, K - 1$. Nói cách khác, quy trình này tạo ra một hình sin phức tạp có tần số a_1 . Nếu đối tượng đang di chuyển V_1 điểm ảnh (theo hướng x) giữa các khung, thì hình sin sẽ có tần số $V_1 a_1$. Bởi vì t thay đổi trong khoảng từ 0 đến $K-1$ theo số nguyên, hạn chế a_1 có các giá trị nguyên gây ra biến đổi Fourier rời rạc của hình sin phức tạp có hai đỉnh - một đỉnh nằm ở tần số $V_1 a_1$ và đỉnh kia ở $K - V_1 a_1$. Đỉnh thứ hai này là kết quả của sự đối xứng trong biến đổi Fourier rời rạc, như đã thảo luận trong Phần 4.6, và có thể bị bỏ qua. Do đó, việc tìm kiếm đỉnh trong phổ Fourier sẽ mang lại một đỉnh có giá trị $V_1 a_1$. Chia đại lượng này cho a_1 kết quả là V_1 - là thành phần vận tốc theo hướng x , vì tốc độ khung hình được giả sử là đã biết. Một phân tích tương tự sẽ mang lại V_2 - là thành phần vận tốc theo hướng y .

Một chuỗi các khung trong đó không có chuyển động nào diễn ra sẽ tạo ra các số hạng hàm mũ giống hệt nhau, biến đổi Fourier của chúng sẽ bao gồm một đỉnh duy nhất ở tần số 0 (một số hạng dc). Do đó, vì các phép toán được thảo luận cho đến nay là tuyến tính, nên trường hợp chung liên quan đến một hoặc nhiều đối tượng chuyển động trong nền tĩnh tùy ý sẽ có biến đổi Fourier với đỉnh tại dc tương ứng với các thành phần ảnh tĩnh và các đỉnh tại các vị trí tỷ lệ với vận tốc của các vật thể.

Những khái niệm này có thể được tóm tắt như sau. Đối với một chuỗi k hình ảnh kỹ thuật số có kích thước $M \times N$ điểm ảnh, tổng các hình chiếu có trọng số lên trục x tại bất kỳ thời điểm nguyên nào là:

$$g_x(t, a_1) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y, t) e^{j2\pi a_1 x \Delta t} \quad t = 0, 1, \dots, K-1 \quad (5-119)$$

Tương tự, tổng các hình chiếu lên trục y là:

$$g_y(t, a_2) = \sum_{y=0}^{N-1} \sum_{x=0}^{M-1} f(x, y, t) e^{j2\pi a_2 y \Delta t} \quad t = 0, 1, \dots, K-1 \quad (5-120)$$

trong đó, như đã lưu ý trước đó, a_1 và a_2 là số nguyên dương.

Các biến đổi Fourier 1D của các phương trình (10-119) và (10-120) lần lượt là:

$$G_x(u_1, a_1) = \sum_{t=0}^{K-1} g_x(t, a_1) e^{-j2\pi u_1 t/K} \quad u_1 = 0, 1, 2, \dots, K-1 \quad (5-121)$$

và:

$$G_y(u_2, a_2) = \sum_{t=0}^{K-1} g_y(t, a_2) e^{-j2\pi u_2 t/K} \quad u_2 = 0, 1, 2, \dots, K-1 \quad (5-122)$$

Những biến đổi này được tính toán bằng thuật toán FFT, như được thảo luận trong Phần 4.11.

Mối quan hệ tần số-vận tốc là:

$$u_1 = a_1 V_1 \quad (5-123)$$

và:

$$u_2 = a_2 V_2 \quad (5-124)$$

Trong công thức trước, đơn vị vận tốc là điểm ảnh trên tổng thời gian khung hình. Ví dụ: $V_1 = 10$ biểu thị chuyển động 10 điểm ảnh trong K khung hình. Đối với các khung hình được chụp đồng nhất, tốc độ vật lý thực tế phụ thuộc vào tốc độ khung hình và khoảng cách giữa các điểm ảnh. Do đó, nếu $V_1 = 10$ và $K=30$, tốc độ khung hình là hai hình ảnh mỗi giây và khoảng cách giữa các điểm ảnh là 0,5 m thì tốc độ vật lý thực tế theo hướng x là:

$$V_1 = (10 \text{ pixels})(0.5 \text{ m/pixel})(2 \text{ frames/s})(30 \text{ frames})$$

Dấu của thành phần x của vận tốc thu được bằng cách tính:

$$S_{1x} = \left. \frac{d^2 \text{Re}[g_x(t, a_1)]}{dt^2} \right|_{t=n} \quad (5-125)$$


và:

$$S_{2x} = \left. \frac{d^2 \text{Im}[g_x(t, a_1)]}{dt^2} \right|_{t=n} \quad (5-126)$$


Vì g_x là hình sin nên nó có thể được chứng minh rằng S_{1x} và S_{2x} sẽ có cùng dấu tại một thời điểm tùy ý, n , nếu thành phần vận tốc là dương. Ngược lại, dấu ngược lại S_{1x} và S_{2x} biểu thị thành phần vận tốc âm. Nếu một trong hai S_{1x} hoặc S_{2x} bằng 0, chúng tôi xem xét thời điểm gần nhất tiếp theo $t = n \pm \Delta t$. Nhận xét tương tự áp dụng để tính dấu của V_2 .

VÍ DỤ 5.29: Phát hiện một vật thể chuyển động nhỏ thông qua phân tích miền tần số


Các Hình 5.67 đến 5.69 minh họa tính hiệu quả của phương pháp vừa được phát triển. Hình 5.67 cho thấy một trong chuỗi 32 khung hình của ảnh LandsAT được tạo bằng cách thêm nhiễu trắng vào ảnh tham chiếu. Chuỗi chứa mục tiêu xếp chồng di chuyển ở tốc độ 0,5 điểm ảnh trên mỗi khung hình theo hướng x và 1 điểm ảnh trên mỗi khung hình theo hướng y. Mục tiêu, được khoanh tròn trong Hình 5.68, có phân bố cường độ Gaussian trải rộng trên một vùng nhỏ (9 điểm ảnh) và không dễ dàng nhận thấy bằng mắt. Hình 5.69 cho thấy kết quả tính toán các phương trình (5-121) và (5-122) tương ứng với $a_1 = 6$ và $a_2 = 4$. Đỉnh tại $u_1 = 3$ trong Hình 5.69(a) mang lại $V_1 = 0.5$ từ phương trình (5-123). Tương tự, đỉnh tại $u_2 = 4$ Hình 5.69(b) thu được $V_2 = 1.0$ từ phương trình (5-124).



Hình 5.67 LANDSAT frame



Hình 5.68 Biểu đồ cường độ của hình ảnh trong Hình 5.67, với mục tiêu được khoanh tròn



Hình 5.69 (a) Phổ của phương trình (10-121) hiển thị đỉnh ở $u_1 = 3$ (b) Phổ của phương trình (10-122) thể hiện đỉnh ở $u_2 = 4$.

Hướng dẫn lựa chọn a_1 và a_2 có thể được giải thích bằng Hình 5.69. Ví dụ, giả sử rằng chúng ta đã sử dụng $a_2 = 15$ thay vì $a_2 = 4$. Trong trường hợp đó, các đỉnh trong Hình 5.69(b) bây giờ sẽ là $u_1 = 15$ và 17 vì $V_2 = 1.0$. Đây sẽ là một kết quả có bí danh nghiêm trọng. Như đã trình bày trước đây, hiện tượng răng cưa là do lấy mẫu dưới mức (quá ít khung trong cuộc thảo luận hiện tại, vì phạm vi của u được xác định bởi K). Bởi vì $u = aV$, một khả năng là chọn a làm số nguyên gần nhất với $a = u_{max}/V_{max}$ trong đó u_{max} là giới hạn tần số răng cưa được thiết lập bởi K , và V_{max} là vận tốc tối đa dự kiến của vật thể.

Câu hỏi ôn tập và bài tập

Bài tập 1

Điểm biên được định nghĩa như thế nào? Kỹ thuật phổ biến nhất để phát hiện biên là gì?

Bài tập 2

Thực hiện cài đặt phương pháp tách biên Canny. Đầu vào của hệ thống là một ma trận ảnh đa cấp xám (0-255) và đầu ra là ảnh với chỉ hai loại điểm ảnh, điểm nền có giá trị là 0 và điểm biên có giá trị là 255.

Bài tập 3

Thực hiện tìm ngưỡng tự động với thuật toán Otsu cho bức ảnh I có biểu đồ tần suất sau:

g	0	1	2	3	4	5	6	7	8	9
h(g)	2	3	4	5	7	8	12	47	10	2

Bài tập 4

Một ảnh nhị phân chứa các đường thẳng có hướng ngang, dọc, ở góc 45° và -45° . Hãy đưa ra một bộ 3 ma trận kernel 3×3 có thể được sử dụng để phát hiện đường phân tách độ rộng một pixel giữa những đường này. Giả sử rằng cường độ của các đường và nền là 1 và 0, tương ứng.

Bài tập 5

Đề xuất một kỹ thuật để phát hiện những khoảng trống - gap có độ dài nằm trong khoảng từ 1 đến K pixel giữa các đoạn thẳng của một hình ảnh nhị phân. Giả sử rằng các đường là một pixel dày. Dựa trên phân tích kết nối lân cận-8, thay vì xây dựng kernel để phát hiện những khoảng trống đó.

Chương 6

TRÍCH RÚT ĐẶC TRƯNG

Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu ý nghĩa và ứng dụng của các đặc trưng phù hợp cho xử lý ảnh.
- ✓ Hiểu khái niệm về véc tơ đặc trưng và không gian đặc trưng, cũng như cách liên kết chúng với các đặc tả khác nhau của ảnh mà được phát triển trong chương này.
- ✓ Nắm vững một số công cụ toán học được sử dụng trong một số thuật toán trích rút đặc trưng.
- ✓ Làm quen thuộc với các hạn chế của các phương pháp trích rút đặc trưng được trình bày.
- ✓ Hiểu các bước chính được sử dụng trong việc giải quyết các bài toán trích rút đặc trưng.
- ✓ Có khả năng xây dựng/phát triển một số thuật toán trích rút đặc trưng.
- ✓ Có "cảm giác (feel)" về các loại đặc trưng nhất định mà có khả năng áp dụng được trong ứng dụng cụ thể.

6.1. Cơ sở của trích chọn đặc trưng

Sau khi một hình ảnh được phân đoạn thành các vùng hoặc ranh giới của chúng bằng các phương pháp như đã đề cập ở chương trước, tập hợp các điểm ảnh được phân đoạn thu được thường phải được chuyển đổi thành dạng phù hợp để xử lý tiếp theo trên máy tính. Thông thường, sau khi phân đoạn là trích rút đặc trưng, bao gồm phát hiện đặc trưng và mô tả đặc trưng. Phát hiện đặc trưng đề cập đến việc tìm kiếm các đặc trưng trong một hình ảnh, vùng hoặc ranh giới. Mô tả tính năng gán các thuộc tính định lượng cho các tính năng được phát hiện. Ví dụ: chúng ta có thể phát hiện các góc trong ranh giới vùng và mô tả các góc đó theo hướng và vị trí của chúng, cả hai đều là thuộc tính định lượng. Các phương pháp xử lý đặc trưng được thảo luận trong chương này được chia thành ba loại chính, tùy thuộc vào việc chúng có thể áp dụng cho ranh giới, vùng hay toàn bộ hình ảnh hay không. Một số tính năng có thể áp dụng cho nhiều danh mục. Các bộ mô tả đối tượng tốt là các mô mô tả mà ít nhạy cảm với các tham số như tỷ lệ, dịch chuyển, quay, chiếu sáng và góc nhìn. Các mô tả được thảo luận trong chương này ít nhạy cảm hoặc có thể được chuẩn hóa để bù cho các biến thể trong một hoặc nhiều tham số này.

Mặc dù không có định nghĩa chính thức, được chấp nhận rộng rãi về những gì tạo nên một đặc trưng hình ảnh, nhưng có rất ít lập luận cho rằng, bằng trực giác, chúng ta thường nghĩ về một đặc trưng như một thuộc tính hoặc mô tả đặc biệt về “thứ gì đó” mà chúng ta muốn gán nhãn hoặc phân biệt. Đối với mục đích của chúng ta, các từ khóa ở đây là nhãn và phân biệt. “Cái gì đó” được quan tâm trong chương này đề cập đến các đối tượng hình ảnh riêng lẻ hoặc thậm chí là toàn bộ hình ảnh hoặc bộ hình ảnh. Do đó, chúng ta coi các đặc trưng là các thuộc tính sẽ giúp gán nhãn duy nhất cho các đối tượng trong một hình ảnh hoặc nói chung hơn là sẽ có giá trị trong việc phân biệt giữa toàn bộ hình ảnh hoặc nhóm hình ảnh.

Có hai khía cạnh chính của việc trích rút đặc trưng ảnh: phát hiện đặc trưng và mô tả đặc trưng. Nghĩa là, khi chúng ta đề cập đến việc trích rút đặc trưng, chúng ta đang đề cập đến cả việc phát hiện các đặc trưng và sau đó mô tả chúng. Để có ích, quá trình trích rút phải bao gồm cả hai. Thuật ngữ chúng ta có thể gặp trong quá trình xử lý và phân tích hình ảnh để mô tả việc phát hiện và mô tả đối tượng có thể khác nhau, nhưng một ví dụ đơn giản sẽ giúp làm rõ việc chúng ta sử dụng các thuật ngữ này. Giả sử chúng ta sử dụng các góc của đối tượng làm đối tượng cho một số tác vụ xử lý ảnh. Trong chương này, việc phát hiện đề cập đến việc tìm các góc trong một vùng hoặc hình ảnh. Mặt khác, mô tả đề cập đến việc gán các

thuộc tính định lượng cho các đặc trưng được phát hiện, chẳng hạn như hướng góc và vị trí so với các góc khác. Nói cách khác, việc biết rằng có các góc trong một hình ảnh sẽ bị hạn chế sử dụng nếu không có thông tin bổ sung có thể giúp chúng ta phân biệt giữa các đối tượng trong hình ảnh hoặc giữa các hình ảnh, dựa trên các góc và thuộc tính của chúng.

Vì chúng ta muốn sử dụng các đặc trưng cho mục đích phân biệt, câu hỏi tiếp theo là: Những đặc trưng quan trọng mà các đặc trưng này phải có trong lĩnh vực xử lý hình ảnh kỹ thuật số là gì? Chúng ta đã quen thuộc với một số đặc trưng này. Nói chung, các đặc trưng phải độc lập với vị trí, góc quay và tỷ lệ. Các yếu tố khác, chẳng hạn như tính độc lập của mức độ chiếu sáng và những thay đổi do góc nhìn giữa (các) cảm biến hình ảnh và cảnh, cũng rất quan trọng. Bất cứ khi nào có thể, nên sử dụng tiền xử lý để chuẩn hóa hình ảnh đầu vào trước khi trích rút đặc trưng. Ví dụ: trong các tình huống mà những thay đổi về độ chiếu sáng đủ nghiêm trọng để gây khó khăn trong việc phát hiện đặc trưng, việc tiền xử lý hình ảnh để bổ sung cho những thay đổi đó sẽ là hợp lý. Sự cân bằng hoặc đặc tả biểu đồ được nghĩ đến như những kỹ thuật tự động mà chúng ta biết là hữu ích trong vấn đề này. Ý tưởng là sử dụng càng nhiều thông tin tiên nghiệm càng tốt để tiền xử lý hình ảnh nhằm cải thiện cơ hội trích rút đặc trưng chính xác.

Khi được sử dụng trong ngữ cảnh của một đối tượng, từ “độc lập” thường có một trong hai nghĩa: bất biến hoặc hiệp biến. Một bộ mô tả đối tượng là bất biến đối với một tập hợp các phép biến đổi nếu giá trị của nó không thay đổi sau khi áp dụng (đối với thực thể được mô tả) của bất kỳ phép biến đổi nào từ họ. Bộ mô tả đối tượng là hiệp biến đối với một tập hợp các phép biến đổi nếu áp dụng cho thực thể bất kỳ phép biến đổi nào từ tập hợp đó đều tạo ra cùng một kết quả trong bộ mô tả. Ví dụ: hãy xem xét tập hợp các phép biến đổi affine này: và giả sử rằng chúng ta có một vùng hình elip mà chúng ta gán vùng mô tả đối tượng. Rõ ràng, việc áp dụng bất kỳ phép biến đổi nào vào vùng này sẽ không làm thay đổi diện tích của nó. Do đó, diện tích là một bộ mô tả đặc trưng bất biến đối với họ các phép biến đổi đã cho. Tuy nhiên, nếu chúng ta thêm tỷ lệ biến đổi affine vào họ, vùng mô tả sẽ không còn bất biến đối với họ mở rộng. Bộ mô tả bây giờ là hiệp biến đối với chúng, bởi vì việc chia tỷ lệ diện tích của vùng theo bất kỳ hệ số nào sẽ chia tỷ lệ giá trị của bộ mô tả theo cùng một hệ số. Tương tự, hướng của bộ mô tả (của trục chính của vùng) là hiệp biến vì việc xoay vùng theo bất kỳ góc nào đều có tác động tương tự đến giá trị của bộ mô tả. Hầu hết các mô tả đặc trưng mà chúng ta sử dụng trong chương này nói chung đều có tính hiệp biến, theo nghĩa là chúng có thể bất biến đối với một số phép biến đổi được quan tâm, nhưng không bất biến đối với các phép biến đổi khác có thể quan trọng tương đương. Như chúng ta sẽ thấy ngay sau đây, cách tốt nhất là bình thường hóa càng nhiều bất biến liên quan ra khỏi hiệp phương sai càng tốt. Ví dụ: chúng ta có thể bù cho những thay đổi về hướng của một vùng bằng cách tính toán hướng thực tế của nó và xoay vùng sao cho trục chính của nó hướng theo một hướng được xác định trước. Nếu chúng ta làm điều này cho mọi vùng được phát hiện trong một hình ảnh, phép quay sẽ không còn mang tính hiệp biến.

Một phân loại chủ yếu khác của các đặc trưng là cục bộ và toàn cục. Chúng ta có thể thấy nhiều nỗ lực khác nhau nhằm phân loại các đối tượng thuộc một trong hai loại này. Điều gây khó khăn cho việc này là một đặc trưng có thể thuộc về cả hai, tùy thuộc vào ứng dụng. Ví dụ: hãy xem xét lại vùng mô tả và giả sử rằng chúng ta đang áp dụng nó vào nhiệm vụ kiểm tra mức độ chai đi chuyển qua cảm biến hình ảnh trên dây chuyền sản xuất có chứa đầy chất lỏng hay không. Cảm biến và phần mềm đi kèm có khả năng tạo ra hình ảnh của mười chai cùng một lúc, trong đó chất lỏng trong mỗi chai xuất hiện dưới dạng vùng sáng và phần còn lại của hình ảnh xuất hiện dưới dạng nền tối. Diện tích của một vùng trong hình học cổ định này tỷ lệ thuận với lượng chất lỏng trong chai và nếu được phát hiện và đo một cách đáng tin cậy, diện tích là đặc điểm duy nhất chúng ta cần để giải quyết vấn đề kiểm tra. Mỗi hình ảnh có mười vùng, vì vậy chúng ta coi vùng là một đặc điểm cục bộ, theo nghĩa là nó có thể

áp dụng cho các phần tử (vùng) riêng lẻ của hình ảnh. Nếu vấn đề là phát hiện tổng lượng (diện tích) chất lỏng trong một hình ảnh, thì bây giờ chúng ta sẽ coi vùng là một bộ mô tả tổng thể. Nhưng câu chuyện chưa dừng tại đó. Giả sử nhiệm vụ kiểm tra chất lỏng được xác định lại để tính toán toàn bộ lượng chất lỏng đi qua trạm hình ảnh mỗi ngày. Chúng ta không còn quan tâm đến diện tích của từng vùng riêng lẻ nữa. Đơn vị của chúng ta bây giờ là hình ảnh. Nếu chúng ta biết tổng diện tích của một hình ảnh và biết số lượng hình ảnh thì việc tính toán tổng lượng chất lỏng trong một ngày là chuyện dễ giải quyết. Giờ đây, diện tích của toàn bộ hình ảnh là một đặc điểm cục bộ và diện tích của tổng thể vào cuối ngày là toàn cục. Rõ ràng, chúng ta có thể xác định lại nhiệm vụ sao cho vùng vào cuối ngày trở thành bộ mô tả đặc trưng cục bộ và vùng dành cho tất cả các dây chuyền lắp ráp trở thành thước đo toàn cục. Và cứ thế, vô tận. Trong chương này, chúng ta gọi một đối tượng cục bộ nếu nó được áp dụng cho một thành viên của một tập hợp và là toàn cục nếu nó áp dụng cho toàn bộ tập hợp, trong đó “thành viên” và “tập hợp” được xác định bởi ứng dụng.

Bản thân các đặc trưng hiếm khi được tạo ra cho con người sử dụng, ngoại trừ trong các ứng dụng như xử lý hình ảnh tương tác, những chủ đề không nằm trong chủ đề chính của cuốn giáo trình này. Trong thực tế, như chúng ta sẽ thấy sau, một số phương pháp trích rút đặc trưng tạo ra hàng chục, hàng trăm hoặc thậm chí hàng nghìn giá trị mô tả mà có vẻ như vô nghĩa nếu xem xét bằng mắt. Thay vào đó, mô tả đặc trưng thường được sử dụng làm bước tiền xử lý cho các tác vụ cấp cao hơn, chẳng hạn như đăng ký hình ảnh, nhận dạng đối tượng để kiểm tra tự động, tìm kiếm các mẫu (ví dụ: từng khuôn mặt và/hoặc dấu vân tay) trong cơ sở dữ liệu hình ảnh và các ứng dụng tự động, chẳng hạn như robot và điều hướng phương tiện. Đối với các ứng dụng này, các đặc trưng số thường được “đóng gói” dưới dạng một véc tơ đặc trưng (tức là ma trận $1 \times n$ hoặc $n \times 1$) có các phần tử là bộ mô tả. Hình ảnh RGB là một trong những ví dụ đơn giản nhất. Như chúng ta đã biết, mỗi điểm ảnh của hình ảnh RGB có thể được biểu diễn dưới dạng véc tơ 3-D,

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

trong đó x_1 là giá trị cường độ của ánh sáng đỏ tại một điểm và các thành phần khác là giá trị cường độ của ánh sáng xanh lục và xanh lam tại cùng một điểm. Nếu màu được sử dụng làm đặc điểm thì một vùng trong ảnh RGB sẽ được biểu diễn dưới dạng tập hợp các véc tơ đặc trưng (điểm) trong không gian 3-D. Khi n bộ mô tả được sử dụng, các véc tơ đặc trưng sẽ trở thành n chiều và không gian chứa chúng được gọi là không gian đặc trưng n chiều. Chúng ta có thể “hình dung” một tập hợp các véc tơ đặc trưng n chiều dưới dạng “siêu đám mây” các điểm trong không gian Euclide n chiều.

Trong chương này, chúng ta nhóm các đặc điểm thành ba loại chính: các đặc điểm ranh giới, vùng và toàn bộ hình ảnh. Việc chia nhỏ này không dựa trên khả năng áp dụng của các phương pháp mà chúng ta sắp thảo luận; đúng hơn, nó dựa trên thực tế là một số danh mục có ý nghĩa hơn những danh mục khác khi được xem xét trong bối cảnh của những gì đang được mô tả. Ví dụ: có nghĩa là khi chúng ta đề cập đến “độ dài của một ranh giới” thì chúng ta đang đề cập đến “độ dài của ranh giới của một vùng”, nhưng sẽ vô nghĩa khi đề cập đến “độ dài” của một hình ảnh. Sẽ trở nên rõ ràng rằng nhiều đặc điểm mà chúng ta sẽ thảo luận có thể áp dụng cho các ranh giới và vùng, đồng thời một số đặc điểm cũng áp dụng cho toàn bộ hình ảnh.


6.2. Tiền xử lý biên

Các kỹ thuật phân đoạn được thảo luận trong hai chương trước mang lại dữ liệu thô ở dạng điểm ảnh dọc theo ranh giới hoặc các điểm ảnh không chứa trong một vùng. Thông lệ tiêu chuẩn là sử dụng các lược đồ thu gọn dữ liệu được phân đoạn thành các biểu diễn để tạo điều kiện thuận lợi cho việc tính toán các bộ mô tả. Trong phần này, chúng ta thảo luận về các

phương pháp tiền xử lý biên khác nhau phù hợp cho mục đích này.

6.2.1. Theo dõi biên

Một số thuật toán được thảo luận trong chương này yêu cầu các điểm trong ranh giới của một vùng được sắp xếp theo chiều kim đồng hồ hoặc ngược chiều kim đồng hồ. Do đó, chúng ta bắt đầu thảo luận bằng cách giới thiệu một thuật toán theo ranh giới có đầu ra là một chuỗi các điểm có thứ tự. Chúng ta giả sử (1) rằng chúng ta đang làm việc với các ảnh nhị phân trong đó đối tượng và điểm nền được gán nhãn tương ứng là 1 và 0; và (2) hình ảnh đó được đệm bằng đường viền bằng 0 để loại trừ khả năng đối tượng hợp nhất với đường viền hình ảnh. Để rõ ràng, chúng ta giới hạn cuộc thảo luận ở các vùng riêng lẻ. Cách tiếp cận này được mở rộng đến nhiều vùng riêng biệt bằng cách xử lý từng vùng riêng lẻ.




Hình 6.1 Minh họa một số bước đầu tiên trong thuật toán theo ranh giới. Điểm cần xử lý tiếp theo được dán nhãn đậm, màu đen; các điểm chưa được xử lý có màu xám; và các điểm được thuật toán tìm thấy được tô bóng. Hình vuông không có nhãn được coi là giá trị nền (0).

Thuật toán sau đây dò tìm ranh giới của vùng có giá trị 1, R , trong ảnh nhị phân.

1. Đặt điểm bắt đầu b_0 là điểm trên cùng bên trái trong ảnh được gán nhãn 1. Biểu thị c_0 là điểm lân cận phía tây của b_0 [xem Hình 6.1(b)]. Rõ ràng, c_0 luôn luôn là một điểm nền. Kiểm tra 8 điểm lân cận của b_0 bắt đầu từ c_0 và tiến hành theo chiều kim đồng hồ. Đặt b_1 biểu thị hàng xóm đầu tiên gặp phải có giá trị là 1 và gọi c_1 là điểm (nền) ngay trước đó trong chuỗi. Lưu trữ các vị trí b_0 sử dụng ở Bước 5.
2. Đặt $b = b_0$ và $c = c_0$
3. Giả sử 8 hàng xóm của b , bắt đầu từ c và tiến hành theo chiều kim đồng hồ, được ký hiệu là $n_1, n_2, \dots, n_8$. Tìm hàng xóm đầu tiên có nhãn 1 và ký hiệu nó bằng n_k .
4. Đặt $b = n_k$ và $c = n_{k-1}$
5. Lặp lại bước 3 và 4 đến khi $b = b_0$. Dãy b điểm tìm được khi thuật toán dừng là tập hợp các điểm biên có thứ tự.

Lưu ý rằng c ở Bước 4 luôn là điểm nền vì là điểm có giá trị 1 đầu tiên được tìm thấy khi quét theo chiều kim đồng hồ. Thuật toán này được gọi là thuật toán dò ranh giới Moore theo tên Edward F. Moore.



Hình 6.2 Ví dụ về các ranh giới có thể được xử lý bằng thuật toán theo ranh giới. (a) Ranh giới khép kín với một nhánh. (b) Ranh giới tự giao nhau. (c) Nhiều ranh giới (được xử lý

từng ranh giới một).

Nếu chúng ta bắt đầu với một vùng nhị phân thay vì một ranh giới, thuật toán sẽ trích xuất ranh giới bên ngoài của vùng. Thông thường, ranh giới kết quả sẽ dày một điểm ảnh, nhưng không phải lúc nào cũng như vậy. Nếu mục tiêu là tìm ranh giới của các lỗ trong một vùng (chúng được gọi là ranh giới bên trong hoặc bên trong của vùng), thì cách tiếp cận đơn giản là trích rút các lỗ và xử lý chúng như các vùng có giá trị 1 trên một nền số 0. Áp dụng thuật toán theo ranh giới cho các vùng này sẽ mang lại ranh giới bên trong của vùng ban đầu.

Chúng ta có thể phát biểu thuật toán một cách dễ dàng dựa trên việc tuân theo một ranh giới theo hướng ngược chiều kim đồng hồ nhưng chúng ta sẽ thấy dễ dàng hơn khi chỉ có một thuật toán và sau đó đảo ngược thứ tự của kết quả để thu được một chuỗi theo hướng ngược lại. Chúng ta sử dụng cả hai hướng thay thế cho nhau (nhưng nhất quán) trong các phần sau để làm quen với cả hai cách tiếp cận.


6.2.2. Mã chuỗi - chain codes

Mã chuỗi được sử dụng để thể hiện ranh giới bằng một chuỗi các đoạn đường thẳng được kết nối với độ dài và hướng xác định. Trong phần này chúng ta giả định rằng tất cả các đường cong đều đồng, là những đường cong đơn giản (tức là những đường cong khép kín và không tự cắt nhau).

6.2.2.1. Mã chuỗi Freeman

Thông thường, việc biểu diễn mã chuỗi dựa trên khả năng kết nối 4 hoặc 8 của các phân đoạn. Hướng của mỗi đoạn được mã hóa bằng cách sử dụng sơ đồ đánh số, như trong Hình 6.3. Mã ranh giới được hình thành dưới dạng một chuỗi các số định hướng như vậy được gọi là mã chuỗi Freeman.

a b




Hình 6.3 Số hướng cho (a) mã chuỗi 4 hướng và (b) mã chuỗi 8 hướng.

Hình ảnh kỹ thuật số thường được thu thập và xử lý ở định dạng lưới với khoảng cách bằng nhau theo hướng x và y, do đó, mã chuỗi có thể được tạo bằng cách tuân theo một ranh giới theo chiều kim đồng hồ và gán hướng cho các phân đoạn kết nối mọi hình ảnh. cặp điểm ảnh. Mức độ chi tiết này thường không được sử dụng vì hai lý do chính: (1) Chuỗi kết quả sẽ khá dài và (2) bất kỳ sự xáo trộn nhỏ nào dọc theo ranh giới do nhiễu hoặc phân đoạn không hoàn hảo sẽ gây ra những thay đổi trong mã có thể không liên quan tới các đặc điểm hình dạng chính của ranh giới.

Một cách tiếp cận được sử dụng để giải quyết những vấn đề này là lấy mẫu lại đường biên bằng cách chọn khoảng cách lưới lớn hơn, như trong Hình 6.4(a). Sau đó, khi đường biên được đi qua, một điểm biên được gán cho một nút của lưới thô hơn, tùy thuộc vào độ gần của điểm biên ban đầu với nút đó, như trong Hình 6.4(b). Ranh giới được lấy mẫu lại thu được theo cách này có thể được biểu thị bằng mã 4 hoặc 8. Hình 6.4(c) cho thấy các điểm biên thô hơn được biểu thị bằng mã chuỗi 8 hướng. Việc chuyển đổi từ mã 8 sang mã 4 và ngược lại là một vấn đề đơn giản. Vì lý do tương tự đã đề cập khi thảo luận về việc dò tìm ranh giới trước đó trong phần này, chúng ta đã chọn điểm bắt đầu trong Hình 6.4(c) làm điểm trên cùng bên trái của ranh giới, mang lại mã chuỗi 0766...1212. Như chúng ta có thể

nghe ngò, khoảng cách của lưới lấy mẫu lại được xác định bởi ứng dụng sử dụng mã chuỗi:



Hình 6.4 (a) Ranh giới rời rạc (digital) với lưới lấy mẫu lại được xếp chồng lên nhau. (b) Kết quả lấy mẫu lại. (c) Ranh giới mã hóa chuỗi 8 hướng.

Nếu lưới lấy mẫu được sử dụng để thu được đường cong rời rạc (digital) được kết nối là một tứ giác đều (xem Hình 2.19), thì tất cả các điểm của mã Freeman dựa trên Hình 6.3 đều được đảm bảo trùng với các điểm của đường cong. Điều tương tự cũng đúng nếu một đường cong rời rạc (digital) được lấy mẫu phụ bằng cách sử dụng cùng một loại lưới lấy mẫu, như trong Hình 6.4(b). Điều này là do các mẫu đường cong được tạo bằng cách sử dụng các lưới như vậy có cùng cách sắp xếp như trong Hình 6.3, do đó tất cả các điểm đều có thể truy cập được khi chúng ta đi qua một đường cong từ điểm này sang điểm tiếp theo để tạo mã.


Giá trị số của mã chuỗi phụ thuộc vào điểm bắt đầu. Tuy nhiên, mã có thể được chuẩn hóa theo điểm bắt đầu bằng một quy trình đơn giản: Chúng ta chỉ cần coi mã chuỗi là một chuỗi tròn các số hướng và xác định lại điểm bắt đầu sao cho chuỗi số kết quả tạo thành một số nguyên có độ lớn tối thiểu. Chúng ta cũng có thể chuẩn hóa phép quay (trong các góc là bội số nguyên của các hướng trong Hình 6.3) bằng cách sử dụng sai phân đầu tiên của mã chuỗi thay vì chính mã đó. Sự khác biệt này có được bằng cách đếm số lần thay đổi hướng (theo hướng ngược chiều kim đồng hồ trong Hình 6.3) để phân tách hai phần tử liên tiếp của mã. Nếu chúng ta coi mã như một chuỗi vòng tròn để chuẩn hóa nó theo điểm bắt đầu, thì phần tử đầu tiên của chênh lệch sẽ được tính bằng cách sử dụng phép chuyển đổi giữa thành phần cuối cùng và thành phần đầu tiên của chuỗi. Ví dụ: điểm khác biệt đầu tiên của mã chuỗi 4 hướng 10103322 là 3133030. Có thể đạt được việc chuẩn hóa kích thước bằng cách thay đổi khoảng cách của lưới lấy mẫu lại.

Việc chuẩn hóa vừa thảo luận chỉ chính xác nếu bản thân các ranh giới là bất biến đối với phép quay (một lần nữa, trong các góc là bội số nguyên của các hướng trong Hình 6.3) và sự thay đổi tỷ lệ, điều này hiếm khi xảy ra trong thực tế. Ví dụ, cùng một đối tượng được số hóa theo hai hướng khác nhau sẽ có hình dạng đường biên khác nhau nói chung, với mức độ khác nhau tỷ lệ thuận với độ phân giải của hình ảnh. Hiệu ứng này có thể được giảm bằng cách chọn các phần tử chuỗi dài tương ứng với khoảng cách giữa các điểm ảnh trong ảnh số hóa và/hoặc bằng cách định hướng lưới lấy mẫu lại dọc theo trục chính của đối tượng được mã hóa, hoặc dọc theo trục riêng của nó.

VÍ DỤ 6.1 Mã chuỗi Freeman và một số biến thể của nó

Hình 6.5(a) hiển thị một hình ảnh 570×570 thang độ xám 8 bit của một nét tròn được nhúng trong các mảnh gương nhỏ, phân bố ngẫu nhiên. Mục tiêu của ví dụ này là thu được mã chuỗi Freeman, số nguyên tương ứng có độ lớn tối thiểu và hiệu đầu tiên của ranh giới bên ngoài của nét. Bởi vì đối tượng quan tâm được nhúng trong các mảnh nhỏ nên việc trích rút ranh giới của nó sẽ dẫn đến một đường cong nhiễu không mô tả được hình dạng chung của đối tượng. Như chúng ta đã biết, làm mịn là một quá trình thường xuyên khi làm việc với các ranh giới nhiễu. Hình 6.5(b) hiển thị ảnh gốc được làm mịn bằng cách sử dụng nhân hộp có kích thước điểm ảnh và Hình 6.5(c) là kết quả của việc đặt ngưỡng cho ảnh này với

ngưỡng tổng thể thu được bằng cách sử dụng phương pháp Otsu. Lưu ý rằng số vùng đã giảm xuống còn hai (một trong số đó là dấu chấm), giúp đơn giản hóa đáng kể vấn đề.



Hình 6.5 (a) Ảnh nhiễu có kích thước 570×570 điểm ảnh. (b) Ảnh được làm mịn bằng nhân hộp (box kernel). (c) Ảnh được làm mịn, lấy ngưỡng bằng phương pháp Otsu. (d) Ranh giới ngoài dài nhất của (c). (e) Ranh giới lấy mẫu phụ (các điểm được hiển thị phóng to cho rõ ràng). (f) Các điểm nối từ (e).

Hình 6.5(d) là ranh giới bên ngoài của vùng trong Hình 6.5(c). Việc lấy trực tiếp mã chuỗi của ranh giới này sẽ dẫn đến một chuỗi dài với các biến thể nhỏ không đại diện cho hình dạng chung của ranh giới, vì vậy chúng ta lấy mẫu lại trước khi lấy mã chuỗi của nó. Điều này làm giảm sự biến đổi không đáng kể. Hình 6.5(e) là kết quả của việc sử dụng lưới lấy mẫu lại với các nút cách nhau 50 điểm ảnh (khoảng 10% chiều rộng hình ảnh) và Hình 6.5(f) là kết quả của việc nối các điểm mẫu bằng các đường thẳng. Phép tính gần đúng đơn giản hơn này vẫn giữ được các đặc điểm chính của ranh giới ban đầu.

Mã chuỗi Freeman 8 hướng của ranh giới đơn giản hóa là:

0 0 0 0 6 0 6 6 6 6 6 6 6 4 4 4 4 4 2 4 2 2 2 2 0 2 2 0 2

Điểm bắt đầu của ranh giới là tại tọa độ (2, 5) trong lưới mẫu con (lưu ý quy ước trước đây gốc của ảnh nằm ở trên cùng, bên trái). Đây là điểm trên cùng bên trái trong Hình 6.5(f). Số nguyên có độ lớn tối thiểu của mã xảy ra trong trường hợp này giống với mã chuỗi:

0 0 0 0 6 0 6 6 6 6 6 6 6 4 4 4 4 4 2 4 2 2 2 2 0 2 2 0 2

Sự khác biệt đầu tiên của mã là:

0 0 0 6 2 6 0 0 0 0 0 0 6 0 0 0 0 0 6 2 6 0 0 0 0 6 2 0 6 2 6

Việc sử dụng mã này để thể hiện ranh giới sẽ giúp giảm đáng kể lượng dữ liệu cần thiết để lưu trữ ranh giới. Ngoài ra, làm việc với mã số cung cấp một cách thống nhất để phân tích hình dạng của đường biên. Cuối cùng, lưu ý rằng ranh giới được lấy mẫu con có thể được phục hồi từ bất kỳ mã nào trước đó.


6.2.2.2. Mã chuỗi dốc - slope chain codes

Việc sử dụng mã chuỗi Freeman thường yêu cầu lấy mẫu lại ranh giới để làm mịn các biến thể nhỏ, một quy trình bao gồm việc xác định lưới và sau đó gán tất cả các điểm ranh giới cho các điểm lân cận gần nhất của chúng trong lưới. Một giải pháp thay thế cho phương pháp này là sử dụng mã chuỗi dốc (slope chain code hay SCC). SCC của đường cong 2-D có được bằng cách đặt các đoạn thẳng có độ dài bằng nhau xung quanh đường cong, với điểm cuối của các đoạn chạm vào đường cong.

Để có được SSC yêu cầu tính toán sự thay đổi độ dốc giữa các đoạn đường liền kề và chuẩn

hóa các thay đổi đối với khoảng thời gian (mở) liên tục. Cách tiếp cận này yêu cầu xác định độ dài của các đoạn đường, trái ngược với mã Freeman, yêu cầu xác định lưới và gán các điểm đường cong đối với nó—một thủ tục phức tạp hơn nhiều. Giống như mã Freeman, SCC độc lập với phép quay, nhưng phạm vi thay đổi độ dốc lớn hơn có thể mang lại sự biểu diễn chính xác hơn khi xoay so với tính độc lập quay của mã Freeman, vốn bị giới hạn ở tám hướng trong Hình 6.3(b). Giống như mã Freeman, SCC độc lập với việc dịch chuyển và có thể được chuẩn hóa khi thay đổi tỷ lệ.

Hình 6.6 minh họa cách tạo ra SCC. Bước đầu tiên là chọn độ dài của đoạn đường sẽ sử dụng để tạo mã [xem Hình 6.6(b)]. Tiếp theo, điểm bắt đầu (điểm gốc) được chỉ định (đối với đường cong mở, điểm bắt đầu hợp lý là một trong những điểm cuối của nó). Như Hình 6.6(c) chỉ ra, khi điểm gốc đã được chọn, một đầu của đoạn đường được đặt tại điểm gốc và đầu kia của đoạn được đặt trùng với đường cong. Điểm này trở thành điểm bắt đầu của đoạn đường tiếp theo và chúng ta lặp lại quy trình này cho đến khi đạt đến điểm bắt đầu (hoặc điểm kết thúc trong trường hợp đường cong mở). Như hình minh họa, chúng ta có thể hình dung quá trình này như một chuỗi các đường tròn giống hệt nhau (có bán kính bằng chiều dài của đoạn thẳng) đi qua đường cong. Giao điểm của đường tròn và đường cong xác định các nút của đường thẳng gần đúng với đường cong.



Hình 6.6 (a) Một đường cong mở. (b) Đoạn thẳng. (c) Di chuyển đường cong bằng cách sử dụng chu vi để xác định sự thay đổi độ dốc; dấu chấm là điểm gốc (điểm bắt đầu). (d) Phạm vi thay đổi độ dốc trong khoảng mở (mũi tên ở giữa biểu đồ biểu thị hướng di chuyển). Có thể có mười khoảng con giữa các số độ dốc được hiển thị. (e) Kết quả đường cong được mã hóa hiển thị chuỗi số thay đổi độ dốc tương ứng của nó.

Khi đã biết giao điểm của các đường tròn, chúng ta xác định độ dốc thay đổi giữa các đoạn đường liên tiếp. Thay đổi độ dốc dương và bằng 0 được chuẩn hóa thành khoảng nửa mở $[0,1)$, trong khi thay đổi độ dốc âm được chuẩn hóa thành khoảng mở $(-1,0)$. Không cho phép thay đổi độ dốc giúp loại bỏ các vấn đề triển khai do phải giải quyết thực tế là những thay đổi đó dẫn đến trong cùng một đoạn thẳng có hướng ngược nhau.

Trình tự thay đổi độ dốc là chuỗi xác định xấp xỉ SCC với đường cong ban đầu. Ví dụ, mã cho đường cong trong Hình 6.6(e) là 0.12, 0.20, 0.21, 0.11, -0.11, -0.12, -0.21, -0.22, -0.24, -0.28, -0.28, -0.31, -0.30. Độ chính xác của các thay đổi độ dốc được xác định trong Hình 6.6(d) là 10^{-2} dẫn đến một “bảng chữ cái” gồm 199 ký hiệu có thể có (thay đổi độ dốc). Tất nhiên, độ chính xác có thể được thay đổi. Ví dụ, độ chính xác 10^{-1} tạo ra một bảng chữ cái gồm 19 ký hiệu. Không giống như mã Freeman, không có gì đảm bảo rằng điểm cuối cùng của đường cong được mã hóa sẽ trùng với điểm cuối cùng của đường cong đó. Tuy nhiên, việc rút ngắn độ dài dòng và/hoặc tăng độ phân giải góc thường giải quyết được vấn đề vì kết quả tính toán được làm tròn đến số nguyên gần nhất (hãy nhớ rằng chúng ta làm

việc với tọa độ nguyên).


Nghịch đảo của SCC là một chuỗi khác có cùng độ dài, thu được bằng cách đảo ngược thứ tự của các ký hiệu và dấu hiệu của chúng. Hình ảnh phản chiếu của một chuỗi thu được bằng cách bắt đầu từ gốc và đảo ngược dấu của các ký hiệu. Cuối cùng, chúng ta chỉ ra rằng phân thảo luận trước đó có thể áp dụng trực tiếp cho các đường cong khép kín. Đường cong đi theo sẽ bắt đầu tại một điểm tùy ý (ví dụ: điểm trên cùng bên trái của đường cong) và tiếp tục theo hướng theo chiều kim đồng hồ hoặc ngược chiều kim đồng hồ, dừng lại khi đạt đến điểm bắt đầu. Chúng ta sẽ minh họa việc sử dụng SSC trong Ví dụ 6.6.

6.2.3. Xấp xỉ biên sử dụng đa giác chu vi tối thiểu

Một biên rời rạc (digital boundary) có thể được tính gần đúng với độ chính xác tùy ý bằng một đa giác. Đối với một đường cong khép kín, phép tính gần đúng trở nên chính xác khi số đoạn của đa giác bằng số điểm trên đường biên, do đó mỗi cặp điểm liên tiếp xác định một đoạn của đa giác. Mục tiêu của phép tính gần đúng đa giác là nắm bắt được bản chất của hình dạng trong một ranh giới nhất định bằng cách sử dụng số lượng phân đoạn ít nhất có thể. Nói chung, vấn đề này không hề tầm thường và có thể trở thành một cuộc tìm kiếm lặp đi lặp lại tốn nhiều thời gian. Tuy nhiên, các kỹ thuật gần đúng có độ phức tạp vừa phải lại rất phù hợp cho các tác vụ xử lý ảnh. Trong số này, một trong những cách mạnh mẽ nhất là biểu diễn ranh giới bằng đa giác có chu vi tối thiểu (MPP), như được định nghĩa trong phần thảo luận sau.

6.2.3.1. Cơ sở lý thuyết

Một cách tiếp cận trực quan để tính toán MPP là bao quanh một ranh giới [xem Hình 6.7(a)] bằng một tập hợp các ô được nối, như trong Hình 6.7(b). Hãy coi ranh giới như một sợi dây cao su chứa trong các ô màu xám trong Hình 6.7(b). Khi được phép co lại, dây cao su sẽ bị hạn chế bởi các đỉnh của thành trong và thành ngoài của vùng ô xám. Cuối cùng, sự co lại này tạo ra hình dạng của một đa giác có chu vi tối thiểu (đối với sự sắp xếp hình học này) bao quanh vùng được bao quanh bởi dải ô, như trong Hình 6.7(c). Lưu ý trong hình này rằng tất cả các đỉnh của MPP trùng với các góc của bức tường bên trong hoặc bên ngoài.




Hình 6.7 (a) Một ranh giới đối tượng. (b) Ranh giới được bao bọc bởi các ô (bóng mờ). (c) Đa giác có chu vi tối thiểu thu được bằng cách cho phép ranh giới co lại. Các đỉnh của đa giác được tạo bởi các góc của các bức tường bên trong và bên ngoài của vùng màu xám.

Kích thước của các ô xác định độ chính xác của phép tính gần đúng đa giác. Trong giới hạn, nếu kích thước của mỗi ô (hình vuông) tương ứng với một điểm ảnh trong ranh giới, thì sai số tối đa trong mỗi ô giữa ranh giới và xấp xỉ MPP sẽ là $\sqrt{2}d$ trong đó d là khoảng cách tối thiểu có thể có giữa các điểm ảnh (tức là khoảng cách giữa các điểm ảnh được thiết lập bởi

độ phân giải của ranh giới được lấy mẫu ban đầu). Lỗi này có thể giảm đi một nửa bằng cách buộc mỗi ô trong phép tính gần đúng đa giác phải tập trung vào điểm ảnh tương ứng của nó trong ranh giới ban đầu. Mục tiêu là sử dụng kích thước ô lớn nhất có thể được chấp nhận trong một ứng dụng nhất định, do đó tạo ra MPP với số đỉnh ít nhất. Mục tiêu của chúng ta trong phần này là xây dựng quy trình tìm các đỉnh MPP này.

Phương pháp tế bào vừa được mô tả làm giảm hình dạng của đối tượng được bao quanh bởi ranh giới ban đầu, thành khu vực được bao quanh bởi các bức tường màu xám trong Hình 6.7(b). Hình 6.8(a) cho thấy hình dạng này có màu xám đậm. Giả sử chúng ta đi qua ranh giới của vùng màu xám đậm theo hướng ngược chiều kim đồng hồ. Mỗi lượt gặp trong quá trình truyền tải sẽ là một đỉnh lồi hoặc lõm (góc của một đỉnh được định nghĩa là góc trong của đường biên tại đỉnh đó). Các đỉnh lồi và lõm lần lượt được biểu diễn dưới dạng các chấm tsnaresg và xanh trong Hình 6.8(b). Lưu ý rằng các đỉnh này là các đỉnh của thành trong của vùng giới hạn màu xám nhạt trong Hình 6.8(b) và mọi đỉnh lõm (màu xanh) trong vùng màu xám đậm đều có một đỉnh “gương” lõm tương ứng trong vùng sáng bức tường màu xám, nằm chéo đối diện với đỉnh. Hình 6.8(c) hiển thị gương của tất cả các đỉnh lõm, với MPP từ Hình 6.7(c) được xếp chồng lên nhau để tham khảo. Chúng ta thấy rằng các đỉnh của MPP trùng với các đỉnh lồi ở bức tường bên trong (các chấm tsnaresg) hoặc với các gương của các đỉnh lõm (các chấm màu xanh) ở bức tường bên ngoài. Chỉ các đỉnh lồi của tường trong và các đỉnh lõm của tường ngoài mới có thể là đỉnh của MPP. Vì vậy, thuật toán của chúng ta chỉ cần tập trung sự chú ý vào các đỉnh đó.



Hình 6.8 (a) Vùng (xám đậm) là kết quả của việc bao quanh ranh giới ban đầu bằng các ô (xem Hình 6.7). (b) Các đỉnh lồi (chấm trắng) và lõm (chấm xanh) thu được bằng cách đi theo ranh giới của vùng màu xám đậm theo hướng ngược chiều kim đồng hồ. (c) Các đỉnh lõm (các chấm màu xanh) dịch chuyển đến các vị trí gương chéo của chúng ở bức tường ngoài của vùng giới hạn; các đỉnh lồi không thay đổi. MPP (ranh giới vững chắc) được xếp chồng lên nhau để tham khảo.

6.2.3.2. Thuật toán MPP

Tập hợp các ô bao quanh ranh giới rời rạc (digital) [ví dụ: các ô màu xám trong Hình 6.7(b)] được gọi là phức hợp ô. Chúng ta giả sử các phức hợp tế bào được kết nối đơn giản, theo nghĩa là các ranh giới mà chúng bao quanh không tự giao nhau. Dựa trên giả định này và đề màu tsnaresg (W) biểu thị các đỉnh lồi và màu xanh lam (B) biểu thị các đỉnh lõm được phản chiếu, chúng ta nêu các quan sát sau:

1. MPP được giới hạn bởi một tổ hợp di động được kết nối đơn giản sẽ không tự giao nhau.
2. Mọi đỉnh lồi của MPP đều là đỉnh W, nhưng không phải mọi đỉnh W của ranh giới đều là

đỉnh của MPP.

3. Mọi đỉnh lõm đối xứng của MPP đều là đỉnh B, nhưng không phải mọi đỉnh B của đường biên đều là đỉnh của MPP.

4. Tất cả các đỉnh B đều nằm trên hoặc bên ngoài MPP và tất cả các đỉnh W đều nằm trên hoặc bên trong MPP.

5. Đỉnh trên cùng bên trái trong chuỗi các đỉnh chứa trong tổ hợp ô luôn là đỉnh W của MPP.

Người ta đã chứng minh được những khẳng định này một cách chính thức. Tuy nhiên, tính đúng đắn của chúng là hiển nhiên đối với mục đích của chúng ta (xem Hình 6.8), vì vậy chúng ta không tập trung vào các chứng minh ở đây. Không giống như các góc của các đỉnh của vùng màu xám đậm trong Hình 6.8, các góc được duy trì bởi các đỉnh của MPP không nhất thiết phải là bội số của 90° .

Trong phần thảo luận sau đây, chúng ta sẽ cần tính toán hướng của bộ ba điểm. Xét một bộ ba điểm, (a, b, c) và đặt tọa độ của các điểm này là $a = (a_x, a_y)$, $b = (b_x, b_y)$ và $c = (c_x, c_y)$. Nếu chúng ta sắp xếp các điểm này thành các hàng của ma trận:

$$A = \begin{bmatrix} a_x & a_y & 1 \\ b_x & b_y & 1 \\ c_x & c_y & 1 \end{bmatrix} \quad (6-1)$$

Sau đó, từ phân tích ma trận mà

$$\det(A) = \begin{cases} > 0 \text{ nếu } (a, b, c) \text{ là một dãy ngược chiều kim đồng hồ} \\ 0 \text{ nếu các điểm thẳng hàng} \\ < 0 \text{ nếu } (a, b, c) \text{ là một dãy cùng chiều kim đồng hồ} \end{cases} \quad (6-2)$$

trong đó $\det(A)$ là định thức của A . Theo phương trình này, chuyển động theo hướng ngược chiều kim đồng hồ hoặc theo chiều kim đồng hồ đối với hệ tọa độ thuận tay phải (xem chú thích trong phần thảo luận của Hình 2.19). Ví dụ: sử dụng hệ tọa độ ảnh từ Hình 2.19 (trong đó gốc tọa độ ở trên cùng bên trái, trục x dương kéo dài theo chiều dọc xuống dưới và trục y dương kéo dài theo chiều ngang sang bên phải), chuỗi $a=(3,4)$, $b=(2,3)$ và $c=(3,2)$ nằm trong hướng ngược chiều kim đồng hồ. Điều này sẽ cho khi được thay thế vào phương trình $\det(A) > 0$ (6-2). Thật thuận tiện khi mô tả thuật toán để xác định

$$\text{sgn}(a, b, c) \equiv \det(A) \quad (6-3)$$

sao cho $\text{sgn}(a, b, c) > 0$ với trình tự ngược chiều kim đồng hồ, $\text{sgn}(a, b, c) < 0$ với trình tự theo chiều kim đồng hồ và $\text{sgn}(a, b, c) = 0$ khi các điểm thẳng hàng. Về mặt hình học, $\text{sgn}(a, b, c) > 0$ chỉ ra rằng điểm c nằm ở phía dương của cặp (a, b) (tức là c nằm ở phía dương của đường thẳng đi qua các điểm a và b). Tương tự, $\text{sgn}(a, b, c) < 0$ nếu điểm c nằm ở phía âm của đường thẳng. Các phương trình (6-2) và (6-3) cho kết quả tương tự nếu dãy (c, a, b) hoặc (b, c, a) được sử dụng vì hướng di chuyển trong dãy giống như đối với (a, b, c) . Tuy nhiên, cách giải thích hình học là khác nhau. Ví dụ: $\text{sgn}(c, a, b) > 0$ chỉ ra rằng điểm b nằm ở phía dương của đường thẳng đi qua các điểm c và a .

Để chuẩn bị dữ liệu cho thuật toán MPP, chúng ta tạo một danh sách các bộ ba bao gồm nhãn đỉnh (ví dụ: $V_0, V_1, \dots$); tọa độ của mỗi đỉnh; và một phần tử bổ sung biểu thị đỉnh là W hay B. Điều quan trọng là các đỉnh lõm phải được phản chiếu, như trong Hình 6.8(c), các đỉnh phải theo thứ tự tuần tự và đỉnh đầu tiên phải là đỉnh trên cùng bên trái đỉnh mà chúng ta biết từ tính chất 5 là đỉnh W của MPP. Đặt V_0 biểu thị đỉnh này. Chúng ta giả sử rằng các đỉnh được sắp xếp theo hướng ngược chiều kim đồng hồ. Thuật toán tìm MPP sử dụng hai điểm “trình thu thập thông tin”: trình thu thập thông tin màu tsnaesg (W_c) và trình thu thập

thông tin màu xanh (B_c). W_c bò dọc theo các đỉnh lõm (W) và B_c bò dọc theo các đỉnh lõm (B). Hai điểm thu thập thông tin này, đỉnh MPP cuối cùng được tìm thấy và đỉnh đang được kiểm tra là tất cả những gì cần thiết để thực hiện thuật toán.

Thuật toán bắt đầu bằng cách thiết lập $W_c = B_c = V_0$ (nhớ lại rằng V_0 là đỉnh MPP). Sau đó, tại bất kỳ bước nào trong thuật toán, đặt V_L biểu thị đỉnh MPP cuối cùng được tìm thấy và V_k ký hiệu đỉnh hiện tại đang được kiểm tra. Một trong ba điều kiện sau có thể tồn tại giữa V_L, V_k và hai điểm của trình thu thập thông tin:

- V_k nằm về phía dương của đường thẳng đi qua cặp điểm (V_L, W_c) trong trường hợp đó $\text{sgn}(V_L, W_c, V_k) > 0$.
- V_k nằm ở phía âm của đường thẳng đi qua cặp (V_L, W_c) hoặc thẳng hàng với nó; tức là $\text{sgn}(V_L, W_c, V_k) \leq 0$. Đồng thời V_k nằm về phía dương của đường thẳng đi qua (V_L, B_c) hoặc thẳng hàng với nó; đó là $\text{sgn}(V_L, B_c, V_k) \geq 0$.
- V_k nằm ở phía âm của đường đi qua cặp (V_L, B_c) trong trường hợp đó $\text{sgn}(V_L, B_c, V_k) < 0$.

Nếu điều kiện (a) được giữ, thì đỉnh MPP tiếp theo là W_c và chúng ta đặt $V_L = W_c$; sau đó khởi tạo lại thuật toán bằng cách thiết lập $W_c = B_c = V_L$ và bắt đầu với đỉnh tiếp theo sau đỉnh V_L mới được thay đổi.

Nếu điều kiện (b) được thỏa mãn, V_k sẽ trở thành đỉnh MPP ứng viên. Trong trường hợp này, chúng ta đặt $W_c = V_k$ nếu V_k là lõm (tức là nó là đỉnh W); nếu không thì chúng ta đặt $B_c = V_k$. Sau đó chúng ta tiếp tục với đỉnh tiếp theo trong danh sách.

Nếu điều kiện (c) được giữ, thì đỉnh MPP tiếp theo là B_c và chúng ta đặt $V_L = B_c$, sau đó khởi tạo lại thuật toán bằng cách thiết lập $W_c = B_c = V_L$ và bắt đầu với đỉnh tiếp theo sau đỉnh V_L mới được thay đổi.

Thuật toán dừng lại khi đến đỉnh đầu tiên và do đó đã xử lý tất cả các đỉnh trong đa giác. Các đỉnh V_L được tìm thấy bởi thuật toán là các đỉnh của MPP. Người ta đã chứng minh rằng thuật toán này tìm thấy tất cả các đỉnh MPP của một đa giác được bao bọc bởi một tổ hợp tế bào được kết nối đơn giản.

VÍ DỤ 6.3 Áp dụng thuật toán MPP

Hình 6.9(a) là ảnh nhị phân 566×566 của một chiếc lá phong, và Hình 6.9(b) là ranh giới 8 điểm nối của nó. Trình tự trong hình. 6.9(c) đến (h) hiển thị biểu diễn MMP của ranh giới này bằng cách sử dụng các ô phức hợp ô vuông có kích thước lần lượt là 2, 4, 6, 8, 16 và 32 (các đỉnh trong mỗi hình được nối bằng các đường thẳng để tạo thành một hình khép kín ranh giới). Lá có hai đặc điểm chính: thân và ba thùy chính. Thân cây bắt đầu bị mất khi kích thước tế bào lớn hơn 4×4 như minh họa trong Hình 6.9(e). Ba thùy chính được bảo quản khá tốt, thậm chí đối với kích thước tế bào 16×16 như minh họa trong Hình 6.9(g). Tuy nhiên, chúng ta thấy trong Hình 6.8(h) rằng vào thời điểm kích thước ô được tăng lên đến 32×32 đặc điểm đặc biệt này đã gần như bị mất.




Hình 6.9 (a) ảnh nhị phân 566×566 . (b) ranh giới 8 kết nối. (c) đến (h), MMP thu được bằng cách sử dụng các ô vuông có kích thước lần lượt là 2, 4, 6, 8, 16 và 32 (các đỉnh được nối bằng các đoạn thẳng để hiển thị). Số điểm biên trong (b) là 1900. Số đỉnh trong (c) đến (h) lần lượt là 206, 127, 92, 66, 32 và 13. Hình ảnh (b) đến (h) được hiển thị dưới dạng âm bản để giúp dễ nhìn thấy ranh giới hơn.

Số điểm trong ranh giới ban đầu [Hình 6.9(b)] là 1900. Số đỉnh trong Hình 6.9(c) đến (h) lần lượt là 206, 127, 92, 66, 32 và 13. Hình 6.9(e), có 127 đỉnh, vẫn giữ lại tất cả các đặc điểm chính của ranh giới ban đầu trong khi đạt được mức giảm dữ liệu trên 90%. Vì vậy, ở đây chúng ta thấy một lợi thế đáng kể của MMP trong việc thể hiện ranh giới. Một ưu điểm quan trọng khác là MMP thực hiện làm mịn ranh giới. Như đã giải thích ở phần trước, đây là yêu cầu thông thường khi biểu diễn ranh giới bằng mã chuỗi.

6.2.4. Biên dạng - signature

Biên dạng - signature là biểu diễn hàm 1-D của biên 2-D và có thể được tạo theo nhiều cách khác nhau. Một trong những cách đơn giản nhất là vẽ khoảng cách từ trọng tâm đến đường biên dưới dạng hàm của góc, như minh họa trong Hình 6.10. Ý tưởng cơ bản của việc sử dụng biên dạng là giảm biểu diễn ranh giới thành hàm 1-D có lẽ dễ mô tả hơn ranh giới 2-D ban đầu.



Hình 6.10 Biên dạng theo khoảng cách so với góc. Trong (a), $r(\theta)$ là hằng số. Trong (b), biên dạng bao gồm sự lặp lại của mẫu $r(\theta) = A \sec\theta$ cho $0 \leq \theta \leq \pi/4$ và $r(\theta) = A \csc\theta$ cho $\pi/4 \leq \theta \leq \pi/2$.

cho $\pi/4 \leq \theta \leq \pi/2$.


Dựa trên các giả định về tính đồng nhất trong tỷ lệ đối với cả hai trục và việc lấy mẫu được thực hiện ở các khoảng thời gian bằng nhau khi thay đổi kích thước của hình dạng dẫn đến thay đổi giá trị biên độ của biên dạng tương ứng. Một cách để bình thường hóa điều này là chia tỷ lệ tất cả các hàm sao cho chúng luôn có cùng phạm vi giá trị, ví dụ: $[0, 1]$. Ưu điểm chính của phương pháp này là đơn giản, nhưng nó có nhược điểm là việc chia tỷ lệ của toàn bộ hàm chỉ phụ thuộc vào hai giá trị: cực tiểu và cực đại. Nếu các hình dạng bị nhiễu, đây có thể là nguồn gây ra lỗi đáng kể từ đối tượng này sang đối tượng khác. Một cách tiếp cận chắc chắn hơn (nhưng cũng cần tính toán nhiều hơn) là chia mỗi mẫu cho phương sai của biên dạng, giả sử rằng phương sai khác 0—như trong trường hợp của Hình 6.10(a)—hoặc nhỏ đến mức nó tạo ra phép tính nổi khó khăn. Việc sử dụng phương sai mang lại hệ số tỷ lệ thay đổi tỷ lệ nghịch với những thay đổi về kích thước và hoạt động giống như điều khiển âm lượng tự động. Dù sử dụng phương pháp nào thì ý tưởng trọng tâm là loại bỏ sự phụ thuộc vào kích thước trong khi vẫn giữ được hình dạng cơ bản của dạng sóng.

Khoảng cách so với góc không phải là cách duy nhất để tạo biên dạng. Ví dụ, một cách khác là đi qua đường biên và tương ứng với mỗi điểm trên đường biên, vẽ góc giữa một đường tiếp tuyến với đường biên tại điểm đó và một đường tham chiếu. Biên dạng thu được, mặc dù khá khác so với các đường cong trong Hình 6.10, nhưng mang thông tin về các đặc điểm hình dạng cơ bản. Ví dụ, các đoạn nằm ngang trong đường cong tương ứng với các đường thẳng dọc theo ranh giới vì góc tiếp tuyến ở đó không đổi. Một biến thể của phương pháp này là sử dụng cái gọi là hàm mật độ độ dốc làm dấu hiệu. Hàm này là biểu đồ của các giá trị góc tiếp tuyến. Bởi vì biểu đồ là thước đo mức độ tập trung của các giá trị, hàm mật độ độ dốc phản ứng mạnh mẽ với các phần của ranh giới có các góc tiếp tuyến không đổi (các đoạn thẳng hoặc gần thẳng) và có các thung lũng sâu ở các phần tạo ra các góc thay đổi nhanh chóng (các góc hoặc các điểm uốn sắc nét khác).

VÍ DỤ 6.4 Biên dạng của hai vùng

Hình 6.11(a) và (d) hiển thị hai đối tượng nhị phân và Hình 6.11(b) và (e) là ranh giới của chúng. Các biên dạng $r(\theta)$ tương ứng trong Hình 6.11(c) và (f) nằm trong phạm vi từ 0° tới 360° theo gia số 1° . Số lượng đỉnh nổi bật trong dấu hiệu đủ để phân biệt hình dạng của hai vật thể.

a b c
d e f




Hình 6.11 (a) và (d) Hai vùng nhị phân, (b) và (e) ranh giới bên ngoài của chúng và (c) và (f) biên dạng $r(\theta)$ tương ứng của chúng. Các trục ngang ở (c) và (f) tương ứng với các góc từ 0° tới 360° , với gia số là 1° .

6.2.5. Xương, trục tâm và các phép biến đổi khoảng cách (Skeletons, Medial Axes, and Distance Transforms)

Giống như biên, các bộ khung xương có liên quan đến hình dạng của một vùng. Các bộ khung xương có thể được tính toán từ một ranh giới bằng cách lấp đầy vùng được bao quanh bởi ranh giới với các giá trị tiền cảnh và xử lý kết quả dưới dạng vùng nhị phân. Nói cách khác, một khung được tính toán bằng cách sử dụng tọa độ của các điểm trong toàn bộ vùng, bao gồm cả ranh giới của nó. Ý tưởng là thu gọn một vùng thành một cây hoặc đồ thị bằng cách tính toán khung của nó. Như đã giải thích, khung của một vùng là tập hợp các điểm trong vùng cách đều biên giới của vùng.

Bộ khung xương thu được bằng cách sử dụng một trong hai phương pháp chính: (1) bằng cách làm mỏng vùng liên tiếp (ví dụ: sử dụng xói mòn hình thái) trong khi bảo toàn các điểm cuối và kết nối đường (điều này được gọi là làm mỏng bảo toàn cấu trúc liên kết); hoặc (2) bằng cách tính toán trục trung gian của vùng thông qua triển khai hiệu quả phép biến đổi trục trung gian (hay medial axis transform - MAT). MAT của vùng R có biên B như sau: Với mỗi điểm p trong R , chúng ta tìm lân cận gần nhất của nó trong B . Nếu p có nhiều hơn một lân cận như vậy, nó được cho là thuộc về trục trung gian của R . Khái niệm “gần nhất” (và do đó kết quả là MAT) phụ thuộc vào định nghĩa của thước đo khoảng cách. Hình 6.12 cho thấy một số ví dụ sử dụng khoảng cách Euclide. Nếu khoảng cách Euclide được sử dụng, khung kết quả sẽ giống với những gì thu được bằng cách sử dụng số đĩa tối đa. Bộ khung xương của một vùng được xác định là trục trung gian của nó.




Hình 6.12 Trục trung gian (nét đứt) của ba vùng đơn giản.

MAT của một vùng có cách diễn giải trực quan dựa trên khái niệm “lửa thảo nguyên” được thảo luận trong Phần 6.3 (xem Hình 6.15). Hãy xem vùng hình ảnh như một thảo nguyên có cỏ khô đồng nhất và giả sử rằng một ngọn lửa được thắp sáng đồng thời dọc theo tất cả các điểm trên đường viền của nó. Tất cả các mặt trận hỏa lực sẽ tiến vào khu vực với tốc độ như nhau. MAT của vùng là tập hợp các điểm đạt được bởi nhiều mặt trận cháy cùng một lúc.

Nhìn chung, MAT tiện gần hơn đáng kể so với việc làm mỏng đi để tạo ra những bộ khung xương “có ý nghĩa”. Tuy nhiên, việc tính toán MAT của một vùng yêu cầu tính khoảng cách từ mọi điểm bên trong đến mọi điểm trên đường biên của vùng—một nỗ lực không thực tế trong hầu hết các ứng dụng. Thay vào đó, cách tiếp cận là thu được khung tương đương từ phép biến đổi khoảng cách, trong đó tồn tại nhiều thuật toán hiệu quả.

Biến đổi khoảng cách của một vùng điểm ảnh phía trước trên nền bằng 0 là khoảng cách từ mỗi điểm ảnh đến điểm ảnh có giá trị khác 0 gần nhất. Hình 6.13(a) hiển thị một ảnh nhị phân nhỏ và Hình 6.13(b) là phép biến đổi khoảng cách của nó. Quan sát rằng mọi điểm ảnh có giá trị 1 đều có giá trị biến đổi khoảng cách bằng 0 vì điểm ảnh có giá trị khác 0 gần nhất của nó là chính nó. Với mục đích tìm kiếm các khung tương đương với MAT, chúng ta quan tâm đến khoảng cách từ các điểm ảnh của một vùng điểm ảnh nền trước (màu trắng) đến các điểm ảnh nền (không) gần nhất của chúng, tạo thành ranh giới vùng. Do đó, chúng ta tính toán phép biến đổi khoảng cách của phần bù của hình ảnh, như Hình 6.13(c) và (d) minh họa. Bằng cách so sánh Hình 6.13(d) và 6.12(a), trước đây chúng ta thấy rằng MAT (khung xương) tương đương với đường gờ của biến đổi khoảng cách [tức là đường gờ trong hình

trong Hình 6.13(d)]. Sóng núi này là tập hợp các cực đại cục bộ [được in đậm trong hình 6.13(d)]. Hình 6.13(e) và (f) cho thấy hiệu ứng tương tự trên ảnh nhị phân (414×708) lớn hơn.




Hình 6.13 (a) Một ảnh nhỏ và (b) biến đổi khoảng cách của nó. Lưu ý rằng tất cả các điểm ảnh có giá trị 1 trong (a) đều có số 0 tương ứng trong (b). (c) Một ảnh nhỏ, và (d) phép biến đổi khoảng cách của phần bù của nó. (e) Một hình ảnh lớn hơn và (f) biến đổi khoảng cách của phần bù của nó. Khoảng cách Euclide đã được sử dụng xuyên suốt.

VÍ DỤ 6.5 Bộ khung xương thu được bằng cách tỉa thưa và cắt tỉa so với biến đổi khoảng cách

Hình 6.14(a) hiển thị hình ảnh được phân đoạn của các mạch máu và Hình 6.14(b) hiển thị bộ khung xương thu được bằng cách làm mỏng hình thái. Như chúng ta đã thảo luận trước đây, sự tỉa thưa thường đi kèm với gai nhọn, điều này chắc chắn đúng trong trường hợp này. Hình 6.14(c) cho thấy kết quả của 40 lần loại bỏ cựa. Ngoại trừ một số gai nhỏ có thể nhìn thấy ở phía dưới bên trái của hình ảnh, việc cắt tỉa đã thực hiện công việc hợp lý để làm sạch bộ khung xương. Một nhược điểm của việc làm mỏng là mất đi các tính năng quan trọng tiềm tàng. Đây không phải là trường hợp ở đây, ngoại trừ bộ khung xương được cắt tỉa không bao phủ toàn bộ phạm vi của hình ảnh. Hình 6.14(c) cho thấy bộ khung xương thu được bằng cách sử dụng các tính toán biến đổi khoảng cách dựa trên việc di chuyển nhanh. Cách thuật toán mà chúng ta sử dụng triển khai việc tạo nhánh sẽ tự động xử lý các trường hợp không rõ ràng, chẳng hạn như các nhánh.

a b
c d



Hình 6.14 (a) Hình ảnh ngưỡng của mạch máu. (b) Bộ khung xương thu được bằng cách làm mỏng, được hiển thị chồng lên hình ảnh (lưu ý các cựa). (c) Kết quả của 40 lần loại bỏ cựa. (d) Bộ khung xương thu được bằng cách sử dụng phép biến đổi khoảng cách.

Kết quả trong Hình 6.14(d) tốt hơn một chút so với kết quả trong Hình 6.14(c), nhưng cả hai khung chắc chắn nắm bắt được các đặc điểm quan trọng của hình ảnh trong trường hợp này. Ưu điểm chính của phương pháp làm mỏng là tính đơn giản trong triển khai, điều này có thể quan trọng trong các ứng dụng chuyên dụng. Nhìn chung, các công thức biến đổi khoảng cách có xu hướng tạo ra các khung ít bị gián đoạn hơn, nhưng việc vượt qua gánh nặng tính toán của biến đổi khoảng cách sẽ dẫn đến việc triển khai phức tạp hơn đáng kể so với việc làm mỏng.

6.3. Các bộ mô tả đặc trưng biên

Chúng ta bắt đầu thảo luận về các bộ mô tả đặc điểm bằng cách xem xét một số cách tiếp cận cơ bản để mô tả biên của các vùng.

6.3.1. Một số mô tả biên cơ bản

Độ dài của một ranh giới là một trong những mô tả đơn giản nhất của nó. Số lượng điểm ảnh dọc theo một ranh giới là xấp xỉ độ dài của nó. Đối với một đường cong được mã hóa chuỗi có khoảng cách đơn vị theo cả hai hướng, số lượng thành phần dọc và ngang nhân với số lượng thành phần đường chéo sẽ cho độ dài chính xác của nó. Nếu ranh giới được biểu diễn bằng đường cong đa giác thì chiều dài bằng tổng chiều dài các đoạn đa giác.

Đường kính của ranh giới B được định nghĩa là:

$$diameter(B) = \max_{i,j} [D(p_i, p_j)] \quad (6-4)$$

trong đó D là thước đo khoảng cách và là các điểm trên đường biên. Giá trị của đường kính và hướng của đoạn thẳng nối hai điểm cực trị tạo thành đường kính được gọi là trục chính (hoặc dây cung dài nhất) của đường biên. Nghĩa là, nếu trục chính được xác định bởi các điểm thì độ dài và hướng của trục chính được xác định bởi:

$$length_m = [(x_2 - x_1)^2 + (y_2 - y_1)^2]^{1/2} \quad (6-5)$$

và

$$angle_m = \tan^{-1} \left[\frac{y_2 - y_1}{x_2 - x_1} \right]$$

Trục nhỏ (còn gọi là dây vuông góc dài nhất) của một ranh giới được định nghĩa là đường

thẳng vuông góc với trục chính và có chiều dài sao cho một hình hộp đi qua bốn điểm giao nhau bên ngoài của ranh giới với hai trục bao quanh hoàn toàn đường biên đó. Hộp vừa mô tả được gọi là hình chữ nhật cơ bản hoặc hộp giới hạn và tỷ lệ giữa trục chính và trục phụ được gọi là độ lệch tâm của đường biên. Chúng ta sẽ đưa ra một số ví dụ về mô tả này trong các phần tiếp theo.

Độ cong của một ranh giới được định nghĩa là tốc độ thay đổi của độ dốc. Nói chung, khó có được số đo đáng tin cậy về độ cong tại một điểm của ranh giới rời rạc (digital) thô vì những ranh giới này có xu hướng “rách rưới” cục bộ. Làm mịn có thể hữu ích, nhưng một thước đo chắc chắn hơn về độ cong là sử dụng sự khác biệt giữa độ dốc của các đoạn ranh giới liên kế đã được biểu diễn dưới dạng đường thẳng. Các phép tính gần đúng đa giác rất phù hợp cho cách tiếp cận này [xem Hình 6.8(c)], trong trường hợp đó chúng ta chỉ quan tâm đến độ cong ở các đỉnh. Khi chúng ta đi qua đa giác theo chiều kim đồng hồ, điểm đỉnh p được gọi là lồi nếu độ thay đổi độ dốc tại p là không âm; ngược lại, p được cho là lõm. Mô tả có thể được tinh chỉnh hơn nữa bằng cách sử dụng phạm vi thay đổi độ dốc. Ví dụ: p có thể được gắn nhãn là một phần của đoạn gần như đường thẳng nếu thay đổi tuyệt đối của độ dốc tại điểm đó nhỏ hơn 10° , hoặc nó có thể được gắn nhãn là điểm “giống góc” nếu thay đổi tuyệt đối nằm trong phạm vi $90^\circ, \pm 30^\circ$.

Các bộ mô tả dựa trên sự thay đổi của độ dốc có thể được xây dựng dễ dàng bằng cách biểu thị một ranh giới dưới dạng mã chuỗi độ dốc (SSC), như đã thảo luận trước đó (xem Hình 6.6). Một bộ mô tả ranh giới đặc biệt hữu ích có thể dễ dàng thực hiện bằng cách sử dụng SSC là độ uốn khúc, thước đo độ uốn khúc của một đường cong. Độ uốn khúc của đường cong được biểu thị bằng SCC được định nghĩa là tổng các giá trị tuyệt đối của các phần tử chuỗi:

$$\tau = \sum_{i=1}^n |a_i|$$


trong đó n là số phần tử trong SCC và $|a_i|$ là các giá trị (thay đổi độ dốc) của các phần tử trong mã. Ví dụ tiếp theo minh họa một cách sử dụng mô tả này.

VÍ DỤ 6.6 Sử dụng mã chuỗi dốc để mô tả độ uốn khúc

Một thước đo quan trọng của hình thái mạch máu là độ uốn khúc của nó. Số liệu này có thể hỗ trợ chẩn đoán bệnh võng mạc ở trẻ sinh non (ROP) với sự hỗ trợ của máy tính, một bệnh về mắt ảnh hưởng đến trẻ sinh non. ROP khiến các mạch máu phát triển bất thường ở võng mạc. Sự tăng trưởng này có thể khiến võng mạc tách ra khỏi phía sau mắt, có khả năng dẫn đến mù lòa.

Hình 6.15(a) cho thấy hình ảnh võng mạc (được gọi là hình ảnh đáy mắt) của một em bé sơ sinh. Các bác sĩ nhãn khoa chẩn đoán và đưa ra quyết định về phương pháp điều trị ROP ban đầu dựa trên hình ảnh của các mạch máu võng mạc. Sự giãn nở và tăng độ uốn khúc của các mạch võng mạc là dấu hiệu có khả năng xảy ra ROP cao. Các mạch máu được ký hiệu là A, B và C trong Hình 6.15 đã được chọn để chứng minh khả năng phân biệt của SCC trong việc định lượng tình trạng uốn khúc (mỗi mạch được hiển thị là một vùng dài, mỏng, không phải là một đoạn thẳng).

a b



Curve	n	τ
A	50	2.3770
B	50	2.5132
C	50	1.6285


Hình 6.15 (a) Hình ảnh đáy mắt của một đứa trẻ sinh non mắc ROP. (b) Sự uốn khúc của các mạch máu A, B và C.

Đường viền của mỗi mạch được trích rút và chiều dài của nó (số điểm ảnh), P , đã được tính toán. Để làm cho việc so sánh SCC có ý nghĩa, ba ranh giới đã được chuẩn hóa sao cho mỗi ranh giới sẽ có cùng số lượng đoạn thẳng, m . Độ dài L của đoạn đường sau đó được tính như sau $L=m/P$. Số phần tử của mỗi SCC là $m-1$. Độ uốn khúc, τ của đường cong được biểu thị bằng SCC được định nghĩa là tổng các giá trị tuyệt đối của các phần tử chuỗi, như đã lưu ý trong phương trình (6-6).

Bảng trong Hình 6.15(b) thể hiện các giá trị của τ cho đoạn A, B và C dựa trên 51 đoạn thẳng (như đã lưu ý ở trên, $n=m-1$). Các giá trị của độ uốn khúc phù hợp với phân tích trực quan của chúng ta về ba đoạn, cho thấy B là "bận rộn" hơn một chút so với A, và C là có ít khúc mắc nhất.

6.3.2. Số hình dạng - shape numbers

Số hình dạng của ranh giới được mã hóa chuỗi Freeman, dựa trên mã 4 hướng của Hình 6.3(a), được định nghĩa là sai phân đầu tiên có độ lớn nhỏ nhất. Thứ tự n của một số hình được định nghĩa là số chữ số trong biểu diễn của nó. Hơn nữa, n thậm chí còn dành cho một ranh giới khép kín và giá trị của nó giới hạn số lượng các hình dạng khác nhau có thể có. Hình 6.16 hiển thị tất cả các hình dạng theo thứ tự 4, 6 và 8, cùng với các biểu diễn mã chuỗi, sự khác biệt đầu tiên và số hình dạng tương ứng của chúng. Mặc dù sự khác biệt đầu tiên của mã chuỗi 4 hướng không phụ thuộc vào việc xoay, ranh giới được mã hóa nói chung phụ thuộc vào hướng của lưới. Một cách để bình thường hóa hướng lưới là căn chỉnh lưới mã chuỗi với các cạnh của hình chữ nhật cơ bản được xác định trong phần trước.




Hình 6.16 Tất cả các hình dạng theo thứ tự 4, 6 và 8. Các hướng được lấy từ Hình 6.3(a) và dấu chấm biểu thị điểm bắt đầu.

Trong thực tế, đối với thứ tự hình dạng mong muốn, chúng ta tìm hình chữ nhật có thứ tự n có độ lệch tâm (được xác định trong Phần 6.4) gần đúng nhất với hình chữ nhật cơ bản và sử dụng hình chữ nhật mới này để thiết lập kích thước lưới. Ví dụ: nếu $n = 12$ tất cả các hình chữ nhật theo thứ tự 12 (nghĩa là những hình có chiều dài chu vi là 12) đều có kích thước $2 \times 4, 3 \times 3, 1 \times 5$. Nếu độ lệch tâm của hình chữ nhật phù hợp nhất với độ lệch tâm của hình chữ nhật cơ bản đối với một ranh giới nhất định, chúng ta sẽ thiết lập một lưới 2×4 có tâm trên hình chữ nhật cơ bản và sử dụng quy trình được nêu trong Phần 6.2 để lấy mã chuỗi Freeman. Số hình dạng theo sau sự khác biệt đầu tiên của mã này. Mặc dù thứ tự của số lượng hình dạng thu được thường bằng n do cách chọn khoảng cách lưới, các ranh giới có độ lõm tương đương với khoảng cách này đôi khi mang lại số lượng hình dạng có thứ tự lớn hơn n . Trong trường hợp này, chúng ta chỉ định một hình chữ nhật có bậc thấp hơn n và lặp lại quy trình cho đến khi số hình thu được có bậc n . Thứ tự của số hình bắt đầu từ 4 và luôn chẵn vì chúng ta đang làm việc với kết nối 4 và yêu cầu các ranh giới đó phải đóng lại.

VÍ DỤ 6.7 Tính số hình dạng

Giả sử điều đó được xác định cho ranh giới trong Hình 6.17(a). Để có được số hình dạng theo thứ tự này, chúng ta làm theo các bước vừa thảo luận. Đầu tiên, chúng ta tìm hình chữ nhật cơ bản, như trong Hình 6.17(b). Tiếp theo chúng ta tìm hình chữ nhật gần nhất có cấp độ 18. Nó là một hình chữ nhật 3×6 , yêu cầu chia nhỏ hình chữ nhật cơ bản như trong Hình 6.17(c). Các hướng mã chuỗi được căn chỉnh với lưới kết quả. Bước cuối cùng là lấy mã chuỗi và sử dụng sai phân đầu tiên của nó để tính số hình dạng, như trong Hình 6.17(d).

a b
c d



Chain code: 0 0 0 0 3 0 0 3 2 2 3 2 2 2 1 2 1 1
Difference: 3 0 0 0 3 1 0 3 3 0 1 3 0 0 3 1 3 0
Shape no.: 0 0 0 3 1 0 3 3 0 1 3 0 0 3 1 3 0 3


Hình 6.17 Các bước tạo số hình dạng.

6.3.3. Bộ mô tả Fourier - Fourier descriptors

Hình 6.18 cho thấy một ranh giới số trong mặt phẳng xy, bao gồm K điểm. Bắt đầu từ một điểm (x_0, y_0) tùy ý, các cặp tọa độ $(x_0, y_0), (x_1, y_1), (x_2, y_2), \dots, (x_{K-1}, y_{K-1})$ sẽ gặp khi đi qua ranh giới, chẳng hạn, theo hướng ngược chiều kim đồng hồ. Các tọa độ này có thể được biểu diễn dưới dạng $x(k) = x_k$ và $y(k) = y_k$. Sử dụng ký hiệu này, bản thân ranh giới có thể được biểu diễn dưới dạng chuỗi tọa độ $s(k) = [x(k), y(k)]$ với $k = 0, 1, 2, \dots, K - 1$. Hơn nữa, mỗi cặp tọa độ có thể được coi là một số phức sao cho với $k = 0, 1, 2, \dots, K - 1$. Nghĩa là, trục x được coi là trục thực và trục y là trục ảo của một chuỗi số phức. Mặc dù cách giải thích trình tự đã được trình bày lại nhưng bản chất của ranh giới vẫn không thay đổi. Tất nhiên, cách biểu diễn này có một ưu điểm lớn: Nó biến vấn đề mô tả 2-D thành 1-D.

$$s(k) = x(k) + jy(k)$$

(6-7)



Hình 6.18 Một ranh giới rời rạc (digital) và biểu diễn của nó dưới dạng chuỗi số phức. Các điểm (x_0, y_0) và (x_1, y_1) là (tùy ý) hai điểm đầu tiên trong chuỗi.

Chúng ta đã có biến đổi Fourier rời rạc (DFT) của $s(k)$ là:

$$a(u) = \sum_{k=0}^{K-1} s(k) e^{-j2\pi uk/K} \quad (6-8)$$

với $u = 0, 1, 2, \dots, K - 1$. Các hệ số phức $a(u)$ được gọi là bộ mô tả Fourier của đường biên. Biến đổi Fourier nghịch đảo của các hệ số này khôi phục $s(k)$:

$$s(k) = \frac{1}{K} \sum_{u=0}^{K-1} a(u) e^{j2\pi uk/K} \quad (6-9)$$

với $k = 0, 1, 2, \dots, K - 1$. Chúng ta đã có nghịch đảo giống với đầu vào ban đầu, với điều kiện là tất cả các hệ số Fourier được sử dụng trong biểu thức (6-9). Tuy nhiên, giả sử rằng, thay vì tất cả các hệ số Fourier, chỉ sử dụng hệ số P đầu tiên. Điều này tương đương với cài đặt $a(u) = 0$ với $u > P-1$ trong biểu thức (6-9). Kết quả là xấp xỉ sau với $s(k)$:


$$\bar{s}(k) = \frac{1}{K} \sum_{u=0}^{P-1} a(u) e^{j2\pi uk/K} \quad (6-10)$$

với $k = 0, 1, 2, \dots, K - 1$. Mặc dù chỉ sử dụng thuật ngữ P để thu được từng thành phần của $\hat{s}(k)$ tham số k vẫn nằm trong khoảng từ 0 đến K-1. Nghĩa là, cùng một số điểm tồn tại trong ranh giới gần đúng, nhưng không có nhiều thuật ngữ được sử dụng để tái cấu trúc từng điểm.

Việc xóa các hệ số tần số cao cũng giống như lọc biến đổi bằng bộ lọc thông thấp lý tưởng. Chúng ta đã thấy trong Chương 4 rằng tính tuần hoàn của DFT yêu cầu chúng ta căn giữa biến đổi trước khi lọc nó bằng cách nhân nó với $(-1)^x$. Do đó, chúng ta sử dụng quy trình này khi triển khai phương trình (6-8) và sử dụng lại nó để đảo ngược việc định tâm khi tính nghịch đảo trong phương trình (6-10). Do tính đối xứng trong DFT, số điểm trong đường biên và nghịch đảo của nó phải chẵn. Điều này ngụ ý rằng số lượng hệ số bị loại bỏ (đặt thành 0) trước khi tính nghịch đảo phải là số chẵn. Vì phép biến đổi được căn giữa nên chúng ta đặt bằng 0 một nửa số hệ số ở mỗi đầu của phép biến đổi để bảo toàn tính đối xứng. Tất nhiên, DFT và nghịch đảo của nó được tính toán bằng thuật toán FFT.

VÍ DỤ 6.8 Sử dụng bộ mô tả Fourier

Hình 6.19(a) cho thấy ranh giới của nhiễm sắc thể người, bao gồm 2868 điểm. Các bộ mô tả Fourier 2868 tương ứng được lấy bằng phương trình (6-8). Mục tiêu của ví dụ này là kiểm tra tác động của việc xây dựng lại ranh giới bằng cách sử dụng ít bộ mô tả Fourier hơn. Hình 6.19(b) cho thấy ranh giới được xây dựng lại bằng cách sử dụng một nửa trong số 2868 bộ mô tả trong biểu thức (6-10). Quan sát rằng không có sự khác biệt có thể cảm nhận được giữa ranh giới này và ranh giới ban đầu. Các hình 6.19(c) đến (h) cho thấy các ranh giới được xây dựng lại với số lượng bộ mô tả Fourier lần lượt là 10%, 5%, 2,5%, 1,25%, 0,63% và 0,28% của 2868. Khi được làm tròn đến số nguyên chẵn gần nhất, các tỷ lệ phần trăm này lần lượt bằng 286, 144, 72, 36, 18 và 8 mô tả. Điểm quan trọng là 18 bộ mô tả, chỉ bằng sáu phần mười của một phần trăm trong số 2868 bộ mô tả ban đầu, là đủ để giữ lại các đặc điểm hình dạng chính của ranh giới ban đầu: bốn phần nhô ra dài và hai phần lõm sâu. Hình 6.19(h), thu được với 8 ký hiệu mô tả, là không thể chấp nhận được vì các đặc điểm chính đã bị mất. Việc giảm thêm xuống 4 và 2 bộ mô tả sẽ dẫn đến một hình elip và một hình tròn tương ứng.



Hình 6.19 (a) Ranh giới của nhiễm sắc thể người (2868 điểm). (b)–(h) Các ranh giới được

xây dựng lại bằng cách sử dụng lần lượt 1434, 286, 144, 72, 36, 18 và 8 bộ mô tả Fourier. Những con số này lần lượt là khoảng 50%, 10%, 5%, 2,5%, 1,25%, 0,63% và 0,28% của 2868. Hình ảnh (b)–(h) được hiển thị dưới dạng âm bản để giúp dễ nhìn thấy ranh giới hơn.

Như ví dụ trước, một vài bộ mô tả Fourier có thể được sử dụng để nắm bắt bản chất của một ranh giới. Thuộc tính này có giá trị vì các hệ số này mang thông tin về hình dạng. Do đó, việc hình thành một véc tơ đặc trưng từ các hệ số này có thể được sử dụng để phân biệt giữa các hình dạng biên.

Chúng ta đã tuyên bố nhiều lần rằng các bộ mô tả phải càng ít nhạy cảm càng tốt đối với những thay đổi về dịch chuyển, xoay và tỷ lệ. Trong trường hợp kết quả phụ thuộc vào thứ tự các điểm được xử lý, một ràng buộc bổ sung là các bộ mô tả không nhạy cảm với điểm bắt đầu. Bộ mô tả Fourier không trực tiếp không nhạy cảm với những thay đổi hình học này, nhưng những thay đổi trong các tham số này có thể liên quan đến các phép biến đổi đơn giản trên bộ mô tả. Ví dụ, hãy xem xét phép quay và nhớ lại từ phân tích toán học cơ bản rằng phép quay một điểm theo một góc θ quanh gốc của mặt phẳng phức được thực hiện bằng cách nhân điểm bằng $e^{j\theta}$. Làm như vậy với mọi điểm của $s(k)$ quay toàn bộ chuỗi quanh gốc tọa độ. Chuỗi được xoay là $s(k)e^{j\theta}$, có mô tả Fourier là

$$a_r(u) = \sum_{k=0}^{K-1} s(k)e^{j\theta} e^{-j2\pi uk/K} = a(u)e^{j\theta}$$

với $u = 0, 1, 2, \dots, K - 1$. Vì vậy, phép quay đơn giản ảnh hưởng như nhau đến tất cả các hệ số bằng một hằng số nhân $e^{j\theta}$.

Bảng 6.1 tóm tắt các bộ mô tả Fourier cho chuỗi biên $s(k)$ trải qua quá trình quay, dịch chuyển, chia tỷ lệ và thay đổi ở điểm bắt đầu. Ký hiệu Δ_{xy} được định nghĩa như $\Delta_{xy} = \Delta x + j\Delta y$, do đó ký hiệu $s_t(k) = s(k) + \Delta_{xy}$ biểu thị việc xác định lại (dịch) chuỗi là:

$$s_t(k) = [x(k) + \Delta x] + j[y(k) + \Delta y] \quad (6-12)$$


BẢNG 6.1

Một số tính chất cơ bản của bộ mô tả Fourier.

Phép biến đổi	Biên	Bộ mô tả Fourier
Định danh	$s(k)$	$a(u)$
Xoay	$s_r(k) = s(k)e^{j\theta}$	$a_r(u) = a(u)e^{j\theta}$
Dịch chuyển	$s_t(k) = s(k) + \Delta_{xy}$	$a_t(u) = a(u) + \Delta_{xy}\Delta(u)$
Tỉ lệ	$s_s(k) = \alpha s(k)$	$a_s(u) = \alpha a(u)$
Điểm khởi đầu	$s_p(k) = s(k - k_0)$	$a_p(u) = a(u)e^{-j2\pi uk_0/K}$

6.3.4. Mô men thống kê - statistical moments

Các mô men thống kê của một biến là các mô tả hữu ích có thể áp dụng cho các biểu diễn 1-D của ranh giới 2-D, chẳng hạn như biên dạng. Để xem làm thế nào điều này có thể được thực hiện, hãy xem Hình 6.20 thể hiện biên dạng từ Hình 6.10(b) được lấy mẫu và được xử lý như một hàm rời rạc thông thường $g(r)$ của một biến, r .



Hình 6.20 Biên dạng mẫu từ Hình 6.10(b) được coi như một hàm thông thường, rời rạc của một biến.

Giả sử rằng chúng ta coi biên độ của g là một biến ngẫu nhiên rời rạc z và tạo thành biểu đồ biên độ $p(z_i)$, $i = 0, 1, 2, \dots, A - 1$ trong đó A là số mức tăng biên độ rời rạc trong đó chúng ta chia thang biên độ. Nếu p được chuẩn hóa sao cho tổng các phần tử của nó bằng 1, từ đó $p(z_i)$ là ước tính xác suất xảy ra giá trị cường độ z_i . Sau đó nó theo sau phương trình (3-33) rằng moment thứ n của z xung quanh giá trị trung bình của nó là:

$$\mu_n(z) = \sum_{i=0}^{A-1} (z_i - m)^n p(z_i) \quad (6-14)$$

trong đó,

$$m = \sum_{i=0}^{A-1} z_i p(z_i) \quad (6-15)$$

Như chúng ta đã biết, m là giá trị trung bình của z và μ_2 là phương sai của nó. Nói chung, chỉ cần một vài mô men đầu tiên để phân biệt giữa các biên dạng có hình dạng khác biệt rõ ràng.

Một cách tiếp cận khác là chuẩn hóa diện tích của $g(r)$ trong Hình 6.20 thành đơn vị và coi nó như một biểu đồ. Nói cách khác, $g(r_i)$ hiện được coi là xác suất xảy ra giá trị r_i . Trong trường hợp này, r được coi là biến ngẫu nhiên và các mô men là

$$\mu_n(z) = \sum_{i=0}^{K-1} (r_i - m)^n g(r_i) \quad (6-16)$$

trong đó,

$$m = \sum_{i=0}^{K-1} r_i g(r_i) \quad (6-17)$$

Trong các phương trình này, K là số điểm trên đường biên và $\mu_n(r)$ liên quan trực tiếp đến hình dạng của biên dạng $g(r)$. Ví dụ, mô men thứ hai $\mu_2(r)$ đo độ giãn của đường cong quanh giá trị trung bình của r , và mô men thứ ba $\mu_3(r)$ đo tính đối xứng của nó đối với giá trị trung bình.

Mặc dù các mô men được sử dụng thường xuyên để mô tả biên dạng nhưng chúng không phải là mô tả duy nhất được sử dụng cho mục đích này. Ví dụ, một cách tiếp cận khác là tính toán biến đổi Fourier rời rạc 1-D của $g(r)$, thu được phổ của nó và sử dụng một số thành phần đầu tiên làm mô tả. Ưu điểm của mô men so với các kỹ thuật khác là việc triển khai chúng rất đơn giản và chúng cũng mang theo cách diễn giải “vật lý” về hình dạng biên dạng (và theo ranh giới hàm ý). Sự ít nhạy cảm của cách tiếp cận này đối với phép quay xuất phát từ thực tế là các biên dạng không phụ thuộc vào phép quay, miễn là điểm bắt đầu luôn giống nhau dọc theo đường biên. Việc chuẩn hóa kích thước có thể đạt được bằng cách chia tỷ lệ các giá trị của g và r .

6.4. Bộ mô tả đặc điểm vùng

Như đã làm với ranh giới, chúng ta bắt đầu thảo luận về các đặc điểm vùng bằng một số mô tả vùng cơ bản.

6.4.1. Một số mô tả cơ bản

Các trục chính và trục phụ của một vùng, cũng như ý tưởng về hộp giới hạn, được xác định trước đó cho các ranh giới. Diện tích của một vùng được xác định là số điểm ảnh trong vùng đó. Chu vi của một vùng là chiều dài ranh giới của nó. Khi diện tích và chu vi được sử dụng làm mô tả, chúng thường chỉ có ý nghĩa khi chúng được chuẩn hóa (Ví dụ 6.9 cho thấy cách sử dụng như vậy). Việc sử dụng thường xuyên hơn hai ký hiệu mô tả này là để đo độ nén của một vùng, được định nghĩa là bình phương chu vi trên diện tích:

$$compactness = \frac{p^2}{A} \quad (6-18)$$

Đây là thước đo không thứ nguyên 4π dành cho hình tròn (giá trị tối thiểu của nó) và 16 cho hình vuông.

Một thước đo không thứ nguyên tương tự là độ tròn, được định nghĩa là:

$$circularity = \frac{4\pi A}{p^2} \quad (6-19)$$

Giá trị của bộ mô tả này là 1 cho hình tròn (giá trị tối đa của nó) và $\pi/4$ cho hình vuông. Lưu ý rằng hai thước đo này độc lập với kích thước, hướng và độ dịch. Một thước đo khác dựa trên đường tròn là đường kính hiệu dụng:

$$d_e = 2\sqrt{\frac{A}{\pi}} \quad (6-20)$$


Đây là đường kính của một vòng tròn có cùng diện tích A với vùng đang được xử lý. Biện pháp này không phải là không thứ nguyên cũng như không độc lập với kích thước vùng, nhưng nó không phụ thuộc vào định hướng và dịch chuyển. Nó có thể được chuẩn hóa về kích thước và tạo thành không thứ nguyên bằng cách chia nó cho đường kính lớn nhất dự kiến trong một ứng dụng nhất định.

Theo cách tương tự như cách chúng ta xác định độ nén và độ tròn so với hình tròn, chúng ta xác định độ lệch tâm của một vùng so với hình elip là độ lệch tâm của một hình elip có cùng mô men trung tâm thứ hai với vùng đó. Đối với 1-D, mô men trung tâm thứ hai là phương sai mà đối với các biến rời rạc, chúng ta ước tính bằng phương trình (2-114). Đối với dữ liệu rời rạc 2-D, chúng ta phải xem xét phương sai của từng biến cũng như hiệp phương sai giữa chúng. Đây là các thành phần của ma trận hiệp phương sai, được ước tính từ các mẫu sử dụng biểu thức (2-130), với các mẫu trong trường hợp này là véc tơ 2-D biểu thị tọa độ của dữ liệu.

Hình 6.21(a) hiển thị một hình elip ở dạng chuẩn (tức là một hình elip có trục chính và trục phụ thẳng hàng với trục tọa độ). Độ lệch tâm của một hình elip như vậy được định nghĩa là tỷ số giữa khoảng cách giữa các tiêu điểm ($2c$ trong Hình 6.21) và chiều dài của trục chính của nó ($2a$), cho ra tỷ lệ $\frac{2c}{2a} = c/a$, đó là:

$$eccentricity = \frac{c}{a} = \frac{\sqrt{a^2 - b^2}}{a} = \sqrt{1 - (b/a)^2} \text{ với } a \geq b$$

a b



Hình 6.21 (a) Một hình elip ở dạng chuẩn. (b) Một hình elip xấp xỉ một vùng theo hướng tùy ý.

Tuy nhiên, chúng ta quan tâm đến độ lệch tâm của một hình elip có mô men trung tâm thứ hai giống như một vùng 2-D nhất định, điều đó có nghĩa là các hình elip của chúng ta có thể có hướng tùy ý. Theo trực giác, những gì chúng ta đang cố gắng làm là ước chừng dữ liệu 2-D của chúng ta bằng một vùng hình elip có các trục thẳng hàng với các trục chính của dữ liệu, như Hình 6.21(b) minh họa. Như chúng ta sẽ biết trong Phần 6.5 (xem Ví dụ 6.17), các trục chính là các véc tơ riêng của ma trận hiệp phương sai, C , của dữ liệu, được cho bởi:

$$C = \frac{1}{K-1} \sum_{k=1}^K (\mathbf{z}_k - \bar{\mathbf{z}})(\mathbf{z}_k - \bar{\mathbf{z}})^T \quad (6-21)$$

trong đó $\mathbf{z}_k$ véc tơ 2 chiều có các phần tử là hai tọa độ không gian của một điểm trong vùng, K là tổng số điểm và $\bar{\mathbf{z}}$ là véc tơ trung bình:

$$\bar{\mathbf{z}} = \frac{1}{K} \sum_{k=1}^K \mathbf{z}_k \quad (6-22)$$

Các phần tử đường chéo chính của C là phương sai của các giá trị tọa độ của các điểm trong vùng và các phần tử ngoài đường chéo là hiệp phương sai của chúng (xem phần thảo luận về mật độ Gaussian đa biến).

Một hình elip được định hướng cùng hướng với các trục chính của vùng có thể được hiểu là giao điểm của hàm Gaussian 2-D với mặt phẳng xy. Hướng của các trục của hình elip cũng theo hướng của véc tơ riêng của ma trận hiệp phương sai và khoảng cách từ tâm của hình elip đến giao điểm của nó với trục chính và trục phụ của nó bằng giá trị riêng lớn nhất và nhỏ nhất của hiệp phương sai ma trận tương ứng như Hình 6.21(b) cho thấy. Dựa vào Hình 6.21 và phương trình độ lệch tâm của nó cho ở trên, chúng ta thấy bằng cách tương tự rằng độ lệch tâm của một hình elip có cùng mô men giây với vùng được cho bởi:

$$\text{eccentricity} = \frac{\sqrt{\lambda_2^2 - \lambda_1^2}}{\lambda_2} = \sqrt{1 - (\lambda_1/\lambda_2)^2} \text{ với } \lambda_2 > \lambda_1 \quad (6-23)$$

Đối với các vùng hình tròn, $\lambda_1 = \lambda_2$ và độ lệch tâm là 0. Đối với một đường thẳng $\lambda_1 = 0$, độ lệch tâm là 1. Do đó, các giá trị của bộ mô tả này nằm trong khoảng $[0, 1]$.

VÍ DỤ 6.9 So sánh các bộ mô tả đặc trưng.

Hình 6.22 cho thấy các giá trị của các ký hiệu mô tả trước đó cho một số hình dạng vùng. Không có mô tả nào cho đường tròn chính xác bằng giá trị lý thuyết của nó vì việc số hóa một đường tròn sẽ đưa ra lỗi trong quá trình tính toán và vì chúng ta đã tính gần đúng độ dài của một đường biên bằng số phần tử của nó. Độ lệch tâm của hình vuông có giá trị chính xác bằng 0, bởi vì hình vuông không có góc quay sẽ căn chỉnh hoàn hảo với lưới lấy mẫu. Hai mô tả khác cho hình vuông cũng gần với giá trị lý thuyết của chúng.


a b c d

Descriptor				
Compactness	10.1701	42.2442	15.9836	13.2308
Circularity	1.2356	0.2975	0.7862	0.9478
Eccentricity	0.0411	0.0636	0	0.8117

Hình 6.22 Tính nén, tính tròn và độ lệch tâm của một số vùng nhị phân đơn giản.

Các giá trị được liệt kê trong hai hàng đầu tiên của Hình 6.22 mang cùng thông tin. Ví dụ, chúng ta có thể nói rằng ngôi sao này nhỏ gọn hơn và kém tròn hơn các hình dạng khác. Tương tự, từ những con số được liệt kê, thật dễ dàng để biết rằng vùng hình giọt nước có độ lệch tâm lớn nhất cho đến nay, nhưng khó phân biệt hơn với các hình dạng khác bằng cách sử dụng độ nén hoặc độ tròn.

Như chúng ta đã thảo luận trong Phần 6.1, các bộ mô tả đặc trưng thường được sắp xếp dưới dạng véc tơ đặc trưng để xử lý tiếp theo. Hình 6.23 hiển thị không gian đặc trưng cho các bộ mô tả trong Hình 6.22. Mỗi điểm trong không gian đặc trưng “đóng gói” ba giá trị mô tả cho từng đối tượng. Mặc dù chúng ta có thể biết khi nhìn vào các giá trị của các bộ mô tả trong hình rằng hình tròn và hình vuông giống nhau hơn nhiều so với hai đối tượng còn lại, hãy lưu ý rằng thực tế này rõ ràng hơn bao nhiêu trong không gian đặc trưng. Chúng ta có thể tưởng tượng rằng nếu có nhiều mẫu của những vật thể đó bị nhiễu do nhiễu, thì việc phân biệt giữa các véc tơ (điểm) tương ứng với hình vuông hoặc hình tròn có thể trở nên khó khăn. Ngược lại, các vật thể ngôi sao và giọt nước ở xa nhau, cách xa nhau, cách xa hình tròn và hình vuông, do đó chúng ít có khả năng bị phân loại sai khi có nhiễu. Không gian đặc trưng sẽ đóng một vai trò quan trọng trong chương phân loại ảnh, khi chúng ta thảo luận về phân loại mẫu hình ảnh.




Hình 6.23 Các mô tả từ Hình 6.22 trong không gian đặc trưng 3-D. Mỗi dấu chấm được hiển thị tương ứng với một véc tơ đặc trưng có các thành phần là ba bộ mô tả tương ứng trong Hình 6.22.

VÍ DỤ 6.10 Sử dụng đặc điểm vùng

Ngay cả một bộ mô tả đơn giản như vùng chuẩn hóa cũng có thể khá hữu ích để trích xuất thông tin từ hình ảnh. Ví dụ, Hình 6.24 cho thấy hình ảnh hồng ngoại qua vệ tinh vào ban đêm của Châu Mỹ. Như chúng ta đã thảo luận ở Phần 1.3, những hình ảnh như vậy cung cấp một danh sách toàn cục về các khu định cư của con người. Các cảm biến hình ảnh được sử

dụng để thu thập những hình ảnh này có khả năng phát hiện các phát xạ hồng ngoại nhìn thấy và gần, chẳng hạn như ánh sáng, đám cháy và pháo sáng. Bảng bên cạnh các hình ảnh hiển thị (theo vùng từ trên xuống dưới) tỷ lệ diện tích bị chiếm bởi màu tsnalesg (đèn) trên tổng diện tích ánh sáng ở cả bốn vùng. Ví dụ, một phép đo đơn giản như thế này có thể đưa ra ước tính tương đối theo khu vực tiêu thụ năng lượng điện. Dữ liệu có thể được tinh chỉnh bằng cách chuẩn hóa nó theo diện tích đất trên mỗi khu vực, liên quan đến số lượng dân số, v.v.




Hình 6.24 Hình ảnh hồng ngoại của châu Mỹ vào ban đêm.

6.4.2. Bộ mô tả cấu trúc liên kết - topological descriptors

Cấu trúc liên kết là nghiên cứu về các đặc tính của một hình không bị ảnh hưởng bởi bất kỳ biến dạng nào, với điều kiện là không có sự rách hoặc nối của hình (đôi khi chúng được gọi là biến dạng tấm cao su). Ví dụ, Hình 6.25(a) cho thấy một vùng có hai lỗ. Rõ ràng, một bộ mô tả cấu trúc liên kết được định nghĩa là số lỗ trong vùng sẽ không bị ảnh hưởng bởi phép biến đổi kéo dài hoặc xoay. Tuy nhiên, số lượng lỗ có thể thay đổi nếu vùng đó bị rách hoặc bị gấp. Bởi vì sự kéo dài ảnh hưởng đến khoảng cách, nên các thuộc tính cấu trúc liên kết không phụ thuộc vào khái niệm khoảng cách hoặc bất kỳ thuộc tính nào hoàn toàn dựa trên

khái niệm thước đo khoảng cách.

a b




Hình 6.25 (a) Một vùng có hai lỗ trống. (b) Một vùng có ba thành phần được kết nối.

Một thuộc tính cấu trúc liên kết khác hữu ích cho việc mô tả vùng là số lượng các thành phần được kết nối của một hình ảnh hoặc vùng. Hình 6.25(b) hiển thị một vùng có ba thành phần được kết nối. Số lỗ H và các thành phần C được kết nối trong hình có thể được sử dụng để xác định số Euler, E:

$$E = C - H. \quad (6-24)$$

Số Euler cũng là một tính chất cấu trúc liên kết. Ví dụ, các vùng được hiển thị trong Hình 6.26 có số Euler lần lượt bằng 0 và -1, bởi vì “A” có một thành phần liên thông và một lỗ, còn “B” có một thành phần liên thông nhưng có hai lỗ.


a b



Hình 6.26 Các miền có số Euler lần lượt bằng 0 và -1

Các vùng được biểu thị bằng các đoạn thẳng (gọi là mạng đa giác) có cách hiểu đặc biệt đơn giản theo số Euler. Hình 6.27 cho thấy một mạng đa giác. Việc phân loại các vùng bên trong của mạng như vậy thành các mặt và các lỗ thường rất quan trọng. Ký hiệu số đỉnh là V, số cạnh là Q và số mặt là F sẽ cho mối quan hệ sau đây, gọi là công thức Euler:

$$V - Q + F = C - H. \quad (6-25)$$



Hình 6.27 Một vùng chứa mạng đa giác.


trong đó, theo quan điểm của phương trình (6-24), có thể được biểu diễn dưới dạng:

$$V - Q + F = E. \quad (6-26)$$

Mạng trong Hình 6.27 có bảy đỉnh, mười một cạnh, hai mặt, một vùng được kết nối và ba lỗ; do đó số Euler là -2 (cụ thể: $7 - 11 + 2 = 1 - 3 = -2$).

VÍ DỤ 6.11 Trích rút và mô tả đặc điểm lớn nhất trong ảnh được phân đoạn

Hình 6.28(a) hiển thị hình ảnh 512×512 8-bit của Washington, D.C. được chụp bởi vệ tinh LANDSAT của NASA. Hình ảnh này nằm trong dải hồng ngoại gần (xem hình 1.10 để biết chi tiết). Giả sử chúng ta muốn phân đoạn dòng sông chỉ bằng hình ảnh này (ngược lại với việc sử dụng một số hình ảnh đa quang phổ, điều này sẽ đơn giản hóa nhiệm vụ, như chúng ta sẽ thấy ở phần sau của chương này). Bởi vì dòng sông là một vùng tối, đồng nhất so với phần còn lại của hình ảnh nên việc đặt ngưỡng là một cách tiếp cận rõ ràng để thử. Kết quả của việc tạo ngưỡng cho hình ảnh có giá trị ngưỡng cao nhất có thể trước khi dòng sông trở thành vùng bị ngắt kết nối được hiển thị trong Hình 6.28(b). Ngưỡng được chọn thủ công để minh họa quan điểm rằng trong trường hợp này không thể tự phân đoạn dòng sông mà không có các vùng khác của hình ảnh cũng xuất hiện trong kết quả được ngưỡng.



Hình 6.28 (a) Ảnh hồng ngoại của khu vực Washington, D.C. (b) Ảnh ngưỡng. (c) Thành phần liên thông lớn nhất của (b). (d) Bộ khung xương của (c).


Hình ảnh trong Hình 6.28(b) có 1591 thành phần liên thông (thu được bằng cách sử dụng kết nối 8) và số Euler của nó là 1552, từ đó chúng ta suy ra số lỗ trống là 39. Hình 6.28(c) biểu thị thành phần liên thông với số điểm ảnh lớn nhất (8479). Đây là kết quả mong muốn mà chúng ta đã biết không thể tự phân đoạn khỏi hình ảnh bằng cách sử dụng ngưỡng. Lưu ý kết quả này rõ ràng như thế nào. Số lượng lỗ trong khu vực được xác định bởi thành phần được kết nối vừa tìm thấy sẽ cho chúng ta số lượng đất liền trong sông. Nếu chúng ta muốn thực hiện các phép đo, chẳng hạn như chiều dài của mỗi nhánh sông, chúng ta có thể sử dụng khung của thành phần được kết nối [Hình 6.28(d)] để làm như vậy.

6.4.2. Kết cấu - texture

Một cách tiếp cận quan trọng để mô tả vùng là định lượng nội dung kết cấu của nó. Mặc dù không có định nghĩa chính thức nào về kết cấu, nhưng về mặt trực quan, bộ mô tả này cung cấp các thước đo về các đặc tính như độ mịn, độ thô và độ đều đặn (Hình 6.29 cho thấy một số ví dụ). Trong phần này, chúng ta thảo luận về các phương pháp thống kê và quang phổ để mô tả kết cấu của một vùng. Các phương pháp thống kê mang lại các đặc tính của kết cấu như mịn, thô, sần sùi, v.v. Các kỹ thuật quang phổ dựa trên các đặc tính của phổ Fourier và được sử dụng chủ yếu để phát hiện tính tuần hoàn tổng thể trong một hình ảnh bằng cách

xác định các đỉnh hẹp, năng lượng cao trong phổ của nó.

a b c



Hình 6.29 Các ô vuông đánh dấu màu tsnaesg, từ trái sang phải, có kết cấu mịn, thô và đều đặn. Đây là những hình ảnh kính hiển vi quang học của chất siêu dẫn, cholesterol của con người và bộ vi xử lý.

6.4.3. Các cách tiếp cận thống kê - statistical approaches

Một trong những cách tiếp cận đơn giản nhất để mô tả kết cấu là sử dụng các mô men thống kê của biểu đồ cường độ của một hình ảnh hoặc vùng. Đặt z là một biến ngẫu nhiên biểu thị cường độ và gọi $p(z_i)$, $i = 0, 1, 2, \dots, L - 1$ là biểu đồ chuẩn hóa tương ứng, trong đó L là số mức cường độ riêng biệt. Từ phương trình (3-33), mô men thứ n của z về giá trị trung bình là:

$$\mu_n(z) = \sum_{i=0}^{L-1} (z_i - m)^n p(z_i) \quad (6-27)$$

trong đó m là giá trị trung bình của z (tức là cường độ trung bình của hình ảnh hoặc vùng):

$$m = \sum_{i=0}^{L-1} z_i p(z_i) \quad (6-28)$$

Lưu ý từ phương trình (6-27) đó $\mu_0 = 1$ và $\mu_1 = 0$. Thời điểm thứ hai [phương sai $\sigma^2(z) = \mu_2(z)$] đặc biệt quan trọng trong mô tả kết cấu. Nó là thước đo độ tương phản cường độ có thể được sử dụng để thiết lập các mô tả về độ mịn cường độ tương đối. Ví dụ, độ đo:

$$R(z) = 1 - \frac{1}{1 + \sigma^2(z)} \quad (6-29)$$

là 0 đối với các vùng có cường độ không đổi (ở đó phương sai bằng 0) và tiến tới 1 đối với các giá trị lớn của $\sigma^2(z)$. Bởi vì các giá trị phương sai có xu hướng lớn đối với các ảnh thang độ xám có giá trị, ví dụ: trong phạm vi từ 0 đến 255, nên chúng ta chuẩn hóa phương sai thành khoảng $[0, 1]$ để sử dụng trong biểu thức (6-29). Điều này được thực hiện đơn giản bằng cách chia cho trong biểu thức (6-29). Độ lệch chuẩn $\sigma(z)$ cũng được sử dụng thường xuyên như thước đo kết cấu vì các giá trị của nó trực quan hơn.

Như đã thảo luận trong Phần 2.6, mô men thứ ba là thước đo độ lệch của biểu đồ trong khi mô men thứ tư $\mu_4(z)$ là thước đo độ phẳng tương đối của nó. Mô men thứ năm và cao hơn không dễ dàng liên quan đến hình dạng biểu đồ, nhưng chúng cung cấp sự phân biệt định lượng hơn nữa về nội dung kết cấu. Một số biện pháp kết cấu bổ sung hữu ích dựa trên biểu đồ bao gồm thước đo tính đồng nhất, được định nghĩa là:

$$U(z) = \sum_{i=0}^{L-1} p^2(z_i) \quad (6-30)$$

và thước đo entropy trung bình, như chúng ta có thể nhớ lại từ lý thuyết thông tin, được định nghĩa là:

$$e(z) = - \sum_{i=0}^{L-1} p(z_i) \log_2 p(z_i) \quad (6-31)$$

Bởi vì các giá trị của p nằm trong phạm vi $[0, 1]$ và tổng của chúng bằng 1, nên giá trị của

bộ mô tả U là lớn nhất đối với một hình ảnh trong đó tất cả các mức cường độ đều bằng nhau (đồng nhất tối đa) và giảm dần từ đó. Entropy là thước đo độ biến thiên và bằng 0 đối với hình ảnh không đổi.

VÍ DỤ 6.12 Bộ mô tả kết cấu dựa trên biểu đồ

Bảng 6.2 liệt kê các giá trị của các mô tả trước đó cho ba loại kết cấu được tô sáng trong Hình 6.29. Giá trị trung bình chỉ mô tả cường độ trung bình của từng vùng và chỉ hữu ích như một ý tưởng sơ bộ về cường độ chứ không phải kết cấu. Độ lệch chuẩn mang lại nhiều thông tin hơn; các con số cho thấy rõ ràng rằng kết cấu đầu tiên có cường độ thay đổi ít hơn đáng kể (mượt mà hơn) so với hai kết cấu còn lại. Kết cấu thô hiện lên rõ ràng ở thước đo này. Đúng như mong đợi, các nhận xét tương tự cũng đúng đối với R , vì về cơ bản nó đo lường kết quả tương tự như độ lệch chuẩn. Mô men thứ ba rất hữu ích để xác định tính đối xứng của biểu đồ và liệu chúng có bị lệch sang trái (giá trị âm) hay sang phải (giá trị dương). Điều này đưa ra dấu hiệu cho biết liệu các mức cường độ có thiên về phía tối hay sáng của giá trị trung bình hay không. Về mặt kết cấu, thông tin thu được từ mô men thứ ba chỉ hữu ích khi có sự khác biệt lớn giữa các phép đo. Nhìn vào thước đo độ đồng nhất, một lần nữa chúng ta kết luận rằng ảnh con đầu tiên mượt mà hơn (đồng đều hơn các ảnh còn lại) và ảnh ngẫu nhiên nhất (độ đồng đều thấp nhất) tương ứng với kết cấu thô. Cuối cùng, chúng ta thấy rằng các giá trị entropy tăng khi độ đồng đều giảm, dẫn chúng ta đến những kết luận tương tự về kết cấu của các vùng như thước đo độ đồng nhất đã đưa ra. Ảnh con đầu tiên có mức độ thay đổi cường độ thấp nhất và ảnh thô có nhiều biến đổi nhất. Kết cấu thông thường nằm ở giữa hai thái cực đối với cả hai biện pháp này.

BẢNG 6.2

Các thước đo kết cấu thống kê cho các ảnh con trong Hình 6.29.


Texture	Mean	Standard deviation	R (normalized)	3rd moment	Uniformity	Entropy
Smooth	82.64	11.79	0.002	-0.105	0.026	5.434
Coarse	143.56	74.63	0.079	-0.151	0.005	7.783
Regular	99.72	33.73	0.017	0.750	0.013	6.674

Các phép đo kết cấu được tính toán chỉ bằng biểu đồ không mang thông tin liên quan đến mối quan hệ không gian giữa các điểm ảnh, điều này rất quan trọng khi mô tả kết cấu. Một cách để kết hợp loại thông tin này vào quy trình phân tích kết cấu là xem xét không chỉ sự phân bố cường độ mà còn cả vị trí tương đối của các điểm ảnh trong ảnh.

Giả sử Q là toán tử xác định vị trí của hai điểm ảnh so với nhau và xem xét một hình ảnh, f , với mức cường độ có thể là L . Giả sử G là một ma trận có phần tử g_{ij} là số lần điểm ảnh ghép với cường độ z_i và z_j xuất hiện trong ảnh f ở vị trí được chỉ định bởi Q , trong đó $1 \leq i, j \leq L$. Một ma trận được hình thành theo cách này được gọi là ma trận đồng hiện mức xám (hoặc cường độ). Khi ý nghĩa rõ ràng, G được gọi đơn giản là ma trận đồng hiện.

Hình 6.30 cho thấy một ví dụ về cách xây dựng ma trận đồng hiện sử dụng toán tử vị trí Q được định nghĩa là “một điểm ảnh ngay bên phải” (tức là lân cận của một điểm ảnh được xác định là điểm ảnh ngay bên phải của nó). Mảng bên trái là một ảnh nhỏ và mảng bên phải là ma trận G . Ta thấy phần tử (1,1) của G là 1, vì chỉ có một lần xuất hiện trong f của điểm ảnh có giá trị 1 có điểm ảnh có giá trị 1 ngay bên phải của nó. Tương tự, phần tử (6,2) của G là 3, vì có ba lần xuất hiện trong f của một điểm ảnh có giá trị 6 có một điểm ảnh có giá trị 2 ngay bên phải nó. Các phần tử khác của G được tính toán tương tự. Nếu chúng ta định nghĩa Q là “một điểm ảnh ở bên phải và một điểm ảnh ở trên”, thì vị trí (1,1) trong G sẽ là 0

vì không có trường hợp nào trong f của số 1 có số 1 khác ở vị trí đó. được chỉ định bởi Q . Mặt khác, các vị trí (1,3), (1,5) và (1,7) trong G đều là 1, vì giá trị cường độ 1 xuất hiện trong f với các lân cận có giá trị 3, 5 và 7 ở vị trí được chỉ định bởi Q - mỗi lần xuất hiện một lần. Như một bài tập, chúng ta nên tính tất cả các phần tử của G bằng cách sử dụng định nghĩa Q này.



Hình 6.30 Cách xây dựng ma trận đồng hiện.

Số mức cường độ có thể có trong ảnh xác định kích thước của ma trận G . Đối với hình ảnh 8 bit (256 mức cường độ có thể có), G sẽ có kích thước 256×256 . Đây không phải là vấn đề khi làm việc với một ma trận, nhưng như chúng ta sẽ thấy trong Ví dụ 6.13, ma trận đồng hiện đôi khi được sử dụng theo trình tự. Một cách tiếp cận để giảm bớt tính toán là lượng tử hóa cường độ thành một vài dải để giữ cho kích thước của G có thể quản lý được. Ví dụ: trong trường hợp 256 cường độ, chúng ta có thể thực hiện điều này bằng cách đặt 32 mức cường độ đầu tiên bằng 1, 32 mức cường độ tiếp theo bằng 2, v.v. Điều này sẽ dẫn đến một ma trận đồng hiện có kích thước 8×8 .

Tổng số n của các cặp điểm ảnh thỏa mãn Q bằng tổng các phần tử của G (trong ví dụ ở Hình 6.30). Sau đó, số lượng:

$$p_{ij} = \frac{g_{ij}}{n}$$

là ước tính xác suất để một cặp điểm thỏa mãn Q sẽ có các giá trị. Các xác suất này nằm trong khoảng $[0, 1]$ và tổng của chúng là 1:

$$\sum_{i=1}^K \sum_{j=1}^K p_{ij} = 1$$

trong đó K là kích thước hàng và cột của ma trận vuông G .

Bởi vì G phụ thuộc vào Q , nên sự hiện diện của các mẫu kết cấu cường độ có thể được phát hiện bằng cách chọn toán tử vị trí thích hợp và phân tích các phần tử của G . Một tập hợp các mô tả hữu ích để mô tả đặc điểm nội dung của G được liệt kê trong Bảng 6.3. Các đại lượng được sử dụng trong bộ mô tả tương quan (hàng thứ hai) được xác định như sau:

$$m_r = \sum_{i=1}^K i \sum_{j=1}^K p_{ij}$$

$$m_c = \sum_{j=1}^K j \sum_{i=1}^K p_{ij}$$

BẢNG 6.3

Bộ mô tả được sử dụng để mô tả các ma trận đồng xuất hiện có kích thước $K \times K$. Số hạng p_{ij} là số hạng thứ ij của G chia cho tổng các phần tử của G .

Descriptor	Explanation	Formula
Maximum probability	Measures the strongest response of G . The range of values is $[0, 1]$.	$\max_{i,j}(p_{ij})$
Correlation	A measure of how correlated a pixel is to its neighbor over the entire image. The range of values is 1 to -1 corresponding to perfect positive and perfect negative correlations. This measure is not defined if either standard deviation is zero.	$\frac{\sum_{i=1}^K \sum_{j=1}^K (i - m_r)(j - m_c)p_{ij}}{\sigma_r \sigma_c}$ $\sigma_r \neq 0; \sigma_c \neq 0$
Contrast	A measure of intensity contrast between a pixel and its neighbor over the entire image. The range of values is 0 (when G is constant) to $(K - 1)^2$.	$\sum_{i=1}^K \sum_{j=1}^K (i - j)^2 p_{ij}$
Uniformity (also called Energy)	A measure of uniformity in the range $[0, 1]$. Uniformity is 1 for a constant image.	$\sum_{i=1}^K \sum_{j=1}^K p_{ij}^2$
Homogeneity	Measures the spatial closeness to the diagonal of the distribution of elements in G . The range of values is $[0, 1]$, with the maximum being achieved when G is a diagonal matrix.	$\sum_{i=1}^K \sum_{j=1}^K \frac{p_{ij}}{1 + i - j }$
Entropy	Measures the randomness of the elements of G . The entropy is 0 when all p_{ij} 's are 0 , and is maximum when the p_{ij} 's are uniformly distributed. The maximum value is thus $2\log_2 K$.	$-\sum_{i=1}^K \sum_{j=1}^K p_{ij} \log_2 p_{ij}$

và

$$\sigma_r^2 = \sum_{i=1}^K (i - m_r)^2 \sum_{j=1}^K p_{ij}$$

$$\sigma_c^2 = \sum_{j=1}^K (j - m_c)^2 \sum_{i=1}^K p_{ij}$$

Nếu ta đặt

$$P(i) = \sum_{j=1}^K p_{ij}$$

và

$$P(j) = \sum_{i=1}^K p_{ij}$$

thì các phương trình trước có thể được viết là

$$m_r = \sum_{i=1}^K iP(i)$$

$$m_c = \sum_{j=1}^K jP(j)$$

$$\sigma_r^2 = \sum_{i=1}^K (i - m_r)^2 P(i)$$

và

$$\sigma_c^2 = \sum_{j=1}^K (j - m_c)^2 P(j)$$


Với sự tham khảo đến các phương trình (6-27), (6-28) và theo lời giải thích, chúng ta thấy nó ở dạng giá trị trung bình được tính dọc theo các hàng của G đã chuẩn hóa và là giá trị trung bình được tính dọc theo các cột. Tương tự, và ở dạng độ lệch chuẩn (căn bậc hai của phương sai) được tính dọc theo hàng và cột tương ứng. Mỗi số hạng này là một đại lượng vô hướng, độc lập với kích thước của G .

Lưu ý rằng khi xem xét Bảng 6.3 rằng “hàng xóm” liên quan đến cách xác định Q (tức là hàng xóm không nhất thiết phải ở gần nhau) và p_{ij} cũng không có gì khác hơn là số lần được chuẩn hóa các điểm ảnh đó có cường độ z_i và z_j xuất hiện trong f so với vị trí được chỉ định trong Q . Vì vậy, tất cả những gì chúng ta đang làm ở đây là cố gắng tìm các mẫu (kết cấu) trong các số lượng đó.

VÍ DỤ 6.13 Sử dụng bộ mô tả để mô tả ma trận đồng hiện

Các Hình 6.31(a) đến (c) hiển thị các hình ảnh lần lượt bao gồm các mẫu điểm ảnh ngẫu nhiên, tuần hoàn theo chiều ngang (sine) và hỗn hợp. Ví dụ này có hai mục tiêu: (1) hiển thị giá trị của các bộ mô tả trong Bảng 6.3 cho ba ma trận đồng xuất hiện và tương ứng (từ trên xuống dưới) cho những hình ảnh này; và (2) để minh họa cách sử dụng chuỗi ma trận đồng hiện để phát hiện các mẫu kết cấu trong một hình ảnh.


a
b
c



Hình 6.31 Hình ảnh có các điểm ảnh có (a) mẫu kết cấu ngẫu nhiên, (b) định kỳ và (c) hỗn hợp. Mỗi hình ảnh có kích thước 263×800 điểm ảnh.

Hình 6.32 thể hiện các ma trận đồng hiện G_1, G_2, G_3 hiển thị dưới dạng hình ảnh. Các ma trận này thu được bằng cách sử dụng toán tử vị trí “một điểm ảnh ngay bên phải”. Giá trị tại tọa độ (i, j) trong những ảnh này là số lần điểm ảnh ghép cặp với cường độ z_i và z_j xuất hiện ở vị trí được chỉ định bởi Q , do đó không có gì đáng ngạc nhiên khi Hình 6.32(a) là một ảnh ngẫu nhiên, dựa trên bản chất của hình ảnh mà nó thu được.

a b c



Hình 6.32 Ma trận đồng hiện 256×256 G_1, G_2, G_3 tương ứng từ trái qua phải với các ảnh trong Hình 6.31.

Hình 6.32(b) thú vị hơn. Đặc điểm rõ ràng đầu tiên là tính đối xứng của đường chéo chính. Do tính đối xứng của sóng hình sin nên số lượng đếm của một cặp (z_i, z_j) cũng giống như số lượng của cặp (z_j, z_i) tạo ra ma trận đồng hiện đối xứng. Các phần tử khác 0 của G_2 rất thưa thớt vì sự khác biệt về giá trị giữa các điểm ảnh liên kề theo chiều ngang trong sóng hình sin ngang là tương đối nhỏ. Sẽ rất hữu ích khi giải thích các khái niệm này rằng sóng hình sin được số hóa là một cầu thang, với chiều cao và chiều rộng của mỗi bậc thang tùy thuộc vào tần số của sóng hình sin và số mức biên độ được sử dụng để biểu diễn hàm số.

Cấu trúc của ma trận đồng hiện G_3 trong Hình 6.32(c) phức tạp hơn. Các giá trị số lượng cao cũng được nhóm dọc theo đường chéo chính, nhưng sự phân bố của chúng dày đặc hơn so với đặc tính biểu thị một hình ảnh có sự thay đổi phong phú về giá trị cường độ nhưng có ít bước nhảy lớn về cường độ giữa các điểm ảnh liên kề. Xem xét Hình 6.32(c), chúng ta thấy rằng có những vùng rộng lớn được đặc trưng bởi độ biến thiên cường độ thấp. Sự chuyển đổi cường độ cao xảy ra ở ranh giới đối tượng, nhưng số lượng này thấp so với sự chuyển đổi cường độ vừa phải trên các khu vực rộng lớn, do đó chúng bị che khuất bởi khả năng hiển thị hình ảnh để hiển thị đồng thời các giá trị cao và thấp.

Các quan sát trước đó là định tính. Để định lượng “nội dung” của ma trận đồng hiện, chúng ta cần các mô tả như trong Bảng 6.3. Bảng 6.4 cho thấy các giá trị của các mô tả này được tính toán cho ba ma trận đồng hiện trong Hình 6.32. Để sử dụng các bộ mô tả này, các ma trận đồng xuất hiện phải được chuẩn hóa bằng cách chia chúng cho tổng các phần tử của chúng, như đã thảo luận trước đó. Các mục trong Bảng 6.4 phù hợp với những gì người ta mong đợi từ các hình ảnh trong Hình 6.31 và các ma trận đồng hiện tương ứng của chúng trong Hình 6.32. Ví dụ, hãy xem xét cột xác suất tối đa trong Bảng 6.4. Xác suất cao nhất tương ứng với ma trận đồng hiện thứ ba, cho chúng ta biết rằng ma trận này có số lượng đếm cao nhất (số cặp điểm ảnh lớn nhất xuất hiện trong ảnh so với các vị trí trong Q) so với hai ma trận còn lại. Điều này phù hợp với phân tích của chúng ta về G_3 . Cột thứ hai chỉ ra rằng mối tương quan cao nhất tương ứng với G_2 , điều này cho chúng ta biết rằng cường độ trong hình ảnh thứ hai có mối tương quan cao. Sự lặp đi lặp lại của mô hình hình sin trong Hình 6.31(b) chỉ ra lý do tại sao điều này lại như vậy. Lưu ý rằng mối tương quan về G_1 cơ bản là bằng 0, cho thấy hầu như không có mối tương quan giữa các điểm ảnh liên kề, đặc trưng của các hình ảnh ngẫu nhiên như hình ảnh trong Hình 6.31(a).

BẢNG 6.4

Các bộ mô tả được đánh giá bằng cách sử dụng các ma trận đồng hiện được hiển thị dưới dạng hình ảnh trong Hình 6.32

Normalized Co-occurrence Matrix	Maximum Probability	Correlation	Contrast	Uniformity	Homogeneity	Entropy
G_1/n_1	0.00006	-0.0005	10838	0.00002	0.0366	15.75
G_2/n_2	0.01500	0.9650	00570	0.01230	0.0824	06.43
G_3/n_3	0.06860	0.8798	01356	0.00480	0.2048	13.58


Bộ mô tả độ tương phản là cao nhất cho G_1 và thấp nhất cho G_2 . Vì vậy, chúng ta thấy rằng hình ảnh càng ít ngẫu nhiên thì độ tương phản của nó càng thấp. Chúng ta có thể thấy lý do bằng cách nghiên cứu ma trận hiển thị trong Hình 6.32. Các số hạng $(i - j)^2$ là sự khác biệt của các số nguyên với $1 \leq i, j \leq L$ vì vậy chúng giống nhau đối với mọi G . Do đó, xác suất của các phần tử của ma trận đồng hiện chuẩn hóa là các yếu tố xác định giá trị tương phản. Mặc dù có xác suất tối đa thấp nhất, hai ma trận còn lại có nhiều xác suất bằng 0 hoặc gần bằng 0 hơn (các vùng tối trong Hình 6.32). Vì tổng các giá trị của G/n là 1 nên dễ hiểu tại sao bộ mô tả độ tương phản có xu hướng tăng như một hàm ngẫu nhiên.

Ba mô tả còn lại được giải thích theo cách tương tự. Tính đồng nhất tăng theo hàm của các giá trị xác suất bình phương. Do đó, càng có ít sự ngẫu nhiên trong một hình ảnh thì bộ mô tả đồng nhất sẽ càng cao, như cột thứ năm trong Bảng 6.4 cho thấy. Tính đồng nhất đo lường mức độ tập trung các giá trị của G đối với đường chéo chính. Các giá trị của số hạng mẫu số $(1 + |i - j|)$ là như nhau đối với cả ba ma trận đồng hiện và chúng giảm khi i và j trở nên gần nhau hơn về giá trị (tức là, gần đường chéo chính hơn). Như vậy, ma trận có giá trị xác suất (số hạng) cao nhất gần đường chéo chính sẽ có giá trị đồng nhất cao nhất. Như chúng ta đã thảo luận trước đó, ma trận như vậy sẽ tương ứng với các hình ảnh có nội dung mức xám “phong phú” và các vùng có giá trị cường độ thay đổi chậm. Các mục trong cột thứ sáu của Bảng 6.4 phù hợp với cách giải thích này.

Các mục trong cột cuối cùng của bảng là thước đo tính ngẫu nhiên trong ma trận đồng hiện, từ đó chuyển thành thước đo tính ngẫu nhiên trong các hình ảnh tương ứng. Đúng như mong đợi, có giá trị cao nhất vì hình ảnh mà nó được tạo ra là hoàn toàn ngẫu nhiên. Hai mục còn lại là tự giải thích. Lưu ý rằng số đo entropy cho gần mức tối đa theo lý thuyết là 16 ($2 \log_2 256 = 16$). Hình ảnh trong Hình 6.31(a) bao gồm nhiều đồng nhất, do đó mỗi mức cường độ có xác suất xuất hiện xấp xỉ bằng nhau, đó là điều kiện được nêu trong Bảng 6.3 cho entropy mức tối đa.


Cho đến nay, chúng ta đã xử lý các hình ảnh đơn lẻ và ma trận đồng xuất hiện của chúng. Giả sử chúng ta muốn “khám phá” (mà không cần nhìn vào hình ảnh) xem có bất kỳ phần nào trong những hình ảnh này chứa các thành phần lặp lại (tức là các kết cấu định kỳ). Một cách để hoàn thành mục tiêu này là kiểm tra bộ mô tả tương quan cho các chuỗi ma trận xảy ra đồng thời, xuất phát từ những hình ảnh này bằng cách tăng khoảng cách giữa các lân cận. Như đã đề cập trước đó, thông thường khi làm việc với các chuỗi ma trận đồng hiện, lượng tử hóa số lượng cường độ nhằm giảm kích thước ma trận và tải tính toán tương ứng. Các kết quả sau đây thu được bằng cách sử dụng $L=8$.

Hình 6.33 hiển thị đồ thị của các bộ mô tả tương quan như là một hàm của “độ lệch” theo chiều ngang (tức là khoảng cách theo chiều ngang giữa các lân cận) từ 1 (đối với các điểm ảnh liền kề) đến 50. Hình 6.33(a) cho thấy tất cả các giá trị tương quan đều gần bằng 0, biểu thị rằng không có mẫu nào như vậy được tìm thấy trong hình ảnh ngẫu nhiên. Hình dạng của mối tương quan trong Hình 6.33(b) là một dấu hiệu rõ ràng rằng hình ảnh đầu vào có dạng hình sin theo hướng ngang. Lưu ý rằng hàm tương quan bắt đầu ở giá trị cao, sau đó giảm dần khi khoảng cách giữa các lân cận tăng lên và sau đó lặp lại.



Hình 6.33 Các giá trị của bộ mô tả tương quan như là một hàm bù (khoảng cách giữa các điểm ảnh “liền kề”) tương ứng với các hình ảnh (a) nhiễu, (b) hình sin và (c) bảng mạch trong Hình 6.31.

Hình 6.33(c) cho thấy rằng bộ mô tả tương quan liên quan đến hình ảnh bảng mạch ban đầu giảm xuống, nhưng có đỉnh cao đối với khoảng cách bổ sung là 16 điểm ảnh. Phân tích hình ảnh trong Hình 6.31(c) cho thấy các mối hàn phía trên tạo thành một mẫu lặp đi lặp lại cách nhau khoảng 16 điểm ảnh (xem Hình 6.34). Đỉnh chính tiếp theo là ở mức 32, do cùng một mẫu gây ra, nhưng biên độ của đỉnh thấp hơn vì số lần lặp lại ở khoảng cách này ít hơn ở mức 16 điểm ảnh. Một quan sát tương tự giải thích đỉnh thậm chí còn nhỏ hơn ở độ lệch 48 điểm ảnh.



Hình 6.34 Một phần được phóng to của hình ảnh bảng mạch hiển thị tính tuần hoàn của các thành phần.

6.4.4. Các tiếp cận phổ - spectral approaches

Phổ Fourier phù hợp một cách lý tưởng để mô tả tính định hướng của các mẫu 2-D tuần hoàn hoặc bán tuần hoàn trong một ảnh. Những kiểu kết cấu tổng thể này có thể dễ dàng được phân biệt dưới dạng nồng độ của các vụ nổ năng lượng cao trong quang phổ. Ở đây, chúng ta xem xét ba đặc điểm của phổ Fourier hữu ích cho việc mô tả kết cấu: (1) các đỉnh nổi bật trong phổ đưa ra hướng chính của các mẫu kết cấu; (2) vị trí của các đỉnh trong mặt phẳng tần số cho biết chu kỳ không gian cơ bản của các mẫu; và (3) loại bỏ bất kỳ thành phần định kỳ nào thông qua việc lọc để lại các phần tử hình ảnh không định kỳ, sau đó có thể được mô tả bằng các kỹ thuật thống kê. Hãy nhớ lại rằng phổ đối xứng qua gốc tọa độ, do đó chỉ cần xem xét một nửa mặt phẳng tần số. Do đó, với mục đích phân tích, mỗi mẫu tuần hoàn chỉ được liên kết với một đỉnh trong phổ chứ không phải hai.

Việc phát hiện và giải thích các đặc điểm phổ vừa đề cập thường được đơn giản hóa bằng cách biểu thị phổ theo tọa độ cực để thu được hàm $S(r, \theta)$ trong đó S là hàm phổ và r, θ là các biến trong hệ tọa độ này. Đối với mỗi hướng θ , $S(r, \theta)$ có thể được coi là hàm 1-D $S_\theta(r)$. Tương tự, đối với mỗi tần số r , $S_r(\theta)$ là hàm 1-D. Phân tích $S_\theta(r)$ với một giá trị θ cố định mang lại hành vi của phổ (ví dụ: sự hiện diện của các đỉnh) dọc theo hướng xuyên tâm từ gốc, trong khi phân tích $S_r(\theta)$ với giá trị cố định của r mang lại hành vi dọc theo một vòng

tròn có tâm ở gốc.

Một mô tả tổng quát hơn có được bằng cách tích hợp (tổng các biên rời rạc) các hàm này:

$$S(r) = \sum_{\theta=0}^{\pi} S_{\theta}(r) \quad (6-32)$$

và

$$S(\theta) = \sum_{r=1}^{R_0} S_r(\theta) \quad (6-33)$$


trong đó R_0 là bán kính của hình tròn có tâm ở gốc tọa độ.

Các kết quả của phương trình (6-32) và (6-33) tạo thành một cặp giá trị $[S(r), S(\theta)]$ cho mỗi cặp tọa độ (r, θ) . Bằng cách thay đổi các tọa độ này, chúng ta có thể tạo ra hai hàm 1-D, $S(r), S(\theta)$ tạo thành mô tả năng lượng quang phổ của kết cấu cho một toàn bộ hình ảnh hoặc khu vực đang được xem xét. Hơn nữa, bản thân các bộ mô tả của các chức năng này có thể được tính toán để mô tả hành vi của chúng một cách định lượng. Các mô tả hữu ích cho mục đích này là vị trí của giá trị cao nhất, giá trị trung bình và phương sai của cả biên độ và biên thiên thực, cũng như khoảng cách giữa giá trị trung bình và giá trị cao nhất của hàm.

VÍ DỤ 6.14 Kết cấu phổ

Hình 6.35(a) hiển thị một hình ảnh chứa các đối tượng được phân bố ngẫu nhiên và Hình 6.35(b) hiển thị một hình ảnh trong đó các đối tượng này được sắp xếp tuần hoàn. Hình 6.35(c) và (d) thể hiện phổ Fourier tương ứng. Sự bùng nổ năng lượng định kỳ kéo dài theo tứ giác theo hai chiều trong cả hai phổ Fourier là do kết cấu tuần hoàn của vật liệu nền thô mà các vật thể nằm trên đó. Các thành phần chiếm ưu thế khác trong quang phổ ở Hình 6.35(c) là do sự định hướng ngẫu nhiên của các cạnh của vật thể trong Hình 6.35(a). Mặt khác, năng lượng chính trong Hình 6.35(d) không liên kết với nền nằm dọc theo trục ngang, tương ứng với các cạnh thẳng đứng mạnh trong Hình 6.35(b).


a b
c d



Hình 6.35 (a) và (b) Hình ảnh của các vật thể ngẫu nhiên và có thứ tự. (c) và (d) Phổ Fourier tương ứng. Tất cả hình ảnh đều có kích thước 600×600 điểm ảnh.

Hình 6.36(a) và (b) là đồ thị của $S(r), S(\theta)$ cho các đối tượng ngẫu nhiên, và tương tự trong (c) và (d) cho các đối tượng được sắp xếp. Đồ thị của $S(r)$ đối với các đối tượng ngẫu nhiên cho thấy không có thành phần tuần hoàn mạnh (nghĩa là không có đỉnh vượt trội trong phổ ngoài đỉnh ở gốc, là thành phần dc). Ngược lại, đồ thị $S(r)$ cho các vật thể có thứ tự cho thấy

một đỉnh mạnh ở gần $r = 15$ và một đỉnh gần nhỏ hơn $r = 25$ tương ứng với sự lặp lại theo chiều ngang định kỳ của các vùng sáng (vật thể) và vùng tối (nền) trong Hình 6.35(b). Tương tự, tính chất ngẫu nhiên của các bùng nổ năng lượng trong Hình 6.35(c) khá rõ ràng trong đồ thị của $S(r)$ Hình 6.36(b). Ngược lại, đồ thị trong Hình 6.36(d) cho thấy các thành phần năng lượng mạnh ở vùng gần góc tọa độ và tại 90° và 180° . Điều này phù hợp với sự phân bố năng lượng của phổ thứ n trong Hình 6.35(d).



Hình 6.36 (a) và (b) Đồ thị của $S(r), S(\theta)$ cho Hình 6.35(a). (c) và (d) Đồ thị của $S(r), S(\theta)$ cho Hình 6.35(b). Tất cả các trục dọc đều được $\times 10^5$.

6.4.5. Các bất biến mô men - moment invariants

Mô men thứ tự $(p + q)$ 2-D của một hình ảnh kỹ thuật số $(M \times N)$, $f(x, y)$, được định nghĩa là

$$m_{pq} = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} x^p y^q f(x, y) \quad (6-34)$$

trong đó $p = 0, 1, 2, \dots$ và $q = 0, 1, 2, \dots$ là số nguyên. Mô men trung tâm của thức tự $(p + q)$ tương ứng được định nghĩa là:

$$\mu_{pq} = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} (x - \bar{x})^p (y - \bar{y})^q f(x, y) \quad (6-35)$$

với $p = 0, 1, 2, \dots$ và $q = 0, 1, 2, \dots$, trong đó:

$$\bar{x} = \frac{m_{10}}{m_{00}} \text{ và } \bar{y} = \frac{m_{01}}{m_{00}} \quad (6-36)$$

Mô men trung tâm chuẩn hóa của trật tự $(p + q)$ được ký hiệu η_{pq} được định nghĩa là:

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{\gamma}} \quad (6-37)$$

trong đó:

$$\gamma = \frac{p+q}{2} + 1 \quad (6-38)$$

với $p + q = 2, 3, \dots$ Một tập hợp gồm bảy mô men bất biến 2-D có thể được suy ra từ mô men trung tâm chuẩn hóa thứ hai và thứ ba.

$$\phi_1 = \eta_{20} + \eta_{02} \quad (6-39)$$

$$\phi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \quad (6-40)$$

$$\phi_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \quad (6-41)$$

$$\phi_4 = (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2 \quad (6-42)$$

$$\phi_5 = (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \quad (6-43)$$


$$\phi_6 = (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}^2(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03}) \quad (6-44)$$

$$\phi_7 = (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \quad (6-45)$$

Tập hợp các mô men này bất biến đối với sự dịch chuyển, thay đổi tỷ lệ, phản chiếu (trong dấu trừ) và xoay. Chúng ta có thể gán ý nghĩa vật lý cho một số mô men bất biến bậc thấp. Ví dụ: ϕ_1 là tổng của hai mô men đối với trục chính của mức lan truyền dữ liệu, do đó, mô men này có thể được hiểu là thước đo mức lan truyền dữ liệu. Tương tự, ϕ_3 là sự khác biệt của mô men thứ hai và có thể được hiểu là thước đo của “độ mảnh mai”. Tuy nhiên, khi thứ tự của các mô men bất biến tăng lên, độ phức tạp trong công thức của chúng khiến ý nghĩa vật lý bị mất đi. Tầm quan trọng của phương trình (6-39) đến (6-45) là tính bất biến của chúng chứ không phải ý nghĩa vật lý của chúng.

VÍ DỤ 6.15 Bất biến mô men

Mục tiêu của ví dụ này là tính toán và so sánh các bất biến mô men trước đó bằng cách sử dụng hình ảnh trong Hình 6.37(a). Đường viền màu đen (0) đã được thêm vào để làm cho tất cả hình ảnh trong ví dụ này có cùng kích thước; các số 0 không ảnh hưởng đến việc tính toán các bất biến mô men. Các Hình 6.37(b) đến (f) hiển thị ảnh gốc được dịch, được chia tỷ lệ 0,5 theo cả hai chiều không gian, được phản chiếu, được xoay 45° và được xoay 90° một cách lần lượt. Bảng 6.5 tóm tắt các giá trị của bảy mô men bất biến cho sáu hình ảnh này. Để giảm phạm vi động và do đó đơn giản hóa việc giải thích, các giá trị hiển thị được chia tỷ lệ bằng cách sử dụng biểu thức $-sgn(\phi_i) \log_{10}(|\phi_i|)$. Giá trị tuyệt đối là cần thiết để xử lý bất kỳ số nào có thể âm. Thuật ngữ $sgn(\phi_i)$ này giữ nguyên dấu của ϕ_i và dấu trừ ở phía trước để xử lý các phân số trong tính toán nhật ký. Ý tưởng là làm cho các con số dễ diễn giải hơn. Mỗi quan tâm trong ví dụ này là tính bất biến và dấu tương đối của các mô men chứ không phải giá trị thực của chúng. Hai điểm chính trong Bảng 6.5 là: (1) sự gần nhau của các giá trị mô men, không phụ thuộc vào sự tịnh tiến, thay đổi tỷ lệ, phản chiếu và xoay; và (2) thực tế là dấu của ϕ_i là khác nhau đối với ảnh được phản chiếu.



Hình 6.37 (a) Ảnh gốc. (b)–(f) Hình ảnh được dịch, chia tỷ lệ một nửa, được phản chiếu, xoay 45° và xoay 90°.

BẢNG 6.5

Bất biến mô men cho các ảnh trong Hình 6.37

Moment Invariant	Original Image	Translated	Half Size	Mirrored	Rotated 45°	Rotated 90°
ϕ_1	2.8662	2.8662	2.8664	2.8662	2.8661	2.8662
ϕ_2	7.1265	7.1265	7.1257	7.1265	7.1266	7.1265
ϕ_3	10.4109	10.4109	10.4047	10.4109	10.4115	10.4109
ϕ_4	10.3742	10.3742	10.3719	10.3742	10.3742	10.3742
ϕ_5	21.3674	21.3674	21.3924	21.3674	21.3663	21.3674
ϕ_6	13.9417	13.9417	13.9383	13.9417	13.9417	13.9417
ϕ_7	-20.7809	-20.7809	-20.7724	20.7809	-20.7813	-20.7809

6.5. Các bộ mô tả đặc trưng ảnh sử dụng các thành phần chính – principal components

Tài liệu trong phần này có thể áp dụng cho các ranh giới và vùng. Nó khác với cuộc thảo luận của chúng ta cho đến nay, theo nghĩa là các đặc điểm dựa trên nhiều hình ảnh. Giả sử chúng ta có ba ảnh thành phần của một ảnh màu. Ba hình ảnh có thể được coi là một đơn vị bằng cách biểu thị từng nhóm ba điểm ảnh tương ứng dưới dạng véc tơ, như đã thảo luận trong Phần 6.1. Nếu chúng ta có tổng cộng n ảnh đã đăng ký thì các điểm ảnh tương ứng ở cùng một vị trí không gian trong tất cả các ảnh có thể được sắp xếp dưới dạng véc tơ n chiều:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} \quad (6-46)$$

Trong suốt phần này, giả định là tất cả các véc tơ đều là véc tơ cột (tức là ma trận có bậc $n \times 1$). Chúng ta có thể viết chúng trên một dòng văn bản đơn giản bằng cách biểu thị chúng như $x = (x_1, x_2, \dots, x_n)^T$ trong đó T biểu thị chuyển vị.

Chúng ta có thể coi các véc tơ là các đại lượng ngẫu nhiên, giống như chúng ta đã làm khi xây dựng biểu đồ cường độ. Điểm khác biệt duy nhất là, thay vì nói về các đại lượng như giá trị trung bình và phương sai của các biến ngẫu nhiên, giờ đây chúng ta nói về véc tơ trung bình và ma trận hiệp phương sai của véc tơ ngẫu nhiên, như đã giải thích trong Phần 2.6. Véc tơ trung bình của quần thể được định nghĩa là

$$\mathbf{m}_x = E\{x\} \quad (6-47)$$

trong đó $E\{x\}$ là giá trị kỳ vọng của x và chỉ số dưới biểu thị rằng m được liên kết với tập hợp các véc tơ x . Hãy nhớ lại rằng giá trị mong đợi của một véc tơ hoặc ma trận có được bằng cách lấy giá trị mong đợi của từng phần tử.

Ma trận hiệp phương sai của quần thể véc tơ được định nghĩa là:

$$\mathbf{C}_x = E\{(x - \mathbf{m}_x)(x - \mathbf{m}_x)^T\} \quad (6-48)$$

Vì x có n chiều nên C_x là ma trận $n \times n$. Phần tử c_{ii} của C_x là phương sai của x_i thành phần thứ i của x trong quần thể và phần tử c_{ij} của C_x là hiệp phương sai giữa các phần tử x_i và x_j của các véc tơ này. Ma trận C_x là thực và đối xứng. Nếu các phần tử x_i và x_j không tương quan với nhau thì hiệp phương sai của chúng bằng 0 và do đó $c_{ij} = 0$ tạo ra ma trận hiệp phương sai đường chéo.

Bởi vì C_x là số thực và đối xứng nên việc tìm một tập n véc tơ riêng trực giao luôn có thể thực hiện được. Đặt e_i và $\lambda_i, i = 1, 2, \dots, n$ là các véc tơ riêng và các giá trị riêng tương ứng của C_x được sắp xếp (để thuận tiện) theo thứ tự giảm dần sao cho $\lambda_j > \lambda_{j+1}$ với $j = 1, 2, \dots, n - 1$. Đặt A là một ma trận có các hàng được hình thành từ các véc tơ riêng của C_x được sắp xếp theo giá trị giảm dần của các giá trị riêng của chúng, sao cho hàng đầu tiên của A là véc tơ riêng tương ứng với giá trị riêng lớn nhất.

Giả sử chúng ta sử dụng A làm ma trận biến đổi để ánh xạ x thành các véc tơ ký hiệu là y , như sau

$$y = A(x - m_x) \quad (6-49)$$

Biểu thức này được gọi là phép biến đổi Hotelling, mà chúng ta sẽ tìm hiểu sau đây, nó có một số tính chất rất thú vị và hữu ích.

Không khó để chỉ ra rằng giá trị trung bình của véc tơ y thu được từ phép biến đổi này bằng 0; đó là,

$$m_y = E\{y\} = 0 \quad (6-50)$$

Theo lý thuyết ma trận cơ bản, ma trận hiệp phương sai của y được cho theo A và C_x bằng biểu thức

$$C_y = AC_x A^T \quad (6-51)$$

Hơn nữa, do cách hình thành A , C_y là ma trận đường chéo có các phần tử dọc theo đường chéo chính là các giá trị riêng của C_x , đó là:

$$C_y = \begin{bmatrix} \lambda_1 & 0 & & 0 \\ 0 & \lambda_2 & & 0 \\ & & \ddots & \\ 0 & & & \lambda_n \end{bmatrix} \quad (6-52)$$

Các phần tử ngoài đường chéo của ma trận hiệp phương sai này là 0, do đó các phần tử của véc tơ y không tương quan. Hãy nhớ rằng λ_i là giá trị riêng của C_x và các phần tử dọc theo đường chéo chính của ma trận chéo là giá trị riêng của nó. Do đó, C_x và C_y có cùng giá trị riêng.

Một tính chất quan trọng khác của phép biến đổi Hotelling liên quan đến việc tái tạo x từ y . Vì các hàng của A là các véc tơ trực chuẩn nên nó tuân theo $A^{-1} = A^T$ và bất kỳ véc tơ x nào cũng có thể được phục hồi từ y tương ứng của nó bằng cách sử dụng biểu thức:

$$x = A^T y + m_x \quad (6-53)$$

Tuy nhiên, giả sử rằng, thay vì sử dụng tất cả các véc tơ riêng của C_x chúng ta, chúng ta tạo thành một ma trận A_k từ k véc tơ riêng tương ứng với k giá trị riêng lớn nhất, tạo ra một ma trận biến đổi có bậc $k \times n$. Các véc tơ y khi đó sẽ có k chiều và sự tái cấu trúc được đưa ra trong biểu thức (6-53) sẽ không còn chính xác nữa (điều này hơi giống với thủ tục chúng ta đã sử dụng trong Phần 6.3 để mô tả một ranh giới với một vài hệ số Fourier).

véc tơ được xây dựng lại bằng cách sử dụng A_k là:

$$\hat{x} = A_k^T y + m_x \quad (6-54)$$

Có thể chỉ ra rằng sai số bình phương trung bình giữa x và $\hat{x}$ được cho bởi biểu thức:


$$e_{ms} = \sum_{j=1}^n \lambda_j - \sum_{j=1}^k \lambda_j = \sum_{j=k+1}^n \lambda_j \quad (6-55)$$

Phương trình (6-55) chỉ ra rằng sai số bằng 0 nếu $k = n$ (nghĩa là, nếu tất cả các véc tơ riêng

được sử dụng trong phép biến đổi). Bởi vì sự giảm đơn điệu của λ_j , phương trình (6-55) cũng chỉ ra rằng sai số có thể được giảm thiểu bằng cách chọn k véc tơ riêng liên kết với giá trị riêng lớn nhất. Do đó, phép biến đổi Hotelling là tối ưu theo nghĩa là nó giảm thiểu sai số bình phương trung bình giữa các véc tơ x và các giá trị $\hat{x}$ gần đúng của chúng. Do ý tưởng sử dụng các véc tơ riêng tương ứng với các giá trị riêng lớn nhất, phép biến đổi Hotelling còn được gọi là phép biến đổi thành phần chính.


VÍ DỤ 6.16 Sử dụng các thành phần chính để mô tả ảnh

Hình 6.38 cho thấy sáu ảnh vệ tinh đa phổ tương ứng với sáu dải quang phổ: xanh lam nhìn thấy được (450–520 nm), xanh lục nhìn thấy được (520–600 nm), đỏ nhìn thấy được (630–690 nm), hồng ngoại gần (760–900 nm), hồng ngoại trung bình (1550–1.750 nm) và hồng ngoại nhiệt (10.400–12.500 nm). Mục tiêu của ví dụ này là minh họa cách sử dụng các thành phần chính làm đặc điểm hình ảnh.



Hình 6.38 Hình ảnh đa phổ ở (a) màu xanh lam nhìn thấy được, (b) màu xanh lá cây nhìn thấy được, (c) màu đỏ nhìn thấy được, (d) gần hồng ngoại, (e) hồng ngoại giữa và (f) dải hồng ngoại nhiệt.

Việc sắp xếp các hình ảnh như trong Hình 6.39 dẫn đến sự hình thành một véc tơ sáu phần tử x từ mỗi tập hợp điểm ảnh tương ứng trong các hình ảnh, như đã thảo luận trước đó trong phần này. Các hình ảnh trong ví dụ này có kích thước 564×564 điểm ảnh, do đó tập hợp bao gồm $(564)^2 = 318,096$ các véc tơ mà từ đó véc tơ trung bình, ma trận hiệp phương sai, các giá trị riêng và véc tơ riêng tương ứng được tính toán. Sau đó, các véc tơ riêng được sử dụng làm các hàng của ma trận A và thu được một tập hợp các véc tơ y bằng phương trình (6-49). Tương tự, chúng ta đã sử dụng phương trình (6-51) để có được C_y . Bảng 6.6 cho thấy các giá trị riêng của ma trận này. Lưu ý sự vượt trội của hai giá trị riêng đầu tiên.




Hình 6.39 Hình thành một véc tơ đặc trưng từ các điểm ảnh tương ứng trong sáu hình ảnh.

BẢNG 6.6

Giá trị riêng của C_x thu được từ các ảnh trong Hình 6.38.

λ_1	λ_2	λ_3	λ_4	λ_5	λ_6
10344	2966	1401	203	94	31


Một tập hợp các hình ảnh thành phần chính được tạo ra bằng cách sử dụng các véc tơ y được đề cập trong đoạn trước (các hình ảnh được xây dựng từ các véc tơ bằng cách áp dụng ngược lại Hình 6.39). Hình 6.40 thể hiện kết quả. Hình 6.40(a) được hình thành từ thành phần đầu tiên của véc tơ 318.096 y , Hình 6.40(b) từ thành phần thứ hai của các véc tơ này, v.v., vì vậy những ảnh này có cùng kích thước với ảnh gốc trong Hình 6.38. Đặc điểm rõ ràng nhất trong các hình ảnh thành phần chính là một phần đáng kể chi tiết tương phản được chứa trong hai hình ảnh đầu tiên và nó giảm nhanh chóng từ đó. Lý do có thể được giải thích bằng cách nhìn vào giá trị riêng. Như Bảng 6.6 cho thấy, hai giá trị riêng đầu tiên lớn hơn nhiều so với các giá trị còn lại. Bởi vì giá trị riêng là phương sai của các phần tử của véc tơ y và phương sai là thước đo độ tương phản cường độ, không có gì ngạc nhiên khi hình ảnh được hình thành từ các thành phần véc tơ tương ứng với giá trị riêng lớn nhất sẽ thể hiện độ tương phản cao nhất. Trên thực tế, hai hình ảnh đầu tiên trong Hình 6.40 chiếm khoảng 89% tổng phương sai. Bốn hình ảnh còn lại có độ chi tiết tương phản thấp vì chỉ chiếm 11% còn lại.




Hình 6.40 Sáu hình ảnh thành phần chính thu được từ các véc tơ được tính toán bằng phương trình (6-49). Các véc tơ được chuyển đổi thành hình ảnh bằng cách áp dụng ngược lại Hình 6.39.

Theo phương trình (6-54) và (6-55), nếu chúng ta sử dụng tất cả các véc tơ riêng trong ma trận A , chúng ta có thể tái tạo lại các ảnh gốc từ các ảnh thành phần chính với sai số bằng 0 giữa ảnh gốc và ảnh được tái tạo (nghĩa là các ảnh sẽ giống hệt nhau). Nếu mục tiêu là lưu trữ và/hoặc truyền tải các ảnh thành phần chính và ma trận biến đổi để tái tạo lại các ảnh gốc sau này, thì việc lưu trữ và/hoặc truyền tải tất cả các ảnh thành phần chính sẽ không có ý nghĩa gì vì sẽ không thu được gì. Tuy nhiên, giả sử rằng chúng ta giữ và/hoặc truyền chỉ hai ảnh thành phần chính. Khi đó sẽ tiết kiệm được đáng kể chi phí lưu trữ và/hoặc truyền tải (ma trận A sẽ có kích thước 2×6 nên tác động của nó sẽ không đáng kể).

Hình 6.41 cho thấy kết quả tái tạo lại sáu ảnh đa phổ từ hai ảnh thành phần chính tương ứng với giá trị riêng lớn nhất. Năm hình ảnh đầu tiên trông khá giống với hình ảnh gốc trong Hình 6.38, nhưng điều này không đúng với hình ảnh thứ sáu. Nguyên nhân là vì hình ảnh thứ sáu ban đầu thực sự bị mờ, nhưng hai hình ảnh thành phần chính được sử dụng trong quá trình tái tạo lại sắc nét nên mất “chi tiết” mờ. Hình 6.42 cho thấy sự khác biệt giữa ảnh gốc và ảnh được tái tạo. Các hình ảnh trong Hình 6.42 đã được cải tiến để làm nổi bật sự khác biệt giữa chúng. Nếu chúng được hiển thị mà không được tăng cường, năm hình ảnh đầu tiên sẽ xuất hiện gần như toàn màu đen, với hình ảnh thứ sáu (khác biệt) hiển thị nhiều biến đổi nhất.



Hình 6.41 Hình ảnh đa phổ được tái tạo chỉ bằng cách sử dụng hai hình ảnh thành phần chính tương ứng với hai véc tơ thành phần chính có giá trị riêng lớn nhất. So sánh những hình ảnh này với ảnh gốc trong Hình 6.38.



Hình 6.42 Sự khác biệt giữa hình ảnh gốc và hình ảnh được tái tạo. Tất cả các hình ảnh đều được nâng cao bằng cách chia tỷ lệ chúng thành phạm vi $[0, 255]$ đầy đủ để hỗ trợ phân tích trực quan.

6.6. Các đặc trưng toàn ảnh

Các đặc trưng được giới thiệu trong Phần 6.2 đến 6.4 rất phù hợp cho các ứng dụng (ví dụ: kiểm tra công nghiệp), trong đó các khu vực riêng lẻ có thể được phân đoạn một cách đáng tin cậy bằng các phương pháp như các phương pháp đã được trình bày. Ngoại trừ ứng dụng trong Ví dụ 6.17, các véc tơ đặc trưng thành phần chính trong Phần 6.5 khác với tài liệu trước đó, theo nghĩa là chúng dựa trên nhiều hình ảnh. Nhưng ngay cả những bộ mô tả này cũng được bản địa hóa thành các tập hợp điểm ảnh tương ứng. Trong một số ứng dụng, chẳng hạn như tìm kiếm cơ sở dữ liệu hình ảnh để tìm kết quả trùng khớp (ví dụ như trong nhận


dạng khuôn mặt người), sự biến đổi giữa các hình ảnh quá rộng đến mức các phương pháp đã trình bày không thể áp dụng được.

Công nghệ tiên tiến trong xử lý hình ảnh là khi độ phức tạp của nhiệm vụ tăng lên thì số lượng kỹ thuật phù hợp để giải quyết các nhiệm vụ đó sẽ giảm đi. Điều này đặc biệt đúng khi xử lý các bộ mô tả đặc điểm áp dụng cho toàn bộ hình ảnh là thành viên của một họ hình ảnh lớn. Trong phần này, chúng ta thảo luận về hai phương pháp phát hiện đặc trưng chính hiện đang được sử dụng cho mục đích này. Một cái dựa trên việc phát hiện các góc và cái còn lại hoạt động với toàn bộ các vùng trong một hình ảnh. Sau đó, trong Phần 6.7, chúng ta trình bày cách tiếp cận mô tả và phát hiện đặc trưng được thiết kế đặc biệt để làm việc với các loại tính năng này.

6.6.1. Bộ phát hiện góc Harris-Stephens

Theo trực giác, chúng ta coi một góc là sự thay đổi hướng nhanh chóng của một đường cong. Các góc là những đặc điểm có hiệu quả cao vì chúng đặc biệt và bất biến theo quan điểm. Do những đặc điểm này, các góc được sử dụng thường xuyên để khớp các tính năng hình ảnh trong các ứng dụng như theo dõi để điều hướng tự động, thuật toán thị giác máy âm thanh nổi và truy vấn cơ sở dữ liệu hình ảnh.

Trong phần này, chúng ta thảo luận về thuật toán phát hiện góc. Ý tưởng đằng sau máy dò góc Harris-Stephens (HS) được minh họa trong Hình 6.43. Cách tiếp cận cơ bản như sau: Các góc được phát hiện bằng cách chạy một cửa sổ nhỏ trên hình ảnh, như chúng ta đã làm về lọc không gian. Cửa sổ máy dò được thiết kế để tính toán sự thay đổi cường độ. Chúng ta quan tâm đến ba kịch bản: (1) Các vùng có cường độ bằng 0 (hoặc nhỏ) thay đổi theo mọi hướng, xảy ra khi cửa sổ nằm trong một vùng không đổi (hoặc gần như không đổi), như ở vị trí A trong Hình 6.43; (2) các vùng thay đổi theo một hướng nhưng không có (hoặc thay đổi nhỏ) theo hướng trực giao, điều này xảy ra khi cửa sổ mở rộng ranh giới giữa hai vùng, như ở vị trí B; và (3) các khu vực có sự thay đổi đáng kể theo mọi hướng, một điều kiện xảy ra khi cửa sổ chứa một góc (hoặc các điểm cô lập), như ở vị trí C. Bộ dò góc HS là một công thức toán học cố gắng phân biệt giữa ba điều kiện này.



Hình 6.43 Minh họa cách hoạt động của bộ phát hiện góc Harris-Stephens trong ba loại tiểu vùng được biểu thị bằng A (phẳng), B (cạnh) và C (góc). Các mũi tên lác lác biểu thị phản ứng định hướng bằng đồ họa trong máy dò khi nó di chuyển trong ba khu vực được hiển thị.

Gọi f là một ảnh, và $f(s, t)$ là một mảng ảnh được xác định bởi các giá trị của (s, t) . Một miếng vá có cùng kích thước, nhưng bị dịch chuyển bởi (x, y) , được cho bởi $f(s + x, t + y)$. Khi đó, tổng có trọng số của các chênh lệch bình phương giữa hai miếng vá được cho bởi:

$$C(x, y) = \sum_s \sum_t w(s, t) [f(s + x, t + y) - f(s, t)]^2$$

trong đó $w(s, t)$ là hàm trọng số sẽ được thảo luận sau. Miếng vá bị dịch chuyển có thể được tính gần đúng bằng các số hạng tuyến tính của khai triển Taylor.

$$f(s + x, t + y) \approx f(s, t) + xf_x(s, t) + yf_y(s, t) \quad (6-57)$$

trong đó $f_x(s, t) = \partial f / \partial x$ và $f_y(s, t) = \partial f / \partial y$ cả hai đều được đánh giá tại (s, t) . Sau đó chúng ta có thể viết phương trình (6-56) như sau:

$$C(x, y) = \sum_s \sum_t w(s, t) [xf_x(s, t) + yf_y(s, t)]^2 \quad (6-58)$$

Phương trình này có thể viết dưới dạng ma trận dưới dạng:

$$C(x, y) = [x \quad y] \mathbf{M} \begin{bmatrix} x \\ y \end{bmatrix} \quad (6-59)$$

trong đó,

$$\mathbf{M} = \sum_s \sum_t w(s, t) \mathbf{A} \quad (6-60)$$

và


$$\mathbf{A} = \begin{bmatrix} f_x^2 & f_x f_y \\ f_x f_y & f_y^2 \end{bmatrix} \quad (6-61)$$

Ma trận $\mathbf{M}$ đôi khi còn được gọi là ma trận Harris. Điều này được hiểu rằng các số hạng của nó được đánh giá tại (s, t) . Nếu $w(s, t)$ đẳng hướng thì $\mathbf{M}$ đối xứng vì $\mathbf{A}$ đối xứng. Hàm trọng số $w(s, t)$ được sử dụng trong bộ dò HS thường có một trong hai dạng: (1) nó là 1 bên trong miếng vá và 0 ở những nơi khác (nghĩa là nó có hình dạng của hạt nhân bộ lọc thông thấp dạng hộp), hoặc (2) nó là hàm số mũ có dạng:

$$w(s, t) = e^{-(s^2 + t^2)/2\sigma^2} \quad (6-62)$$

Hộp được sử dụng khi tốc độ tính toán là tối quan trọng và độ nhiễu thấp. Dạng hàm mũ được sử dụng khi việc làm mịn dữ liệu là quan trọng.

Như được minh họa trong Hình 6.43, một góc được đặc trưng bởi các giá trị lớn ở vùng C, theo cả hai hướng không gian. Tuy nhiên, khi bản vá vượt quá một ranh giới thì cũng sẽ có phản hồi theo một hướng. Câu hỏi là: Làm thế nào chúng ta có thể nhận ra sự khác biệt? Như chúng ta đã thảo luận trong Phần 6.5 (xem Ví dụ 6.17), các véc tơ riêng của ma trận thực, đối xứng (chẳng hạn như $\mathbf{M}$ ở trên) chỉ theo hướng trải rộng dữ liệu tối đa và các giá trị riêng tương ứng tỷ lệ thuận với lượng trải rộng dữ liệu theo hướng của các véc tơ riêng. Trong thực tế, véc tơ riêng là các trục chính của hình elip phù hợp với dữ liệu và độ lớn của giá trị riêng là khoảng cách từ tâm của hình elip đến các điểm mà nó giao với các trục chính. Hình 6.46 minh họa cách chúng ta có thể sử dụng các thuộc tính này để phân biệt giữa ba trường hợp mà chúng ta quan tâm.



Hình 6.44 (a)–(c) Hình ảnh nhiễu và các mảng hình ảnh (hình vuông nhỏ) bao gồm các vùng hình ảnh có nội dung tương tự như trong Hình 6.43. (d)–(f) Đồ thị các cặp giá trị (f_x, f_y) biểu thị đặc điểm của giá trị riêng của M hữu ích cho việc phát hiện sự hiện diện của một góc trong một mảng ảnh.

Vì vậy, chúng ta thấy rằng các giá trị riêng của ma trận được hình thành từ các dẫn xuất trong mảng hình ảnh có thể được sử dụng để phân biệt giữa ba kịch bản quan tâm. Tuy nhiên, thay vì sử dụng các giá trị riêng (rất tốn kém để tính toán), bộ tách HS sử dụng thước đo đáp ứng góc dựa trên thực tế là vết của ma trận vuông bằng tổng các giá trị riêng của nó và định thức của nó bằng tích các giá trị riêng của nó. Độ đo được định nghĩa là:

$$R = \lambda_x \lambda_y - k(\lambda_x + \lambda_y)^2 = \det(\mathbf{M}) - k \text{trace}^2(\mathbf{M}) \quad (6-63)$$


trong đó k là hằng số sẽ được giải thích ngắn gọn. Thước đo R có giá trị dương lớn khi cả hai giá trị riêng đều lớn, biểu thị sự hồi phục của một góc; nó có giá trị âm lớn khi một giá trị riêng lớn và giá trị kia nhỏ, biểu thị một cạnh; và giá trị tuyệt đối của nó nhỏ khi cả hai giá trị riêng đều nhỏ, biểu thị rằng vùng ảnh đang được xem xét là phẳng.

Hằng số k được xác định theo kinh nghiệm và phạm vi giá trị của nó phụ thuộc vào việc triển khai. Ví dụ: Hộp công cụ xử lý ảnh MATLAB sử dụng $0 < k < 0.25$. Chúng ta có thể hiểu k là “hệ số nhạy cảm;” nó càng nhỏ thì khả năng máy dò tìm được các góc càng cao. Thông thường, R được sử dụng với một ngưỡng, T . Chúng ta nói rằng một góc tại một vị trí hình ảnh chỉ được phát hiện nếu $R > T$ tại vị trí đó.

VÍ DỤ 6.18 Ứng dụng bộ phát hiện góc HS

Hình 6.45(a) hiển thị hình ảnh nhiễu và Hình 6.45(b) là kết quả của việc sử dụng bộ dò góc HS với $k = 0.04$ và $T = 0.01$ (các giá trị mặc định trong quá trình triển khai của chúng ta). Tất cả các góc của hình vuông đều được phát hiện chính xác, nhưng số lượng phát hiện sai quá cao (lưu ý rằng tất cả các lỗi xảy ra ở phía bên phải của hình ảnh, nơi có sự khác biệt về cường độ giữa các hình vuông ít hơn). Hình 6.45(c) cho thấy kết quả thu được bằng cách tăng k lên 0,1 và để T ở mức 0,01. Lần này, tất cả các góc đều được phát hiện chính xác. Như Hình 6.45(d) cho thấy, việc tăng ngưỡng lên $T = 0.1$ sẽ mang lại kết quả tương tự. Trong thực tế, việc sử dụng giá trị mặc định của k và để T ở mức 0,1 cũng tạo ra kết quả tương tự, như minh họa trong Hình 6.45(e). Điểm mấu chốt của tất cả những điều này là có


sự linh hoạt đáng kể trong sự tương tác giữa các giá trị của k và T . Hình 6.45(f) cho thấy kết quả thu được khi sử dụng giá trị mặc định cho k và sử dụng $T = 0.3$. Như mong đợi, việc tăng giá trị của ngưỡng đã loại bỏ một số các góc, trong trường hợp này chỉ thu được góc của các hình vuông có chênh lệch cường độ lớn hơn. Việc tăng giá trị k lên 0,1 và đặt T thành giá trị mặc định của nó mang lại kết quả tương tự, cũng như việc sử dụng $k = 0.1$ và $T = 0.3$ chứng minh lại tính linh hoạt trong các giá trị được chọn cho hai tham số này. Tuy nhiên, khi mức độ nhiễu tăng lên, phạm vi các giá trị có thể trở nên hẹp hơn, như kết quả trong đoạn tiếp theo.



Hình 6.45 (a) Một hình ảnh 600×600 có các giá trị trong phạm vi $[0,1]$, bị sai lệch bởi nhiễu Gaussian cộng với giá trị trung bình bằng 0 và phương sai là 0,006. (b) Kết quả của việc áp dụng bộ dò góc HS với $k = 0.04$ và $T = 0.01$ (giá trị mặc định). Một số lỗi có thể nhìn thấy được. (c) Kết quả sử dụng $k = 0.1$ và $T = 0.01$ (d) Kết quả sử dụng và (e) Kết quả sử dụng $k = 0.04$ và $T = 0.3$ (f) Kết quả sử dụng và (chỉ phát hiện được các góc mạnh nhất bên trái).

Hình 6.46(a) cho thấy bàn cờ bị hỏng do mức nhiễu Gaussian phụ cao hơn nhiều (xem chú thích hình). Mặc dù hình ảnh này trông không khác nhiều so với Hình 6.45(a), kết quả sử dụng các giá trị mặc định của k và T tệ hơn nhiều so với trước đây. Các góc sai được phát hiện ngay cả ở phía bên trái của ảnh, nơi có sự chênh lệch cường độ mạnh hơn nhiều. Hình 6.46(c) là kết quả của việc tăng k gần giá trị tối đa trong quá trình triển khai của chúng ta trong khi vẫn giữ T ở giá trị mặc định. Lần này chỉ riêng k cũng không thể vượt qua được độ ồn cao hơn. Mặt khác, giảm k về giá trị mặc định và tăng T lên 0,15 sẽ tạo ra một kết quả hoàn hảo, như biểu diễn trong Hình 6.46(d):

a	b
c	d



Hình 6.46 (a) Tương tự như Hình 6.45(a), nhưng bị sai lệch với nhiễu Gaussian có giá trị trung bình 0 và phương sai 0,01. (b) Kết quả sử dụng máy dò HS với $k = 0.04$ và $T = 0.01$ [so sánh với Hình 6.47(b)]. (c) Kết quả với $k = 0.249$ (gần giá trị cao nhất trong quá trình triển khai của chúng ta) và $T = 0.01$ (d) Kết quả của việc sử dụng $k = 0.04$ và $T = 0.15$.

Hình 6.47(a) cho thấy một hình ảnh phức tạp hơn với số lượng đáng kể các góc được nhúng trong các phạm vi cường độ khác nhau. Hình 6.47(b) là kết quả thu được bằng cách sử dụng các giá trị mặc định cho k và T . Như chúng ta có thể thấy, rất nhiều lỗi phát hiện đã xảy ra (ví dụ, xem số lượng lớn các phát hiện sai góc ở cạnh bên phải của tòa nhà). Chỉ riêng việc tăng k ít ảnh hưởng đến việc phát hiện quá mức các góc cho đến khi k gần giá trị tối đa của nó. Việc sử dụng các giá trị tương tự như trong Hình 6.46(c) dẫn đến hình ảnh trong Hình 6.47(c), cho thấy số lượng các góc bị sai đã giảm đi, dẫn đến việc thiếu nhiều góc quan trọng ở phía trước tòa nhà. Việc giảm k xuống 0,17 và tăng T lên 0,05 đã thực hiện công việc tốt hơn nhiều, như được chỉ ra trong Hình 6.47(d). Tham số k không đóng vai trò chính trong việc phát hiện góc cho hình ảnh tòa nhà. Trong thực tế, các hình 6.47(e) và (f) về cơ bản thể hiện cùng một mức hiệu suất thu được bằng cách giảm k xuống giá trị mặc định là 0,04 và sử dụng lần lượt $T = 0.05$ và $T = 0.07$.



Hình 6.47 Hình ảnh 600×600 của một tòa nhà. (b) Kết quả của việc áp dụng bộ dò góc HS với $k = 0.04$ và $T = 0.01$ (các giá trị mặc định trong quá trình triển khai của chúng ta). Nhiều góc không liên quan đã được phát hiện. (c) Kết quả sử dụng $k = 0.249$ giá trị mặc định cho T . (d) Kết quả sử dụng $k = 0.17$ và $T = 0.05$ (e) Kết quả sử dụng giá trị mặc định cho k và (f) Kết quả sử dụng giá trị mặc định của k và $T = 0.07$.

Cuối cùng, Hình 6.48 cho thấy khả năng phát hiện góc trên một hình ảnh được xoay. Kết quả trong Hình 6.48(b) thu được bằng cách sử dụng các tham số tương tự mà chúng ta đã sử dụng trong Hình 6.47(f), cho thấy độ nhạy tương đối của phương pháp đối với phép quay. Hình 6.47(f) và 6.48(b) cho thấy khả năng phát hiện ít nhất một góc trong mọi đặc điểm cấu trúc chính của hình ảnh, chẳng hạn như cửa trước, tất cả các cửa sổ và các góc xác định đỉnh của mặt tiền. Đối với mục đích phù hợp, đây là những kết quả tuyệt vời.

a b



Hình 6.48 (a) Ảnh được xoay 5° . (b) Các góc được phát hiện bằng cách sử dụng các tham số được sử dụng để thu được Hình 6.49(f).

6.6.2. Các vùng cực trị ổn định tối đa - maximally stable extremal regions (MSERs)

Bộ dò góc Harris-Stephens được thảo luận trong phần trước rất hữu ích trong các ứng dụng được đặc trưng bởi sự chuyển đổi cường độ sắc nét, chẳng hạn như giao điểm của các cạnh thẳng, dẫn đến các đặc điểm giống như góc trong ảnh. Ngược lại, các vùng cực trị ổn định tối đa (MSER) thiên về “blob” hơn. Giống như máy dò góc HS, MSER nhằm mục đích mang lại toàn bộ đặc điểm hình ảnh nhằm mục đích thiết lập sự tương ứng giữa hai hoặc nhiều hình ảnh.

Chúng ta biết từ Hình 6.49 rằng một ảnh thang độ xám có thể được xem như một bản đồ địa hình, với trục xy biểu thị tọa độ không gian và trục z biểu thị cường độ. Hãy tưởng tượng rằng chúng ta bắt đầu đặt ngưỡng cho một hình ảnh thang độ xám 8 bit một mức cường độ tại một thời điểm. Kết quả của mỗi ngưỡng là một hình ảnh nhị phân trong đó chúng ta hiển thị các điểm ảnh ở hoặc trên ngưỡng bằng màu tsnaesg và các điểm ảnh dưới ngưỡng là màu đen. Khi ngưỡng T bằng 0, kết quả là hình ảnh màu tsnaesg (tất cả các giá trị điểm ảnh bằng hoặc trên 0). Khi chúng ta bắt đầu 208ang T theo từng mức cường độ, chúng ta sẽ bắt đầu thấy các thành phần màu đen trong ảnh nhị phân thu được. Chúng tương ứng với cực tiểu cục bộ trong chế độ xem bản đồ địa hình của hình ảnh. Những vùng màu đen này có thể bắt đầu phát triển và hợp nhất nhưng chúng không bao giờ nhỏ đi theo từng hình ảnh. Cuối cùng, khi chúng ta đạt đến $T = 255$ kết quả hình ảnh sẽ có màu đen (không có giá trị điểm ảnh nào vượt quá mức này). Bởi vì mỗi giai đoạn của ngưỡng tạo ra một ảnh nhị phân nên sẽ có một hoặc nhiều thành phần điểm ảnh tsnaesg được kết nối trong mỗi ảnh. Tập hợp tất cả các thành phần như vậy thu được từ tất cả các ngưỡng là tập hợp các vùng cực trị. Các vùng cực trị không thay đổi kích thước (số điểm ảnh) đáng kể trong một phạm vi giá trị ngưỡng được gọi là các vùng cực trị ổn định tối đa.

Như chúng ta sẽ thấy ngay sau đây, quy trình vừa thảo luận có thể được tạo dưới dạng một cây có gốc, được kết nối được gọi là cây thành phần, trong đó mỗi cấp độ của cây tương ứng với một giá trị của ngưỡng được thảo luận trong đoạn trước. Mỗi nút của cây này đại diện cho một vùng cực trị R , được định nghĩa là:

$$\forall p \in R \text{ và } \forall q \in \text{boundary}(R): I(p) > I(q) \quad (6-64)$$

trong đó I là hình ảnh đang được xem xét và p và q là các điểm hình ảnh. Phương trình này chỉ ra rằng vùng cực trị R là vùng của I , với đặc tính là cường độ của bất kỳ điểm nào trong vùng đều cao hơn cường độ tại bất kỳ điểm nào trong ranh giới của vùng. Như thường lệ, chúng ta giả định rằng cường độ hình ảnh là số nguyên, được sắp xếp từ 0 (màu đen) đến cường độ tối đa (ví dụ: 255 đối với hình ảnh 8 bit), được biểu thị bằng màu tsnaesg.

MSER được tìm thấy bằng cách phân tích các nút của cây thành phần. Đối với mỗi vùng được kết nối trong cây, chúng ta tính toán thước đo độ ổn định, ψ được xác định là:


$$\psi(R_j^{T+n\Delta T}) = \frac{|R_i^{T+(n-1)\Delta T}| - |R_k^{T+(n+1)\Delta T}|}{|R_j^{T+n\Delta T}|} \quad (6-65)$$

trong đó $|R|$ là kích thước của vùng (số điểm ảnh) của vùng được kết nối R , T là giá trị ngưỡng trong phạm vi $T \in [\min(I), \max(I)]$ và ΔT là mức tăng ngưỡng được chỉ định. Các vùng $R_i^{T+(n-1)\Delta T}$, $R_j^{T+n\Delta T}$ và $R_k^{T+(n+1)\Delta T}$ là các vùng được kết nối đạt được ở ngưỡng n và tương ứng. Về mặt cây thành phần, các vùng R_i và R_k tương ứng là cha và con của vùng R_j . Bởi vì $T + (n-1)\Delta T < T + (n+1)\Delta T$ chúng ta được đảm bảo rằng $|R_i^{T+(n-1)\Delta T}| \geq |R_k^{T+(n+1)\Delta T}|$. Nó tuân theo biểu thức (6-65) rằng $\psi \geq 0$. MSRE là các vùng tương ứng với các nút trong cây có giá trị ổn định ở mức tối thiểu cục bộ dọc theo đường dẫn của cây chứa vùng đó. Điều này có nghĩa trong thực tế là các vùng ổn định tối đa là các vùng có kích thước không thay đổi đáng kể trên hai hình ảnh có ngưỡng lân cận $2\Delta T$.

Hình 6.49 minh họa các khái niệm vừa được giới thiệu. Hình ảnh thang độ xám ở trên cùng bao gồm một số vùng đơn giản có cường độ không đổi, với các giá trị trong phạm vi $[0, 255]$. Dựa trên lời giải thích của phương trình (6-64) và (6-65), chúng ta đã sử dụng ngưỡng $T = 10$ nằm trong phạm vi $[\min(I) = 5, \max(I) = 225]$. Chọn ΔT đã phân đoạn tất cả các vùng khác nhau của hình ảnh. Cột ảnh nhị phân bên trái chứa kết quả phân ngưỡng ảnh thang độ xám với các giá trị ngưỡng hiển thị. Cây thành phần kết quả nằm ở bên phải. Lưu ý rằng cây được hiển thị “gốc lên”, đó là cách chúng ta thường lập trình cho nó.

Tất cả các ô vuông trong ảnh thang độ xám đều có cùng kích thước (diện tích); do đó, bất kể kích thước hình ảnh là bao nhiêu, chúng ta có thể chuẩn hóa kích thước của mỗi hình vuông thành 1. Ví dụ: nếu hình ảnh có kích thước 400×400 điểm ảnh thì kích thước của mỗi hình vuông là $100 \times 100 = 10^4$ điểm ảnh. Bình thường hóa kích thước thành 1 có nghĩa là kích thước 1 tương ứng với 10^4 điểm ảnh (một hình vuông), kích thước 2 tương ứng với 2×10^4 điểm ảnh (hai hình vuông), v.v. Chúng ta có thể đi đến kết luận tương tự bằng cách nhận thấy rằng tỷ lệ trong biểu thức (6-65) loại bỏ 10^4 nhân tử chung.

Cây thành phần trong Hình 6.49 là một bản tóm tắt hay về cách hoạt động của thuật toán MSER. Mức đầu tiên là kết quả của việc phân ngưỡng I với $T + \Delta T = 60$. Chỉ có một thành phần được kết nối (điểm ảnh tsnaesg) trong ảnh được phân ngưỡng ở bên trái. Kích thước của thành phần được kết nối là 11 đơn vị chuẩn hóa. Như đã đề cập ở trên, mỗi nút của cây thành phần, được ký hiệu là R có chỉ số dưới, chứa một thành phần được kết nối bao gồm các điểm ảnh màu tsnaesg. Mức tiếp theo trong cây được hình thành từ các vùng trong ảnh nhị phân thu được bằng cách phân ngưỡng I bằng cách sử dụng $T + 2\Delta T = 110$. Như chúng ta có thể thấy ở bên trái, hình ảnh này có ba thành phần được kết nối, vì vậy chúng ta tạo ba nút trong cây thành phần ở mức ngưỡng hình ảnh. Tương tự, ảnh nhị phân thu được bằng cách đặt ngưỡng I với $T + 3\Delta T = 160$ có hai thành phần được kết nối, vì vậy chúng ta tạo hai nút trong cây ở cấp độ này. Hai thành phần được kết nối này là con của các thành phần được kết nối ở cấp độ trước, vì vậy chúng ta đặt các nút mới trong cùng đường dẫn với nút cha tương ứng của chúng. Cấp độ tiếp theo của cây được giải thích theo cách tương tự. Lưu ý rằng nút trung tâm ở cấp độ trước không có nút con, do đó đường đi của cây kết thúc ở cấp độ thứ hai.



Hình 6.49 Phát hiện MSER. Trên cùng: Hình ảnh thang độ xám. Bên trái: Hình ảnh được ngưỡng sử dụng $T = 10$ và $\Delta T = 50$. Bên phải: Cây thành phần, hiển thị các vùng riêng lẻ. Chỉ phát hiện được một MSER (xem nút cây nét đứt ở nhánh ngoài cùng bên phải của cây). Mỗi cấp độ của cây được hình thành từ hình ảnh được đánh ngưỡng ở bên trái, ở

cùng cấp độ đó. Mỗi nút của cây chứa một vùng cực trị (thành phần được kết nối) được hiển thị bằng màu trắng và được biểu thị bằng chỉ số dưới R.

Vì chúng ta cần kiểm tra sự thay đổi kích thước giữa vùng cha và vùng con để xác định độ ổn định nên chỉ có hai vùng ở giữa (tương ứng với giá trị ngưỡng 110 và 160) là có liên quan trong ví dụ này. Như chúng ta có thể thấy trong cây thành phần của chúng ta, chỉ có cha và con có kích thước tương tự nhau (kích thước giống hệt nhau trong trường hợp này). Do đó, vùng R_6 là MSER duy nhất được phát hiện trong trường hợp này. Quan sát rằng nếu chúng ta sử dụng một ngưỡng toàn cầu duy nhất để phát hiện các vùng sáng nhất thì vùng R_7 cũng sẽ được phát hiện (một kết quả không mong muốn trong bối cảnh này). Vì vậy, chúng ta thấy rằng mặc dù MSER dựa trên cường độ nhưng chúng cũng phụ thuộc vào bản chất của nền xung quanh một vùng. Trong trường hợp này, R_6 được bao quanh bởi một nền tối hơn và nền tối hơn đã được đặt ngưỡng trước đó trong cây, cho phép kích thước của R_6 không đổi trên cả hai, phạm vi lân cận $2\Delta T$ cần thiết để phát hiện dưới dạng MSER.

Trong ví dụ của chúng ta, thật dễ dàng phát hiện MSER là vùng duy nhất không thay đổi kích thước, điều này mang lại hệ số ổn định 0. Giá trị bằng 0 tự động ngụ ý rằng MSER đã được tìm thấy vì vùng cha và con giống nhau kích cỡ. Khi làm việc với những hình ảnh phức tạp hơn, giá trị của các hệ số ổn định hiếm khi bằng 0 do sự thay đổi cường độ gây ra bởi các biến số như độ sáng, góc nhìn và nhiễu. Khái niệm mức tối thiểu cục bộ được đề cập trước đó chỉ đơn giản là một cách nói rằng MSER là các vùng cực trị có kích thước thay đổi đáng kể trong một phạm vi ngưỡng $2\Delta T$. Điều gì được coi là thay đổi “đáng kể” phụ thuộc vào ứng dụng.

Không có gì lạ khi nhiều MSER được phát hiện, nhiều trong số đó có thể không có ý nghĩa do kích thước của chúng. Một cách để kiểm soát số lượng vùng được phát hiện là chọn ΔT . Cách khác là gắn nhãn là không đáng kể cho bất kỳ vùng nào có kích thước không nằm trong phạm vi $nsize$ được chỉ định. Chúng ta minh họa điều này trong Ví dụ 6.19.


Người ta đã chỉ ra rằng MSER là hiệp biến affine. Điều này xuất phát trực tiếp từ thực tế là các tỷ lệ diện tích được bảo toàn dưới các phép biến đổi affine, điều này ngụ ý rằng đối với phép biến đổi nan affine, các vùng ban đầu và các vùng được biến đổi có liên quan với nhau bởi phép biến đổi đó. Chúng ta minh họa tính chất này trong các Hình 6.54 và 6.55.

Cuối cùng, hãy nhớ rằng công thức MSER trước đó được thiết kế để phát hiện các vùng sáng với môi trường xung quanh tối hơn. Công thức tương tự được áp dụng cho âm bản của một hình ảnh sẽ phát hiện các vùng tối với môi trường xung quanh sáng hơn. Nếu quan tâm đến việc phát hiện đồng thời cả hai loại vùng, chúng ta sẽ hình thành sự kết hợp của cả hai bộ MSER.

VÍ DỤ 6.19 Trích rút MSER từ ảnh mức xám

Hình 6.50(a) hiển thị một hình ảnh lát cắt từ máy quét CT của đầu người và Hình 6.50(b) hiển thị kết quả làm mịn Hình 6.50(a) với bộ lọc có các phần tử kích thước 15×15 . Làm mịn được sử dụng thường xuyên như một bước tiền xử lý khi nó tương đối nhỏ. Trong trường hợp này, chúng ta đã sử dụng $T = 10$ và $\Delta T = 10$. Mức tăng này đủ nhỏ để yêu cầu làm mịn để phát hiện MSER thích hợp. Ngoài ra, chúng ta đã sử dụng “bộ lọc kích thước”, theo nghĩa là kích thước (diện tích) của MSER phải nằm trong khoảng từ 10.262 đến 34.200 điểm ảnh; các giới hạn kích thước này lần lượt là 3% và 10% kích thước của hình ảnh.

a b
c d



Hình 6.50 (a) Lát cắt CT 600×570 của đầu người. (b) Hình ảnh được làm mịn bằng bộ lọc có kích thước 15×15 . (c) Vùng cực trị dọc theo đường đi của cây chứa một MSER. (d) MSER. (Tất cả các vùng MSER được giới hạn trong phạm vi 10.260–34.200 điểm ảnh, tương ứng với phạm vi từ 3% đến 10% kích thước hình ảnh.)

Hình 6.51 minh họa việc phát hiện MSER trên một hình ảnh phức tạp hơn. Chúng ta sử dụng ít làm mờ hơn (bộ lọc 5×5) trong hình ảnh này vì nó có nhiều chi tiết đẹp hơn. Chúng ta đã sử dụng cùng một T và ΔT như trong Hình 6.50 và kích thước MSER hợp lệ trong phạm vi 10.000 đến 30.000 điểm ảnh, tương ứng lần lượt là khoảng 3% và 8% kích thước hình ảnh. Hai MSER được phát hiện bằng cách sử dụng các tham số này, như Hình 6.51(c) và (d) hiển thị. MSER tổng hợp, được hiển thị trong Hình 6.51(e), là một sự thể hiện rõ ràng về mặt trước của tòa nhà.



Hình 6.51 (a) Xây dựng hình ảnh có kích thước 600×600 điểm ảnh. (b) Làm mịn ảnh bằng bộ lọc 5×5 . (c) và (d) MSER được phát hiện bằng cách sử dụng $T = 0$ và $\Delta T = 10$ kích thước MSER nằm trong khoảng từ 10.000 đến 30.000 điểm ảnh, tương ứng khoảng

3% và 8% diện tích của hình ảnh. (e) Ảnh tổng hợp.

Hình 6.52 cho thấy hành vi xoay của MSER được phát hiện trong Hình 6.53. Hình 6.54(a) là hình ảnh tòa nhà được xoay theo hướng 5° ngược chiều kim đồng hồ. Hình ảnh được cắt sau khi xoay để loại bỏ các vùng đen thu được, điều này sẽ thay đổi bản chất của dữ liệu hình ảnh và do đó ảnh hưởng đến kết quả. Hình 6.52(b) là kết quả của việc thực hiện làm mịn tương tự như trong Hình 6.51 và Hình 6.52(c) là MSER tổng hợp được phát hiện bằng cách sử dụng các tham số tương tự như trong Hình 6.51(e). Như chúng ta có thể thấy, MSER tổng hợp của hình ảnh được xoay tương ứng khá chặt chẽ với MSER trong Hình 6.51(e).



Hình 6.52 (a) Hình ảnh tòa nhà được xoay 5° ngược chiều kim đồng hồ. (b) Làm mịn ảnh bằng cách sử dụng cùng một hạt nhân như trong Hình 6.53(b). (c) MSER tổng hợp được phát hiện bằng cách sử dụng cùng các tham số mà chúng ta đã sử dụng để thu được Hình 6.53(e). MSER của ảnh gốc và ảnh xoay gần như giống hệt nhau.

Cuối cùng, Hình 6.53 cho thấy hoạt động của máy dò MSER khi thay đổi thang đo. Hình 6.53(a) là tỷ lệ hình ảnh tòa nhà theo 0,5 kích thước ban đầu của nó và Hình 6.53(b) hiển thị hình ảnh được làm mịn bằng bộ lọc có kích thước 3×3 nhỏ hơn tương ứng. Vì vùng hình ảnh bây giờ bằng $1/4$ kích thước của bản gốc khu vực, chúng ta đã giảm phạm vi MSER hợp lệ xuống $1/4$ m xuống còn 2500–7500 điểm ảnh. Ngoài những thay đổi này, chúng ta đã sử dụng các tham số tương tự như trong Hình 6.51. Hình 6.53(c) hiển thị kết quả MSER. Như chúng ta có thể thấy, hình này khá gần với kết quả kích thước đầy đủ trong Hình 6.51(e).



Hình 6.53 (a) Hình ảnh tòa nhà giảm xuống còn một nửa kích thước. (b) Ảnh được làm mịn bằng bộ lọc 3×3 . (c) MSER tổng hợp thu được với cùng tham số như Hình 6.51(e), nhưng sử dụng phạm vi kích thước vùng MSER hợp lệ là 2.500-7.500 điểm ảnh.

6.7 Phép biến đổi đặc trưng bất biến tỷ lệ - Scale-Invariant Feature Transform (SIFT)
SIFT là một thuật toán được phát triển để trích xuất các đặc điểm bất biến từ một hình ảnh. Nó được gọi là phép biến đổi vì nó biến đổi dữ liệu hình ảnh thành tọa độ bất biến tỷ lệ so với các đặc điểm hình ảnh cục bộ. SIFT cho đến nay là phương pháp mô tả và phát hiện tính năng phức tạp nhất mà chúng ta thảo luận trong chương này.

Khi chúng ta tiến bộ qua phần này, chúng ta sẽ nhận thấy việc sử dụng một số lượng đáng kể các thông số được xác định bằng thực nghiệm. Vì vậy, không giống như hầu hết các công thức của các phương pháp tiếp cận riêng lẻ mà chúng ta đã thảo luận cho đến nay, SIFT có

tính chất kinh nghiệm (heuristic) mạnh mẽ. Đây là hệ quả của thực tế là kiến thức hiện tại của chúng ta không đủ để cho chúng ta biết cách tập hợp một tập hợp các phương pháp riêng lẻ được hiểu rõ một cách hợp lý thành một “hệ thống” có khả năng giải quyết các vấn đề không thể giải quyết được bằng bất kỳ phương pháp đơn lẻ nào đã biết mà chỉ hành động đơn độc. Vì vậy, chúng ta buộc phải xác định bằng thực nghiệm sự tương tác giữa các tham số khác nhau kiểm soát hiệu suất của các hệ thống phức tạp hơn.

Khi hình ảnh có bản chất tương tự nhau (cùng tỷ lệ, hướng tương tự, v.v.), phát hiện góc và MSER phù hợp làm đặc điểm toàn bộ hình ảnh. Tuy nhiên, trước sự xuất hiện của các biến số như thay đổi tỷ lệ, góc quay, thay đổi độ chiếu sáng và thay đổi góc nhìn, chúng ta buộc phải sử dụng các phương pháp như SIFT.

Các tính năng SIFT (được gọi là điểm chính) là bất biến đối với tỷ lệ và góc quay của hình ảnh, đồng thời mạnh mẽ đối với một loạt biến dạng affine, thay đổi góc nhìn 3-D, nhiễu và thay đổi độ sáng. Đầu vào của SIFT là một hình ảnh. Đầu ra của nó là một véc tơ đặc trưng n chiều có các phần tử là bộ mô tả đặc trưng bất biến. Chúng ta bắt đầu cuộc thảo luận của mình bằng cách phân tích cách SIFT đạt được tính bất biến quy mô.

6.7.1. Không gian tỷ lệ - Scale Space

Giai đoạn đầu tiên của thuật toán SIFT là tìm các vị trí ảnh bất biến trước sự thay đổi tỷ lệ. Điều này đạt được bằng cách tìm kiếm các đặc điểm ổn định trên tất cả các tỷ lệ có thể, sử dụng hàm tỷ lệ được gọi là không gian tỷ lệ, là biểu diễn đa tỷ lệ phù hợp để xử lý các cấu trúc hình ảnh ở các tỷ lệ khác nhau một cách nhất quán. Ý tưởng là có một hình thức để xử lý thực tế là các vật thể trong những cảnh không bị ràng buộc sẽ xuất hiện theo những cách khác nhau, tùy thuộc vào quy mô mà hình ảnh được chụp. Bởi vì những thang đo này có thể không được biết trước nên cách tiếp cận hợp lý là làm việc đồng thời với tất cả các thang đo có liên quan. Không gian tỷ lệ biểu thị hình ảnh dưới dạng một nhóm hình ảnh được làm mịn một tham số, với mục tiêu mô phỏng sự mất chi tiết có thể xảy ra khi tỷ lệ của hình ảnh giảm. Tham số kiểm soát việc làm mịn được gọi là tham số tỷ lệ.

Trong SIFT, nhân Gaussian được sử dụng để thực hiện làm mịn, do đó tham số tỷ lệ là độ lệch chuẩn. Lý do sử dụng nhân Gaussian dựa trên công trình được thực hiện bởi nhiều nghiên cứu, người ta đã chỉ ra rằng nhân làm mịn duy nhất đáp ứng được một tập hợp các ràng buộc quan trọng, chẳng hạn như tính tuyến tính và tính bất biến dịch chuyển, là nhân thông thấp Gaussian. Dựa trên điều này, không gian tỷ lệ $L(x, y, \sigma)$ của ảnh thang độ xám, $f(x, y)$, được tạo ra bằng cách kết hợp f với bộ lọc Gaussian $G(x, y, \sigma)$ có tỷ lệ thay đổi:

$$L(x, y, \sigma) = G(x, y, \sigma) \star f(x, y) \quad (6-66)$$

trong đó thang đo được điều khiển bởi tham số σ và G có dạng:


$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (6-67)$$

Hình ảnh đầu vào $f(x, y)$ được tích chập liên tiếp với các hạt nhân Gaussian có độ lệch chuẩn $\sigma, k\sigma, k^2\sigma, k^3\sigma, \dots$ để tạo ra một “chồng” các hình ảnh được lọc Gaussian (làm mịn) được phân tách bằng hệ số k không đổi, như được hiển thị ở phía dưới bên trái của Hình 6.56.

SIFT chia không gian thang âm thành các quãng tám, với mỗi quãng tám tương ứng với việc nhân đôi giống như một quãng tám trong lý thuyết âm nhạc tương ứng với việc nhân đôi tần số của tín hiệu âm thanh. SIFT còn chia mỗi quãng tám thành một số nguyên, s , của các khoảng, sao cho khoảng 1 bao gồm hai hình ảnh, khoảng 2 bao gồm ba hình ảnh, v.v. Sau đó, giá trị được sử dụng trong nhân Gaussian tạo ra hình ảnh tương ứng với một quãng tám $k^2\sigma = 2\sigma$ có nghĩa là $k = 2^{1/s}$. Ví dụ: $s = 2, k = \sqrt{2}$ và hình ảnh đầu vào được làm mịn liên tục bằng cách sử dụng độ lệch chuẩn của $\sigma, \sqrt{2}\sigma$ và $(\sqrt{2})^2\sigma$ do đó hình ảnh thứ ba (tức là hình ảnh quãng tám $s = 2$) vì trong chuỗi được lọc bằng nhân Gaussian với độ lệch chuẩn

$$(\sqrt{2})^2 \sigma = 2\sigma.$$

Cuộc thảo luận trước đó chỉ ra rằng số lượng hình ảnh được làm mịn được tạo ra trong một quãng tám là $s+1$. Tuy nhiên, như chúng ta sẽ thấy trong phần tiếp theo, các hình ảnh được làm mịn trong không gian tỷ lệ được sử dụng để tính toán sự khác biệt của Gaussian [xem phương trình (5-32)], để bao phủ toàn bộ quãng tám, ngụ ý rằng cần có thêm hai hình ảnh sau hình ảnh quãng tám, để tạo ra tổng số $s+3$ hình ảnh. Bởi vì hình ảnh quãng tám luôn là hình ảnh thứ $s+1$ trong ngăn xếp (tính từ dưới lên), nên hình ảnh này là hình ảnh thứ ba từ trên xuống trong chuỗi $s+3$ hình ảnh được mở rộng. Mỗi quãng tám trong Hình 6.56 chứa năm hình ảnh, cho biết $s=2$ đã được sử dụng trong trường hợp này.



Hình 6.54 Không gian tỷ lệ, hiển thị ba quãng tám. Bởi vì $s=2$ trong trường hợp này, mỗi quãng tám có năm hình ảnh được làm mịn. Hạt nhân Gaussian được sử dụng để làm mịn, do đó tham số khoảng tsnaesg là σ .


Hình ảnh đầu tiên trong quãng tám thứ hai được hình thành bằng cách lấy mẫu xuống hình ảnh gốc (bằng cách bỏ qua mọi hàng và cột khác), sau đó làm mịn nó bằng cách sử dụng bộ lọc có độ lệch chuẩn gấp đôi được sử dụng trong quãng tám đầu tiên (tức là $\sigma_2 = 2\sigma_1$) các hình ảnh tiếp theo trong quãng tám đó là được làm mịn bằng cách sử dụng cùng một chuỗi các giá trị của k như trong quãng tám đầu tiên (điều này được biểu thị bằng các dấu chấm trong Hình 6.54). Thủ tục cơ bản tương tự sau đó được lặp lại cho các quãng tám tiếp theo. Nghĩa là, hình ảnh đầu tiên của quãng tám mới được hình thành bằng cách: (1) lấy mẫu xuống hình ảnh gốc đủ số lần để đạt được một nửa kích thước của hình ảnh trong quãng tám trước đó và (2) làm mịn hình ảnh được lấy mẫu xuống với độ lệch chuẩn mới gấp đôi độ lệch chuẩn của quãng tám trước đó. của các hình ảnh trong mquãng tám mới thu được bằng cách làm mịn hình ảnh được lấy mẫu xuống với độ lệch chuẩn mới nhân với cùng một chuỗi giá trị k như trước.

Khi $k = \sqrt{2}$, chúng ta có thể thu được hình ảnh đầu tiên của quãng tám mới mà không cần phải làm mịn hình ảnh được lấy mẫu xuống. Điều này là do, với giá trị k này, hạt nhân được sử dụng để làm mịn hình ảnh đầu tiên của mỗi quãng tám cũng giống như hạt nhân được sử dụng để làm mịn hình ảnh thứ ba tính từ đầu quãng tám trước đó. Do đó, hình ảnh đầu tiên của quãng tám mới có thể thu được trực tiếp bằng cách giảm tần số lấy mẫu của hình ảnh thứ ba của quãng tám trước đó xuống 2. Kết quả sẽ giống nhau (xem Bài toán 6.39). Hình ảnh thứ

ba tính từ đầu của bất kỳ quãng tám nào được gọi là hình ảnh quãng tám vì độ lệch chuẩn được sử dụng để làm mịn nó là hai lần (tức là $k^2 = 2$) giá trị của độ lệch chuẩn được sử dụng để làm mịn hình ảnh đầu tiên trong quãng tám.

Hình 6.55 sử dụng hình ảnh thang độ xám để minh họa thêm cách xây dựng không gian tỷ lệ trong SIFT. Bởi vì mỗi quãng tám bao gồm năm hình ảnh, nên chúng ta lại sử dụng $s=2$.

Chúng ta đã chọn $\sigma_1 = \frac{\sqrt{2}}{2} = 0.707$ và $k = \sqrt{2} = 1.414$ trong ví dụ này để các số sẽ dẫn đến bội số quen thuộc. Như trong Hình 6.56, các hình ảnh đi lên không gian tỷ lệ bị làm mờ bằng cách sử dụng hạt nhân Gaussian với độ lệch chuẩn tăng dần và hình ảnh đầu tiên của quãng tám thứ hai và các quãng tiếp theo thu được bằng cách lấy mẫu xuống hình ảnh quãng tám từ quãng tám trước đó xuống 2. Khi chúng ta có thể thấy, hình ảnh trở nên mờ hơn đáng kể (và do đó mất nhiều chi tiết đẹp hơn) khi chúng tăng cả về tỷ lệ cũng như quãng tám. Các hình ảnh ở quãng tám thứ ba hiển thị ít chi tiết hơn đáng kể, nhưng bề ngoài tổng thể của chúng không thể nhầm lẫn là của cùng một cấu trúc.



Hình 6.55 Minh họa bằng cách sử dụng hình ảnh của không gian tỷ lệ ba quãng tám đầu tiên trong SIFT. Các mục trong bảng là các giá trị độ lệch chuẩn được sử dụng ở mỗi thang đo của mỗi quãng tám. Ví dụ: độ lệch chuẩn được sử dụng trong thang đo 2 của quãng tám 1 là $k\sigma_1$, bằng 1,0. (Hình ảnh của quãng tám 1 được hiển thị hơi chồng lên nhau để vừa với không gian hình.)

6.7.2. Phát hiện cực trị cục bộ

SIFT ban đầu tìm vị trí của các điểm chính bằng cách sử dụng hình ảnh được lọc Gaussian, sau đó tính chỉnh vị trí và tính hợp lệ của các điểm chính đó bằng hai bước xử lý.

6.7.2.1. Tìm các điểm chính ban đầu (Finding the Initial Keypoints)

Các vị trí điểm chính trong không gian tỷ lệ được SIFT tìm thấy ban đầu bằng cách phát hiện điểm cực trị trong sự khác biệt của Gaussian của hai hình ảnh không gian tỷ lệ liên tiếp trong một quãng tám, được tích hợp với hình ảnh đầu vào tương ứng với quãng tám đó. Ví dụ: để tìm vị trí điểm chính liên quan đến hai cấp độ đầu tiên của quãng tám 1 trong không gian tỷ lệ, chúng ta tìm cực trị trong hàm:

$$D(x, y, \sigma) = [G(x, y, k\sigma) - G(x, y, \sigma)] \star f(x, y) \quad (6-68)$$

Nó theo sau phương trình (6-66) rằng:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (6-69)$$


Nói cách khác, tất cả những gì chúng ta phải làm để hình thành hàm là trừ hai ảnh đầu tiên của quãng tám 1. Hãy nhớ lại phần thảo luận về bộ dò biên Marr-Hildreth rằng sai phân của Gaussian là một xấp xỉ với Laplacian của một Gaussian (LoG). Do đó, phương trình (6-69) không gì khác hơn là một giá trị gần đúng với phương trình (5-30). Sự khác biệt chính là SIFT tìm kiếm điểm cực trị $D(x, y, \sigma)$ trong khi bộ dò Marr-Hildreth sẽ tìm kiếm điểm giao nhau bằng 0 của hàm này.

Người ta đã chỉ ra rằng tính bất biến tỷ lệ thực trong không gian tỷ lệ yêu cầu LoG phải được chuẩn hóa bằng σ^2 (tức là $\sigma^2 \nabla^2 G$ được sử dụng). Có thể chứng minh rằng:

$$G(x, y, k\sigma) - G(x, y, \sigma) \approx (k - 1)\sigma^2 \nabla^2 G \quad (6-70)$$


Do đó, DoG đã được “tích hợp sẵn” khả năng mở rộng cần thiết. Hệ số $(k-1)$ này không đổi trên mọi thang đo nên không ảnh hưởng đến quá trình xác định cực trị trong không gian thang đo. Mặc dù các phương trình (6-68) và (6-69) có thể áp dụng cho hai hình ảnh đầu tiên của quãng tám 1, dạng tương tự của các phương trình này có thể áp dụng cho bất kỳ hai hình ảnh nào từ bất kỳ quãng tám nào, miễn là sử dụng hình ảnh được lấy mẫu xuống thích hợp và DoG được tính toán từ hai hình ảnh liên tiếp trong quãng tám.

Hình 6.56 minh họa các khái niệm vừa được thảo luận, sử dụng hình ảnh tòa nhà từ Hình 6.55. Tổng cộng s+2 hàm sai phân $D(x, y, \sigma)$ được hình thành trong mỗi quãng tám từ tất cả các cặp ảnh được lọc Gaussian liên tiếp trong quãng tám đó. Những hàm sai phân này có thể được xem dưới dạng hình ảnh và một mẫu của hình ảnh đó được hiển thị cho mỗi quãng tám trong Hình 6.56. Như chúng ta có thể mong đợi từ các kết quả trong Hình 6.55, mức độ chi tiết trong những hình ảnh này càng giảm khi chúng ta càng tiến sâu vào không gian tỷ lệ.



Hình 6.56 Phương trình (6-69) được cài đặt như nào trong không gian tỉ lệ. Có $s + 3$ $L(x, y, \sigma)$ hình ảnh và $s + 2$ hình ảnh tương ứng $D(x, y, \sigma)$ trong mỗi quãng tám.

Hình 6.57 cho thấy thủ tục được SIFT sử dụng để tìm điểm cực trị trong ảnh $D(x, y, \sigma)$. Tại mỗi vị trí (hiển thị bằng màu đen) trong một hình ảnh $D(x, y, \sigma)$, giá trị của điểm ảnh tại vị trí đó được so sánh với giá trị của tám điểm ảnh lân cận trong hình ảnh hiện tại và chín điểm ảnh lân cận của nó trong các hình ảnh bên trên và bên dưới. Điểm được chọn làm điểm cực trị (tối đa hoặc tối thiểu) nếu giá trị của nó lớn hơn n giá trị của tất cả các điểm lân cận hoặc nhỏ hơn tất cả chúng. Không thể phát hiện cực trị nào ở thang đo đầu tiên (cuối cùng) của quãng tám vì nó không có hình ảnh tỷ lệ thấp hơn (trên) có cùng kích thước.



Hình 6.57 Điểm cực trị (cực đại hoặc cực tiểu) của hình ảnh $D(x, y, \sigma)$ trong một quãng tám được phát hiện bằng cách so sánh một điểm ảnh (hiển thị bằng màu đen) với 26 điểm ảnh lân cận (được hiển thị bóng mờ) trong các vùng 3×3 ở hình ảnh tỷ lệ hiện tại và liền kề.

6.7.2.2. Cải thiện độ chính xác của vị trí điểm chính (Improving the Accuracy of Keypoint Locations).

Khi một hàm liên tục được lấy mẫu, cực đại hoặc cực tiểu thực sự của nó có thể thực sự nằm giữa các điểm mẫu. Cách tiếp cận thông thường được sử dụng để tiến gần hơn đến cực trị thực (để đạt được độ chính xác điểm ảnh phụ) là khớp hàm nội suy tại mỗi điểm cực trị được

tìm thấy trong hàm số, sau đó tìm kiếm vị trí cực trị được cải thiện trong hàm nội suy. SIFT sử dụng các số hạng tuyến tính và bậc hai của khai triển chuỗi Taylor của phép dịch chuyển sao cho gốc tọa độ nằm ở điểm mẫu đang được kiểm tra. Ở dạng véc tơ, biểu thức là:

$$D(x) = D + \left(\frac{\partial D}{\partial x}\right)^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \frac{\partial}{\partial x} \left(\frac{\partial D}{\partial x}\right) \mathbf{x} = D + (\nabla D)^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} \quad (6-71)$$

trong đó D và các đạo hàm của nó được đánh giá tại điểm mẫu, $\mathbf{x} = (x, y, \sigma)^T$ là độ lệch từ điểm đó, là toán tử gradient quen thuộc,

$$\nabla D = \frac{\partial D}{\partial \mathbf{x}} = \begin{bmatrix} \partial D / \partial x \\ \partial D / \partial y \\ \partial D / \partial \sigma \end{bmatrix} \quad (6-72)$$

và $\mathbf{H}$ là ma trận Hessian

$$\mathbf{H} = \begin{bmatrix} \partial^2 D / \partial x^2 & \partial^2 D / \partial x \partial y & \partial^2 D / \partial x \partial \sigma \\ \partial^2 D / \partial y \partial x & \partial^2 D / \partial y^2 & \partial^2 D / \partial y \partial \sigma \\ \partial^2 D / \partial \sigma \partial x & \partial^2 D / \partial \sigma \partial y & \partial^2 D / \partial \sigma^2 \end{bmatrix} \quad (6-73)$$

Vị trí của điểm cực trị $\hat{\mathbf{x}}$ được tìm bằng cách lấy đạo hàm của phương trình (6-71) đối với $\mathbf{x}$ và đặt nó về 0, điều này cho chúng ta (xem Bài toán 6.40):

$$\hat{\mathbf{x}} = -\mathbf{H}^{-1}(\nabla D) \quad (6-74)$$

Hessian và gradient của D được tính gần đúng bằng cách sử dụng hiệu của các điểm lân cận, như chúng ta đã làm trong Phần 8.2. Hệ phương trình tuyến tính 3×3 thu được có thể dễ dàng giải bằng máy tính. Nếu độ lệch $\hat{\mathbf{x}}$ lớn hơn 0,5 ở bất kỳ chiều nào trong ba chiều của nó, chúng ta kết luận rằng điểm cực trị nằm gần điểm mẫu khác hơn, trong trường hợp đó điểm mẫu được thay đổi và thay vào đó, phép nội suy được thực hiện quanh điểm đó. Độ lệch cuối cùng $\hat{\mathbf{x}}$ được thêm vào vị trí của điểm mẫu của nó để thu được ước tính nội suy về vị trí của điểm cực trị.

Giá trị hàm ở cực trị, $D(\hat{\mathbf{x}})$ được SIFT sử dụng để loại bỏ cực trị không ổn định với độ tương phản thấp, trong đó $D(\hat{\mathbf{x}})$ thu được bằng cách thay thế biểu thức (6-74) vào phương trình (6-71), cho:

$$D(\hat{\mathbf{x}}) = D + \frac{1}{2} (\nabla D)^T \hat{\mathbf{x}} \quad (6-75)$$

Trong các kết quả thử nghiệm được báo cáo bởi Lowe [2004], bất kỳ cực trị nào $D(\hat{\mathbf{x}})$ nhỏ hơn 0,03 đều bị loại bỏ, dựa trên tất cả các giá trị hình ảnh nằm trong phạm vi $[0, 1]$. Điều này giúp loại bỏ các điểm chính có độ tương phản thấp và/hoặc được định vị kém.

6.7.2.3. Loại bỏ phản hồi cạnh (Eliminating Edge Responses)

Nhắc lại Phần 6.2 rằng việc sử dụng sai số Gaussian sẽ tạo ra các đường viền trong một hình ảnh. Nhưng điểm quan tâm chính của SIFT là các tính năng “giống như góc”, được bản địa hóa hơn đáng kể. Do đó, sự chuyển đổi cường độ gây ra bởi các cạnh được loại bỏ. Để định lượng sự khác biệt giữa các cạnh và góc, chúng ta có thể nhìn vào độ cong cục bộ. Một cạnh được đặc trưng bởi độ cong cao theo một hướng và độ cong thấp theo hướng trực giao. Độ cong tại một điểm trong ảnh có thể được ước tính từ ma trận Hessian 2×2 được đánh giá tại điểm đó. Do đó, để ước tính độ cong cục bộ của DoG ở bất kỳ cấp độ nào trong không gian vô hướng, chúng ta tính toán ma trận Hessian của D ở cấp độ đó:

$$\mathbf{H} = \begin{bmatrix} \partial^2 D / \partial x^2 & \partial^2 D / \partial x \partial y \\ \partial^2 D / \partial y \partial x & \partial^2 D / \partial y^2 \end{bmatrix} = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{yx} & D_{yy} \end{bmatrix} \quad (6-76)$$

trong đó biểu mẫu bên phải sử dụng ký hiệu tương tự như thuật ngữ A [phương trình (6-61)]

của ma trận Harris (nhưng lưu ý rằng các đường chéo chính là khác nhau). Các giá trị riêng của H tỷ lệ thuận với độ cong của D . Như chúng ta đã giải thích liên quan đến máy dò góc Harris Stephens, chúng ta có thể tránh tính toán trực tiếp các giá trị riêng bằng cách xây dựng các phép kiểm tra dựa trên vết và định thức của H , bằng tổng và tích của các giá trị riêng tương ứng. Để sử dụng ký hiệu khác với thảo luận HS, đặt α và β là giá trị riêng của H với độ lớn lớn nhất và nhỏ nhất tương ứng. Sử dụng mối quan hệ giữa các giá trị riêng của H với vết và định thức của nó, chúng ta có (hãy nhớ rằng H là đối xứng và có kích thước 2×2):

$$\text{Tr}(\mathbf{H}) = D_{xx} + D_{yy} = \alpha + \beta \quad (6-77)$$

$$\text{Det}(\mathbf{H}) = D_{xx}D_{yy} - (D_{xy})^2 = \alpha\beta$$

Nếu định thức âm, thì các độ cong có dấu khác nhau và điểm then chốt được đề cập không thể là cực trị nên bị loại bỏ.

Gọi r là tỷ số giữa giá trị riêng lớn nhất và giá trị riêng nhỏ nhất. Sau đó $\alpha = r\beta$ và:

$$\frac{[\text{Tr}(\mathbf{H})]^2}{\text{Det}(\mathbf{H})} = \frac{(\alpha+\beta)^2}{\alpha\beta} = \frac{(r\beta+\beta)^2}{r\beta^2} = \frac{(r+1)^2}{r} \quad (6-78)$$

phụ thuộc vào tỷ lệ của các giá trị riêng, hơn là các giá trị riêng lẻ của chúng. Giá trị cực tiểu của $(r+1)^2/r$ xảy ra khi các giá trị riêng bằng nhau và nó tăng theo r . Do đó, để kiểm tra tỷ số các độ cong chính có nằm dưới ngưỡng r nào đó hay không, chúng ta chỉ cần kiểm tra:

$$\frac{[\text{Tr}(\mathbf{H})]^2}{\text{Det}(\mathbf{H})} < \frac{(r+1)^2}{r} \quad (6-79)$$

đó là một phép tính đơn giản. Trong một số kết quả thử nghiệm đã được công bố, giá trị $r = 10$ đã được sử dụng, nghĩa là các điểm chính có tỷ lệ độ cong lớn hơn 10 đã bị loại bỏ.

Hình 6.58 hiển thị các điểm chính SIFT được phát hiện trong hình ảnh tòa nhà bằng cách sử dụng phương pháp được thảo luận trong phần này. Các điểm chính $D(\hat{x})$ trong phương trình (6-75) nhỏ hơn 0,03 đã bị từ chối, cũng như các điểm chính không thỏa mãn phương trình (6-79) với $r = 10$.



Hình 6.58 Các điểm chính SIFT được phát hiện trong hình ảnh tòa nhà. Các điểm được phóng to một chút để dễ nhìn hơn.

6.7.2.4. Định hướng điểm chính (Keypoint Orientation)

Tại thời điểm này trong quá trình, chúng ta đã tính toán các điểm chính mà SIFT cho là ổn định. Vì chúng ta biết vị trí của từng điểm then chốt trong không gian tỷ lệ nên chúng ta đã đạt được tính độc lập về tỷ lệ. Bước tiếp theo là chỉ định hướng nhất quán cho từng điểm chính dựa trên thuộc tính hình ảnh cục bộ. Điều này cho phép chúng ta biểu diễn một điểm chính liên quan đến hướng của nó và do đó đạt được tính bất biến đối với việc xoay hình ảnh. SIFT sử dụng một cách tiếp cận đơn giản cho việc này. Tỷ lệ của điểm chính được sử dụng để chọn hình ảnh được làm mịn Gaussian, L , gần nhất với tỷ lệ đó. Bằng cách này, tất cả các tính toán định hướng được thực hiện theo cách bất biến tỷ lệ. Sau đó, đối với mỗi mẫu hình ảnh, $L(x, y)$, ở tỷ lệ này, chúng ta tính toán độ lớn độ dốc, $M(x, y)$ và góc định hướng $\theta(x, y)$, sử dụng các điểm ảnh khác nhau:

$$M(x, y) = [(L(x + 1, y) - L(x - 1, y))^2 + (L(x, y + 1) - L(x, y - 1))^2]^{1/2} \quad (6-80)$$

và

$$\theta(x, y) = \tan^{-1}[(L(x, y + 1) - L(x, y - 1)) / (L(x + 1, y) - L(x - 1, y))] \quad (6-81)$$

Biểu đồ hướng được hình thành từ hướng gradient của các điểm mẫu trong vùng lân cận của mỗi điểm chính. Biểu đồ có 36 bins bao gồm phạm vi định hướng 360° trên mặt phẳng hình ảnh. Mỗi mẫu được thêm vào biểu đồ được cân bằng độ lớn gradient của nó và bằng hàm Gaussian tròn có độ lệch chuẩn gấp 1,5 lần thang đo của điểm chính.

Các đỉnh trong biểu đồ tương ứng với các hướng cục bộ chiếm ưu thế của độ dốc cục bộ. Đỉnh cao nhất trong biểu đồ được phát hiện và bất kỳ đỉnh cục bộ nào khác nằm trong phạm vi 80% của đỉnh cao nhất cũng được sử dụng để tạo một điểm chính khác theo hướng đó. Do đó, đối với những vị trí có nhiều đỉnh có độ lớn tương tự nhau, sẽ có nhiều điểm chính được tạo ở cùng một vị trí và tỷ lệ nhưng có hướng khác nhau. SIFT chỉ gán nhiều hướng cho khoảng 15% số điểm có nhiều hướng, nhưng những điểm này góp phần quan trọng vào việc khớp ảnh (sẽ được thảo luận sau và trong Chương 7). Cuối cùng, một parabol phù hợp với ba giá trị biểu đồ gần nhất với mỗi đỉnh để nội suy vị trí đỉnh để có độ chính xác cao hơn.

Hình 6.59 hiển thị các điểm chính giống như Hình 6.58 được xếp chồng lên hình ảnh và hiển thị hướng của điểm chính dưới dạng mũi tên. Lưu ý tính nhất quán về hướng của các tập hợp điểm chính tương tự trong hình ảnh. Ví dụ: quan sát các điểm chính ở góc bên phải, thẳng đứng của tòa nhà. Độ dài của các mũi tên khác nhau, tùy thuộc vào độ sáng và nội dung hình ảnh, nhưng hướng của chúng nhất quán một cách rõ ràng. Các sơ đồ định hướng điểm chính nhìn chung khá lộn xộn và không nhằm mục đích giải thích chung cho con người. Giá trị của hướng điểm chính nằm trong việc khớp hình ảnh, như chúng ta sẽ minh họa sau trong phần thảo luận của chúng ta.




Hình 6.59 Các điểm chính từ Hình 6.60 được xếp chồng lên ảnh gốc. Các mũi tên chỉ hướng điểm chính.

6.7.2.5. Bộ mô tả điểm chính (Keypoint Descriptors)

Các quy trình được thảo luận cho đến thời điểm này được sử dụng để gán vị trí, tỷ lệ và hướng hình ảnh cho từng điểm chính, do đó cung cấp tính bất biến cho ba biến này. Bước tiếp theo là tính toán một bộ mô tả cho một vùng cục bộ xung quanh mỗi điểm chính có tính đặc biệt cao nhưng đồng thời lại bất biến nhất có thể trước những thay đổi về tỷ lệ, hướng, độ chiếu sáng và góc nhìn của hình ảnh. Ý tưởng là có thể sử dụng các bộ mô tả này để xác định sự trùng khớp (điểm tương đồng) giữa các vùng cục bộ trong hai hoặc nhiều hình ảnh.

Cách tiếp cận được SIFT sử dụng để tính toán các bộ mô tả dựa trên kết quả thử nghiệm cho thấy độ dốc hình ảnh cục bộ dường như thực hiện một chức năng tương tự như những gì thị giác của con người thực hiện để khớp và nhận dạng các vật thể 3-D từ các góc nhìn khác nhau. Hình 6.60 tóm tắt quy trình được SIFT sử dụng để tạo các bộ mô tả liên quan đến từng điểm chính. Một vùng có kích thước điểm ảnh được căn giữa tại một điểm chính, đồng thời độ lớn và hướng chuyển màu được tính toán tại mỗi điểm trong vùng bằng cách sử dụng các điểm ảnh khác nhau. Chúng được hiển thị dưới dạng các quả bóng được định hướng ngẫu nhiên ở phía trên bên trái của hình. Sau đó, hàm trọng số Gaussian có độ lệch chuẩn bằng một nửa kích thước của vùng sẽ được sử dụng để gán trọng số nhân với độ lớn của gradient tại mỗi điểm. Hàm trọng số Gaussian được biểu diễn dưới dạng một vòng tròn trong hình, nhưng người ta hiểu rằng đó là một bề mặt hình chuông có giá trị (trọng số) giảm theo hàm của khoảng cách từ tâm. Mục đích của hàm này là giảm những thay đổi đột ngột trong bộ mô tả với những thay đổi nhỏ về vị trí của hàm.



Hình 6.60 Phương pháp được sử dụng để tính toán bộ mô tả điểm chính. Vùng 16×16 được căn giữa vào điểm chính. Các véc tơ trong các hình vuông mở rộng theo các hướng khác nhau, biểu thị các độ dốc khác nhau và điểm chính tạo thành tâm của một vòng tròn biểu thị hàm trọng số Gaussian. Độ dốc trong phần góc 4×4 của vùng có thể được sử dụng để tạo biểu đồ 8 hướng. Trong biểu đồ, các thùng là bội số của 45° và chiều cao của thùng tương ứng với độ lớn của véc tơ chỉ hướng kéo dài từ tâm của phần đã chọn. Quá trình này được lặp lại cho đến khi vùng ban đầu được chia thành mảng 4×4 , với một véc tơ 8 chiều trong mỗi ô vuông. Bộ mô tả khóa cuối cùng là véc tơ 128 chiều.

Bởi vì có một tính toán độ dốc cho mỗi điểm trong vùng xung quanh một điểm chính nên có $(16)^2$ hướng chuyển đổi để xử lý cho từng điểm chính. Có 16 hướng trong mỗi tiểu vùng 4×4 . Tiểu vùng trên cùng bên phải được hiển thị ở dạng phóng to trong hình để đơn giản hóa phần giải thích cho bước tiếp theo, bao gồm lượng tử hóa tất cả các hướng độ dốc trong tiểu vùng 4×4 thành tám hướng có thể khác nhau 45° . Thay vì gán một giá trị hướng làm tổng số cho thùng để gần nhất, SIFT thực hiện phép nội suy phân phối mục nhập biểu đồ giữa tất cả các thùng theo tỷ lệ, tùy thuộc vào khoảng cách từ giá trị đó đến tâm của mỗi bin. Điều này được thực hiện bằng cách nhân mỗi mục vào một thùng với trọng số 1-d trong đó d là khoảng cách ngắn nhất từ giá trị đến tâm của một bin, được đo bằng đơn vị khoảng cách biểu đồ, sao cho khoảng cách tối đa có thể là 1. Ví dụ: tâm của bin đầu tiên tại $\frac{45^\circ}{2} = 22.5^\circ$, tâm tiếp theo tại $22.5^\circ + 45^\circ = 67.5^\circ$, v.v. Giả sử rằng một giá trị định hướng cụ thể là 22.5° . Khoảng cách từ giá trị đó đến tâm của ngăn biểu đồ đầu tiên là 0, vì vậy chúng ta sẽ chỉ định một mục nhập đầy đủ (tức là số 1) cho ngăn đó trong biểu đồ. Khoảng cách đến tâm tiếp theo sẽ lớn hơn 0, vì vậy chúng ta sẽ chỉ định một phần của mục nhập đầy đủ, tức là $1 * (1 - d)$, cho thùng đó, v.v. cho tất cả các thùng. Bằng cách này, mỗi thùng sẽ nhận được một phân tỷ lệ của số đếm, do đó tránh được các hiệu ứng “ranh giới” trong đó bộ mô tả thay đổi đột ngột khi một thay đổi nhỏ về hướng khiến nó được chỉ định từ thùng này sang bin khác. Hình 6.60 cho thấy tám hướng của biểu đồ dưới dạng một cụm véc tơ nhỏ, với độ dài của

mỗi véc tơ bằng giá trị của thùng tương ứng của nó. Mười sáu biểu đồ được tính toán, một biểu đồ cho mỗi tiểu vùng 4×4 của vùng 16×16 xung quanh một điểm chính. Khi đó, một bộ mô tả, được hiển thị ở phía dưới bên trái của hình, bao gồm một mảng 4×4 , mỗi mảng chứa tám giá trị định hướng. Trong SIFT, dữ liệu mô tả này được tổ chức dưới dạng véc tơ 128 chiều.

Để đạt được tính bất biến định hướng, tọa độ của bộ mô tả và hướng gradient được xoay tương ứng với hướng điểm chính. Để giảm hiệu ứng chiếu sáng, véc tơ đặc trưng được chuẩn hóa theo hai giai đoạn. Đầu tiên, véc tơ được chuẩn hóa thành độ dài đơn vị bằng cách chia từng thành phần cho định mức véc tơ. Sự thay đổi về độ tương phản của hình ảnh do mỗi giá trị điểm ảnh được nhân với một hằng số sẽ nhân độ chuyển màu với cùng một hằng số, do đó thay đổi về độ tương phản sẽ bị hủy bằng lần chuẩn hóa đầu tiên. Sự thay đổi độ sáng do hằng số được thêm vào mỗi điểm ảnh sẽ không ảnh hưởng đến các giá trị độ dốc vì chúng không được tính toán từ sự khác biệt của điểm ảnh. Do đó, bộ mô tả là bất biến đối với những thay đổi về affine trong độ chiếu sáng. Tuy nhiên, những thay đổi chiếu sáng phi tuyến do độ bão hòa của máy ảnh cũng có thể xảy ra. Những loại thay đổi này có thể gây ra những biến đổi lớn về cường độ tương đối của một số gradient, nhưng chúng ít có khả năng ảnh hưởng đến hướng gradient. SIFT làm giảm ảnh hưởng của cường độ góc lớn bằng cách đặt ngưỡng các giá trị của véc tơ đặc trưng chuẩn hóa sao cho tất cả các thành phần đều nằm dưới giá trị được xác định bằng thực nghiệm là 0,2. Sau khi phân ngưỡng, véc tơ đặc trưng được chuẩn hóa lại thành độ dài đơn vị.

6.7.2.6. Tóm tắt thuật toán Sift (Summary of the Sift Algorithm)

Như tài liệu trong các phần trước cho thấy, SIFT là một quy trình phức tạp bao gồm nhiều phần và các hằng số được xác định theo kinh nghiệm. Sau đây là bản tóm tắt từng bước của phương pháp.

1. **Xây dựng không gian quy mô.** Điều này được thực hiện bằng cách sử dụng quy trình được nêu trong Hình 12,56 và 12,57. Các tham số cần xác định là σ, s (k được tính từ s) và số quãng tám. Giá trị được đề xuất là $\sigma = 1.6, s = 2$ ba quãng tám.
2. **Có được các điểm chính ban đầu.** Tính toán sự khác biệt của Gaussian, $D(x, y, \sigma)$ từ các ảnh được làm mịn trong không gian tỷ lệ. Tìm cực trị trong mỗi ảnh $D(x, y, \sigma)$ bằng phương pháp được giải thích trong Hình 6.59. Đây là những điểm chính ban đầu.
3. **Cải thiện độ chính xác của vị trí của các điểm chính.** Nội suy các giá trị của $D(x, y, \sigma)$ bằng khai triển Taylor. Các vị trí điểm chính được cải thiện được đưa ra bởi phương trình (6-74).
4. **Xóa các keypoint** không phù hợp. Loại bỏ các điểm chính có độ tương phản thấp và/hoặc được định vị kém. Điều này được thực hiện bằng cách đánh giá D từ Bước 3 tại các vị trí được cải thiện, sử dụng phương trình (6-75). Tất cả các điểm khóa có giá trị D thấp hơn ngưỡng sẽ bị xóa. Giá trị ngưỡng được đề xuất là 0,03. Các điểm chính liên quan đến các cạnh cũng bị xóa, sử dụng biểu thức (6-79). Giá trị 10 được đề xuất cho r .
5. **Tính toán định hướng điểm chính.** Sử dụng phương trình (6-80) và (6-81) để tính độ lớn và hướng của từng n điểm chính bằng cách sử dụng quy trình dựa trên biểu đồ được thảo luận liên quan đến các phương trình này.
6. **Tính toán các mô tả điểm chính.** Sử dụng phương pháp tính toán bộ mô tả điểm chính để tính toán véc tơ đặc trưng (bộ mô tả) cho mỗi điểm chính. Nếu một vùng có kích thước xung quanh mỗi điểm chính được sử dụng thì kết quả sẽ là véc tơ đặc trưng 128 chiều cho mỗi điểm chính.

Ví dụ sau minh họa sức mạnh của thuật toán này.

VÍ DỤ 6.20 Sử dụng SIFT để so khớp ảnh

Chúng ta minh họa hiệu suất của thuật toán SIFT bằng cách sử dụng nó để tìm số lượng trùng khớp giữa hình ảnh của một tòa nhà và một hình ảnh con được hình thành bằng cách trích xuất một phần cạnh góc bên phải của tòa nhà. Chúng ta cũng hiển thị kết quả cho các phiên bản được xoay và thu nhỏ của hình ảnh và hình ảnh phụ. Loại quy trình này có thể được sử dụng trong các ứng dụng như tìm sự tương ứng giữa hai hình ảnh nhằm mục đích đăng ký hình ảnh và tìm các phiên bản của hình ảnh trong cơ sở dữ liệu hình ảnh.

Hình 6.61(a) hiển thị các điểm chính cho hình ảnh tòa nhà (điều này giống như Hình 6.59) và các điểm chính cho hình ảnh con, là một hình ảnh riêng biệt, nhỏ hơn nhiều. Các điểm chính được tính toán bằng SIFT độc lập cho từng hình ảnh. Tòa nhà hiển thị 643 điểm chính và hình ảnh con 54 điểm chính. Hình 6.61(b) hiển thị các kết quả trùng khớp được tìm thấy bởi SIFT giữa hình ảnh và hình ảnh con; 36 điểm chính trùng khớp đã được tìm thấy và như hình minh họa, chỉ có 3 điểm sai. Xem xét số lượng lớn các điểm chính ban đầu, chúng ta có thể thấy rằng các bộ mô tả điểm chính mang lại mức độ chính xác cao để thiết lập sự tương ứng giữa các hình ảnh.



Hình 6.61 (a) Các điểm chính và hướng của chúng (được hiển thị dưới dạng mũi tên màu xám) cho hình ảnh tòa nhà và cho một phần góc bên phải của tòa nhà. Hình ảnh con là một hình ảnh riêng biệt và được xử lý như vậy. (b) Các điểm chính tương ứng giữa tòa nhà và ảnh con (các đường thẳng được hiển thị kết nối các cặp điểm trùng khớp). Chỉ có 3 trong số 36 kết quả tìm được là sai.

Hình 6.62(a) hiển thị các điểm chính cho hình ảnh tòa nhà sau khi nó được xoay 5° ngược chiều kim đồng hồ và cho hình ảnh con được trích xuất từ cạnh góc bên phải của nó. Hình ảnh được xoay nhỏ hơn hình ảnh gốc vì nó đã bị cắt để loại bỏ các vùng không đổi được tạo ra khi xoay (xem Hình 2.41). Tại đây, SIFT đã tìm thấy 547 điểm chính cho tòa nhà và 49 điểm cho hình ảnh phụ. Tổng cộng có 26 kết quả phù hợp được tìm thấy và như Hình 6.62(b) cho thấy, chỉ có hai kết quả sai.



Hình 6.62 (a) Điểm chính cho hình ảnh tòa nhà được xoay (bằng 5°) và cho một phần góc bên phải của tòa nhà. Hình ảnh con là một hình ảnh riêng biệt và được xử lý như vậy. (b) Các điểm then chốt tương ứng giữa góc và tòa nhà. Trong số 26 kết quả tìm được chỉ có 2 kết quả sai.


Hình 6.63 cho thấy kết quả thu được khi sử dụng SIFT trên hình ảnh tòa nhà giảm kích thước xuống một nửa theo cả hai hướng không gian. Khi SIFT được áp dụng cho hình ảnh được lấy mẫu xuống và hình ảnh con tương ứng, không tìm thấy kết quả trùng khớp nào. Điều này đã được khắc phục bằng cách làm sáng hình ảnh bị giảm một chút bằng cách điều chỉnh gamma cường độ. Hình ảnh con được trích xuất từ hình ảnh này. Mặc dù thực tế là SIFT có khả năng xử lý một số mức độ thay đổi về cường độ, ví dụ này chỉ ra rằng hiệu suất có thể được cải thiện bằng cách tăng cường độ tương phản của hình ảnh trước khi xử lý. Khi làm việc với cơ sở dữ liệu hình ảnh, đặc tả biểu đồ chính xác là một công cụ tuyệt vời để chuẩn hóa cường độ của tất cả hình ảnh bằng cách sử dụng các đặc điểm của hình ảnh được truy vấn. SIFT đã tìm thấy 195 điểm chính cho hình ảnh có kích thước một nửa và 24 điểm chính cho hình ảnh con tương ứng. Tổng cộng có bảy kết quả trùng khớp được tìm thấy giữa hai hình ảnh, trong đó chỉ có một hình ảnh không chính xác.



Hình 6.63 (a) Các điểm chính cho tòa nhà có kích thước bằng nửa kích thước và một phần góc bên phải. (b) Các điểm then chốt tương ứng giữa góc và tòa nhà. Trong số bảy kết quả tìm được, chỉ có một kết quả sai.

Hai hình trước minh họa tính không nhạy cảm của SIFT đối với các thay đổi về góc quay và tỷ lệ, nhưng chúng không phải là các thử nghiệm lý tưởng vì lý do tìm kiếm tính không nhạy cảm với các biến này ngay từ đầu là vì chúng ta không phải lúc nào cũng biết tiên nghiệm khi hình ảnh được thu được dưới các điều kiện khác nhau. điều kiện và sự sắp xếp hình học. Một thử nghiệm thực tế hơn là tính toán các đặc điểm cho một hình ảnh nguyên mẫu và kiểm tra chúng trên các mẫu chưa biết. Hình 6.64 cho thấy kết quả của những thử nghiệm đó. Hình 6.64(a) là hình ảnh xây dựng ban đầu, trong đó các véc tơ đặc trưng SIFT đã được tính toán

(xem Hình 6.61). SIFT được sử dụng để so sánh ảnh con được xoay từ Hình 6.62(a) với ảnh gốc, không được xoay. Như Hình 6.64(a) cho thấy, có 10 kết quả được tìm thấy, trong đó có 2 kết quả không chính xác. Đây là những kết quả tuyệt vời khi xét đến kích thước tương đối nhỏ của ảnh con và thực tế là nó đã được xoay. Hình 6.64(b) hiển thị kết quả so khớp ảnh con có kích thước bằng một nửa với ảnh gốc. 11 kết quả được tìm thấy, trong đó có 4 kết quả không chính xác. Một lần nữa, đây là những kết quả tốt, xét đến thực tế là chi tiết quan trọng đã bị mất trong ảnh con khi nó được xoay hoặc giảm kích thước. Nếu được hỏi trong cả hai trường hợp: Chỉ dựa trên các kết quả trùng khớp mà SIFT tìm thấy, hai hình ảnh phụ đến từ phần nào của tòa nhà? Câu trả lời rõ ràng ở cả hai là các ảnh con nằm ở góc bên phải của tòa nhà. Hai thử nghiệm trước minh họa khả năng thích ứng của SIFT với các biến thể về góc quay và tỷ lệ.



Hình 6.64 (a) Trùng khớp giữa hình ảnh tòa nhà ban đầu và phiên bản xoay của một đoạn ở góc bên phải của nó. Mười kết quả được tìm thấy, trong đó có hai kết quả không chính xác. (b) So khớp giữa ảnh gốc và phiên bản thu nhỏ một nửa của một đoạn ở góc phải của nó. Tại đây, 11 kết quả được tìm thấy, trong đó có 4 kết quả sai.

6.8. Biểu đồ tần suất gradient định hướng - histogram of oriented gradients (HOG, một dạng SIFT)

Đặc trưng dạng biểu đồ tần suất gradient định hướng - histogram of oriented gradients (HOG) xây dựng một mô tả chi tiết hơn về cấu trúc không gian sử dụng một cửa sổ ảnh nhỏ. Đây là một bước tiền xử lý hữu ích cho các thuật toán phát hiện đối tượng có cấu trúc tựa quy chuẩn – quasi-regular như người đi bộ. Giống như đặc trưng SIFT, đặc trưng HOG bao gồm một tập hợp các biểu đồ tần suất chuẩn hóa được tính toán trên các phần nhỏ được dịch chuyển trong không gian ảnh; kết quả là một đặc trưng mô tả cấu trúc không gian thô, nhưng bất biến đối với các biến dạng nhỏ, cục bộ.

Quá trình tính toán đặc trưng HOG thích hợp cho việc phát hiện người đi bộ bao gồm các giai đoạn sau. Trước tiên, hướng θ_{ij} và độ lớn a_{ij} của các gradient ảnh được tính toán tại mỗi pixel (i, j) trong một cửa sổ kích cỡ 64×128 sử dụng phương trình (6.8-1).

$$\begin{aligned}\theta_{ij} &= \arctan[v_{ij}/h_{ij}] \\ a_{ij} &= \sqrt{h_{ij}^2 + v_{ij}^2}.\end{aligned}\tag{6.8-1}$$

Trong đó v_{ij} và h_{ij} là các giá trị theo pixel của các ảnh H và V, theo thứ tự, chứa các đạo hàm theo các hướng ngang và hướng thẳng đứng. Các ảnh H và V thu nhận được từ ảnh đầu vào bằng cách: thứ nhất là xử lý lọc nhiễu, sau đó nhân tích chập ảnh đã lọc nhiễu với một cặp bộ lọc tính đạo hàm trực giao ví dụ như các bộ lọc Prewitt.

Hướng được lượng tử hóa thành chín khoảng – bin phân bố trên dải 0° – 180° . Vùng 64×128


của bộ phát hiện được chia thành một lưới đều của các ô 6×6 chồng lẫn nhau. Một biểu đồ tần suất 9D theo hướng được tính toán trong mỗi ô, trong đó đóng góp vào biểu đồ tần suất được trọng số bằng độ lớn gradient và khoảng cách từ tâm của ô để các pixel ở trung tâm đóng góp mạnh hơn. Đối với mỗi khối 3×3 của các ô 6×6 , các đặc trưng được nối với nhau và được chuẩn hóa để tạo ra một đặc trưng dạng khối. Tất cả các đặc trưng dạng khối được nối để tạo ra đặc trưng HOG cuối cùng.

Đặc trưng cuối cùng chứa thông tin được tổng hợp theo không gian về các gradient địa phương (trong mỗi ô), nhưng vẫn giữ được một số thông tin chi tiết theo không gian (vì có nhiều ô). Nó tạo ra bất biến đối với sự phân cực độ tương phản cục bộ (ví dụ bất biến đối với thay đổi tối-sáng giữa đối tượng-nền hay ngược lại sáng-tối) bằng cách chỉ sử dụng độ lớn của gradient. Nó tạo ra bất biến đối với độ lớn của độ tương phản cục bộ bằng cách chuẩn hóa tương đối so với mỗi khối. Đặc trưng HOG tương tự với đặc trưng SIFT về mặt ý tưởng nhưng được phân biệt bởi bất biến với sự phân cực (phân ngưỡng) độ tương phản – contrast polarity, có mức độ thông tin chi tiết về mặt không gian cao hơn của các biểu đồ tần suất được tính toán và thực hiện chuẩn hóa một cách cục bộ hơn.

6.9. Đặc trưng mẫu nhị phân địa phương - local binary patterns (LBP)

Phép toán mẫu nhị phân địa phương - Local Binary Patterns (LBP) operator trả về một giá trị rời rạc tại mỗi điểm ảnh, đặc trưng cho cấu trúc texture cục bộ theo cách thức là một bất biến bán phần đối với những thay đổi độ sáng của ảnh. Vì lý do này, các đặc trưng dựa trên các mẫu nhị phân địa phương thường được sử dụng là nền tảng cho các thuật toán nhận diện khuôn mặt.

Phép toán LBP cơ bản so sánh tám giá trị độ sáng của các điểm xung quanh với giá trị trung tâm, gán một giá trị 0 hoặc 1 cho mỗi điểm xung quanh tùy thuộc vào việc chúng có nhỏ hơn hay lớn hơn giá trị trung tâm. Những giá trị nhị phân này sau đó được ghép lại theo một thứ tự đã quy định trước và chuyển đổi thành một số thập phân đơn biểu thị "loại" cấu trúc ảnh cục bộ (Hình 6.8.1).



Hình 6.65 Mô hình nhị phân cục bộ. a) Mô hình nhị phân cục bộ được tính toán bằng cách so sánh điểm trung tâm với tám điểm xung quanh của nó. Giá trị nhị phân được liên kết với mỗi vị trí được thiết lập thành một nếu điểm xung quanh đó lớn hơn hoặc bằng điểm trung tâm. Tám giá trị nhị phân có thể được đọc ra và kết hợp để tạo ra một số 8 bit duy nhất. b) Mô hình nhị phân cục bộ có thể được tính toán trên các khu vực lớn hơn bằng cách so sánh các điểm ảnh hiện tại với ảnh (nội suy) tại các vị trí trên một vòng tròn. Loại LBP này được đặc trưng bởi số mẫu P và bán kính của vòng tròn R.


Với xử lý tiếp theo, phép toán LBP có thể trở thành bất biến theo hướng: biểu diễn nhị phân liên tục được đưa qua các phép dịch bit để tạo ra tám giá trị nhị phân mới và chọn giá trị nhỏ nhất trong chúng. Điều này giảm số lượng giá trị LBP có thể có xuống còn 36. Trong thực tế, người ta đã phát hiện rằng phân phối trên 36 giá trị LBP này thường bị chi phối bởi những giá trị tương đối đồng đều. Nói cách khác, chuỗi nhị phân mà không có sự dịch chuyển (ví dụ: 00000000, 11111111) hoặc hiếm gặp hơn (ví dụ: 00001111, 00111111) xuất hiện nhiều nhất. Số lượng các lớp texture có thể được giảm xuống bằng cách tổng hợp tất cả các LBP không đồng nhất thành một lớp duy nhất. Bây giờ, cấu trúc ảnh cục bộ được phân loại thành

chín kiểu LBP (tám mẫu đồng nhất bất biến đối với phép xoay ảnh và một lớp không đồng nhất).

Phép toán LBP có thể được mở rộng để sử dụng các vùng lân cận có kích thước khác nhau: điểm ảnh trung tâm được so sánh với các vị trí khác theo một kiểu vòng tròn (Hình 6.8.1b). Nói chung, những vị trí này không hoàn toàn trùng khớp với lưới điểm ảnh, và độ sáng tại những vị trí này phải được ước lượng bằng phương pháp nội suy tuyến tính. Phép toán LBP mở rộng này có thể bắt được kết cấu ở các kích cỡ - scale khác nhau trong ảnh.

6.10. Đặc trưng kiểu Haar - Haar-like feature

Bộ lọc Haar-like bao gồm các vùng hình chữ nhật kề nhau được cân bằng sao cho giá trị trung bình của bộ lọc là bằng không, và chúng là bất biến đối với thay đổi độ sáng hằng số. Tùy thuộc vào cấu hình của những vùng này, chúng có thể tương tự như bộ lọc đạo hàm hay bộ lọc Gabor (Hình 6.66).



Hình 6.66 Bộ lọc Haar-like. a–d) Bộ lọc Haar-like bao gồm các khu vực hình chữ nhật. Phép tích chập với các bộ lọc Haar-like có thể được thực hiện với thời gian hằng số. e) Để hiểu tại sao, hãy xem xét bài toán lọc với một vùng chữ nhật đơn trong hình. f) Chúng ta ký hiệu tổng giá trị pixel trong bốn vùng là A, B, C và D. Mục tiêu của chúng ta là tính D. g) Hình ảnh tích phân (tổng) có giá trị là tổng các độ sáng của các pixel ở phía trên và bên trái vị trí hiện tại. Do đó hình ảnh tích phân tại vị trí (i_1, j_1) có giá trị là $A + B + C + D$. h) Hình ảnh tích phân tại (i_1, j_0) có giá trị là $A + C$. i) Hình ảnh tích phân tại (i_0, j_1) có giá trị là $A + B$. j) Hình ảnh tích phân tại (i_0, j_0) có giá trị là A. Tổng của các pixel trong khu vực D có thể được tính toán như sau: $I_{i_1,j_1} + I_{i_0,j_0} - I_{i_1,j_0} - I_{i_0,j_1} = (A + B + C + D) + A - (A + C) - (A + B) = D$. Điều này chỉ yêu cầu bốn phép toán không phụ thuộc vào kích thước ban đầu của khu vực vuông.

Tuy nhiên, các bộ lọc Haar-like nhiều hơn so với các bộ lọc mà chúng xấp xỉ (chẳng hạn bộ lọc đạo hàm...): chúng có các cạnh sắc giữa các vùng dương và âm và do đó di chuyển một pixel gần một cạnh có thể làm thay đổi đáng kể kết quả đầu ra. Nhược điểm này được bù đắp bằng tốc độ tương đối nhanh của việc tính toán các hàm Haar.

Để tính toán các hàm Haar-like nhanh chóng, chúng ta trước tiên tạo ra hình ảnh tích phân (Hình 6.66g). Đây là một biểu diễn trung gian trong đó mỗi pixel chứa tổng của tất cả các giá trị độ sáng ở phía trên và bên trái vị trí hiện tại. Do đó, giá trị ở góc trên cùng bên trái là giá trị pixel gốc tại vị trí đó và giá trị ở góc dưới cùng bên phải là tổng của tất cả các giá trị pixel trong ảnh. Các giá trị ở các phần khác của hình ảnh tích phân nằm giữa các thái cực đó.

Cho trước hình ảnh tích phân I, có thể tính tổng độ sáng trong bất kỳ khu vực hình chữ nhật nào chỉ với bốn phép toán, bất kể kích thước của khu vực này là bao nhiêu. Xét vùng được

xác định bởi dải $[i_0, i_1]$ theo cột và $[j_0, j_1]$ theo hàng, tổng S của các cường độ sáng của các pixel trong vùng là:

$$S = I_{i_1, j_1} + I_{i_0, j_0} - I_{i_1, j_0} - I_{i_0, j_1}. \quad (6.8-2)$$

Cơ sở lý luận của phép tính này được minh họa trong Hình 6.66 f-i.

Vì bộ lọc Haar-like được tạo thành từ các vùng hình chữ nhật, chúng có thể được tính toán bằng một cách thức tương tự. Đối với một bộ lọc với hai vùng hình chữ nhật kề nhau, cần sáu phép toán. Với ba vùng hình chữ nhật kề nhau, cần tám phép toán. Khi kích thước M và N của bộ lọc là lớn, phương pháp này có lợi thế so sánh hơn hẳn so với cách cài đặt đơn giản của bộ lọc thông thường (chẳng hạn các bộ lọc Gauss, Sobel, Prewitt v.v.). Các bộ lọc thông thường như thế đòi hỏi $O(MN)$ phép toán để tính toán đầu ra của bộ lọc khi sử dụng một nhân – kernel cỡ $M \times N$, trong khi bộ lọc kiểu Haar chỉ cần cố định 6 hoặc 8 phép toán. Bộ lọc Haar thường được sử dụng trong các ứng dụng thời gian thực như nhận diện khuôn mặt do tốc độ tính toán nhanh của chúng.

Câu hỏi ôn tập và bài tập

Bài tập 1

(a) Chứng minh rằng việc định lại điểm bắt đầu của một mã chuỗi sao cho chuỗi kết quả tạo thành một số nguyên có giá trị tuyệt đối nhỏ nhất sẽ làm cho mã này không phụ thuộc vào điểm bắt đầu ban đầu trên biên.

(b) Tìm điểm bắt đầu chuẩn hóa của mã 11076765543322.

Bài tập 2

(a) Chứng minh rằng hiệu bậc 1 (hiệu của 2 số liên tiếp nhau trong mã chuỗi) của một mã chuỗi sẽ chuẩn hóa nó đối với phép xoay.

(b) Tính hiệu bậc 1 của mã 01010303033232212111.

Bài tập 3

(a) Chứng minh rằng phương pháp xấp xỉ đa giác bằng rubber-band sẽ tạo ra một đa giác có chu vi tối thiểu.

(b) Chứng minh rằng nếu mỗi ô tương ứng với một pixel trên biên, sai số tối đa có thể trong ô đó là $\sqrt{2}d$, trong đó d là khoảng cách ngang hoặc dọc tối thiểu giữa các pixel kề nhau (tức là khoảng cách giữa các dòng trong lưới mẫu được sử dụng để tạo ra hình ảnh kỹ thuật số).

Bài tập 4

(a) Thảo luận về ảnh hưởng của ngưỡng lỗi đối với đa giác kết quả nếu thiết lập ngưỡng là không.

(b) Ảnh hưởng của nó lên phương pháp chia vùng.

Bài tập 5

(a) Vẽ biểu đồ biên dạng-signature của một biên vuông sử dụng phương pháp góc tiếp xúc.

(b) Lặp lại cho hàm mật độ độ dốc.

Giả sử rằng hình vuông được căn chỉnh với trục x và y , và trục x là đường tham chiếu. Bắt đầu từ góc gần gốc tọa độ.

Bài tập 6

Tìm biểu thức cho biên dạng của mỗi biên sau đây và vẽ biên dạng.

(a) Một tam giác đều

(b) Một hình chữ nhật

(c) Một elip

Bài tập 7

Vẽ trục trung tâm của

(a) Một đường tròn

(b) Một hình vuông

(c) Một hình chữ nhật

(d) Một tam giác đều

Chương 7

PHÂN LOẠI MẪU ẢNH

Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Hiểu ý nghĩa của các mẫu – pattern và lớp mẫu – pattern classes, và cách chúng liên quan đến xử lý ảnh số.
- ✓ Quen thuộc với kiến thức cơ bản của phân loại khoảng cách tối thiểu.
- ✓ Biết cách áp dụng các kỹ thuật tương quan ảnh cho việc khớp mẫu.
- ✓ Hiểu khái niệm về khớp chuỗi.
- ✓ Quen thuộc với các bộ phân loại Bayes.
- ✓ Hiểu về perceptrons hay mạng perceptron: lịch sử, các khái niệm, lý thuyết và ứng dụng của chúng.
- ✓ Quen thuộc với khái niệm về học từ các mẫu huấn luyện.
- ✓ Hiểu về kiến trúc mạng neural.
- ✓ Quen thuộc với khái niệm học sâu trong các mạng neural kết nối đầy đủ và mạng tích chập sâu. Đặc biệt là việc quen thuộc với tầm quan trọng của mạng tích chập sâu trong xử lý ảnh số.

7.1. Mở đầu

Trong nhận dạng mẫu ảnh, chúng ta xem mẫu là sự sắp xếp theo không gian của các đặc trưng. Một lớp mẫu là một tập hợp các mẫu có chia sẻ một số thuộc tính chung. Nhận dạng mẫu dùng máy (pattern recognition by machine) bao gồm các kỹ thuật cho việc gán mẫu tự động vào các lớp tương ứng của chúng. Chính là, cho trước một mẫu hoặc một tập hợp các mẫu chưa biết lớp, công việc của hệ thống nhận dạng mẫu là gán nhãn lớp cho mỗi mẫu đầu vào.

Có 4 giai đoạn liên quan đến nhận dạng: (1) thu nhận ảnh, (2) tiền xử lý, (3) trích chọn đặc trưng, và (4) phân loại. Trong xử lý ảnh, cảm biến liên quan tới việc sinh tín hiệu trong một miền không gian (2-D hoặc định dạng nhiều chiều không gian hơn). Chúng ta đã nói về thu nhận ảnh trong Chương 1. Tiền xử lý liên quan đến các kỹ thuật như giảm nhiễu, cải thiện ảnh, khôi phục, và phân đoạn như đã trình bày trong các chương trước. Tương tự như vậy chúng ta đã nói về trích chọn đặc trưng trong chương trước. Phân loại ảnh là chủ đề của chương này. Nó liên quan đến việc dùng một tập các đặc trưng làm cơ sở cho việc gán các nhãn lớp cho các mẫu ảnh đầu vào chưa biết.

Ở phần tiếp theo, chúng ta sẽ tìm hiểu ba cách tiếp cận cơ bản được sử dụng cho phân loại mẫu ảnh: (1) phân loại dựa trên việc so khớp các mẫu chưa biết với các nguyên mẫu đã được xác định, (2) các bộ phân loại thống kê tối ưu, và (3) các mạng nơ-ron. Một cách để mô tả sự khác biệt giữa các cách tiếp cận đó là mức kỹ thuật hoặc kỹ nghệ (level of engineering) cần thiết để chuyển đổi dữ liệu thô sang các định dạng phù hợp cho việc xử lý bằng máy tính. Cuối cùng, hiệu năng của nhận dạng được xác định bằng khả năng phân lập của các đặc trưng được sử dụng.

Trong phân loại ảnh dựa trên các nguyên mẫu (prototypes), mục tiêu là làm cho các đặc trưng của ảnh trở nên thật riêng biệt và dễ dàng phát hiện, phân biệt nhau vì thế phân loại ảnh trở thành một nhiệm vụ đơn giản. Một ví dụ tốt ở đây là các máy đọc séc ngân hàng, chúng sử dụng các kiểu font chữ được định kiểu rất rõ ràng, riêng biệt (mỗi ký tự có một đặc trưng không thể lẫn lộn nhau) để đơn giản hóa việc xử lý bằng máy (sẽ được trình bày cụ thể trong phần tiếp theo).

Trong cách tiếp cận thứ hai, phân loại ảnh được giải quyết theo lý thuyết quyết định và thống

kê, và phương pháp phân loại được thực hiện dựa trên việc lựa chọn các tham số mà người ta có thể chứng minh được là tạo ra hiệu năng phân loại tối ưu theo nghĩa thống kê. Cách tiếp cận này chú trọng đến cả 2 yếu tố: các đặc trưng (features) được sử dụng và thiết kế của bộ phân loại. Chúng ta sẽ minh họa cách tiếp cận này trong phần tiếp theo bằng cách tạo ra bộ phân loại mẫu Bayes, bắt đầu với những nguyên tắc cơ bản.

Trong cách tiếp cận thứ ba, phân loại ảnh được thực hiện sử dụng mạng nơ-ron. Các định nghĩa có liên quan sẽ được trình bày cụ thể trong phần này. Về cơ bản, mạng nơ-ron có thể hoạt động với các đặc trưng đã được định nghĩa trước và đã được tính toán, đo đạc, nhưng một số mạng nơ-ron cũng có khả năng sinh các biểu diễn (đặc trưng) phù hợp cho việc nhận dạng. Các hệ thống này có thể thực hiện nhận dạng ảnh bằng cách sử dụng trực tiếp dữ liệu (ảnh) thô, mà không cần trích xuất các đặc trưng.

Một đặc điểm chung của cả ba cách tiếp cận là chúng dựa trên các tham số hoặc là phải được xác định hoặc là phải học từ các mẫu đầu vào của bài toán nhận dạng chúng ta muốn thực hiện. Các mẫu đó có thể được gán nhãn, nghĩa là chúng ta đã biết lớp của mỗi mẫu (một cách thô thiển là ta đã biết ảnh đó là ảnh gì), hoặc không gán nhãn, có nghĩa là dữ liệu được hiểu là mẫu, nhưng lớp của mỗi mẫu ảnh là không xác định. Ví dụ kinh điển về dữ liệu được gán nhãn là bài toán nhận dạng ký tự, trong đó một tập các ký tự ví dụ mẫu (ảnh mẫu) được thu thập và sự xác định của mỗi ký tự được ghi dưới dạng nhãn từ 0 (ảnh số 0) đến 9 (ảnh số 9) và từ a (ảnh chữ a) đến z (ảnh chữ z). Một ví dụ về dữ liệu không gán nhãn là khi chúng ta tìm kiếm các nhóm (cụm) dữ liệu trong tập dữ liệu, với mục tiêu sử dụng các nhóm được sinh ra như là các nguyên mẫu (không cần gán tên cụ thể trước) của các lớp mẫu chứa đựng trong dữ liệu.

Khi làm việc với dữ liệu được gán nhãn, một tập dữ liệu cho trước thường được chia thành ba tập con: tập huấn luyện, tập kiểm chuẩn và tập kiểm thử (tỷ lệ phân chia điển hình có thể là 50% cho tập huấn luyện và 25% cho mỗi tập kiểm chuẩn và tập kiểm thử). Một bộ phân loại thông thường phụ thuộc rất nhiều tham số. Quá trình sử dụng tập huấn luyện để tính toán giá trị của các tham số của một bộ phân loại được gọi là quá trình huấn luyện. Trong quá trình huấn luyện, bộ phân loại được cung cấp nhãn lớp của mỗi mẫu, mục tiêu huấn luyện là điều chỉnh các tham số nếu bộ phân loại mắc lỗi (phân loại sai) trong việc xác định lớp của một mẫu cho trước. Ở điểm này, chúng ta có thể đang làm việc với một vài thiết kế khác nhau (tham số mô hình, kiến trúc... khác nhau) để chọn lựa mô hình tốt nhất. Ở cuối quá trình huấn luyện, chúng ta sử dụng tập kiểm chuẩn để so sánh các thiết kế khác nhau theo tiêu chí hiệu năng. Thường chúng ta cần một số lần lặp lại quá trình huấn luyện/kiểm chuẩn để xác định thiết kế nào tiến gần nhất đến việc đáp ứng mục tiêu mong muốn (thiết kế tốt nhất). Một khi một thiết kế đã được lựa chọn, bước cuối cùng là xác định xem nó sẽ hoạt động ra sao với các dữ liệu thực tế khác. Để làm điều này, chúng ta sử dụng tập kiểm thử, bao gồm các mẫu mà hệ thống chưa bao giờ tiếp xúc, phân tích trước đó. Nếu tập huấn luyện và tập kiểm chuẩn thực sự đại diện cho dữ liệu mà hệ thống sẽ gặp trong thực tế, kết quả của quá trình huấn luyện/kiểm chuẩn nên phải gần sát với hiệu năng của hệ thống khi làm việc với tập kiểm thử. Nếu kết quả của quá trình huấn luyện/kiểm chuẩn là tốt, nhưng kết quả của hệ thống khi làm việc với tập kiểm thử lại kém, chúng ta nói rằng quá trình huấn luyện/kiểm chuẩn quá khớp - overfit các tham số hệ thống dựa trên dữ liệu có sẵn, trong trường hợp này thường cần can thiệp vào kiến trúc của hệ thống của mô hình phân loại. Tất nhiên, tất cả những điều đó giả định rằng dữ liệu đã được cung cấp là thực sự đại diện cho bài toán chúng ta muốn giải quyết. Đồng thời phải đảm bảo rằng bài toán thực sự có thể được giải quyết bằng công nghệ hiện tại của bộ phân loại, chỉ là cần phải điều chỉnh thiết kế, tham số v.v.

Một hệ thống được thiết kế với việc sử dụng dữ liệu huấn luyện được gọi là học có giám sát – supervised learning. Nếu chúng ta làm việc với dữ liệu không gán nhãn, hệ thống sẽ tự học các lớp mẫu với chế độ học không có giám sát – unsupervised learning. Trong chương này,

chúng ta chỉ xem xét học có giám sát. Học có giám sát bao gồm các cách tiếp cận từ các ứng dụng trong đó hệ thống học các tham số của các đặc trưng có dạng được cố định bởi người thiết kế hệ thống (dạng đặc trưng của ảnh đã xây dựng trước), đến các hệ thống sử dụng học sâu – deep learning cùng các tập rất lớn các bộ dữ liệu thô để tự học các đặc trưng cần thiết (tự xây dựng đặc trưng cho ảnh) cho việc phân loại. Các hệ thống như vậy thực hiện nhiệm vụ học các đặc trưng trong dữ liệu mà không cần các đặc trưng phải được xác định trước.

Trong phần tiếp theo, sau khi xem xét sơ bộ về cách các mẫu được hình thành, và bản chất của các lớp mẫu, chúng ta sẽ tìm hiểu về các phương pháp khác nhau cho việc phân loại dựa trên nguyên mẫu. Chúng ta sẽ bắt đầu từ các nguyên lý cơ bản và rút ra các phương trình của bộ phân loại Bayes, một cách tiếp cận được đặc trưng bởi hiệu năng phân lớp tối ưu xét theo khía cạnh tổng thể. Chúng ta cũng sẽ thảo luận về dạy có giám sát – supervised training cho bộ phân loại Bayes dựa trên giả thuyết về các phân phối Gauss nhiều chiều. Một bộ phân loại với hiệu năng cao, được sử dụng rộng rãi là bộ phân loại thích nghi – Adaboost (Adaptive Boosting) sẽ được giới thiệu sau bộ phân loại thống kê. Ý tưởng của Adaboost là cải thiện hiệu năng của các bộ phân loại yếu, đơn giản và từ đó tạo ra các bộ phân loại mạnh, hiệu quả và có độ chính xác cao. Tiếp theo, chúng ta sẽ dành phần còn lại của chương để thảo luận về mạng neural. Chúng ta sẽ bắt đầu với một giới thiệu ngắn về perceptrons và lịch sử của học máy. Sau đó sẽ giới thiệu khái niệm về mạng neural sâu và thu nhận các phương trình của quá trình lan truyền ngược – backpropagation là phương pháp được lựa chọn để dạy - training các mạng neural sâu. Các mạng này thích hợp cho các ứng dụng trong đó các mẫu đầu vào là các vector. Trong phần tiếp theo, chúng ta sẽ giới thiệu các mạng neural tích chập sâu, là cách tiếp cận được ưu tiên hiện nay khi đầu vào của hệ thống là ảnh số. Sau khi thu nhận các phương trình lan truyền ngược được sử dụng để dạy các mạng tích chập, chúng ta sẽ đưa ra một số ví dụ về các ứng dụng liên quan đến các lớp ảnh có độ phức tạp khác nhau. Bên cạnh khả năng làm việc trực tiếp với đầu vào ảnh, các mạng tích chập sâu cũng có khả năng tự học các đặc trưng ảnh phù hợp cho việc phân loại. Khả năng đó được thực hiện bắt đầu với dữ liệu ảnh thô, khác với các phương pháp phân loại khác – các phương pháp dựa vào các đặc trưng đã được thiết kế có dạng được xác định trước bởi người thiết kế.

7.2. Các mẫu và các lớp mẫu

Trong phân loại mẫu ảnh, có hai sắp xếp chính với mẫu là: mẫu định lượng và mẫu cấu trúc. Mẫu định lượng được tổ chức theo dạng các vector mẫu. Mẫu cấu trúc thường được tạo thành từ các biểu tượng, sắp xếp dưới dạng chuỗi, cây, hoặc, ít phổ biến hơn là dưới dạng đồ thị. Hầu hết nội dung trình bày trong chương này là dựa trên các vector mẫu, nhưng chúng ta cũng sẽ trình bày ngắn gọn về các mẫu cấu trúc ở cuối phần này, và đưa ra một ví dụ ở phần tiếp theo.

7.2.1. Các vector mẫu


Các vector mẫu được biểu diễn bằng các chữ cái in thường như x , y , và z và có dạng:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad (7-1)$$

Trong đó mỗi thành phần x_i , biểu diễn mô tả của đặc trưng thứ i , và n là tổng số các mô tả. Chúng ta có thể biểu diễn một vector dưới dạng cột, như trong công thức (7-1), hoặc tương đương dưới dạng hàng $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, với T là phép chuyển vị ma trận. Một vector mẫu có thể được xem như là một điểm trong không gian Euclide n chiều, và một lớp mẫu có thể được hiểu như một đám mây – hypercloud gồm các điểm trong không gian mẫu này. Đối với mục đích nhận dạng ảnh, chúng ta muốn các lớp mẫu được nhóm chặt chẽ (độ tụ cao) và các nhóm càng xa nhau càng tốt (các loại mẫu càng phân biệt nhau càng tốt).


Các vector mẫu có thể được tạo ra trực tiếp từ cường độ sáng của các pixel ảnh bằng cách

vector hóa ảnh, chẳng hạn như sử dụng chỉ mục tuyến tính như trong Hình 7.1. Một cách tiếp cận phổ biến hơn là các phần tử mẫu là các đặc trưng. Một ví dụ khởi đầu cách đây gần một thế kỷ liên quan đến việc sử dụng các phần tử mẫu là các đặc trưng là của Fisher, người đã trình bày về việc sử dụng một kỹ thuật mới tên là phân tích phân biệt – discriminant analysis để nhận diện ba loại hoa iris (Iris setosa, virginica và versicolor). Fisher mô tả mỗi bông hoa sử dụng bốn đặc trưng: chiều dài, chiều rộng của cánh hoa và tương tự cho lá bấp (xem Hình 7.2). Điều này sinh ra các vector 4 chiều như trong Hình 7.2. Một tập hợp các vector này, được thu thập cho năm mẫu của mỗi loại hoa, tạo thành ba lớp mẫu iris Fisher nổi tiếng. Nếu Fisher còn làm việc ngày nay, ông rất có thể sẽ thêm màu sắc phổ và các đặc trưng hình dạng vào các đo đạc của mình. Khi đó các vector mẫu thu nhận được sẽ có nhiều chiều hơn. Chúng ta sẽ tiếp tục làm việc với tập dữ liệu iris gốc trong các phân tích tiếp sau trong chương này.




Hình 7.1 Sử dụng chỉ mục tuyến tính để vector hóa 1 ảnh đa cấp xám.

Một biểu diễn mức cao hơn của các mẫu được dựa trên các mô tả về các đặc trưng - features đã trình bày trong chương trước. Ví dụ, các vector mẫu được tạo nên từ các mô tả hình dạng biên sẽ thích hợp cho các ứng dụng trong các môi trường được kiểm soát, như trong chẩn đoán công nghiệp – industrial inspection. Hình 7.3 minh họa khái niệm này. Ở đây, chúng ta quan tâm đến việc phân loại các kiểu khác nhau của các biên dạng có nhiều. Nếu chúng ta biểu diễn một đối tượng bằng một Biên dạng - signature của nó, chúng ta sẽ thu nhận được các tín hiệu 1-D có dạng trong Hình 7.3(b). Chúng ta có thể biểu diễn một Biên dạng của 1 đối tượng như là một vector bằng việc lấy mẫu biên độ của Biên dạng đó tại các mức tăng của góc quay θ , sau đó hình thành một vector bằng cách đặt các thành phần $x_i = r(\theta_i)$, với $i = 0, 1, 2, \dots, n$. Thay vì sử dụng cách lấy mẫu dạng thô, có một cách tiếp cận phổ biến hơn là tính toán một hàm nào đó, chẳng hạn $x_i = g(r(\theta_i))$ của các mẫu – sample của Biên dạng và sử dụng chúng để hình thành các vector. Chúng ta sẽ tìm hiểu trong các phần tiếp theo một số cách tiếp cận để thực hiện điều này, chẳng hạn như các moment thống kê.



Hình 7.2 Đo độ rộng và độ dài cánh hoa và lá bấp (xem các mũi tên) trên hoa iris nhằm

mục đích phân loại dữ liệu. Hình ảnh được hiển thị là của giống loài Iris virginica.




Hình 7.3 Biên dạng – signature (a) Một biên đối tượng (biên bị nhiễu), và (b) mô tả tương ứng của nó.


Các vector cũng có thể được hình thành cả từ các đặc trưng của biên và miền. Ví dụ, các đối tượng trong Hình 7.4 có thể được biểu diễn bằng các vector 3-D, trong đó các thành phần của vector thể hiện thông tin hình dạng liên quan đến các thuộc tính của cả biên và miền của các đối tượng nhị phân trong hình. Các vector mẫu cũng có thể được sử dụng để biểu diễn các thuộc tính của các miền trong ảnh. Ví dụ, các thành phần của 1 vector 6-D trong Hình 7.5 là các đo đặc kết cấu dựa trên các mô tả đặc trưng của ảnh bộ phận. Hình 7.6 cho thấy một ví dụ trong đó các thành phần của vector mẫu là các đặc trưng bất biến đối với các biến đổi, chẳng hạn như xoay hình ảnh, thay đổi tỷ lệ ảnh v.v.



Hình 7.4 Các vector mẫu 3-D mà thành phần của nó thể hiện cả các đặc điểm biên và vùng (gồm các thuộc tính chỉ mức độ gọn - compactness, tròn – circularity và tập trung - eccentricity).




Hình 7.5 Một ví dụ của các vector mẫu 6-D dựa trên các tính chất của các ảnh bộ phận.



Hình 7.6 Các vector đặc trưng 7-D với các thành phần là bất biến đối với các phép biến đổi như xoay, thay đổi tỷ lệ, tịnh tiến v.v. Các thành phần của vector là các bất biến moment.


Khi làm việc với các chuỗi của các hình ảnh đồng bộ, chúng ta có lựa chọn sử dụng các vector mẫu được hình thành từ các pixel tương ứng trong các ảnh (xem Hình 7.7). Việc hình thành các vector mẫu theo cách này nghĩa là nhận dạng sẽ dựa trên thông tin được trích xuất từ vị trí không gian giống nhau trên toàn bộ các ảnh. Mặc dù điều này có vẻ như là một cách tiếp cận rất hạn chế, nhưng trong thực tế nó là lý tưởng cho các ứng dụng như nhận dạng các vùng trong các ảnh đa phổ, như chúng ta sẽ đề cập đến trong các phần tiếp theo.



Hình 7.7 Các vector mẫu 6-D (hay vector đặc trưng) được tạo nên bằng việc ghép nối thông tin ở các pixel tương ứng từ 1 tập 6 ảnh đồng bộ.



7.2.2. Các mẫu cấu trúc

Vector mẫu không phù hợp cho các ứng dụng trong đó các đối tượng được biểu diễn bằng các đặc trưng cấu trúc, chẳng hạn như chuỗi các ký hiệu. Mặc dù chúng được sử dụng ít hơn nhiều so với các vector trong các ứng dụng xử lý ảnh, các mẫu chứa các mô tả cấu trúc của các đối tượng đóng vai trò quan trọng trong các ứng dụng mà hình dạng đối tượng là yếu tố quyết định. Hình 7.8 cho thấy một ví dụ như vậy. Các biên của các chai được xấp xỉ bằng một đa giác bằng cách sử dụng các cách tiếp cận về trích chọn đặc trưng đã được trình bày trong chương trước. Biên được chia nhỏ thành các đoạn thẳng (được biểu thị bằng ký hiệu β như trong hình), và góc trong, θ , được tính toán tại mỗi giao cắt của hai đoạn thẳng. Một chuỗi của các ký hiệu tuần tự được sinh ra khi biên được duyệt theo hướng ngược chiều kim đồng hồ. Các chuỗi có dạng này gọi là các mẫu cấu trúc – structural patterns, và mục tiêu của bài toán nhận dạng ảnh là khớp một chuỗi cho trước với các nguyên mẫu chuỗi đã có lưu trữ trong dữ liệu lịch sử (đã biết trước).



Hình 7.8 Chuỗi ký hiệu được sinh từ 1 xấp xỉ đa thức của các biên của các lọ thuốc.

Cây là một biểu diễn cấu trúc (structural representation) khác và cũng là dạng biểu diễn cấu trúc phù hợp cho các mô tả bậc cao của toàn bộ một hình ảnh theo các vùng thành phần của nó. Hầu hết các phương pháp sắp xếp theo thứ bậc đều dẫn đến các cấu trúc cây. Ví dụ, Hình 7.9 cho thấy một ảnh vệ tinh của một khu vực đô thị đông đúc và các khu dân cư xung quanh. Đặt ký hiệu \$ biểu diễn gốc của cây. Cây (ở đây trình bày dạng mọc ngược) hiển thị trong hình được thu nhận bằng cách sử dụng quan hệ cấu trúc "tạo nên từ". Gốc của cây đại diện cho toàn bộ ảnh. Mức tiếp theo cho biết ảnh bao gồm một khu trung tâm và các khu dân cư. Đến lượt nó, các khu dân cư bao gồm nhà cửa, đường cao tốc và trung tâm mua sắm. Mức tiếp theo trong cây mô tả chi tiết hơn về các khu vực nhà ở và đường cao tốc. Chúng ta có thể tiếp tục chia nhỏ theo kiểu này cho đến khi chúng ta đạt đến giới hạn của khả năng phân chia ảnh thành các vùng mà vẫn còn sự khác biệt giữa chúng.



Hình 7.9 Biểu diễn cây (tree representation) của 1 ảnh vệ tinh một vùng đô thị có mật độ xây dựng cao và các vùng dân cư xung quanh.

7.3. Phân loại mẫu bằng cách khớp nguyên mẫu

Khớp nguyên mẫu liên quan đến việc so sánh một mẫu chưa biết với một tập các nguyên mẫu (đã được xác định), và gán lớp của nguyên mẫu cho mẫu chưa biết khi gặp nguyên mẫu "tương tự - similar" nhất với mẫu chưa biết. Mỗi nguyên mẫu đại diện cho một lớp mẫu duy

nhất, nhưng có thể có nhiều hơn một nguyên mẫu cho mỗi lớp. Điều phân biệt một phương pháp khớp nguyên mẫu này so với các phương pháp khớp nguyên mẫu khác là phép đo hay phép tính toán được sử dụng để xác định sự tương tự.

7.3.1. Bộ phân loại khoảng cách nhỏ nhất hay bộ phân loại láng giềng gần nhất

Một trong những phương pháp khớp nguyên mẫu đơn giản nhất và phổ biến nhất là bộ phân loại khoảng cách tối thiểu. Bộ phân loại này tính toán một đo đặc khoảng cách giữa một vector mẫu chưa gán nhãn và mỗi nguyên mẫu của 1 lớp. Sau đó, nó gán mẫu chưa biết này vào lớp của nguyên mẫu gần nhất với nó. Các vector nguyên mẫu của bộ phân loại khoảng cách tối thiểu thường là các vector trung bình của các lớp mẫu khác nhau. Vector trung bình của mỗi lớp thường được tính theo công thức trung bình cộng của các vector trong lớp:

$$\mathbf{m}_j = \frac{1}{n_j} \sum_{\mathbf{x} \in c_j} \mathbf{x} \quad j = 1, 2, \dots, N_c \quad (7-2)$$

Trong đó, n_j là số vector mẫu được sử dụng để tính vector trung bình lớp thứ j , c_j là lớp mẫu thứ j , và N_c là số lớp. Nếu chúng ta sử dụng khoảng cách Euclide để xác định tính tương tự, bộ phân loại khoảng cách tối thiểu tính toán các khoảng cách.

$$D_j(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_j\| \quad j = 1, 2, \dots, N_c \quad (7-3)$$

Trong đó $\|a\| = (a^T a)^{1/2}$ là chuẩn Euclide. Bộ phân loại sau đó gán mẫu chưa biết x vào lớp c_i nếu $D_i(x) < D_j(x)$ với $j = 1, 2, \dots, N_c, j \neq i$. Các trường hợp xảy ra dấu bằng hay $D_i(x) = D_j(x)$ thì x có thể được phân vào nhóm i hoặc j tùy ý.

Có thể thấy rằng việc chọn khoảng cách bé nhất tương đương với việc ước lượng các hàm:

$$d_j(\mathbf{x}) = \mathbf{m}_j^T \mathbf{x} - \frac{1}{2} \mathbf{m}_j^T \mathbf{m}_j \quad j = 1, 2, \dots, N_c \quad (7-4)$$

Và gán một mẫu chưa biết x vào lớp mà nguyên mẫu của nó cho giá trị lớn nhất của d . Hay mẫu x được gán vào lớp c_i nếu:

$$d_i(\mathbf{x}) > d_j(\mathbf{x}) \quad j = 1, 2, \dots, N_c; j \neq i \quad (7-5)$$

Khi được sử dụng cho nhận dạng, các hàm có dạng này được gọi là các hàm quyết định hoặc hàm phân loại.

Biên ra quyết định phân tách các lớp c_i và c_j được cho bởi các giá trị của x mà:

$$d_i(\mathbf{x}) = d_j(\mathbf{x}) \quad (7-6)$$

Hoặc tương đương là bởi các giá trị của x mà:

$$d_i(\mathbf{x}) - d_j(\mathbf{x}) = 0 \quad (7-7)$$

Các biên ra quyết định của bộ phân loại khoảng cách tối thiểu được viết bởi phương trình này và phương trình (7-4) như sau:

$$\begin{aligned} d_{ij}(\mathbf{x}) &= d_i(\mathbf{x}) - d_j(\mathbf{x}) \\ &= (\mathbf{m}_i - \mathbf{m}_j)^T \mathbf{x} - \frac{1}{2} (\mathbf{m}_i - \mathbf{m}_j)^T (\mathbf{m}_i + \mathbf{m}_j) = 0 \end{aligned} \quad (7-8)$$

Biên cho bởi phương trình (7-8) là đường vuông góc với đoạn thẳng nối $\mathbf{m}_i$ và $\mathbf{m}_j$ tại trung điểm của đoạn. Trong trường hợp 2-D với $n = 2$ thì biên này là đường thẳng, với $n = 3$ biên này là mặt phẳng và với $n > 3$ biên này được gọi là siêu phẳng.

7.3.2. Bộ phân loại sử dụng phép tính tương quan cho bài toán khớp nguyên mẫu 2-D

Như đã giới thiệu ở các chương trước, phép tính tương quan – correlation của một cửa sổ w


với ảnh $f(x,y)$ được cho bởi:

$$(w \star f)(x,y) = \sum_s \sum_t w(s,t) f(x+s, y+t) \quad (7-9)$$

Trong đó các giới hạn của phép tính tổng được lấy trên vùng chồng khớp nhau của w và f . Phương trình này được tính toán cho tất cả các giá trị của các chuyển vị x và y , do đó tất cả các phân tử của w sẽ tương ứng với mọi điểm ảnh của f trong vùng chồng khớp. Như chúng ta đã biết, tương quan có (các) giá trị cao nhất ở các vùng mà f và w giống hoặc gần giống nhau. Nói cách khác, phương trình (7-9) tìm các vị trí mà w khớp với một vùng của f . Nhưng phương trình này có điểm yếu là kết quả nhạy cảm đối với sự thay đổi biên độ của một trong hai hàm. Vì thế, thay vào đó, để chuẩn hóa tương quan đối với sự thay đổi biên độ của một trong hai hàm hoặc cả hai, chúng ta thực hiện việc khớp bằng cách sử dụng hệ số tương quan:

$$\gamma(x,y) = \frac{\sum_s \sum_t [w(s,t) - \bar{w}][f(x+s, y+t) - \bar{f}_{xy}]}{\left\{ \sum_s \sum_t [w(s,t) - \bar{w}]^2 \sum_s \sum_t [f(x+s, y+t) - \bar{f}_{xy}]^2 \right\}^{\frac{1}{2}}} \quad (7-10)$$

Ở đây, giới hạn của phép tổng được áp dụng trong vùng chung của w và f , $\bar{w}$ là giá trị trung bình của kernel – cửa sổ (hằng số và chỉ cần tính toán một lần), và $\bar{f}_{xy}$ là giá trị trung bình của f trong vùng khớp với w . Trong tính toán tương quan với ảnh, w thường được gọi là mẫu - template (tức là, một phần của nguyên mẫu), và tương quan thường được gọi là việc khớp mẫu. Có thể chứng minh được rằng $\gamma(x,y)$ có giá trị trong khoảng $[-1,1]$ và do đó đã được chuẩn hóa đối với sự thay đổi về biên độ của w và f . Giá trị lớn nhất của γ xảy ra khi w (đã được chuẩn hóa) và vùng tương ứng (cũng đã được chuẩn hóa) của ảnh f là hoàn toàn giống nhau. Điều này cho tương quan tối đa (khớp khả dĩ tốt nhất). Giá trị nhỏ nhất của hàm tương quan xảy ra khi hai hàm đã được chuẩn hóa có ít điểm tương đồng nhất theo nghĩa của phương trình (7-10).



Hình 7.10 Cơ chế của khớp mẫu theo tính toán tương quan.

Hình 7.10 minh họa cơ chế làm việc của phương pháp khớp mẫu tương quan đã trình bày ở

trên. Biên quanh ảnh f được điền bổ sung thêm các pixel như trong các phép lọc sử dụng cửa sổ. Trong các phép toán khớp nguyên mẫu tương quan, các giá trị tương quan khi tâm của mẫu – template ở gần biên nhìn chung ít có ý nghĩa. Vì thế các thao tác chèn thêm pixel có thể bổ sung thêm một nửa độ rộng của mẫu.

7.3.3. Khớp các đặc trưng của phép biến đổi đặc trưng bất biến theo kích thước (phép biến đổi SIFT – Scale-Invariant Feature Transform)

Như đã trình bày ở trước, phép biến đổi SIFT tính toán một tập các đặc trưng bất biến có thể được sử dụng để khớp giữa ảnh chưa phân loại và các ảnh nguyên mẫu đã gán nhãn trước. SIFT có thể tạo ra các vector đặc trưng tới 128 chiều cho mỗi vùng địa phương trong ảnh. SIFT thực hiện việc khớp mẫu bằng cách tìm kiếm những sự tương ứng giữa các tập các nguyên mẫu vector đặc trưng (đã có) và các vector đặc trưng được tính toán cho một ảnh chưa biết nhãn. Một trong những phương pháp tìm kiếm đơn giản như đã trình bày ở phần trước có thể được sử dụng là bộ phân loại khoảng cách tối thiểu.

Do có số lượng lớn các đặc trưng liên quan, việc tìm kiếm các khớp chính xác rất nặng về tính toán. Thay vào đó, cách tiếp cận thường là sử dụng phương pháp best-bin-first có thể xác định các hàng xóm gần nhất với xác suất cao chỉ với một lượng tính toán giới hạn. Tìm kiếm còn được đơn giản hóa thêm nữa bằng cách tìm kiếm các cụm nghiệm tiềm năng bằng cách sử dụng phép biến đổi Hough tổng quát.

7.3.4. Khớp các nguyên mẫu cấu trúc

Các kỹ thuật phân lớp đã được trình bày đến trước phần này đều làm việc với các mẫu một cách định lượng, và phần lớn bỏ qua các mối liên quan mang tính cấu trúc ở trong hình dạng các đối tượng trong mẫu ảnh. Các phương pháp được trình bày trong phần này nhằm phục vụ mục đích nhận dạng mẫu bằng cách tận dụng chính xác các quan hệ đã bỏ qua ở trên. Chúng ta sẽ tìm hiểu hai cách tiếp cận cơ bản để nhận dạng các hình dạng biên dựa trên biểu diễn sâu chuỗi, là các cách tiếp cận rộng rãi nhất trong nhận dạng mẫu theo cấu trúc.

7.3.4.1. Khớp các số hình dạng – shape number

Một thuật toán có ý tưởng tương tự như bộ phân loại theo khoảng cách tối thiểu trình bày ở phần trước cho các vector mẫu có thể được xây dựng để so sánh các biên vùng mô tả bằng các số hình dạng. Như đã được trình bày trong chương trước, mức độ tương tự, k , giữa hai biên vùng, được định nghĩa là bậc lớn nhất mà số hình dạng của chúng vẫn trùng nhau. Ví dụ, ký hiệu a và b là các số hình dạng của các đường biên đóng biểu diễn bằng mã chuỗi 4 hướng. Hai hình dạng này có mức độ tương tự k nếu

$$\begin{aligned} s_j(a) &= s_j(b) && \text{for } j = 4, 6, 8, \dots, k; \text{ and} \\ s_j(a) &\neq s_j(b) && \text{for } j = k+2, k+4, \dots \end{aligned} \quad (7-11)$$

Trong đó s biểu thị số hình dạng, và ký hiệu dưới j xác định bậc của hình. Khoảng cách giữa hai hình dạng a và b được định nghĩa bằng nghịch đảo của mức độ tương tự của chúng:

$$D(a, b) = \frac{1}{k} \quad (7-12)$$

Biểu thức này thỏa mãn các tính chất :

$$\begin{aligned} D(a, b) &\geq 0 \\ D(a, b) &= 0 \quad \text{if and only if } a = b \\ D(a, c) &\leq \max[D(a, b), D(b, c)] \end{aligned} \quad (7-13)$$

k hoặc D có thể được sử dụng để so sánh hai hình dạng. Nếu sử dụng mức độ tương tự, khi k càng lớn, hai hình dáng càng giống nhau (lưu ý rằng $k = \infty$ cho các hình dáng giống hệt nhau). Ngược lại, khi sử dụng D , các phát biểu sẽ ngược lại với các phát biểu cho k .

7.3.4.2. Khớp chuỗi

Giả sử hai biên vùng, a và b , được mã hóa dưới dạng chuỗi các ký hiệu dạng $a_1a_2\dots a_n$ và $b_1b_2\dots b_n$. Đặt α là số các khớp giữa hai chuỗi, theo đó khớp xảy ra ở vị trí thứ k nếu $a_k = b_k$. Số các ký hiệu còn lại không khớp là:

$$\beta = \max(|a|, |b|) - \alpha \quad (7-14)$$

Trong đó $|arg|$ là độ dài (số các ký hiệu) của chuỗi nằm trong biên arg . Có thể thấy rằng $\beta = 0$ nếu và chỉ nếu a và b là giống hệt nhau.

Một đo đặc hiệu dụng của tính giống hệt nhau giữa 2 chuỗi là tỷ số:

$$R = \frac{\alpha}{\beta} = \frac{\alpha}{\max(|a|, |b|) - \alpha} \quad (7-15)$$

Chúng ta thấy rằng R là vô hạn trong trường hợp hai chuỗi trùng khớp hoàn hảo và bằng 0 khi không có bất kỳ ký hiệu nào khớp nhau trong a và b ($\alpha = 0$ trong trường hợp này). Bởi vì việc khớp ký hiệu được thực hiện theo từng ký hiệu một, vị trí bắt đầu trên mỗi biên là quan trọng để giảm lượng tính toán cần thiết để kiểm tra khớp 2 chuỗi. Bất kỳ phương pháp nào chuẩn hóa hoặc gần chuẩn hóa theo điểm bắt đầu giống nhau đều hữu ích nếu nó có lợi thế tính toán hơn so với phương pháp trùng khớp kiểu vết cạn, bao gồm các phương pháp thực hiện việc kiểm tra khớp 2 chuỗi bắt đầu ở các điểm tùy ý trên mỗi chuỗi, sau đó dịch một trong các chuỗi và tính toán R cho mỗi dịch chuyển. Giá trị lớn nhất của R cho trùng khớp tốt nhất.

7.4. Support-vector machine (SVM)

Support vector machines (SVM) (một số tài liệu dịch là *máy véc tơ tựa*) là kỹ thuật học có giám sát tương đối mới, được đề xuất lần đầu vào năm 1992 và được áp dụng nhiều từ khoảng cuối những năm chín mươi thế kỷ trước. SVM được đề xuất ban đầu cho bài toán phân loại nhị phân, và có thể mở rộng cho phân loại đa lớp tương tự như hồi quy logistic.

Hiện nay, theo nhiều tài liệu, SVM là phương pháp học có giám sát *phổ biến nhất*. Nhiều thư viện hoặc gói phần mềm cho phép sử dụng ngay SVM cho bài toán học có giám sát (phân loại hoặc hồi quy), người sử dụng chỉ cần chọn rất ít tham số để có thể sử dụng các thư viện này. SVM cũng cho độ chính xác cao, thường ở trong nhóm đứng đầu trong số thuật toán phân loại, trong nhiều ứng dụng. Nhìn chung, khi có bài toán học có giám sát, nếu không có thêm thông tin gì đặc biệt thì thuật toán đầu tiên nên thử là SVM.

Nguyên tắc chung

SVM dựa trên hai nguyên tắc chính:

- Thứ nhất, SVM tìm cách phân chia ví dụ có nhãn khác nhau bằng một siêu phẳng sao cho khoảng cách từ siêu phẳng tới những ví dụ có nhãn khác nhau là lớn nhất. Nguyên tắc này được gọi là nguyên tắc *lề cực đại* (max margin). Trong quá trình huấn luyện, thuật toán SVM xác định siêu phẳng có lề cực đại bằng cách giải bài toán tối ưu cho một hàm mục tiêu bậc 2.
- Thứ hai, để giải quyết trường hợp các ví dụ không thể phân chia bằng một siêu phẳng, phương pháp SVM sẽ *ánh xạ không gian ban đầu của các ví dụ sang một không gian khác thường là có số chiều cao hơn*, sau đó tìm siêu phẳng với lề cực đại trong không gian này. Để tăng tính hiệu quả khi ánh xạ, một kỹ thuật được sử dụng là *kỹ thuật dùng hàm nhân* (kernel function) thay cho tích có hướng của các vectơ.

Trong các phần tiếp theo, ta sẽ xem xét cụ thể cách triển khai hai nguyên tắc này.

7.4.1. Phân loại tuyến tính với lề cực đại

7.4.1.1. Bộ phân loại tuyến tính

SVM được phát triển từ mô hình phân loại tuyến tính. Do vậy, trước hết ta sẽ xem xét mô

hình phân loại dạng này. Xét bài toán phân loại hai lớp, trong đó mỗi mẫu được biểu diễn bằng d đặc trưng liên tục (số thực), và có thể nhận nhãn $+1$ (ví dụ dương) hoặc -1 (ví dụ âm). Tương tự các phần trước, giả sử tập dữ liệu huấn luyện gồm n mẫu, trong đó mẫu thứ i được xác định bởi (x_i, y_i) , với x_i là vec tơ các đặc trưng và y_i là nhãn phân loại. Trong ví dụ trên Hình 7.11, vec tơ x có hai chiều, do vậy mỗi mẫu ví dụ được biểu diễn như một điểm trong không gian hai chiều, các điểm đen tương ứng với ví dụ $+1$ và điểm trắng biểu diễn ví dụ -1 . Trong phần tiếp theo, không gian hai chiều sẽ được sử dụng để tiện cho việc minh họa.

Tương tự trường hợp hồi quy tuyến tính, ta sẽ sử dụng hàm phân loại có dạng:

$$f(\mathbf{x}) = \sum_{i=1}^d w_i x_i + b = \mathbf{w}^T \mathbf{x} + b \quad (7-16)$$


Trong đó w là vector trọng số và b là độ chệch. Để hiểu ý nghĩa các đại lượng này, ta xét trường hợp $b = 0$ trước. Khi đó, tập các điểm (hay vector) x sao cho $w^T x = 0$ là một điểm trong không gian một chiều ($d = 1$), đường thẳng trong không gian hai chiều ($d = 2$), mặt phẳng trong không gian ba chiều, và siêu phẳng (hyperplane) trong trường hợp tổng quát. Siêu phẳng này đi qua gốc tọa độ và vuông góc với vec tơ w . Với $b \neq 0$, siêu phẳng này sẽ được đẩy khỏi gốc tọa độ một khoảng bằng $|b|/\|w\|$, trong đó $\|w\|$ là độ dài (chuẩn) của vector w . Siêu phẳng $f(x)$ phân chia không gian thành hai phần, phần bên phải gồm những điểm x có $f(x) > 0$ và phần bên trái gồm những điểm có $f(x) < 0$ (Hình 7.16).

Như vậy, một ví dụ x sẽ có nhãn phân loại y được xác định như sau:

$$y = \text{sgn}(f(x)) \quad (7-17)$$

Trong đó $\text{sgn}()$ là hàm dấu, nhận giá trị $+1$ nếu $f(x) > 0$ và -1 nếu $f(x) < 0$.

Cần lưu ý rằng, trong ví dụ trên Hình 7.11, ta có thể tìm được siêu phẳng $f(x)$ sao cho các ví dụ dương nằm về một phía và ví dụ âm nằm về phía còn lại. Trong trường hợp như vậy, ta nói rằng dữ liệu có thể phân chia tuyến tính. Trường hợp dữ liệu không phân chia tuyến tính, tức là không tồn tại siêu phẳng như vậy, sẽ được đề cập sau.




Hình 7.11 Bộ phân loại tuyến tính.

7.4.1.2. Phân loại tuyến tính với lề cực đại


Có thể nhận thấy, trong trường hợp dữ liệu phân chia tuyến tính, có thể tìm được nhiều siêu

phẳng cho phép phân cách đúng ví dụ dương khỏi ví dụ âm như thể hiện trên Hình 7.12. Vậy nên chọn siêu phẳng nào để làm hàm phân loại? Gọi $m+$ và $m-$ là khoảng cách từ siêu phẳng $f(x)$ tới ví dụ dương và ví dụ âm gần nhất. Các điểm nằm cách đều siêu phẳng các khoảng $m+$ và $m-$ được thể hiện bởi hai đường đứt nét trên Hình 7.13 và tạo ra một vùng ngăn cách các ví dụ khác dấu. Siêu phẳng được chọn nằm giữa vùng phân cách, tức là $m+ = m-$. Độ rộng của vùng phân cách này, tức là $(m+ + m-)$ được gọi là “lề” (“margin”) của siêu phẳng phân cách.

Nguyên tắc lề cực đại: Trong số các siêu phẳng cho phép phân chia ví dụ khác dấu, SVM sử dụng siêu phẳng có lề lớn nhất làm bộ phân loại.



Hình 7.12 Tồn tại nhiều siêu phẳng phân cách ví dụ dương và ví dụ âm.



Hình 7.13 Siêu phẳng phân cách. Các vectơ tựa được khoanh tròn bên ngoài.

Các ví dụ cho phép xác định ranh giới của lề (các điểm được khoanh tròn trên hình vẽ) được gọi là các vectơ tựa (support vector).

Tại sao sử dụng siêu phẳng với lề cực đại? Khi xây dựng bộ phân loại, mục tiêu là giảm tối đa số ví dụ bị phân loại sai, gọi là tổn thất (lost). Trong giai đoạn huấn luyện, ta chỉ có thể tính tổn thất trên dữ liệu huấn luyện, được gọi là tổn thất thực nghiệm (empirical lost). Trong khi đó, mục tiêu là tính tổn thất trên dữ liệu mới, tức là tổn thất thực. Dựa trên một lý thuyết về học máy, siêu phẳng có lề cực đại là siêu phẳng cho tổn thất thực nhỏ nhất trên dữ liệu mới. Về mặt trực giác, siêu phẳng như vậy cũng là siêu phẳng “an toàn” nhất do nó nằm xa vùng các ví dụ dương và âm nên khả năng ví dụ mới rơi vào vùng ngược dấu cũng nhỏ hơn.

7.4.1.3. Xác định siêu phẳng với lề cực đại

Để xác định siêu phẳng với lề cực đại, ta cần tìm w và b tương ứng. Quá trình đó được thực hiện như sau. Trước hết, có thể yêu cầu hàm phân loại cho phép phân chia toàn bộ ví dụ

huấn luyện với một khoảng cách an toàn, chẳng hạn phải thoả mãn:

$$w^T x_i + b \geq +1 \text{ nếu } y_i = +1$$

$$w^T x_i + b \leq -1 \text{ nếu } y_i = -1$$

hay viết gọn lại thành $y_i(w^T x_i + b) - 1 \geq 0$ với mọi i . Điều này có thể thực hiện được, chẳng hạn bằng cách nhân w và b với hệ số phù hợp.

Các điểm x_i sao cho $w^T x_i + b = +1$ nằm trên siêu phẳng song song với siêu phẳng phân cách và cách gốc toạ độ một khoảng $|1 - b|/\|w\|$. Tương tự, các điểm x_i sao cho $w^T x_i + b = -1$ nằm trên siêu phẳng song song với siêu phẳng phân cách và cách gốc toạ độ một khoảng $|-1 - b|/\|w\|$. Khi đó, $m_+ = m_- = 1/\|w\|$, và giá trị của lề sẽ bằng $2/\|w\|$. Để giá trị lề là cực đại, ta cần xác định w sao cho $2/\|w\|$ là lớn nhất, hay $\|w\|/2$ là nhỏ nhất (cực tiểu hoá $\|w\|/2$ thuận lợi hơn do dễ tính đạo hàm hơn). Như vậy, siêu phẳng có lề cực đại được xác định bằng cách tìm w và b sao cho: $1/2\|w\|^2$ là nhỏ nhất, đồng thời thoả mãn ràng buộc: $y_i(w^T x_i + b) - 1 \geq 0$ với mọi i .

7.4.1.4. Phân loại với lề mềm cho dữ liệu không phân chia tuyến tính

Trong trường hợp dữ liệu không thể phân chia tuyến tính, chẳng hạn do một số lý do, ví dụ nhiễu, hay thậm chí trong trường hợp phân chia tuyến tính, vẫn có thể tìm được siêu phẳng với lề rộng nếu chấp nhận phân loại sai một số ví dụ. Việc chấp nhận một số trường hợp sai được thể hiện bằng cách thay các ràng buộc thành: $y_i(w^T x_i + b) \geq 1 - \xi_i$ trong đó $\xi_i \geq 0$ là các biến phụ, được thêm vào để cho phép các ví dụ nằm trong vùng của lề ($1 \geq \xi_i > 0$) hoặc thậm chí bị phân loại sai ($\xi_i \geq 1$). Tổng của các biến phụ này sẽ giới hạn mức độ sai khi phân loại, tổng càng lớn chứng tỏ càng sai nhiều, nếu tất cả biến phụ bằng 0 thì toàn bộ dữ liệu không lẫn vào vùng lề và được phân loại đúng. Do vậy, ta có thể thêm tổng các biến phụ vào hàm mục tiêu như một thành phần phạt cho các trường hợp bị sai. Bài toán tìm cực trị ở trên sẽ trở thành: Tìm w và b sao cho: $1/2\|w\|^2 + C\sum \xi_i$ là nhỏ nhất, đồng thời thoả mãn ràng buộc: $y_i(w^T x_i + b) \geq 1 - \xi_i$, $\xi_i \geq 0$, với mọi i .

Tham số $C > 0$ thể hiện sự ưu tiên giữa hai mục tiêu: 1) tìm được lề lớn; và 2) giảm số lỗi. C càng lớn thì mục tiêu thứ hai càng được ưu tiên và ngược lại. Mô hình phân loại như vậy gọi là phân loại với lề mềm (soft margin).

Bài toán tối ưu trên gồm yêu cầu cực tiểu hoá mục tiêu và các ràng buộc. Bài toán này có thể giải bằng phương pháp nhân tử Lagrange (chi tiết về việc áp dụng phương pháp này không được trình bày ở đây). Sử dụng phương pháp nhân tử Lagrange, ta đưa bài toán về dạng đối ngẫu như sau:

Tìm các tham số α_i sao cho hàm mục tiêu:
$$\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j$$
 đạt giá trị lớn nhất (cực đại hoá), đồng thời thoả mãn các ràng buộc:
$$\sum_{i=1}^n y_i \alpha_i = 0, \quad 0 \leq \alpha_i \leq C$$

Sau khi xác định được α_i , trọng số w được tính như sau:
$$\mathbf{w} = \sum_{i=1}^n y_i \alpha_i \mathbf{x}_i$$
 để tính b , ta có thể

chọn một giá trị i sao cho $\alpha_i > 0$ và tính b theo công thức sau:
$$b = y_i - \mathbf{w}^T \mathbf{x}_i = y_i - \sum_{j=1}^n y_j \alpha_j \mathbf{x}_j^T \mathbf{x}_i$$
 SVM với vector trọng số w và tham số b xác định như trên được gọi là SVM tuyến tính.

Cần lưu ý rằng mỗi ví dụ đều có giá trị tham số α_i tương ứng. Các ví dụ có giá trị $\alpha_i > 0$ nằm trên ranh giới của lề (hoặc bên trong lề nếu sử dụng lề mềm). Các ví dụ này tạo thành các vector tựa (support vector) xác định giới hạn lề. Đây là các ví dụ quan trọng trong dữ liệu

huấn luyện, cho phép xác định siêu phẳng phân cách của SVM và cũng nằm gần siêu phẳng này nhất. Các ví dụ còn lại nằm bên ngoài vùng lề và có thể bỏ đi mà không ảnh hưởng tới vị trí của lề và hàm phân loại. Nói cách khác, các vec tơ tựa chứa toàn bộ thông tin cần thiết từ dữ liệu huấn luyện để xây dựng hàm phân loại cho SVM.


Như vậy, mặc dù hàm phân loại được tạo thành từ các ví dụ huấn luyện, nhưng chỉ những ví dụ tương ứng với $\alpha_i > 0$ mới đóng góp vào hàm phân loại (trọng số w là tổ hợp của các ví dụ này), và số lượng ví dụ như vậy thường không lớn. Đây là một trong những đặc điểm giúp SVM có tính khái quát hoá và khả năng dự toán tốt cho dữ liệu mới.

7.4.2. Kỹ thuật hàm nhân và SVM tổng quát

Bộ phân loại tuyến tính trình bày ở trên cho kết quả tốt trong trường hợp dữ liệu có thể phân chia tuyến tính. Với dữ liệu không phân chia tuyến tính, việc sử dụng hàm phân loại phi tuyến sẽ phù hợp và cho kết quả tốt hơn. Trong phần này, ta sẽ xem xét cách mở rộng SVM tuyến tính cho trường hợp phi tuyến.


Việc sử dụng hàm phân loại tuyến tính cho trường hợp không tuyến tính có thể thực hiện bằng cách ánh xạ không gian dữ liệu ban đầu X sang không gian mới F bằng một hàm ánh xạ phi tuyến $\varphi(x)$. Thông thường không gian F có số chiều lớn hơn số chiều trong không gian dữ liệu ban đầu. Trong không gian mới, hàm phân loại trở thành: $f(x) = w^T \varphi(x) + b$. Ảnh hưởng của việc ánh xạ sang không gian mới được minh hoạ qua một số ví dụ sau.

Ví dụ 1. Để minh hoạ cho việc ánh xạ sang không gian mới, trước tiên ta xét một ví dụ đơn giản như trên Hình 7.14. Dữ liệu ban đầu (bên trái) thuộc không gian 1 chiều, tức là mỗi ví dụ được biểu diễn bởi 1 thuộc tính (x). Các chấm đen tương ứng ví dụ dương, chấm trắng là ví dụ âm. Rõ ràng không thể tìm được một điểm cho phép phân chia các ví dụ khác dấu. Hình bên phải thể hiện việc ánh xạ sang không gian mới với 2 chiều (z_1, z_2) với ($z_1 = x, z_2 = x^2$). Có thể thấy trong không gian mới có thể tìm được đường thẳng cho phép phân cách ví dụ dương khỏi ví dụ âm.



Hình 7.14 Ví dụ ánh xạ từ không gian một chiều sang không gian hai chiều sử dụng ánh xạ $x \rightarrow (z_1, z_2) = (x, x^2)$. Trong không gian hai chiều, dữ liệu có thể phân chia tuyến tính.

Ví dụ 2. Trên Hình 7.15 là ví dụ khác. Từ không gian 2 chiều ban đầu (x_1, x_2) , bằng ánh xạ $(x_1, x_2) \rightarrow (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ ta được không gian mới ba chiều, trong đó các ví dụ dương (dấu nhân) được phân chia tuyến tính khỏi ví dụ âm (chấm trắng) bằng một mặt phẳng. Vector đặc trưng trong không gian mới bao gồm tất cả các tích bậc hai của các đặc trưng trong không gian gốc.



$$\Phi: \mathbb{R}^2 \rightarrow \mathbb{R}^3$$

$$(x_1, x_2) \rightarrow (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

Hình 7.15 Ví dụ một ánh xạ từ không gian hai chiều sang không gian ba chiều. Trong không gian mới, các ví dụ có thể phân chia tuyến tính bởi một mặt phẳng.

7.4.2.1. Ánh xạ bằng cách dùng hàm nhân – kernel function

Các ví dụ trên cho thấy, việc ánh xạ sang không gian mới nhiều chiều hơn làm cho dữ liệu trở thành phân chia tuyến tính. Khó khăn ở chỗ, việc thực hiện các ánh xạ như vậy đòi hỏi tính toán các đặc trưng mới. Số lượng đặc trưng như vậy có thể rất lớn. Chẳng hạn, với phép ánh xạ trong ví dụ 2 ở trên, số đặc trưng mới xấp xỉ bình phương số đặc trưng cũ. Một số phép ánh xạ khác dẫn tới số đặc trưng lớn hơn nữa, thậm chí là vô cùng. Việc tính số lượng đặc trưng mới nhiều như vậy là không thực tế.

Để tránh việc tính toán các đặc trưng trong không gian mới, SVM sử dụng các hàm nhân - kernel function. Cụ thể, do trong không gian mới, vector trọng số của SVM được tính bởi:

$$\mathbf{w} = \sum_{i=1}^n y_i \alpha_i \phi(\mathbf{x}_i) \quad (7-18)$$

Nên hàm phân loại sẽ trở thành:

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i=1}^n y_i \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b \quad (7-19)$$

Hàm mục tiêu cần cực đại hoá cũng trở thành:

$$\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \quad (7-20)$$

Do các biểu thức trên chứa $\phi(x)^T \phi(x')$ nên nếu ta có thể tìm được hàm $K(x, x') = \phi(x)^T \phi(x')$, ta có thể sử dụng $K(x, x')$ trong các biểu thức trên và không cần tính cụ thể các ánh xạ $\phi(x)$, $\phi(x')$. Hàm $K(x, x')$ như vậy được gọi là hàm nhân - kernel function và cách sử dụng hàm nhân như vậy được gọi là kỹ thuật nhân - kernel trick.

Ví dụ. Quay lại ví dụ 2 ở trên với ánh xạ $\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$. Dễ dàng chứng minh được $K(x, x') = \phi(x)^T \phi(x') = (x^T x')^2$ như vậy, thay vì tính $\phi(x)$, ta sẽ dùng $K(x, x') = (x^T x')^2$. Với kỹ thuật sử dụng hàm nhân, ta thu được hàm phân loại của SVM tổng quát có dạng:

$$f(\mathbf{x}) = \sum_{i=1}^n y_i \alpha_i K(\mathbf{x}_i, \mathbf{x}) + b$$

Trong đó các tham số được xác định bằng cách giải bài toán tối ưu sau:

Cực đại hoá hàm mục tiêu: $\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j K(\mathbf{x}_i, \mathbf{x}_j)$, đồng thời thoả mãn các ràng buộc:

$$\sum_{i=1}^n y_i \alpha_i = 0, \quad 0 \leq \alpha_i \leq C$$

, sau đó tính b theo công thức sau:

$$b = y_i - \mathbf{w}^T \mathbf{x}_i = y_i - \sum_{j=1}^n y_j \alpha_j \mathbf{x}_j^T \mathbf{x}_i$$

7.4.2.2. Một số dạng hàm nhân thông dụng

Với mỗi bài toán phù hợp với một dạng hàm nhân cụ thể. Sau đây là một số dạng hàm nhân thường được sử dụng với SVM:

Hàm nhân đa thức: $K(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + 1)^d$.

Trong trường hợp $d = 1$, hàm nhân gọi là hàm tuyến tính (không ánh xạ gì cả) và SVM trở thành SVM tuyến tính. Trong trường hợp nói chung, d là bậc của hàm nhân đa thức.

Hàm nhân Gauss: $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$ trong đó $\|\mathbf{x}\|$ là độ dài của vec tơ $\mathbf{x}$: $\|\mathbf{x}\| = \sqrt{\mathbf{x}^T \mathbf{x}}$; γ là tham số thể hiện độ rộng của nhân.

Hàm nhân sigmoid: $K(\mathbf{x}, \mathbf{x}') = \tanh(\kappa \mathbf{x}^T \mathbf{x}' + \theta)$

Trong trường hợp nói chung, nếu không có thông tin gì về bài toán thì nên thử hàm nhân Gauss. Đây là dạng hàm nhân thông dụng nhất.

7.4.3. Sử dụng SVM trên thực tế

7.4.3.1. Huấn luyện SVM

Huấn luyện SVM là quá trình xác định các tham số α bằng cách giải bài toán tối ưu đã trình bày ở trên. Đây là bài toán tối ưu với hàm mục tiêu bậc hai và có thể giải bằng các phương pháp số. Trên thực tế, một số phương pháp đã được thiết kế để giải bài toán tối ưu này, tất cả đều dựa trên việc chia nhỏ bài toán tối ưu thành các bài toán con. Phương pháp thông dụng nhất là Sequential Minimal Optimization (SMO). Phương pháp này lần lượt cố định các giá trị α và chỉ cho phép hai giá trị thay đổi sau đó tìm giá trị tối ưu của hai tham số. Quá trình này được thực hiện với từng đôi α cho đến khi đạt tới giá trị tối ưu. Chi tiết về thuật toán huấn luyện SMO không được trình bày ở đây.

7.4.3.2. Phân loại đa lớp

Trong trường hợp phân loại với nhiều nhãn, cách thường dùng là kết hợp nhiều SVM nhị phân với nhau. Có hai cách kết hợp các bộ phân loại nhị phân như vậy. Cách thứ nhất được gọi là kết hợp từng đôi (pairwise). Cách thứ hai được gọi là một chọi tất cả (one-vs-all). Chi tiết về hai cách này hoàn toàn giống như trong phần phân loại đa lớp với hồi quy logistic.

7.4.3.3. Lựa chọn tham số

Tham số đầu tiên cần quan tâm khi sử dụng SVM là dạng hàm nhân và tham số C . Với mỗi dạng hàm nhân lại có các tham số riêng của mình như bậc d của hàm nhân đa thức, độ rộng của hàm nhân Gauss hay tham số ngưỡng của nhân sigmoid.

Việc lựa chọn hàm nhân có thể thực hiện nếu biết các đặc điểm của bài toán. Trong trường hợp không có thông tin như vậy, cần thử nghiệm các dạng nhân và tham số khác nhau bằng cách sử dụng thủ tục kiểm tra chéo (cross-validation).

7.4.3.4. Các ưu điểm của SVM

SVM có nhiều ưu điểm:

- Đây là phương pháp có cơ sở lý thuyết tốt dựa trên lý thuyết về khả năng khái quát hóa của bộ phân loại.
- Có thể làm việc tốt với dữ liệu nhiều chiều (nhiều thuộc tính).
- Cho kết quả rất chính xác so với các phương pháp khác trong hầu hết ứng dụng.


7.5. AdaBoost – Adaptive Boosting

Chương này trình bày về thuật toán AdaBoost là thuật toán ứng dụng trong nhiều trong bài toán nhận dạng vì có nhiều ưu điểm là nhanh chóng, đơn giản và dễ dàng cài đặt. Nó không

có các tham số để điều chỉnh và không cần tri thức về bộ học yếu và do đó có thể được linh hoạt kết hợp với phương pháp nào cho việc tìm kiếm bộ phân loại yếu. Với những ưu điểm đó, ta nghiên cứu áp dụng vào việc phát hiện và nhận dạng đối tượng.


7.5.1. Tiếp cận Boosting

Boosting là kỹ thuật dùng để tăng độ chính xác cho các thuật toán học (learning algorithm). Nguyên lý cơ bản của nó là kết hợp các bộ phân loại yếu thành một bộ phân loại mạnh. Trong đó, bộ phân loại yếu là các bộ phát hiện đơn giản chỉ cần có độ chính xác trên 50%. Bằng cách này, chúng ta nói bộ phát hiện đã được “boost”.



Hình 7.16 Minh họa hoạt động theo kỹ thuật boosting.

Xét một bài toán phát hiện 2 lớp (mẫu cần nhận dạng sẽ được phân vào 1 trong 2 lớp) với D là tập huấn luyện gồm có n mẫu. Trước tiên, chúng ta sẽ chọn ngẫu nhiên ra n_1 mẫu từ tập D với $n_1 < n$ để tạo tập D_1 . Sau đó, chúng ta sẽ xây dựng bộ phân loại yếu đầu tiên C_1 từ tập D_1 . Tiếp theo, chúng ta xây dựng tập D_2 để huấn luyện bộ phát hiện C_2 . D_2 sẽ được xây dựng sao cho một nửa số mẫu của nó được phát hiện đúng bởi C_1 và nửa còn lại bị phát hiện sai bởi C_1 . Bằng cách này, D_2 chứa đựng những thông tin bổ sung cho C_1 . Bây giờ chúng ta sẽ xây dựng bộ huấn luyện C_2 từ D_2 . Tiếp theo, chúng ta sẽ xây dựng tập D_3 từ những mẫu không được phát hiện tốt bởi sự kết hợp giữa C_1 và C_2 : những mẫu còn lại trong D mà C_1 và C_2 cho kết quả khác nhau. Như vậy, D_3 sẽ gồm những mẫu mà C_1 và C_2 hoạt động không hiệu quả. Sau cùng, chúng ta sẽ huấn luyện bộ phát hiện C_3 từ D_3 . Bây giờ chúng ta đã có một bộ phân loại mạnh là bộ kết hợp C_1 , C_2 và C_3 . Khi tiến hành nhận dạng một mẫu X , kết quả sẽ được quyết định bởi sự thỏa thuận của 3 bộ C_1 , C_2 và C_3 : Nếu cả C_1 và C_2 đều phân X vào cùng một lớp thì lớp này chính là kết quả phát hiện của X ; ngược lại, nếu C_1 và C_2 phân X vào 2 lớp khác nhau, C_3 sẽ quyết định X thuộc về lớp nào (Hình 7.17).



Hình 7.17 Quy trình Boosting.


7.5.2. Thuật toán AdaBoost

Adaboost (Adaptive Boost) là một dạng tiếp cận boosting và đã giải quyết nhiều thực tế khó khăn của các thuật toán boosting trước đó.

Adaboost là một cải tiến của tiếp cận boosting, Adaboost sử dụng thêm khái niệm trọng số (weight) để đánh dấu các mẫu khó nhận dạng. Trong quá trình huấn luyện, cứ mỗi bộ phân loại yếu được xây dựng, thuật toán sẽ tiến hành cập nhật lại trọng số để chuẩn bị cho việc xây dựng bộ phân loại yếu kế tiếp là: tăng trọng số của các mẫu bị nhận dạng sai và giảm trọng số của các mẫu được nhận dạng đúng bởi bộ phân loại yếu vừa xây dựng. Bằng cách này, các bộ phân loại yếu tiếp theo có thể tập trung vào các mẫu mà các bộ phân loại yếu trước nó chưa làm tốt. Sau cùng, các bộ phân loại yếu sẽ được kết hợp tùy theo mức độ “tốt” của chúng để tạo dựng nên bộ phân loại mạnh.

Có thể hình dung một cách trực quan như sau: để biết một ảnh có phải là bàn tay hay không, ta hỏi T người (tương đương với T bộ phân loại yếu xây dựng từ T vòng lặp của boosting), đánh giá của mỗi người (tương đương với một bộ phân loại yếu) chỉ cần tốt hơn ngẫu nhiên một chút (tỉ lệ sai dưới 50%). Sau đó, ta sẽ đánh trọng số cho đánh giá của từng người (thể hiện qua hệ số α), người nào có khả năng đánh giá tốt các mẫu khó thì mức độ quan trọng của người đó trong kết luận cuối cùng sẽ cao hơn những người chỉ đánh giá tốt được các mẫu dễ. Việc cập nhật lại trọng số của các mẫu sau mỗi vòng boosting chính là để đánh giá độ khó của các mẫu (mẫu càng có nhiều người đánh giá sai là mẫu càng khó).

Thuật toán có đầu vào là một tập huấn luyện $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ trong đó mỗi x_i thuộc về một số tên miền hay không gian X và mỗi nhãn y_i thuộc tập nhãn Y với giả thiết rằng $Y = \{-1, +1\}$. AdaBoost gọi hay thực thi lặp nhiều lần một thuật toán học yếu trong một dãy vòng lặp từ $t = 1, \dots, T$. Một trong những ý tưởng chính của thuật toán là để duy trì một phân phối (chính là một tập trọng số) trên tập huấn luyện. Ban đầu, tất cả các trọng số được thiết lập bằng nhau, nhưng trên mỗi vòng lặp, trọng số của các mẫu được phát hiện không chính xác sẽ được tăng lên để bộ học yếu tập trung vào các mẫu khó trong tập huấn luyện.



Hình 7.18 Bộ phân loại mạnh $H(x)$ xây dựng với AdaBoost, bằng tổ hợp tuyến tính của các bộ phân loại yếu $h_k(x)$ với α_k là trọng số.

Công việc của bộ học yếu là để tìm một bộ phân loại yếu $h_t: X \rightarrow \{-1, +1\}$ tương ứng với phân phối D_t (nhắc lại chính là tập các trọng số; để đảm bảo tính nhất quán qua mỗi vòng lặp t , D_t có dạng phân phối xác suất và được chuẩn hoá với tổng bằng 1 trên tập huấn luyện). Độ tốt của một giả thuyết yếu được đo bằng lỗi của nó:

$$\epsilon_t = \Pr_{i \sim D_t} [h_t(x_i) \neq y_i] = \sum_{i: h_t(x_i) \neq y_i} D_t(i) \quad (7-21)$$

Trong đó:

ϵ_t là sai số của bộ phân loại giả thuyết yếu h_t ;

$\Pr$ là đo đặc xác suất gắn với phân bố D_t ;

$i \sim D_t$ nghĩa là mẫu i tương ứng với phân bố D_t ;

$h_t(x_i) \neq y_i$ kiểm tra liệu bộ phân loại yếu h_t có nhận dạng sai mẫu x_i hay không;

$D_t(i)$ là trọng số gắn với mẫu x_i trong phân bố D_t .

Lưu ý là lỗi được đo đối với phân phối D_t mà trên đó các bộ học yếu được huấn luyện. Trong thực tế, các bộ học yếu có thể là một thuật toán có thể dùng trọng số D_t trên các mẫu huấn luyện. Ngoài ra, khi điều này là không thể, một tập hợp con của các mẫu đang huấn luyện có thể được lấy mẫu theo D_t và các mẫu được đánh lại trọng số có thể được dùng để huấn luyện bộ học yếu.

Thuật toán: AdaBoost

1. Đầu vào: $(x_1, y_1), \dots, (x_m, y_m)$ với $x_i \in X$ và $y_i \in Y = \{-1, +1\}$
2. Khởi tạo: $D_1(i) = 1/m$

3. For $t = 1, \dots, T$

- Huấn luyện bộ học yếu sử dụng phân phối D_t
- Chọn bộ phân loại yếu $h_t: X \rightarrow \{-1, +1\}$ với sai số: $\epsilon_t = \Pr_{i \sim D_t}[h_t(x_i) \neq y_i]$
- Chọn: $\alpha_t = 1/2 \ln[(1 - \epsilon_t) / \epsilon_t]$
- Cập nhật:

$$\begin{aligned} D_{t+1}(i) &= \frac{D_t(i)}{Z_t} \times \begin{cases} e^{-\alpha_t} & \text{if } h_t(x_i) = y_i \\ e^{\alpha_t} & \text{if } h_t(x_i) \neq y_i \end{cases} \\ &= \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} \end{aligned}$$

Trong đó Z_t là hệ số chuẩn hoá được lựa chọn để D_{t+1} thoả mãn là 1 phân phối chuẩn.

Bộ phân loại đầu ra:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right) \quad (7-22)$$

Một khi bộ phân loại yếu h_t đã được thu nhận, AdaBoost sẽ chọn một tham số α_t như trong thuật toán. Dễ dàng thấy α_t đo mức độ quan trọng được gán cho h_t . Chú ý rằng $\alpha_t \geq 0$ nếu $\epsilon_t \leq 1/2$ (chúng ta có thể giả định mà không mất tính tổng quát) và α_t sẽ lớn hơn khi ϵ_t nhỏ đi.

Tiếp theo phân phối D_t được cập nhật sử dụng luật như trình bày trong thuật toán Adaboost ở trên. Tác dụng của luật này là làm tăng trọng số của các mẫu mà h_t phát hiện sai và giảm trọng số của các mẫu phát hiện chính xác. Vì vậy trọng số sẽ có xu hướng tập trung vào các mẫu khó-hard.

Bộ phân loại cuối cùng thu nhận được H là tập hợp theo trọng số của T bộ phân loại yếu trong đó α_t là trọng số được gán cho h_t . Người ta cũng đã chỉ ra cách mở rộng AdaBoost để có thể tạo ra bộ phân loại yếu với giá trị đầu ra thuộc tập số thực hoặc đầu ra là các dự báo với độ tin cậy xác định. Nghĩa là với mỗi x thì h_t sẽ cho ra $h_t(x) \in \mathbb{R}$ mà dấu của nó là nhãn dự báo (-1 hoặc +1) và giá trị của nó $|h_t(x)|$ sẽ đo độ tin cậy của dự đoán.

7.5.3. Sử dụng Adaboost trong thực tế

7.5.3.1. Chọn các đặc trưng


Một loại đặc trưng đơn giản có thể được sử dụng với Adaboost là đặc trưng Haar-like, là một loại đặc trưng thường được dùng cho bài toán nhận dạng trên ảnh. Đặc trưng Haar-like được xây dựng từ các hình chữ nhật có kích thước bằng nhau, dùng để tính độ chênh lệch giữa các giá trị điểm ảnh trong các vùng kề nhau. Trong Hình 7.19 A và B, giá trị của đặc trưng cho bởi 1 ảnh bằng hiệu số giữa tổng các điểm ảnh thuộc 2 vùng hình chữ nhật sáng và tối. Trong hình C thì giá trị đặc trưng bằng tổng các điểm ảnh trong 2 vùng hình chữ nhật bên ngoài trừ cho tổng các điểm ảnh trong hình chữ nhật ở giữa.

Lợi ích của đặc trưng Haar-like là nó diễn đạt được tri thức về các đối tượng trong ảnh (bởi vì nó biểu diễn mối liên hệ giữa các bộ phận của đối tượng), điều mà bản thân từng điểm ảnh không diễn đạt được.

Trong quá trình huấn luyện, số lượng xử lý trên các đặc trưng Haar-like có thể là rất lớn, việc tính tổng các điểm ảnh cho bởi từng đặc trưng làm cho thời gian xử lý tăng đáng kể. Để khắc phục điều này, người ta cũng đã đưa ra một số dạng cải tiến chẳng hạn như Integral Image để tính toán nhanh cho các đặc trưng cơ bản. Chi tiết về Integral Image có thể được tham khảo thêm trong các tài liệu liên quan đến chủ đề này.

7.5.3.2. Mô hình cascade


Ví dụ đặc trưng Haar-like:



Hình 7.19 Đặc trưng Haar-like cơ bản được sử dụng với thuật toán Adaboost.

Một hệ thống phát hiện tốt thường tốn rất nhiều thời gian để cho ra kết quả phát hiện bởi vì nó phải xét rất nhiều đặc trưng của mẫu. Tuy nhiên, trong các mẫu đưa vào, không phải mẫu nào cũng thuộc loại khó nhận dạng. Có những mẫu background rất dễ nhận ra (ta gọi đây là những mẫu background đơn giản). Đối với những mẫu này, ta chỉ cần xét một hay vài đặc trưng đơn giản là có thể nhận diện được chứ không cần xét tất cả các đặc trưng. Nhưng đối với các bộ phát hiện thông thường thì cho dù mẫu cần nhận dạng là dễ hay khó thì nó vẫn sẽ xét tất cả các đặc trưng mà nó rút ra được trong quá trình học. Do đó, chúng tốn thời gian xử lý một cách không cần thiết.

Mô hình cascade được xây dựng với mục đích chính là nhằm rút ngắn thời gian xử lý, giảm thiểu tỷ lệ nhận dạng sai của bộ nhận dạng. Mô hình cascade phân tầng theo dạng hình cây, mỗi cây gồm nhiều tầng, mỗi tầng của cây sẽ là một bộ phân loại. Một mẫu để được phát hiện là đối tượng thì nó cần phải đi qua hết tất cả các tầng của cây, các bộ phân loại ở tầng sau được huấn luyện bằng những mẫu negative mà bộ phân loại trước nó nhận dạng sai, tức là nó sẽ tập trung học từ các mẫu background khó hơn, do đó sự kết hợp các bộ phân loại này lại sẽ giúp bộ phát hiện có false alarm thấp. Với cấu trúc này, những mẫu background dễ nhận diện sẽ bị loại ngay từ những tầng đầu tiên, giúp đáp ứng tốt nhất đối với độ phức tạp gia tăng của các mẫu đưa vào, đồng thời giúp rút ngắn thời gian xử lý.



Hình 7.20 Mô hình cascade áp dụng cho phân loại ảnh với thuật toán Adaboost.

7.6. Bộ phân loại thống kê tối ưu Bayes

Trong phần này, chúng ta trình bày cách tiếp cận xác suất đối với việc phân loại mẫu. Như trong hầu hết các lĩnh vực liên quan đến đo đạc và diễn dịch các sự kiện vật lý, nghiên cứu xác suất cũng quan trọng trong nhận dạng mẫu do tính ngẫu nhiên trong quá trình sinh thông thường các lớp mẫu. Như trình bày trong phần tiếp theo, có thể thu nhận được một phương pháp phân loại mẫu tối ưu theo nghĩa, về mặt trung bình, nó tạo ra xác suất thấp nhất phân

loại sai.

7.6.1. Xây dựng bộ phân loại Bayes

Xác suất mà 1 vector mẫu x xuất hiện trong lớp mẫu c_i được ký hiệu là $p(c_i/x)$. Nếu bộ phân loại mẫu quyết định xếp x vào lớp c_j khi mà x thực sự thuộc về lớp c_i , nó sẽ sinh ra một tổn thất – loss được ký hiệu là L_{ij} . Vì mẫu x có thể thuộc về bất kỳ lớp N_c nào đó, mất mát trung bình xảy ra khi gán x vào lớp c_j (thay vì vào đúng lớp c_i) là:

$$r_j(x) = \sum_{k=1}^{N_c} L_{kj} p(c_k/x) \quad (7-23)$$

Đại lượng $r_j(x)$ được gọi là rủi ro trung bình có điều kiện (conditional average risk) hoặc gọi là tổn thất trong thuật ngữ lý thuyết quyết định.

Theo luật Bayes chúng ta có $p(a/b) = [p(a)p(b/a)]/p(b)$, vì thế chúng ta có thể viết lại phương trình (7-23) như sau:

$$r_j(x) = \frac{1}{p(x)} \sum_{k=1}^{N_c} L_{kj} p(x/c_k) P(c_k) \quad (7-24)$$

Trong đó $p(x/c_k)$ là hàm mật độ xác suất của các mẫu từ lớp c_k , và $P(c_k)$ là xác suất xuất hiện của lớp c_k (đôi khi $P(c_k)$ được gọi là xác suất tiên đoán, hay đơn giản còn được gọi là xác suất tiên nghiệm). Do $1/p(x)$ là dương và giống nhau cho tất cả các $r_j(x)$, $j = 1, 2, \dots, N_c$. Thành phần này có thể được bỏ qua trong phương trình (7-24) khi xem xét độ lớn của $r_j(x)$ từ bé nhất đến lớn nhất. Biểu thức hàm tổn thất trung bình khi đó được viết như sau:

$$r_j(x) = \sum_{k=1}^{N_c} L_{kj} p(x/c_k) P(c_k) \quad (7-25)$$

Cho trước một mẫu chưa phân lớp, bộ phân lớp có N_c lớp khả dĩ để lựa chọn phân lớp cho mẫu. Nếu bộ phân lớp tính toán $r_1(x), r_2(x), \dots, r_{N_c}(x)$ cho mỗi mẫu x và gán mẫu vào lớp với tổn thất thấp nhất, tổn thất trung bình tổng cộng theo tất cả các quyết định sẽ là bé nhất. Bộ phân loại làm cực tiểu tổn thất trung bình tổng được gọi là bộ phân loại Bayes. Bộ phân loại này gán một mẫu chưa biết x vào lớp c_i nếu $r_i(x) < r_j(x)$ với mọi $j = 1, 2, \dots, N_c; j \neq i$. Nói cách khác, x được gán vào lớp c_i nếu:

$$\sum_{k=1}^{N_c} L_{ki} p(x/c_k) P(c_k) < \sum_{q=1}^{N_c} L_{qj} p(x/c_q) P(c_q) \quad (7-26)$$

Cho mọi $j: j \neq i$. Tổn thất đối với một quyết định chính xác thường được quy định là 0, và tổn thất cho bất kỳ quyết định sai nào được gán một giá trị 1. Khi đó hàm mất mát trở thành:

$$L_{ij} = 1 - \delta_{ij} \quad (7-27)$$

Trong đó $\delta_{ij} = 1$ nếu $i = j$, và $\delta_{ij} = 0$ nếu $i \neq j$. Phương trình (7-27) chỉ ra rằng tổn thất 1 cho các quyết định sai và tổn thất 0 cho các quyết định đúng. Thay (7-27) vào (7-25) chúng ta có:

$$\begin{aligned} r_j(x) &= \sum_{k=1}^{N_c} (1 - \delta_{kj}) p(x/c_k) P(c_k) \\ &= p(x) - p(x/c_j) P(c_j) \end{aligned} \quad (7-28)$$

Bộ phân loại Bayes sau đó gán mẫu x vào lớp c_i nếu với mọi $j: j \neq i$:

$$p(x) - p(x/c_i) P(c_i) < p(x) - p(x/c_j) P(c_j) \quad (7-29)$$

Tương đương với nếu:

$$p(\mathbf{x}/c_i)P(c_i) > p(\mathbf{x}/c_j)P(c_j) \quad j = 1, 2, \dots, N_c; j \neq i \quad (7-30)$$

Như vậy, bộ phân loại Bayes với hàm tổn thất 0-1 tính toán các hàm quyết có dạng:

$$d_j(\mathbf{x}) = p(\mathbf{x}/c_j)P(c_j) \quad j = 1, 2, \dots, N_c \quad (7-31)$$

Và gán một mẫu vào lớp c_i nếu $d_i(\mathbf{x}) > d_j(\mathbf{x})$ với mọi $j \neq i$. Quá trình này hoàn toàn giống với quá trình đã được trình bày trong phương trình (7-5), chỉ khác là ở đây chúng ta làm việc với các hàm ra quyết định mà đã được chứng minh là tối ưu theo nghĩa chúng làm cực tiểu hóa tổn thất trung bình cho các nhận dạng sai.


Để tính tối ưu của các hàm quyết định Bayes được đảm bảo, các hàm mật độ xác suất của các mẫu trong mỗi lớp, cùng với xác suất xuất hiện của mỗi lớp, phải được xác định. Điều kiện thứ 2 thường dễ dàng có được. Ví dụ nếu sự xuất hiện của tất cả các lớp có mức độ chắc chắn ngang nhau, khi đó $P(c_j) = 1/N_c$. Thậm chí nếu điều kiện này không đúng, các xác suất đó thường có thể được suy luận từ thông tin của bài toán. Việc ước lượng hàm mật độ xác suất $p(\mathbf{x}/c_j)$ là khó hơn nhiều. Nếu các vector mẫu là n chiều, khi đó $p(\mathbf{x}/c_j)$ là một hàm n biến. Nếu dạng của $p(\mathbf{x}/c_j)$ là chưa biết, việc ước lượng nó đòi hỏi việc sử dụng các phương pháp ước lượng nhiều chiều. Các phương pháp đó khó áp dụng trong thực tế, đặc biệt là nếu số các mẫu đại diện từ mỗi lớp là không lớn, hoặc nếu các hàm mật độ xác suất là bất thường. Vì những lý do đó, các ứng dụng của bộ phân loại Bayes thường được dựa trên việc giả thiết một biểu thức giải tích cho các hàm mật độ xác suất. Điều này đơn giản hóa bài toán ban đầu thành bài toán sau: sử dụng các mẫu huấn luyện (đã gán nhãn hay đã phân lớp), tính toán các tham số cần thiết từ các mẫu chọn thí điểm – sample pattern từ mỗi lớp. Hiện nay dạng phổ biến nhất thường được giả thiết cho phân bố $p(\mathbf{x}/c_j)$ là hàm mật độ xác suất Gauss. Giả thiết này càng gần với dữ liệu thực tế thì bộ lọc Bayes càng sát với tổn thất trung bình tối thiểu trong quá trình nhận dạng.

7.6.2. Bộ phân loại Bayes cho các lớp mẫu Gauss

Chúng ta bắt đầu bằng việc xem xét bài toán một chiều ($n = 1$) liên quan đến hai lớp mẫu ($N_c = 2$) giả thiết là tuân theo phân bố xác suất Gauss, với các giá trị trung bình m_1 và m_2 , và các độ lệch chuẩn σ_1 và σ_2 . Từ phương trình (7-31), các hàm quyết định Bayes có dạng:

$$\begin{aligned} d_j(x) &= p(x/c_j)P(c_j) \\ &= \frac{1}{\sqrt{2\pi}\sigma_j} e^{-\frac{(x-m_j)^2}{2\sigma_j^2}} P(c_j) \quad j = 1, 2 \end{aligned} \quad (7-32)$$

Trong đó các mẫu bây giờ là các vô hướng ký hiệu bởi x . Hình 7.21 trình bày đồ thị của các hàm mật độ xác suất của 2 lớp. Biên giữa 2 lớp là một điểm đơn x_0 , thỏa mãn $d_1(x_0) = d_2(x_0)$. Nếu khả năng xảy ra của hai lớp là như nhau, khi đó $P(c_1) = P(c_2) = 1/2$, và biên ra quyết định chính là giá trị của x_0 mà $p(x_0/c_1) = p(x_0/c_2)$. Điểm này là điểm giao cắt của 2 hàm mật độ xác suất như trong Hình 7.21. Bất kỳ mẫu (ở đây chỉ đơn giản là 1 điểm) nào nằm bên phải của x_0 sẽ được phân loại là thuộc lớp c_1 . Tương tự như vậy, bất kỳ mẫu nào về bên trái của x_0 sẽ được phân loại thuộc về lớp c_2 . Khi khả năng xảy ra của các lớp là không đều nhau, x_0 dịch chuyển về bên trái nếu lớp c_1 là chắc chắn xảy ra cao hơn và ngược lại nó dịch chuyển về bên phải nếu khả năng xảy ra lớp c_2 là cao hơn. Kết quả này là trong dự đoán vì bộ phân loại cố gắng làm tối thiểu hóa tổn thất do phân loại sai. Ví dụ, trong một tình huống cực trị, nếu c_2 không bao giờ xảy ra, bộ phân loại sẽ cố không bao giờ mắc lỗi bằng cách luôn luôn gán tất cả các mẫu vào lớp c_1 (chính là, x_0 sẽ dịch về phía $-\infty$).



Hình 7.21 Các hàm mật độ xác suất cho các lớp mẫu 1-D. Điểm x_0 (tại vị trí giao cắt của 2 đồ thị) là biên ra quyết định Bayes nếu khả năng xảy ra của 2 lớp là đều nhau).

Trong trường hợp n chiều, hàm mật độ xác suất Gauss của các vector trong lớp mẫu thứ j có dạng:

$$p(\mathbf{x}/c_j) = \frac{1}{(2\pi)^{n/2} |\mathbf{C}_j|^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\mathbf{m}_j)^T \mathbf{C}_j^{-1}(\mathbf{x}-\mathbf{m}_j)} \quad (7-33)$$

Trong đó mỗi hàm mật độ xác suất sẽ được hoàn toàn xác định bởi vector trung bình $\mathbf{m}_j$ và ma trận hiệp phương sai $\mathbf{C}_j$, được định nghĩa như sau:

$$\mathbf{m}_j = E_j\{\mathbf{x}\} \quad (7-34)$$

và

$$\mathbf{C}_j = E_j\{(\mathbf{x} - \mathbf{m}_j)(\mathbf{x} - \mathbf{m}_j)^T\} \quad (7-35)$$

Trong đó $E_j\{\cdot\}$ là giá trị kỳ vọng của đối số (ở đây là ký hiệu là $\cdot$) trên các mẫu của lớp c_j . Trong phương trình (7-33), n là số chiều của các vector mẫu, và $|\mathbf{C}_j|$ là định thức của ma trận $\mathbf{C}_j$. Việc xấp xỉ giá trị kỳ vọng E_j bởi trung bình của mẫu chọn cho ta một ước lượng của vector trung bình và ma trận hiệp phương sai:

$$\mathbf{m}_j = \frac{1}{n_j} \sum_{\mathbf{x} \in c_j} \mathbf{x} \quad (7-36)$$

Và

$$\mathbf{C}_j = \frac{1}{n_j} \sum_{\mathbf{x} \in c_j} \mathbf{x}\mathbf{x}^T - \mathbf{m}_j\mathbf{m}_j^T \quad (7-37)$$

Trong đó n_j là số các vector mẫu chọn – sample pattern vectors từ lớp c_j và phép tổng được lấy trên các vector đó. Chúng ta sẽ đưa ra một ví dụ ở cuối phần này về việc làm thế nào để sử dụng hai biểu thức (7-36) và (7-37).

Ma trận hiệp phương sai là đối xứng và xác định dương. Phần tử thứ k trên đường chéo của nó là phương sai của phần tử thứ k của các vector mẫu. Phần tử thứ k ngoài đường chéo là hiệp phương sai của các phần tử x_k và x_j trong các vector đó. Hàm mật độ xác suất Gauss đa biến suy biến thành tích của mật độ xác suất Gauss đơn biến của mỗi phần tử x khi các phần tử ngoài đường chéo của ma trận hiệp phương sai là bằng 0, điều xảy ra khi các phần tử

vector x_k và x_j là không tương quan.

Từ phương trình (7-31), hàm quyết định Bayes cho lớp c_j là $d_j(x) = p(x/c_j)P(c_j)$. Tuy nhiên dạng hàm mũ của hàm mật độ Gauss cho phép chúng ta làm việc với logarithm tự nhiên của hàm quyết định này một cách thuận tiện hơn. Nói cách các chúng ta có thể sử dụng dạng:

$$\begin{aligned} d_j(\mathbf{x}) &= \ln[p(\mathbf{x}/c_j)P(c_j)] \\ &= \ln p(\mathbf{x}/c_j) + \ln P(c_j) \end{aligned} \quad (7-38)$$

Biểu thức này tương đương với phương trình (7-31) theo hiệu năng phân loại bởi vì logarithm là hàm đơn điệu tăng. Nghĩa là bậc số - numerical order của các hàm quyết định trong các phương trình (7-31) và (7-38) là giống nhau. Thay (7-33) vào (7-38) ta thu được:

$$d_j(\mathbf{x}) = \ln P(c_j) - \frac{n}{2} \ln 2\pi - \frac{1}{2} \ln |\mathbf{C}_j| - \frac{1}{2} [(\mathbf{x} - \mathbf{m}_j)^T \mathbf{C}_j^{-1} (\mathbf{x} - \mathbf{m}_j)] \quad (7-39)$$

Lưu ý trong phương trình này số hạng cuối cùng bên phải được gọi là khoảng cách Mahalanobis - Mahalanobis distance, là một phép đo khoảng cách hữu ích trong phân ngưỡng đa biến.

Số hạng $(n/2) \ln 2\pi$ là giống nhau cho tất cả các lớp, vì thế nó có thể được loại bỏ khỏi phương trình (7-39) và ta có:

$$d_j(\mathbf{x}) = \ln P(c_j) - \frac{1}{2} \ln |\mathbf{C}_j| - \frac{1}{2} [(\mathbf{x} - \mathbf{m}_j)^T \mathbf{C}_j^{-1} (\mathbf{x} - \mathbf{m}_j)] \quad (7-40)$$

Với $j = 1, 2, \dots, N_c$. Phương trình này cho các hàm quyết định Bayes với các lớp mẫu Gauss dưới điều kiện hàm tổn thất 0-1.

Các hàm quyết định trong phương trình (7-40) là các siêu bậc 2 (các hàm bậc 2 trong không gian n chiều), bởi vì không có số hạng nào cao hơn bậc 2 trong các thành phần của $\mathbf{x}$ xuất hiện trong phương trình. Rõ ràng khi đó, việc tốt nhất mà một bộ phân loại Bayes với các mẫu Gauss có thể thực hiện là đặt một hàm quyết định bậc 2 giữa mỗi cặp 2 lớp mẫu. Nếu quần thể mẫu là Gauss thực sự, không có một biên nào khác có thể tạo ra một tổn thất trung bình thấp hơn trong phân loại so với bộ phân loại Bayes.

Nếu tất cả các ma trận hiệp phương sai là bằng nhau, khi đó $\mathbf{C}_j = \mathbf{C}$ với $j = 1, 2, \dots, N_c$. Bằng cách khai triển phương trình (7-40) và bỏ qua các số hạng không phụ thuộc vào j , ta nhận được:

$$d_j(\mathbf{x}) = \ln P(c_j) + \mathbf{x}^T \mathbf{C}^{-1} \mathbf{m}_j - \frac{1}{2} \mathbf{m}_j^T \mathbf{C}^{-1} \mathbf{m}_j \quad (7-41)$$

là các hàm quyết định tuyến tính (các siêu phẳng) với $j = 1, 2, \dots, N_c$.

Ngoài ra nếu $\mathbf{C} = \mathbf{I}$ (ma trận đơn vị) và nếu các lớp có xác suất xuất hiện chắc chắn như nhau (hay $P(c_j) = 1/N_c$ cho mọi j), khi đó ta có thể bỏ qua số hạng $\ln P(c_j)$ vì nó là giống nhau với mọi j . Phương trình (7-41) sẽ trở thành:


$$d_j(\mathbf{x}) = \mathbf{m}_j^T \mathbf{x} - \frac{1}{2} \mathbf{m}_j^T \mathbf{m}_j \quad j = 1, 2, \dots, N_c \quad (7-42)$$

Chính là các hàm quyết định của bộ phân lớp khoảng cách tối thiểu (xem phương trình (7-4)). Do vậy, như đã nói ở phần trước, bộ phân loại khoảng cách tối thiểu là tối ưu theo nghĩa Bayes nếu (1) các lớp mẫu tuân theo luật phân phối Gauss, (2) tất cả các ma trận hiệp phương sai là bằng nhau và bằng ma trận đơn vị, và (3) tất cả các lớp là có xác suất xuất hiện như nhau. Các lớp mẫu Gauss thỏa mãn các điều kiện đó là các đám mây hình cầu có dạng giống nhau trong không gian n chiều (gọi là các siêu cầu). Bộ phân loại khoảng cách tối thiểu thiết lập một siêu phẳng giữa mỗi cặp lớp, với tính chất là siêu phẳng là vuông góc với đường nối

tâm của 2 siêu cầu. Trong trường hợp 2-D, các mẫu được phân bố trong các miền tròn, và các biên trở thành các đường thẳng vuông góc với đường nối tâm của các cặp hình tròn.

7.6.3. Áp dụng mô hình phân loại Bayes trong thực tế

Chúng ta minh họa cơ chế của bộ phân loại Bayes sử dụng các mẫu đơn giản trong Hình 7.22 dưới đây.



Hình 7.22 Hai lớp mẫu đơn giản và phần biên quyết định Bayes cho 2 mẫu (phần tô màu giao cắt với khối lập phương)

Chúng ta giả thiết rằng các mẫu thuộc 2 phân bố Gauss, và các lớp là có xác suất xuất hiện như nhau. Sử dụng phương trình (7-36) và (7-37) cho ta:

$$\mathbf{m}_1 = \frac{1}{3} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{m}_2 = \frac{1}{3} \begin{bmatrix} 1 \\ 3 \\ 3 \end{bmatrix}, \quad \mathbf{C}_1 = \mathbf{C}_2 = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}, \quad \text{and} \quad \mathbf{C}_1^{-1} = \mathbf{C}_2^{-1} = \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix}$$

Tiếp theo chúng ta thu nhận các hàm ra quyết định. Có thể áp dụng phương trình (7-41) vì các ma trận hiệp phương sai là bằng nhau và chúng ta đã giả thiết các lớp có xác suất xuất hiện như nhau. Từ đó ta có:

$$d_j(\mathbf{x}) = \mathbf{x}^T \mathbf{C}^{-1} \mathbf{m}_j - \frac{1}{2} \mathbf{m}_j^T \mathbf{C}^{-1} \mathbf{m}_j$$

Thực hiện khai triển ma trận – vector ta thu được 2 hai hàm ra quyết định như sau:

$$d_1(\mathbf{x}) = 4x_1 - 1.5 \quad \text{và} \quad d_2(\mathbf{x}) = -4x_1 + 8x_2 + 8x_3 - 5.5$$

Biên ra quyết định phân tách 2 lớp được xác định bởi:

$$d_1(\mathbf{x}) - d_2(\mathbf{x}) = 8x_1 - 8x_2 - 8x_3 + 4 = 0$$

7.7. Các mạng nơ-ron - neural networks và học sâu - deep learning

Các mục tiêu chính của nội dung trong phần này và trong phần tiếp theo về các mạng tích chập học sâu là giới thiệu về mạng nơ-ron sâu và thu nhận các phương trình là cơ sở của học sâu. Chúng ta sẽ thảo luận về hai loại mạng. Trong phần này, chúng ta tập trung vào mạng nơ-ron đa tầng, kết nối đầy đủ, với đầu vào là các vector mẫu theo định dạng được giới thiệu trong phần trước. Trong tiếp theo, chúng ta sẽ thảo luận về mạng nơ-ron tích chập, có khả năng chấp nhận hình ảnh làm đầu vào. Chúng ta theo cùng một cách tiếp cận cơ bản khi trình bày nội dung trong hai phần này. Nghĩa là, chúng ta sẽ bắt đầu bằng cách phát triển các phương trình mô tả cách đầu vào – input được ánh xạ hay xử lý qua các mạng để tạo ra các đầu ra – output mà dựa vào đó đầu vào sẽ được phân loại. Sau đó, chúng ta thu nhận các

phương trình của quá trình lan truyền ngược, đó là các công cụ được sử dụng để huấn luyện cả hai loại mạng. Chúng ta đưa ra các ví dụ trong cả hai phần để minh họa khả năng của mạng nơ-ron sâu và học sâu trong việc giải quyết các vấn đề phân loại mẫu phức tạp.

7.7.1. Giới thiệu

Phần tiếp theo nghiên cứu các mô hình với các phần tử tính toán phi tuyến cơ bản (gọi là neuron nhân tạo). Các nơtron được tổ chức, liên kết với nhau tạo thành một mạng tính toán. Sự tương tác giữa các neuron tương đồng về một số mặt với tế bào thị giác của động vật. Các mô hình được tạo ra được gọi theo nhiều tên khác nhau như mạng neural, máy tính neuron, mô hình xử lý phân tán song song, hệ thống neuronmorphic, mạng tự điều chỉnh phân tầng, và mô hình điểm kết nối. Ở đây, chúng ta sử dụng tên các mạng neuron, hoặc để ngắn gọn là neural nets. Chúng ta sử dụng những mạng này như phương tiện để học tự điều chỉnh các tham số của các hàm quyết định thông qua việc dùng liên tiếp các mẫu huấn luyện.

Sự quan tâm đến mạng neural bắt đầu từ đầu những năm 1940. Ban đầu người ta đề xuất mô hình neuron có dạng là công cụ phân ngưỡng nhị phân cùng với các thuật toán ngẫu nhiên liên quan đến sự thay đổi đột ngột giữa các trạng thái 0-1 và 1-0, là cơ sở cho việc mô hình hoá hệ thống thần kinh. Bước tiếp theo, người ta đã phát triển các mô hình toán học cho việc học tăng cường hoặc học liên kết.

Trong giai đoạn giữa những năm 1950 và đầu những năm 1960, một loại máy học gọi là perceptrons đã được phát triển với đầy đủ chứng minh toán học cho thấy rằng perceptrons, khi được huấn luyện với các tập dữ liệu huấn luyện có thể tách biệt tuyến tính (tức là các tập dữ liệu có thể tách biệt bằng một siêu phẳng), và quá trình sẽ hội tụ đến nghiệm sau một số hữu hạn các bước lặp. Nghiệm đó có dạng các tham số (các hệ số) của các siêu phẳng có khả năng phân tách đúng các lớp thể hiện bởi các mẫu trong tập huấn luyện.

Tuy nhiên những phát triển tiếp theo không có đột phá. Perceptron cơ bản, và một số bổ sung của nó, là không đủ cho hầu hết các tác nhiệm nhận dạng mẫu có ý nghĩa ứng dụng thực tế. Các cố gắng sau đó mở rộng khả năng của các công cụ giống perceptron bằng cách sử dụng nhiều tầng nhưng lại thiếu các thuật toán huấn luyện hiệu quả. Tuy nhiên thực trạng đó đã thay đổi hoàn toàn khi người ta phát minh ra các thuật toán huấn luyện mới cho các thiết kế đa tầng của các phần tử kiểu perceptron. Phương pháp cơ bản của phát minh gọi là lan truyền ngược - backpropagation (hay ngắn gọn là backprop). Nó cho một phương pháp huấn luyện hiệu quả cho các mạng đa tầng. Tuy thuật toán huấn luyện kiểu này không thể được chứng minh là hội tụ đến nghiệm theo nghĩa của chứng minh cho perceptron một tầng đơn, lan truyền ngược backpropagation lại có khả năng cho các kết quả đã tạo tính cách mạng trong, đến một mức nào đó, tất cả các lĩnh vực nhận dạng mẫu.

Các cách tiếp cận bài toán nhận dạng mẫu chúng ta đã nghiên cứu cho đến trước phần này đều dựa vào các kỹ thuật được thiết kế bởi con người để chuyển đổi dữ liệu thô thành định dạng phù hợp cho xử lý máy tính. Các phương pháp trích xuất đặc trưng mà chúng ta nghiên cứu trong chương trước là ví dụ cho điều này. Khác với những cách tiếp cận trên, mạng neural có thể sử dụng lan truyền ngược để tự động học các biểu diễn phù hợp cho việc nhận dạng, bắt đầu từ dữ liệu thô. Mỗi tầng trong mạng "tinh chỉnh" biểu diễn dữ liệu thành các cấp độ trừu tượng hơn. Kiểu học nhiều tầng này thường được gọi là học sâu – deep learning, và đây là một trong những lý do cơ bản cho việc tại sao ứng dụng của mạng neural đã có thể thành công đến vậy. Như chúng ta đã lưu ý ở đầu phần này, các triển khai thực tế của học sâu thường liên quan đến các tập dữ liệu lớn.

Tất nhiên, đó không phải là các hệ thống tự thiết lập "ảo thuật". Can thiệp của con người vẫn cần thiết cho việc chỉ định các tham số như số tầng, số neuron nhân tạo mỗi tầng, và các hệ số phụ thuộc bài toán. Việc dạy nhận dạng chuẩn cho một mạng neural nhiều tầng phức tạp như vậy bên cạnh ý nghĩa khoa học thì còn là cả một nghệ thuật đòi hỏi kiến thức và thử

nghiệm đáng kể của người thiết kế. Nhiều ứng dụng của nhận dạng mẫu, đặc biệt là trong môi trường hạn chế, thường được xử lý tốt hơn bằng các phương pháp "truyền thống". Một ví dụ tốt về điều này là bài toán nhận diện font chữ đã được định kiểu rõ ràng. Việc phát triển một mạng neural để nhận diện kiểu font chữ đã định dạng E-13B mà chúng ta nghiên cứu trong chương trước là không có ý nghĩa. Một bộ phân loại khoảng cách tối thiểu thực hiện trên một kiến trúc có sẵn là giải pháp lý tưởng cho vấn đề này, miễn là quan tâm chỉ giới hạn trong việc đọc font E-13B in trên séc ngân hàng. Ngược lại, mạng neural đã chứng minh là giải pháp lý tưởng nếu phạm vi ứng dụng được mở rộng để yêu cầu tất cả các văn bản liên quan được viết trên séc, bao gồm cả chữ viết nối liền tục, được đọc với độ chính xác cao.

Học sâu đã tỏ ra hiệu quả trong các ứng dụng khác nhau mà các phương pháp khác không thể giải quyết. Trong hai thập kỷ sau sự xuất hiện của phương pháp tính toán lan truyền ngược, mạng neural đã được sử dụng thành công trong một loạt các ứng dụng. Một số, như nhận dạng giọng nói, đã trở thành một phần không thể thiếu của cuộc sống hàng ngày (trong các thiết bị điều khiển bằng giọng nói...). Khi chúng ta nói vào một điện thoại thông minh, việc nhận dạng (đúng từ, chữ v.v.) gần như hoàn hảo được thực hiện bởi một mạng neural. Đây là bước đột phá mới đạt được vài năm trở lại đây. Các ứng dụng có ích khác mà chúng ta ít để ý là bộ lọc thông minh học theo sở thích của người dùng để chuyển hướng thư rác và thư tập vào tài khoản email, các hệ thống đọc mã zip trên thư chuyển phát. Ngày càng nhiều chúng ta càng thường xuyên thấy các đoạn video truyền hình về các phương tiện tự định hình đường đi một cách tự động và các robot có khả năng tương tác với môi trường xung quanh. Hầu hết đều là các kết quả được dựa trên mạng neural. Các ứng dụng ít quen thuộc khác bao gồm việc tự động chế các loại thuốc mới, dự đoán đột biến gen trong nghiên cứu DNA và các tiến bộ trong hiểu ngôn ngữ tự nhiên.


Mặc dù hiện nay đã có rất nhiều các ứng dụng thực tế của các mạng neural, việc sử dụng công nghệ này trong phân loại hình ảnh có phần chậm hơn. Như sẽ được trình bày trong các phần tiếp theo, việc sử dụng mạng neural trong xử lý hình ảnh chủ yếu dựa trên kiến trúc mạng neural gọi là mạng neural tích chập (được ký hiệu là CNNs hoặc ConvNets). Một trong những ứng dụng sớm nhất và có nhiều ảnh hưởng của CNNs xuất hiện vào đầu những năm 1990 trong bài toán đọc các mã zip viết tay. Tiếp sau đó một số ứng dụng khác của các mạng CNN lần lượt xuất hiện. Tuy nhiên phải đến Cuộc thi ImageNet 2012 thì CNNs mới trở nên phổ biến trong việc nhận dạng mẫu ảnh. Hiện nay, đây là phương pháp được lựa chọn để giải quyết các bài toán nhận dạng ảnh phức tạp.

Tài liệu liên quan đến mạng neural hiện nay rất lớn và gia tăng nhanh chóng. Do vậy cũng như các phần trước, cách tiếp cận của chúng ta là tập trung vào các vấn đề cơ bản. Trong phần này và các phần tiếp theo, chúng ta sẽ thiết lập nền tảng về cách các mạng neural được huấn luyện và cách chúng hoạt động sau khi được huấn luyện. Chúng ta sẽ bắt đầu với các sơ lược về perceptrons. Mặc dù các phần tử tính toán này không được sử dụng trực tiếp trong các kiến trúc mạng neural hiện tại, các phép toán chúng thực hiện gần như giống với các neuron nhân tạo, là đơn vị tính toán cơ bản của mạng neural. Hơn thế, giới thiệu về mạng neural sẽ không đầy đủ nếu thiếu thảo luận về perceptrons. Tiếp theo chúng ta sẽ trình bày nền tảng lý thuyết của quá trình lan truyền ngược - backpropagation. Sau khi phát triển các phương trình lan truyền ngược cơ bản, chúng ta sẽ viết lại chúng dưới dạng ma trận, qua đó quá trình huấn luyện và vận hành của mạng neural sẽ đơn giản là một chuỗi các phép nhân ma trận.

Sau khi nghiên cứu một số ví dụ về mạng neural kết nối đầy đủ, chúng ta sẽ tiếp tục trình bày nền tảng cơ sở của mạng CNNs, bao gồm sự khác biệt của chúng so với mạng neural đầy đủ kết nối và cách huấn luyện của mạng CNNs. Tiếp theo là một số ví dụ trình bày làm thế nào các mạng CNN được sử dụng để phân loại mẫu ảnh.

7.7.2. Mạng Perceptron

Một đơn vị perceptron đơn có thể học một biên tuyến tính giữa 2 lớp mẫu phân tách tuyến tính. Hình 7.23(a) trình bày một ví dụ đơn giản nhất trong không gian 2 chiều: 2 lớp mẫu, mỗi lớp chứa 1 mẫu đơn lẻ. Một biên tuyến tính trong không gian 2 chiều là một đường thẳng với phương trình dạng $y = ax + b$, trong đó a là hệ số góc và b là giá trị tung độ góc. Lưu ý rằng nếu $b = 0$ đường thẳng đi qua gốc tọa độ. Do đó hiểu cách khác thì đó là hàm của tham số b (khác 0) xác định dịch chuyển của đường thẳng khỏi gốc tọa độ một đoạn b mà không ảnh hưởng đến độ dốc của nó. Vì lý do này, b , còn có ý nghĩa là một hệ số trôi nổi - floating, chính là phần mà không được nhân với một tọa độ nào đó, và thường được gọi là độ lệch (hoặc chệch), hệ số độ chệch hoặc trọng số độ chệch.



Hình 7.23 (a) Ví dụ đơn giản nhất về hai lớp trong không gian hai chiều cho thấy 1 biên quyết định khả dĩ trong vô số biên khả dĩ như vậy. (b) Tương tự như (a), nhưng biên quyết định được biểu diễn bằng cách sử dụng ký hiệu tổng quát hơn.

Chúng ta quan tâm đến đường thẳng chia hai lớp trong Hình 7.23. Đường thẳng này được đặt ở vị trí sao cho mẫu (x_1, y_1) ở lớp c_1 nằm ở một phía của đường thẳng, và mẫu (x_2, y_2) từ lớp c_2 nằm ở phía bên kia. Tập hợp các điểm (x, y) thuộc đường thẳng này thỏa mãn phương trình $y - ax - b = 0$. Đường chia đôi này có phương trình làm cho bất kỳ điểm (x, y) nào trên đường thẳng đều thỏa mãn phương trình. Kết quả là bất kỳ điểm nào ở một bên của đường thẳng khi được đưa vào phương trình này đều cho giá trị dương, và cho giá trị âm với điểm ở phía còn lại.

Thông thường chúng ta làm việc với các mẫu trong không gian có số chiều lớn hơn hai rất nhiều, nên chúng ta cần sử dụng ký hiệu tổng quát hơn. Các điểm trong không gian n chiều là các vector. Các thành phần $x_1, x_2, \dots, x_n$ của một vector là các tọa độ của điểm đó. Đối với các hệ số của đường chia hai lớp, chúng ta sử dụng ký hiệu $w_1, w_2, \dots, w_n, w_{n+1}$ trong đó w_{n+1} là độ chệch. Phương trình tổng quát của đường thẳng sử dụng các ký hiệu như vậy sẽ là $w_1x_1 + w_2x_2 + w_3 = 0$. Với ký hiệu tổng quát đó, chúng ta nói rằng một điểm tùy ý (x_1, x_2) nằm ở phía dương của một đường thẳng nếu $w_1x_1 + w_2x_2 + w_3 > 0$, và ngược lại cho bất kỳ điểm nào ở phía âm. Đối với các điểm trong không gian ba chiều, chúng ta có phương trình của một mặt phẳng và thực hiện chính xác các kiểm tra như trên để xem xét liệu một điểm có nằm ở phía dương hay phía âm của mặt phẳng. Đối với một điểm trong không gian n chiều, kiểm tra sẽ là đối với một siêu mặt phẳng - hyperplane có phương trình là:

$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1} = 0 \quad (7-43)$$

Phương trình này viết dưới dạng tổng như sau:

$$\sum_{i=1}^n w_i x_i + w_{n+1} = 0 \quad (7-44)$$

Hoặc ở dạng vector:

$$w^T x + w_{n+1} = 0 \quad (7-45)$$

Ở đây, w và x là các vector cột n chiều, và $w^T x$ là tích vô hướng (dot product) của hai vector. Do tích vô hướng là giao hoán, chúng ta có thể biểu diễn phương trình (7-45) dưới dạng tương đương là $x^T w + w_{n+1} = 0$. Chúng ta gọi w là một vector trọng số và w_{n+1} là độ chệch. Vì độ chệch là trọng số luôn được nhân với 1, đôi khi chúng ta tránh lặp lại bằng cách sử dụng thuật ngữ trọng số, hệ số, hoặc tham số khi đề cập đến độ chệch và các thành phần của một vector trọng số cùng với nhau.

Mô tả bài toán tách lớp ở dạng tổng quát, chúng ta nói rằng, cho trước bất kỳ vector mẫu x nào từ một quần thể vector mẫu, chúng ta mong muốn tìm một bộ trọng số có tính chất:

$$w^T x + w_{n+1} = \begin{cases} > 0 & \text{if } x \in c_1 \\ < 0 & \text{if } x \in c_2 \end{cases} \quad (7-46)$$

Việc tìm một đường thẳng chia đôi hai lớp mẫu tuyến tính trong không gian hai chiều có thể được thực hiện bằng quan sát. Việc tìm một mặt phẳng chia 2 lớp dựa vào quan sát dữ liệu ba chiều thì khó khăn hơn, nhưng vẫn khả thi. Tuy nhiên, nhìn chung thì việc tìm một siêu mặt phẳng trong không gian n chiều chia 2 lớp dựa vào quan sát như ở trên là bất khả thi. Chúng ta phải dựa vào một thuật toán để tìm kiếm nghiệm. Perceptron là một cài đặt của một thuật toán như vậy. Nó cố gắng tìm kiếm nghiệm bằng cách lặp qua từng mẫu của hai lớp. Nó bắt đầu với một vector trọng số và độ chệch tùy ý và đảm bảo sẽ hội tụ sau một số lần lặp hữu hạn nếu các lớp có thể phân chia tuyến tính được. Nhắc lại các lớp có thể phân tách tuyến tính thỏa mãn phương trình (7-46) chính là chúng có thể tách nhau bằng các siêu phẳng đơn.

Thuật toán perceptron là khá đơn giản. Đặt $\alpha > 0$ ký hiệu giá trị gia tăng hiệu chỉnh (cũng được gọi là gia tăng học tập hay tốc độ học), đặt $w(1)$ là một vector với các giá trị tùy ý và $w_{n+1}(1)$ là một hằng số tùy ý. Sau đó thực hiện tính toán sau với $k = 2, 3, \dots$. Với một vector mẫu $x(k)$ ở bước k :

1. Nếu $x(k) \in c_1$ và $w^T(k)x(k) + w_{n+1}(k) \leq 0$, đặt:

$$\begin{aligned} w(k+1) &= w(k) + \alpha x(k) \\ w_{n+1}(k+1) &= w_{n+1}(k) + \alpha \end{aligned} \quad (7-47)$$

2. Nếu $x(k) \in c_2$ và $w^T(k)x(k) + w_{n+1}(k) \geq 0$, đặt:

$$\begin{aligned} w(k+1) &= w(k) - \alpha x(k) \\ w_{n+1}(k+1) &= w_{n+1}(k) - \alpha \end{aligned} \quad (7-48)$$

3. Nếu khác với trên, đặt:

$$\begin{aligned} w(k+1) &= w(k) \\ w_{n+1}(k+1) &= w_{n+1}(k) \end{aligned} \quad (7-49)$$

Sự hiệu chỉnh trong phương trình (7-47) được thực hiện khi mẫu là từ lớp c_1 nhưng phương trình (7-46) lại không trả về giá trị dương. Tương tự, sự điều chỉnh trong phương trình (7-48) được áp dụng khi mẫu là từ lớp c_2 và phương trình (7-46) không trả về giá trị âm. Còn phương trình (7-49) cho thấy, không có thay đổi nào được thực hiện khi phương trình (7-46) đưa ra kết quả chính xác tương ứng với đúng lớp của $x(k)$.

Ký hiệu trong các phương trình (7-47) đến (7-49) có thể được đơn giản hóa nếu chúng ta

thêm số 1 vào cuối mỗi vector mẫu (số chiều của không gian tăng lên 1) và gộp độ chệch vào vector trọng số. Nghĩa là chúng ta định nghĩa vector $x = [x_1, x_2, \dots, x_n, 1]^T$ và $w = [w_1, w_2, \dots, w_n, w_{n+1}]^T$. Khi đó phương trình (7-46) sẽ trở thành:

$$w^T x = \begin{cases} > 0 & \text{if } x \in c_1 \\ < 0 & \text{if } x \in c_2 \end{cases} \quad (7-50)$$

Trong đó cả 2 vector đều có $(n+1)$ chiều. Trong công thức này, x và w được gọi là các vector mẫu mở rộng – augmented pattern và trọng số mở rộng – augmented weight. Thuật toán trong các phương trình (7-47) đến (7-49) khi đó trở thành. Với bất kỳ vector mẫu $x(k)$ ở bước k nào:

1. Nếu $x(k) \in c_1$ và $w^T(k)x(k) \leq 0$, đặt:

$$w(k+1) = w(k) + \alpha x(k) \quad (7-51)$$

2. Nếu $x(k) \in c_2$ và $w^T(k)x(k) \geq 0$, đặt:


$$w(k+1) = w(k) - \alpha x(k) \quad (7-52)$$

3. Nếu khác với trên, đặt:

$$w(k+1) = w(k) \quad (7-53)$$

Trong đó vector bắt đầu $w(1)$ là tùy ý và tương tự như trên hằng số $\alpha > 0$. Thuật toán cài đặt theo các phương trình (7-47) – (7-49) hoặc (7-51) – (7-53) được gọi là thuật toán huấn luyện perceptron – perceptron training algorithm. Định lý về hội tụ perceptron – perceptron convergence theorem phát biểu rằng thuật toán đảm bảo hội tụ đến nghiệm (chính là siêu phẳng phân tách) sau một số hữu hạn bước nếu 2 lớp mẫu là có thể phân tách tuyến tính. Thông thường các phương trình (7-51) - (7-53) là cơ sở để cài đặt thuật toán huấn luyện perceptron và nó sẽ được sử dụng trong các phần sau. Tuy nhiên ký hiệu trong các phương trình (7-47) – (7-49) trong đó độ chệch được biểu diễn riêng rẽ khá phổ biến trong các mạng neural vì vậy chúng ta cũng cần ghi nhớ dạng đó.

Hình 7.24 trình bày lược đồ thiết kế của một perceptron. Như chúng ta thấy, tất cả những phép toán mà phần tử đơn giản này thực hiện là tạo ra một tổng của các tích của một mẫu đầu vào sử dụng các trọng số và độ chệch tính toán được trong quá trình huấn luyện. Đầu ra của phép toán là một giá trị vô hướng và được đưa qua một hàm kích thích – activation function để tạo ra một đầu ra đơn vị -1 hoặc 1. Đối với perceptron, hàm kích thích là một hàm phân ngưỡng (chúng ta sẽ xem xét các dạng hàm kích thích khác khi tìm hiểu về các mạng neural). Nếu đầu ra được phân ngưỡng là $a + 1$, chúng ta nói rằng mẫu thuộc về lớp c_1 . Ngược lại $a - 1$ chỉ ra rằng mẫu thuộc về lớp c_2 . Giá trị 1 hoặc 0 đôi khi cũng được sử dụng để ký hiệu 2 trạng thái của đầu ra.



Hình 7.24 Lược đồ biểu diễn một perceptron, thể hiện các phép toán mà phần tử này thực hiện.

Trong thực tế, ít có các lớp mẫu có thể phân tách tuyến tính hoàn hảo. Do đó nhiều nghiên cứu những năm 1960 và 1970 đã được tiến hành để phát triển các kỹ thuật xử lý các lớp mẫu không thể phân tách tuyến tính. Chúng ta sẽ không trình bày hết các nghiên cứu đó mà chỉ trình bày ngắn gọn một phương pháp liên quan đến mạng nơ-ron. Phương pháp này dựa trên tính toán giảm thiểu sai số giữa kết quả thực tế và kết quả mong muốn ở bất kỳ bước huấn luyện nào.

Đặt r là kết quả mong muốn perceptron tạo ra cho bất kỳ mẫu nào trong quá trình đào tạo. Đầu ra của perceptron có thể là $+1$ hoặc -1 , vì vậy đó là hai giá trị có thể có của r . Chúng ta muốn tìm vector trọng số bổ sung, w , mà có thể làm giảm thiểu sai số bình phương trung bình (MSE – Mean Square Error) giữa kết quả mong muốn và kết quả tính toán của perceptron. Hàm sai số này phải là hàm khả vi và có một giá trị tối thiểu duy nhất. Hàm được chọn cho mục đích này là một hàm bậc hai có dạng:

$$E(w) = \frac{1}{2} (r - w^T x)^2 \quad (7-54)$$

Trong đó E là phép tính toán hay phép đo sai số, w là vector trọng số đang cần tìm, x là bất kỳ mẫu nào từ tập huấn luyện, và r là kết quả mong muốn cho mẫu đó. Cả w và x là các vector mở rộng (bổ sung thêm 1 hằng số hay tăng thêm 1 chiều).


Chúng ta tìm cực tiểu của $E(w)$ sử dụng thuật toán giảm gradient lặp – iterative gradient descent, có dạng sau:

$$w(k+1) = w(k) - \alpha \left[\frac{\partial E(w)}{\partial w} \right]_{w=w(k)} \quad (7-55)$$

Trong đó vector trọng số ban đầu là tùy ý và $\alpha > 0$.

Hình 7.25(a) thể hiện biểu đồ của E đối với các giá trị vô hướng wx , của 2 vector w và x . Chúng ta muốn dịch chuyển w tăng dần để $E(w)$ tiến gần đến một giá trị cực tiểu có nghĩa là E dừng giảm hay tương đương là $\partial E(w)/\partial w = 0$, phương trình (7-55) thể hiện chính xác điều này. Nếu $\partial E(w)/\partial w > 0$, một phần của đại lượng này (xác định cụ thể bởi giá trị của độ tăng học tập α) được trừ bớt đi khỏi $w(k)$ để tạo ra một giá trị mới được cập nhật của trọng số là $w(k+1)$. Điều ngược lại đúng nếu $\partial E(w)/\partial w < 0$. Nếu $\partial E(w)/\partial w = 0$, trọng số không thay đổi, có nghĩa là chúng ta đã đạt đến một giá trị cực tiểu, đó chính là nghiệm cần tìm kiếm. Giá trị của α quyết định độ lớn tương đối của sự hiệu chỉnh trong giá trị trọng số. Nếu α quá nhỏ, các thay đổi ở từng bước sẽ nhỏ tương ứng và trọng số sẽ di chuyển chậm đến hội tụ như mô tả trong Hình 7.25(a) mô tả. Ngược lại, lựa chọn α quá lớn có thể gây ra nhiễu động

lớn ở cả hai bên của giá trị tối thiểu, hoặc thậm chí trở nên không hội tụ, như Hình 7.25(b) mô tả. Không có quy tắc chung nào cho việc chọn giá trị α . Tuy nhiên, một giải pháp hợp lý là bắt đầu nhỏ và thử nghiệm bằng cách tăng giá trị α để xác định ảnh hưởng của nó đối với một tập hợp cụ thể các mẫu huấn luyện. Hình 7.25(c) thể hiện hình dạng của hàm sai số $E(w)$ cho hai biến w và x .



Hình 7.25 Biểu đồ của E như một hàm của wx cho $r = 1$. (a) Một giá trị của quá nhỏ có thể làm chậm quá trình hội tụ. (b) Nếu quá lớn, có thể xảy ra dao động lớn hoặc phân kỳ. (c) Hình dạng của hàm lỗi trong không gian 2 chiều.

Do hàm sai số được cho dưới dạng giải tích và khả vi, chúng ta có thể biểu diễn phương trình (7-55) dưới dạng không yêu cầu tính toán hiện gradient ở mỗi bước. Đạo hàm riêng của $E(w)$ theo w là:

$$\left[\frac{\partial E(w)}{\partial w} \right] = -(r - w^T x)x \quad (7-56)$$

Thay vào phương trình (7-55) cho:


$$w(k+1) = w(k) + \alpha[r(k) - w^T(k)x(k)]x(k) \quad (7-57)$$

Chính là được viết theo các số hạng có thể dễ dàng tính toán và đã biết. Cũng như trước $w(1)$ là tùy ý.

Các nghiên cứu đã chỉ ra rằng, điều kiện cần (nhưng không đủ) là α phải nằm trong khoảng $0 < \alpha < 2$ để thuật toán trong phương trình (7-57) hội tụ. Một dải giá trị được sử dụng phổ biến cho α là $0.1 < \alpha < 1$ và thuật toán hội tụ đến nghiệm w làm cực tiểu sai số bình phương trung bình đối với các mẫu của tập huấn luyện. Vì lý do này, thuật toán thường được gọi là thuật toán sai số bình phương trung bình nhỏ nhất (LMSE – Least Mean Square Error). Trong thực tế, chúng ta nói rằng thuật toán đã hội tụ khi sai số giảm xuống dưới một ngưỡng xác định. Nghiệm khi hội tụ có thể không phải là một siêu phẳng phân chia đầy đủ hai lớp có thể phân tách tuyến tính. Nghĩa là, một nghiệm của phương pháp sai số bình phương trung bình không nhất thiết phải là nghiệm theo nghĩa của lý thuyết huấn luyện perceptron. Sự bất định này là đánh đổi khi sử dụng một thuật toán mà sự hội tụ của nó độc lập với tính phân tách tuyến tính của các lớp mẫu.


Một ví dụ kinh điển được sử dụng để thể hiện hạn chế của các biên quyết định tuyến tính đơn (và cũng là các đơn vị perceptron đơn) là bài toán phân loại XOR. Bảng trong Hình 7.26(a) trình bày định nghĩa của toán tử XOR cho hai biến. Phép toán XOR cho giá trị true (1) khi một trong các biến (không đồng thời) là true; còn lại, kết quả là false (0). Bài toán phân loại XOR hai lớp được thiết lập bằng cách cho mỗi cặp giá trị A và B là một điểm trong không gian 2D, và cho các giá trị XOR true (1) xác định một lớp, và các giá trị false (0) xác định 1 lớp. Trong trường hợp này, chúng ta gán nhãn lớp c_1 cho các mẫu $\{(0, 0), (1, 1)\}$, và nhãn c_2 cho các mẫu $\{(1, 0), (0, 1)\}$. Một bộ phân loại có khả năng giải bài toán phân lớp

XOR phải cho giá trị 1 khi một mẫu từ lớp c_1 được đưa vào nhận dạng, và một giá trị khác, chẳng hạn 0 hoặc -1 khi mẫu đầu vào là từ lớp c_2 . Có thể thấy từ Hình 7.26(b) rằng một biên quyết định tuyến tính đơn (một đường thẳng) không thể có cách nào phân chia được đúng hai lớp. Điều này có nghĩa là không thể giải được bài toán với một perceptron đơn. Biên quyết định tuyến tính đơn giản nhất cần có hai đường thẳng như Hình 7.26(b). Một biên quyết định phi tuyến (phức tạp hơn) có khả năng giải quyết bài toán này là một hàm bậc hai như trong Hình 7.26(c).



Hình 7.26 Bài toán phân loại XOR trong không gian 2D. (a) Bảng chân lý định nghĩa toán tử XOR. (b) Các lớp mẫu 2D được tạo ra bằng cách gán các giá trị chân lý XOR đúng (giá trị 1) cho một lớp mẫu và sai (giá trị 0) cho một lớp khác. Biên quyết định đơn giản nhất giữa hai lớp bao gồm hai đường thẳng. (c) Biên phi tuyến (bậc hai) tách hai lớp.

Ở đây một cách tự nhiên sẽ xuất hiện một số câu hỏi như sau: Liệu nhiều hơn một perceptron có thể giải bài toán XOR không? Nếu có, thì số lượng tối thiểu là bao nhiêu? Chúng ta đã biết rằng một perceptron đơn có thể cho một đường thẳng, và chúng ta cần tạo hai đường thẳng. Vì vậy câu trả lời là: có đối với câu hỏi đầu tiên, và hai cho câu hỏi thứ hai. Hình 7.27(a) trình bày nghiệm cho hai biến trong đó cần tổng cộng sáu hệ số vì cần có hai đường thẳng là các biên quyết định. Các hệ số của nghiệm được thiết lập sao cho, đối với một trong hai mẫu từ lớp c_1 , một đầu ra là true (1) và đầu còn lại là false (0). Điều kiện ngược lại phải đúng cho mẫu từ lớp c_2 . Nghiệm kiểu này yêu cầu phân tích hai đầu ra. Nếu chúng ta muốn thể hiện được bảng chân lý, nghĩa là nếu dùng một đầu ra đơn thì sẽ cho cùng một kết quả như hàm XOR ở cột thứ ba trong Hình 7.26(a). Khi đó chúng ta cần dùng một perceptron bổ sung. Hình 7.27(b) trình bày kiến trúc cho nghiệm này. Ở đây, một perceptron ở tầng đầu tiên ánh xạ bất kỳ đầu vào nào từ một lớp thành 1, và perceptron còn lại ánh xạ một mẫu (đầu vào) từ lớp còn lại thành 0. Điều này thu bốn đầu vào thành hai đầu ra, mà đó chính là bài toán phân tách hai điểm. Như đã nói ở trên, một perceptron đơn có thể giải quyết bài toán này. Vì thế cần ba perceptron để tạo được bảng XOR, như trong Hình 7.27(b).



Hình 7.27 (a) Nghiệm với số perceptron tối thiểu cho bài toán XOR trong không gian 2 chiều. (b) Một nghiệm tạo được bằng XOR như trong Hình 7.26(a).

7.7.3. Mạng nơ-ron đa tầng lan truyền thẳng

Trong phần này, chúng ta thảo luận về kiến trúc và hoạt động của mạng nơ-ron đa tầng, thu nhận các phương trình của giải thuật lan truyền ngược được sử dụng để huấn luyện các mạng này. Sau đó, chúng ta trình bày một số ví dụ để minh họa khả năng của các mạng nơ-ron.


7.7.3.1. Mô hình của một nơ-ron nhân tạo

Mạng nơ-ron là một hệ thống các phần tử tính toán tương tự như perceptron, được kết nối với nhau và được gọi là nơ-ron nhân tạo. Các nơ-ron này thực hiện các phép tính giống như perceptron, nhưng chúng khác với perceptron ở cách xử lý kết quả của các phép tính. Như được minh họa trong Hình 7.24, perceptron sử dụng một hàm phân ngưỡng "cứng" mà đầu ra của nó là hai giá trị, chẳng hạn như +1 và -1, để thực hiện phân loại. Giả sử rằng trong một mạng các perceptron, đầu ra trước khi phân ngưỡng của một trong những perceptron là vô cùng nhỏ lớn hơn không. Khi phân ngưỡng, tín hiệu rất nhỏ này sẽ trở thành +1. Tuy nhiên, một tín hiệu nhỏ tương đương với dấu âm sẽ gây ra một biến động lớn từ +1 đến -1. Mạng nơ-ron được tạo thành từ các tầng của các phần tử tính toán, trong đó đầu ra của một đơn vị ảnh hưởng đến ứng xử của tất cả các phần tử theo sau. Tính nhạy của perceptron đối với dấu của các tín hiệu nhỏ có thể gây ra các vấn đề ổn định nghiêm trọng trong một hệ thống liên kết của các phần tử như vậy, và khiến cho các perceptrons không phù hợp cho các kiến trúc phân tầng.

Giải pháp là thay đổi đặc tính của hàm kích hoạt từ một hàm ngưỡng cứng thành một hàm trơn. Hình 7.28 cho một ví dụ dựa trên việc sử dụng hàm kích hoạt sau:

$$h(z) = \frac{1}{1 + e^{-z}} \quad (7-58)$$

Trong đó z là kết quả của tính toán được thực hiện bởi nơ-ron như trong Hình 7.28. Ngoài trừ ký hiệu phức tạp hơn, và việc sử dụng hàm trơn thay vì ngưỡng cứng, mô hình này thực hiện tính toán tổng tích như trong phương trình (7-43) đối với perceptron. Chú ý rằng số hạng độ chệch ở đây được ký hiệu là b thay vì w_{n+1} như chúng ta đã dùng với perceptron. Theo thói quen chúng ta thường dùng b để ký hiệu độ chệch trong các mạng nơ-ron. Ký hiệu phức tạp hơn như trong Hình 7.28 cần được sử dụng bởi vì chúng ta sẽ làm việc với các thiết kế đa tầng với một số nơ-ron trên mỗi tầng. Chúng ta dùng ký hiệu " l " để ký hiệu các lớp.




Hình 7.28 Mô hình một tế bào thần kinh nhân tạo, thể hiện tất cả các phép toán mà nó thực hiện. Dấu " l " được sử dụng để chỉ một tầng cụ thể trong một mạng có nhiều tầng.

Như có thể thấy bằng việc so sánh các Hình 7.28 với 7.24 ở đây ta sử dụng biến z ký hiệu

tổng của các tích tính toán bởi notron. Đầu ra của notron ký hiệu là a nhận được bằng việc truyền z qua h . Chúng ta gọi h là hàm kích hoạt và gọi đầu ra của nó $a = h(z)$ là giá trị kích hoạt của notron. Chú ý trong Hình 7.29, các đầu vào của notron là các giá trị kích hoạt từ các notron ở lớp trước. Hình 7.29 trình bày đồ thị của $h(z)$ từ phương trình (7-58). Vì $h(z)$ có hình dáng của một hàm sigmoid nên notron trong Hình 7.28 đôi khi được gọi là notron sigmoid nhân tạo hoặc đơn giản là notron sigmoid. Đạo hàm của $h(z)$ có dạng hết sức thú vị, có thể biểu diễn thông qua chính nó như sau:

$$h'(z) = \frac{\partial h(z)}{\partial z} = h(z)[1 - h(z)] \quad (7-59)$$


Hình 7.29(b) và 7.29(c) biểu diễn 2 dạng hàm khác của $h(z)$ được sử dụng khá thường xuyên. Hàm tanh cũng có hình dạng như hàm sigmoid, nhưng nó đối xứng qua cả hai trục. Đặc tính này có thể giúp cải thiện quá trình hội tụ của thuật toán lan truyền ngược sẽ được thảo luận sau. Hàm trong Hình 7.29(c) được gọi là hàm điều chỉnh, và notron sử dụng nó được gọi là notron tuyến tính điều chỉnh (ReLU). Thường, hàm này được gọi là hàm kích hoạt ReLU. Kết quả thử nghiệm cho thấy rằng hàm này có xu hướng vượt trội hơn so với hai hàm khác trong mạng neural học sâu.



Hình 7.29 Các hàm kích hoạt khác nhau. (a) Sigmoid. (b) Tanh (cũng có hình dạng sigmoid, nhưng nó tập trung xung quanh 0 ở cả hai phía). (c) Notron tuyến tính điều chỉnh (ReLU).

7.7.3.2. Liên kết các notron tạo thành mạng notron kết nối đầy đủ

Hình 7.30 trình bày sơ đồ chung của một mạng neural đa tầng. Mỗi tầng trong mạng là tập hợp các nút (neuron) trong một cột của mạng. Theo hình phóng to của 1 node trong Hình 7.30, các nút trong mạng là những neuron nhân tạo có dạng Hình 7.28 ngoại trừ tầng đầu vào với các nút là các thành phần của một vector mẫu đầu vào x . Vì thế các đầu ra (các giá trị kích hoạt) của tầng đầu tiên vẫn là giá trị của các phần tử của x . Các đầu ra của tất cả các nút khác (ở các tầng khác) là giá trị kích hoạt của các neuron trong tầng đó. Mỗi tầng trong mạng có thể có một số lượng nút khác nhau, nhưng mỗi nút chỉ có một đầu ra. Hình 7.30 cho thấy các node (hay các nút) có nhiều đường ra có ý nghĩa là 1 giá trị đầu ra của 1 node sẽ được cung cấp đến đầu vào của tất cả các nút trong tầng tiếp theo, vì vậy tạo thành một mạng kết nối đầy đủ. Chú ý rằng cũng không có vòng lặp tồn tại trong mạng. Những mạng như vậy được gọi là mạng truyền thẳng. Các mạng neural truyền thẳng, kết nối đầy đủ là kiểu mạng duy nhất chúng ta nghiên cứu trong phần này.



Hình 7.30 Mô hình chung của mạng nơtron kết nối đầy đủ lan truyền thẳng. Nơtron có dạng như trong Hình 7.28. Lưu ý cách đầu ra của mỗi nơtron kết nối với tất cả các nơtron trong lớp tiếp theo, do đó mà người ta đặt tên cho kiến trúc này là kết nối đầy đủ.

Chúng ta hiển nhiên biết giá trị của các nút trong tầng đầu tiên, và có thể quan sát giá trị của các nơ-ron đầu ra. Tất cả những nơ-ron còn lại đều là ẩn, và các tầng chứa chúng được gọi là các tầng ẩn. Thông thường, chúng ta gọi một mạng neural với một tầng ẩn là một mạng neural nông, và gọi mạng có hai hoặc nhiều tầng ẩn là mạng neural sâu. Tuy nhiên, thuật ngữ này không phải lúc nào cũng thống nhất. Đôi khi các từ "nông" và "sâu" cũng có thể được sử dụng để chỉ các mạng có "ít" (nông) và "nhiều" (sâu) tầng.

Chúng ta đã sử dụng ký pháp trong phương trình (7-44) để ký hiệu đầu vào và trọng số của một perceptron. Trong một mạng neural, ký hiệu trở nên phức tạp hơn vì chúng ta phải tính đến các trọng số, các đầu vào và đầu ra của nơ-ron trong một tầng, cũng như từ tầng này

sang tầng khác. Tạm bỏ qua ký hiệu tầng, chúng ta ký hiệu w_{ij} là trọng số liên kết giữa đầu ra của nơ-ron j và đầu vào của nơ-ron i . Chính là, chỉ số đầu tiên i chỉ nơ-ron nhận tín hiệu, và chỉ số thứ hai j chỉ nơ-ron gửi tín hiệu. Bởi vì i đứng trước j theo thứ tự chữ cái, dường như là hợp lý hơn nếu i gửi và j nhận. Lý do chúng ta sử dụng ký hiệu như trên là để tránh việc chuyển vị ma trận trong phương trình mô tả sự lan truyền của tín hiệu qua mạng. Ký hiệu này là theo quy ước, nhưng không có nghi ngờ gì rằng nó có thể gây nhầm lẫn, vì vậy cần phải chú ý đặc biệt để giữ cho các ký hiệu luôn rõ ràng.

Bởi độ chệch chỉ phụ thuộc vào nơ-ron chứa nó, một chỉ số đơn liên kết một độ chệch với 1 nơ-ron là đủ. Ví dụ, chúng ta sử dụng b_i để ký hiệu giá trị độ chệch gắn với nơ-ron thứ i trong một tầng nhất định của mạng. Việc sử dụng b thay vì w_{n+1} (như chúng ta đã làm với perceptrons) tuân theo quy ước ký pháp được sử dụng trong các mạng neural. Trọng số, độ chệch và các hàm kích hoạt hoàn toàn xác định một mạng neural. Mặc dù hàm kích hoạt của bất kỳ nơ-ron nào trong một mạng neural có thể khác với các hàm khác, nhưng không có cơ sở thuyết phục nào cho thấy rằng dùng các hàm kích hoạt khác nhau là có ích. Chúng ta giả thiết trong tất cả các phần tiếp theo rằng cùng một dạng hàm kích hoạt được sử dụng trong tất cả các nơ-ron.

Ký hiệu l là một tầng trong mạng neural với $l = 1, 2, \dots, L$. Theo Hình 7.30, $l = 1$ là tầng đầu vào, $l = L$ là tầng đầu ra, và tất cả các giá trị khác của l ký hiệu các tầng ẩn. Số lượng nơ-ron trong tầng l được ký hiệu là n_l . Chúng ta có hai lựa chọn để đưa chỉ số tầng vào trong các tham số của mạng neural. Chúng ta có thể dùng chỉ số trên, ví dụ w_{ij}^l và b_i^l , hoặc chúng ta có thể sử dụng ký hiệu $w_{ij}(l)$ và $b_i(l)$. Lựa chọn đầu tiên phổ biến hơn trong các tài liệu về mạng neural. Chúng ta sử dụng lựa chọn thứ hai vì nó thống nhất hơn với cách chúng ta mô tả các biểu thức lặp trong tài liệu này, và cũng vì nó dễ theo dõi hơn. Sử dụng ký hiệu này, giá trị đầu ra (giá trị kích hoạt) của nơ-ron k trong tầng l được ký hiệu là $a_k(l)$.

Lưu ý rằng mục tiêu của chúng ta khi sử dụng mạng neural cũng giống như với perceptrons: xác định lớp cho các mẫu đầu vào chưa xác định. Cách phổ biến nhất để thực hiện phân loại mẫu sử dụng mạng neural là gán một nhãn lớp cho mỗi nơ-ron đầu ra. Do đó, một mạng neural với n_L đầu ra có thể phân loại một mẫu chưa xác định vào một trong số n_L lớp. Mạng gán một vector mẫu chưa xác định x vào lớp c_k nếu nơ-ron đầu ra k có giá trị kích hoạt lớn nhất; tức là, nếu $a_k(L) > a_j(L)$, $j = 1, 2, \dots, n_L$; $j \neq k$.

Thay vì một hàm sigmoid hoặc hàm tương tự trong tầng đầu ra cuối cùng, đôi khi hàm softmax được sử dụng thay thế. Điều này đã giải thích trước đó, về cơ bản là không tạo ra ưu điểm nào so với các dạng hàm khác. Tuy nhiên các giá trị kích hoạt của softmax được đưa ra bởi công thức $a_i(L) = \exp[z_i(L)] / \sum_k \exp[z_k(L)]$, trong đó phép tổng thực hiện trên tất cả các đầu ra. Trong công thức này, tổng của tất cả các kích hoạt là 1, do đó mang lại cho đầu ra duy nhất ý nghĩa xác suất. Trong phần này và phần tiếp theo, số lượng các đầu ra của mạng neural chúng ta xem xét sẽ luôn bằng số lượng các lớp mẫu đã biết. Nhưng điều này không phải là một yêu cầu. Ví dụ, một mạng để phân loại hai lớp mẫu có thể được thiết kế với một đầu ra duy nhất vì chúng ta chỉ cần hai trạng thái, và một nơ-ron duy nhất có thể giải quyết điều đó. Đối với ba và bốn lớp, chúng ta cần ba và bốn trạng thái, tương ứng. Điều đó có thể đạt được với hai nơ-ron đầu ra. Tất nhiên, bài toán với cách tiếp cận này là chúng ta sẽ cần logic bổ sung để giải mã các kết hợp đầu ra. Sẽ đơn giản hơn nếu chúng ta có một nơ-ron cho mỗi đầu ra và để nơ-ron có giá trị đầu ra cao nhất xác định lớp của đầu vào.

7.7.4. Lan truyền thẳng qua mạng nơ-ron lan truyền thẳng

Quá trình truyền thẳng qua một mạng neural ánh xạ tầng đầu vào (tức là, các giá trị của x) đến tầng đầu ra. Các giá trị trong tầng đầu ra được sử dụng để xác định lớp mẫu của một vector mẫu đầu vào. Các phương trình được trình bày trong phần này làm rõ cách một mạng neural truyền thẳng thực hiện các tính toán cho kết quả đầu ra. Ở đây các tham số của mạng (trọng số và độ chệch) là đã biết.

7.7.4.1. Phương trình của sự lan truyền thẳng

Các đầu ra của lớp 1 là các thành phần của vector đầu vào x :

$$a_j(1) = x_j \quad j = 1, 2, \dots, n_1 \quad (7-60)$$

Trong đó $n_l = n$ là số chiều của vector x . Như đã trình bày trong các Hình 7.28 và 7.30, tính toán thực hiện bởi notron i thuộc tầng l được cho bởi:

$$z_i(\ell) = \sum_{j=1}^{n_{\ell-1}} w_{ij}(\ell) a_j(\ell-1) + b_i(\ell) \quad (7-61)$$

Với $i = 1, 2, \dots, n_l$ và $l = 2, \dots, L$. Đại lượng $z_i(l)$ được gọi là đầu vào tổng cho notron i ở tầng l đôi khi được ký hiệu là net_i . Lý do gọi như vậy là bởi vì $z_i(l)$ được tạo nên từ tất cả các output từ tầng $l-1$. Đầu ra (giá trị kích hoạt) của notron i trong tầng l được cho bởi:

$$a_i(\ell) = h(z_i(\ell)) \quad i = 1, 2, \dots, n_\ell \quad (7-62)$$

Trong đó h là hàm kích hoạt. Giá trị của node đầu ra của mạng là:

$$a_i(L) = h(z_i(L)) \quad i = 1, 2, \dots, n_L \quad (7-63)$$

Các phương trình từ (7-60) đến (7-63) mô tả tất cả các phép toán cần thiết để ánh xạ đầu vào của một mạng kết nối đầy đủ lan truyền thẳng sang đầu ra.

7.7.4.2. Thiết lập bài toán theo ma trận

Ví dụ trên cho thấy rằng có rất nhiều tính toán liên quan đến một tính toán truyền thẳng (từ tầng vào đến tầng ra) qua một mạng neural. Nếu ta viết một chương trình máy tính để tự động hóa các bước đó, mã trở nên rất không hiệu quả do tất cả các tính toán vòng lặp cần thiết, các chỉ số nút và tầng phải sử dụng v.v. Chúng ta có thể phát triển một cách thực hiện hiệu quả hơn bằng cách sử dụng các phép toán ma trận và chương trình máy tính sẽ sử dụng các phép toán này. Điều này có nghĩa là viết lại các phương trình (7-60) đến (7-62) như sau.

$$a(1) = x \quad (7-64)$$

Tiếp theo chúng ta viết lại phương trình (7-61). Số hạng tổng đơn giản là tích vô hướng của 2 vector. Tuy nhiên phương trình này phải được tính toán cho tất cả các node ở mỗi tầng. Giải pháp là xây dựng ma trận $W(l)$ chứa tất cả trọng số ở tầng l . Cấu trúc của ma trận này có dạng đơn giản – mỗi dòng của nó chứa các trọng số cho 1 trong các node ở tầng l như sau:

$$W(\ell) = \begin{bmatrix} w_{11}(\ell) & w_{12}(\ell) & \dots & w_{1n_{\ell-1}}(\ell) \\ w_{21}(\ell) & w_{22}(\ell) & \dots & w_{2n_{\ell-1}}(\ell) \\ \vdots & \vdots & \dots & \vdots \\ w_{n_\ell 1}(\ell) & w_{n_\ell 2}(\ell) & \dots & w_{n_\ell n_{\ell-1}}(\ell) \end{bmatrix} \quad (7-65)$$

Khi đó chúng ta thu được phép tính tổng tích $z_i(l)$ như sau:

$$z(\ell) = W(\ell)a(\ell-1) + b(\ell) \quad \ell = 2, 3, \dots, L \quad (7-66)$$

Trong đó $a(l-1)$ là vector cột có chiều $n_{l-1} \times 1$ chứa tất cả các đầu ra của lớp $l-1$, $b(l)$ là vector cột có chiều $n_l \times 1$ chứa tất cả các giá trị độ chệch của tất cả các notron ở tầng l , và $z(l)$ là một vector cột cỡ $n_l \times 1$ chứa các giá trị đầu vào $z_i(l)$, $i = 1, 2, \dots, n_l$ theo công thức tổng tích. Chúng ta có thể kiểm tra ngay rằng công thức (7-66) đảm bảo về thứ nguyên.

Do hàm kích hoạt được áp dụng cho mỗi đầu vào tổng một cách độc lập, các đầu ra của mạng ở mỗi tầng có thể được biểu diễn theo dạng vector như sau:

$$\mathbf{a}(\ell) = h[\mathbf{z}(\ell)] = \begin{bmatrix} h(z_1(\ell)) \\ h(z_2(\ell)) \\ \vdots \\ h(z_r(\ell)) \end{bmatrix} \quad (7-67)$$

Giải các phương trình (7-64) đến (7-67) chỉ yêu cầu một loạt các phép tính ma trận và không cần bất kỳ vòng lặp nào.

Phương trình (7-64) đến (7-67) là một cải tiến đáng kể so với việc tính toán từng node một, nhưng chúng chỉ áp dụng cho một mẫu. Để phân loại đồng thời nhiều vector mẫu, chúng ta sẽ phải lặp lại tính toán cho từng mẫu sử dụng cùng một bộ tính ma trận cho mỗi vòng lặp. Chúng ta cần xây dựng một bộ tính toán ma trận duy nhất có khả năng xử lý tất cả các mẫu trong một lan truyền thẳng qua mạng. Mở rộng phương trình (7-64) đến (7-67) thành dạng tổng quát hơn là khá tường minh. Chúng ta bắt đầu bằng cách sắp xếp tất cả các vector mẫu đầu vào thành các cột của một ma trận duy nhất, $\mathbf{X}$, có kích thước $n \times n_p$, trong đó, vẫn như các phần trước, n là số chiều của các vector và n_p là số lượng vector mẫu. Kết quả từ phương trình (7-64) cho ta:

$$\mathbf{A}(1) = \mathbf{X} \quad (7-68)$$

Trong đó mỗi cột của ma trận $\mathbf{A}(1)$ chứa các giá trị kích hoạt ban đầu (các giá trị theo vector) cho 1 mẫu. Đây là mở rộng của phương trình (7-64), ngoại trừ bây giờ chúng ta làm việc với một ma trận cỡ $n \times n_p$ thay vì 1 vector cỡ $n \times 1$.

Các tham số của mạng không thay đổi. Chúng ta chỉ xử lý nhiều vector mẫu đồng thời vì vậy ma trận trọng số được sử dụng như trong phương trình (7-65). Ma trận này có kích thước $n_l \times n_{l-1}$. Khi $l = 2$, chúng ta có ma trận $\mathbf{W}(2)$ với kích thước $n_2 \times n$ vì n_1 luôn bằng n . Tiếp theo, mở rộng số hạng tích của phương trình (7-66) để sử dụng ma trận $\mathbf{A}(2)$ thay vì vector $\mathbf{a}(2)$, cho kết quả tích ma trận $\mathbf{W}(2)\mathbf{A}(2)$, có kích thước $(n_2 \times n)(n \times n_p) = (n_2 \times n_p)$. Đến đây, chúng ta phải thêm vector độ chệch cho tầng thứ hai, mà có kích thước của nó là $n_2 \times 1$. Rõ ràng, chúng ta không thể cộng một ma trận với kích thước $n_2 \times n_p$ với một vector kích thước $n_2 \times 1$. Tuy nhiên, giống như các ma trận trọng số, các vector độ chệch cũng không thay đổi. Chúng ta chỉ phải xét một vector độ chệch giống hệt nhau, $\mathbf{b}(2)$, cho mỗi vector đầu vào. Điều này được thực hiện bằng cách tạo ra một ma trận $\mathbf{B}(2)$ có kích thước $n_2 \times n_p$ được tạo thành bằng cách viết liên tiếp các vector cột $\mathbf{b}(2)$ n_p lần, theo chiều ngang. Sau đó, phương trình (7-66) viết dưới dạng ma trận trở thành $\mathbf{Z}(2) = \mathbf{W}(2)\mathbf{A}(1) + \mathbf{B}(2)$. Ma trận $\mathbf{Z}(2)$ có kích thước $n_2 \times n_p$ và chứa các tính toán thực hiện bởi phương trình (7-66), nhưng cho tất cả các mẫu đầu vào. Nghĩa là mỗi cột của $\mathbf{Z}(2)$ chính xác là tính toán thực hiện bởi phương trình (7-66) cho một mẫu đầu vào.

Lý luận vừa được trình bày ở trên áp dụng cho việc lan truyền từ bất kỳ tầng nào sang tầng tiếp theo trong mạng neural, miễn là chúng ta sử dụng đúng trọng số và độ chệch tại vị trí đó của mạng. Do đó, phiên bản ma trận đầy đủ của phương trình (7-66) là:

$$\mathbf{Z}(\ell) = \mathbf{W}(\ell)\mathbf{A}(\ell - 1) + \mathbf{B}(\ell) \quad (7-69)$$

Trong đó $\mathbf{W}(l)$ được cho bởi phương trình (7-65) và $\mathbf{B}(l)$ là một ma trận $n_l \times n_p$ mà các cột của nó là lặp lại của $\mathbf{b}(l)$, chính là vector độ chệch chứa các độ chệch của các nơtron ở tầng l .

Cái còn lại cần xác định bây giờ chỉ còn công thức dạng ma trận của đầu ra của tầng l . Theo phương trình (7-67), hàm kích hoạt được áp dụng một cách độc lập cho mỗi phần tử của vector $\mathbf{z}(l)$. Vì mỗi cột của ma trận $\mathbf{Z}(l)$ đơn giản là áp dụng của phương trình (7-67) tương ứng với một vector đầu vào cụ thể, và vì thế:

$$\mathbf{A}(\ell) = h[\mathbf{Z}(\ell)] \quad (7-70)$$

Trong đó hàm kích hoạt h được áp dụng cho mỗi phần tử của ma trận $Z(l)$.

Tổng kết về thứ nguyên của công thức ma trận ở đây ta có: X và $A(1)$ có cỡ $n \times n_p$. $Z(l)$ có cỡ $n_l \times n_p$. $W(l)$ có cỡ $n_l \times n_{l-1}$. $A(l-1)$ có cỡ $n_{l-1} \times n_p$. $B(l)$ có cỡ $n_l \times n_p$. Và $A(l)$ có cỡ $n_l \times n_p$. Bảng dưới đây tóm tắt công thức ma trận cho quá trình truyền thẳng qua mạng nơtron truyền thẳng kết nối đầy đủ cho tất cả các vector mẫu. Thực hiện các phép tính toán đó với một ngôn ngữ lập trình chuyên thao tác với ma trận (dạng ngôn ngữ Matlab, Octave etc.) là việc đơn giản. Hiệu năng tính toán có thể được cải thiện đáng kể bằng việc sử dụng phần cứng chuyên biệt, chẳng hạn như 1 hoặc nhiều bộ vi xử lý đồ họa (GPUs).

Bảng 7-1

Các bước trong tính toán ma trận đối với quá trình truyền thẳng qua một mạng nơ tron lan truyền thẳng, kết nối đầy đủ.

Bước	Mô tả	Phương trình
1	Nhập các mẫu	$A(1) = X$
2	Truyền thẳng	Với $l = 2, \dots, l$ tính toán $Z(l) = W(l)A(l-1) + B(l)$ và $A(l) = h(Z(l))$
3	Xuất đầu ra	$A(L) = h(Z(L))$

Các phương trình trong bản được sử dụng để phân loại mỗi mẫu thành 1 trong số n_L lớp mẫu. Mỗi cột của ma trận đầu ra $A(L)$ chứa các giá trị kích hoạt của n_L nơtron đầu ra cho mỗi một vector mẫu cụ thể. Kết luận về lớp của mẫu đó được xác định bởi vị trí của nơtron đầu ra với giá trị kích hoạt cao nhất. Tất nhiên ở đây chúng ta luôn giả thiết là các trọng số và độ chệch đã được xác định trên toàn mạng. Các giá trị đó được thu nhận trong quá trình huấn luyện sử dụng lan truyền ngược, sẽ được trình bày trong phần tiếp theo.

7.7.5. Sử dụng lan truyền ngược - backpropagation để huấn luyện mạng nơ-ron sâu

Một mạng nơ-ron hoàn toàn được định nghĩa thông qua các tham số: trọng số, độ lệch, và hàm kích hoạt của nó. Huấn luyện một mạng nơ-ron nghĩa là sử dụng một hoặc nhiều bộ mẫu huấn luyện để giúp ước lượng, tính toán những tham số đó. Trong quá trình huấn luyện, chúng ta xác định trước kết quả mong muốn của mỗi nơ-ron đầu ra (đã gán nhãn lớp cho mẫu đầu vào) trong một mạng nơ-ron đa tầng. Tuy nhiên, chúng ta không có cách nào để biết giá trị của đầu ra của các nơ-ron ẩn nên là gì. Ở phần này, chúng ta sẽ phát triển các phương trình của quá trình lan truyền ngược - backpropagation, công cụ được lựa chọn để tìm giá trị của các tham số: trọng số và độ chệch trong một mạng nơ-ron đa tầng. Quá trình huấn luyện bằng lan truyền ngược như vậy bao gồm bốn bước cơ bản: (1) đưa vào các vector mẫu; (2) lan truyền thẳng một lần qua mạng để phân loại tất cả các mẫu của bộ mẫu huấn luyện và xác định lỗi phân loại; (3) lan truyền ngược - backpropagation một lần để truyền lỗi đầu ra ngược lại qua mạng để tính toán các thay đổi cần thiết để cập nhật các tham số; và (4) cập nhật các tham số: trọng số và độ chệch trong mạng. Những bước này được lặp lại cho đến khi lỗi đạt đến một mức chấp nhận được. Chúng ta sẽ cung cấp tóm tắt của tất cả các kết quả chính thu nhận được trong phần này ở cuối chương. Như vậy chúng ta có thể sớm hình dung được, công cụ toán học chính cần thiết để thu nhận các phương trình của lan truyền ngược là quy tắc chuỗi – chain rule từ chủ đề toán học Phép tính cơ bản - Calculus.

7.7.5.1. Phương trình lan truyền ngược

Cho tập các mẫu huấn luyện và một kiến trúc mạng nơ-ron truyền thẳng nhiều tầng, cách tiếp cận trong lý thuyết dưới đây là tìm ra các tham số của mạng mà có thể làm cực tiểu hàm sai số (còn được gọi là hàm chi phí hay hàm mục tiêu). Quan tâm của chúng ta là hiệu năng phân lớp, vì thế chúng ta định nghĩa hàm sai số cho một mạng nơ-ron là trung bình của hiệu số giữa kết quả mong muốn và kết quả tính toán phân loại thực tế do mạng tính được. Đặt r là kết quả mong muốn cho một vector mẫu cụ thể, x , và $a(L)$ là kết quả thực tế của mạng đối

với đầu vào đó. Ví dụ, trong một ứng dụng nhận diện mười lớp, r và $a(L)$ sẽ là các vector cột 10 chiều. Mười thành phần của $a(L)$ sẽ là mười đầu ra của mạng nơ-ron, và các thành phần của r sẽ là 0, ngoại trừ phần tử tương ứng với lớp của x , mà thường sẽ là 1. Ví dụ, nếu mẫu huấn luyện thuộc lớp 6, thành phần thứ 6 của r sẽ phải là 1 và những phần còn lại sẽ là 0.

Giá trị kích hoạt của nơ-ron j của tầng đầu ra là $a_j(L)$. Chúng ta định nghĩa sai số của nơ-ron đó như sau:

$$E_j = \frac{1}{2} (r_j - a_j(L))^2 \quad (7-71)$$

Với $j = 1, 2, \dots, n_L$, trong đó r_j là giá trị xác định trước của đầu ra của nơ-ron $a_j(L)$ đối với một mẫu x . Sai số đầu ra theo một mẫu x là tổng của tất cả các sai số đầu ra của các nơ-ron tương ứng với vector đó.

$$\begin{aligned} E &= \sum_{j=1}^{n_L} E_j = \frac{1}{2} \sum_{j=1}^{n_L} (r_j - a_j(L))^2 \\ &= \frac{1}{2} \|r - a(L)\|^2 \end{aligned} \quad (7-72)$$

Trong đó dòng thứ hai là định nghĩa của chuẩn (độ dài) vector Euclid. Tổng sai số đầu ra của toàn bộ mạng trên tất cả các mẫu huấn luyện được định nghĩa là tổng của các sai số của từng mẫu cụ thể. Chúng ta muốn tìm các tham số trong số để làm cực tiểu tổng sai số này. Như chúng ta đã thực hiện cho LMSE – Least Mean Squared Error của perceptron, chúng ta sẽ tìm nghiệm bằng cách sử dụng phương pháp gradient descent. Tuy nhiên, khác với perceptron, chúng ta không có cách nào để tính toán gradient của các trọng số ở các nút ẩn. Điều rất hay của lan truyền ngược - backpropagation là chúng ta có thể đạt được kết quả tương đương bằng cách truyền sai số đầu ra ngược trở lại vào trong mạng.

Mục tiêu chính là tìm một sơ đồ tính toán để điều chỉnh tất cả các trọng số trong mạng sử dụng các mẫu huấn luyện. Để làm điều này, chúng ta cần biết làm thế nào E thay đổi theo trọng số trong mạng. Các trọng số được chứa trong biểu thức cho đầu vào net của mỗi nút, phương trình (7-61), vì vậy lượng thay đổi chúng ta cần là $\partial E / \partial z_j(l)$, như được định nghĩa trong phương trình (7-61), $z(l)$ là đầu vào net của nút j trong tầng l . Để đơn giản hóa ký hiệu sau này, chúng ta sử dụng ký hiệu $\delta_j(l)$ để ký hiệu $\partial E / \partial z_j(l)$. Vì lan truyền ngược bắt đầu từ đầu ra của mạng và sẽ lan truyền ngược lại từ đó, chúng ta trước tiên xem xét đại lượng:

$$\delta_j(L) = \frac{\partial E}{\partial z_j(L)} \quad (7-73)$$

Chúng ta có thể biểu diễn phương trình này theo các số hạng của đầu ra $a_j(L)$ sử dụng quy tắc chuỗi như sau:

$$\begin{aligned} \delta_j(L) &= \frac{\partial E}{\partial z_j(L)} = \frac{\partial E}{\partial a_j(L)} \frac{\partial a_j(L)}{\partial z_j(L)} = \frac{\partial E}{\partial a_j(L)} \frac{\partial h(z_j(L))}{\partial z_j(L)} \\ &= \frac{\partial E}{\partial a_j(L)} h'(z_j(L)) \end{aligned} \quad (7-74)$$

Trong đó chúng ta sử dụng phương trình (7-63) để thu nhận biểu thức cuối cùng trên dòng đầu tiên của (7-74). Phương trình này cho ta các giá trị của $\delta_j(L)$ theo các đại lượng có thể tính toán, xác định được. Ví dụ nếu ta sử dụng phương trình (7-71) là độ đo sai số và phương trình (7-59) cho đại lượng $h'(z_j(x))$, khi đó:

$$\delta_j(L) = h(z_j(L)) [1 - h(z_j(L))] [a_j(L) - r_j] \quad (7-75)$$

Trong đó chúng ta hoán đổi thứ tự của các số hạng. Thành phần $h(z_j(L))$ được tính toán theo lan truyền thẳng, $a_j(L)$ có thể tính toán được theo đầu ra của mạng và r_j được cho cùng với x trong quá trình huấn luyện. Từ đó chúng ta có thể tính $\delta_j(L)$.

Bởi vì mối quan hệ giữa đầu vào tổng và đầu ra của bất kỳ nơtron nào ở bất kỳ tầng nào (ngoại trừ tầng đầu tiên) là giống nhau, dạng của phương trình (7-73) là đúng cho bất kỳ node j nào ở các tầng ẩn:

$$\delta_j(\ell) = \frac{\partial E}{\partial z_j(\ell)} \quad (7-76)$$

Phương trình này cho ta thông tin về cách E thay đổi như thế nào theo đầu vào tổng với bất kỳ nơtron nào trong mạng. Tiếp theo ta sẽ biểu diễn $\delta_j(l)$ theo $\delta_j(l+1)$. Vì chúng ta sẽ đi lùi trong mạng, biểu diễn đó có nghĩa là ta có thể bắt đầu với $\delta_j(L)$ và tìm $\delta_j(L-1)$, tiếp theo là $\delta_j(L-2)$ và tiếp tục cho đến khi chúng ta đạt đến tầng 2. Chúng ta thu nhận được biểu thức mong muốn sử dụng quy tắc chuỗi như sau:

$$\begin{aligned} \delta_j(\ell) &= \frac{\partial E}{\partial z_j(\ell)} = \sum_i \frac{\partial E}{\partial z_j(\ell+1)} \frac{\partial z_j(\ell+1)}{\partial a_j(\ell)} \frac{\partial a_j(\ell)}{\partial z_j(\ell)} \\ &= \sum_i \delta_i(\ell+1) \frac{\partial z_j(\ell+1)}{\partial a_j(\ell)} h'(z_j(\ell)) \\ &= h'(z_j(\ell)) \sum_i w_{ij}(\ell+1) \delta_i(\ell+1) \end{aligned} \quad (7-77)$$

Với $l = L-1, L-2, \dots, 2$ bằng cách sử dụng các phương trình (7-62) và (7-76) để thu nhận phương trình ở dòng 2 trong (7-77) và sử dụng phương trình (7-61) kết hợp sắp xếp lại các số hạng để thu nhận phương trình cuối cùng trong (7-77).

Phản trên cho ta cách chúng ta có thể bắt đầu tính toán lan truyền ngược với sai số ở đầu ra (lưu ý sai số này hoàn toàn tính toán được) và thu nhận được thông tin về cách sai số đó thay đổi như thế nào theo dạng hàm của các đầu vào tổng với mỗi node trong mạng. Đây là bước trung gian để ta có thể đạt được tính toán cuối cùng để nhận được các biểu thức $\partial E / \partial w_{ij}(l)$ và $\partial E / \partial b_i(l)$ theo dạng $\delta_j(l) = \partial E / \partial z_j(l)$. Để thực hiện điều đó chúng ta sử dụng quy tắc chuỗi một lần nữa:

$$\begin{aligned} \frac{\partial E}{\partial w_{ij}(\ell)} &= \frac{\partial E}{\partial z_i(\ell)} \frac{\partial z_i(\ell)}{\partial w_{ij}(\ell)} \\ &= \delta_i(\ell) \frac{\partial z_i(\ell)}{\partial w_{ij}(\ell)} \\ &= a_j(\ell-1) \delta_i(\ell) \end{aligned} \quad (7-78)$$

Trong đó chúng ta sử dụng phương trình (7-61) và (7-66) và đạo thứ tự của các kết quả để làm rõ ràng các công thức ma trận. Tương tự như thế chúng ta có:

$$\frac{\partial E}{\partial b_i(\ell)} = \delta_i(\ell) \quad (7-79)$$

Ở đây chúng ta có tốc độ thay đổi của E theo các trọng số và độ chệch của mạng theo các đại lượng có thể tính toán được. Bước cuối cùng là sử dụng các kết quả đó để cập nhật các tham số của mạng sử dụng phương pháp gradient descent:

$$\begin{aligned} w_{ij}(\ell) &= w_{ij}(\ell) - \alpha \frac{\partial E(\ell)}{\partial w_{ij}(\ell)} \\ &= w_{ij}(\ell) - \alpha \delta_i(\ell) a_j(\ell-1) \end{aligned} \quad (7-80)$$

và

$$\begin{aligned} b_i(\ell) &= b_i(\ell) - \alpha \frac{\partial E}{\partial b_i(\ell)} \\ &= b_i(\ell) - \alpha \delta_i(\ell) \end{aligned} \quad (7-81)$$

Với $l = L-1, L-2, \dots, 2$ trong đó các giá trị α được tính toán trong bước truyền thẳng và các giá trị của δ được tính toán trong quá trình lan truyền ngược. Như đối với perceptron, α là

hằng số học tập được sử dụng trong phương pháp gradient descent. Có nhiều phương pháp tìm α tối ưu nhưng lưu ý về cơ bản α là tham số phụ thuộc trong bài toán liên quan đến tính toán thực nghiệm. Một giải pháp hợp lý là bắt đầu với α nhỏ (chẳng hạn 0.01), sau đó thực nghiệm với các vector mẫu từ tập huấn luyện để xác định giá trị phù hợp cho ứng dụng đang xét. Lưu ý rằng α chỉ được sử dụng trong quá trình huấn luyện, vì thế nó không ảnh hưởng đến hiệu năng tính toán sau huấn luyện.

7.7.5.2. Công thức dạng ma trận

Cũng tương tự như trường hợp các phương trình mô tả quá trình truyền thẳng qua mạng neuron, các phương trình lan truyền ngược trình bày trong phần trước hết sức phù hợp cho việc minh họa ở mức độ căn bản phương pháp lan truyền ngược hoạt động thế nào, nhưng chúng lại phức tạp khi cài đặt. Trong phần này, chúng ta sẽ trình bày các phương trình ma trận cho quá trình truyền ngược theo cùng trình tự như đã trình bày với quá trình truyền thẳng.

Tương tự như trước, chúng ta bố trí tất cả các vector mẫu thành các cột của ma trận X , và nhóm các trọng số của tầng l thành ma trận $W(l)$. Chúng ta dùng $D(l)$ để ký hiệu dạng ma trận tương đương của $\delta(l)$ hay vector sai số của tầng l . Bước đầu tiên là tìm ra biểu diễn cho $D(L)$. Chúng ta cũng vẫn bắt đầu ở đầu ra và xử lý ngược vào trong mạng. Từ phương trình (7-74) ta có:

$$\delta(L) = \begin{bmatrix} \delta_1(L) \\ \delta_2(L) \\ \vdots \\ \delta_{n_L}(L) \end{bmatrix} = \begin{bmatrix} \frac{\partial E}{\partial a_1(L)} h'(z_1(L)) \\ \frac{\partial E}{\partial a_2(L)} h'(z_2(L)) \\ \vdots \\ \frac{\partial E}{\partial a_{n_L}(L)} h'(z_{n_L}(L)) \end{bmatrix} = \begin{bmatrix} \frac{\partial E}{\partial a_1(L)} \\ \frac{\partial E}{\partial a_2(L)} \\ \vdots \\ \frac{\partial E}{\partial a_{n_L}(L)} \end{bmatrix} \odot \begin{bmatrix} h'(z_1(L)) \\ h'(z_2(L)) \\ \vdots \\ h'(z_{n_L}(L)) \end{bmatrix} \quad (7-82)$$

Trong đó $\odot$ ký hiệu phép nhân theo từng phần tử (của 2 vector trong trường hợp này). Chúng ta có thể viết vector bên vế trái của ký hiệu này là $\partial E / \partial a(L)$, và vector bên phải là $h'(z(L))$. Khi đó chúng ta có thể viết phương trình (7-82) thành:

$$\delta(L) = \frac{\partial E}{\partial a(L)} \odot h'(z(L)) \quad (7-83)$$

Vector cột cỡ $n_L \times 1$ này chứa các giá trị kích hoạt của tất cả các neuron đầu ra cho 1 vector mẫu. Hàm sai số duy nhất chúng ta sử dụng trong chương này là hàm bậc 2, có dạng vector như trong phương trình (7-72). Đạo hàm riêng của hàm này theo $a(L)$ là $(a(L) - r)$ mà khi được thay vào phương trình (7-83) cho ta:

$$\delta(L) = (a(L) - r) \odot h'(z(L)) \quad (7-84)$$

Vector cột $\delta(L)$ ứng với 1 vector mẫu. Để xét hết toàn bộ n_p vector mẫu đồng thời, chúng ta thiết lập ma trận $D(l)$ với các cột của nó là $\delta(L)$ từ phương trình (7-84) tính toán cho 1 vector mẫu nhất định. Điều này tương đương với việc viết phương trình (7-84) trực tiếp dưới dạng ma trận như sau:

$$D(L) = (A(L) - R) \odot h'(Z(L)) \quad (7-85)$$

Mỗi cột của ma trận $A(L)$ là đầu ra của mạng ứng với 1 mẫu. Tương tự như thế, mỗi cột của R là 1 vector nhị phân với giá trị 1 ở vị trí tương ứng với lớp đã được gán của vector mẫu, và 0 ở các vị trí khác như đã quy ước từ trước. Mỗi cột của hiệu $(A(L) - R)$ chứa các thành phần của chuẩn $\|a - r\|$. Do đó bình phương các phần tử của một cột, cộng chúng lại và chia 2 tương đương với tính toán độ đo sai số định nghĩa trong phương trình (7-72), cho 1 mẫu. Cộng tất cả các tính toán theo cột cho 1 đo đặc trưng bình của sai số cho tất cả các mẫu. Tương tự như vậy các cột của ma trận $h'(Z(L))$ là các giá trị của các đầu vào tổng với tất cả

các notron đầu ra, với mỗi cột tương ứng với 1 vector mẫu. Tất cả các ma trận trong phương trình (7-85) có cỡ $n_L \times n_p$.

Lý luận tương tự, chúng ta có thể biểu diễn phương trình (7-77) theo dạng ma trận như sau:

$$\mathbf{D}(\ell) = (\mathbf{W}^T(\ell + 1)\mathbf{D}(\ell + 1)) \odot \mathbf{h}'(\mathbf{Z}(\ell)) \quad (7-86)$$

Có thể dễ dàng xác nhận theo phân tích thứ nguyên rằng ma trận $\mathbf{D}(L)$ là có cỡ $n_l \times n_p$. Lưu ý rằng phương trình (7-86) sử dụng ma trận trọng số chuyển vị. Điều này cho thấy rằng các đầu vào tầng l là từ tầng $l + 1$, vì trong lan truyền ngược quá trình diễn ra ngược với lan truyền thẳng.

Chúng ta sẽ hoàn thành công thức ma trận bằng cách biểu diễn các phương trình cập nhật các tham số trọng số và độ chệch theo dạng ma trận. Trước tiên xét ma trận trọng số, chúng ta có thể dẫn từ các phương trình (7-77) và (7-82) ra các dạng cần thiết của các ma trận $\mathbf{W}(l)$, $\mathbf{D}(l)$ và $\mathbf{A}(l - 1)$. Chúng ta đã biết rằng $\mathbf{W}(l)$ có cỡ $n_l \times n_{l-1}$ và $\mathbf{D}(l)$ có cỡ $n_l \times n_p$. Mỗi cột của ma trận $\mathbf{A}(l - 1)$ là tập các đầu ra của các notron ở tầng $l - 1$ đối với 1 vector mẫu. Có n_p vector mẫu, vì thế $\mathbf{A}(l - 1)$ có cỡ $n_{l-1} \times n_p$. Từ phương trình (7-80), chúng ta suy ra rằng $\mathbf{A}$ nhân bên phải với $\mathbf{D}$, vì thế chúng ta cũng sẽ cần $\mathbf{A}^T(l - 1)$, là ma trận có cỡ $n_p \times n_{l-1}$. Cuối cùng nhắc lại trong công thức ma trận chúng ta xây dựng ma trận $\mathbf{B}(l)$ có cỡ $n_l \times n_p$ với các cột của nó là copy của vector $\mathbf{b}(l)$ chính là vector chứa tất cả các độ chệch ở tầng l .

Tiếp theo chúng ta sẽ xem xét cập nhật độ chệch. Từ phương trình (7-81) chúng ta biết rằng mỗi phần tử $b_i(l)$ của $\mathbf{b}(l)$ được cập nhật theo $b_i(l) = b_i(l) - \alpha \delta_i(l)$ với $i = 1, 2, \dots, n_l$. Do đó $\mathbf{b}(l) = \mathbf{b}(l) - \alpha \boldsymbol{\delta}(l)$. Tuy nhiên công thức này chỉ cho một mẫu, và các cột của $\mathbf{D}(l)$ là $\boldsymbol{\delta}(l)$ cho tất cả các mẫu trong tập huấn luyện. Điều này được xử lý theo công thức ma trận bằng cách dùng trung bình của các cột của $\mathbf{D}(l)$ (chính là sai số trung bình trên toàn bộ các mẫu) để cập nhật $\mathbf{b}(l)$.

Tập hợp lại ta thu nhận được 2 phương trình để cập nhật các tham số mạng gồm:

$$\mathbf{W}(\ell) = \mathbf{W}(\ell) - \alpha \mathbf{D}(\ell) \mathbf{A}^T(\ell - 1) \quad (7-87)$$

và

$$\mathbf{b}(\ell) = \mathbf{b}(\ell) - \alpha \sum_{k=1}^{n_p} \boldsymbol{\delta}_k(\ell) \quad (7-88)$$

Trong đó $\boldsymbol{\delta}_k(l)$ là cột thứ k của ma trận $\mathbf{D}(l)$. Như trước đây, chúng ta thiết lập ma trận $\mathbf{B}(l)$ có cỡ $n_l \times n_p$ bằng cách ghép vector $\mathbf{b}(l)$ n_p lần theo phương ngang:

$$\mathbf{B}(\ell) = \underset{n_p \text{ times}}{\text{concatenate } \{\mathbf{b}(\ell)\}} \quad (7-89)$$

Như vậy, lan truyền ngược bao gồm 4 bước cơ bản: (1) cập các mẫu đầu vào, (2) lan truyền thẳng, (3) lan truyền ngược, và (4) cập nhật tham số. Quá trình bắt đầu bằng việc xác định các trọng số và độ chệch khởi tạo là các giá trị ngẫu nhiên (đủ nhỏ). Bảng dưới đây tổng kết các công thức ma trận của 4 bước đó. Trong quá trình huấn luyện, các bước đó được lặp lại một số lần epoch nhất định, hoặc cho tới khi sai số đạt được là đủ nhỏ.

Bảng 7-2

Công thức dạng ma trận để huấn luyện một mạng notron đa tầng truyền thẳng kết nối đầy đủ. Các bước 1-4 là cho 1 epoch huấn luyện. $\mathbf{X}$, $\mathbf{R}$ và tham số tốc độ học α được cung cấp vào cho huấn luyện mạng. Mạng được khởi tạo bằng việc xác định các trọng số $\mathbf{W}(1)$ và độ chệch $\mathbf{B}(1)$ là các số ngẫu nhiên đủ bé.

Bước	Mô tả	Các phương trình
------	-------	------------------

1	Nhập các mẫu	$A(1) = X$
2	Lan truyền thẳng	Với $l = 2, 3, \dots, L$ tính: $Z(l) = W(l)A(l-1) + B(l)$; $A(l) = h(Z(l))$; $h'(Z(l))$ và $D(L) = (A(L) - R) \odot h'(Z(L))$
3	Lan truyền ngược	Với $l = L-1, L-2, \dots, 2$ tính $D(l) = (W^T(l+1)D(l+1)) \odot h'(Z(l))$
4	Cập nhật trọng số và độ chệch	Với $l = 2, \dots, L$ đặt $W(l) = W(l) - \alpha D(l)A^T(l-1)$, $b(l) = b(l) - \alpha \sum_{k=1}^{n_p} \delta_k(l)$, và $B(l) = \text{concatenate}_{n_p \text{ times}} \{b(l)\}$, trong đó $\delta_k(l)$ là các cột của ma trận $D(l)$.

Có 2 kiểu lỗi chính mà ta cần quan tâm. Thứ nhất là lỗi phân loại, tính toán bằng cách đếm số mẫu bị phân loại sai và chia cho tổng số mẫu trong tập huấn luyện. Nhân kết quả với 100 cho ta phần trăm của mẫu phân loại sai. Nếu lấy 1 trừ đi sai số trên và nhân với 100 sẽ cho ta phần trăm nhận dạng đúng. Sai số còn lại là sai số bình phương trung bình tính toán dựa trên các giá trị thực sự của E . Với sai số được định nghĩa theo phương trình (7-72) giá trị này được tính toán (cho 1 mẫu) bằng cách bình phương các phần tử của 1 cột của ma trận $(A(L) - R)$, cộng lại, và chia kết quả cho 2. Lặp lại tính toán này cho tất cả các cột và chia kết quả cho số mẫu trong X cho ta sai số bình phương trung bình trên toàn bộ tập huấn luyện.


7.8. Các mạng nơtron tích chập sâu

Đến đây chúng ta đã tổ chức các đặc trưng mẫu dưới dạng vector. Nói chung, điều này giả định rằng dạng của những đặc trưng đó đã được xác định (tức là, được "thiết kế" bởi một người thiết kế) và được trích xuất từ hình ảnh trước khi được đưa vào một mạng nơ-ron. Nhưng một trong những thế mạnh của mạng nơ-ron là khả năng học các đặc trưng mẫu trực tiếp từ dữ liệu huấn luyện. Điều chúng ta muốn là đưa vào một tập hình ảnh huấn luyện trực tiếp vào một mạng nơ-ron và để mạng nơ-ron học các đặc trưng cần thiết mà không cần sự can thiệp của con người. Một cách để thực hiện điều này là chuyển đổi ảnh thành vector trực tiếp bằng cách tổ chức các pixel dựa trên một chỉ số tuyến tính, sau đó để mỗi phần tử (pixel) của chỉ số tuyến tính là một phần tử của vector. Tuy nhiên, phương pháp này không tận dụng bất kỳ mối quan hệ không gian nào có thể tồn tại giữa các pixel trong một ảnh, chẳng hạn như sắp xếp các pixel thành các góc, sự xuất hiện của cạnh, và các đặc trưng khác có thể giúp phân biệt một ảnh với ảnh khác. Trong phần này, chúng ta giới thiệu một loại mạng nơ-ron gọi là mạng nơ-ron tích chập sâu (CNNs hoặc ConvNets) có khả năng chấp nhận ảnh làm đầu vào và rất thích hợp cho việc học tự động và phân loại ảnh. Để phân biệt giữa CNNs và các mạng nơ-ron chúng ta đã nghiên cứu ở trên, chúng ta sẽ gọi các mạng đã trình bày ở phần trước là các mạng nơtron "kết nối đầy đủ".

7.8.1. Kiến trúc cơ bản của mạng CNN

Ở đây chúng ta sử dụng một kiến trúc gọi là LeNet để giới thiệu về mạng nơtron tích chập. Có hai lý do chính: thứ nhất, kiến trúc LeNet tương đối đơn giản và dễ hiểu. Điều đó làm cho nó trở nên lý tưởng để giới thiệu các khái niệm cơ bản của CNN. Thứ hai, chúng ta sẽ tập trung thu nhận các phương trình lan truyền ngược cho các mạng tích chập, một điều được đơn giản hóa bởi tính trực quan của LeNets.

CNN trong Hình 7.20 chứa tất cả các yếu tố cơ bản của một kiến trúc LeNet. Chúng ta sử dụng hình này mà vẫn đảm bảo không mất tính tổng quát. Một sự khác biệt chính giữa kiến trúc này và các kiến trúc mạng nơ-ron chúng ta đã tìm hiểu trong phần trước là đầu vào của CNN là các mảng 2-D (ảnh), trong khi đầu vào của mạng nơ-ron kết nối đầy đủ là các vector. Tuy nhiên, chúng ta có thể thấy ngay, các phép toán được thực hiện bởi cả hai mạng là hoàn toàn tương tự và bao gồm: (1) tổng của tích được tạo ra, (2) giá trị độ chệch được bổ sung, (3) kết quả được truyền qua một hàm kích hoạt, và (4) giá trị kích hoạt trở thành đầu vào duy nhất cho tầng tiếp theo.



Hình 7.31 Một mạng CNN chứa đựng tất cả các phần tử cơ bản của kiến trúc LeNet. Các điểm A và B là các giá trị xác định sẽ được xác định sau trong phần này. Các bản đồ đặc trưng tổng hợp – pooled feature map ở cuối được vector hoá và đóng vai trò đầu vào của một mạng nơ-tron kết nối đầy đủ. Lớp mà ảnh đầu vào thuộc về được xác định bởi nơ-tron đầu ra với giá trị cao nhất.

Mặc dù các tính toán được thực hiện bởi CNNs và mạng nơ-ron kết nối đầy đủ là tương tự, có một số sự khác biệt cơ bản giữa chúng, ngoài khác biệt định dạng đầu vào của chúng là mảng 2-D so với vectơ đầu vào của các mạng kết nối đầy đủ. Một sự khác biệt quan trọng là CNNs có khả năng học trực tiếp các đặc trưng 2-D từ dữ liệu ảnh nguyên gốc. Bởi vì không có công cụ nào có thể thiết kế các tập đặc trưng toàn diện cho các nhiệm vụ nhận diện ảnh phức tạp, việc có một hệ thống có thể học các đặc trưng ảnh từ dữ liệu ảnh nguyên gốc là một ưu điểm quan trọng của CNNs. Một sự khác biệt lớn khác nữa là cách các tầng được kết nối với nhau. Trong một mạng nơ-ron kết nối đầy đủ, chúng ta đưa ra đầu ra của mỗi nơ-ron trong một tầng trực tiếp vào đầu vào của mỗi nơ-ron trong lớp tiếp theo. Ngược lại, trong một CNN, chúng ta cấp vào mỗi đầu vào của một tầng một giá trị đơn, được xác định bởi phép tích chập (do đó kiến trúc được gọi là mạng nơ-ron tích chập) trên một lân cận không gian ở đầu ra của tầng trước. Do đó, CNNs không phải là kết nối đầy đủ theo ý nghĩa được xác định trong phần trước. Một khác biệt khác nữa là các mảng 2-D từ một tầng sang tầng tiếp theo được chia nhỏ để giảm độ nhạy cảm đối với các biến thiên tịnh tiến trong đầu vào. Những khác biệt này và ý nghĩa của chúng sẽ trở nên rõ ràng khi chúng ta xem xét các cấu hình CNN khác nhau trong phần tiếp theo.

7.8.1.1. Cơ bản về cách thức làm việc của mạng CNN

Như đã đề cập ở trên, phép xử lý đối với các vùng láng giềng trong ảnh trong mạng CNNs là phép tính tích chập không gian. Phép tính tích chập không gian đã được trình bày trong phần các phép lọc không gian. Như công thức đó cho thấy, tích chập tính tổng của tích giữa các pixel và một tập hợp các trọng số của cửa sổ lọc - filter hay kernel. Thao tác này được thực hiện ở mọi vị trí không gian - pixel trong ảnh đầu vào. Kết quả tích chập tại mỗi vị trí pixel (x, y) của ảnh đầu vào là một giá trị vô hướng. Có thể xem giá trị này như là đầu ra của một nơ-ron trong một tầng của một mạng nơ-ron kết nối đầy đủ. Nếu chúng ta cộng thêm độ chệch và truyền kết quả qua một hàm kích hoạt, chúng ta có một tương tự hoàn chỉnh giữa các phép toán cơ bản được thực hiện bởi một CNN và những phép toán được thực hiện bởi các mạng nơ-ron đã được thảo luận ở phần trước.

Những nhận xét đó đã được tóm tắt trong Hình 7.31, phần bên trái Hình 7.31 hiển thị một vùng láng giềng tại một vị trí pixel trong ảnh đầu vào. Trong thuật ngữ của CNN, những vùng láng giềng này được gọi là trường tiếp nhận – receptive field. Một trường tiếp nhận chọn lựa một vùng pixel trong ảnh đầu vào. Như Hình 7.31 cho thấy, phép toán đầu tiên được thực hiện bởi một CNN là tích chập, giá trị của nó được tạo ra bằng cách di chuyển vùng tiếp nhận trên ảnh và, tại mỗi vị trí, tạo ra một tổng của tích của một bộ trọng số với các pixel tương ứng của ảnh thuộc vùng tiếp nhận. Bộ trọng số, được sắp xếp theo dạng của vùng tiếp nhận, được gọi là kernel tương tự như trong Chương Phép lọc không gian. Số lần

tiền trong không gian mà một vùng tiếp nhận được di chuyển trên ảnh được gọi là bước trượt - stride. Các phép tính tích chập không gian ở các chương trước thường có một bước nhảy là một (chẳng hạn như trong phép lọc trung bình tuyến tính không gian, bước trượt phải bằng 1), nhưng đó không phải là một yêu cầu bắt buộc của các phương trình của mạng CNN. Trong CNNs, có một nhu cầu quan trọng để sử dụng bước trượt lớn hơn 1 là để giảm dữ liệu. Ví dụ, việc thay đổi bước nhảy từ 1 thành 2 làm giảm độ phân giải ảnh một nửa trong mỗi chiều không gian, làm giảm khoảng ba phần tư lượng dữ liệu cho mỗi ảnh. Một yêu cầu quan trọng khác là nó đóng vai trò thay thế cho việc lấy mẫu con - subsampling để giảm độ nhạy cảm của hệ thống đối với tịnh tiến không gian.

Đối với mỗi giá trị tích chập (tổng của tích), chúng ta thêm một độ chệch, sau đó đưa kết quả qua một hàm kích hoạt để tạo ra một giá trị duy nhất. Sau đó, giá trị này được đưa vào vị trí (x, y) tương ứng trong đầu vào của tầng tiếp theo. Khi lặp lại cho tất cả các vị trí trong ảnh đầu vào, quá trình trên cho ta một bộ giá trị 2-D mà chúng ta lưu trữ trong tầng tiếp theo dưới dạng một mảng 2-D, gọi là một bản đồ đặc trưng - feature map. Thuật ngữ này bắt nguồn từ thực tế rằng vai trò của tích chập trong xử lý ảnh là trích xuất các đặc trưng như cạnh, điểm và vùng (lưu ý tích chập là cơ sở của bộ lọc không gian sử dụng để làm mịn, làm sắc, và phát hiện cạnh, biên v.v. trong một ảnh). Cùng một bộ trọng số và một độ chệch được sử dụng để tạo ra các giá trị tích chập (hay bản đồ đặc trưng) tương ứng với tất cả các vị trí của vùng tiếp nhận trong ảnh đầu vào. Điều này được thực hiện để làm cho cùng một đặc trưng (hay các đặc trưng giống nhau) sẽ được phát hiện tại tất cả các điểm trong ảnh. Việc sử dụng cùng một bộ trọng số và độ chệch cho mục đích này được gọi là chia sẻ trọng số (hoặc tham số) - weight sharing.

Hình 7.31 cho thấy ba bản đồ đặc trưng trong tầng đầu tiên của mạng. Hai bản đồ đặc trưng khác được tạo ra theo cùng cách ở trên, nhưng sử dụng một bộ trọng số và độ chệch khác nhau cho mỗi bản đồ đặc trưng. Vì mỗi bộ trọng số và độ chệch là khác nhau, nên mỗi bản đồ đặc trưng thường sẽ chứa một bộ đặc trưng khác nhau, tất cả đều được trích xuất từ cùng một ảnh đầu vào. Các bản đồ đặc trưng tạo nên một tầng tích chập. Do đó, mạng CNN trong Hình 7.31 có hai tầng tích chập.

Quá trình sau khi tích chập và kích hoạt là phép lấy mẫu con (còn được gọi là tổng hợp - pooling), được đề xuất dựa trên các nghiên cứu của mô hình của vỏ não thị giác. Các kết quả của họ gợi ý rằng một số phần của vỏ não thị giác bao gồm các tế bào đơn giản và phức tạp. Các tế bào đơn giản thực hiện trích xuất đặc trưng, trong khi các tế bào phức tạp kết hợp (tổng hợp) những đặc trưng đó thành một tổng thể có ý nghĩa hơn. Trong mô hình này, giảm độ phân giải không gian đóng vai trò để đạt được tính bất biến theo chuyển vị. Tổng hợp là một cách mô hình hóa thao tác giảm chiều của dữ liệu. Khi huấn luyện một mạng CNN với các cơ sở dữ liệu ảnh lớn, phép tổng hợp có lợi thế bổ sung làm giảm dung lượng dữ liệu được xử lý. Chúng ta có thể xem kết quả của việc lấy mẫu con như là việc tạo ra các bản đồ đặc trưng tổng hợp. Nói cách khác, một bản đồ đặc trưng tổng hợp là một bản đồ đặc trưng có độ phân giải không gian giảm đi. Lấy mẫu con được thực hiện bằng cách chia một bản đồ đặc trưng thành một tập hợp các vùng nhỏ (thường có cỡ 2×2), gọi là vùng láng giềng tổng hợp, và thay thế tất cả các phần tử trong một vùng như vậy bằng một giá trị duy nhất. Chúng ta giả sử rằng các vùng láng giềng tổng hợp là kề nhau (tức là chúng không chồng lấn nhau). Có một số cách để tính toán các giá trị tổng hợp; tập hợp các phương pháp khác nhau được gọi là phương pháp tổng hợp. Ba phương pháp tổng hợp phổ biến là: (1) tổng hợp trung bình, trong đó các giá trị trong mỗi vùng láng giềng được thay thế bằng giá trị trung bình trong vùng đó; (2) tổng hợp cực đại, thay thế các giá trị trong một vùng bằng giá trị lớn nhất của các phần tử trong vùng; và (3) tổng hợp L_2 , trong đó giá trị tổng hợp kết quả là căn bậc hai của tổng bình phương các giá trị trong vùng. Kết quả thu được là một bản đồ đặc trưng được tổng hợp cho mỗi bản đồ đặc trưng. Các bản đồ đặc trưng tổng hợp được gọi chung là tầng

lấy mẫu. Trong Hình 7.31, chúng ta đã sử dụng kernel tổng hợp 2×2 do đó mỗi bản đồ tổng hợp kết quả là một phần tư kích thước của bản đồ đặc trưng ban đầu. Việc sử dụng vùng tiếp nhận, tích chập, chia sẻ tham số và tổng hợp là các đặc trưng độc đáo của mạng CNN.

Do các bản đồ đặc trưng là kết quả của phép lọc không gian, chúng đơn giản là các ảnh lọc. Như vậy thì các bản đồ đặc trưng tổng hợp sẽ là các ảnh lọc ở độ phân giải thấp hơn. Hình 7.31 minh họa quá trình các bản đồ đặc trưng tổng hợp ở tầng đầu tiên trở thành đầu vào của tầng tiếp theo trong mạng. Lưu ý ở đây chúng ta có 1 ảnh mẫu đơn đầu vào cho tầng đầu tiên, chúng ta thu được nhiều hơn 1 bản đồ đặc trưng tổng hợp (hay chính là các ảnh lọc) làm đầu vào cho tầng tiếp theo.

Để thấy làm thế nào các đầu vào đó được xử lý ở tầng thứ 2, đầu tiên chúng ta xem xét 1 bản đồ đặc trưng tổng hợp ở tầng 1. Để tạo ra các giá trị cho tính toán bản đồ đặc trưng đầu tiên của tầng tích chập thứ 2, cũng như ở trên, chúng ta thực hiện tích chập, cộng độ lệch và dùng hàm kích hoạt. Tiếp theo chúng ta thay đổi kernel và độ lệch và lặp lại quá trình cho bản đồ đặc trưng thứ 2 (lưu ý là ở tầng 2), lưu ý vẫn dùng cùng 1 bản đồ đặc trưng tổng hợp đầu vào từ tầng thứ nhất. Chúng ta làm như vậy cho tất cả các bản đồ đặc trưng còn lại (ở tầng đang xét – tầng 2). Thay đổi trọng số của kernel và độ lệch cho từng bản đồ. Sau đó chúng ta sẽ xét đến bản đồ đặc trưng tổng hợp tiếp theo đầu vào (ở tầng 1) và thực hiện quá trình hoàn toàn tương tự (tích chập, cộng độ lệch, kích hoạt) cho mỗi bản đồ đặc trưng của tầng thứ 2, sử dụng một tập khác của các kernel và các độ lệch. Khi chúng ta kết thúc, chúng ta sẽ sinh ra 3 giá trị cho cùng một vị trí ở mỗi bản đồ đặc trưng tầng 2, với 1 giá trị thu được từ vị trí tương ứng ở 1 trong 3 bản đồ đặc trưng tổng hợp từ đầu vào (từ tầng 1). Câu hỏi bây giờ là: làm thế nào chúng ta kết hợp 3 giá trị riêng rẽ thành 1 giá trị cho tầng 2 (tổng hợp cho vị trí B trong Hình 7.31)? Câu trả lời nằm ở thực tế rằng tích chập là một quá trình tuyến tính, từ đó ta biết rằng, 3 giá trị riêng biệt được kết hợp làm 1 bằng cách cộng gộp.

Ở tầng đầu tiên, chúng ta có 1 ảnh đầu vào và 3 bản đồ đặc trưng, vì thế chúng ta cần 3 kernel để hoàn thành tất cả các tích chập cần thiết. Ở tầng thứ 2, chúng ta có 3 đầu vào và 7 bản đồ đặc trưng, vì thế tổng số kernel (và độ lệch) cần thiết là $3 \times 7 = 21$. Mỗi bản đồ đặc trưng được tổng hợp cho ta 1 bản đồ đặc trưng tổng hợp, kết quả là có 7 bản đồ đặc trưng tổng hợp. Trong Hình 7.31, mạng CNN chỉ có 2 tầng, vì thế 7 bản đồ đặc trưng tổng hợp đó là các đầu ra của tầng cuối cùng.

Như trước, mục tiêu cuối của chúng ta là dùng các đặc trưng để phân loại, vì thế chúng ta cần 1 bộ phân loại. Theo Hình 7.31, trong 1 mạng CNN chúng ta thực hiện phân loại bằng cách đưa giá trị của tầng tổng hợp cuối cùng vào một mạng nơtron liên kết đầy đủ như đã trình bày trong phần trước. Tuy nhiên đầu ra của một mạng CNN là các mảng 2 chiều (chính là các ảnh lọc có độ phân giải đã giảm cấp) trong khi đầu vào của 1 mạng kết nối đầy đủ lại là các vector. Vì thế chúng ta cần phải vector hoá các bản đồ đặc trưng tổng hợp 2 chiều ở tầng cuối. Chúng ta thực hiện điều này sử dụng phép đánh chỉ số tuyến tính. Mỗi mảng 2 chiều ở tầng cuối cùng được chuyển đổi thành 1 vector, sau đó tất cả các vector kết quả được nối với nhau (theo chiều đứng để tạo ra 1 cột) để tạo thành 1 vector đơn. Vector này lan truyền qua mạng nơtron, như đã giải thích ở các phần trước. Trong bất kỳ 1 ứng dụng nào đó cho trước, số lượng đầu ra trong một mạng kết nối đầy đủ là bằng số lượng các lớp đang được phân loại. Cũng như ở phần trước, đầu ra với giá trị cao nhất xác định lớp của đầu vào.

7.8.1.2. Các tính toán của nơtron trong một mạng CNN

Tính toán cơ bản một nơtron nhân tạo thực hiện là phép tổng tích giữa các trọng số và các giá trị từ tầng trước. Chúng ta cộng thêm độ lệch và gọi kết quả là đầu vào tổng – net input (hay total) vào nơtron đó mà chúng ta ký hiệu là z_i . Như trong phương trình (7-61), tổng liên quan đến việc tính toán z_i là một tổng đơn. Các tính toán được thực hiện trong một mạng

CNN tạo ra 1 giá trị đơn trong một bản đồ đặc trưng là phép tích chập 2-D. Đây lại là một phép tổng kép giữa các hệ số của 1 kernel và các phần tử tương ứng của mảng ảnh tương ứng nằm dưới kernel tại vị trí đang xét. Đặt w là một kernel tạo nên bằng cách bố trí các trọng số theo dạng của trường tiếp nhận. Đặt $a_{x,y}$ ký hiệu ảnh hay các giá trị đặc trưng tổng hợp phụ thuộc vào tầng. Giá trị tích chập ở bất kỳ vị trí (x,y) nào trên đầu vào được cho bởi:

$$w \star a_{x,y} = \sum_l \sum_k w_{l,k} a_{x-l,y-k} \quad (7-90)$$

Trong đó l và k thay đổi theo kích thước của kernel. Giả thiết rằng w có cỡ 3×3 . Khi đó phương trình trên có dạng chi tiết như sau:

$$\begin{aligned} w \star a_{x,y} &= w \star a_{x,y} = \sum_l \sum_k w_{l,k} a_{x-l,y-k} \\ &= w_{1,1} a_{x-1,y-1} + w_{1,2} a_{x-1,y-2} + \dots + w_{3,3} a_{x-3,y-3} \end{aligned} \quad (7-91)$$

Chúng ta có thể viết lại chỉ số dưới của w và a , và viết như sau:

$$\begin{aligned} w \star a_{x,y} &= w_1 a_1 + w_2 a_2 + \dots + w_9 a_9 \\ &= \sum_{i=1}^9 w_i a_i \end{aligned} \quad (7-92)$$

Nếu cộng thêm độ chệch và gọi z là kết quả ta có:

$$\begin{aligned} z &= \sum_{j=1}^9 w_j a_j + b \\ &= w \star a_{x,y} + b \end{aligned} \quad (7-93)$$

Dòng đầu của phương trình này hoàn toàn tương tự phương trình (7-61). Do đó khi cộng thêm độ chệch vào kết quả tính tích chập tính toán bởi mạng CNN tại vị trí (x,y) cố định bất kỳ trong đầu vào, kết quả có thể được biểu diễn dưới dạng hoàn toàn tương tự với kết quả tính bởi một notron nhân tạo trong một mạng notron kết nối đầy đủ. Chúng ta chỉ dùng x, y để minh họa việc phép toán đang được thực hiện trong miền 2-D. Nếu chúng ta xem z là đầu vào tổng của một notron, sự tương đồng với các notron đã thảo luận trước đây là đầy đủ khi truyền z qua hàm kích hoạt h để thu nhận đầu ra của notron:

$$a = h(z) \quad (7-94)$$

Đây chính xác là cách mà giá trị của bất kỳ điểm nào (ví dụ như điểm có nhãn A trong Hình 7.31) trên bản đồ đặc trưng được tính toán.

Bây giờ xem xét điểm B trong hình, giá trị của nó được cho bởi việc cộng 3 phương trình tích chập như sau:

$$\begin{aligned} w_{l,k}^{(1)} \star a_{x,y}^{(1)} + w_{l,k}^{(2)} \star a_{x,y}^{(2)} + w_{l,k}^{(3)} \star a_{x,y}^{(3)} &= \sum_l \sum_k w_{l,k}^{(1)} a_{x-l,y-k}^{(1)} + \\ &\quad \sum_l \sum_k w_{l,k}^{(2)} a_{x-l,y-k}^{(2)} + \sum_l \sum_k w_{l,k}^{(3)} a_{x-l,y-k}^{(3)} \end{aligned} \quad (7-95)$$

Trong đó chỉ số dưới chỉ 3 bản đồ đặc trưng tổng hợp trong Hình 7.31. Các giá trị l, k, x và y là giống nhau trong cả 3 phương trình do tất cả 3 kernel là cùng kích cỡ và chúng dịch chuyển theo nhau. Chúng ta có thể mở rộng phương trình này và thu nhận một tổng của các tích dài hơn cho điểm A trong Hình 7.31 nhưng vẫn có thể viết lại tất cả các thành phần và nhận được một tổng tích mà chỉ liên quan đến phép tổng, một cách chính xác như trước.

Kết quả trên cho ta thấy rằng các phương trình được sử dụng để thu nhận giá trị của một

phần tử trên bất kỳ bản đồ đặc trưng nào của mạng CNN có thể được biểu diễn theo dạng của tính toán thực hiện bởi một neuron nhân tạo. Điều này đúng cho bất kỳ bản đồ đặc trưng nào, không quan trọng có bao nhiêu tích chập liên quan đến trong quá trình tính toán các phần tử của bản đồ đặc trưng đó, mà đơn giản là nếu có nhiều tích chập thì chúng ta làm việc với nhiều tổng tích chập hơn. Ý nghĩa là chúng ta có thể sử dụng dạng cơ bản của các phương trình 7-93 và 7-94 để mô tả cách thức làm thế nào giá trị của một phần tử trong bất kỳ bản đồ đặc trưng nào của một mạng CNN được thu nhận. Điều này có nghĩa là chúng ta không cần phải xem xét cụ thể số lượng của các bản đồ đặc trưng tổng hợp khác nhau (và do đó là số lượng của kernel khác nhau) được sử dụng trong tầng tổng hợp. Kết quả là sự đơn giản hoá đáng kể của các phương trình mô tả quá trình lan truyền thẳng và lan truyền ngược trong một mạng CNN.

7.8.1.3. Nhiều ảnh đầu vào

Các giá trị $a_{x,y}$ ở trên là các giá trị theo pixel trong tầng đầu tiên nhưng trong các tầng tiếp theo $a_{x,y}$ ký hiệu các giá trị của các đặc trưng tổng hợp. Tuy nhiên các phương trình của chúng ta không phân biệt nhau dựa trên cái mà các biến đó thực sự biểu diễn. Ví dụ, giả sử chúng ta thay thế đầu vào ở Hình 7.31 với 3 ảnh, chẳng hạn 3 thành phần của 1 ảnh RGB. Các phương trình tính toán giá trị của điểm A trong hình bây giờ có dạng giống với các phương trình chúng ta viết cho điểm B – chỉ có các trọng số và độ chệch là thay đổi. Do đó các kết quả trong phần trước đối với 1 ảnh đầu vào là áp dụng được trực tiếp cho trường hợp nhiều ảnh đầu vào. Chúng ta sẽ đưa ra một ví dụ một mạng CNN với 3 ảnh đầu vào trong phần tiếp theo.

7.8.2. Các phương trình lan truyền thẳng trong một mạng CNN

Chúng ta đã thu nhận được từ phần trước kết quả tích chập một kernel w và 1 mảng đầu vào với các giá trị $a_{x,y}$ như sau:

$$\begin{aligned} z_{x,y} &= \sum_l \sum_k w_{l,k} a_{x-l,y-k} + b \\ &= w \star a_{x,y} + b \end{aligned} \quad (7-96)$$

Trong đó l và k là chỉ số chạy theo các chiều của kernel, x và y là các chỉ số chạy theo các chiều của đầu vào; b là độ chệch. Giá trị tương ứng của $a_{x,y}$ là:

$$a_{x,y} = h(z_{x,y}) \quad (7-97)$$

Tuy nhiên $a_{x,y}$ ở đây khác với giá trị được sử dụng trong tính toán phương trình 7-96, trong đó $a_{x,y}$ biểu diễn các giá trị từ tầng trước. Do đó chúng ta cần ký hiệu bổ sung để phân biệt giữa các tầng. Tương tự như trong các mạng neuron kết nối đầy đủ, chúng ta sử dụng l cho mục đích này và viết phương trình 7-96 và 7-97 dưới dạng sau:

$$\begin{aligned} z_{x,y}(\ell) &= \sum_l \sum_k w_{l,k}(\ell) a_{x-l,y-k}(\ell-1) + b(\ell) \\ &= w(\ell) \star a_{x,y}(\ell-1) + b(\ell) \end{aligned} \quad (7-98)$$

và

$$a_{x,y}(\ell) = h(z_{x,y}(\ell)) \quad (7-99)$$

Với $l = 1, 2, \dots, L_c$ trong đó L_c là số các tầng tích chập, và $a_{x,y}(l)$ ký hiệu các giá trị của đặc trưng tổng hợp của tầng tích chập l . Khi $l = 1$ ta có:

$$a_{x,y}(0) = \{\text{các giá trị pixel trong ảnh (các ảnh) vào}\} \quad (7-100)$$

Khi $l = L_c$:

$$a_{x,y}(L_c) = \{\text{các giá trị của các đặc trưng tổng hợp của tầng cuối cùng của}\} \quad (7-101)$$

mạng CNN}

Chú ý rằng l bắt đầu từ 1 thay vì 2 như trong phần mạng notron sâu. Lý do là vì chúng ta sẽ đặt tên các tầng là tầng tích chập l . Vì thế sẽ rất khó hiểu khi l bắt đầu từ 2. Cuối cùng chúng ta lưu ý rằng phép tổng hợp – pooling không yêu cầu tính tích chập. Hàm duy nhất của phép tổng hợp là làm giảm số chiều không gian của bản đồ đặc trưng trước nó, vì thế chúng ta không cần viết dạng hiện của các phương trình tổng hợp ở đây.

Các phương trình từ 7-98 đến 7-101 là tất cả những phương trình chúng ta cần để tính toán tất cả các giá trị trong bước lan truyền thẳng thông qua phân tích chập của một mạng CNN. Như mô tả trong Hình 7.31, các giá trị của các đặc trưng tổng hợp của tầng cuối cùng được vector hoá và đưa vào mạng notron lan truyền thẳng kết nối đầy đủ, mà quá trình lan truyền thẳng của các mạng như vậy đã được giải thích trong các phương trình từ 7-61 và 7-62 hoặc ở dạng ma trận trong **Bảng 7-1**.

7.8.3. Các phương trình lan truyền ngược trong huấn luyện mạng CNN

Như trong phần trước, các phương trình lan truyền thẳng của mạng CNN là tương tự với các phương trình của mạng notron kết nối đầy đủ, nhưng với phép nhân tổng tích thay thế bằng phép tích chập, và với dạng ký hiệu phản ánh bản chất rằng CNN không mang nghĩa kết nối đầy đủ kiểu như mạng notron sâu thông thường. Chúng ta sẽ thấy trong phần này các phương trình lan truyền ngược của mạng CNN cũng sẽ tương tự theo nhiều khía cạnh với các mạng notron kết nối đầy đủ.

Tương tự như thu nhận quá trình lan truyền ngược với mạng notron kết nối đầy đủ trước đây, chúng ta bắt đầu với việc xác định sai số đầu ra của mạng CNN thay đổi như thế nào theo mỗi notron trong mạng. Dạng của sai số vẫn giống như với các mạng notron kết nối đầy đủ, nhưng ở đây nó là hàm của x và y thay vì j :

$$\delta_{x,y}(\ell) = \frac{\partial E}{\partial z_{x,y}(\ell)} \quad (7-102)$$

Như trong phần lan truyền ngược của mạng notron kết nối đầy đủ, chúng ta liên kết đại lượng này với $\delta_{xy}(l + 1)$, sử dụng quy tắc chuỗi:

$$\delta_{x,y}(\ell) = \frac{\partial E}{\partial z_{x,y}(\ell)} = \sum_u \sum_v \frac{\partial E}{\partial z_{u,v}(\ell + 1)} \frac{\partial z_{u,v}(\ell + 1)}{\partial z_{x,y}(\ell)} \quad (7-103)$$

Trong đó u và v là 2 biến bất kỳ của tổng theo miền giá trị của z .

Theo định nghĩa, số hạng đầu tiên của tổng kép trong phương trình (7-103) chính là $\delta_{xy}(l + 1)$. Vì thế chúng ta có thể viết lại phương trình (7-103) như sau:

$$\delta_{x,y}(\ell) = \frac{\partial E}{\partial z_{x,y}(\ell)} = \sum_u \sum_v \delta_{u,v}(\ell + 1) \frac{\partial z_{u,v}(\ell + 1)}{\partial z_{x,y}(\ell)} \quad (7-104)$$

Thay thế phương trình (7-99) vào (7-98) và sử dụng $z_{u,v}$ thu được vào phương trình (7-104) ta có:

$$\delta_{x,y}(\ell) = \sum_u \sum_v \delta_{u,v}(\ell + 1) \frac{\partial}{\partial z_{x,y}(\ell)} \left[\sum_l \sum_k w_{l,k}(\ell + 1) h(z_{u-l,v-k}(\ell)) + b(\ell + 1) \right] \quad (7-105)$$

Đạo hàm của biểu thức bên trong ngoặc vuông là bằng 0 trừ khi $u - l = x$ và $v - k = y$, và do đạo hàm của $b(l + 1)$ theo $z_{x,y}(l)$ là bằng 0, phương trình (7-105) có thể được viết lại dưới dạng:

$$\delta_{x,y}(\ell) = \sum_u \sum_v \delta_{u,v}(\ell+1) \left[\sum_{u-x} \sum_{v-y} w_{u-x,v-y}(\ell+1) h'(z_{x,y}(\ell)) \right] \quad (7-106)$$

Các giá trị của x, y, u và v được xác định bên ngoài các số hạng bên trong ngoặc vuông. Một khi các giá trị của các biến đó được cố định, $u-x$ và $v-y$ bên trong ngoặc sẽ là 2 hằng số. Do đó tổng kép sẽ trở thành $w_{u-x,v-y}(\ell+1)h'(z_{x,y}(\ell))$ và chúng ta có thể viết phương trình (7-106) thành:

$$\begin{aligned} \delta_{x,y}(\ell) &= \sum_u \sum_v \delta_{u,v}(\ell+1) w_{u-x,v-y}(\ell+1) h'(z_{x,y}(\ell)) \\ &= h'(z_{x,y}(\ell)) \sum_u \sum_v \delta_{u,v}(\ell+1) w_{u-x,v-y}(\ell+1) \end{aligned} \quad (7-107)$$

Biểu thức tổng kép ở dòng thứ 2 của phương trình (7-107) có dạng tích chập, nhưng chỉ số ngược dấu so với tích chập trong phương trình (7-98). Chúng ta có thể viết lại (7-107) như sau:

$$\delta_{x,y}(\ell) = h'(z_{x,y}(\ell)) [\delta_{x,y}(\ell+1) \star w_{-x,-y}(\ell+1)] \quad (7-108)$$

Dấu âm trong chỉ số cho thấy rằng w được lấy đối xứng theo cả 2 tọa độ. Điều này tương tự với việc quay w một góc 180 độ. Sử dụng kết quả này, chúng ta cuối cùng đại diện đến biểu thức tính toán sai số ở tầng l bằng cách viết lại phương trình (7-108) tương đương như sau:

$$\delta_{x,y}(\ell) = h'(z_{x,y}(\ell)) [\delta_{x,y}(\ell+1) \star \text{rot180}(w_{x,y}(\ell+1))] \quad (7-109)$$

Do các kernel không phụ thuộc vào x và y nên chúng ta có thể viết phương trình này thành:

$$\delta_{x,y}(\ell) = h'(z_{x,y}(\ell)) [\delta_{x,y}(\ell+1) \star \text{rot180}(w(\ell+1))] \quad (7-110)$$

Như trước đây, mục tiêu cuối cùng của chúng ta là tính toán thay đổi của E theo các trọng số và độ chệch. Theo cùng một cách làm chúng ta thu được:

$$\begin{aligned} \frac{\partial E}{\partial w_{l,k}} &= \sum_x \sum_y \frac{\partial E}{\partial z_{x,y}(\ell)} \frac{\partial z_{x,y}(\ell)}{\partial w_{l,k}} \\ &= \sum_x \sum_y \delta_{x,y}(\ell) \frac{\partial z_{x,y}(\ell)}{\partial w_{l,k}} \\ &= \sum_x \sum_y \delta_{x,y}(\ell) \frac{\partial}{\partial w_{l,k}} \left[\sum_l \sum_k w_{l,k}(\ell) h(z_{x-l,y-k}(\ell-1)) + b(\ell) \right] \\ &= \sum_x \sum_y \delta_{x,y}(\ell) h(z_{x-l,y-k}(\ell-1)) \\ &= \sum_x \sum_y \delta_{x,y}(\ell) a_{x-l,y-k}(\ell-1) \end{aligned} \quad (7-111)$$

Trong đó dòng cuối cùng được suy ra từ (7-99). Dòng này có dạng tích chập nhưng so sánh với (7-98) thì có đảo ngược dấu giữa các biến tổng và chỉ số tương ứng của chúng. Để biến nó thành dạng tích chập, chúng ta viết lại dòng cuối như sau:

$$\begin{aligned} \frac{\partial E}{\partial w_{l,k}} &= \sum_x \sum_y \delta_{x,y}(\ell) a_{-(l-x), -(k-y)}(\ell-1) \\ &= \delta_{l,k}(\ell) \star a_{-l,-k}(\ell-1) \\ &= \delta_{l,k}(\ell) \star \text{rot180}(a(\ell-1)) \end{aligned} \quad (7-112)$$

Tương tự như vậy:

$$\frac{\partial E}{\partial b(\ell)} = \sum_x \sum_y \delta_{x,y}(\ell) \quad (7-113)$$

Sử dụng 2 biểu thức trước đây trong phương trình tính toán gradient descent ta có:

$$\begin{aligned} w_{l,k}(\ell) &= w_{l,k}(\ell) - \alpha \frac{\partial E}{\partial w_{l,k}} \\ &= w_{l,k}(\ell) - \alpha \delta_{l,k}(\ell) \star \text{rot180}(a(\ell - 1)) \end{aligned} \quad (7-114)$$

và

$$\begin{aligned} b(\ell) &= b(\ell) - \alpha \frac{\partial E}{\partial b(\ell)} \\ &= b(\ell) - \alpha \sum_x \sum_y \delta_{x,y}(\ell) \end{aligned} \quad (7-115)$$

Các phương trình (7-114) và (7-115) tính toán cập nhật các trọng số và độ chệch của mỗi tầng tích chập trong một mạng CNN. Như đã nói ở trước, $w_{l,k}$ biểu diễn tất cả các trọng số của 1 tầng. Các biến l và k thay đổi trong các kernel 2-D có cùng kích cỡ.

Trong bước truyền thẳng, chúng ta đi từ một tầng tích chập đến 1 tầng tổng hợp. Trong bước truyền ngược, chúng ta đi theo chiều ngược lại. Nhưng các bản đồ đặc trưng tổng hợp là bé hơn các bản đồ đặc trưng tương ứng. Do đó khi đi theo hướng ngược lại chúng ta phải thực hiện thao tác ngược với lấy mẫu con (subsample) hay được gọi là thao tác unsample (chính là bằng cách lặp lại các pixel) trên mỗi bản đồ đặc trưng tổng hợp để làm cho phù hợp với kích cỡ của bản đồ đặc trưng sinh ra nó. Mỗi bản đồ đặc trưng tổng hợp tương ứng với một bản đồ đặc trưng duy nhất, do đó hướng đi ngược là hoàn toàn xác định.

Theo Hình 7.31, lan truyền ngược bắt đầu ở đầu ra của mạng notron kết nối đầy đủ. Chúng ta đã xây dựng từ trước quá trình cập nhật các tham số của dạng mạng này. Khi chúng ta đến chỗ chuyển tiếp giữa mạng notron và mạng CNN, chúng ta phải đảo ngược phương pháp vector hoá sử dụng để sinh ra các vector đầu vào cho mạng notron. Chính là trước khi chúng ta thực hiện lan truyền ngược sử dụng phương trình (7-114) và (7-115) chúng ta phải tái sinh – regenerate các bản đồ đặc trưng tổng hợp riêng rẽ từ một vector đơn thu nhận được từ quá trình lan truyền ngược ở phần mạng notron kết nối đầy đủ.

Chúng ta tổng kết trong bảng 7-3 các bước để thực hiện lan truyền ngược cho mạng CNN trong Hình 7.31. Quá trình được lặp lại một số lần epoch hoặc cho đến khi sai số đầu ra của mạng notron đạt đến giá trị chấp nhận được. Sai số được tính toán chính xác như chúng ta đã làm với mạng notron kết nối đầy đủ. Có thể sử dụng sai số bình phương trung bình hoặc sai số nhận dạng. Lưu ý rằng các trọng số $w(l)$ và độ chệch $b(l)$ là khác nhau đối với mỗi bản đồ đặc trưng trong tầng l .

Bảng 7-3

Các bước cơ bản để huấn luyện mạng CNN. Mạng được khởi tạo với một tập các trọng số và độ chệch ngẫu nhiên nhỏ. Trong lan truyền ngược, chúng ta thu được 1 vector (từ mạng notron kết nối đầy đủ) ở tầng tổng hợp đầu ra của mạng CNN. Vector này phải được chuyển đổi thành các mảng 2-D có cùng kích cỡ như các bản đồ đặc trưng của tầng đó. Mỗi bản đồ đặc trưng tổng hợp được unsample để phù hợp cỡ với bản đồ đặc trưng tương ứng đã tạo ra nó. Các bước trong bảng được trình bày cho huấn luyện qua 1 epoch.

Bước	Mô tả	Các phương trình
1	Nhập ảnh	$a(0)$ = tập các pixel ảnh trong đầu vào tầng 1
2	Truyền thẳng	Với mỗi notron tương ứng với vị trí (x,y) trong mỗi bản đồ đặc trưng của tầng l , tính:

		$z_{x,y}(\ell) = w(\ell) \star a_{x,y}(\ell - 1) + b(\ell)$ and $a_{x,y}(\ell) = h(z_{x,y}(\ell)); \ell = 1, 2, \dots, L_c$
3	Lan truyền ngược	Với mỗi notron trong mỗi bản đồ đặc trưng ở tầng l , tính: $\delta_{x,y}(\ell) = h'(z_{x,y}(\ell))[\delta_{x,y}(\ell + 1) \star \text{rot180}(w(\ell + 1))]; \ell = L_c - 1, L_c - 2, \dots, 1$
4	Cập nhật (tính) tham số	Cập nhật các trọng số và độ chệch của mỗi bản đồ đặc trưng theo phương trình: $w_{l,k}(\ell) = w_{l,k}(\ell) - \alpha \delta_{l,k}(\ell) \star \text{rot180}(a(\ell - 1))$ and $b(\ell) = b(\ell) - \alpha \sum_x \sum_y \delta_{x,y}(\ell); \ell = 1, 2, \dots, L_c$

7.9. Một số chi tiết bổ sung về cài đặt các phương pháp

Như chúng ta đã đề cập trong phần trước, các mạng nơ-ron (bao gồm cả mạng tích chập) có khả năng học các đặc trưng trực tiếp từ dữ liệu huấn luyện, giảm thiểu nhu cầu về các đặc trưng được thiết kế, chế tác - engineered. Mặc dù điều này là một ưu điểm đáng kể, nhưng không phải là thiết kế của một mạng nơ-ron không đòi hỏi can thiệp của con người. Ngược lại, việc thiết kế các mạng nơ-ron phức tạp có chất lượng, hiệu năng cao hết sức đòi hỏi kỹ năng và thử nghiệm đáng kể.

Trong hai phần trước, chúng ta tập trung vào việc phát triển các khái niệm cơ bản trong mạng notron, vào lý thuyết cơ bản cho lan truyền ngược - backpropagation cho cả mạng kết nối đầy đủ và mạng tích chập. Lan truyền ngược là cốt lõi của việc thiết kế mạng notron, nhưng cũng còn có nhiều vấn đề quan trọng khác ảnh hưởng đến khả năng học của một mạng nơ-ron và sau đó tổng quát hóa cho các mẫu mà nó chưa từng gặp trước đó. Ở phần này, chúng ta sẽ trình bày ngắn gọn về một số khía cạnh quan trọng trong việc thiết kế mạng nơ-ron kết nối đầy đủ và mạng tích chập.

Một trong những câu hỏi đầu tiên khi thiết kế kiến trúc của mạng nơ-ron là phải xác định bao nhiêu tầng cho mạng. Lý thuyết định lý xấp xỉ toàn cục cho chúng ta biết rằng, dưới điều kiện thông thường, hàm quyết định với độ phức tạp bất kỳ có thể được xấp xỉ bằng một mạng nơ-ron truyền thẳng liên tục với một tầng ẩn duy nhất. Mặc dù định lý không cho chúng ta biết cách tính các tham số của tầng ẩn duy nhất đó, nhưng nó cho thấy rằng các mạng nơ-ron có cấu trúc đơn giản có thể rất hiệu quả. Chúng ta đã thấy điều này trong một số ví dụ trong hai phần trước. Bằng chứng thực nghiệm cho thấy rằng các mạng nơ-ron sâu (tức là mạng với hai hoặc nhiều tầng ẩn) tốt hơn so với mạng chỉ có một tầng ẩn trong việc học các dạng biểu diễn trừu tượng, mà thường đó chính là mục đích chính của quá trình học với mạng notron. Không có thuật toán nào xác định số tầng "tối ưu" để sử dụng trong một mạng nơ-ron. Do đó, việc xác định số lượng tầng thường được xác định bởi sự kết hợp giữa kinh nghiệm và thử nghiệm. "Bắt đầu nhỏ - starting small" là một cách tiếp cận hợp lý cho vấn đề này. Càng có nhiều tầng mạng, khả năng bài toán lan truyền ngược gặp phải vấn đề triệt tiêu gradient - vanishing gradient, hiện tượng gradient quá nhỏ làm cho phương pháp gradient descent không còn hiệu quả. Trong các mạng tích chập, chúng ta phải đối mặt thêm vấn đề là kích thước của đầu vào giảm đi khi ảnh truyền qua mạng. Có hai nguyên nhân cho điều này. Nguyên nhân đầu tiên là do việc giảm kích thước tự nhiên do quá trình tích chập, với lượng giảm phụ thuộc vào kích thước của vùng tiếp nhận - receptive field. Một giải pháp là bổ sung thêm biên ảnh trước khi thực hiện các phép tích chập, như đã giới thiệu trước đây. Nguyên nhân thứ hai (và quan trọng nhất) của việc giảm kích thước là phép tổng hợp - pooling. Kích thước tối thiểu của vùng tổng hợp - pooling là 2×2 , làm giảm kích thước của các bản đồ đặc trưng đi ba phần tư ở mỗi tầng. Một giải pháp hữu ích là tăng kích thước của ảnh đầu vào, nhưng điều này phải được thực hiện cẩn thận vì kích thước tương đối của các đặc trưng cũng sẽ phải tăng theo, ảnh hưởng đến kích thước được chọn cho các vùng tiếp nhận.

Sau khi số lượng tầng đã được xác định, tiếp theo là xác định số lượng nơ-ron trên mỗi tầng. Tầng đầu tiên và tầng cuối cùng có số lượng nơ-ron đã xác định. Số lượng nơ-ron hợp lý cho các tầng giữa nên là bao nhiêu là một câu hỏi mở với không có câu trả lời lý thuyết "tốt nhất". Nếu mục tiêu là giữ cho số lượng tầng càng ít càng tốt, thì khả năng tính toán của mạng sẽ tăng lên một mức độ nào đó bằng cách tăng số lượng nơ-ron trên mỗi tầng.

Các yếu tố chính của việc xác định kiến trúc của một mạng nơ-ron được xác định đầy đủ khi xác định nút hàm kích hoạt. Trong chương này, chúng ta đã làm việc với các hàm sigmoid để đảm bảo tính thống nhất giữa các ví dụ. Nhưng cần lưu ý có các ứng dụng mà trong đó các hàm kích hoạt hyperbolic tangent và ReLU có hiệu suất huấn luyện tốt hơn.

Khi một kiến trúc mạng đã được xác định, huấn luyện mạng là yếu tố trung tâm để làm cho kiến trúc của mạng có thể hữu ích. Mặc dù các mạng chúng ta đã thảo luận trong chương này tương đối đơn giản, các mạng áp dụng cho các bài toán quy mô lớn có thể có hàng triệu nút và yêu cầu một lượng thời gian rất lớn để huấn luyện. Nếu có sẵn các tham số của một mạng đã được huấn luyện trước đây thì đó là giá trị khởi tạo lý tưởng cho việc huấn luyện thêm hoặc để chuẩn hoá hiệu năng nhận dạng. Một chủ đề trung tâm khác trong việc huấn luyện mạng nơ-ron là sử dụng card đồ hoạ - GPU để tăng tốc tính toán.

Một vấn đề thường gặp khi huấn luyện là quá khớp – over fitting, trong đó việc nhận dạng tập huấn luyện là tốt, nhưng tỷ lệ nhận dạng trên các mẫu không sử dụng cho việc huấn luyện lại thấp. Khi đó mạng không thể tổng quát hóa những gì đã được huấn luyện và áp dụng nó cho đầu vào chưa từng gặp trước đó. Khi dữ liệu huấn luyện bổ sung không có sẵn, phương pháp phổ biến nhất để giải quyết vấn đề này là làm phong phú tập dữ liệu huấn luyện một cách nhân tạo bằng cách sử dụng các biến đổi tạo thêm dữ liệu như biến đổi hình học và biến đổi cường độ. Các biến đổi được thực hiện với dữ liệu huấn luyện để được dữ liệu mới trong khi giữ nguyên lớp của các mẫu học được biến đổi. Một phương pháp chính khác là sử dụng kỹ thuật dropout, một kỹ thuật loại bỏ ngẫu nhiên các nút cùng với kết nối của chúng từ mạng nơ-ron trong quá trình huấn luyện. Ý tưởng là thay đổi tối thiểu kiến trúc của mạng để ngăn mạng thích ứng quá mức với một tập hợp cố định các tham số và gây ra hiện tượng quá khớp.


Ngoài tốc độ tính toán, một khía cạnh quan trọng khác của quá trình huấn luyện là hiệu suất. Có một số cách xử lý đơn giản như việc đảo các mẫu đầu vào ở đầu mỗi epoch huấn luyện có thể giảm thiểu hoặc loại bỏ khả năng bị "xoay tròn" là hiện tượng mà giá trị tham số có cập nhật nhưng lại lặp lại theo chu kỳ đều đặn. Stochastic Gradient Descent là một điều chỉnh quan trọng khác trong quá trình huấn luyện, trong đó, thay vì sử dụng toàn bộ dữ liệu huấn luyện, các mẫu được chọn ngẫu nhiên và đưa vào mạng. Chúng ta có thể xem điều này như việc chia bộ dữ liệu huấn luyện thành các cụm nhỏ - mini-batch, và sau đó chọn một mẫu từ mỗi cụm nhỏ. Phương pháp này thường dẫn đến kết quả hội tụ nhanh hơn trong quá trình huấn luyện.

Câu hỏi ôn tập và bài tập

Bài tập 1

(a) Tính các hàm quyết định của bộ phân loại khoảng cách tối thiểu cho các mẫu được hiển thị trong hình dưới đây. Bạn có thể thu được các vector trung bình cần thiết bằng cách đo đạc cẩn thận các mẫu.

(b) Vẽ đồ thị các bề mặt quyết định được thực hiện bởi các hàm quyết định ở (a).



(mọi câu hỏi liên quan có thể được giải đáp trong phần tương ứng trong quyền bài giảng)

Bài tập 2

Chứng minh rằng công thức dưới đây thực hiện cùng một công việc trong việc phân loại mẫu.

$$D_j(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}_j\| \quad j = 1, 2, \dots, N_c$$

$$d_j(\mathbf{x}) = \mathbf{m}_j^T \mathbf{x} - \frac{1}{2} \mathbf{m}_j^T \mathbf{m}_j \quad j = 1, 2, \dots, N_c$$

(mọi câu hỏi liên quan có thể được giải đáp trong phần tương ứng trong quyền bài giảng)

Bài tập 3

Chứng minh rằng bề mặt được cho bởi phương trình dưới đây là đường vuông góc của đoạn thẳng nối 2 điểm $\mathbf{m}_i$ và $\mathbf{m}_j$ trong không gian n chiều.

$$\begin{aligned} d_{ij}(\mathbf{x}) &= d_i(\mathbf{x}) - d_j(\mathbf{x}) \\ &= (\mathbf{m}_i - \mathbf{m}_j)^T \mathbf{x} - \frac{1}{2} (\mathbf{m}_i - \mathbf{m}_j)^T (\mathbf{m}_i + \mathbf{m}_j) = 0 \end{aligned}$$

(mọi câu hỏi liên quan có thể được giải đáp trong phần tương ứng trong quyền bài giảng)

Bài tập 4

Chứng minh cách bộ phân loại khoảng cách tối thiểu được thảo luận liên quan đến hình dưới đây có thể được thực hiện bằng cách sử dụng W ngân hàng điện trở (W là số lớp), một điểm nối tại mỗi ngân hàng (để tổng hợp dòng điện), và một bộ chọn lựa tối đa có khả năng chọn tối đa của W đầu vào, trong đó các đầu vào là dòng điện.

THƯ VIỆN PTIT

Chương 8

NÉN DỮ LIỆU ẢNH

Sau khi hoàn thành chương này, sinh viên có thể:

- ✓ Có khả năng đo lường lượng thông tin trong một hình ảnh kỹ thuật số.
- ✓ Hiểu rõ các nguồn chính của dữ liệu lặp lại trong hình ảnh kỹ thuật số.
- ✓ Biết sự khác biệt giữa nén mất mát và nén không mất mát, và mức độ nén có thể đạt được với mỗi phương pháp.
- ✓ Quen thuộc với các tiêu chuẩn nén ảnh phổ biến, như JPEG và JPEG-2000, được sử dụng ngày nay.
- ✓ Hiểu về các phương pháp chính của nén hình ảnh, và cách chúng hoạt động và tại sao chúng hoạt động.
- ✓ Có khả năng nén và giải nén hình ảnh xám, màu và video.

8.1. Giới thiệu

8.1.1. Một số khái niệm

Nén dữ liệu (Data Compression)

Nén dữ liệu nhằm làm giảm lượng thông tin “dư thừa” trong dữ liệu gốc và do vậy, lượng thông tin thu được sau khi nén thường nhỏ hơn dữ liệu gốc rất nhiều. Với dữ liệu ảnh, kết quả thường là 10:1. Một số phương pháp còn cho kết quả cao hơn. Theo kết quả nghiên cứu được công bố gần đây tại Viện Kỹ thuật Georfie, kỹ thuật nén fratal cho tỉ số nén là 30 trên 1 [6].

Ngoài thuật ngữ “nén dữ liệu”, do bản chất của kỹ thuật này nó còn có một số tên gọi khác như: giảm độ dư thừa, mã hóa ảnh gốc.

Từ hơn hai thập kỷ nay, có rất nhiều kỹ thuật nén đã được công bố trên các tài liệu về nén và các phần mềm nén dữ liệu đã xuất hiện ngày càng nhiều trên thương trường. Tuy nhiên, chưa có phương pháp nén nào được coi là phương pháp vạn năng (Universal) vì nó phụ thuộc vào nhiều yếu tố và bản chất của dữ liệu gốc. Trong chương này, chúng ta không thể hy vọng xem xét tất cả các phương pháp nén. Hơn thế nữa, các kỹ thuật nén dữ liệu chung đã được trình bày trong nhiều tài liệu chuyên ngành. Ở đây, chúng ta chỉ đề cập các phương pháp nén có đặc thù riêng cho dữ liệu ảnh.

Tỷ lệ nén (Compression Rate)

Tỷ lệ nén là một trong các đặc trưng quan trọng nhất của mọi phương pháp nén. Tuy nhiên, về cách đánh giá và các kết quả công bố trong các tài liệu cũng cần quan tâm xem xét. Nhìn chung, người ta định nghĩa tỷ lệ cơ bản của phương pháp nén. Nhiều khi tỷ lệ nén cao cũng chưa thể nói phương pháp đó hiệu quả hơn các phương pháp khác, vì còn các chi phí như thời gian, không gian và thậm chí cả độ phức tạp tính toán nữa. Thí dụ như nén phục vụ trong truyền dữ liệu: vấn đề đặt ra là hiệu quả nén có tương hợp với đường truyền không.

Cũng cần phân biệt dữ liệu với nén băng truyền. Mục đích chính của nén là giảm lượng thông tin dư thừa và dẫn tới giảm kích thước dữ liệu. Tuy vậy, đôi khi quá trình nén cũng làm giảm băng truyền tín hiệu số hóa thấp hơn so với truyền tín hiệu tương tự.

8.1.2. Các loại dư thừa dữ liệu

Như trên đã nói, nén nhằm mục đích giảm kích thước dữ liệu bằng cách loại bỏ dư thừa dữ liệu. Việc xác định bản chất các kiểu dư thừa dữ liệu rất có ích cho việc xây dựng các phương pháp nén dữ liệu khác nhau. Nói một cách khác, các phương pháp nén dữ liệu khác nhau là do sử dụng các kiểu dư thừa khác nhau. Người ta coi có 4 kiểu dư thừa chính:

- Sự phân bố ký tự:

Trong một dãy ký tự có một số ký tự có tần suất xuất hiện nhiều hơn so với các dãy khác. Do vậy, ta có thể mã hóa dữ liệu một cách cô đọng hơn. Các dãy ký tự có tần suất cao được thay bởi một từ mã nhị phân với số bit nhỏ; ngược lại các dãy có tần suất xuất hiện thấp sẽ được mã hóa bởi từ mã có nhiều bit hơn. Đây chính là bản chất của phương pháp mã hóa từ hóa Huffman.

- Sự lặp lại của các ký tự:

Kỹ thuật nén dùng trong trường hợp này là thay dãy lặp đó bởi dãy mới gồm hai thành phần: số lần lặp và kí hiệu dùng để mã. Phương pháp mã hóa kiểu này có tên là mã hóa loạt dài RLC (Run Length Coding).

- Những mẫu sử dụng tần suất:

Có thể có dãy ký hiệu nào đó xuất hiện với tần suất tương đối cao. Do vậy, có thể mã hóa bởi ít bit hơn. Đây là cơ sở của phương pháp mã hóa kiểu từ điển do Lempel-Ziv đưa ra và có cải tiến vào năm 1977, 1978 và do đó có tên gọi là phương pháp nén LZ77, LZ78. Năm 1984, Terry Welch đã cải tiến hiệu quả hơn và đặt tên là LZW (Lempel-Ziv-Welch).

- Độ dư thừa vị trí:

Do sự phụ thuộc lẫn nhau của dữ liệu, đôi khi biết được ký hiệu (giá trị) xuất hiện tại một vị trí, đồng thời có thể đoán trước sự xuất hiện của các giá trị ở các vị trí khác nhau một cách phù hợp. Chẳng hạn, ảnh biểu diễn trong một lưới hai chiều, một số điểm ở hàng dọc trong một khối dữ liệu lại xuất hiện trong cùng vị trí ở các hàng khác nhau. Do vậy, thay vì lưu trữ dữ liệu, ta chỉ cần lưu trữ vị trí hàng và cột. Phương pháp nén dựa trên sự dư thừa này gọi là phương pháp mã hóa dự đoán.

8.1.3. Phân loại phương pháp nén

Có nhiều cách phân loại các phương pháp nén khác nhau. Cách thứ nhất dựa vào nguyên lý nén. Cách này phân các phương pháp nén thành hai họ lớn:

- Nén chính xác hay nén không mất thông tin: họ này bao gồm các phương pháp nén mà sau khi giải nén ta thu được chính xác dữ liệu gốc.

- Nén có mất thông tin: họ này bao gồm các phương pháp mà sau khi giải nén ta không thu được dữ liệu như bản gốc. Phương pháp này lợi dụng tính chất của mắt người, chấp nhận một số vặn xoắn trong ảnh khi khôi phục lại. Tất nhiên, các phương pháp này chỉ có hiệu quả khi mà độ vặn xoắn chấp nhận được bằng mắt thường hay với dung sai nào đấy.

Cách phân loại thứ hai dựa vào cách thức thực hiện nén. Theo cách này, người ta cũng phân thành hai họ:

- Phương pháp không gian (Spatial Data Compression): Các phương pháp thuộc họ này thực hiện nén bằng các tác động trực tiếp lên việc lấy mẫu của ảnh trong miền không gian.

- Phương pháp sử dụng biến đổi (Transform Coding): gồm các phương pháp tác động lên sự biến đổi của ảnh gốc mà không tác động trực tiếp như họ trên.

Có một cách phân loại khác nữa, cách phân loại thứ ba, dựa vào triết lý của sự mã hóa. Cách này cũng phân các phương pháp nén thành hai họ

- Các phương pháp nén thế hệ thứ nhất: Gồm các phương pháp mà mức độ tính toán là đơn giản, thí dụ việc lấy mẫu, gán từ mã v.v.

- Các phương pháp nén thế hệ thứ hai: dựa vào độ bão hòa của tỷ lệ nén.

Trong cách trình bày dưới đây ta sẽ theo cách phân loại này.

8.2. Các phương pháp nén thể hệ thứ nhất

Trong lớp các phương pháp này, ta lần lượt xem xét các phương pháp:

- Mã hóa loạt dài RLC (Run Length Coding)
- Mã hóa Huffman
- Mã hóa LZW (Lempel Ziv-Wench)
- Mã hóa khối (Block Coding)

8.2.1. Phương pháp mã hóa loạt dài

Phương pháp mã hóa loạt dài lúc đầu được phát triển dành cho ảnh số 2 mức: mức đen (1), và mức trắng (0) như các văn bản trên nền trắng, trang in, các bản vẽ kỹ thuật.

Nguyên tắc của phương pháp là phát hiện một loạt các bit lặp lại, thí dụ như một loạt các bit 0 nằm giữa hai bit 1, hay ngược lại, một loạt bit 1 nằm giữa hai bit 0. Phương pháp này chỉ có hiệu quả khi chiều dài dãy lặp lớn hơn một ngưỡng nào đó. Dãy các bit lặp gọi là loạt hay mạch (run). Tiếp theo, thay thế chuỗi đó bởi một chuỗi mới gồm 2 thông tin: chiều dài chuỗi và bit lặp (ký tự lặp). Như vậy, chuỗi thay thế sẽ có chiều dài ngắn hơn chuỗi cần thay.

Cần lưu ý rằng, đối với ảnh, chiều dài của chuỗi lặp có thể lớn hơn 255. Nếu ta dùng 1 byte để mã hóa thì sẽ không đủ. Giải pháp được dùng là tách các chuỗi đó thành hai chuỗi: một chuỗi có chiều dài 255, chuỗi kia là số bit còn lại.

Phương pháp RLC được sử dụng trong việc mã hóa lưu trữ các ảnh Bitmap theo dạng PCX, BMP.

Phương pháp RLC có thể chia thành 2 phương pháp nhỏ: phương pháp dùng chiều dài tứ mã cố định và phương pháp thích nghi như kiểu mã Huffman. Giả sử các mạch gồm M bits. Để tiện trình bày, đặt $M = 2m - 1$. Như vậy mạch cũ được thay bởi mạch mới gồm m bits.

Với cách thức này, mọi mạch đều được mã hóa bởi từ mã có cùng độ dài. Người ta cũng tính được, với $M = 15$, $p = 0,9$, ta sẽ có $m = 4$ và tỷ số nén là 1,95.

Với chiều dài cố định, việc cài đặt thuật toán là đơn giản. Tuy nhiên, tỷ lệ nén sẽ không tốt bằng chiều dài biến đổi hay gọi là mã RLC thích nghi.

8.2.2. Phương pháp mã hóa Huffman

8.2.2.1. Nguyên tắc

Phương pháp mã hóa Huffman là phương pháp dựa vào mô hình thông kê. Dựa vào dữ liệu gốc, người ta tính tần suất xuất hiện của các ký tự. Việc tính tần suất được thực hiện bởi cách duyệt tuần tự tệp gốc từ đầu đến cuối. Việc xử lý ở đây tính theo bit. Trong phương pháp này người ta gán cho các ký tự có tần suất cao một từ mã ngắn, các ký tự có tần suất thấp từ mã dài. Nói một cách khác, các ký tự có tần suất càng cao được gán mã càng ngắn và ngược lại. Rõ ràng với cách thức này, ta đã làm giảm chiều dài trung bình của từ mã hóa bằng cách dùng chiều dài biến đổi. Tuy nhiên, trong một số tình huống khi tần suất là rất thấp, ta có thể không được lợi một chút nào, thậm chí còn bị thiệt một ít bit.

8.2.2.2. Thuật toán

Thuật toán bao gồm 2 bước chính:

- Giai đoạn thứ nhất: tính tần suất của các ký tự trong dữ liệu gốc: duyệt tệp gốc một cách tuần tự từ đầu đến cuối để xây dựng bảng mã. Tiếp sau đó là sắp xếp lại bảng mã theo thứ tự tần suất giảm dần.
- Giai đoạn thứ hai: mã hóa: duyệt bảng tần suất từ cuối lên đầu để thực hiện ghép 2 phần tử có tần suất xuất hiện thấp nhất thành một phần tử duy nhất. Phần tử này có tần suất bằng tổng 2 tần suất thành phần. Tiến hành cập nhật lại bảng và đương nhiên loại bỏ 2 phần tử đã

xét. Quá trình được lặp lại cho đến khi bảng chỉ có một phần tử. Quá trình này gọi là quá trình tạo cây mã Huffman vì việc tập hợp được tiến hành nhờ một cây nhị phân 2 nhánh. Phần tử có tần suất thấp ở bên phải, phần tử kia ở bên trái. Với cách tạo cây này, tất cả các bit dữ liệu/ký tự là nút lá; các nút trong là các nút tổng hợp. Sau khi cây đã tạo xong, người ta tiến hành gán mã cho các nút lá. Việc mã hóa rất đơn giản: mỗi lần xuống bên phải ta thêm 1 bit “1” vào từ mã; mỗi lần xuống bên trái ta thêm một bit “0”. Tất nhiên có thể làm ngược lại, chỉ có giá trên mã thay đổi còn tổng chiều dài là không đổi. Cũng chính do lý do này mà cây có tên gọi là cây mã Huffman như trên đã gọi.

Quá trình giải nén tiến hành theo chiều ngược lại khá đơn giản. Người ta cũng phải dựa vào bảng mã tạo ra trong giai đoạn nén (bảng này được giữ lại trong cấu trúc của tệp nén cùng với dữ liệu nén). Thí dụ, với một tệp dữ liệu mà tần suất các ký tự cho bởi:

Bảng 8.2.-1 Bảng tần suất theo thứ tự giảm dần

Ký tự	Tần suất	Xác suất
“0”	1532	0.0396
“6”	602	0.0696
“ ”	536	0.0275
“3”	412	0.0969
“5”	385	0.0746
“2”	323	0.1088
“-”	315	0.0167
“4”	226	0.0967
“+”	220	0.0203
“1”	152	0.277
“8”	112	0.0569
“7”	92	0.0585
“9”	87	0.0409

Lưu ý rằng, trong phương pháp Huffman, mã của ký tự là duy nhất và không mã nào là phần bắt đầu của mã khác. Vì vậy, khi đọc tệp nén từng bit từ đầu đến cuối ta có thể duyệt cây mã cho đến một lá, tức là ký tự đã được giải nén.

Bảng từ mã gán cho các ký tự bởi mã Huffman

“0”	10	“-”	110
“6”	10	“4”	11110
“ ”	1	“+”	11011
“.”	0	“1”	111111
“3”	1110	“8”	111110
“5”	1100	“7”	110101
“2”	111	“9”	110100

8.2.3. Phương pháp LZW

8.2.3.1. Mở đầu

Khái niệm nén từ điển được Jacob Lempel và Abraham Ziv đưa ra lần đầu tiên vào năm 1977, sau đó phát triển thành một họ giải thuật nén từ điển LZ. Năm 1984, Terry Welch đã cải tiến giải thuật LZ thành một giải thuật mới hiệu quả hơn và đặt tên là LZW. Phương pháp nén từ điển dựa trên việc xây dựng từ điển lưu các chuỗi ký tự có tần suất lặp lại cao và thay thế bằng từ mã tương ứng mỗi khi gặp lại chúng. Giải thuật LZW hay hơn các giải thuật trước nó ở kỹ thuật tổ chức từ điển cho phép nâng cao tỉ lệ nén.

Giải thuật nén LZW được sử dụng cho tất cả các loại file nhị phân. Nó thường được dùng để nén các loại văn bản, ảnh đen trắng, ảnh màu, ảnh đa mức xám... và là chuẩn nén cho các dạng ảnh GIF và TIFF. Mức độ hiệu quả của LZW không phụ thuộc vào số bit màu của ảnh.

8.2.3.2. Phương pháp

Giải thuật nén LZW xây dựng một từ điển lưu các mẫu có tần suất xuất hiện cao trong ảnh. Từ điển là tập hợp những cặp từ vựng và nghĩa của nó. Trong đó, từ vựng sẽ là các từ mã được sắp xếp theo thứ tự nhất định. Nghĩa là một chuỗi con trong dữ liệu ảnh. Từ điển được xây dựng đồng thời với quá trình đọc dữ liệu. Sự có mặt của một chuỗi con trong từ điển khẳng định rằng chuỗi đó đã từng xuất hiện trong phần dữ liệu đã đọc. Thuật toán liên tục “tra cứu” và cập nhật từ điển sau mỗi lần đọc một ký tự ở dữ liệu đầu vào.

Do kích thước bộ nhớ không phải vô hạn và để đảm bảo tốc độ tìm kiếm, từ điển chỉ giới hạn 4096 ở phần từ vựng để lưu lớn nhất là 4096 giá trị của các từ mã. Như vậy độ dài lớn nhất của từ mã là 12 bits ($4096 = 2^{12}$). Cấu trúc từ điển như sau:

+ 256 từ mã đầu tiên theo thứ tự từ 0...255 chứa các số nguyên từ 0...255. Đây là mã của 256 ký tự cơ bản trong bảng mã ASCII.

+ Từ mã thứ 256 chứa một mã đặc biệt là “mã xóa” (CC – Clear Code). Mục đích việc dùng mã xóa nhằm khắc phục tình trạng số mẫu lặp trong ảnh lớn hơn 4096. Khi đó một ảnh được quan niệm là nhiều mảnh ảnh, và từ điển là một bộ từ điển gồm nhiều từ điển con. Cứ hết một mảnh ảnh người ta lại gửi một mã xóa để báo hiệu kết thúc mảnh ảnh cũ, bắt đầu mảnh ảnh mới đồng thời khởi tạo lại từ điển cho mảnh ảnh mới. Mã xóa có giá trị là 256.

+ Từ mã thứ 257 chứa mã kết thúc thông tin (EOI – End Of Information). Mã này có giá trị là 257. Như chúng ta đã biết, một file ảnh GIF có thể chứa nhiều ảnh. Mỗi một ảnh sẽ được mã hóa riêng. Chương trình giải mã sẽ lặp đi lặp lại thao tác giải mã từng ảnh cho đến khi gặp mã kết thúc thông tin thì dừng lại.

+ Các từ mã còn lại (từ 258 đến 4095) chứa các mẫu thương lặp lại trong ảnh. 512 phần từ đầu tiên của từ điển biểu diễn bằng 9 bit. Các từ mã từ 512 đến 1023 biểu diễn bởi 10 bit, từ 1024 đến 2047 biểu diễn bởi 11 bit và từ 2048 đến 4095 biểu diễn bởi 12 bit.

8.2.3.3. Ví dụ minh họa cơ chế nén và giải nén của LZW

Cho chuỗi đầu vào là “ABCBBCABCABCD” (Mã ASCII của A là 65, B là 66, C là 67). Từ điển ban đầu gồm 256 ký tự cơ bản.

Đầu vào	Đầu ra	Thực hiện
A(65)		A đã có trong từ điển => Đọc tiếp
B(66)	65	Thêm vào từ điển mã 258 đại diện cho chuỗi AB
C(67)	66	Thêm vào từ điển mã 259 đại diện cho chuỗi BC
B	67	Thêm vào từ điển mã 260 đại diện cho chuỗi CB
C		BC đã có trong từ điển => Đọc tiếp
A	259	Thêm vào từ điển mã 261 đại diện cho chuỗi BCA
B		AB đã có trong từ điển => Đọc tiếp
C	258	Thêm vào từ điển mã 262 đại diện cho chuỗi ABC
A	67	Thêm vào từ điển mã 263 đại diện cho chuỗi CA
B		AB đã có trong từ điển => Đọc tiếp
C		ABC đã có trong từ điển => Đọc tiếp
D	262	Thêm vào từ điển mã 263 đại diện cho chuỗi

		ABCD
--	--	------

Chuỗi đầu ra sẽ là:

65 – 66 – 667 – 259 – 258 – 67 – 262

Đầu vào có kích thước: $12 \times 8 = 96$ bits. Đầu ra có kích thước là: $4 \times 8 + 3 \times 9 = 59$ bits. Tỷ lệ nén là $96 : 59 \cong 1,63$.

Giải nén dữ liệu nén bằng LZW

Giải thuật giải nén gần như ngược lại với giải thuật nén. Với giải thuật nén, một từ mã ứng với một chuỗi sẽ được ghi ra tệp khi chuỗi ghép bởi chuỗi trên với kí tự vừa đọc chưa có mặt trong từ điển. Người ta cũng cập nhật ngay vào từ điển từ mã ứng với chuỗi tạo bởi chuỗi cũ với kí tự vừa đọc. Kí tự này đồng thời là kí tự đầu tiên trong chuỗi tương ứng với từ mã sẽ được ghi ra tiếp theo. Đây là điểm mấu chốt cho phép xây dựng thuật toán giải nén.

Ví dụ: Giải nén chuỗi mã hoá nhận được như sau 66 – 65 – 256 – 257 – 65 – 260

Các bước như sau tương ứng với hình dưới kèm theo quá trình xây dựng từ điển trong quá trình giải mã:

66 có trong từ điển; chuỗi đầu ra (66) tức là B


65 có trong từ điển; chuỗi đầu ra (65) tức là A, chèn BA vào từ điển

256 có trong từ điển; chuỗi đầu ra (256) tức là BA, chèn AB vào từ điển

257 có trong từ điển; chuỗi đầu ra (257) tức là AB, chèn BAA vào từ điển

65 có trong từ điển; chuỗi đầu ra (65) tức là A, chèn ABA vào từ điển

260 không có trong từ điển; thuật toán giải mã thực hiện chuỗi đầu ra là kết quả đầu ra trước cộng với ký tự đầu tiên của kết quả đầu ra trước: AA, chèn AA vào từ điển.



Hình 8.1 Các bước giải mã và xây dựng từ điển trong quá trình giải mã 1 đoạn mã bằng phương pháp LZW.

8.2.4. Phương pháp mã hóa khối

8.2.4.1. Nguyên tắc

Phương pháp này lúc đầu được phát triển cho ảnh số 2 mức xám, sau đó hoàn thiện thêm bởi các phương pháp thích nghi và mở rộng cho ảnh số đa cấp xám.

Cho một ảnh số $I(x, y)$ kích thước $M \times N$. Người ta chia nhỏ ảnh số thành các khối hình chữ nhật kích thước $k \times l$ với k, l là rất nhỏ so với M, N . Như vậy ảnh gốc coi như gồm các khối con xếp cạnh nhau và có $N \times M / (k \times l)$ khối con.

Ta có thể dùng phương pháp mã hóa Huffman cho từng khối của ảnh gốc, nghĩa là gán cho

mỗi từ khối một từ mã nhị phân như ở phần trên. Một khó khăn gặp phải khi dùng mã hóa tối ưu Huffman đó là số lượng khối quá lớn. Giải pháp ở đây là dùng mã hóa gần tối ưu, đơn giản hơn để thực hiện mã hóa.

Giả thiết các khối là độc lập nhau và số cấu hình là 2^{kl} . Gọi $p(I, k, l)$ là xác suất xuất hiện cấu hình I , entropy tương ứng là:

$$H(h, l) = - \sum_{i=1}^{2kl} p(i, k, l) \log_2 p(i, k, l)$$

Giá trị $H(k, l)$ có thể được diễn giải là số bit/khối.

Các từ mã gán cho các khối kxl được tạo bởi các điểm trắng (cấu hình trội) là "0". Các từ mã gán cho các khối kxl khác gồm kxl màu ("1" cho đen, "0" cho trắng) đi tiếp sau bit 1 tiền tố "1".

Việc mã hóa theo số khối cũng được sử dụng nhiều trong các phương pháp khác để giảm bớt không gian lưu trữ.

8.2.4.2. Thuật toán

Giả sử $p(0, k, x)$ là xác suất của khối chỉ tạo bởi các điểm trắng đã biết, tỷ số nén có thể tính được dễ dàng. Xác suất này có thể được thiết lập bởi mô hình lý thuyết cho một khối đặc biệt. Do vậy, ta chia khối làm hai loại: khối một chiều và khối hai chiều.

+ Khối một chiều:

Xác suất $P(0, k, l)$ tính được nhờ vào mô hình của quá trình Markov bậc một. Ma trận dịch chuyển trạng thái Π :

$$\Pi = \begin{pmatrix} p(t/t) & p(d/t) \\ p(t/d) & p(d/d) \end{pmatrix} \quad (8.1)$$

Với:

- $p(t/t)$ là xác suất có điều kiện trắng sang trắng.

- $p(d/d)$ là xác suất có điều kiện đen sang đen. Các xác suất khác có ý nghĩa tương tự.

Như vậy:

$$p(0, k, 1) = p(t)p(t/t)^{k-1} \quad (8.2)$$

Điều này có thể giải thích như sau: xác suất xuất hiện một khối $k \times l$ chỉ gồm các điểm trắng bằng xác suất xuất hiện một điểm trắng tiếp theo $k - 1$ dịch chuyển trắng sang trắng.

Dựa vào các quan hệ trên, ta tính được tỉ số nén C_r .

$$C_r = \frac{l}{k[(1-p(t))p(t/t)^{k-1}] + l} \quad (8.3)$$

+Khối hai chiều

Xác suất $p(0, k, l)$ của các khối toàn trắng cũng tính được một cách tương tự như trên:

$$p(0, k, l) = p(t)p(t/t)^{k-1} [p(t/t)p(t/X=t, Y=t)^{l-1}]^{k-1} \quad (8.4)$$

Mối quan hệ này tương đương:

$$p(0, k, l) = p(t)p(t/t)^{k+l-2} p(t/X=t, Y=t)^{(l-1)(k-1)} \quad (8.5)$$

Và tỷ số nén sẽ cho bởi công thức:

$$C_r = \frac{1}{\left[(1-p(t))p(t/t)^{k+l-2} \right] + \frac{1}{kl}} \quad (8.6)$$

Thực tế, khi cài đặt người ta hay chọn khối vuông và giá trị thích hợp của k từ 4 đến 5.

8.2.5. Phương pháp thích nghi

Thuật ngữ “thích nghi” thường dùng để chỉ sự thích hợp của các từ mã theo một nghĩa nào đấy. Như trong phương pháp RLC ở trên, thay vì dùng chiều dài từ mã cố định m bit, người ta dùng chiều dài biến đổi và trên cơ sở đó có phương pháp RLC thích hợp.

Trong phương pháp mã hóa khối, người ta sử dụng chiều dài khối cố định gồm $k \times l$ điểm ảnh. Tuy nhiên, với ảnh không thuần nhất, phương pháp mã hóa này bộc lộ nhiều nhược điểm. Vì rằng, với ảnh không đồng nhất, chính sự không thuần nhất của ảnh quyết định sự thích nghi với điều kiện cục bộ.

Một cải tiến cho vấn đề này là cố định một kích thước của khối, còn kích thước kia coi như là hàm của một tác động trung bình theo hàng (với $l = 1$) hay theo một nhóm hàng ($l > 1$). Tác động được quan tâm cũng giống như các phương pháp là sự dịch chuyển các điểm trắng sang đen trên hàng.

Một cách lý thuyết người ta cũng tính được giá trị tối ưu của k (k_{opt} – viết tắt của k optimized):

$$k_{opt} = \begin{cases} \sqrt{\frac{N}{T}} & l = 1 \\ \sqrt{II} & l > 1 \end{cases} \quad (8.7)$$

Với N là số điểm ảnh trên hàng.

Trên cơ sở này, người ta áp dụng mã hóa khối tự động thích nghi cho một số ứng dụng:


- Mã đoạn hay khối $k \times 1$ tự động thích nghi với tác động cục bộ.
- Mã đoạn hay khối $k \times 1$ tự động thích nghi 1 chiều.
- Mã khối $k \times 1$ tự động thích nghi 2 chiều

8.2.6. Biến đổi Cosin và chuẩn nén JPEG

JPEG là viết tắt của Joint Photographic Expert Group (nhóm các chuyên gia phát triển ảnh này). Chuẩn JPEG được công nhận là chuẩn ảnh quốc tế năm 1990 phục vụ các ứng dụng truyền ảnh cho các lĩnh vực như y học, khoa học, kỹ thuật, ảnh nghệ thuật...

Chuẩn JPEG được sử dụng để mã hóa ảnh đa mức xám, ảnh màu. Nó không cho kết quả ổn định lắm với ảnh đen trắng. Chuẩn JPEG cung cấp giải thuật cho cả hai loại nén là nén không mất mát thông tin và nén mất mát thông tin. Trong phần dưới đây, chúng ta trình bày chi tiết về một trong các dạng nén biến đổi chấp nhận mất mát thông tin dùng biến đổi Cosin của chuẩn JPEG: Biến đổi Cosin tuần tự (Sequential DTC - based). Biến đổi Cosin tuần tự là kỹ thuật đơn giản nhất nhưng được dùng phổ biến nhất và nó đáp ứng được hầu hết các đặc tính cần thiết cho hầu lớn các ứng dụng.


Mã hóa JPEG bao gồm nhiều công đoạn, sơ đồ thuật toán nén và giải nén được mô tả dưới đây:



Hình 8.2 Sơ đồ thuật toán nén JPEG.

Quá trình giải nén sẽ được làm ngược lại, người ta giải mã từng phần ảnh nén tương ứng với phương pháp nén đã sử dụng trong phần nén nhờ các thông tin liên quan ghi trong phần Header của file nén. Kết quả thu được là hệ số đã lượng tử. Các hệ số này được khôi phục về giá trị trước khi lượng tử hóa bằng bộ tương tự hóa. Tiếp đó đem biến đổi Cosin ngược ta được ảnh ban đầu với độ trung thực nhất định.

Bảng mã và bảng lượng tử trong sơ đồ giải nén được dựng lên nhờ những thông tin ghi trong phần cấu trúc đầu tệp (Header) của file ảnh nén. Quá trình nén chịu trách nhiệm tạo ra và ghi lại những thông tin này. Phần tiếp theo sẽ phân tích tác dụng của từng khối trong sơ đồ.



Hình 8.3 Sơ đồ thuật toán giải nén JPEG.

8.2.6.1. Phần khối

Chuẩn nén JPEG phân ảnh ra các khối 8x8. Công đoạn biến đổi nhanh Cosin hai chiều cho các khối 8x8 tỏ ra hiệu quả hơn. Biến đổi Cosin cho các khối có cùng kích thước có thể giảm được một phần các tính toán chung như việc tính hệ số C_{ij} cho 3 tầng ($8 = 2^3$), số các hệ số là: $4 + 2 + 1 = 7$.

Nếu với một ảnh 1024×1024 , phép biến đổi nhanh Cosin một chiều theo hàng ngang hoặc hàng dọc ta phải qua 10 tầng ($1024 = 2^{10}$). Số các hệ số C_{ij} là: $512 + 256 + 128 + 64 + 32 + 16 + 8 + 4 + 2 + 1 = 1021$. Thời gian tính toán các hệ số C_{ij} với toàn bộ ảnh 1024×1024 lớn gấp 150 lần so với thời gian tính toán các hệ số này cho các khối.

Biến đổi Cosin đối với các khối có kích thước nhỏ sẽ làm tăng độ chính xác khi tính toán với số dấu phẩy tính, giảm thiểu sai số do làm tròn sinh ra.

Do điểm ảnh hàng xóm có độ tương quan cao hơn, do đó phép biến đổi Cosin cho từng khối nhỏ sẽ tập trung năng lượng hơn và một số ít các hệ số biến đổi. Việc loại bớt một số hệ số năng lượng thấp trong các khối chỉ tạo ra mất mát thông tin cục bộ giúp nâng cao chất lượng ảnh.

Ảnh sẽ được chia làm B khối với:

$$B = \left(\frac{M'}{k} \right) \times \left(\frac{N'}{l} \right) = M_B \times N_B$$

Các khối được xác định bởi bộ số (m, n) với $m = [0 \dots M_B - 1]$ và $n = [0 \dots N_B - 1]$, ở đây m chỉ thứ tự của khối theo chiều rộng, n chỉ thứ tự của khối theo chiều dài. Phân tích khối thực chất là xác định tương quan giữa tọa độ riêng trong khối với tọa độ thực của điểm ảnh trong ảnh ban đầu. Nếu ảnh ban đầu kí hiệu Image[i, j] thì ma trận biểu diễn khối (m, n) là $x[u, v]$ được tính như sau:

$$x[u, v] = \text{Image}[mk + u, nl + v]$$

8.2.6.2. Biến đổi Cosin

Biến đổi là một trong những công đoạn lớn trong các phương pháp nén sử dụng phép biến đổi. Nhiệm vụ của công đoạn biến đổi là tập trung năng lượng vào một số ít các hệ số biến đổi.

Công thức biến đổi cho mỗi khối là:

$$X(k_1, k_2) = \frac{\varepsilon_{k1} \varepsilon_{k2}}{4} \sum_{n1=0}^7 \sum_{n2=0}^7 x(n_1, n_2) \cos \frac{(2n_1+1)k_1\pi}{16} \cos \frac{(2n_2+1)k_2\pi}{16}$$

Trong đó:

$$\varepsilon_{k1} = \begin{cases} \frac{1}{\sqrt{2}} & \text{khi } k1 = 0 \\ 0 & \text{khi } 0 < k1 < 8 \end{cases} \quad \varepsilon_{k2} = \begin{cases} \frac{1}{\sqrt{2}} & \text{khi } k2 = 0 \\ 0 & \text{khi } 0 < k2 < 8 \end{cases}$$

Thuật toán biến đổi nhanh Cosin hai chiều cho mỗi khối trong trường hợp này sẽ bao gồm 16 phép biến đổi nhanh Cosin một chiều. Đầu tiên, người ta biến đổi nhanh Cosin một chiều cho các dãy điểm ảnh trên mỗi hàng. Lần lượt thực hiện cho 8 hàng. Sau đó đem biến đổi nhanh Cosin một chiều theo từng cột của ma trận vừa thu được sau 8 phép biến đổi trên. Cũng lần lượt thực hiện cho 8 cột. Ma trận cuối cùng sẽ là ma trận hệ số biến đổi của khối tương ứng.

Trong sơ đồ giải nén ta phải dùng phép biến đổi Cosin ngược. Công thức biến đổi ngược cho khối 8x8 như sau:

$$x(n_1, n_2) = \frac{\varepsilon_{k1} \varepsilon_{k2}}{4} \sum_{k1=0}^7 \sum_{k2=0}^7 X(k_1, k_2) \cos \frac{(2n_1+1)k_1\pi}{16} \cos \frac{(2n_2+1)k_2\pi}{16}$$

trong đó:

$$\varepsilon_{k1} = \begin{cases} \frac{1}{\sqrt{2}} & \text{khi } k1 = 0 \\ 0 & \text{khi } 0 < k1 < 8 \end{cases} \quad \varepsilon_{k2} = \begin{cases} \frac{1}{\sqrt{2}} & \text{khi } k2 = 0 \\ 0 & \text{khi } 0 < k2 < 8 \end{cases}$$

8.2.6.3. Lượng tử hóa

Khối lượng tử hóa trong sơ đồ nén đóng vai trò quan trọng và quyết định tỉ lệ nén của chuẩn nén j. Đầu vào của khối lượng tử hóa là các ma trận hệ số biến đổi Cosin của các khối điểm

ảnh.

Để giảm số bộ lượng tử, người ta tìm cách quy các hệ số ở các khối về cùng một khoảng phân bố. Chuẩn nén j chỉ sử dụng một bộ lượng tử hóa. Giả sử rằng các hệ số đều có hàm tính xác suất xuất hiện như nhau.

Chúng ta sẽ căn chỉnh lại hệ số y_j bằng phép gán:

$$y_j = \frac{y_j - \mu_j}{\sigma_j}$$

Với μ_j là trung bình cộng của hệ số thứ j ; σ_j là độ lệch cơ bản của hệ số thứ j .

Như vậy chúng ta sẽ đồng nhất được mức quyết định và mức tạo lại cho tất cả các hệ số. Do đó, các hệ số được biểu diễn cùng bằng một số lượng bit. Có nhiều cách tiếp cận để tính được các mức quyết định và mức tạo lại. Lloyd – Max đưa ra giải thuật sau:

Bước 1: Chọn giá trị khởi tạo:

$$d_0 = y_L$$

$$d_N = y_H$$

$$r_0 = d_0$$

N là mức lượng tử

Bước 2: Cho i biến thiên từ i đến $N-1$ thực hiện các công việc sau:

a. Tính d_i theo công thức:

$$r_{i-1} = \frac{\int_{d_{i-1}}^{d_i} y \cdot p(y) dy}{\int_{d_{i-1}}^{d_i} p(y) dy}$$

b. Tính r_i theo công thức:

$$r_i = 2d_i - r_{i-1}$$

Bước 3: Tính

$$r^t = \frac{\int_{d_{N-1}}^{d_N} y \cdot p(y) dy}{\int_{d_{N-1}}^{d_N} p(y) dy}$$

Bước 4: Nếu $r_{N-1} \neq r^t$ điều chỉnh lại r_0 và lặp lại từ bước 2 đến bước 4.

Trong quá trình cài đặt tạo ra một bộ lượng tử hóa, Lloyd và Max đã có nhiều cải tiến để tính toán dễ dàng hơn. Xác định d_1 bằng công thức trong bước 2a được tiến hành theo phương pháp Newton-Raphson. Sau đây là các bước mô tả toàn bộ công việc của khối lượng tử hóa tác động lên các hệ số biến đổi Cosin:

Bước 1: Tính trung bình cộng μ và độ lệch cơ bản σ cho từng hệ số ở mỗi vị trí trong khối

$$\sigma_j = \frac{\sum y_i}{n}$$

$$\sigma_i = \frac{n \sum y_j^2 - (\sum y_j)^2}{n(n-1)}$$

Với y_j là hệ số thứ j , n là số khối.

Bước 2: Lựa chọn tỉ lệ số hệ số giữ lại trong một khối.

Bước 3: Giữ lại các hệ số có độ lệch cơ bản lớn hơn

Bước 4: Lập ma trận T sao cho: $T_{ij} = 1$ nếu hệ số (i,j) được giữ lại.

Bước 5: Căn chỉnh lại giá trị của các hệ số xoay chiều được giữ lại ở các khối:

$$C_{ij} = \frac{C_{ij} - \mu_{ij}}{\sigma_{ij}}$$

Bước 6: Tính phân bố của các giá trị xoay chiều đã căn chỉnh.

Bước 7: Tính độ lệch cơ bản σ_i của các phân bố vừa tính.

Bước 8: Lượng tử hóa các hệ số xoay chiều bằng cách sử dụng bộ lượng tử Lloyd-Max sau khi đã điều chỉnh mức quyết định và mức tạo lại của nó theo cách sau:

$$d_i \Leftarrow d_i \times \sigma_i$$

$$r_i \Leftarrow r_i \times \sigma_i$$

$$dN = -d0$$

Thành phần một chiều sẽ không lượng tử hóa. Đến đây, ta chuyển sang bước nén.

8.2.6.4. Nén dữ liệu

Đầu vào của khối nén gồm hai thành phần: thành phần các hệ số một chiều và thành phần các hệ số xoay chiều.

Thành phần các hệ số một chiều $C_i(0, 0)$ với $i = 0, 1, \dots, 63$ chứa phần lớn năng lượng tín hiệu ảnh. Người ta không nén trực tiếp các giá trị $C_i(0, 0)$ mà xác định độ lệch của $C_i(0, 0)$: $d_i = C_{i+1}(0, 0) - C_i(0, 0)$; d_i có giá trị nhỏ hơn nhiều so với C_i nên trong biểu diễn dấu phẩy động theo chuẩn IEE754 thường chứa nhiều chuỗi bit 0 nên có thể cho hiệu suất nén cao hơn. Giá trị $C_0(0, 0)$ và các độ lệch d_i , được ghi ra một tệp tạm. Tệp này được nén bằng phương pháp nén Huffman.

Thành phần các hệ số xoay chiều $C_1(m, n)$ với $1 \leq m \leq 7, 1 \leq n \leq 7$ chứa các thông tin chi tiết của ảnh. Để nâng cao hiệu quả nén cho mỗi bộ hệ số trong một khối, người ta xếp chúng lại theo thứ tự ZigZag.

Tác dụng của sắp xếp lại theo thứ tự ZigZag là tạo ra nhiều loại hệ số giống nhau. Chúng ta biết rằng năng lượng của khối hệ số giảm dần từ góc trên bên trái xuống góc dưới bên phải nên việc sắp xếp lại các hệ số theo thứ tự ZigZag sẽ tạo điều kiện cho các hệ số xấp xỉ nhau (cùng mức lượng tử) nằm trên một dòng.

Mỗi khối ZigZag này được mã hóa theo phương pháp RLE. Cuối mỗi khối đầu ra của RLE, ta đặt dấu kết thúc khối EOB (End Of Block). Sau đó, các khối được dồn lại và mã hóa một lần bằng phương pháp mã Huffman. Nhờ có dấu kết thúc khối nên có thể phân biệt được hai khối cạnh nhau khi giải mã Huffman. Hai bảng mã Huffman cho hai thành phần hệ số tất nhiên sẽ khác nhau.

Để có thể giải nén được, chúng ta phải ghi lại thông tin như: kích thước ảnh, kích thước khối,

ma trận Y, độ lệch tiêu chuẩn, các mức tạo lại, hai bảng mã Huffman, kích thước khối nén một chiều, kích thước khối nén xoay chiều... và ghi nối tiếp vào hai file nén của thành phần hệ số.

Cài đặt giải thuật cho nén thực sự phức tạp. Chúng ta phải nắm được các kiến thức về nén RLE, Huffman, biến đổi Cosin, xây dựng bộ lượng tử hóa Lloyd-Max... Nén và giải nén hơi chậm nhưng bù lại, thời gian truyền trên mạng nhanh hơn do kích thước tệp nén nhỏ.

Với những ưu điểm của mình được ISO chấp nhận là chuẩn ảnh quốc tế và được biết đến dưới mã số ISO 10918-1.

8.3. Các phương pháp nén thể hệ thứ hai

8.3.1. Phương pháp Kim tự tháp Laplace - Laplacian Pyramids

Phương pháp này là tổ hợp của hai phương pháp: Mã hóa thích nghi và biến đổi. Tỷ số nén là khá cao, thường là 10:1. Về nguyên tắc, phương pháp này dựa vào mô hình phân cấp quan sát của con người.

Bắt đầu từ ảnh gốc $x(m, n)$ qua bộ lọc dải thấp ta thu được tín hiệu $x_1(m, n)$. Bộ lọc này được thiết kế để tính trung bình cục bộ dựa vào đáp ứng xung 2 chiều gần với đường cong Gauss. Bộ lọc này đóng vai trò “dự đoán” với sai số $e_1(m, n)$ tính bởi:

$$e_1(m, n) = x(m, n) - x_1(m, n)$$

Như vậy là mã hóa của $x_1(m, n)$ và $e_1(m, n)$ là tương đương với mã hóa của $x(m, n)$. Với cách biến đổi như trên $e_1(m, n)$ thuộc loại dải cao. Vì mắt người ít cảm nhận được tín hiệu với tần số cao nên ta có thể dùng một lượng bit ít hơn để mã hóa cho nó. Mặt khác tín hiệu $x_1(m, n)$ thuộc loại dải thấp, nên theo lý thuyết sẽ lấy mẫu số mẫu sẽ ít hơn.

Quá trình này được lặp lại bằng cách dùng các bộ lọc thấp khác nhau và ta sẽ thu được các tín hiệu $x_i(m, n)$, $i=1,2,\dots$ Với mỗi lần lặp kích thước của ảnh sẽ giảm đi một lượng bằng f_i/f_{i+1} . Theo cách này, ta có một cấu trúc xếp chồng tự như cấu trúc Kim tự tháp mà kích thước giảm dần từ gốc đến đỉnh. Nhân chập Gauss được dùng ở đây có kích thước 5×5 . Các tín hiệu ra sau đó được lượng hóa và mẫu hóa.

Theo một số kết quả đã công bố, với bộ lọc giải thấp một chiều tách được với các trọng số: $g(0) = 0,7$, $g(-1) = g(1) = 0,25$ và $g(-2) = g(2) = 0,1$. Tỷ số nén dao động từ 6/1 đến 32/1. Tuy nhiên, nếu tỷ số nén cao thì ảnh kết quả sẽ có biến dạng.

8.3.2. Phương pháp mã hóa dựa vào biểu diễn ảnh

Như đã biết, trong xử lý ảnh tùy theo các ứng dụng mà ta cần toàn bộ ảnh hay chỉ những đặc tính quan trọng của ảnh. Các phương pháp phân vùng ảnh trong chương sáu như hợp vùng, tách, tách và hợp là rất hữu ích và có thể để nén ảnh. Có thể có nhiều phương pháp khác, song dưới đây chúng ta chỉ đề cập đến hai phương pháp: vùng gia tăng và phương pháp tách hợp.

8.3.2.1. Mã hóa dựa vào vùng gia tăng

Kỹ thuật vùng gia tăng thực chất là hợp các vùng có cùng một tính chất nào đó. Kết quả của nó là một ảnh được phân đoạn giống như một ô trong trò xếp chữ (Puzzle). Tuy nhiên, cần lưu ý rằng tất cả các đường bao thu được không tạo nên một ảnh giống ảnh gốc.

Việc xác định tính chất miền đồng nhất xác định độ phức tạp của phương pháp. Để đơn giản, tiêu chuẩn chọn ở đây là khoảng mức xám. Như vậy, miền đồng nhất là tập hợp các điểm ảnh có mức xám thuộc khoảng đã chọn. Cũng cần lưu ý thêm rằng, ảnh gốc có thể có đường bao và các kết cấu (Texture). Trong miền texture, độ xám biến đổi rất chậm. Do vậy, nếu không chú ý sẽ chia ảnh thành quá nhiều miền và gây nên các bao giả. Giải pháp để khắc phục hiện tượng này là ta dùng một bộ lọc thích hợp hay lọc trung vị.

Sau giai đoạn này, ta thu được ảnh phân đoạn với các đường viền kín, độ rộng 1 pixel. Để loại bỏ các đường bao giả, ta có thể dùng phương pháp gradient. Sau khi đã thu được các đường bao đúng, người ta tiến hành mã hóa (xấp xỉ) đường bao bởi các đường cong trong hình học, ví dụ bởi các đoạn thẳng hay đường cong. Nếu ảnh gốc có độ phân giải không thích hợp, người ta dùng khoảng 1,3 bit cho một điểm biên.

Phương pháp này thể hiện ưu điểm: đó là mô hình tham số. Các tham số ở đây là số vùng, độ chính xác mô tả. Tuy nhiên, tham số khoảng mức xám là quan trọng nhất vì nó có ảnh hưởng đến tỉ số nén. Một tham số cũng không kém phần quan trọng là số điểm của các đường bao bị coi là giả. Thường số điểm này không vượt quá 20 điểm.

8.3.2.2. Phương pháp tách - hợp

Cũng như đã chỉ ra trong chương sáu, phương pháp tách - hợp khắc phục được một số nhược điểm của phương pháp phân vùng dựa vào tách vùng hay hợp vùng. Trong phương pháp mã hóa này, người ta thay tiêu chuẩn chọn vùng đơn giản ở trên bằng một tiêu chuẩn khác hiệu quả hơn.

Nguyên tắc chung của phương pháp mô hình biên - texture. Nhìn chung đường biên dễ nhạy cảm với mắt người, còn texture thì ít nhạy cảm hơn. Người ta mong muốn rằng đường phân ranh giữa các vùng là đồng nhất với các đường bao. Lưu ý rằng cần quyết định phân vùng một phần của ảnh sao cho nó không được vắt chéo đường bao. Đây là một tiêu chuẩn kiểm tra quan trọng. Các đường bao thường nhận được bởi các bộ lọc thông cao, đẳng hướng.

Để có thể quản lý các điểm thuộc một vùng một cách tốt hơn, tiêu chuẩn kiểm tra thứ hai cũng được xem xét đó là dấu: “các điểm nằm về một phía của đường bao có cùng dấu”.

Nhìn chung, phương pháp gồm hai giai đoạn. giai đoạn đầu thực hiện việc tách vùng, giai đoạn sau thực hiện việc hợp vùng.

Quá trình tách thực hiện trước. Người ta chia ảnh gốc thành các vùng nhỏ kích thước 9×9 . Tiếp theo, tiến hành xấp xỉ các vùng ảnh đó bằng một đa thức có bậc nhỏ hơn 3. Sau quá trình tách ta thu được trong một số vùng của ảnh các hình vuông liên tiếp. chúng sẽ tạo nên một miền gốc lớn và không nhất thiết vuông. Như vậy, trong trường hợp này phải xấp xỉ bằng rất nhiều các đa thức giống nhau. Rõ ràng là việc mã hóa riêng biệt các đa thức là điều kiện hiệu quả và người nghĩ đến hợp các vùng để giảm độ dư thừa này.

Quá trình hợp được tiến hành như sau: nếu hai vùng có thể được xấp xỉ bởi 2 đa thức tương tự, người ta hợp chúng làm một và chỉ dùng một đa thức xấp xỉ. Nếu mức độ thay đổi là thấp, ta sẽ có nhiều cặp vùng tương tự. Để có thể nhận được kết quả không phụ thuộc vào lần hợp đầu, người ta xây dựng đồ thị “vùng kề cận”. Các nút của đồ thị này là các vùng và các liên hệ biểu diễn mối không tương đồng. Sự liên hệ với mức không tương đồng thấp chỉ ra rằng hai vùng cần hợp lại.

Sau bước hợp này, đồ thị được cập nhật lại và quá trình hợp được lặp lại cho đến khi tiêu chuẩn là thỏa mãn. Quá trình hợp dừng có thể quyết định bởi chất lượng ảnh nén hay một tiêu chuẩn nào khác.

Ta có thể thấy rằng phương pháp này khá phức tạp song bù lại nó cho tỉ số nén khá cao 60:1.

8.4. Kết luận

Mỗi phương pháp nén đều có những ưu điểm và nhược điểm. Tính hiệu quả của phương pháp không chỉ phụ thuộc vào tỉ số nén mà còn vào nhiều chỉ tiêu khác như: độ phức tạp tính toán, nhạy cảm với nhiễu, chất lượng, kiểu ảnh, v.v...

Nén là một vấn đề lớn được quan tâm nhiều và có liên quan đến nhiều lĩnh vực khác nhau. Chúng ta không hi vọng có thể trình bày tất cả trong một chương. Song dù sao, chương này cũng cung cấp một số khái niệm về các phương pháp khả dụng và một số phương pháp mới

về nén dữ liệu nhất là nén ảnh. Bảng tổng kết dưới đây cung cấp cho chúng ta một cách nhìn tương đối toàn diện về các phương pháp nén.

Bảng so sánh kết quả một số phương pháp nén

Phương pháp	Tỷ số nén	Độ phức tạp	Chất lượng	Nhạy cảm với nhiễu	Kiểu ảnh
RLC	10	Đơn giản	Rất tốt	Lớn	Nhị phân
Dự đoán	2-4	Đơn giản	Rất tốt	Trung bình	Mọi ảnh
Biến đổi	10-15	Phức tạp	Tốt	Rất kém	Đa cấp xám
Laplacian Pyramids	5-10	Trung bình	Tốt	Lớn	Đa cấp xám
Vùng gia tăng	20-30	Phức tạp	Trung bình	Rất lớn	Đa cấp xám
Tách và hợp	60-70	Rất phức tạp	Trung bình	Rất lớn	Đa cấp xám

Câu hỏi ôn tập và bài tập

Bài tập 1

Viết một chương trình nén và giải nén theo phương pháp RLC (đơn giản, dọc, ngang, hay kết hợp)

Bài tập 2

Viết một chương trình nén và giải nén theo phương pháp Huffman.

Bài tập 3

Viết một chương trình nén và giải nén theo phương pháp LZW.

Bài tập 4

Viết thủ tục thực hiện biến đổi Cosin thuận.

Bài tập 5

Viết thủ tục thực hiện biến đổi Cosin ngược

Bài tập 6

Viết thủ tục thực hiện lượng tử hóa theo thuật toán Lloyd – Max.

Bài tập 7

Thực hiện mã hóa ảnh sau bằng thuật toán Huffman. Được biết ảnh được chia làm các khối kích thước 2x2 để làm đơn vị mã hóa (Mỗi khối này sẽ như là một chữ cái của bức ảnh).

$$I = \begin{bmatrix} 1 & 1 & 1 & 0 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 1 & 0 & 1 & 1 & 1 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 1 & 1 & 1 & 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 1 & 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 & 1 & 1 & 0 & 1 & 1 & 0 & 1 & 1 & 1 & 0 & 1 & 0 & 0 & 1 & 1 \end{bmatrix}$$

Bài tập 8

Thực hiện mã hóa sau đó giải mã ảnh sau bằng kỹ thuật LZW. Được biết ảnh được chia làm các khối kích thước 1x2 để làm đơn vị mã hóa. Và từ điển gốc bao gồm 4 đơn vị mã hóa sau 00, 01, 10, 11 tương đương với giá trị từ 0 đến 3, từ điển sẽ được xây dựng tiếp theo từ giá trị 4. Bức ảnh sẽ được đọc từ trái qua phải và từ trên xuống dưới. Coi từ điển là đủ lớn để không thiếu chỗ.

$$I = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 1 & 1 & 0 & 0 & 0 \end{bmatrix}$$

TÀI LIỆU THAM KHẢO

- [1] Phạm Việt Bình (2007), *Phát triển kỹ thuật dò biên, phát hiện biên và ứng dụng*, Luận án Tiến sỹ.
- [2] Phạm Việt Bình (2006), “Một số tính chất của phép toán hình thái và ứng dụng trong phát hiện biên”, *Tạp chí Tin học và Điều khiển học*, Tập 22, số 2, 2006, 155-163.
- [3] Phạm Việt Bình, Cao Lê Mạnh Hà, Đỗ Năng Toàn (2005), “Một cách tiếp cận mới trong phát hiện biên của ảnh đa cấp xám”, *Kỷ yếu Hội thảo Quốc gia lần thứ 8 - Một số vấn đề chọn lọc của Công nghệ Thông tin và Truyền thông*, Hải Phòng 25-27/08 /2005, Nxb KH&KT, Hà Nội 2006, 92-102.
- [4] Phạm Việt Bình, Ngô Mạnh Hùng, Đỗ Năng Toàn (2005), “Một cải tiến thuật toán dò biên và ứng dụng trong làm mảnh đối tượng”, *Kỷ yếu Hội thảo Khoa học Quốc gia lần thứ 2 - nghiên cứu cơ bản và ứng dụng Công nghệ Thông tin-FAIR '05*, TP Hồ Chí Minh 23-24/09/2005, Nxb KH&KT, Hà Nội 2006, 477-485.
- [5] Đỗ Năng Toàn, Phạm Văn Dũng, Phạm Việt Bình (2005), “Ứng dụng chu tuyến trong phát hiện góc nghiêng văn bản”, *Kỷ yếu Hội thảo Quốc gia lần thứ 7 - Một số vấn đề chọn lọc của Công nghệ Thông tin và Truyền thông*, Đà Nẵng 18-20/08 /2004, Nxb KH&KT, Hà Nội 2005, 432-441.
- [6] Đỗ Năng Toàn, Phạm Việt Bình (2004), “Một thuật toán cắt chữ in dính ở mức từ dựa vào chu tuyến”, chuyên san Các công trình nghiên cứu và triển khai Công nghệ Thông tin và Viễn thông, *Tạp chí Bưu chính Viễn thông & Công nghệ Thông tin*, số 12 tháng 8/2004, 50-56.
- [7] Lương Mạnh Bá, Nguyễn Thanh Thủy (2002), *Nhập Môn Xử lý ảnh số*, Nxb Khoa học và Kỹ thuật, 2002.
- [8] Ngô Quốc Tạo, Đỗ Năng Toàn (2001), “Tách bảng dựa trên tập các hình chữ nhật rời rạc”, chuyên san Các công trình nghiên cứu và triển khai Công nghệ thông tin và viễn thông, *Tạp chí Bưu chính Viễn thông*, số 5 năm 2001, 73-79.
- [9] Đỗ Năng Toàn (2001), *Nghiên cứu một số phương pháp biểu diễn hình dạng và ứng dụng trong nhận dạng ảnh*, Luận án Tiến sỹ.
- [10] J.R. Paker (1997), *Algorithms for Image processing and Computer Vision*. John Wiley & Sons, Inc.
- [11] Randy Crane (1997), *A simplified approach to image processing*, Prentice-Hall, Inc.
- [12] John C. Russ (1995), *The Image Procesing Handbook*. CRC Press, Inc.
- [13] Adrian Low (1991), *Introductory Computer Vision and Image Processing*, Copyright (c) 1991 by McGrow Hill Book Company (UK) Limited.
- [14] Anil K. Jain (1989), *Fundamental of Digital Image Processing*. Prentice Hall, Engwood cliffs.
- [15] T. Pavlidis (1982), *Algorithms for Graphics and Image Processing*, Computer Science Press.
- [16] Rafael Gonzalez (2018), *Digital Image Processing*, Pearson Education
- [17] Simon J. D. Prince (2012) *Computer Vision: Models, Learning, and Inference*, Cambridge University Press.

- [18] Bo, Liefeng, Xiaofeng Ren, and Dieter Fox. "Kernel descriptors for visual recognition." *Advances in neural information processing systems* 23 (2010).
- [19] Wang, P., Wang, J., Zeng, G., Xu, W., Zha, H., & Li, S. (2013). Supervised kernel descriptors for visual recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2858-2865).
- [20] Từ Minh Phương (2014) Giáo trình nhập môn Trí tuệ nhân tạo, Học viện Công nghệ Bưu chính Viễn thông.

THƯ VIỆN PTIT